



TU Clausthal

硕士学位论文

作者：

Yu Zhang

**解释现实：基于基础模型与视觉事实提取的  
沉浸式仿真中的证据驱动程序性教学**

第一导师： Prof. Dr. Christian Bartelt

第二导师： Prof. Dr. Rüdiger Ehlers

5<sup>th</sup> June 2026

软件与系统工程研究所  
克劳斯塔尔工业大学

## 原创性声明

本人已阅读并理解克劳斯塔尔工业大学以及 ISSE 公告中发布的各项指南，包括关于使用文献及其他来源的规定。本人确认已独立完成本论文。任何取自其他来源并在本论文中复制的信息均已明确标注。

根据通用考试条例，本论文尚未提交至任何其他考试机构。

本人特此同意，本人的硕士学位论文可在本研究所图书馆内展出并供查阅。

克劳斯塔尔-采勒费尔德，5<sup>th</sup> June 2026

地点，日期

Yu Zhang

# 摘要

在高保真仿真环境中进行程序性学习面临着独特的挑战：学习者必须执行固定、有序的动作序列，同时验证中间系统状态、从错误中恢复并保持态势感知——这一切都在没有专家教员持续在场的情况下完成。传统的培训辅助手段（如视频演示和纸质检查单）会打断仿真器内练习的连续性，而缺乏依据的语言模型辅助则存在提供流畅但事实性错误指导的风险。本文提出一个基于遥测的教学运行时系统，它结合了程序包驱动的状态跟踪、检索增强的语言模型辅助生成，以及用于从座舱显示器中提取结构化视觉事实的微调视觉语言模型（VLM）。该系统强制实施显式的证据溯源：每个叠加目标和步骤推荐都必须可追溯到遥测变量、门控规则、检索到的文档片段或视觉事实观察。训练场景为 DCS World 中 F/A-18C 的冷启动程序，涵盖六个操作阶段的 25 个步骤，其步骤间依赖关系使其成为序列敏感、状态依赖型程序性任务的代表性案例。一项核心发现是，视觉事实本体设计决定了模型可靠性：通过将复合目标分解为可局部验证的视觉原子，从 8 事实 v1 本体演进到 13 事实 v2 本体，在独立留出集上将关键假阳性减少了 64–89%，由此得出一个设计原则：VLM 应提取可观察的证据，而程序性解释应归于下游推理。VLM 适配流水线——包括截图捕获、预标注、人工审查、双语监督微调、LoRA 适配和自动化基准测试——在两个骨干架构上进行了展示。在 13 事实本体上，基于 928 条双语训练数据训练的 Qwen3.5-9B LoRA 适配器将事实准确率从基础模型的 0.80–0.87 提升至两个独立留出集上的 0.99（已核实训练数据零重叠）。相同的训练数据方案应用于 Gemma-4-31B 也证实了该改进在不同骨干架构间的泛化性。本文交付了一个可运行的双平台运行时系统，包含自动化测试、基准测试工件和回放基础设施，以及一份为下一阶段人因研究准备的文档化评估设计。

# Zusammenfassung

Prozedurales Lernen in hochrealistischen Simulationsumgebungen stellt besondere Herausforderungen: Lernende müssen feste, geordnete Handlungsabfolgen ausführen, während sie Zwischenzustände des Systems überprüfen, Fehler korrigieren und das Situationsbewusstsein aufrechterhalten—und dies ohne die ständige Anwesenheit eines erfahrenen Ausbilders. Herkömmliche Trainingshilfen wie Videoanleitungen und gedruckte Checklisten unterbrechen den Übungsfluss im Simulator, während nicht zustandsgebundene Sprachmodell-Assistenz Gefahr läuft, flüssige, aber faktisch inkorrekte Anweisungen zu geben. Diese Arbeit stellt ein System vor, eine telemetriegestützte Tutoring-Laufzeitumgebung, die paketbasierte Prozedurzustandsverfolgung, Retrieval-Augmented-LLM-Hilfegenerierung und ein feinabgestimmtes Vision-Language-Model (VLM) zur strukturierten Extraktion visueller Fakten aus Cockpit-Anzeigen kombiniert. Das System erzwingt eine explizite Evidenzgrundlage: Jede hervorgehobene Cockpit-Referenz und jede Schrittempfehlung muss auf eine Telemetrie-Variable, eine Gating-Regel, einen abgerufenen Dokumentausschnitt oder eine visuelle Faktbeobachtung zurückführbar sein. Als Trainingsszenario dient der Kaltstart der F/A-18C in DCS World mit 25 Schritten in sechs Betriebsphasen, deren Abhängigkeiten untereinander sie repräsentativ für zustandsabhängige prozedurale Aufgaben machen. Ein zentrales Ergebnis ist, dass das Design der visuellen Fakten-Ontologie die Modellzuverlässigkeit bestimmt: Die Weiterentwicklung von einer 8-Fact-v1- zu einer 13-Fact-v2-Ontologie durch Zerlegung zusammengesetzter Ziele in lokal überprüfbare visuelle Atome reduzierte kritische False-Positives um 64–89% auf unabhängigen Holdout-Sets und liefert ein Design-Prinzip, wonach VLMs beobachtbare Evidenz extrahieren sollten, während die prozedurale Interpretation dem nachgelagerten Reasoning vorbehalten bleibt. Die VLM-Adaptationspipeline—Screenshot-Erfassung, Vorlabeling, menschliche Überprüfung, bilingualer SFT-Export, LoRA-Feinabstimmung und automatisiertes Benchmarking—wird auf zwei Backbone-Architekturen demonstriert. Auf der 13-Fact-Ontologie verbessert ein Qwen3.5-9B LoRA-Adapter (928 bilinguale Trainingszeilen) die Fact-Genauigkeit von

---

0,80–0,87 (Basismodell) auf 0,99 auf zwei unabhängigen Holdout-Sets mit verifizierter Null-Überlappung zum Training. Die identische Datenrezeptur, auf Gemma-4-31B angewendet, bestätigt die Übertragbarkeit der Verbesserung über Backbones hinweg. Die Arbeit liefert eine funktionsfähige Dual-Platform-Laufzeitumgebung mit automatisierten Tests, Benchmark-Artefakten und Replay-Infrastruktur sowie einem dokumentierten Evaluationsdesign für die nächste Phase der Human-Subject-Forschung.

# 致谢

# Contents

|                                |           |
|--------------------------------|-----------|
| <b>第一章 引言</b>                  | <b>1</b>  |
| 1.1 动机与问题陈述                    | 1         |
| 1.2 研究问题                       | 2         |
| 1.3 论文愿景与范围                    | 2         |
| 1.4 当前实现范围                     | 3         |
| 1.5 贡献                         | 4         |
| 1.6 论文结构                       | 5         |
| <b>第二章 背景与相关工作</b>             | <b>6</b>  |
| 2.1 F/A-18C 冷启动任务              | 6         |
| 2.1.1 程序结构: S01-S25 与 P1-P6 阶段 | 6         |
| 2.1.2 座舱显示器与复合面板               | 7         |
| 2.1.3 DCS-BIOS 遥测              | 8         |
| 2.2 视觉事实本体                     | 8         |
| 2.2.1 从 8-Fact v1 到 13-Fact v2 | 8         |
| 2.2.2 粘性事实与步骤绑定                | 9         |
| 2.3 智能教学系统与程序性训练               | 10        |
| 2.4 基于仿真器的培训与数据采集              | 11        |
| 2.5 基于规则与状态感知的教学               | 11        |
| 2.6 基础模型与面向情境辅助的 VLM           | 12        |
| 2.7 AR/VR 中可解释且基于证据的 AI 辅助     | 12        |
| 2.8 本工作的定位                     | 13        |
| <b>第三章 系统设计</b>                | <b>14</b> |
| 3.1 设计目标与需求                    | 14        |
| 3.2 整体架构                       | 15        |
| 3.3 核心教学逻辑与仿真器适配器的分离           | 16        |

---

|       |                  |    |
|-------|------------------|----|
| 3.4   | 数据流              | 17 |
| 3.4.1 | 观察               | 17 |
| 3.4.2 | 教学请求             | 17 |
| 3.4.3 | 上下文组装            | 17 |
| 3.4.4 | 模型推理             | 18 |
| 3.4.5 | 响应验证与映射          | 18 |
| 3.4.6 | 操作执行             | 19 |
| 3.4.7 | 事件日志记录           | 19 |
| 3.5   | 遥测处理             | 19 |
| 3.6   | 程序引擎与门控规则引擎      | 19 |
| 3.6.1 | 程序引擎             | 19 |
| 3.6.2 | 门控规则引擎           | 20 |
| 3.6.3 | 基于确定性降级的优雅降级     | 20 |
| 3.6.4 | 程序包结构            | 20 |
| 3.7   | 仿真器适配层           | 21 |
| 3.7.1 | 遥测输入适配器          | 21 |
| 3.7.2 | 叠加输出适配器          | 21 |
| 3.7.3 | 视觉输入适配器          | 21 |
| 3.7.4 | Lua 端集成          | 21 |
| 3.7.5 | 计划中及部分实现的适配器     | 21 |
| 3.8   | 事件日志与回放          | 22 |
| 3.8.1 | 事件模型             | 22 |
| 3.8.2 | JSONL 事件存储       | 22 |
| 3.8.3 | 回放与验证            | 22 |
| 3.8.4 | 评分与交互度量          | 22 |
| 3.8.5 | 当前局限             | 22 |
| 3.9   | 用于视觉状态理解的 VLM 适配 | 22 |
| 3.9.1 | VLM 组件的角色        | 23 |
| 3.9.2 | 视觉事实本体           | 23 |
| 3.9.3 | VLM 在帮助循环中的集成    | 23 |
| 3.9.4 | VLM 适配流水线        | 23 |
| 3.9.5 | 与基于规则的状态门控的区别    | 23 |



|                                      |           |
|--------------------------------------|-----------|
| <b>第四章 方法论</b>                       | <b>25</b> |
| 4.1 程序运行时与遥测溯源                       | 25        |
| 4.1.1 DCS-BIOS 原始帧摄入                 | 25        |
| 4.1.2 变量解析与源丢失跟踪                     | 26        |
| 4.1.3 门控规则评估                         | 26        |
| 4.1.4 增量去噪与聚合                        | 26        |
| 4.1.5 确定性降级                          | 27        |
| 4.1.6 运行时效率缓存                        | 27        |
| 4.2 知识溯源与来源策略                        | 27        |
| 4.2.1 BM25 检索                        | 27        |
| 4.2.2 来源策略                           | 28        |
| 4.3 视觉事实数据流水线                        | 28        |
| 4.3.1 第一阶段: DCS 截图捕获                 | 28        |
| 4.3.2 第二阶段: 初始 VLM 预标注               | 29        |
| 4.3.3 第三阶段: Label Studio 人工审查        | 29        |
| 4.3.4 第四阶段: 经审查的 JSONL 导出            | 29        |
| 4.3.5 第五阶段: 双语 SFT JSONL 生成          | 29        |
| 4.3.6 第六阶段: LoRA 微调                  | 30        |
| 4.3.7 第七阶段: 基础模型与 LoRA 对比基准测试        | 30        |
| 4.3.8 端到端可追溯性                        | 30        |
| 4.4 数据集构建                            | 31        |
| 4.4.1 数据集概览                          | 31        |
| 4.4.2 本体演进: 从 8-Fact v1 到 13-Fact v2 | 31        |
| 4.4.3 训练方案: Run-003 + Run-005x2      | 32        |
| 4.4.4 留出集独立性验证                       | 32        |
| 4.5 LoRA 微调配置                        | 33        |
| 4.5.1 基础模型                           | 33        |
| 4.5.2 训练栈                            | 33        |
| 4.5.3 超参数配置                          | 34        |
| 4.5.4 双语 SFT 策略                      | 35        |
| 4.5.5 组合再平衡策略                        | 35        |
| 4.6 基准测试协议                           | 35        |
| 4.6.1 度量指标                           | 35        |
| 4.6.2 基础模型与 LoRA 对比方法论               | 36        |
| 4.6.3 留出定义与基准测试类别                    | 37        |

---

|            |                    |           |
|------------|--------------------|-----------|
| 4.6.4      | 基准测试工件             | 37        |
| 4.7        | 本章小结               | 38        |
| <b>第五章</b> | <b>实现</b>          | <b>39</b> |
| 5.1        | 技术栈                | 39        |
| 5.2        | 核心领域层              | 40        |
| 5.2.1      | 程序引擎               | 40        |
| 5.2.2      | 门控规则引擎             | 40        |
| 5.2.3      | 评分引擎               | 40        |
| 5.2.4      | 视觉事实本体与状态管理        | 41        |
| 5.2.5      | 动态 HelpResponse 模式 | 41        |
| 5.2.6      | 数据契约               | 41        |
| 5.2.7      | 其他核心模块             | 42        |
| 5.3        | 遥测与 DCS 集成         | 42        |
| 5.4        | 结构化帮助生成            | 43        |
| 5.4.1      | 提示构建               | 43        |
| 5.4.2      | 模型适配器              | 44        |
| 5.4.3      | 带最小修复的 JSON 提取     | 44        |
| 5.4.4      | 模式验证               | 44        |
| 5.4.5      | 响应映射与证据溯源          | 44        |
| 5.4.6      | 确定性降级              | 45        |
| 5.4.7      | 操作执行安全             | 45        |
| 5.5        | VLM 视觉事实提取         | 45        |
| 5.5.1      | 捕获触发与帧选择           | 45        |
| 5.5.2      | 多模态负载构建            | 46        |
| 5.5.3      | 13-Fact 提示         | 46        |
| 5.5.4      | 模型响应清洗             | 46        |
| 5.5.5      | 事实合并与后端兼容性         | 46        |
| 5.5.6      | VR 兼容性             | 47        |
| 5.6        | 回放与日志基础设施          | 47        |
| 5.6.1      | JSONL 事件存储         | 47        |
| 5.6.2      | 回放与验证              | 47        |
| 5.6.3      | 交互度量               | 47        |
| 5.6.4      | 当前局限               | 48        |

---

|            |                                |           |
|------------|--------------------------------|-----------|
| 5.7        | CLI 与运行时入口点                    | 48        |
| 5.7.1      | CLI 命令                         | 48        |
| 5.7.2      | 实时运行时编排                        | 48        |
| 5.7.3      | DCS Lua 脚本                     | 49        |
| 5.7.4      | 模型提供者配置                        | 50        |
| <b>第六章</b> | <b>评估</b>                      | <b>51</b> |
| 6.1        | RQ2: VLM 技术评估                  | 51        |
| 6.1.1      | 数据集与训练概览                       | 51        |
| 6.1.2      | Qwen3.5 13 事实 V2 结果            | 52        |
| 6.1.3      | Gemma-4 与 Qwen3.6 骨干对比         | 52        |
| 6.1.4      | 错误分析                           | 53        |
| 6.2        | RQ1: 系统级技术就绪性                  | 53        |
| 6.2.1      | 回放评估                           | 53        |
| 6.2.2      | Harness 夹具回归                   | 54        |
| 6.2.3      | 实验导出基础设施                       | 54        |
| 6.3        | RQ3: 形成性 VR 试点研究               | 54        |
| 6.3.1      | 参与者与试验概览                       | 54        |
| 6.3.2      | 程序性错误                          | 55        |
| 6.3.3      | 教学交互                           | 56        |
| 6.3.4      | 数据质量注记                         | 56        |
| 6.3.5      | 试点发现总结                         | 57        |
| <b>第七章</b> | <b>讨论</b>                      | <b>58</b> |
| 7.1        | 从提案到实现系统的演变                    | 58        |
| 7.2        | 技术结果解读                         | 59        |
| 7.2.1      | 基准测试结果证明了什么                    | 59        |
| 7.2.2      | 基准测试结果未证明什么                    | 59        |
| 7.2.3      | ins_go 到 ins_ok_text 的分解作为设计经验 | 60        |
| 7.3        | 试点发现解读                         | 60        |
| 7.4        | 本体设计经验                         | 60        |
| 7.5        | 局限性                            | 61        |
| 7.5.1      | 实验设置的局限性                       | 61        |
| 7.5.2      | 系统局限性                          | 61        |
| 7.5.3      | 试点研究的局限性                       | 61        |
| 7.5.4      | VLM 适配结果的局限性                   | 62        |

---

|             |                |           |
|-------------|----------------|-----------|
| 7.5.5       | 范围总结           | 62        |
| 7.6         | 未来工作           | 62        |
| 7.6.1       | 受控人因评估         | 62        |
| 7.6.2       | 将视觉事实本体扩展到其他程序 | 62        |
| 7.6.3       | 多帧时序推理         | 62        |
| 7.6.4       | 基于原位校正的在线适配    | 63        |
| 7.6.5       | 系统级端到端评估       | 63        |
| 7.6.6       | 未来方向总结         | 63        |
| <b>第八章</b>  | <b>结论</b>      | <b>64</b> |
| 8.1         | 已完成工作总结        | 64        |
| 8.2         | 未来工作           | 65        |
| <b>参考文献</b> |                | <b>67</b> |
| <b>第九章</b>  | <b>附录</b>      | <b>68</b> |
| 9.1         | 完整 LoRA 超参数配置  | 68        |
| 9.2         | 8 事实 V1 基线基准测试 | 69        |
| 9.3         | 数据集事实分布        | 69        |
| 9.4         | CLI 命令参考       | 69        |
| 9.5         | 模型提供者配置        | 70        |
| 9.6         | 回放评估套件         | 70        |
| 9.7         | VR 试点研究——补充数据  | 71        |

# List of Figures

|     |                                                                                                    |    |
|-----|----------------------------------------------------------------------------------------------------|----|
| 3.1 | 所提出的系统架构。核心层包含仿真器无关的领域逻辑。端口层定义抽象接口。适配器层为 DCS、模型提供者、知识源和视觉流水线提供具体实现。程序包提供声明式配置。 . . . . .           | 16 |
| 3.2 | 主帮助循环中的运行时数据流。 . . . . .                                                                           | 17 |
| 4.1 | 七阶段视觉事实数据流水线。捕获和预标注供给人工审查;经审查的标注驱动双语 SFT 导出;导出的数据训练 LoRA 适配器;基础模型和 LoRA 模型在独立留出集上进行基准测试。 . . . . . | 28 |

# List of Tables

|     |                                                                                       |    |
|-----|---------------------------------------------------------------------------------------|----|
| 4.1 | 数据集清单。所有样本数来自相应的 <code>stats.json</code> 文件。 . . . . .                                | 31 |
| 4.2 | LoRA 微调超参数，在 Qwen3.5-9B 和 Gemma-4-31B 间匹配。 . . . .                                    | 34 |
| 6.1 | 标注视觉事实数据集概览。 . . . . .                                                                | 51 |
| 6.2 | 13 事实 v2 基准测试：Qwen3.5-9B Base vs. LoRA 在两个保留集上。 . .                                   | 52 |
| 6.3 | 三种骨干上的 13 事实 v2 结果（仅 LoRA 模型）。 . . . . .                                              | 53 |
| 6.4 | 参与者与试验概览。观察时长为从第一次遥测事件到最后一次的挂钟间隔；对未完成试验而言，它不是完成时间的度量。 . . . . .                       | 55 |
| 6.5 | 每参与者人工程序性错误计数（来自人工步骤编码）。OM = 遗漏，CO = 执行错误，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违反。 . . . . . | 55 |
| 6.6 | 教学交互摘要（仅教学辅助条件）。 . . . . .                                                            | 56 |
| 7.1 | 未来工作方向总结。 . . . . .                                                                   | 63 |
| 9.1 | 三种骨干的完整 LoRA 微调超参数。 . . . . .                                                         | 68 |
| 9.2 | 8 事实 v1 基准测试：Qwen3.5-9B Base vs. LoRA-v1 在 Run-002 保留集上（50 样本，EN）。 . . . . .          | 69 |
| 9.3 | 训练集和保留集中逐事实 <code>seen</code> 计数（13 事实 v2 本体）。 . . . . .                              | 70 |
| 9.4 | 回放评估用例。 . . . . .                                                                     | 71 |
| 9.5 | 试点参与者经验概况（自报）。 . . . . .                                                              | 71 |
| 9.6 | 无教学辅助条件中未完成的步骤（人工编码）。 . . . . .                                                       | 72 |
| 9.7 | 自动编码 vs. 人工错误计数（每参与者）。 . . . . .                                                      | 72 |

# 第一章 引言

## 1.1 动机与问题陈述

程序性学习——获取必须按正确顺序、在正确上下文中执行的固定动作序列——面临着与陈述性或概念性学习截然不同的挑战。学习者不仅需要记忆步骤，还必须识别每个步骤的适用时机、验证其前提条件是否满足、在推进前确认完成，并从错误中恢复而不将错误传播到程序的后续部分。在高保真仿真环境中，座舱复杂度、仪表信息密度以及在执行不熟悉序列时维持态势感知的认知负荷，进一步加剧了这些挑战。

传统的训练辅助工具——视频演示、纸质检查单、教员引导示范——在初始熟悉阶段是有效的，但会打断仿真器内练习的连续性。暂停去查阅手册或回放视频片段的学习者必须从座舱中切换上下文，失去沉浸感，在某些情况下还会丢失促使查阅的瞬态仿真器状态。反过来，来自大语言模型（LLM）的缺乏依据的文本辅助则存在提供流畅但事实性错误指导的风险，因为模型无法访问当前的仿真器状态。

在这两个极端之间，存在着对有依据的、上下文感知的教学的需求：一个能够通过实时仿真器遥测观察学习者行为、检索相关文档、在遥测不足时从座舱中提取视觉证据，并在不打断训练流程的前提下提供可验证指导的系统。

DCS World 中 F/A-18C 的冷启动程序作为本论文的训练场景。基准测试和评估工作中研究的核心程序包含 25 个步骤（S01-S25），分为六个操作阶段，从电池供电启动到发动机启动、航电配置、飞行控制检查及滑行准备（详见 §2.1）。当前的程序包已扩展至 S01-S33 以涵盖额外的滑行前检查；该扩展不在本文报告的基准测试和 VLM 评估范围之内。每个步骤都携带依赖于之前步骤完成情况及特定遥测条件的显式前提条件。这些步骤间依赖关系使冷启动成为序列敏感、状态依赖型程序性任务的一个代表性实例，此类任务广泛存在于航空、海事操作、工业维护和医疗程序教学等基于仿真器的训练领域。

本工作的核心前提是，通过将每一个可操作输出锚定在显式证据之上——遥测变量、门控规则评估、检索到的文档片段或视觉事实观察——可以使教学系统更加可靠且可审计。这一约束同时是架构承诺和安全要求：对于座舱程序而言，一个错误高亮的控件或一个被误识别的程序状态可能混淆或误导学习者。

## 1.2 研究问题

本论文由一个主要研究问题和三个子问题指导：

**主要 RQ.** 一个基于证据的多模态教学系统如何支持沉浸式飞行仿真器中的状态依赖型程序性训练？

**RQ1 ——系统架构与证据集成。** 如何将仿真器遥测、检索到的程序性知识和视觉事实观察进行集成，使得教学输出具有状态感知能力、可审计性，并对程序性指导具有安全性？

**RQ2 ——VLM 适配与本体设计。** 一个小数据 LoRA 适配的 VLM 能在多大程度上可靠地提取结构化座舱视觉事实？视觉事实本体设计如何影响关键误报？

**RQ3 ——形成性 VR 试点证据。** 在基于 VR 的 F/A-18C 冷启动训练任务中，一项小型试点研究在有教学辅助与无教学辅助的对比中，能提供哪些关于任务完成、程序性错误和教学交互的形成性证据？

RQ1 和 RQ2 通过本论文中呈现的设计、实现和技术评估来回答。RQ3 通过一项已完成的形成性 VR 试点研究 ( $n = 9$ ) 和一个已记录的评估框架来回答；更大规模的受控人因评估仍是未来工作。

## 1.3 论文愿景与范围

本论文的研究愿景，如研究提案 [7] 所述，以一个运行在 Meta Quest 3 上与 DCS-VR 配合的 VR 优先的有依据教学系统为中心。规划的系统将通过 VR 座舱内的眼动追踪、手部追踪和语音输入接收学习者交互；检索相关手册和检查单摘录；通过检索增强的 LLM 生成简洁、有引文支撑的步骤指导；并将指导渲染为头戴式步骤卡片或注册到座舱控件的叠加标注。提案指定了一项三条件人因评估，对比视频加笔记基线、无依据纯文本 LLM 以及有依据教学系统，指标包括完成率、程序性错误率、任务时间、NASA-TLX 工作负荷评分、前/后知识测验，以及 2-4 周间隔后的保持和迁移测试。

当前的实现交付了这一愿景的技术基础，但在三个重要方面与提案有所不同。第一，主要运行时是在桌面 DCS 而非 VR 原生的 Quest 3 上开发的，因为遥测、VLM 和叠加基础设施需要一个稳定的开发和调试环境。第二，大量工程工作投入了提案未曾预见的组件：一条带有 LoRA 微调的视觉事实提取流水线、在 JSON Schema 层面强制执行的证据溯源架构，以及一个具有经验证保留集独立性的系统性基准测试协议。第三，VR 代码路径已实现并经验证功能正常（VR\_MIRROR、教学文本显示、复合



面板捕获)。一项形成性试点研究已在 VR 中开展 (第6.3节); 更大规模的受控评估仍是未来工作。

因此, 本论文的范围包含三个层面:

1. 设计与实现一个集成了 VLM 视觉事实提取的遥测驱动教学运行时系统 (第三、四、五章);
2. 通过在独立保留集上的系统性基准测试评估, 对 VLM 适配流水线进行技术验证 (第六章, A 部分);
3. 一项形成性 VR 试点研究 ( $n = 9$ ), 提供在有教学辅助与无教学辅助条件下关于任务完成、程序性错误和教学交互的描述性证据, 并附有实验工具和已记录的评估框架 (第六章, B 部分)。

## 1.4 当前实现范围

当前实现是一个双平台教学运行时系统, 包含四个集成子系统。

**遥测锚定。** 遥测子系统摄入原始 DCS-BIOS UDP 帧, 并通过变量解析、增量去噪和增量聚合进行处理, 以生成稳定的、规范化的状态表示。源缺失追踪区分"值为零"与"值未知", 这一区分对正确的门控规则评估至关重要。

**VLM 视觉事实提取。** 视觉事实提取流水线填补了 DCS-BIOS 遥测留下的空白: 若干程序步骤需要视觉确认显示页面内容, 而这些内容并未由仿真器导出。该流水线包括结构化本体设计、经人工审查的数据集构建、双语 LoRA 微调, 以及在两个模型骨干 (Qwen3.5-9B 和 Gemma-4-31B) 上的自动化基准测试评估。

**基于证据的帮助生成。** 每个叠加目标和步骤推荐都携带一个可追溯的证据引用——遥测变量、门控规则评估、检索到的知识片段或视觉事实观察——通过运行时生成的 JSON Schema 规则在模式层面强制执行。一条确定性降级路径确保当没有模型可用时系统仍能维持功能。

**程序包与基础设施。** 程序定义、门控规则、遥测映射、错误分类法和视觉事实本体以声明式 YAML 配置 (即 程序包) 的形式组织。系统包含事件日志和回放基础设施、自动化评分引擎、实验导出工具, 以及用于研究部署的 Windows 实验启动器。

## 1.5 贡献

本论文做出三项贡献：

1. **一个基于证据的程序性教学架构**。该架构在单个帮助循环中集成了仿真器遥测、检索到的程序性知识和结构化视觉事实。每个叠加目标和步骤推荐必须可追溯到一个特定的证据来源，通过运行时生成的 JSON Schema 验证而非事后日志记录来强制执行。该架构遵循端口-适配器模式，带有确定性降级路径，所有程序逻辑以声明式包配置形式表达，而非编码在提示或代码中。此项贡献描述于第三和五章，并在第六章第6.2节中进行评估。
2. **一个视觉事实本体与小数据 VLM 适配流水线**。本论文提出了一个用于 F/A-18C 座舱状态提取的 13 事实视觉本体，从 8 事实 v1 基线通过将复合程序性目标系统性分解为局部可验证的视觉原子而演进而来。适配流水线涵盖 DCS 截图捕获、AI 预标注、Label Studio 中的人工审查、双语监督微调、LoRA 微调，以及在独立保留集上的自动化基础模型与 LoRA 对比基准测试，并经验证与训练数据零重叠。基于 928 行双语数据训练的 Qwen3.5-9B LoRA 适配器在两个独立保留集上达到 0.99 的事实准确率，并将关键误报降低了 64–89%。相同的数据配方迁移至 Gemma-4-31B 也获得了一致的提升，表明该方法不局限于单一骨干。本体的演进产生了一个可迁移的设计原则：VLM 应提取可观察的视觉证据，而程序性解释应归于下游推理。此项贡献描述于第三、四章，并在第六章第6.1.2和6.1.3节中进行评估。
3. **一个 VR 程序性训练评估框架与形成性试点研究**。本论文交付了用于评估沉浸式仿真中有依据程序性教学的研究就绪工具：实验导出工具、带会话管理的 Windows 启动器、基线和被动条件配置、半自动预评分、错误编码指南，以及实验操作手册。一项形成性 VR 试点研究 ( $n = 9$ ) 已开展，包含四名有教学辅助和五名无教学辅助的参与者。所有四名教学辅助条件下的参与者完成了完整的 33 步程序；五名无教学辅助的参与者均未完成。有教学辅助的错误以辅助耦合型 (CO/PA) 为主，而无教学辅助的错误以遗漏型为主。该试点提供了关于可行性和工具就绪性的描述性证据；更大规模的受控评估仍是未来工作。此项贡献记录于第六章第 6.3 节及附录九。

贡献 1 和 2 有经过验证的基准测试工件、自动化测试和代码仓库证据作为支撑。贡献 3 综合了已实现的基础设施、一项已完成的形成性试点研究，以及一条通向更大规模受控评估的已记录路径，后者仍在本论文范围之外。

## 1.6 论文结构

**第二章**提供 F/A-18C 冷启动程序、视觉事实本体和 DCS-BIOS 遥测的领域背景，随后综述智能教学系统、基于仿真器的训练、状态感知教学、VLM 适配以及有依据 AI 辅助等相关工作。

**第三章**呈现系统架构：设计目标、端口-适配器分层、运行时数据流、遥测处理、程序与门控引擎、回放基础设施，以及 VLM 适配组件。

**第四章**描述遥测锚定方法论、基于 BM25 和来源策略的知识检索、七阶段视觉事实数据流水线、数据集构建与从 8 事实 v1 到 13 事实 v2 的本体演进、两个骨干的 LoRA 微调配置，以及包括度量定义和保留集策略在内的基准测试协议。

**第五章**涵盖技术栈、核心领域逻辑、遥测集成、结构化帮助生成、VLM 视觉事实提取和回放基础设施的实现层面细节。

**第六章**在 A 部分报告当前技术结果（VLM 基准测试、错误分析、运行时基础设施就绪），在 B 部分报告形成性 VR 试点研究结果。

**第七章**解释结果，阐述从原始提案到当前系统的演变，从两代本体演进中提炼设计经验，列举局限性，并概述未来工作。

**第八章**对照三项贡献和研究问题总结已完成工作，并重申评估本论文应遵循的范围边界。

**附录九**包含补充表格、完整超参数配置、数据集统计、CLI 参考以及 8 事实 v1 基线基准测试。

## 第二章 背景与相关工作

本章提供理解所提出系统设计所需的领域和技术背景，随后综述若干交叉研究领域的相关工作。第2.1节介绍作为该系统训练场景的 F/A-18C 冷启动任务。第2.2节描述视觉事实本体——一个连接原始座舱截图与下游程序性推理的结构化中间表示。本章剩余部分将本工作定位于智能教学系统、基于仿真器的培训、状态感知教学、视觉语言模型适配以及基于证据的 AI 辅助等现有研究之中。

### 2.1 F/A-18C 冷启动任务

本论文核心的程序性训练场景是 F/A-18C 冷启动，这是一个标准的飞行前座舱程序，将飞机从断电状态过渡到可滑行配置。该任务是 DCS World 培训课程中的经典科目，并代表了一类更广泛的固定序列、状态敏感型程序性任务，其中操作顺序、中间系统状态的验证以及对座舱仪表的正确解读共同决定了任务的成功完成。

#### 2.1.1 程序结构：S01–S25 与 P1–P6 阶段

冷启动程序由 25 个编号步骤（S01–S25）、分为六个粗粒度阶段（P1–P6）组成，反映了不同的操作阶段：

**P1 — 供电与安全检查 (S01–S03)：** 电瓶和发电机激活、火警探测系统测试以及辅助动力装置（APU）启动。这些步骤建立电源并确认关键安全系统在发动机点火前处于正常状态。

**P2 — 右发启动 (S04–S07)：** 右发起动、在 25% 转速时推进油门、引气系统循环以及注意/警告/提示灯测试。首先启动右发以为后续程序提供液压和电源。

**P3 — 显示器与通信 (S08–S09)：** 两个数字显示指示器（DDI）、先进多用途彩色显示器（AMPCD）和抬头显示器（HUD）的通电；特定显示页面配置（左 DDI 显示 FCS 页面，右 DDI 显示 BIT 根页面）；通过上前方控制器（UFC）编程 COMM1 预设频率。

**P4 — 左发与核心系统 (S10–S14):** 在验证右发参数处于标称范围后启动左发, INS 校准模式选择 (地面或航母), 雷达通电, 以及 OBOGS (机载制氧系统) 激活。

**P5 — FCS 与飞行控制 (S15–S19):** 飞行控制系统 (FCS) 复位与 BIT (内置测试) 执行, 襟翼和配平配置, 以及包括受油管、减速板、弹射杆和拦阻钩在内的"四项放下"飞行前检查。

**P6 — 滑行前仪表与最终检查 (S20–S25):** 驻车制动释放, BINGO 燃油设定, 气压和雷达高度表配置, 备用姿态指示仪解锁, 以及姿态源选择。

该程序严格有序: 每个步骤都带有显式的前提门控条件, 这些条件取决于先前步骤的完成情况以及特定遥测条件的满足。例如, S04 (右发起动) 要求已建立 APU 启动支持 (S03 完成), 而 S10 (左发起动) 要求右发参数——转速、温度、燃油流量、尾喷口位置和滑油压力——在启动左发之前全部处于标称绿区范围内。这些步骤间依赖关系使冷启动任务成为上下文感知教学的引人注目的测试案例: 跳过验证或误判仪表读数的学习者可能将错误传播到序列的其余部分。

### 2.1.2 座舱显示器与复合面板

视觉事实提取子系统 (§2.2) 操作于一个固定的复合面板图像, 该图像捕获三个座舱显示区域, 从上到下排列:

- **左 DDI (数字显示指示器):** 多功能显示器, 用于 FCS 页面、SUPT (设置) 页面、TAC (战术) 页面及其他系统页面。在冷启动过程中, 左 DDI 主要用于 FCS 监控 (S08、S15)。
- **AMPCD (先进多用途彩色显示器):** 中央彩色显示器, 用于 HSI (水平状态指示器) 页面、INS 校准状态、地图图层和导航数据。在冷启动中, AMPCD 在 INS 校准阶段 (S12) 起关键作用。
- **右 DDI:** 第二个多功能显示器, 在冷启动中用于 BIT 根页面 (S08), 随后用于 FCS-MC BIT 序列 (S18)。右 DDI 也是 BIT 故障指示以及 FCS BIT 中间和最终结果出现的位置。

复合面板图像将这三个区域合并为视觉语言模型 (VLM) 的单一输入。这一设计选择避免了训练与推理之间的不匹配 (即模型在各区域裁剪上训练但在完整复合图像上评估, 或反之), 并将多轮视觉流水线简化为每个观察窗口的单图像提取步骤 [6]。

### 2.1.3 DCS-BIOS 遥测

DCS-BIOS 提供来自 DCS World 的基于 UDP 的实时遥测数据流，将座舱开关、指示器、警告灯、仪表及其他仪器的状态导出为结构化数据。教学运行时接收这些原始 BIOS 帧，并将其传递通过遥测增强流水线，该流水线将原始值规范化为稳定的运行时变量（如 `rpm_r`、`apu_ready`、`ins_mode`），应用增量去噪处理以抑制噪声和抖动，并锁定离散状态完成标志以供门控评估。

这一遥测数据流是教学系统的主要状态基础信号。与纯视觉方法（必须仅从像素级证据推断程序状态）不同，教学运行时可以将视觉观察与确定性遥测状态进行交叉比对。S01（电瓶和发电机）、S05（右发慢车）、S13（雷达模式 OPR）等步骤可直接通过 DCS-BIOS 观测，无需视觉推理。其他步骤，如 S08 和 S18，涉及未通过 DCS-BIOS 直接导出的显示页面状态，因此依赖于下文描述的视觉事实提取流水线。

## 2.2 视觉事实本体

所提出系统的一个核心设计决策是视觉感知与程序性推理的分离。系统不是训练模型直接产生导师决策（“学习者现在应该按下 PB5”），而是使用一个称为视觉事实的中间结构化表示。一个视觉事实是关于某一时刻某个座舱显示区域可见状态的离散、可审计命题。每个事实被标注为三种状态之一：

**seen:** 事实所描述的视觉证据在当前座舱图像中清晰可见。

**not\_seen:** 视觉证据不存在或不可识别。

**uncertain:** 图像模糊、被遮挡、不完整或因其他原因无法做出确信判断。

这些事实被下游程序引擎（g??）消费，该引擎将其与遥测状态、门控规则和知识检索相结合，以判断程序步骤是视觉确认、仍未完成还是被阻塞。这种分层架构将 VLM 的职责隔离在结构化视觉证据提取上，而将程序级决策保留给确定性的基于规则的组件。

### 2.2.1 从 8-Fact v1 到 13-Fact v2

视觉事实本体经历了两代演进，反映了早期微调实验的经验教训以及运行时程序包的需求。



**8-fact v1 (早期基线)。** 第一代本体包含八个事实，针对三个显示区域。这些事实涵盖 FCS 页面可见性 (左 DDI)、BIT 页面和 BIT 故障可见性 (右 DDI)、FCS-MC 页面和在测状态 (右 DDI)、FCS BIT 结果可见性 (右 DDI)、INS 校准页面可见性 (AMPCD) 以及 INS GO 完成信号 (AMPCD)。该本体用于在 180 张经人工审查的 Run-001 图像上训练首个 LoRA 适配器 (LoRA-v1)，产生了有希望的分布内结果，但也暴露了一个关键弱点：ins\_go 事实混合了抽象层次，要求 VLM 从单帧视觉图像中识别出一个高级程序完成状态 ("INS 校准已完成")。结果是独立 Run-002 留出集上的高假阳性率 (50 个样本中有 13 个在人工标注为 not\_seen 时被预测为 seen)。

**13-fact v2 (运行时对齐)。** 第二代本体通过将高级程序状态分解为低层次、视觉可观测的证据来解决这一问题。当前的 13-fact 集合定义于 vision\_facts.yaml，包括：

- **左 DDI 事实：** tac\_page\_visible、supt\_page\_visible、fcs\_page\_visible、fcs\_page\_x\_marks\_visible。
- **右 DDI 事实：** bit\_root\_page\_visible、fcsmc\_page\_visible、fcsmc\_intermediate\_result\_visible、fcsmc\_in\_test\_visible、fcsmc\_final\_go\_result\_visible。
- **AMPCD 事实：** hsi\_page\_visible、hsi\_map\_layer\_visible、ins\_grnd\_alignment\_text\_visible、ins\_ok\_text\_visible。

注意，v1 中的 ins\_go 已被分解为若干低层次 AMPCD 事实 (ins\_grnd\_alignment\_text\_visible、ins\_ok\_text\_visible、hsi\_map\_layer\_visible)，每个事实描述一个特定的、局部可验证的视觉证据。下游程序引擎 (而非 VLM) 负责将这些原子观察结果组合成关于 INS 校准阶段是否完成的程序性判断。

## 2.2.2 粘性事实与步骤绑定

本体中的两个额外机制提高了其在运行时使用中的鲁棒性。

**粘性事实。** 某些视觉事实代表瞬态状态，一旦被观察到，就不应被后续的 not\_seen 帧覆盖。例如，fcsmc\_final\_go\_result\_visible 事实被标记为 sticky: true，生存时间为 600 秒。一旦 VLM 报告该事实为 seen，它就在运行时事实状态中被锁定，不会在 TTL 窗口内被后续的 not\_seen 或 uncertain 预测覆盖。这防止了在关键视觉事件已被捕获后，因显示页面切换、摄像机遮挡或短暂渲染伪影导致的闪烁和假阴性。

非粘性事实 (如 fcs\_page\_visible、bit\_root\_page\_visible) 带有较短的 2 秒 TTL，并被持续重新评估，反映了这些显示页面可能因学习者在不同座舱页面之间导航而发生变化。

**步骤绑定。** 视觉事实通过定义于 `vision_facts.yaml` 中的显式步骤绑定与程序步骤相链接。步骤绑定规定了哪些事实必须为 `seen` 状态，程序引擎才能将该步骤视为视觉确认。当前本体定义了两种绑定类型：

- `all_of`: 绑定集合中的每个事实都必须为 `seen`。例如, S08 要求 `fcs_page_visible` (左 DDI) 和 `bit_root_page_visible` (右 DDI) 均被确认。
- `any_of` (多选一事实集合): 集合中至少有一个事实必须为 `seen`。这适应用于程序状态可通过若干替代视觉线索中的任何一个来验证的情况。

依赖视觉确认的步骤(S08、S15、S18)被注册为程序包中的 `vision_priority_steps`, 而可直接通过 DCS-BIOS 遥测观测的步骤 (S01、S03–S07、S09–S13、S21) 被注册为 `bios_priority_steps`。需要人工确认或涉及三显示器布局以外座舱区域的步骤 (S02、S14、S16–S20、S22–S25) 被标记为 `manual_or_out_of_layout_steps`。这种三元分类确保每个步骤的完成证据来自最可靠的可用信号。

## 2.3 智能教学系统与程序性训练

智能教学系统 (ITS) 在程序性训练领域有着悠久的历史, 从军事装备操作到医疗程序指导。经典的 ITS 架构通常对专家知识进行建模, 通过学生模型跟踪学习者状态, 并通过教学模块提供上下文敏感的反馈 [5] (如经典的四组件 ITS 模型或近期的全面综述)。

在程序性领域, 基于约束的导师和示例追踪导师已被应用于飞机维修、编程和设备故障排除等任务。TODO:CITE —— 程序性训练中的基于约束建模; TODO:CITE —— 程序性领域中的示例追踪导师或认知导师。这些系统通常在封闭、定义明确的任务环境中运行, 其中正确和错误操作的空间可以被枚举。本论文研究的冷启动任务共享此封闭程序的特性, 但在两个关键方面有所不同。首先, 系统通过仿真器遥测和座舱视觉来观察学习者行为, 而非通过自定义导师界面, 使其适用于未修改的仿真环境。其次, 教学输出由 LLM 动态生成, 而非从预编写的反馈消息库中检索, 使系统能够响应程序中任意的学习者状态, 而不仅仅响应预期的错误模式。

更近期的研究探索了使用大语言模型进行教学和指导对话。TODO:CITE —— 基于 LLM 的教学系统或对话式导师 (如 Khanmigo 风格的系统, 或任何 LLM 作为导师的论文)。这些系统证明 LLM 能够产生流畅、上下文适当的教学文本, 但它们通常在非结构化的对话环境中运行, 不强制执行所提出系统方法的严格证据溯源约束。特别是, 本工作约束每个叠加目标和步骤推荐都必须具有可验证的证据来源——遥测数据、门控规则、检索到的文档片段或视觉事实——而非仅仅依赖模型的参数化知识。



## 2.4 基于仿真器的培训与数据采集

高保真仿真环境（如 DCS World）为程序性训练提供了真实、可重复的平台。仿真器在航空培训中的应用已十分成熟，对从仿真器到真实飞机的培训迁移有广泛的研究。TODO:CITE ——航空领域基于仿真器的培训有效性（如培训迁移研究或飞行仿真培训综述）。

基于仿真器的培训研究中的一个关键挑战是数据采集：即培训系统观察学习者操作和座舱状态的方式。先前的工作通过屏幕捕获、事件日志或直接状态导出 API 对仿真器进行了数据采集。TODO:CITE ——仿真器数据采集方法，如 X-Plane 数据输出、Microsoft Flight Simulator SimConnect 或 DCS-BIOS 学术使用。本工作使用 DCS-BIOS，这是一个社区开发的遥测桥梁，通过 UDP 导出 DCS World 座舱状态。DCS-BIOS 提供比单独屏幕捕获更丰富的信号，暴露开关的确切位置、发动机参数的数值以及警告灯的状态，而无需依赖计算机视觉来恢复它们。这使得系统能够将视觉感知保留给显示页面状态（DCS-BIOS 不导出这些内容），同时依赖确定性遥测获取开关位置和仪表读数。

DCS World [2] 作为本研究所使用的仿真平台；DCS-BIOS 提供了贯穿系统始终的遥测接口。

## 2.5 基于规则与状态感知的教学

所提出系统在基于 LLM 的帮助生成之外，大量使用显式门控规则、确定性步骤推理和遥测驱动的状态跟踪。这种混合设计将其定位于基于规则和基于神经方法的智能辅助的交叉点。

基于规则的程序跟踪方法——使用有限状态机、Petri 网或产生式规则来建模任务进度——在可解释性和正确性方面提供强有力的保证。TODO:CITE ——基于规则的程序跟踪或训练中的计划识别（如程序性任务的计划识别、或程序执行的有限状态模型）。然而，这些方法通常需要手动编写程序模型，并且不能泛化到新颖的学习者错误或意外的状态配置。所提出系统使用手动编写的程序包（定义步骤、门控和证据需求）作为状态跟踪的骨干，但将自然语言解释和叠加目标选择委托给 LLM。这种分工保持了程序模型的可解释性，同时赋能于语言模型生成反馈的灵活性。

混合神经-符号架构已被提出用于任务指导，结合了神经感知或生成与符号任务模型。TODO:CITE ——神经-符号任务辅助或混合规划 +LLM 系统（如 SayCan 风格的 grounding、或 LLM+PDDL 集成）。本工作与这些努力的不同之处在于其对证据溯源的强调：系统的每个可操作输出都必须可追溯到一个具体的、可审计的证据来源（遥测变量、视觉事实观察、门控规则评估或检索到的文档块）。这一约束不仅是一种架构

偏好，更是一项安全要求：在座舱程序的语境中，被错误高亮的控件或被错误识别的程序状态可能会使学习者产生混淆或误导。

## 2.6 基础模型与面向情境辅助的 VLM

将视觉语言模型（VLM）适配到特定领域的结构化提取任务是一个快速发展的领域。参数高效微调方法，特别是低秩适配（LoRA），使得以适度的计算资源和小规模精选数据集将大型预训练模型适配到狭窄领域变得可行。[3]; [4]; [1].

本论文中的 VLM 适配流水线 (g??) 遵循一个捕获-预标注-审查-训练-基准测试的循环，其显著特点在于使用经人工审查的小数据（数百张图像，而非数万张）来推动结构化提取准确率的有意义改进。这与依赖网络规模数据和广泛指令微调的大规模 VLM 微调工作形成对比。TODO:CITE ——小数据领域适配 VLM 或 LLM 的工作，少样本任务特定微调。

先前关于图形用户界面和结构化屏幕内容视觉理解的研究已探索了诸如控件检测、屏幕摘要和 UI 状态分类等任务。TODO:CITE ——使用 VLM 进行 UI 理解或屏幕解析（如 Screen2Words、Widget Captioning 或基于视觉的 UI 自动化）。本研究中的座舱显示领域与 GUI 理解具有结构相似性——固定区域、结构化布局、符号内容——但在任务的关键性以及需要显式、可审计的证据而非开放式描述方面有所不同。

本工作中使用的双语 SFT 策略（从相同的图像和标注训练英文和中文变体）与微调中的跨语言迁移和指令多样性相关。TODO:CITE ——跨语言指令微调或 VLM 的多语言 SFT。然而，这里的主要动机并非多语言部署，而是指令多样性作为一种正则化形式：通过在两种语言上训练，鼓励模型关注视觉内容而非语言特定的先验，而结构化 JSON 输出格式保持与语言无关。

## 2.7 AR/VR 中可解释且基于证据的 AI 辅助

原始论文研究计划设想了一个运行在 Meta Quest 3 上的头显内增强现实/虚拟现实教学界面。虽然当前实现在桌面 DCS 运行时上运行（见 §1.4），但长期研究议程仍然锚定在沉浸式程序性训练中。

关于程序性任务增强现实指导的研究已经证明了空间注册指令在装配、维护和维修任务中的价值。TODO:CITE ——AR 引导的程序性训练综述（如用于装配、维护或医疗程序指导的 AR）。这些系统通常使用注册到已知物理对象的预编写内容（箭头、文本、动画）。所提出系统的愿景不同之处在于，教学内容是在运行时从当前程序状态和视觉证据生成的，而非从固定库中检索。

关于决策支持系统中可解释 AI 的研究强调了可追溯推理的重要性，特别是在安全关键领域。TODO:CITE ——决策支持或安全关键 AI 辅助中的可解释 AI（如航空领域的 XAI，或高风险任务中的可解释推荐系统）。本系统中的证据溯源约束与此原则一致：每个叠加目标和推荐步骤必须携带一个证据引用，将输出链接到其来源（遥测变量、门控规则、视觉事实或检索到的文档块）。此审计追踪旨在支持运行时调试（系统为什么高亮此控件？）和帮助循环的事后分析。

TODO:CITE ——任何在 VR/AR 中处理 grounding、证据或程序正确性（而非开放式对话）的基于 LLM 或 AI 驱动的辅助工作。

## 2.8 本工作的定位

所提出系统占据了一个在单一系统中很少被同时组合的若干研究领域的交汇点：它应用了**基于遥测证据**的方法而非纯视觉或纯文本方法进行程序性状态跟踪；使用**参数高效 VLM 适配**产生结构化视觉事实而非自由形式描述；对所有可操作输出强制执行**显式证据溯源**；并将**程序包**视为可独立于模型进行编写、版本化和回放的一等配置工件。源于这一定位的具体贡献在第1.5节中列举。

本论文呈现的工作代表了一个技术基线，而非完整评估。VLM 适配结果 (§6) 提供了证据表明结构化视觉事实提取可通过小数据领域微调得到实质性改进，但它们尚未构成学习增益、工作负荷降低或迁移的证据。原始论文研究计划中设想的人因评估仍为计划的下一阶段 (§??)，当前系统最好被理解为使该评估成为可能的运行时与数据采集基础设施。

## 第三章 系统设计

本章描述了一个基于遥测数据基础的教学运行时的设计，用于 DCS F/A-18C 冷启动任务中的程序性训练。本章涵盖系统架构、组件设计和设计原理。详细的方法论——包括 VLM 适配协议、数据集构建和基准测试设计——延至第4章；具体模块的实现级细节见第5章。第3.1节从论文问题陈述中推导设计目标。第3.2节呈现整体架构以及核心教学逻辑与仿真器特定适配器的分离。第3.4节描述主帮助循环中的运行时数据流。第3.5和3.6节涵盖遥测处理流水线以及程序和门控规则引擎。第3.7节详述仿真器适配层及 Lua 端集成。第3.8节描述事件日志、回放和评分基础设施。第3.9节介绍用于视觉状态理解的 VLM 适配组件。

### 3.1 设计目标与需求

本论文解决的是为操作复杂仿真器的学习者提供基于证据、上下文感知的程序性指导这一问题。在目标场景——DCS World 中 F/A-18C 冷启动程序——中，学习者必须执行跨越六个阶段（P1-P6）的 25 个固定步骤序列（S01-S25），从电瓶供电开始，历经发动机启动、航电配置、飞行控制检查，直至滑行准备。每个步骤都有执行前必须满足的特定前提条件和推进前必须满足的完成条件。错误包括遗漏、顺序错误、参数设置错误和状态违反——这些类别在第4章描述的错误分类法中予以形式化。

基于此问题，我们推导出以下设计目标：

- G1 – 基于仿真器的程序性教学。** 系统必须通过仿真器状态观察学习者的操作，确定学习者当前正在尝试的程序步骤，并在学习者卡住或请求帮助时提供及时、基于证据的指导。教学输出必须引用具体的座舱元素，并引用来自遥测、文档或视觉事实的证据。
- G2 – 状态感知的步骤指导。** 系统必须通过形式化状态机跟踪程序进度。在允许步骤变为活跃状态之前，必须评估前提条件；在推进之前，必须验证完成条件。指导必须以当前仿真器状态为条件，而不仅仅是步骤顺序。

- G3 – 教学逻辑与仿真器特定集成的分离。** 核心教学逻辑——程序跟踪、门控、评分和帮助生成——必须独立于任何特定仿真器、模型提供者或知识源。仿真器特定代码、模型提供者代码和知识检索代码必须隔离在稳定接口之后，使核心能够在没有运行仿真器的情况下进行测试，并可移植到其他仿真器或训练领域。
- G4 – 可回放性和可检查性。** 学习者、教学系统和仿真器之间的每次交互都必须记录为结构化、带时间戳的事件。这些事件日志必须支持用于调试的离线回放、针对程序包的自动化评分，以及学习者行为的事后分析。它们还必须支持 VLM 适配流水线的遥测捕获和基准测试追踪的回放。
- G5 – 基础模型与基于 VLM 的视觉事实提取。** 系统必须能够在有大语言模型或无大语言模型的情况下运行。当模型可用时，它可以提供更丰富的诊断和解释。当模型不可用或其输出验证失败时，系统必须优雅降级到确定性的基于规则的降级行为。基于视觉语言模型 (VLM) 从座舱截图中提取视觉事实是一个核心系统组件，它通过为 DCS-BIOS 未导出的显示页面状态提供结构化视觉证据来补充遥测门控。
- G6 – 对不同仿真器和程序的可扩展性。** 程序定义、UI 目标映射、遥测映射、错误分类法和知识源策略必须以声明式配置 (YAML 文件) 表达，而非硬编码在源代码中。添加新程序或将系统适配到不同仿真器应该仅需新的配置工件，而无需更改核心教学逻辑。

这些目标直接影响以下各节描述的架构决策。

## 3.2 整体架构

该系统遵循端口-适配器（六边形）架构。该系统组织为三个主要层次，每个层次具有明确定义的职责和依赖方向。

**核心层 (core/)**。核心包含所有独立于任何特定仿真器、模型提供者或外部服务的领域逻辑。它定义了运行时消息传递的数据契约（第3.4节）、程序状态机和门控规则引擎（第3.6节）、评分和交互度量引擎、视觉事实本体及粘性/TTL 持久化语义、BM25 检索实现、HelpResponse 模式构建器，以及安全和审计基础设施。按设计，核心仅依赖标准 Python 库和端口层中定义的抽象接口。

**端口层 (ports/)**。端口层为核心在运行时可能需要的四个外部依赖定义了稳定的、技术无关的 Python 协议：模型推理 (ModelPort)、知识检索 (KnowledgePort)、



视觉输入 (VisionPort) 和遥测输入 (TelemetryPort)。这些接口是核心与外部世界之间的唯一依赖注入点。

**适配器层 (adapters/)**。适配器层包含所有仿真器特定、提供者特定和基础设施特定的代码。它包括 DCS-BIOS 遥测接收器、遥测增强与增量去噪流水线、DCS 叠加发送器、OpenAI 兼容模型客户端 (带和不带多模态支持)、Ollama 降级客户端、用于测试的确定性模型桩、本地 BM25 知识适配器、视觉事实提取运行时, 以及连接模型输出与运行时行为的响应映射和操作执行组件。适配器依赖于它们所实现的端口以及它们生成和消费的核心类型; 它们从不向核心引入反向依赖。

三个层次由另外两个结构元素补充:

**程序包 (packs/)**。程序包是一个声明式 YAML 配置文件的目录, 完整描述一个程序性任务。包定义了步骤列表、前提条件和完成条件 (门控规则)、UI 目标及其仿真器特定元素标识符、遥测变量映射、错误分类法类别和评分权重、增量去噪策略、带步骤绑定的视觉事实本体, 以及视觉布局描述。当前代码仓库包含一个包: `fa18c_startup`, 涵盖完整的 F/A-18C 冷启动程序。

**CLI 与运行时入口点 (simtutor/、live\_dcs.py)**。simtutor 包提供命令行界面, 用于运行模拟场景、回放和验证事件日志、评分运行、记录 VLM 预测以进行基准测试, 以及回放 DCS-BIOS 原始捕获。live\_dcs.py 模块编排完整的实时运行时循环: 它将 DCS-BIOS 接收器、遥测增强流水线、知识检索、基于模型的帮助生成、VLM 视觉事实提取、叠加操作执行和事件日志记录连接成一个长期运行进程。

图3.1展示了高层组件图。

**Figure 3.1:** 所提出的系统架构。核心层包含仿真器无关的领域逻辑。端口层定义抽象接口。适配器层为 DCS、模型提供者、知识源和视觉流水线提供具体实现。程序包提供声明式配置。

### 3.3 核心教学逻辑与仿真器适配器的分离

仿真器无关核心逻辑与仿真器特定适配器之间的分离服务于四个具体目的:

1. **可测试性**。核心逻辑可以使用模拟适配器和确定性场景进行测试, 无需运行中的 DCS 实例、GPU 或到模型服务器的网络连接。代码仓库包含一个重放预录制观察序列的 `MockEnvAdapter` 和一个返回确定性响应的 `ModelStub`, 从而支持快速、可复现的单元和集成测试。

2. **可维护性**。当仿真器 API 发生变化时，只需更新受影响的适配器；核心保持不变。当模型提供者发生变化时（例如，从 Ollama 变为 OpenAI 兼容的 vLLM 服务器），只有模型适配器配置受到影响。通过单一配置接口支持三种提供者（`openai_compat`、`ollama`、`stub`）。
3. **可移植性**。将系统移植到新仿真器或飞机只需编写新的遥测和叠加适配器并创建新的程序包。程序性推理、门控、评分和帮助生成基础设施可以原样复用。端口接口有意保持最小化：遥测端口需要 `start`、`poll` 和 `stop` 方法；叠加端口仅需向命名座舱元素发送高亮、清除和脉冲命令的能力。
4. **VLM 流水线的独立演进**。VLM 视觉事实提取组件通过视觉端口和视觉事实观察模式与教学运行时通信，而非直接耦合。VLM 流水线可以独立于教学运行时进行开发、训练和基准测试。运行时部署可以包含 VLM 组件、完全省略它，或用不同的感知后端替换它，而不影响教学逻辑。

## 3.4 数据流

运行时数据流遵循从仿真器观察到教学输出和日志记录的结构化流水线。图3.2提供了可视化摘要。

**Figure 3.2:** 主帮助循环中的运行时数据流。

### 3.4.1 观察

仿真器适配器——在当前实现中为 DCS-BIOS UDP 接收器——产生一组观察流：带有版本号和时间戳的数据对象，包含原始仿真器状态以及增强后的一组规范化状态变量。

### 3.4.2 教学请求

当学习者触发帮助时——通过热键或 UDP 消息——将创建一个教学请求。该请求携带一个意图（`help`）、一个可选的自由文本消息、对当前观察的引用，以及由运行时编排器填充的上下文字典。

### 3.4.3 上下文组装

运行时编排器通过收集以下内容为帮助循环组装上下文：

- **状态变量** (`vars`): 来自最近遥测观察的规范化键值对。
- **最近增量** (`recent_deltas`): 最近状态变化的去噪、聚合摘要。
- **候选步骤** (`candidate_steps`): 来自程序包的合格步骤标识符。
- **确定性步骤提示** (`deterministic_step_hint`): 来自基于规则推理的本地计算的降级建议, 同时用作提示指导和模型输出不可用时的降级方案。
- **叠加目标允许列表** (`overlay_target_allowlist`): 模型被允许引用的 UI 元素集合。
- **知识片段** (`rag_topk`, 可选): `top-k` BM25 检索结果, 仅在存在知识索引时包含。

### 3.4.4 模型推理

如果 ModelPort 实现可用, 组装后的上下文将被格式化为提示并发送给语言模型。模型返回一个符合 HelpResponse 模式的 JSON 结构化对象, 该模式在运行时从程序包、UI 映射和分类法动态生成。

### 3.4.5 响应验证与映射

原始模型输出通过验证流水线: (1) 带最小修复的 JSON 提取, (2) 模式验证, (3) 对诊断步骤 ID、下一步步骤 ID 和叠加目标的允许列表检查, (4) 证据溯源验证。如果验证成功, 帮助对象被映射为 TutorResponse, 叠加操作通过 UI 映射解析。如果验证失败, 或没有可用模型, 系统进入确定性降级。

**模式级证据溯源。** 证据约束在模式层面而非事后检查层面运作。HelpResponse JSON Schema 在运行时从程序包和 UI 映射动态生成 (第3.2节)。对于模式中 `targets` 数组里的每个叠加目标, 一条 `if/then` 规则要求相应的 `evidence` 数组至少包含一个 `target` 字段与该叠加目标匹配的条目。每个证据条目还必须声明一个 `type`, 来自五种溯源类型——`var` (遥测变量)、`gate` (门控规则)、`rag` (知识片段)、`delta` (最近状态变化)、`visual` (视觉事实)——每种类型带有对应的 `ref` 前缀 (`VARs.`、`GATES.`、`RAG_SNIPPETS.`、`DELTA_KEYS.`、`VISION_FACTS.`)。若 LLM 响应提出一个叠加高亮却没有匹配的、类型有效的证据条目, 则该响应在结构上无效, 并将在任何操作到达仿真器之前被拒绝。这创建了一个统一的审计追溯: 例如, 高亮 `battery_switch` 必须附带一条证据条目, 形如 `{"target": "battery_switch", "type": "var", "ref": "VARs.battery_switch", "quote": "0"}`, 将操作追溯回为其提供理由的遥测变量。



### 3.4.6 操作执行

教学响应可能包含针对特定座舱元素的叠加操作（高亮、清除或脉冲）。操作执行器根据 UI 目标允许列表验证每个操作，限制并发高亮数量（默认：一个），并通过 UDP 将命令分发到仿真器。自动点击和控件注入操作在设计上被禁止。

### 3.4.7 事件日志记录

帮助循环的每个阶段被记录为带版本号和时戳的 `Event` 对象，并追加到 JSONL 事件日志中，该日志作为所有下游分析、回放和评分的权威记录。

## 3.5 遥测处理

遥测处理子系统通过四个阶段将原始仿真器数据转换为规范化状态表示：

1. **原始数据摄入**。DCS-BIOS 接收器在 UDP 套接字上监听二进制 DCS-BIOS 导出帧，将每帧解码为结构化 JSON 对象，附带挂钟时戳和单调递增的序列号。
2. **变量解析**。遥测映射规定原始 BIOS 字段如何投影到规范化状态变量上。变量解析器生成一个扁平的键值对字典，并在 `vars_source_missing` 集合中跟踪不可用或未知的来源，使下游组件能够区分"值为零"和"值未知"。
3. **增量去噪处理**。可配置的策略（阈值、防抖动窗口、逐变量过滤规则）抑制由开关回弹、传感器漂移和 UDP 乱序传递引起的虚假变化。
4. **增量聚合**。去噪后的增量在可配置时间窗口内累积并被压缩为紧凑摘要以供提示上下文使用。

遥测流水线持续运行，独立于帮助循环。

## 3.6 程序引擎与门控规则引擎

### 3.6.1 程序引擎

程序引擎在步骤有序序列上维护一个有限状态机。每个步骤处于四种状态之一：`pending`、`active`（最多一个）、`done` 或 `blocked`。操作包括 `activate_next`、`complete_active`、`block_active`、`rewind` 和 `check_timeout`。所有转换被记录为内部事件并传播到事件日志。

### 3.6.2 门控规则引擎

门控规则引擎使用具有四个操作符的 v1 DSL 评估前提门控和完成门控：`var_gte`、`arg_in_range`、`flag_true` 和 `time_since`。评估器包含显式的未知值处理：缺失、来源缺失或哨兵值变量会导致规则失败并附诊断原因，而非静默地视为 `false`。规则在首次失败时短路；失败索引和原因被输入确定性步骤提示。

### 3.6.3 基于确定性降级的优雅降级

当没有模型可用或模型输出未通过模式验证时，系统并非简单地返回错误。相反，它通过确定性推理主动计算有用的步骤提示——这一设计选择将所提出的系统与那些没有模型就无法运行的依赖 LLM 的教学系统区分开来。确定性降级分析三个信息来源：(1) 来自程序引擎的活跃步骤及其未满足的门控规则，(2) 学习者最近的 UI 交互（来自增量聚合），(3) 可观测性元数据，该元数据将每个缺失的证据来源分类为硬阻塞（门控显式失败——例如，开关处于错误位置）或软阻塞（遥测源缺失——例如，传感器未被 DCS-BIOS 导出，因此真实状态未知而非 `false`）。这一区分防止教学者在证据仅是不可用时错误地声称某步骤未满足。降级产生仅限于当前活跃步骤的纯文本提示；叠加高亮被抑制，除非本地规则能够根据当前遥测状态唯一确定一个有效目标。这一机制使教学系统在 LLM 不可用时仍能保持部分功能——这是一个刻意的架构属性，而非事后补救。

### 3.6.4 程序包结构

程序包是驱动整个教学运行时的声明式配置。每个步骤按主要证据来源分类：

- **BIOS 优先步骤** (S01, S03–S07, S09–S13, S21)：主要通过 DCS-BIOS 遥测变量进行验证。
- **视觉优先步骤** (S02, S08, S14–S20, S22–S25)：通过 VLM 从座舱显示器中提取视觉事实进行验证。

所有步骤都可通过这两种机制中的至少一种进行观测。包还定义了每个步骤的门控规则、UI 目标、教学提示和配置文件覆盖（陆基 vs. 航母）。

## 3.7 仿真器适配层

### 3.7.1 遥测输入适配器

通过 UDP 接收 DCS-BIOS 状态数据。Python 端 `DcsBiosRawReceiver` 解析二进制协议并发射原始帧作为 JSONL 记录，供给遥测增强流水线。

### 3.7.2 叠加输出适配器

通过纯文本 UDP 消息向 DCS 发送高亮、清除和脉冲命令。DCS 内的 Lua 脚本 (`VRHilite.lua`) 在座舱元素上渲染图形叠加。适配器使用程序包的 UI 映射将抽象目标名称映射到 DCS 内部点代码。

### 3.7.3 视觉输入适配器

通过基于 UDP 的捕获触发器触发 DCS 中的截图捕获。Lua 端 `SimTutor.lua` 将三个主要座舱显示器渲染到单个复合图像中。Python 端适配器选择预触发帧和触发帧，并将它们传递给视觉事实提取器。

### 3.7.4 Lua 端集成

三类 Lua 脚本在 DCS 内执行：

- **状态导出** (`Export.lua`)：配置 DCS-BIOS 导出。
- **叠加渲染** (`Hooks/VRHilite.lua`、`Hooks/SimTutorHighlight.lua`)：接收并渲染高亮命令。
- **SimTutor 集成** (`SimTutor/SimTutor.lua`、`SimTutor/SimTutor Function.lua`、`SimTutor/SimTutorDcsBiosHub.lua`)：处理捕获和复合面板渲染。

### 3.7.5 计划中及部分实现的适配器

当前代码仓库包含一个 `MockEnvAdapter`，用于无需运行仿真器的确定性测试。VR 运行时代码路径已实现，包括 Quest 3 VR 模式下的 `VR_MIRROR` 和 `VR_allow_MFD_out_of_HMI` 配置、教学文本通过 UDP 注入 DCS 游戏内文本区域，以及 VR 模式下复合面板捕获兼容性验证。VR 代码路径尚未通过受控人因实验进行验证（第??节）。

## 3.8 事件日志与回放

### 3.8.1 事件模型

所有运行时事件均表示为具有固定模式的 Event 对象：唯一标识符、挂钟时间戳、会话标识符、事件类型(`observation`、`tutor_request`、`tutor_response`、`overlay_requested`、`overlay_applied`、`overlay_failed`)、类型化负载、模式版本和可扩展元数据。

### 3.8.2 JSONL 事件存储

事件通过 `JsonlEventStore` 以 JSONL 格式持久化，支持仅追加写入和全文件加载。

### 3.8.3 回放与验证

录制的事件日志可离线回放，以验证步骤顺序和状态机一致性。遥测日志经过独立验证以确保单调序列号和时间戳。回放基础设施已在代码层面实现并使用录制的遥测追踪进行了演练；尚未通过端到端的人在环会话进行验证。

### 3.8.4 评分与交互度量

评分引擎使用可配置的逐类别权重和关键步骤乘数计算遗漏和状态违反。交互度量刻画学习者行为：停滞时间、帮助请求、LLM 触发、UI 点击次数以及叠加请求/确认次数。

### 3.8.5 当前局限

回放基础设施当前支持遥测层面的合成回归回放，包括带视觉帧副文件的场景(`replay_eval/fa18c_startup_v04/`)。来自真人运行的带同步视觉帧的完整多模态会话的端到端回放尚未验证。

## 3.9 用于视觉状态理解的 VLM 适配

所提出的系统中的视觉感知是一个核心的、可独立运行的子系统。

### 3.9.1 VLM 组件的角色

VLM 组件从座舱截图中提取结构化视觉事实——关于可见显示内容的中间命题。视觉事实不是最终的教学决策；它们提供视觉证据，教学运行时将其与遥测、程序状态和文档相结合。这种分解使每个组件能够独立开发、测试和评估。

### 3.9.2 视觉事实本体

当前本体（v2）定义了跨三个显示区域的 13 个事实：

- 左 DDI: `tac_page_visible`、`supt_page_visible`、`fcs_page_visible`、`fcs_page_x_marks_visible`。
- 右 DDI: `bit_root_page_visible`、`fcsmc_page_visible`、`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`。
- AMPCD: `hsi_page_visible`、`hsi_map_layer_visible`、`ins_grnd_alignment_text_visible`、`ins_ok_text_visible`。

每个事实具有三值状态（`seen`、`not_seen`、`uncertain`）、生存时间、可选的 `sticky` 标志，以及通过 `all_of` / `any_of` 条件实现的步骤绑定。

### 3.9.3 VLM 在帮助循环中的集成

当帮助请求到达且活跃步骤为视觉优先（S08、S15、S18）时，向 DCS 发送捕获触发器。预触发帧和触发帧被渲染并发送给 VLM。返回的事实被合并到视觉事实快照中（具有粘性和 TTL 语义），并包含在帮助循环上下文中。如果视觉适配器不可用或多模态请求失败，帮助循环仅使用遥测和知识继续。

### 3.9.4 VLM 适配流水线

运行时使用的 VLM 经过微调。适配流水线——详见第 4 章——包括截图捕获、由大型 VLM 进行预标注、在 Label Studio 中进行人工审查、双语 SFT 导出、LoRA 微调（Unsloth + PEFT + TRL），以及在独立留出会话上进行基础模型与 LoRA 对比基准测试。该流水线构成一个自成一体的贡献，涵盖从数据捕获到基准测试评估的全过程。

### 3.9.5 与基于规则的状态门控的区别

基于规则的门控确定性地评估遥测变量；它是确定性的和可审计的，但限于遥测可表示的条件。基于 VLM 的视觉事实提取解释没有遥测表示的显示内容。这两种机

制是互补的：门控引擎提供主要的程序跟踪骨干；视觉事实为那些无法仅从遥测推断完成情况的步骤提供补充证据。

## 第四章 方法论

本章描述支撑已实现系统的方法论框架。第4.1节涵盖将原始 DCS-BIOS 数据转换为规范化运行时状态的遥测处理流水线。第4.2节描述知识溯源子系统，包括 BM25 检索和来源策略执行。第4.3节介绍从截图捕获到 LoRA 微调再到基准测试评估的七阶段视觉事实数据流水线。第4.4节详述六个精选数据集、从 8-fact v1 到 13-fact v2 的本体演进以及训练方案构建。第4.5节说明 LoRA 微调配置，包括两个骨干模型的确切超参数。第4.6节定义基准测试协议、度量和留出策略。本章为第三章呈现的系统设计和第六章报告的技术结果提供了方法论基础。

### 4.1 程序运行时与遥测溯源

程序运行时是本系统跟踪学习者 F/A-18C 冷启动程序进度并生成有依据、状态感知教学输出的核心机制。它摄入原始仿真器遥测数据，将其规范化为稳定的状态变量，评估门控规则以确定步骤合格性，并将结果状态表示提供给帮助循环上下文组装机。本节描述遥测处理链的每个阶段以及门控规则评估框架。

#### 4.1.1 DCS-BIOS 原始帧摄入

遥测子系统始于原始 DCS-BIOS 数据摄入。DCS-BIOS 接收器在 UDP 套接字上监听仿真器发送的二进制 DCS-BIOS 导出帧。每帧被解码为结构化 JSON 对象，附带挂钟时间戳和单调递增的序列号。解码后的帧被写入 JSONL 文件用于存档和回放目的，并转发到遥测增强流水线中。

DCS-BIOS 协议涵盖广泛的座舱控件和指示器——开关位置、旋钮状态、警告灯以及显示相关状态标志——但原始帧是嘈杂的。开关回弹、传感器漂移、快速波动的仪表值以及 UDP 乱序传递会产生虚假变化，如果直接传递给教学运行时，将产生虚假的状态变化事件并触发不必要的帮助循环。后续流水线阶段系统地解决了这些问题。

### 4.1.2 变量解析与源丢失跟踪

遥测映射（在程序包的 `telemetry_map.yaml` 中指定）定义了原始 DCS-BIOS 字段如何投影到规范化状态变量上。变量解析器消费增强后的遥测观察，并生成一个扁平的键值对字典，其中每个键对应程序包中的一个命名变量（如 `apu_ready`、`battery_switch_on`）。

至关重要的是，解析器跟踪不可用或未知的来源，使下游组件能够区分“值为零”和“值未知”，这对正确的门控规则行为至关重要。缺失的变量永远不会静默地评估为成功条件。

### 4.1.3 门控规则评估

程序引擎为每个步骤评估两种类型的门控：前提门控（在步骤变为活跃之前必须满足）和完成门控（在步骤被标记为完成之前必须满足）。门控规则 DSL 支持四种操作符：

**var\_gte** — 命名变量必须大于或等于阈值。

**arg\_in\_range** — 命名变量必须落在指定范围内。

**flag\_true** — 布尔标志必须为 `true`。

**time\_since** — 自指定事件以来必须经过最小时间。

评估器包含显式的未知值处理：缺失、来源缺失或哨兵值变量会导致规则失败并附诊断原因，而非静默地视为 `false`。规则在首次失败时短路，失败索引和原因被传播到下游组件，包括确定性步骤提示和帮助循环上下文。

门控规则以声明方式在程序包的配置中指定。F/A-18C 冷启动程序中的每个步骤都根据程序的操作要求被分配了前提门控和完成门控。分类为 BIOS 优先的步骤（S01、S03-S07、S09-S13、S21）主要依赖基于遥测的门控规则进行完成检测。分类为视觉优先的步骤（S08、S15、S18）以视觉事实证据补充门控评估，因为它们的完成条件涉及遥测中未反映的座舱显示状态。

### 4.1.4 增量去噪与聚合

原始遥测变量由于仿真器物理以高频率变化，即使没有执行任何学习者操作。为产生适合提示上下文的稳定状态表示，流水线应用两个连续的处理阶段。

**增量去噪**。可配置的策略（在程序包的 `delta_policy.yaml` 中指定）定义了逐变量阈值、防抖动窗口和过滤规则。由开关回弹、传感器噪声和 UDP 乱序传递引起的虚



假变化被抑制。只有超过配置阈值并在防抖动窗口后持续存在的变化才被提升到去噪后的增量流中。

**增量聚合。**去噪后的增量在可配置时间窗口内累积，并被压缩为紧凑的、人类可读的摘要。该摘要被包含在帮助循环上下文中，为语言模型提供最近学习者操作和状态转换的简洁表示，而不暴露原始高频遥测数据。

### 4.1.5 确定性降级

当没有语言模型可用或模型输出验证失败时，程序运行时降级到确定性步骤推理。降级机制检查当前活跃步骤、其未满足的门控规则以及最近的 UI 目标，以产生限制在当前活跃步骤的文本提示。默认情况下，除非本地规则能够根据当前遥测状态证明一个唯一、有效的目标，否则在降级模式下不发送叠加高亮。这确保系统即使在没有模型的情况下也能保持运行和安全。

### 4.1.6 运行时效率缓存

程序运行时中若干对性能至关重要的路径采用 LRU 缓存，以避免在长时间的辅导会话中重复计算。HelpResponse JSON Schema 验证每次模型生成的叠加层和解释是否符合当前程序包配置，该 Schema 以其源配置文件的文件系统修改时间为键进行缓存；当配置未变更时跳过 Schema 重新生成，消除了每次帮助循环中冗余的 YAML 解析和 JSON Schema 构建。视觉事实配置加载器采用相同的缓存策略，避免在每次视觉观察合并时重复解析和规范化 13-fact 本体。这些缓存点被选择性地应用于那些本会重复相同 I/O 和验证工作的路径，体现了对运行时效率的关注，同时避免了缓存失效复杂性的引入。

## 4.2 知识溯源与来源策略

知识溯源子系统为教学运行时提供检索增强的程序性文档。它从已索引的文档集合中检索相关文本片段，并强制执行限制哪些文档可以呈现给模型的来源策略。知识溯源是教学运行时的核心架构特性：每次帮助循环从当前程序状态组装溯源查询，检索相关文档片段，并将其作为证据上下文包含在模型提示中。

### 4.2.1 BM25 检索

知识检索使用 BM25，一种来自概率信息检索家族的词袋排序函数。文档在句子级别进行索引：F/A-18C NATOPS 飞行手册和补充冷启动文档被预处理为本地 JSON

索引。

在检索时，从当前程序状态构造一个溯源查询：活跃步骤标识符、其在步骤注册表中的描述以及最近的遥测观察。查询使用标准 BM25 加权函数以默认参数 ( $k_1 = 1.2$ ,  $b = 0.75$ ) 进行分词并与索引句子进行评分。返回 top- $k$  得分片段（默认  $k = 5$ ），并作为证据上下文包含在帮助循环提示中。

### 4.2.2 来源策略

并非所有知识源都适用于每种教学上下文。声明式来源策略（在 `knowledge_source_policy.yaml` 中指定）定义了允许的文档来源允许列表。每个索引句子携带一个来源标识符，策略强制执行只有来自允许来源的片段才包含在检索结果中。

来源策略服务于两个目的。首先，它防止模型暴露于与当前程序包相矛盾的程序变体——例如，当当前配置文件为陆基时的航母程序。其次，它将检索范围限制在经过筛选、已验证的文档中，降低因过时或不相关来源产生幻觉的风险。

## 4.3 视觉事实数据流水线

视觉事实数据流水线将原始 DCS 座舱截图转换为结构化视觉事实提取模型。它包含七个阶段，涵盖数据捕获、人工标注、监督微调数据集生成、模型训练和基准测试评估。每个阶段产生带版本号、可检查的工件，实现从原始图像到基准测试指标的完全可追溯性。图4.1提供了概览。

**Figure 4.1:** 七阶段视觉事实数据流水线。捕获和预标注供给人工审查；经审查的标注驱动双语 SFT 导出；导出的数据训练 LoRA 适配器；基础模型和 LoRA 模型在独立留出集上进行基准测试。

### 4.3.1 第一阶段：DCS 截图捕获

第一阶段从 DCS World 捕获座舱截图。DCS 将三个主要多功能显示器——左 DDI、AMPCD 和右 DDI——渲染为单个复合面板图像。捕获过程以可配置间隔触发截图，将每次捕获与一个会话标识符和挂钟时间戳关联，并存储原始图像及副文件清单。

选择复合面板格式是为了使训练、预标注、评估和运行时使用保持在同一输入分布上，避免训练-评估不匹配——即模型在训练期间接收三个分离的区域裁剪图像，但在推理时接收单个复合图像。

### 4.3.2 第二阶段：初始 VLM 预标注

每张捕获的复合面板图像由大型 VLM (通过 OpenAI 兼容 API 访问的 Qwen 397B 级模型) 使用目标视觉事实本体作为提示契约进行预标注。预标注脚本将每张图像与一个结构化提示一起发送, 该提示枚举本体中的所有事实、其定义以及三种可接受状态 (`seen`、`not_seen`、`uncertain`)。VLM 返回一个包含逐事实标签和证据注释的 JSON 对象。

预标注作为种子步骤: 它大规模生成初始标注, 然后通过人工审查加以完善。预标注 VLM 是大型通用模型; 它未在座舱领域进行微调, 经常在模糊或稀有视觉状态上出错。下一阶段的人工审查纠正这些错误。

### 4.3.3 第三阶段：Label Studio 人工审查

预标注样本被导入 Label Studio, 一个开源数据标注平台。每个任务向审查者呈现复合面板图像、VLM 对所有事实的预测标签以及一个自由文本摘要字段。审查者检查图像, 纠正任何标注错误的事实, 并为每处更正提供证据注释。审查界面强制要求每个事实接收三种可接受状态之一, 并且摘要字段必须填写。

人工审查是质量控制瓶颈: 每个捕获会话包含 50 到 220 张图像, 每张图像的审查时间取决于可见事实的数量和审查者对座舱显示的熟悉程度。所有经审查的样本都带有审计追踪, 可追溯到原始图像、原始 VLM 预标注和审查者的更正。

### 4.3.4 第四阶段：经审查的 JSONL 导出

人工审查后, Label Studio 将更正后的标签导出为 JSONL 文件。每行包含任务标识符、原始图像路径、带逐事实状态和证据注释的经审查事实, 以及经审查的摘要。此经审查的 JSONL 是所有下游阶段 (SFT 导出、训练和基准测试) 的权威真实标注工件。

### 4.3.5 第五阶段：双语 SFT JSONL 生成

经审查的 JSONL 被转换为 OpenAI 兼容的多模态对话 SFT 格式。每个经审查的样本生成两行训练数据——一行英文和一行中文——共享相同的复合面板图像和相同的事实标签, 但在系统和用户指令文本上有所不同。

每个 SFT 行是一个三消息对话: 一则系统消息指示模型仅输出 JSON, 一则用户消息包含 base64 编码的图像和文本指令 (枚举所有事实、其定义和决策边界), 以及一则助手消息包含带有 `facts` 数组和 `summary` 字符串的真实标注 JSON 对象。助手输出中的每个事实条目恰好包含三个字段: `fact_id`、`state` 和 `evidence_note`。外部元

数据字段如 `frame_id`、`session_id`、`confidence` 和图像路径被排除在训练目标之外，因为它们是数据集管理字段，而非视觉可推断属性。

双语 SFT 增加的是指令多样性而非视觉多样性：英文和中文示例共享相同的图像和事实标签。其目的是提高两种语言下的 JSON 格式鲁棒性，并支持最终的双语运行时部署。

### 4.3.6 第六阶段：LoRA 微调

导出的 SFT JSONL 文件用于通过低秩适配 (LoRA) 微调基础 VLM。训练栈组合三个组件：Unsloth 用于 4 位 VLM 加载、LoRA 注入和视觉批次整理；PEFT（参数高效微调）用于 LoRA 适配器定义；TRL SFTTrainer 用于监督微调循环。

训练脚本通过 Unsloth 的 `FastVisionModel.from_pretrained` 以 4 位精度加载基础模型，对视觉和语言层 (Qwen) 或仅语言线性层 (Gemma) 应用 LoRA 适配器，并在双语 SFT 数据上进行训练。适配器权重与基础模型分开保存，便于高效存储和推理时加载。完整的训练配置细节见第 4.5 节。

### 4.3.7 第七阶段：基础模型与 LoRA 对比基准测试

最后阶段在留出数据集上评估微调后的 LoRA 适配器与未适配基础模型。基准测试脚本以 4 位推理模式加载每个模型（基础模型和基础模型加 LoRA），通过训练期间使用的相同提示发送每个留出样本，根据预期 JSON 模式解析和验证模型输出，并计算一套将模型预测与人工审查真实标注进行比较的度量。基准测试协议详见第 4.6 节。

### 4.3.8 端到端可追溯性

该流水线的一个定义性方法论属性是端到端可追溯性。每个基准测试预测都可以通过训练数据、人工审查标签、VLM 预标注和原始 DCS 截图进行追溯。流水线在每个阶段产生带版本号的工作：捕获清单、预标注 JSONL 文件、Label Studio 导出文件、SFT JSONL 文件、LoRA 适配器权重、`train_summary.json` 文件、基准测试预测以及基准测试度量摘要。这一监管链使得对任何观察到的模型行为进行严格审计成为可能，从单个事实误分类到聚合基准测试度量。

## 4.4 数据集构建

### 4.4.1 数据集概览

视觉事实数据流水线在连续的捕获和审查周期中生成了六个数据集。表4.1总结了每个数据集的角色、样本数、事实本体版本、审查状态和导出语言。

**Table 4.1:** 数据集清单。所有样本数来自相应的 `stats.json` 文件。

| 数据集                                                                  | 角色                | 样本  | 本体         | 已 |
|----------------------------------------------------------------------|-------------------|-----|------------|---|
| Run-001 ( <code>vision_sft</code> )                                  | 训练源 (8-fact v1)   | 180 | 8-fact v1  |   |
| Run-002 ( <code>vision_sft_holdout_run002</code> )                   | 留出 (8-fact v1)    | 50  | 8-fact v1  |   |
| Run-002 newfacts ( <code>vision_sft_holdout_run002_newfacts</code> ) | 留出 (13-fact v2)   | 50  | 13-fact v2 |   |
| Run-003 ( <code>vision_sft_run003</code> )                           | 训练源 (13-fact v2)  | 220 | 13-fact v2 |   |
| Run-004 ( <code>vision_sft_holdout_run004_random</code> )            | 留出 (13-fact v2)   | 100 | 13-fact v2 |   |
| Run-005 ( <code>vision_sft_run005_composition_rebalance</code> )     | 训练补充 (13-fact v2) | 122 | 13-fact v2 |   |

每个数据集均经过完全人工审查：每个样本都已在 Label Studio 中检查并更正。Run-003 和 Run-005 包含人工审查者将摘要字段留空的样本（分别有 82 和 25 个样本，如 `missing_summary_count` 字段所记录）。这些样本对训练和评估仍然有效，因为事实数组——主要监督目标——对每个样本中的每个事实都已完全标注。

### 4.4.2 本体演进：从 8-Fact v1 到 13-Fact v2

初始的 8-fact v1 本体(用于 Run-001 和 Run-002)定义了八个事实：`fcs_page_visible`、`bit_root_page_visible`、`bit_page_failure_visible`、`right_ddi_fcsmc_page_visible`、`right_ddi_in_test_visible`、`fcs_bit_result_visible`、`ins_alignment_page_visible` 和 `ins_go`。

v1 本体在初始基准分析中暴露出两个结构性弱点。首先，它混合了抽象层次：一些事实描述低层视觉观察（如 `fcs_page_visible`），而另一些则编码了更高层的程序性判断（如 `ins_go`，它代表 INS 校准过程的完成信号而非直接可观察的视觉特征）。其次，若干事实共享重叠语义：`bit_root_page_visible` 和 `bit_page_failure_visible` 可能在某些座舱状态下重叠，而 `right_ddi_fcsmc_page_visible` 将区域标识符与事实语义混淆。

13-fact v2 本体（用于 Run-003、Run-004、Run-005 及当前运行时）重新设计并扩展了事实集。v2 事实为：`tac_page_visible`、`supt_page_visible`、`fcs_page_visible`、`fcs_page_x_marks_visible`、`bit_root_page_visible`、`fcsmc_page_visible`、`fcsmc_intermediate`

`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`hsi_page_visible`、`hsi_map_layer_visible`、`ins_grnd_alignment_text_visible` 和 `ins_ok_text_visible`。

v2 重新设计通过三种策略解决了 v1 的弱点。首先，模糊的 `ins_go` 事实被分解为两个低层、直接可观察的事实：`ins_grnd_alignment_text_visible`（要求字面 GRND 校准块文本）和 `ins_ok_text_visible`（要求校准块附近清晰可读的 OK 文本）。其次，区域标识符从事实名称中移除（`right_ddi_fcsmc_page_visible` 变为 `fcsmc_page_visible`），并为 TAC 和 SUPT 菜单添加了页面可见性事实以覆盖左 DDI。第三，FCS-MC 状态序列被分解为更细粒度的四状态链（`page`、`intermediate_result`、`in_test`、`final_go_result`），替换了单一的 `fcs_bit_result_visible` 事实。第四，HSI 相关事实被拆分为 `hsi_page_visible` 和 `hsi_map_layer_visible`，FCS X 标记事实与 FCS 页面可见性分离。

### 4.4.3 训练方案：Run-003 + Run-005x2

13-fact v2 模型的主要训练方案将 Run-003（220 个经审查样本，双语导出生成 220 条英文和 220 条中文训练行）与包含两次的 Run-005 组合再平衡数据（122 个经审查样本，双语导出生成  $122 \times 2 = 244$  条英文和  $122 \times 2 = 244$  条中文训练行）相结合。得到的训练集包含 928 行。

Run-005 专门作为组合再平衡数据集采集。对 Run-003 事实状态分布的分析揭示了严重的类别不平衡：若干关键事实（如 `fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`ins_ok_text_visible`）在训练数据中具有极少的 `seen` 示例。Run-005 设计了目标座舱状态转换以过采样这些代表性不足的视觉状态。

Run-005 的双重计数（Run-005x2）进一步放大了这些稀有状态在训练分布中的代表性。该训练运行的输入文件为：来自 Run-003 的 `sft_en.jsonl` 和 `sft_zh.jsonl`，加上来自 Run-005 的 `sft_en.jsonl` 和 `sft_zh.jsonl` 各两份副本，共计六个输入文件。

未使用内部评估划分：训练配置设置 `eval_rows = 0`。所有评估均在独立留出数据集上执行。

### 4.4.4 留出集独立性验证

留出集独立性是一项关键的方法论要求：基准测试必须测量跨会话泛化，而非分布内记忆。构建了两个留出集：

- **Run-002**（及其 13-fact 重标注 `run002_newfacts`）：一个与所有训练会话不同的新 DCS 捕获会话。包含 50 个经审查样本。

- **Run-004 random**: 一个进一步独立的捕获会话，采用均匀随机采样的座舱状态。包含 100 个经审查样本。

每个留出集与训练数据之间的完全重叠经验证为零 (0)。重叠检查比较了训练和留出划分中的图像工件路径和样本标识符。没有留出样本出现在任何训练输入文件中。

相比之下，早期 8-fact v1 实验中使用的 Run-001 基准测试是一个**受污染开发集**：训练示例所来源的同一数据池被用于评估。Run-001 结果仅为回归分析报告，并与独立留出结果明确区分。

## 4.5 LoRA 微调配置

### 4.5.1 基础模型

两种基础 VLM 架构在相同训练数据方案下进行了微调以实现骨干对比：

**Qwen/Qwen3.5-9B-Base** — 一个 90 亿参数的视觉语言模型，支持多模态输入（图像 + 文本）和文本生成。这是主要的实验骨干。

**google/gemma-4-31B** — 来自 Google DeepMind 的 310 亿参数视觉语言模型。这是补充对比骨干，用于检验相同训练数据方案是否可跨模型家族泛化。

两个模型均通过 Unsloth 的 `FastVisionModel.from_pretrained` 以 4 位精度加载。对 Qwen, LoRA 适配器应用于视觉层和语言层 (`finetune_vision_layers=True`, `finetune_language_layers=True`)。对 Gemma, LoRA 被限制在所有线性模块 (`lora_target_modules`) 且视觉层未微调 (`finetune_vision_layers=False`)。

### 4.5.2 训练栈

训练栈包含三个集成组件：

1. **Unsloth** — 处理 4 位模型加载、LoRA 注入、通过 `UnslothVisionDataCollator` 进行视觉批次整理，以及 FP16/BF16 自动精度选择。
2. **PEFT (参数高效微调)** — 定义 LoRA 适配器格式，包括秩、alpha、dropout 和目标模块选择。
3. **TRL SFTTrainer** — 以可配置的批次大小、梯度累积、轮数、学习率、预热和权重衰减运行监督微调循环。

4.5.3 超参数配置

表4.2列出了主要训练运行 (Run-003 + Run-005x2) 使用的精确超参数，在两个骨干间匹配。所有值取自 `train_summary.json` 工件。

Table 4.2: LoRA 微调超参数，在 Qwen3.5-9B 和 Gemma-4-31B 间匹配。

| 参数                          | Qwen3.5-9B                          | Gemma-4-31B        |
|-----------------------------|-------------------------------------|--------------------|
| max_seq_length              | 4096                                | 4096               |
| num_train_epochs            | 4.0                                 | 4.0                |
| learning_rate               | $2 \times 10^{-4}$                  | $2 \times 10^{-4}$ |
| per_device_train_batch_size | 1                                   | 1                  |
| gradient_accumulation_steps | 4                                   | 4                  |
| lora_r                      | 16                                  | 16                 |
| lora_alpha                  | 16                                  | 16                 |
| lora_dropout                | 0.0                                 | 0.0                |
| seed                        | 3407                                | 3407               |
| load_in_4bit                | True                                | True               |
| warmup_ratio                | 0.1                                 | 0.1                |
| weight_decay                | 0.01                                | 0.01               |
| train_rows                  | 928                                 | 928                |
| eval_rows                   | 0                                   | 0                  |
| 骨干特定                        |                                     |                    |
| 视觉 LoRA                     | 启用                                  | 禁用                 |
| LoRA 目标模块                   | vision + language + attention + MLP | all-linear         |
| 对话模板                        | Qwen 默认                             | gemma-4            |
| GPU 内存利用率                   | 0.6                                 | 0.95               |
| 训练结果                        |                                     |                    |
| 训练运行时间 (秒)                  | 6419.16                             | 8049.65            |
| 训练损失 (最终)                   | 0.2156                              | 0.0474             |

最终训练损失值 (Qwen 为 0.2156, Gemma 为 0.0474) 不应在骨干间直接比较，因为分词器行为、对话模板结构、目标序列分布和模型参数化各不相同。4 个轮数的选择是作为小数据领域适配的折衷：仅有 928 个训练样本，更少的轮数可能无法可靠地教会模型固定的 JSON 模式和座舱事实边界，而更多的轮数则有过度拟合训练会话的风险。

LoRA 秩  $r = 16$  和  $\alpha = 16$  提供适度的适配能力：足以学习座舱布局模式和 JSON 格式，但不像高容量适配器 ( $r \geq 64$ ) 那样可能更激进地过度拟合小数据集。在主要运行中将 Dropout 设置为零，在首次适配实验中优先考虑可学习性而非正则化。



### 4.5.4 双语 SFT 策略

双语 SFT 策略为每个经审查样本生成两行训练数据：一行使用英文系统和用户指令，一行使用中文指令。两行共享相同的图像（base64 编码）和相同的助手目标（真实标注事实 JSON）。英文助手目标被复用于中文行；模型的任务是从图像中提取视觉事实，而非生成语言特定的自然语言描述。

这种方法在不增加额外人工标注工作量的情况下提高了跨语言指令遵循的鲁棒性。然而，它不能替代额外的座舱状态截图或困难负样本视觉数据。

### 4.5.5 组合再平衡策略

组合再平衡策略（Run-005）解决了主要训练源（Run-003）中观察到的类别不平衡。在 Run-003 中，若干事实具有极低的正例（seen）计数：`ins_ok_text_visible` 在 220 个样本中仅有 12 个 seen 示例（5.5%）；`fcs_page_x_marks_visible` 有 16 个（7.3%）；`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible` 和 `fcsmc_final_go_result_visible` 各有 18 个（8.2%）。

Run-005 捕获了 122 个额外样本，针对这些稀有事实为 seen 的座舱状态。在 Run-005 增强后，组合训练集提供了对先前代表性不足事实的改进覆盖：`supt_page_visible`（组合 seen 从 20 到 54）、`fcsmc_page_visible`（从 55 到 111）、`hsi_page_visible`（从 106 到 215）以及 `ins_grnd_alignment_text_visible`（从 58 到 130）。

Run-005 数据在训练方案中被包含两次（Run-005x2），进一步放大了这些代表性不足视觉状态的信号。

## 4.6 基准测试协议

### 4.6.1 度量指标

基准测试使用以下度量比较模型预测与人工审查真实标注标签：

**json\_valid\_rate** — 模型输出可被解析为 JSON 对象的样本比例。此处的失败表明模型产生了非 JSON 文本（如 markdown、自然语言评论或格式错误的括号）。

**schema\_valid\_rate** — 解析后的 JSON 符合预期模式的样本比例：顶层对象仅包含 `summary` 和 `facts` 键，`facts` 数组中每个条目恰好包含 `fact_id`、`state` 和 `evidence_note`，所有 13 个事实 ID 均恰好出现一次，所有状态均在 `{seen, not_seen, uncertain}` 中。

**fact\_accuracy** — 所有样本中所有事实的三类准确率，计算为与真实标注标签匹配的单个事实预测的比例。

**macro\_f1** — 跨三种状态 (`seen`、`not_seen`、`uncertain`) 的宏平均 F1 分数，逐事实计算后跨所有 13 个事实平均。

**seen\_f1** — 正类 `seen` 的 F1 分数，逐事实计算后跨所有 13 个事实平均。这是一个特别重要的指标，因为遗漏 `seen` 状态 (假阴性) 或幻觉出 `seen` 状态 (假阳性) 直接影响下游程序状态推理。

**sample\_exact\_match** — 所有 13 个事实与真实标注标签完全匹配的样本比例。单个事实的误分类计为样本级失败。

**critical\_false\_positive\_count** — 分类为关键的事实子集(6 个事实的子集: `fcs_page_x_marks_visible`、`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`ins_grnd_alignment_text_visible`、`ins_ok_text_visible`) 中，当真实标注为 `not_seen` 或 `uncertain` 时被预测为 `seen` 的错误计数。

关键假阳性被单独跟踪，因为它们代表了教学上下文中最具后果性的错误类型：错误地报告一个完成关键状态为已观察而实际上并非如此。例如，一个错误地认为 INS 校准已完成 (基于 `ins_ok_text_visible` 假阳性) 的导师可能跳过必要的指导，潜在地导致程序性错误。

基准测试还计算逐事实混淆矩阵以及逐事实的精确率、召回率和 F1 分数，这些存储在 `fact_scores.csv` 中，并附带自动生成的图表 (总体准确率、样本完全匹配、逐事实宏 F1、逐事实 `seen` F1、关键假阳性以及逐事实混淆矩阵)。

## 4.6.2 基础模型与 LoRA 对比方法论

基准测试协议比较两种模型配置在相同真实标注标签上的表现：

1. **基础模型**：未适配的基础 VLM，以 4 位推理模式加载，不带任何 LoRA 适配器。
2. **LoRA 模型**：相同基础 VLM，以 4 位推理模式加载，通过 PEFT 的 `PeftModel.from_pretrained` 加载 LoRA 适配器权重。

两种配置接收相同的提示、相同的图像和相同的生成参数：`temperature = 0.0` (贪婪解码)、`max_new_tokens = 1024`、`seed = 3407`。基准测试独立运行每个样本，将预测序列化到 JSONL 中，并在没有任何事后过滤或排除的情况下计算度量。

对比脚本 (`comparison.json`) 计算增量度量 (LoRA 减去基础模型) 和一个自动化推荐标志 (`recommend_simtutor_chain_validation`)，该标志在 LoRA 适配器同时提升 JSON 有效性、事实准确率、`seen` F1，且不增加关键假阳性时激活。

### 4.6.3 留出定义与基准测试类别

每个基准测试运行被赋予一个 `benchmark_kind`，决定其结果应如何解读：

**contaminated\_dev\_set** — 评估集从与训练集相同的数据池中抽取。结果表明模型是否学会了模式和分布内视觉边界，但不能支持泛化声明。用于 Run-001 基准测试。

**heldout\_new\_session** — 评估集是一个完全独立的捕获会话，与任何训练数据零重叠。结果支持跨会话泛化声明。这是主要评估类别。Run-002 newfacts 和 Run-004 random 基准测试属于此类别。

受污染与留出基准测试之间的区分在整个基准测试基础设施中被严格执行，并反映在结果章节（第六章）中。

### 4.6.4 基准测试工件

每个基准测试运行生成一个标准化的工件目录：

- `benchmark_summary.json` — 顶层摘要，包含对比增量和图表路径。
- `metrics_base.json` / `metrics_lora.json` — 完整度量字典，包括逐事实分数和混淆矩阵。
- `predictions_base.jsonl` / `predictions_lora.jsonl` — 逐样本模型输出，每行一个 JSON 对象。
- `errors_base.jsonl` / `errors_lora.jsonl` — 单个预测错误，包含金标签、预测标签和原始模型文本。
- `comparison.json` — 增量度量和推荐标志。
- `fact_scores.csv` — 逐事实逐模型度量的 CSV 表。
- `report.md` — 人类可读的 markdown 摘要。
- `charts/` — 自动生成图表：总体准确率、样本完全匹配、逐事实宏 F1、逐事实 seen F1、关键假阳性，以及基础模型和 LoRA 模型的逐事实混淆矩阵。

这些工件构成了第六章中报告的技术结果的完整证据链。通过使用相同的经审查 JSONL 和 LoRA 适配器权重重新运行基准测试脚本，每个度量、图表和错误记录都是可复现的。

## 4.7 本章小结

本章描述了本系统的四个方法论支柱：基于遥测证据的程序运行时、以 BM25 检索和来源策略为基础的知识溯源、从截图捕获到基准测试的七阶段视觉事实数据流水线，以及在两个骨干架构间匹配超参数的 LoRA 微调协议。该方法论的特征在于端到端可追溯性——每个基准测试度量可通过训练数据、人工审查标签和原始截图进行追溯——以及受污染开发基准测试与独立留出基准测试之间的严格分离。这些方法论选择直接支撑了第[六](#)和第[七](#)章中呈现的声明和结果。

# 第五章 实现

本章描述 SimTutor 系统的具体实现，其设计已在第[三](#)章中呈现。本章涵盖技术栈、核心领域模块、遥测与 DCS 集成流水线、结构化帮助生成子系统、VLM 视觉事实提取运行时、回放与日志基础设施，以及 CLI 和实时运行时入口点。方法论层面的细节——VLM 适配协议、数据集构建和基准测试设计——见第[四](#)章。

## 5.1 技术栈

SimTutor Python 代码库使用 Poetry<sup>1</sup> 管理，要求 Python 3.10 或更高版本。核心库依赖保持最小化：`httpx` (v0.28+) 用于 HTTP 客户端功能，`PyYAML` (v6+) 用于所有声明式配置，`jsonschema` (v4.23+) 用于模型输出和遥测帧的 Draft 2020-12 JSON Schema 验证，以及 `Pillow` (v12+) 用于 VLM 流水线中的图像处理。测试依赖 `pytest` (v7.4+) 和 `pytest-cov` (v5.0+) 并启用分支覆盖率。

DCS Lua 端集成包含部署到 DCS Saved Games 目录的五个脚本：`Export.lua` 引导 DCS-BIOS 导出协议；`VRHilite.lua` 和 `SimTutorHighlight.lua` 在 UDP 套接字上监听高亮、清除和脉冲命令，并通过 `net.dostring_in` 将它们渲染为座舱叠加；`SimTutor.lua` 及其配套 `SimTutor Function.lua` 处理复合面板截图捕获和 DCS-BIOS 集线器集成。

模型服务是提供者无关的。主要路径使用 OpenAI 兼容 API 端点（适用于 vLLM、llama.cpp 或 TGI 服务器），通过环境变量 `SIMTUTOR_MODEL_PROVIDER=openai_compat` 以及基础 URL 和 API 密钥进行配置。Ollama 降级方案(`SIMTUTOR_MODEL_PROVIDER=ollama`)提供无需 API 密钥的本地兼容性。确定性桩(`SIMTUTOR_MODEL_PROVIDER=stub`)为测试返回固定响应，无需任何外部模型服务。通过设置 `SIMTUTOR_MODEL_ENABLE_MULTIMODAL=1` 启用多模态支持，使 OpenAI 兼容适配器在请求负载中包含 base64 编码的图像。

视觉语言模型的 LoRA 微调使用 Unsloth 库配合 PEFT 和 TRL，以 Qwen3.5-9B-Base 为主要骨干，Gemma-4-31B 为补充线。视觉事实标注的预标注和人工审查在 Label Studio 中进行。

---

<sup>1</sup>版本 0.1.0，在 `pyproject.toml` 中以包名 `simtutor-core` 声明。

## 5.2 核心领域层

核心层实现所有独立于特定仿真器、模型提供者或外部服务的领域逻辑。它被组织为大约十五个模块，每个模块具有明确的单一职责。

### 5.2.1 程序引擎

`core/procedure.py` 中的 `ProcedureEngine` 类实现了第3.6节描述的步骤状态机。每个步骤由一个 `StepState` 数据类表示，包含步骤标识符和 `StepStatus` 枚举定义的四种状态之一：PENDING、ACTIVE、DONE 或 BLOCKED。引擎强制确保在任何时刻最多只有一个步骤为 ACTIVE。暴露五个操作：`activate_next` 将下一个 PENDING 步骤推进到 ACTIVE；`complete_active` 将活跃步骤转换为 DONE；`block_active` 将其标记为 BLOCKED；`rewind` 将已完成步骤返回到 ACTIVE；`check_timeout` 测试活跃步骤是否超过可配置的挂钟时限。所有状态转换发出带有 ISO-8601 时间戳和可选原因字符串的内部事件记录；这些事件随后传播到 JSONL 事件存储。

### 5.2.2 门控规则引擎

`core/gating.py` 中的门控引擎评估以前述小型领域特定语言表达的前提门控和完成门控。实现了四种操作符：`var_gte`（遥测值阈值）、`arg_in_range`（数值区间成员）、`flag_true`（带字符串强转的布尔标志）和 `time_since`（自标记事件以来的挂钟时间）。每条规则返回一个 `RuleResult` 数据类，携带布尔状态、点号表示法的失败路径以及人类可读的原因。评估器包含显式的未知值处理：哨兵字符串 "unknown"、"unk"、"missing"、"n/a" 和 "na" 导致规则失败并附诊断消息，而非静默地视为 `False`。规则在首次失败时短路；首个未满足规则的索引和原因输入确定性步骤推理逻辑。

### 5.2.3 评分引擎

`core/scoring.py` 中的评分模块实现了一个简单的事件日志评分器，遵循程序包中定义的错误分类法。它统计两类错误：遗漏（OM），定义为从未完成直到最大观察到步骤的规范步骤；以及状态违反（SV），通过观察负载中的 "state\_violation" 标签识别。对步骤注册表中标记为 `critical` 的步骤遗漏应用关键步骤乘数。三个额外类别（CO、OR、PA）的分类法定义了计数器和基础权重，但在当前 v1 评分实现中默认值为零。总错误分数计算为向上取整的加权和。

### 5.2.4 视觉事实本体与状态管理

`core/vision_facts.py` 中的视觉事实模块将 13-fact v2 本体集中为 `VISION_FACT_IDS` 元组, 包含诸如 `tac_page_visible`、`fcsmc_final_go_result_visible` 和 `ins_ok_text_visible` 等标识符。配置通过一个文件系统 `stat` 缓存、LRU 缓存的加载器 (`load_vision_facts_config`) 从 `vision_facts.yaml` 加载, 该加载器规范化事实规范 (粘性标志、毫秒 TTL、预期区域、关联步骤 ID) 和步骤绑定 (`all_of` 和 `any_of` 条件)。

`merge_vision_fact_observation` 中的核心合并逻辑实现了三种关键语义。第一, 粘性保留: 先前状态为 `seen`、其 `sticky` 标志为 `True` 且其 TTL 未过期的事实不会被后续的 `not_seen` 或 `uncertain` 观察覆盖——只有后续的 `seen` 或过期才能替换它。第二, 基于 *TTL* 的过期: `prune_expired_facts` 丢弃任何 `expires_at_wall_ms` 早于当前挂钟时间的事实。第三, 步骤绑定满足: `facts_satisfy_step_binding` 检查 `all_of` 列表中的所有事实均为 `seen` 且 `any_of` 列表中至少有一个事实 (如果已定义) 为 `seen`。

对于 `fcsmc_final_go_result_visible` 事实 (步骤 S18), 一个额外的强制转换层检查 `result_kind` 字段和 `evidence_note` 文本, 对照一组正则表达式 (如 "MC1: GO"、"FCSA: GO")。seen 状态仅在分类产生 "final\_go" 时保留; 中间状态 (如 "intermediate\_go"、"in\_test" 或 "not\_ready") 被强制转换为 "not\_seen", 其他任何状态被强制转换为 "uncertain"。

### 5.2.5 动态 HelpResponse 模式

`core/llm_schema.py` 模块在运行时而非从静态文件生成结构化帮助响应的 JSON Schema。函数 `build_help_response_schema` 接收三个枚举值列表——来自步骤注册表 (或包配置) 的步骤标识符、来自 UI 映射的叠加目标名称, 以及来自分类法的错误类别代码——并构建一个具有四个必需顶层键的 Draft 2020-12 模式: `diagnosis`、`next`、`overlay` 和 `explanations`。模式中一个特别详细的部分是 `overlay.evidence` 数组: 对于每个叠加目标, 一个条件子模式 (`if/then`) 要求证据数组至少包含一个引用该目标的项目, 从而强制模型不能在不引用推断该目标所依据的证据源的情况下请求叠加。该模式还要求每个证据项携带一个限制在集合 `{"var", "gate", "rag", "delta", "visual"}` 中的 `type` 字段、非空的 `ref` 和 `quote`, 以及介于 0.0 和 1.0 之间的 `grounding_confidence`。计算出的模式基于其源文件的文件系统修改时间和大小进行缓存键控, 从而在长时间运行会话中避免模式重新生成。

### 5.2.6 数据契约

两个版本的数据契约共存。`core/types.py` 中的 `v1` 类型定义了整个运行时使用的四个核心数据类: `Observation` (带时间戳的仿真器状态, 包含可选程序提示和标签)、

`TutorRequest` (学习者发起的帮助意图, 包含观察引用和上下文字典)、`TutorResponse` (教学输出, 包含状态、消息、叠加操作和解释) 以及 `Event` (通用日志条目, 包含会话标识符、事件类型、带版本号的负载和可扩展元数据)。所有四个类都带有基于 UUID 的标识符、ISO-8601 挂钟时间戳和 `to_dict` 序列化方法。

`core/types_v2.py` 中的 `v2` 类型扩展了契约空间, 增加了仿真器特定结构: `DcsObservation` (原始 DCS-BIOS 帧, 包含序列号和座舱字典)、`TelemetryFrame` (增强状态, 包含规范化的 `vars`、BIOS 快照和座舱参数)、`VisionObservation` (截图元数据, 包含帧标识符、布局标识符、捕获时间戳和图像 URI)、`VisionFact` (单个视觉事实, 包含标识符、三值状态、源帧引用、TTL 和证据注释) 以及 `VisionFactObservation` (提取器返回的事实集合, 携带触发时间戳和帧标识符列表)。

### 5.2.7 其他核心模块

若干支撑性核心模块完善了领域层。`core/vars.py` 实现了 `VarResolver`——一个遥测变量解析器, 评估受限的 Python 表达式 (数值算术、布尔逻辑、比较和 `num()` 强制转换函数) 以将原始 BIOS 数据投影到规范化状态变量上, 同时跟踪 `vars_source_missing` 以实现键级可观测性。`core/knowledge.py` 提供了一个 `BM25Retriever` 类, 实现了具有 Okapi 风格 IDF 的标准 BM25 词项加权, 供本地知识适配器用于文档片段检索。`core/overlay.py` 定义了 `OverlayPlanner` 类, 使用程序包的 UI 映射将抽象目标名称 (如 `battery_switch`) 映射到 DCS 内部点代码, 并生成具有三种意图之一的 `OverlayIntent` 对象: `highlight`、`clear` 或 `pulse`。`core/step_signal_metadata.py` 提供可观测性状态规范化和 `compute_requires_visual_confirmation`, 该函数基于步骤的 `observability` 字段和 `evidence_requirements` 列表确定步骤是否需要视觉证据。`core/help_cycle_audit.py` 定义了规范集合的帮助循环审计字段 (`generation_mode`、`vision_used`、`frame_id`、`sync_delta_ms` 等) 以及一个被实时运行和回放路径一致使用的规范化函数。

## 5.3 遥测与 DCS 集成

遥测集成流水线分四个阶段运行, 每个阶段由一个专用适配器模块实现。

**原始 DCS-BIOS 摄入。** `DcsBiosRawReceiver` 类打开一个 UDP 套接字并监听 DCS-BIOS 二进制导出帧。原始帧被解码为 UTF-8 JSON 并直接写入 JSONL 文件而不做处理, 从而支持独立于实时运行时离线回放 BIOS 数据。配套的 `DcsBiosReceiver` 类提供更高层的接口, 解析 BIOS 负载, 强制单调序列号, 将全状态增量合并到累积状态字典中, 并生成供教学运行时消费的 `Observation` 对象。



**BIOS 到 UI 的映射。**BiosUiMapper 类从程序包加载 bios\_to\_ui.yaml, 将 DCS-BIOS 键名映射到抽象 UI 目标标识符。此映射使增量聚合流水线和确定性步骤推理模块能够将原始遥测变化转换为语义上有意义的 UI 引用。

**变量解析与增强。**adapters/telemetry\_pipeline.py 中的 enrich\_bios\_observation 将 VarResolver 应用于 TelemetryFrame, 在 vars 字典中生成规范化的键值对。解析器通过 telemetry\_map.yaml 中定义的表达式从四个引用根 (bios、lo、cockpit\_args、vars) 进行投影。源引用缺失或表达式求值为 None 的变量在 vars\_source\_missing 中被跟踪, 为下游组件提供键级可观测性。

**增量去噪与聚合。**adapters/delta\_sanitizer.py 中的 DeltaSanitizer 类应用从 delta\_policy.yaml 加载的可配置 DeltaPolicy 以抑制虚假状态变化。该策略指定了逐变量数值变化阈值、防抖动窗口和过滤规则。验证后的变化作为 SanitizedDelta 记录发出, 携带保留和丢弃的变化计数以及逐原因细分。adapters/delta\_aggregator.py 中的 DeltaAggregator 在可配置的时间窗口内累积去噪增量, 并将其压缩为包含最近 UI 目标 (通过 BiosUiMapper 映射)、top-*k* 键变化和丢弃变化统计的 DeltaSummary。这些摘要包含在帮助循环提示上下文和实时运行时使用的最近操作环形缓冲区中。

**遥测帧模式。**v2 遥测帧模式 (simtutor/schemas/v2/telemetry\_frame.json) 定义了增强遥测记录的规范结构, 包括挂钟时间戳、会话标识符、BIOS 快照、座舱参数、规范化变量和可选的底层输出。所有实时和回放路径在发射点根据此模式验证遥测帧。

整个遥测流水线作为连续后台线程在实时运行时中运行, 独立于任何特定的帮助循环。

## 5.4 结构化帮助生成

帮助生成子系统将教学请求及其组装的上下文转换为经过验证的、可执行的教学响应。它经过六个阶段进行处理。

### 5.4.1 提示构建

adapters/prompting.py 中的 build\_help\_prompt\_result 函数组装发送给语言模型的完整提示。它包括: 当前仿真器状态 (vars)、去噪后的最近增量、带可观测性状态和视觉确认要求的候选程序步骤、确定性步骤提示及其缺失条件列表、叠加目标允许列表、BM25 检索的知识片段 (最多五个, 每个截断为 220 字符), 以及当可用时的当前视觉事实摘要。提示受硬字符上限 (9000) 约束, 预估令牌限制为 2400。开关位置、旋钮旋转和按钮点击约定的交互策略规则以中文或英文包含。

### 5.4.2 模型适配器

模型适配器层通过统一接口支持三种后端。`OpenAICompatModel` (在 `adapters/openai_compat_model.py` 中) 将聊天完成请求发送到 OpenAI 兼容端点, 将 `/v1/chat/completions` 追加到配置的基础 URL。它要求 API 密钥, 支持可配置的超时和最大令牌限制, 并可切换到多模态模式。`OllamaModel` (在 `adapters/ollama_model.py` 中) 是用于本地 Ollama 服务器的零依赖适配器。`ModelStub` (在 `adapters/model_stub.py` 中) 为测试返回固定的确定性响应, 使得完整的帮助生成流水线无需外部模型服务即可运行。所有适配器通过统一的调用接口返回原始文本响应。

### 5.4.3 带最小修复的 JSON 提取

模型响应不保证仅包含有效的 JSON。`adapters/json_extract.py` 模块实现了一个 `parse_first_json` 函数, 具有刻意限制为四种转换的修复集: (1) 移除平衡的 Markdown 代码块 (三重反引号 JSON 块), (2) 移除导言 `<think>...</think>` 块, (3) 丢弃第一个 `{` 或 `[` 之前的非 JSON 前缀文本, (4) 丢弃闭合括号之后的后续文本。此集合之外的任何转换均被拒绝。提取使用基于栈的解析器, 跟踪字符串引号和转义序列以正确定位平衡的 JSON 分隔符。每次提取返回一个 `JsonExtractionResult`, 记录是否应用了修复以及具体的修复原因枚举。

### 5.4.4 模式验证

提取的 JSON 对象使用 `jsonschema` 库的 `Draft202012Validator` 根据运行时生成的 `HelpResponse` 模式 (第5.2节) 进行验证。验证错误以从验证器错误路径派生的 JSON Path 位置报告。该模式强制执行四类约束: (1) 必需的顶层键, (2) 步骤标识符和错误类别代码的枚举成员资格, (3) 叠加目标唯一性和允许列表成员资格, (4) 每个提及的叠加目标必须存在证据项。

### 5.4.5 响应映射与证据溯源

`adapters/response_mapping.py` 中的 `map_help_response_to_tutor_response` 函数将经过验证的 `HelpResponse` 转换为运行时 `TutorResponse`。它通过 `OverlayPlanner` (查询 `ui_map.yaml`) 将叠加目标解析为 DCS 内部元素标识符。映射函数还验证响应中引用的每个叠加目标至少有一个证据引用, 其前缀 (`VARS.`、`GATES.`、`VISION_FACTS.`、`RAG_SNIPPETS.` 或 `DELTA_KEYS.`) 与帮助循环上下文中实际存在的键匹配。没有溯源证据的目标被拒绝, 拒绝被记录在响应元数据中。解释和诊断字段原样传递。`TutorResponse` 状态在完全成功时设置为 `"ok"`, 在发生映射失败时设置为 `"partial"` 或 `"fallback"`。

### 5.4.6 确定性降级

当没有模型可用、模型输出未通过 JSON 提取或模式验证、或响应映射产生空或无效结果时,系统降级到确定性步骤推理。`adapters/step_inference.py` 中的 `StepInferenceResult` 类检查活跃步骤,评估未满足的门控规则,识别缺失条件,通过硬编码查找表将条件引用映射到可能的 UI 目标,并生成限制在当前活跃步骤的文本提示。默认情况下,确定性降级不触发叠加高亮,除非本地规则能够基于当前遥测状态证明一个唯一、有效的目标。降级结果连同降级原因记录在帮助循环审计元数据中。

### 5.4.7 操作执行安全

`adapters/action_executor.py` 中的 `OverlayActionExecutor` 在通过 UDP 向 DCS 分发操作之前对所有操作强制执行三项安全约束。第一,仅类型为 "overlay" 的操作可执行——无控件注入、无按键模拟、无点击模拟。第二,每个叠加目标均根据从程序包的 `ui_targets` 字段导出的 UI 目标允许列表进行检查;不在允许列表中的目标被拒绝并记录。第三,同一时间最多高亮一个目标 (`max_targets=1`)。当请求新的高亮时,先前的活跃高亮被自动清除以防止视觉混乱。`pulse` 意图在分发清除命令之前使用阻塞睡眠 (`ttd_s`),这会阻塞调用线程但保证脉冲的完整传递。可配置的确认接收器 (`DcsOverlayAckReceiver`) 可以通过监听来自 Lua 端叠加脚本的 UDP 确认消息来可选地验证传递。

## 5.5 VLM 视觉事实提取

VLM 视觉事实提取运行时被实现为核心的、可独立运行的子系统,通过结构化观察与教学运行时通信。

### 5.5.1 捕获触发与帧选择

当活跃步骤为视觉优先(S08、S15 或 S18)且帮助请求到达时,通过 `adapters/vision_capture_tr` 中的 `build_capture_request_payload` 向 DCS 发送 UDP 捕获请求。Lua 端 `SimTutor.lua` 脚本将三个主要座舱显示器(左 DDI、AMPCD、右 DDI)渲染为单个复合 PNG 图像。Python 端 `BufferedVisionSession` (在 `adapters/vision_sync.py` 中)维护最近视觉观察的滑动缓冲区并执行帧选择:默认情况下,它检索预触发帧(可配置同步窗口 250 ms 内紧接触发事件之前的最近帧)和触发帧本身。如果窗口内预触发帧不可用,会话降级为仅触发帧模式。帧过时和同步缺失原因记录在帧负载元数据中。

### 5.5.2 多模态负载构建

选定的候选帧由 `adapters/openai_compat_multimodal.py` 中的 `build_multimodal_image_con` 转换为多模态聊天完成负载。可配置根目录下的本地帧文件被读取并以 `data: URL` 形式进行 base64 编码, 并检测 MIME 类型。远程 URL 和内联数据 URL 被拒绝。可配置的最大文件大小防范意外的大图像。该函数生成一组 `image_url` 内容块, 每个块标记有帧的角色 ("`pre_trigger`" 或 "`trigger`"), 这些块与文本提示一起插入到 OpenAI 兼容请求的 `messages` 数组中。

### 5.5.3 13-Fact 提示

视觉事实提取的提示由 `adapters/vision_fact_prompting.py` 中的 `build_vision_fact_prompt` 构建。它枚举所有 13 个已配置的事实, 描述三区域复合面板布局 (上: 左 DDI; 中: AM-PCD; 下: 右 DDI), 并为每个事实提供详细的决策边界指令: 例如, `tac_page_visible` 要求实际的 TAC 页面内容, 而不仅仅是 TAC 菜单标签; `fcsmc_final_go_result_visible` 要求所有四个通道 (MC1、MC2、FCSA、FCSB) 的最终 GO 结果; `ins_ok_text_visible` 要求在 INS 校准块附近清晰可读的 OK 文本。提示通过 `lang` 参数以中文和英文两种语言可用。

### 5.5.4 模型响应清洗

原始模型输出由 `adapters/vision_fact_extractor.py` 中的 `_sanitize_model_response` 解析为 JSON 并进行清洗。清洗函数剥离未知的顶层键, 拒绝不是映射的事实数组条目, 拒绝缺失必需字段 (`fact_id`、`state`、`evidence_note`) 的条目, 并拒绝 `fact_id` 不属于配置中定义的有效事实 ID 集合的事实条目。仅接受三种事实状态: "`seen`"、"`not_seen`" 和 "`uncertain`"。使用 `_vision_fact_response_schema` 从允许的事实 ID 动态生成 JSON Schema, 清洗后的输出通过 `Draft202012Validator` 根据该模式进行验证。

### 5.5.5 事实合并与后端兼容性

清洗后的事实通过 `merge_vision_fact_observation` (第5.2节) 合并到运行时视觉事实快照中, 该函数在更新快照之前应用粘性保留和基于 TTL 的过期。`adapters/openai_compat_m` 中的 VLM 后端兼容性层处理特定于提供者的错误条件, 包括检测表明多模态或 JSON Schema 不支持后端的 400 响应, 以及区分真实错误与 DashScope 为多模态响应发送的 `null` 负载。当 VLM 不可用或多模态请求失败时, 帮助循环仅使用遥测和知识继续, 在视觉降级元数据中记录原因。

### 5.5.6 VR 兼容性

当前 VLM 运行时从复合面板布局(左 DDI、AMPCD、右 DDI)提取事实。复合面板捕获已在 VR 模式(Quest 3)下验证兼容性,使用 `VR_MIRROR` 和 `VR_allow_MFD_out_of_HMD` 配置。视觉端口抽象支持替代帧来源而无需更改提取或合并逻辑。

## 5.6 回放与日志基础设施

### 5.6.1 JSONL 事件存储

`core/event_store.py` 中的 `JsonlEventStore` 类是运行时事件的唯一持久化机制。它实现了一个仅追加写入器,并在每次写入后立即 `flush`,确保崩溃安全的日志记录。该存储支持上下文管理器用法 (`__enter__` / `__exit__`),并提供一个静态 `load` 方法,将整个 JSONL 文件读入内存作为字典列表。事件序列化接受 `Event` 数据类实例和普通字典,当提供前者时委托给 `Event.to_dict()`。

### 5.6.2 回放与验证

`simtutor/runner.py` 中的回放模块提供两个入口点。`run_simulation` 使用重放预录制观察序列的 `MockEnvAdapter` 驱动完整仿真,与 `ProcedureEngine` 实例协调,并将生成的事件日志写入带时间戳的 JSONL 文件。`replay_log` 通过根据程序包重放来验证现有事件日志:它重建步骤状态机,验证每个事件的步骤状态转换是否合法(例如,步骤不能在激活之前完成),并返回布尔成功标志和诊断消息。回放验证包括对遥测追踪中单调序列号和时间戳的检查。

`simtutor/replay_eval.py` 中的回放评估基础设施将回放扩展到支持套件驱动的评估:YAML 套件文件指定程序包路径、一组测试用例、模型配置和可选的视觉帧目录,从而在遥测层面和视觉副文件场景中实现系统性的回归回放。

### 5.6.3 交互度量

`core/interaction_metrics.py` 中的 `compute_interaction_metrics` 函数从事件日志中派生行为度量。它计算:每步骤停滞时间(总计和最大,从 `step_activated` 到 `step_completed` 间隔派生)、帮助请求计数、LLM 触发计数(带模型元数据的教学响应)、UI 点击计数和失败计数,以及高亮/清除请求和确认计数。输出是一个带有 `to_dict` 序列化方法的 `InteractionMetrics` 数据类。

### 5.6.4 当前局限

日志和回放基础设施已通过合成回归场景（模拟环境、预录制观察序列和离线 BIOS 捕获）进行了演练。来自真人的人在环运行的带同步视觉帧的完整多模态会话的端到端回放尚未验证。

## 5.7 CLI 与运行时入口点

### 5.7.1 CLI 命令

`simtutor` 包通过 `simtutor/__main__.py` 提供命令行界面。实现了以下命令：

**run.** 使用带有预录制场景文件的 `MockEnvAdapter` 执行仿真，并将事件日志写入带时间戳的 JSONL 文件。

**replay.** 根据程序包验证现有事件日志，检查步骤排序和状态机一致性。

**score.** 使用评分引擎对事件日志进行评分，生成遗漏计数、状态违反计数和总错误分数。

**record-vlm.** 在一组视觉观察上运行 VLM 事实提取并记录预测以进行基准测试。

**replay-bios.** 通过遥测流水线重放原始 DCS-BIOS 捕获 (`dcs_bios_raw.jsonl`)，并可选择调用帮助生成循环，生成新的带时间戳事件日志。

**validate.** 根据模式注册表中的命名模式（如 `dcs_bios_frame`、`telemetry_frame`、`vision_fact_observation`）验证 JSONL 文件。

所有命令接受 `-model-provider`、`-model-name`、`-model-base-url` 和 `-model-timeout-s` 参数，允许在命令行覆盖模型配置。`-lang` 标志在中文 (zh) 和英文 (en) 提示与输出语言之间切换。

### 5.7.2 实时运行时编排

`live_dcs.py` 模块是主要的实时运行时入口点。它编排以下连续循环：

1. `DcsBiosRawReceiver` 或 `DcsBiosReceiver` 从 DCS 摄入 UDP 帧。
2. 每个原始帧通过 `enrich_bios_observation` 进行增强以生成规范化的状态变量。

3. 当接收到帮助触发器时(通过 `WindowsGlobalHelpTrigger` 的热键或 UDP 消息), 帮助循环开始:

- 通过 `infer_step_id` 计算确定性步骤提示, 根据当前遥测评估程序包门控。
- 如果活跃步骤需要视觉确认, 发送视觉捕获触发器并调用 VLM 事实提取器。
- 构建 BM25 溯源查询并检索知识片段。
- 组装完整提示并发送给模型适配器。
- 模型响应被解析、验证并映射为 `TutorResponse`。
- 叠加操作通过 `OverlayActionExecutor` 执行, 并进行允许列表和基数强制。
- 完整帮助循环(请求、响应、操作、视觉事实、降级原因(如有))被记录为 `Event` 记录。

4. 循环持续直至终止。

实时运行时通过共享代码路径同时支持实时 DCS 操作和预录制 BIOS 捕获的回放, 由 `-replay-bios` 标志控制。所有线程(BIOS 接收器、叠加确认接收器、帮助循环处理)均通过 Python 标准库线程原语进行管理, 线程间通信基于队列。

### 5.7.3 DCS Lua 脚本

三类 Lua 脚本在 DCS 进程内执行:

**状态导出。** `Export.lua` 加载 DCS-BIOS 和 SimTutor 集成模块, 建立状态导出链。

**叠加渲染。** `VRHilite.lua` 在端口 7778 上绑定 UDP 套接字并监听纯文本叠加命令 (`HIGHLIGHT <pnt>`、`CLEAR`、`PULSE <pnt> <t1_s>`)。高亮通过 DCS 的 `a_cockpit_highlight` / `a_cockpit_remove_highlight` API 渲染, 该 API 通过 `net.dostring_in` 访问。`SimTutorHighlight.lua` 为 SimTutor 特定的高亮上下文提供替代渲染路径。

**SimTutor 集成。** `SimTutor.lua` 加载包含捕获和导出逻辑的 `SimTutor Function.lua`, 并安装导出链。`SimTutorDcsBiosHub.lua` 将 SimTutor 特定的状态查询桥接到 DCS-BIOS 数据模型。

### 5.7.4 模型提供者配置

模型访问通过具有统一命名约定的环境变量进行配置 (第3.2节)。实时运行时在启动时验证所有必需的配置, 发出非敏感的摘要 (提供者、模型名称、超时、语言、基础 URL), 并在任何必需变量缺失时以明确的错误消息拒绝会话。API 密钥从不包含在日志输出或异常消息中, 由 `core/security.py` 中的 `redact_sensitive_text` 函数强制执行。



## 第六章 评估

本章围绕第一章定义的三个研究问题组织实证证据。第6.1节 (RQ2) 报告了在三个骨干模型上 13 事实本体的 VLM 技术基准测试结果。第6.2节 (RQ1) 通过回放评估和 harness 回归测试评估系统级技术就绪性。第6.3节 (RQ3) 报告了包含九名参与者的形成性 VR 试点研究。

### 6.1 RQ2: VLM 技术评估

技术评估关注的是，经过 LoRA 微调的 VLM 能否在模型从未见过的保留数据上可靠地从 F/A-18C 座舱截图中提取结构化视觉事实。所有指标均由第4.6节描述的自动化基准测试 harness 计算得出。

#### 6.1.1 数据集与训练概览

视觉事实提取任务经历了两个代际的事实本体演进。第一代 (v1) 定义了 8 个视觉事实并建立了初始训练流水线。第二代 (v2) 将本体扩展为 13 个事实，与运行时契约对齐。表 6.1 总结了六个标注数据集。

Table 6.1: 标注视觉事实数据集概览。

| Dataset                                 | Run     | Facts | Tasks | Bilingual | Role        |
|-----------------------------------------|---------|-------|-------|-----------|-------------|
| vision_sft                              | Run-001 | 8     | 180   | yes       | v1 train    |
| vision_sft_holdout_run002               | Run-002 | 8     | 50    | no        | v1 hold     |
| vision_sft_holdout_run002_newfacts      | Run-002 | 13    | 50    | no        | v2 hold     |
| vision_sft_run003                       | Run-003 | 13    | 220   | yes       | v2 training |
| vision_sft_run005_composition_rebalance | Run-005 | 13    | 122   | yes       | v2 rebal    |
| vision_sft_holdout_run004_random        | Run-004 | 13    | 100   | no        | v2 hold     |

v2 训练配方将 Run-003 (220 个人工审查任务) 与 Run-005 (122 个人工审查任务，专门采集用于再平衡代表性不足的事实状态) 结合，其中 Run-005 应用两次 (Run-005×2)。双语导出 (EN + ZH) 产生总计 **928 行** 训练数据。保留集——Run-002 newfacts

(50 样本) 和 Run-004 random (100 样本) ——均为仅英文，并经验证与训练数据零精确重叠。

### 6.1.2 Qwen3.5 13 事实 V2 结果

主要技术结果是基于 Run-003 + Run-005 $\times$ 2 训练的 Qwen3.5-9B LoRA 适配器的性能 (928 行, 4 轮, 学习率  $2\times 10^{-4}$ , LoRA  $r = 16$ ,  $\alpha = 16$ )。表 6.2 报告了两个独立保留集上的结果。

**Table 6.2:** 13 事实 v2 基准测试: Qwen3.5-9B Base vs. LoRA 在两个保留集上。

| Metric        | Run-002 newfacts (50) |               |          | Run-004 random (100) |               |          |
|---------------|-----------------------|---------------|----------|----------------------|---------------|----------|
|               | Base                  | LoRA          | $\Delta$ | Base                 | LoRA          | $\Delta$ |
| JSON valid    | 1.0                   | 1.0           | —        | 0.96                 | 1.0           | +0.04    |
| Schema valid  | 1.0                   | 1.0           | —        | 0.96                 | 1.0           | +0.04    |
| Fact accuracy | 0.8677                | <b>0.9908</b> | +0.1231  | 0.8038               | <b>0.9931</b> | +0.1892  |
| Macro $F_1$   | 0.4513                | <b>0.6515</b> | +0.2002  | 0.4393               | <b>0.6100</b> | +0.1707  |
| Seen $F_1$    | 0.5022                | <b>0.9648</b> | +0.4626  | 0.5659               | <b>0.9159</b> | +0.3500  |
| Exact match   | 0.10                  | <b>0.88</b>   | +0.78    | 0.03                 | <b>0.92</b>   | +0.89    |
| Critical FP   | 11                    | <b>4</b>      | -7       | 70                   | <b>8</b>      | -62      |

LoRA 适配器在 Run-002 上达到 0.9908 的事实准确率, Run-004 上达到 0.9931, 样本完全匹配率分别为 0.88 和 0.92。关键误报在 Run-002 上降低了 64% (11 $\rightarrow$ 4), 在 Run-004 上降低了 89% (70 $\rightarrow$ 8)。基础模型在更大的 Run-004 保留集上显著退化 (4 个模式无效响应, 70 个关键误报集中在 `fcsmc_intermediate_result_visible`), 而 LoRA 适配器恢复了格式可靠性并抑制了无差别幻觉。

LoRA 适配器的残余关键误报集中在完成类事实上: `fcsmc_final_go_result_visible` (Run-004 上 8 个, Run-002 上 1 个) 和 `ins_ok_text_visible` (Run-002 上 2 个)。

### 6.1.3 Gemma-4 与 Qwen3.6 骨干对比

为评估训练配方的泛化性, 相同的数据配方 (Run-003 + Run-005 $\times$ 2, 928 行, 13 事实本体) 被应用于两个额外的骨干。表 6.3 总结了对比结果。

Qwen3.6-27B 的基础模型起步明显强于 Qwen3.5-9B (Run-002 上事实准确率 0.91 vs. 0.87), 但 LoRA 增益更窄 ( $\Delta = +0.077$  vs.  $+0.123$ ), 这与较大模型在小数据微调下适配空间较小的预期一致。Qwen3.6 LoRA 适配器在大多数指标上达到与 Qwen3.5 可比的性能, 但未超越 9B 线。

**Table 6.3:** 三种骨干上的 13 事实 v2 结果 (仅 LoRA 模型)。

| Metric        | Run-002 newfacts (50) |          |          | Run-004 random (100) |          |         |
|---------------|-----------------------|----------|----------|----------------------|----------|---------|
|               | Q3.5-9B               | Q3.6-27B | G-4-31B  | Q3.5-9B              | Q3.6-27B | G-4-31B |
| Fact accuracy | <b>0.9908</b>         | 0.9877   | 0.9492   | <b>0.9931</b>        | 0.9892   | 0.9715  |
| Seen $F_1$    | <b>0.9648</b>         | 0.9479   | 0.8123   | <b>0.9159</b>        | 0.9147   | 0.7959  |
| Exact match   | <b>0.88</b>           | 0.86     | 0.44     | <b>0.92</b>          | 0.86     | 0.74    |
| Critical FP   | 4                     | 3        | <b>0</b> | <b>8</b>             | 8        | 13      |

Gemma-4-31B 在 Run-002 上实现了零关键误报，反映了更保守的错误风格，但代价是较低的召回率 (Run-002 上 seen  $F_1$  0.81 vs. Qwen3.5 的 0.96) 和较低的样本完全匹配率 (0.44 vs. 0.88)。这种骨干层面的错误风格差异——保守型 (Gemma) vs. 自信型 (Qwen) ——对安全关键型部署决策具有参考价值。

总体而言，Qwen3.5-9B 在两个保留集上的事实准确率、seen  $F_1$  和样本完全匹配率方面仍然是最佳配置。数据配方在所有三个骨干上均产生了相对于各自基础模型的持续改进。

#### 6.1.4 错误分析

基于 Qwen LoRA 适配器的性能，13 个事实可分为三个难度类别。**粗粒度面板存在** (6 个事实): 近乎完美分类，仅 Run-002 上 `tac_page_visible` 有两次假阴性例外。**细粒度状态指示器** (5 个事实): 四个事实上完美; `fcsmc_final_go_result_visible` 上有残余误报 (Run-004 上 8 个)。**小文本识别** (2 个事实): 对齐文本表现强劲 (Run-002 上 1 个误报); Run-002 上 `ins_ok_text_visible` 有 2 个误报。

基础模型的主要失败模式是对稀有状态的单向幻觉:`fcsmc_intermediate_result_visible` 仅出现在 100 个 Run-004 样本中的 7 个中，但基础模型在额外 60 个样本中断言其为 `seen`。LoRA 适配器几乎完全消除了这类错误，将错误画像从弥漫性幻觉转变为聚焦的、可解释的完成类事实残余错误。

## 6.2 RQ1: 系统级技术就绪性

除了组件级 VLM 基准测试之外，代码仓库中还包含系统层面的系统性验证证据。

### 6.2.1 回放评估

`replay_eval/fa18c_startup_v04/` 中的回放评估套件定义了五个测试用例，涵盖不同的场景类型：无操作、电池开启、电池与发电机关闭、FCS 复位与 BIT，以及 INS

校准（见附录九，表 9.4）。每个用例包含 DCS-BIOS 原始捕获，并在适用时包含视觉依赖步骤的逐帧 sidecar 文件。所有五个用例均产生了预期的步骤推理和叠加目标，确认遥测流水线、程序引擎和视觉路径在由录制数据驱动时端到端功能正常。

### 6.2.2 Harness 夹具回归

步骤 harness（第??节）通过覆盖矩阵中的 20 个 live-fixture 回归条目进行了验证，每个条目重放一个特定的遥测快照通过完整帮助循环，并断言特定的预期结果。这些夹具涵盖：已完成条件的正确推进、对错误目标提议的安全拒绝（例如将 BIT root 子状态的 PB18 修复为 PB5、S10 左发动机指导使用左键单击而非右键单击语义）、防止 VLM 证据泄漏到非视觉步骤、正确处理移动/稳定控件（加油探头、拦阻钩）、一致的交互语义（旋转控件的鼠标滚轮），以及对部分完成步骤的正确修复。

### 6.2.3 实验导出基础设施

实验导出流水线（第??节）已在九次实时 VR 试验中得到运用，为每次试验生成了完整的工件集（trial\_summary、step\_coding、help\_cycles、action\_timeline、quality\_gate）。所有九次试验的质量门控均通过，配置哈希在整个研究中验证一致。这表明工具流水线可用于人因数据采集，尽管参与者/会话元数据模式仍不完整（P04 的质量门控警告中指出了缺失的问卷关联字段）。

## 6.3 RQ3：形成性 VR 试点研究

一项小型形成性试点研究以九名参与者开展，收集关于教学系统在 F/A-18C 冷启动程序中如何支持学习者（与无辅助练习相比）的描述性证据。该研究应被理解为初步实地试验，而非有统计效力的受控实验。方法论细节见第??节。

### 6.3.1 参与者与试验概览

表 6.4 总结了每位参与者的条件、完成状态、步骤完成情况、观察时长和关键交互计数。所有数据来自人工步骤编码(step\_coding.csv)和试验摘要(trial\_summary.csv)。

**完成情况。**所有四名教学辅助条件下的参与者完成了完整的 33 步程序。五名无教学辅助的参与者无一完成完整程序；他们在完成 19-29 步后停止。无教学辅助条件下最常见的遗漏步骤是 S18（FCS-MC BIT 页面，5/5 参与者遗漏）、S19（FCS BIT 最终 GO，5/5 遗漏）和 S27（襟翼开关至 AUTO，5/5 遗漏）。

**Table 6.4:** 参与者与试验概览。观察时长为从第一次遥测事件到最后一轮的挂钟间隔；对未完成试验而言，它不是完成时间的度量。

| P   | 条件            | 完成   | 步骤    | 时长 (s) | 帮助 | VLM | 叠加 | 降级 |
|-----|---------------|------|-------|--------|----|-----|----|----|
| P01 | without_tutor | no   | 23/33 | 2015   | 0  | 0   | 0  | 0  |
| P02 | without_tutor | no   | 27/33 | 739    | 0  | 0   | 0  | 0  |
| P03 | without_tutor | no   | 24/33 | 243    | 0  | 0   | 0  | 0  |
| P06 | without_tutor | no   | 29/33 | 269    | 0  | 0   | 0  | 0  |
| P07 | without_tutor | no   | 19/33 | 218    | 0  | 0   | 0  | 0  |
| P04 | with_tutor    | yes  | 33/33 | 442    | 19 | 6   | 22 | 6  |
| P05 | with_tutor    | yes  | 33/33 | 317    | 7  | 2   | 6  | 2  |
| P08 | with_tutor    | yes* | 33/33 | 332    | 7  | 5   | 10 | 4  |
| P09 | with_tutor    | yes  | 33/33 | 1033   | 44 | 10  | 44 | 9  |

\*P08: 自动摘要报告未完成；人工编码确认 33/33 完成（见下方数据质量注记）。

**观察时长。**有教学辅助试验的范围是 317s 至 1033s（中位数 387s）。无教学辅助试验的范围是 218s 至 2015s。由于无教学辅助试验在参与者无法继续推进的不同程序节点结束，这些时长不能作为完成时间进行比较。

### 6.3.2 程序性错误

表 6.5 报告了每参与者的人工错误计数。

**Table 6.5:** 每参与者人工程序性错误计数（来自人工步骤编码）。OM = 遗漏，CO = 执行错误，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违反。

| P   | 条件            | OM | CO | OR | PA | SV |
|-----|---------------|----|----|----|----|----|
| P01 | without_tutor | 8  | 0  | 1  | 0  | 1  |
| P02 | without_tutor | 0  | 0  | 0  | 1  | 0  |
| P03 | without_tutor | 7  | 0  | 2  | 0  | 2  |
| P06 | without_tutor | 2  | 0  | 0  | 2  | 0  |
| P07 | without_tutor | 11 | 0  | 0  | 0  | 0  |
| P04 | with_tutor    | 0  | 3  | 0  | 3  | 1  |
| P05 | with_tutor    | 0  | 3  | 0  | 3  | 0  |
| P08 | with_tutor    | 0  | 0  | 0  | 0  | 0  |
| P09 | with_tutor    | 0  | 3  | 0  | 2  | 0  |

**遗漏错误。**无教学辅助条件显示出明显的遗漏模式：五分之四的参与者记录了 7–11 个 OM 错误（遗漏步骤）。相比之下，有教学辅助条件记录了零 OM 错误——所有四名参与者均完成了全部 33 步。

**执行与辅助错误。**有教学辅助条件显示出不同的错误画像：CO 错误（P04、P05、

P09 每名参与者 3 个) 和 PA 错误 (每参与者 2–3 个) 取代了无教学辅助条件中观察到的遗漏错误。这些主要是辅助耦合型错误——教学提供了指导并被遵循, 但未完全符合程序规范, 或者参与者实质正确但以轻微偏离规定顺序的方式执行了步骤。

**错误总计。**无教学辅助参与者平均 7.4 个人工错误; 有教学辅助参与者平均 4.5 个。然而, 错误类别在性质上有所不同: 无教学辅助错误以遗漏为主 (平均 OM = 5.6), 而有教学辅助错误仅为 CO 和 PA (平均 CO = 2.3, 平均 PA = 2.0)。

6.3.3 教学交互

表 6.6 总结了四次有教学辅助试验的教学交互指标。

Table 6.6: 教学交互摘要 (仅教学辅助条件)。

| P   | 帮助循环 | VLM 调用 | 叠加执行 | 叠加拒绝 | 降级 |
|-----|------|--------|------|------|----|
| P04 | 19   | 6      | 22   | 0    | 6  |
| P05 | 7    | 2      | 6    | 0    | 2  |
| P08 | 7    | 5      | 10   | 0    | 4  |
| P09 | 44   | 10     | 44   | 0    | 9  |
| 合计  | 77   | 23     | 82   | 0    | 21 |

所有帮助循环使用模型生成路径 (`generation_mode = model`); 无循环降级到仅确定性模式。VLM 调用针对视觉优先步骤 (S08、S15、S18) 发出, 四次试验合计 23 次。**叠加拒绝率为零:** 教学系统提出的全部 82 个叠加操作均通过了证据溯源、允许列表和模式验证。21 个降级事件 ( $21/77 =$  帮助循环的 27%) 发生在模型提出的叠加目标被 harness 修复时——例如模型提出一个目标, harness 将其重映射到更具体的子状态目标 (如将 BIT root 的 PB18 修复为 PB5)。

6.3.4 数据质量注记

- P08 自动摘要校正。**自动化流水线将 P08 报告为未完成 (5/33 步)。人工遥测审查确认所有 33 步均达到所需状态。自动流水线未能从被动遥测中为视觉优先步骤重建完成证据。按编码策略, 人工编码覆盖自动摘要; P08 报告为已完成, 0 个人工错误。
- P02 问卷排除。**P02 的问卷 JSON 文件包含内部 `participant_id = P01`, 表明标注错误。P02 被排除在任何工作负荷、TLX 或信心摘要之外。来自 `trial_summary.csv` 和 `step_coding.csv` 的任务指标 (步骤、错误) 可用。

3. **时长解释。**无教学辅助试验在参与者无法继续推进的不同程序节点结束。观察时长仅为完整性报告，不支持条件间的完成时间比较。
4. **非随机分配。**参与者基于排期可用性被分配到条件，非随机化。先前的 DCS 和 VR 经验在参与者之间有所不同（见附录九，表 9.5）。

### 6.3.5 试点发现总结

本试点提供了三项形成性证据。第一，所有四名教学辅助条件下的参与者完成了完整的 33 步程序，而五名无教学辅助的参与者无一完成。第二，教学辅助条件在编码数据中消除了遗漏错误，但未消除所有错误：辅助耦合型 CO 和 PA 错误出现在四分之三的有教学辅助试验中。第三，教学基础设施——遥测锚定、叠加分发、证据验证——在 77 个帮助循环中无叠加拒绝地运行。

这些发现是描述性和形成性的。它们并未确立该教学系统相对于其他方法改善学习、降低工作负荷或加速技能获取。试点的小样本（ $n = 9$ ）、非随机分配和参与者经验差异排除了推断性结论。针对这些局限性的大规模受控评估是必需的。



## 第七章 讨论

本章解释第**六**章中呈现的结果，并将其置于论文的更大轨迹之中。第**7.1**节解释项目为何从原 VR 优先提案演变为本文报告的遥测和 VLM 为主的实现，以及形成性试点研究如何契合这一轨迹。第**7.2**节解释基准测试结果证明了什么以及未证明什么。第**7.3**节解释形成性 VR 试点发现。第**7.4**节从两代视觉事实本体演进中提炼设计经验。第**7.5**节列举当前系统和实验证据的已知局限性。第**7.6**节概述由这些局限性引出的未来工作方向。

### 7.1 从提案到实现系统的演变

原始论文提案 [7] 指定了一个 VR 优先的有依据教学系统，在 Meta Quest 3 上通过眼动追踪、手部追踪和语音输入运行，由轻量级 RAG+LLM 后端支撑，并通过一项三条件人因研究进行评估。本文报告的工作在两个实质性方面与这一愿景有所不同。

第一，实现工作从 VR 原生交互转向了在桌面 DCS 上的遥测驱动教学，因为核心技术挑战——可靠的遥测处理、证据溯源、基于 VLM 的视觉事实提取以及 harness 级输出验证——需要一个桌面 DCS 提供的稳定开发和调试环境。这一转变产生了端口-适配器架构、程序包和门控引擎、确定性降级路径、JSONL 日志和回放基础设施，以及 VLM 适配流水线——所有这些在原始提案中均未预见。

第二，VLM 适配工作从一个未计划的组件成长为论文的主要贡献之一。原始提案假设只读仿真器状态标志足以进行程序状态追踪；在实践中，若干关键程序步骤需要视觉确认 DCS-BIOS 未导出的显示页面内容。填补这一空白导致了视觉事实本体、七阶段数据流水线、LoRA 微调实验以及三骨干基准测试对比——构成了一个具有经验证保留证据的自包含贡献。

形成性 VR 试点研究 (RQ3) 代表了向原始提案人因评估目标的局部回归。该试点在 Quest 3 上使用完整的教学运行时，产生了真实的参与者数据，并证明了基于证据的基础设施在实时 VR 环境中正确运行。然而，试点规模较小 ( $n = 9$ )，非随机化，且为描述性而非推断性。它并未实现提案的三条件受控评估目标。形成性试点与完全有统计效力的受控研究之间的差距，仍是论文未完成的中心线索。



## 7.2 技术结果解读

第6.1节报告的基准测试结果提供了关于 VLM 视觉事实提取流水线性能的证据。本节从这些结果中得出解释性结论，仔细区分基准测试证明了什么以及未证明什么。

### 7.2.1 基准测试结果证明了什么

**小数据 LoRA 适配极大改善了领域特定的 VLM 提取。**在 13 事实 v2 本体下，基于 928 行 (Run-003 + Run-005 $\times$ 2) 训练的 Qwen3.5-9B LoRA 适配器，在 Run-002 newfacts 保留集上达到 0.9908 的事实准确率，在 Run-004 random 保留集上达到 0.9931，而基础模型分别为 0.8677 和 0.8038。seen  $F_1$  从 0.50–0.57（基础模型）提升至 0.92–0.96（LoRA）。这些都是以任何标准衡量都很大的效应量，且在经验证零训练重叠的保留集上观察到，排除了记忆化作为解释。

**数据配方可在模型骨干之间迁移。**相同的训练配方应用于 Gemma-4-31B 骨干产生了一致的改进模式，证实改进是由数据和本体设计驱动的，而非单一模型架构的特异属性。

**JSON 和模式有效性在训练后接近完美。**在 Run-004 random 保留集上，基础模型产出 4 个模式无效或 JSON 无效的响应（共 100 个）；LoRA 适配器为零。在必须解析模型输出以提取叠加目标和步骤推荐的运行时系统中，格式可靠性是硬性要求。

**错误画像从无差别幻觉转变为针对完成类事实的定向误报。**基础模型的主要失败模式是单向幻觉，LoRA 适配器几乎完全消除了这类错误，将残余错误集中在完成类事实上。

**基准测试协议本身构成了一项贡献。**具有经验证零重叠的保留集、逐事实混淆分析、关键误报追踪和自动化图表生成，提供了一个可复现的评估框架。

### 7.2.2 基准测试结果未证明什么

**它们未证明教学系统改善了学习。**基准测试测量的是从座舱截图中提取视觉事实的准确率。准确的视觉事实提取是有依据教学系统正确运行的必要条件，但不是改善人类学习效果的充分条件。

**它们未证明视觉事实提取能带来更好的教学。**基准测试孤立评估 VLM 组件，而非端到端教学系统。

**它们测量的是感知子任务，而非教学有效性。**报告的指标是感知指标，回答的是 "VLM 是否正确看到了座舱？" 而非 "教学系统是否帮助了学习者？"。

### 7.2.3 ins\_go 到 ins\_ok\_text 的分解作为设计经验

8 事实 v1 本体包含单一事实 ins\_go，要求 VLM 识别 INS 校准是否已达到可见的 GO 状态。该事实成为 v1 适配器误报的主要来源。问题不在于 VLM 未能从训练数据中学习，而在于目标本身定义不佳——它不是一个视觉事实，而是一个需要整合多种信息源的程序完成判断。13 事实 v2 本体将这一复合目标分解为更低层次、视觉可观察的事实。这种分解不是表面性更改，而是本体演进中最重要的设计决策。

## 7.3 试点发现解读

形成性 VR 试点研究（第6.3节）提供了必须在其适当范围内解读的描述性证据。

**完成与遗漏错误。**最清晰的信号是完成差距：4/4 有教学辅助参与者完成了全部 33 步，而 0/5 无教学辅助参与者完成。这与教学系统的设计一致：帮助系统主动识别下一个所需步骤并高亮相关座舱控件，使参与者难以无意跳过步骤。

**辅助耦合型错误。**教学辅助条件并未消除错误，而是改变了错误的组成。CO 和 PA 错误出现在四分之三的有教学辅助试验中。这些主要是辅助耦合型错误：教学提供了被遵循的指导，但结果动作未完全符合程序规范。这些错误凸显了灵活的 LLM 生成指导与固定程序规范之间的固有权衡。

**基础设施可靠性。**零叠加拒绝率（0/82）在 77 个帮助循环中提供了证据，表明证据溯源、允许列表和模式验证流水线在实时 VR 操作中功能正确。所有 21 个降级事件均为 harness 修复（目标重映射）而非拒绝。

**试点未表明什么。**试点未提供关于学习（无前/后知识测量）、保持（无后续测试）、工作负荷（P02 问卷数据未解决）或迁移的证据。小样本、非随机分配和参与者经验差异意味着条件间观察到的差异不能单独归因于教学系统。

## 7.4 本体设计经验

从 8 事实 v1 到 13 事实 v2 的两代演进提供了具体的设计经验。核心经验是，基于 VLM 的视觉事实提取器应被要求报告可观察的视觉证据，而非程序性结论。v2 本体强制执行的设计纪律是：每个事实都是一条局部可验证的视觉证据。这一经验产生了一个可迁移的设计原则：**VLM 事实目标应是低层次的、局部可验证的视觉命题；高层次的程序状态判断应由下游推理结合时序和遥测上下文从多个视觉事实综合得出。**

分解的有效性是可度量的。在 Run-002 保留集上，8 事实 v1 的关键误报从 15 降至 4。一般设计原则可表述为：如果人工标注者在不了解程序步骤的情况下仅通过查看单张图像无法确定事实标签，则该事实可能过于高层次，应当被分解。

## 7.5 局限性

以下局限性界定了可从本工作中得出的结论范围。

### 7.5.1 实验设置的局限性

**单一程序。**所有实验、基准测试和数据集构建工作聚焦于 F/A-18C 冷启动这单一程序。

**单一复合面板布局。**视觉事实提取器在固定的三显示器复合面板上训练和评估。

**小数据集规模。**最大训练配置使用 928 行，与典型的 VLM 微调数据集相比较小。

**保留集来自同一飞机和座舱世代。**基准测试测量的是域内泛化，而非跨域泛化。

### 7.5.2 系统局限性

**VR 运行时已运行；试点已完成但受控研究尚未进行。**VR 运行时已在包含九名参与者的形成性试点研究中得到运用，证实教学系统在实时 VR 操作中端到端功能正常。但试点规模较小 ( $n = 9$ )，非随机化，且为描述性。

**无受控人因评估。**形成性试点提供了关于可行性的描述性证据，但不构成受控评估。需要更大规模的受控研究。

**基准测试测量的是事实提取，而非教学质量。**VLM 基准测试是感知指标，未测量教学响应的质量、有用性或及时性。

### 7.5.3 试点研究的局限性

**小样本与非随机分配。**九名参与者基于排期可用性被分配到条件，非随机化。条件规模小而失衡。

**参与者经验差异。**参与者从初学者到频繁 DCS 用户不等。先前经验未在条件间平衡。

**不完整的工作负荷和问卷数据。**P02 的问卷文件标注错误。NASA-TLX 集成在这些试验的导出流水线中尚未实现。

**无教学辅助时长不可比。**无教学辅助试验在不同程序节点结束，因此观察时长不能与有教学辅助时长比较。

**被动视觉验证局限。**对于无教学辅助试验，步骤完成从被动遥测门控推断，缺乏活跃 VLM 视觉确认。

### 7.5.4 VLM 适配结果的局限性

**完成类事实上的残余关键误报。**Qwen LoRA 适配器在 `fcsmc_final_go_result_visible` 上保留了关键误报。

**有限的模型多样性。**评估了三种骨干，结果不能推广到其他模型架构或微调方法。

**未对训练组件进行消融。**训练配方结合了多项设计选择而未隔离每个选择的贡献。

### 7.5.5 范围总结

这些局限性界定了本论文的主张。在此边界内，论文证明了：(1) 一个可运行的双平台教学运行时，具有自动化测试和 harness 级证据验证；(2) 一条可复现的 VLM 适配流水线，在保留数据上达到 0.99 事实准确率，附跨骨干证据；(3) 一个支持扩展到新程序和仿真器的程序包驱动架构；(4) 形成性 VR 试点证据 ( $n = 9$ )，表明教学辅助与完整程序完成和较少编码遗漏错误相关联，而辅助耦合型错误持续存在。这些贡献不依赖于超出所述边界的主张。

## 7.6 未来工作

以上列举的局限性定义了一个具体的研究议程。

### 7.6.1 受控人因评估

形成性试点研究证明了可行性和工具就绪性。下一阶段是一项更大规模的受控受试者间评估。鉴于试点观察到的完成率模式，一个双条件设计（有教学辅助 vs. 无教学辅助），每组  $n \geq 15$ ，提供了一个比原三条件提案设计更可行的起点。

### 7.6.2 将视觉事实本体扩展到其他程序

当前的 13 事实本体特定于 F/A-18C 冷启动。将方法扩展到其他程序将检验本体设计原则的通用性。

### 7.6.3 多帧时序推理

当前的视觉事实提取在单帧对上操作。融入跨多帧的时序上下文可提高涉及瞬态或状态转换的事实准确率。

7.6.4 基于原位校正的在线适配

当前的 VLM 适配流水线是一个离线过程。在线适配循环可使系统逐步提高边缘情况的准确率。

7.6.5 系统级端到端评估

除组件级 VLM 基准测试外，还需要对完整帮助循环进行系统级评估。

7.6.6 未来方向总结

表 7.1 总结了主要未来方向及其当前状态。

Table 7.1: 未来工作方向总结。

| 方向        | 当前状态                          | 关键挑战                |
|-----------|-------------------------------|---------------------|
| 受控人因评估    | 形成性试点已完成 ( $n = 9$ ); 受控研究待进行 | 招募、随机化、统计效力         |
| 本体扩展到其他程序 | 13 事实 v2 仅在冷启动上验证             | 任务分析、标注工作、领域通用性     |
| 多帧时序推理    | 单帧流水线已运行                      | VLM 容量、训练数据量、基准测试设计 |
| 基于校正的在线适配 | 尚未实现                          | 标签可靠性、灾难性遗忘、评估      |
| 系统级端到端评估  | 尚未开展                          | 定义有意义的系统级指标         |

本论文呈现的工作为上述每个方向提供了技术基础。架构、数据流水线、训练基础设施和基准测试协议被设计为可扩展的，从两代本体演进和跨骨干对比中获得的经验为项目的下一阶段提供了基于证据的指导。

## 第八章 结论

本论文旨在设计、实现并从技术上验证一个基于遥测数据基础的教学运行时系统，用于高保真飞行仿真器中的程序性学习，并收集其在沉浸式 VR 训练中使用的形成性证据。所交付的三项贡献为：一个基于证据的教学架构，一个视觉事实本体与小数据 VLM 适配流水线（附跨骨干基准测试证据），以及一个在形成性试点研究（ $n = 9$ ）中经过了实际运用的 VR 评估框架。本章对照三项研究问题总结已完成工作，重申贡献，并概述未来工作方向。

### 8.1 已完成工作总结

本论文产生了三项贡献，分别对应第一章中定义的两项研究问题。

**C1 ——一个基于证据的程序性教学架构。**教学运行时强制要求每个叠加目标和步骤推荐都携带可追溯的证据引用（遥测变量、门控规则、RAG 片段或视觉事实），通过运行时生成的 JSON Schema 及 if/then 规则在模式层面执行——而不仅仅是事后审计的日志记录。该架构遵循端口-适配器模式，具有确定性降级路径、在模型输出到达仿真器之前验证和修复它们的步骤 harness，以及将所有程序逻辑表达为声明式 YAML 配置的程序包格式。该架构通过自动化测试、一个回放评估套件（5 个用例）以及覆盖正确推进、安全拒绝和交互语义的 20 个 live-fixture 回归条目进行了验证。在 VR 试点中，该架构处理了 77 个帮助循环，叠加拒绝率为零。

**C2 ——一个视觉事实本体与小数据 VLM 适配流水线。**13 事实 v2 本体将座舱显示页面状态分解为可局部验证的命题。该本体从混合了抽象层次的 8 事实 v1 基线演进而来，后者在完成类事实上产生了系统性误报。v2 的分解——将 ins\_go 拆分为 ins\_grnd\_alignment\_text\_visible 和 ins\_ok\_text\_visible，并将 FCS-MC 序列分解为四个子状态——在 Run-002 上将关键误报降低了 64%（13→4），在 Run-004 上降低了 89%（70→8）。基于 928 行双语数据训练的 Qwen3.5-9B LoRA 适配器在两个保留集上均达到 0.99 的事实准确率。相同的数据配方在三个骨干（Qwen3.5-9B、Qwen3.6-27B、Gemma-4-31B）上均产生了相对于各自基础模型的持续改进。本体的演进产生了一个可迁移的设计原则：VLM 应提取可观察的视觉证据，而程序性解释应归



于下游推理。

**C3 ——一个由形成性试点支撑的 VR 评估框架。** 本论文交付了用于评估沉浸式仿真中有依据程序性教学的研究就绪工具，以及一项运用了这些工具的形成性 VR 试点研究 ( $n = 9$ )。所有四名教学辅助条件下的参与者完成了完整的 33 步程序；五名无教学辅助的参与者均未完成。有教学辅助的错误以辅助耦合型 (CO/PA) 为主，而无教学辅助的错误以遗漏型为主。该试点提供了关于可行性和工具就绪性的描述性证据，而非对学习效果的推断性验证。更大规模的受控评估仍是未来工作。

**本论文证明了什么。** 本工作确立了：一个具备结构化视觉事实提取功能的、基于遥测数据与证据约束的教学运行时在技术上是可行的，并且可以通过系统性基准测试进行验证。它证明了 928 行经人工审查的数据足以将通用 VLM 适配到特定领域的提取任务，并在独立保留集上达到接近上限的准确率。它表明视觉事实本体设计——具体而言，将复合程序性目标分解为局部可验证的原子——对模型可靠性具有可度量、可量化的影响。跨骨干结果证实，驱动增益的是数据配方而非特定架构。形成性 VR 试点提供了初步描述性证据：在所有教学辅助试验中均观察到完整的程序完成，且遗漏错误较少，同时支撑了工具流水线在实时 VR 数据采集中的就绪性。

**范围与边界。** VLM 基准测试测量的是事实提取准确率，而非教学有效性。VR 试点提供了形成性描述性证据 ( $n = 9$ ，非随机化，条件不平衡)，并未确立学习效果、工作负荷降低或保持改善。无教学辅助的观察时长不与有教学辅助的时长可比，因为试验在不同的程序节点被停止。问卷和工作负荷数据仍不完整 (P02 问卷标注错误)。在这些边界之内，本论文交付了一个经技术验证的教学运行时、一条可复现的 VLM 适配流水线 (附基准测试证据)，以及证明了可行性和工具就绪性的形成性 VR 试点结果。

## 8.2 未来工作

本论文的贡献为若干未来工作方向开辟了道路，每个方向都直接建立在已完成的贡献之上。

**受控人因评估。** 形成性 VR 试点研究 (第6.3节) 证明了可行性和工具就绪性。下一步是一项更大规模的受控受试者间评估，将基于证据的教学与适当的基线条件进行对比，采用随机分配、预注册分析和充足样本量。所需的关键基础设施升级包括完成参与者/会话元数据模式、NASA-TLX 集成、测验关联和匿名化流水线。鉴于试点观察到的完成率模式，一个双条件设计 (有教学辅助 vs. 无教学辅助)，每组  $n \geq 15$ ，提供了一个可行的起点。

**本体向其他程序的扩展。** 13 事实 v2 本体特定于 F/A-18C 冷启动任务及其三显示器复合面板布局。将本体扩展到 DCS 内的其他程序——如导航、武器使用或应急检查单——将检验视觉事实分解策略的通用性，并需要新的数据集采集和标注周期。程序包格式专为容纳此类扩展而设计。

**多帧时序推理。** 当前的 VLM 流水线在单帧对上操作并做出独立预测。在多个帧之间融入时序上下文可以提高涉及瞬态或状态转换的事实准确率，例如 FCS-MC 测试序列。可能的方法包括帧堆叠、事实预测的递归聚合，或轻量级时序模型。

**在线适配。** 当前的 LoRA 适配器在固定数据集上离线训练。在线适配循环可以逐步提高边缘情况的准确率，并适应 DCS 版本或飞机变体间座舱显示配置的变化。这将需要轻量级微调基础设施和质量控制机制。

**确定性程序引擎增强。** 当前的门控规则引擎使用包含四个操作符的 v1 DSL。扩展 DSL 以提高程序包的表达能力，并减少对边缘情况手动步骤分类的依赖。

本论文所完成的工作确立了：一个具备结构化视觉事实提取功能的、基于遥测数据与证据约束的教学运行时在技术上是可行的，并可通过自动化基准测试进行验证。下一阶段的研究必须确定这一技术能力能否转化为沉浸式仿真环境中人类学习的实际改善。



## 参考文献

- [1] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.
- [2] Eagle Dynamics. DCS World, 2013. Digital Combat Simulator. Available at: <https://www.digitalcombatsimulator.com/>.
- [3] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [4] Sourab Mangrulkar, Sylvain Gugger, Lysandre Debut, Younes Belkada, Sayak Paul, and Benjamin Bossan. PEFT: State-of-the-art parameter-efficient fine-tuning methods, 2022. URL <https://github.com/huggingface/peft>.
- [5] Kurt VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011. doi: 10.1080/00461520.2011.611369.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [7] Yu Zhang. Explain reality: Grounded procedural tutoring with foundation models and visual fact extraction in immersive simulation — MSc thesis proposal. TU Clausthal, Institute for Software and Systems Engineering (ISSE). Unpublished manuscript., 2025.

## 第九章 附录

### 9.1 完整 LoRA 超参数配置

表 9.1 列出了在匹配的 Run-003 + Run-005 $\times$ 2 数据配方下三种骨干模型的完整超参数配置。数值来自可用的训练报告和基准测试工件。

Table 9.1: 三种骨干的完整 LoRA 微调超参数。

| 参数                          | Qwen3.5-9B        | Qwen3.6-27B       | Gemma-4-31B       |
|-----------------------------|-------------------|-------------------|-------------------|
| max_seq_length              | 4096              | 4096              | 4096              |
| num_train_epochs            | 4.0               | 4.0               | 4.0               |
| learning_rate               | $2\times 10^{-4}$ | $2\times 10^{-4}$ | $2\times 10^{-4}$ |
| per_device_train_batch_size | 1                 | 1                 | 1                 |
| gradient_accumulation_steps | 4                 | 4                 | 4                 |
| lora_r                      | 16                | 16                | 16                |
| lora_alpha                  | 16                | 16                | 16                |
| lora_dropout                | 0.0               | 0.0               | 0.0               |
| seed                        | 3407              | 3407              | 3407              |
| load_in_4bit                | True              | True              | True              |
| warmup_ratio                | 0.1               | 0.1               | 0.1               |
| weight_decay                | 0.01              | 0.01              | 0.01              |
| train_rows                  | 928               | 928               | 928               |
| eval_rows                   | 0                 | 0                 | 0                 |
| 骨干特定参数                      |                   |                   |                   |
| Vision LoRA                 | enabled           | enabled           | disabled          |
| LoRA target modules         | vision+lang       | vision+lang       | all-linear        |
| Chat template               | Qwen default      | Qwen default      | gemma-4           |
| GPU memory util.            | 0.6               | 0.6               | 0.95              |
| 训练结果                        |                   |                   |                   |
| Train runtime (s)           | 6419              | 12619             | 8050              |
| Train loss (final)          | 0.2156            | 0.1068            | 0.0474            |

注：训练损失值不可在不同骨干之间直接比较，因为分词器行为、聊天模板结构、

目标序列分布和模型参数化存在差异。

## 9.2 8 事实 V1 基线基准测试

最早的完整基准测试使用在 Run-001 (180 个任务) 上训练的 8 事实 LoRA 适配器, 并在 Run-002 保留集 (50 个样本) 上进行评估。该实验线早于 13 事实本体, 此处列作历史参考。

**Table 9.2:** 8 事实 v1 基准测试: Qwen3.5-9B Base vs. LoRA-v1 在 Run-002 保留集上 (50 样本, EN)。

| 指标                       | Base   | LoRA-v1 | $\Delta$ |
|--------------------------|--------|---------|----------|
| JSON valid rate          | 1.0    | 1.0     | —        |
| Schema valid rate        | 1.0    | 1.0     | —        |
| Fact accuracy            | 0.7600 | 0.9150  | +0.1550  |
| Macro $F_1$              | 0.4241 | 0.5847  | +0.1605  |
| Seen $F_1$               | 0.4714 | 0.8380  | +0.3666  |
| Sample exact match       | 0.06   | 0.36    | +0.30    |
| Critical false positives | 13     | 15      | +2       |

LoRA 适配器在事实级指标上有显著改善, 但关键误报从 13 个增加到 15 个, 这证实了 8 事实 v1 本体的结构性弱点: 诸如 `ins_go` 等复合目标无法从单一帧中进行视觉验证, 并在完成类事实上产生了系统性的误报错误。

## 9.3 数据集事实分布

表 9.3 报告了两个主要训练来源 (Run-003、Run-005) 和两个 13 事实保留集 (Run-002 newfacts、Run-004 random) 的逐事实 `seen` 计数。计数数据取自对应的 `stats.json` 文件。

Run-005 的组合再平衡成功改进了代表性不足的事实覆盖范围: `supt_page_visible` 从 20 增加到 54 combined seen, `fcsmc_page_visible` 从 55 增加到 111, `ins_grnd_alignment_text_v` 从 58 增加到 130。

## 9.4 CLI 命令参考

`simtutor` 包提供以下 CLI 命令:

**run.** 使用模拟环境适配器和预录制场景文件执行仿真, 写入事件日志。

Table 9.3: 训练集和保留集中逐事实 seen 计数 (13 事实 v2 本体)。

| Fact ID                           | Run-003 (220) | Run-005 (122) | Run-002 new (50) | Run- |
|-----------------------------------|---------------|---------------|------------------|------|
| tac_page_visible                  | 46            | 24            | 23               |      |
| supt_page_visible                 | 20            | 34            | 5                |      |
| fcs_page_visible                  | 30            | 40            | 13               |      |
| fcs_page_x_marks_visible          | 16            | 18            | 1                |      |
| bit_root_page_visible             | 18            | 43            | 9                |      |
| fcsmc_page_visible                | 55            | 56            | 9                |      |
| fcsmc_intermediate_result_visible | 18            | 15            | 1                |      |
| fcsmc_in_test_visible             | 18            | 19            | 6                |      |
| fcsmc_final_go_result_visible     | 18            | 22            | 2                |      |
| hsi_page_visible                  | 106           | 109           | 49               |      |
| hsi_map_layer_visible             | 79            | 37            | 27               |      |
| ins_grnd_alignment_text_visible   | 58            | 72            | 42               |      |
| ins_ok_text_visible               | 12            | 14            | 4                |      |

**replay.** 对照程序包验证现有事件日志，检查步骤排序和状态机一致性。

**score.** 使用评分引擎对事件日志进行评分。

**record-vlm.** 在视觉观察集上运行 VLM 事实提取，记录预测用于基准测试。

**replay-bios.** 通过遥测流水线重放原始 DCS-BIOS 捕获。

**validate.** 对照模式注册表中的命名模式验证 JSONL 文件。

所有命令接受模型配置覆盖 (-model-provider、-model-name、-model-base-url、-model-timeout-s) 和语言切换 (-lang)。

## 9.5 模型提供者配置

模型访问通过环境变量配置:SIMTUTOR\_MODEL\_PROVIDER(openai\_compat | ollama | stub)、SIMTUTOR\_MODEL\_BASE\_URL、SIMTUTOR\_MODEL\_NAME、SIMTUTOR\_MODEL\_TIMEOUT\_S、SIMTUTOR\_MODEL\_API\_KEY(openai\_compat 必需)、SIMTUTOR\_MODEL\_ENABLE\_MULTIMODAL (切换请求中的 base64 图像编码) 以及 SIMTUTOR\_LANG (zh | en)。实时运行时在启动时验证所有必需配置，并从所有日志输出中脱敏 API 密钥。

## 9.6 回放评估套件

表 9.4 列出了 fa18c\_startup\_v04 套件中的五个回放评估用例。

Table 9.4: 回放评估用例。

| Case ID                    | 预期步骤 | 视觉          | 预期目标                  |
|----------------------------|------|-------------|-----------------------|
| noop_2min                  | S01  | unavailable | battery_switch        |
| batteryon_2min             | S02  | unavailable | fire_test_switch      |
| Batteryon_enginGenoff_2min | S01  | unavailable | generator_left_switch |
| fcs_reset_fcs_bit_2min     | S18  | available   | fcs_bit_switch        |
| ins_2min                   | S12  | available   | ins_mode_knob         |

具有 vision\_status = available 的用例在对应的 DCS Saved Games 目录中包含逐帧 sidecar 文件 (frames.jsonl)，支持在无实时 DCS 实例的情况下回放视觉依赖的程序步骤。

9.7 VR 试点研究——补充数据

表 9.5 列出了参与者的经验概况。

Table 9.5: 试点参与者经验概况（自报）。

| P   | 条件            | DCS 经验       | 飞行仿真         | VR 经验        | Quest 3      | 分组           |
|-----|---------------|--------------|--------------|--------------|--------------|--------------|
| P01 | without_tutor | frequent     | frequent     | frequent     | frequent     | intermediate |
| P02 | without_tutor | intermediate | intermediate | frequent     | frequent     | —            |
| P03 | without_tutor | novice       | novice       | intermediate | frequent     | beginner     |
| P04 | with_tutor    | intermediate | intermediate | frequent     | frequent     | intermediate |
| P05 | with_tutor    | intermediate | intermediate | frequent     | frequent     | —            |
| P06 | without_tutor | novice       | novice       | intermediate | frequent     | beginner     |
| P07 | without_tutor | novice       | novice       | intermediate | frequent     | beginner     |
| P08 | with_tutor    | novice       | novice       | frequent     | frequent     | —            |
| P09 | with_tutor    | novice       | novice       | intermediate | intermediate | beginner     |

— = 未记录。

表 9.6 列出了每位无教学辅助参与者未完成的步骤。

表 9.7 报告了自动编码的错误计数（人工审查前）与人工错误计数的对比，说明本试点中自动到人工校正的量级。

**Table 9.6:** 无教学辅助条件中未完成的步骤（人工编码）。

| P   | 未完成的步骤                                                               |
|-----|----------------------------------------------------------------------|
| P01 | S09, S12, S18, S19, S20, S22, S24, S27, S29, S31                     |
| P02 | S02, S14, S18, S19, S27, S30                                         |
| P03 | S07, S09, S16, S18, S19, S26, S27, S29, S32                          |
| P06 | S07, S18, S19, S27                                                   |
| P07 | S02, S09, S12, S13, S16, S17, S18, S19, S22, S26, S27, S28, S29, S32 |

S18（右 DDI 上的 FCS-MC BIT 页面）和 S19（FCS BIT 最终 GO 结果）被所有五名无教学辅助参与者遗漏。S27（襟翼开关至 AUTO）也被所有五人遗漏。这些步骤是视觉优先的，需要 VLM 确认或教员对正确显示页面序列的了解。

**Table 9.7:** 自动编码 vs. 人工错误计数（每参与者）。

| P   | 条件            | 自动 OM | 自动 CO | 人工 OM | 人工 CO | 人工总计 |
|-----|---------------|-------|-------|-------|-------|------|
| P01 | without_tutor | 4     | 3     | 8     | 0     | 10   |
| P02 | without_tutor | 0     | 3     | 0     | 0     | 1    |
| P03 | without_tutor | 0     | 4     | 7     | 0     | 11   |
| P06 | without_tutor | 0     | 3     | 2     | 0     | 4    |
| P07 | without_tutor | 1     | 9     | 11    | 0     | 11   |
| P04 | with_tutor    | 0     | 4     | 0     | 3     | 7    |
| P05 | with_tutor    | 0     | 3     | 0     | 3     | 6    |
| P08 | with_tutor    | 0     | 3     | 0     | 0     | 0    |
| P09 | with_tutor    | 0     | 3     | 0     | 3     | 5    |

自动编码错误来自自动化流水线（`step_coding.csv` 中的 `Auto_Error_*` 列）。人工错误来自人工审查列（`Error_*`）。P08 的自动错误在人工审查中被全部覆盖为零（见第6.3节的数据质量注记）。