



TU Clausthal

硕士学位论文

作者：

Yu Zhang

解释现实：基于基础模型的 Meta Quest 3 交互式解释

第一导师：

Prof. Dr. Christian Bartelt

第二导师：

Prof. Dr. Rüdiger Ehlers

11th June 2026

软件与系统工程研究所
克劳斯塔尔工业大学

原创性声明

本人已阅读并理解克劳斯塔尔工业大学以及 ISSE 公告中发布的各项指南，包括关于使用文献及其他来源的规定。本人确认已独立完成本论文。任何取自其他来源并在本论文中复制的信息均已明确标注。

根据通用考试条例，本论文尚未提交至任何其他考试机构。

本人特此同意，本人的硕士学位论文可在本研究所图书馆内展出并供查阅。

克劳斯塔尔-采勒费尔德，11th June 2026

地点，日期

Yu Zhang

摘要

解释现实研究基础模型如何在沉浸式仿真器中提供有用的交互式解释，同时避免成为无界的对话代理。研究的动机场景是一个在数字战斗模拟器世界 (DCS World) 中的 Meta Quest 3 训练任务：学习者执行 F/A-18C Lot 20 冷启动程序，而教学系统必须根据实际存在的飞机状态解释下一步操作。在此场景中，"现实"并非物理飞机，而是一个实时的、高负荷的、多模态的仿真状态。只有当解释能够追溯到可检查的证据时，它才是有用的。

本文提出 SimTutor，一个基于证据的程序性教学运行时系统，结合了程序包规则、DCS-BIOS 遥测、检索到的程序知识、结构化响应验证、可回放日志，以及用于座舱显示事实的视觉语言模型 (VLM) 层。主要的机器学习贡献是一个用于结构化视觉事实提取的小数据 LoRA 适配流水线。最初的 8 事实本体揭示了一个问题：诸如程序完成状态之类的复合目标容易产生高风险假阳性。修订后的 13 事实本体则要求 VLM 提供局部视觉证据原子，并将程序性解释留给确定性的下游规则。

在两个独立且经验证与训练集零完全重叠的 13 事实留出集上，使用 Run-003 + Run-005x2 配方训练的 Qwen3.5 LoRA 适配器是最强的离线产品线。在 Run-002 new-facts 上，事实准确率从 0.8677 升至 0.9908，样本完全匹配率从 0.10 升至 0.88；在 Run-004 random 上，事实准确率从 0.8038 升至 0.9931，样本完全匹配率从 0.03 升至 0.92。关键假阳性在 Run-002 上从 11 降至 4，在 Run-004 上从 70 降至 8。匹配的 Qwen3.6-27B 实验显示出一个更强的基座模型和一个适用于本地服务部署的 LoRA 候选，但它在当前留出集上并未超越 Qwen3.5 LoRA 产品线。Gemma 在相同数据配方下显著改善，在某些关键事实上更加保守，但在整体完全匹配行为上仍低于 Qwen3.5。

一项非随机的形成性 Quest 3 试点研究 (9 名参与者) 补充了技术证据。参与者群体包括自报的新手、中级和专家用户。4 名参与者使用教学系统，5 名在无教学系统的被动条件下进行。经人工审核，所有 4 名教学系统条件下的参与者均达到最终 33 步状态；无教学系统条件下的 5 次试验均未达到经确认的最终 33 步状态。教学系统条件下的遗漏错误为零，但在若干试验中引入了与辅助耦合的执行错误和提示错误。原始 NASA-TLX 和可用性/信任度评分仅为描述性报告；P02 的问卷因元数据不匹配被排除，P08 使用人工完成编码。因此，该试点支持可行性、仪器化和错误模式声明，但

不支持关于学习收益、工作负荷降低、记忆保持、迁移效果或任务速度的因果性声明。

本文认为, 沉浸式训练中的可靠交互式解释最好作为一个证据设计问题来处理: 基础模型应仅通过运行时能够观测、验证和回放的证据来解释实时的任务状态。

Zusammenfassung

Explain Reality untersucht, wie Foundation Models in einer immersiven Simulationsumgebung interaktive Erklärungen geben können, ohne als unbegrenzte Dialogsysteme eingesetzt zu werden. Der Anwendungskontext ist ein Training mit der Meta Quest 3 in Digital Combat Simulator World, in dem Teilnehmende den Kaltstart der F/A-18C Lot 20 ausführen. Die Erklärung des Systems muss sich auf den tatsächlich beobachtbaren Simulatorzustand beziehen. “Realität” bedeutet in dieser Arbeit daher den laufenden, multimodalen und kognitiv anspruchsvollen Zustand der Simulation.

Die Arbeit stellt SimTutor vor, eine evidenzbasierte Laufzeitumgebung für prozedurales Tutoring. Sie kombiniert deklarative Prozedurregeln, DCS-BIOS- Telemetrie, Retrieval von Prozedurwissen, strukturierte Antwortvalidierung, Replay-Logs und ein Vision-Language Model für Cockpit-Anzeigen. Der zentrale Machine-Learning-Beitrag ist eine kleine LoRA-Anpassung für strukturierte visuelle Fakten. Eine frühe 8-Fact-Ontologie zeigte, dass zusammengesetzte Zielzustände riskante False Positives erzeugen können. Die revidierte 13-Fact-Ontologie trennt deshalb lokale visuelle Evidenz von der späteren prozeduralen Interpretation.

Auf zwei unabhängigen 13-Fact-Holdouts ist die Qwen3.5-LoRA-Linie mit Run-003 + Run-005x2 die stärkste Offline-Konfiguration. Die Fact Accuracy steigt auf Run-002 newfacts von 0,8677 auf 0,9908 und auf Run-004 random von 0,8038 auf 0,9931; gleichzeitig sinken kritische False Positives von 11 auf 4 beziehungsweise von 70 auf 8. Qwen3.6-27B liefert eine starke Kandidatenlinie für das lokale Serving, übertrifft die Qwen3.5-LoRA-Linie auf den aktuellen Holdouts jedoch nicht. Gemma profitiert ebenfalls von derselben Datenrezeptur, bleibt aber beim exakten Sample-Match hinter Qwen3.5.

Eine formative, nicht randomisierte Quest-3-Pilotstudie mit neun Teilnehmenden ergänzt die technische Evaluation. Die Stichprobe enthielt selbstberichtete Novizen, intermediäre und erfahrene Teilnehmende. Vier Teilnehmende nutzten den Tutor, fünf absolvierten eine passive Bedingung ohne Tutor. Alle vier Tutor-Teilnehmenden erreichten

den manuell geprüften finalen 33-Schritt-Zustand; keine der fünf Sitzungen ohne Tutor erreichte einen bestätigten finalen 33-Schritt-Zustand. Die Pilotdaten belegen Machbarkeit, Instrumentierung und Fehlermuster, aber keine kausalen Effekte auf Lernen, Arbeitsbelastung, Retention, Transfer oder Geschwindigkeit.

致谢

感谢我的导师在本论文全程中给予的指导与反馈。同时感谢试点研究的参与者在 VR 环节中付出的时间、耐心与专注。

AI 工具使用声明

在本论文及相关软件项目的准备过程中，使用了 AI 辅助工具，包括 ChatGPT/Codex、Claude Code 和 GitHub Copilot。其用途包括语言编辑、结构调整建议、LaTeX 一致性检查、引文缺口审计、在作者指导下检查仓库产物、代码补全支持、代码审查辅助以及代码集成和合并审查过程中的辅助。这些工具未被用于编造实验数据、参与者结果或文献元数据。所有声明、数值结果、引文、解释、源代码决策和最终措辞均由作者负责。

Contents

第一章 引言	1
1.1 动机：解释一个实时的训练现实	1
1.1.1 本论文中“现实”的含义	2
1.2 案例研究：DCS World 中的 F/A-18C Lot 20 冷启动	2
1.3 问题陈述	3
1.4 研究问题	3
1.5 方法	4
1.6 贡献	5
1.7 论文结构	5
第二章 理论背景与相关工作	7
2.1 沉浸式仿真中的程序性训练	7
2.2 已有辅助方法	8
2.3 为什么已有方法在这里不足	9
2.4 作为有边界组件的基础模型	9
2.5 视觉事实提取与 PEFT 适配	10
2.5.1 结构化输出与可靠性指标	10
2.5.2 参数高效适配	10
2.6 定位与最接近工作的缺口	11
第三章 方法：基于证据的教学运行时	13
3.1 设计需求	13
3.2 证据对象模型	14
3.3 程序包作为权威先验	14
3.4 权限层级	15
3.5 遥测基础	15
3.6 检索与数据源策略	16
3.7 视觉事实集成	16

3.8	帮助循环	16
3.9	结构化响应与覆盖层校验	17
3.10	不确定性与降级模式	17
3.11	VR 交互边界	18
3.12	日志记录、回放与导出	18
3.13	方法边界	19
第四章	方法：视觉事实适配与试点协议	20
4.1	程序运行时与遥测基础	20
4.2	知识基础与来源策略	21
4.3	视觉事实数据流水线	21
4.3.1	标注单元与决策边界	23
4.4	数据集整理	24
4.4.1	数据集概览	24
4.4.2	数据集质量检查	24
4.4.3	本体演进：从 8 事实 v1 到 13 事实 v2	25
4.4.4	训练配方：Run-003 + Run-005x2	26
4.4.5	留出独立性	26
4.5	LoRA 微调配置	26
4.5.1	骨干模型与比较策略	26
4.5.2	训练栈与超参数	27
4.5.3	双语 SFT 与组成再平衡	27
4.5.4	训练目标构建	27
4.6	基准测试协议	28
4.6.1	指标	28
4.6.2	Base vs. LoRA 比较	28
4.6.3	基准测试类别	28
4.6.4	基准测试制品	29
4.6.5	错误审查协议	29
4.7	人类被试试点方法论	29
4.7.1	伦理、知情同意与数据保护	29
4.7.2	参与者与条件	30
4.7.3	任务与设备	30
4.7.4	数据来源与编码	30
4.7.5	问卷与评论工具	31

4.7.6	数据质量说明	31
4.7.7	分析方法	31
4.8	小结	32
第五章	可复现性与产物溯源	33
5.1	产物与主张边界	33
5.2	RQ 层级溯源	34
5.3	可复现性限制	34
第六章	结果	36
6.1	RQ1: 基于证据的教学运行时	37
6.1.1	运行时就绪性总结	37
6.1.2	回放与约束层结果	37
6.1.3	实时导出结果	38
6.1.4	示例证据路径	38
6.2	RQ2: 面向座舱视觉事实的 VLM 适配	39
6.2.1	数据集与训练总结	39
6.2.2	Qwen3.5 主要结果	39
6.2.3	主要结果的指标解读	41
6.2.4	Qwen3.6 与 Gemma 的比较	42
6.2.5	模型特定解读	43
6.2.6	错误模式	43
6.3	RQ3: 形成性 Quest 3 先导实验	44
6.3.1	参与者与任务结果	44
6.3.2	过程错误模式	45
6.3.3	工作负荷、可用性、信任与评论	46
6.3.4	RQ3 总结	47
第七章	讨论	49
7.1	从提案到实现系统的演进	49
7.2	技术证据的解读	50
7.2.1	技术证据不能证明什么	51
7.2.2	对 VLM 结果的数据导向解读	51
7.2.3	对 ML 系统设计的启示	51
7.3	试点发现的解读	52
7.3.1	辅助与协作的边界	53

7.4	本体设计的教训	53
7.5	局限性	54
7.5.1	评估范围	54
7.5.2	系统与 VLM 范围	55
7.5.3	构念效度	55
7.5.4	试点范围	56
7.5.5	范围总结	56
7.6	未来工作	56
7.6.1	受控人体受试者评估	56
7.6.2	本体向其他过程的扩展	57
7.6.3	时序与多帧视觉推理	57
7.6.4	系统级帮助循环评估	57
7.6.5	多模态协作策略	57
7.6.6	原位纠正与适配	58
7.6.7	未来方向总结	58
第八章	结论	59
8.1	已完成工作总结	59
8.2	未来工作	61
参考文献		62
第九章	附录	67
9.1	完整 LoRA 超参数配置	67
9.2	8 事实 v1 基线基准测试	67
9.3	数据集事实分布	67
9.4	CLI 命令参考	69
9.5	模型提供方配置	70
9.6	回放评估套件	70
9.7	补充架构与导出图示	70
9.8	VR 试点研究——补充数据	74

List of Figures

4.1	VLM 适配流水线。DCS World 复合截图经预标注、人工审核后，转换为双语监督微调数据行，使用 LoRA 适配，在独立留出集上进行评估，并用于推动本体修订。	22
4.2	从 8 事实 v1 到 13 事实 v2 的本体演进。复合目标如 <code>ins_go</code> 和宽泛的 FCS-MC 完成事实被分解为局部可验证的视觉原子；程序引擎随后将这些观测与遥测、阶段和时序证据结合起来。	25
6.1	各研究问题的评估与数据流。回放与约束层产物支撑 RQ1，VLM 基准测试产物支撑 RQ2，Quest 3 先导实验导出数据支撑 RQ3 的描述性发现。	36
6.2	选自 VLM 训练报告的 Qwen3.5 基准测试图。	41
6.3	选自 VLM 训练报告的补充基座模型基准测试图。	43
9.1	Harness 与证据验证。候选 tutor 动作在接受为叠加层动作计划之前，需经过 Schema 约束、UI 白名单、证据一致性和过程状态的检查；不安全或证据不足的动作会被修复、拒绝或降级为纯文字指导。	71
9.2	原型所使用的部署拓扑。模拟器、Quest 3 叠加层路径、本地运行时、回放工具和远程模型提供方被分离开来，使得实时试验和离线分析可以使用相同的证据和日志契约。	72
9.3	详细的实验导出管线	73

List of Tables

2.1	面向程序性 VR 仿真的基于证据辅导循环的最接近工作定位。	12
4.1	用于视觉事实提取的数据集清单。	24
4.2	试点数据质量问题与最终分析权威。	32
6.1	RQ1 运行时就绪性证据，以产物覆盖率的形式呈现。	37
6.2	所报告 VLM 结果的视觉事实数据集清单。	39
6.3	13 事实主要结果：Qwen3.5-9B 基座对比 LoRA 在两个留出集上的表现。	40
6.4	Qwen3.5 主要结果的计数解读。	40
6.5	在匹配的 Run-003 + Run-005×2 配方下的补充基座模型比较。	42
6.6	Qwen3.5、Qwen3.6 与 Gemma 匹配比较的解释。	42
6.7	参与者与试验概览。	45
6.8	手动过程错误计数。OM = 遗漏，CO = 执行错误，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违反。	46
6.9	排除 P02 后的试验后问卷摘要。Confidence、tutor rating 和 user rating 使用记录的 1–7 响应量表；Raw TLX 以未加权原始工作负荷平均值报告。	47
6.10	简短的匿名参与者评论，为节省空间进行了改写或轻微压缩。	47
7.1	未来工作方向总结。	58
9.1	三种骨干模型的完整 LoRA 微调超参数配置。	68
9.2	8 事实 v1 基准测试：Qwen3.5-9B 基础模型 vs. LoRA-v1 在 Run-002 留存验证集上（50 样本，英文）。	68
9.3	训练集和留存验证集中各事实 seen 计数（13 事实 v2 本体）。	69
9.4	回放评估案例。	70
9.5	试点参与者经验画像（自我报告）。	74
9.6	无 tutor 条件下未被确认为完成的步骤。	74
9.7	每位参与者的自动编码 vs. 人工错误计数。	75

9.8 试点补充数据质量权威规则。	75
-----------------------------	----

第一章 引言

1.1 动机：解释一个实时的训练现实

本论文的标题——解释现实：在 *Meta Quest 3* 上使用基础模型进行交互式解释 (*Explain Reality: Interactive Explanations with Foundation Models on the Meta Quest 3*) ——有意将两个常常被分开讨论的理念结合在一起。其一是交互式解释：学习者需要在操作过程中获得帮助，而不是在任务结束之后。其二是现实：解释必须与训练环境中当前存在的状态绑定。在本工作中，这一现实是一个实时的高保真仿真环境，而非不受约束的自然场景。学习者佩戴 *Meta Quest 3* 虚拟现实设备，在数字战斗模拟器世界 (*DCS World*) 中操控一架 *F/A-18C Lot 20*，并尝试在不中断训练流程的情况下完成冷启动程序。

程序性训练所产生的问题与普通的问答截然不同。正确的下一步操作并非仅仅是手册中记载的一个事实。它取决于顺序、前置条件、座舱状态、先前的错误以及学习者当前的困惑点。在座舱启动任务中，一个诸如“打开航电系统”的泛泛回答是不够的，除非飞机已通电、相关显示器已激活、且程序已达到适当的阶段。基础模型能够生成流畅的程序性语言，但仅凭流畅性并不能使指令安全、及时或可审查。一个对错误状态做出解释的导师可能比一份静态检查单更糟糕，因为它看似具有适应性，却在悄然间失去了与仿真器的联系。

因此，本文的动机场景并不是一个用于航空问题的通用聊天机器人，而是一个面向序列敏感程序性训练的头戴式导师。学习者不应在每次需要提示时都必须摘下头戴设备、搜索 PDF、重放视频或失去空间环境感知。本文的科学重心是一个机器学习系统问题：如何通过来自仿真器的证据、由人工编写的程序规则以及一个经过领域适配、能够报告结构化座舱视觉事实的视觉语言模型 (VLM) 来约束基础模型导师的行为？

这种聚焦并非对标题的偏离。它是使标题可信的技术前提。在一个动态的、高负荷的、多模态 VR 任务中，AI 助手只有在能够解释学习者实际任务状态时才能变得有用。因此，系统必须能够充分观测该状态，将模型输出绑定到证据上，拒绝或修复无依据的操作，并保存会话结束后可以回放的日志。本论文将这一设计原则称为基于证据的交互式解释 (*evidence-grounded interactive explanation*)。

1.1.1 本论文中“现实”的含义

标题中的“现实”一词既不指哲学实在论，也不指狭义的图形学意义上的混合现实渲染。它指的是学习者当前正在其中进行操作的操作性状态。在 Quest 3 环境下，这一状态是多模态的。它包括仿真器遥测数据、座舱显示页面、人工编写的程序阶段、学习者的近期操作、检索到的手册上下文以及学习者可能遵循的可见叠加层。一个忽略这些层次中任何一层的导师，可能会产生一个局部流畅但实际错误的解释。

例如，继续 FCS BIT 序列的指令只有在相关显示页面可见或最近被观测到、所需的前置步骤已满足、且学习者尚未越过所描述的状态时才有意义。文本模型可以措辞出这样的指令，但不能允许它凭空编造为其辩护的状态。VLM 可以读取显示内容，但不应当决定整个程序。遥测数据可以确认开关和发动机参数，但仅凭遥测本身并不能解释学习者下一步应该做什么。因此，“解释现实”变成了一项系统主张：解释是通过连接这些证据来源而产生的，而不是请求基础模型即兴扮演导师角色。

Meta Quest 3 之所以居于核心地位，是因为它使这一问题变得交互化和具身化。在桌面使用场景中，学习者可以更容易地查阅外部文档或切换窗口。在头戴设备中，帮助信息与空间注意力、手部运动、座舱扫描和任务记忆争夺资源。一个错误或过时的叠加层可能在错误的时间将注意力引向错误的对象。一个正确但无依据的解释仍可能鼓励过度信任，如果学习者看不到它为何被给出的理由。因此，本论文不将 VR 视为一种装饰性的输出媒介，而是将其视为迫使基于证据的解释必须精确、简洁且可审计的场景。

这一框架也解释了为什么本工作强调机器学习而非仅仅关注界面设计。系统需要一个能够阅读富含文本的座舱显示器的感知组件，一个能够从证据中措辞帮助信息的语言组件，以及一个防止任何组件越权的运行时环境。机器学习贡献不仅仅在于使用 VLM 或 LLM，而在于模型输出如何被转换为程序性辅导循环中受约束的、可检查的主张。

1.2 案例研究：DCS World 中的 F/A-18C Lot 20 冷启动

实证场景是 DCS World 中 F/A-18C Lot 20 的冷启动程序 [9, 10]。SimTutor 使用的程序包并非一个虚构的提示词脚本。它是从 DCS World F/A-18C 手册和本地评估材料中衍生出的、经过人工分解的训练指南，表现为用于辅导和评分的权威先验知识。当前程序包包含 33 个有序教学步骤，按阶段分组，从初始通电到发动机启动、航电准备、飞行控制检查，再到最终的滑行前配置。

该任务足够紧凑，适合在一篇论文中进行研究，但又足够具有挑战性，能够暴露

证据问题。一些状态通过 DCS-BIOS 遥测接口可得，例如开关位置、发动机参数或指示器数值。其他状态则显示在座舱显示器上。左右数字显示指示器（DDI）和先进多用途彩色显示器（AMPCD）展示了对确认飞行控制和导航状态至关重要的页面和文本。因此，导师不能依赖单一观察通道。它必须结合遥测数据、显示器感知、程序规则和检索到的程序性知识。

视觉组件被有意地控制在一个狭窄范围内。VLM 不被要求描述整个 VR 场景、推断学习者的意图或决定哪个程序步骤已完成。它报告一组少量的结构化视觉事实，例如 FCS 页面、BIT 根页面、FCS-MC 结果、HSI 页面或 INS 对准文本是否可见。然后，程序引擎将这些事实与遥测数据和序列状态一同解释。感知与程序逻辑之间的这种分离是本论文的主要设计经验之一。

1.3 问题陈述

研究问题可以表述如下：

基础模型导师如何在沉浸式仿真器内部提供交互式程序性解释，同时使每一个可操作输出都根植于可观察、可验证和可回放的证据之中？

三个缺口推动了这一问题。首先，手册、视频和检查单是权威的，但不具备状态感知能力。它们可以告诉学习者程序包含什么，但不知道学习者是否已经完成某个步骤、跳过了某个前置条件，或者达到了需要视觉确认的显示页面。其次，仿真器遥测在其存在的地方是精确的，但它本身并不提供一个完整的解释通道。它暴露状态，但不决定如何措辞一个即时的提示，也不决定如何解释某个步骤为何被阻塞。第三，基础模型可以生成灵活的语言并解析视觉输入，但当其输出可能引导程序性操作时，它们需要运行时约束。

本论文的贡献在于将这些部件连接起来。语言模型不被视为导师本身。它是运行时环境中的一个组件，该环境组装证据、评估程序门控、检索源材料、验证结构化输出、通过白名单映射叠加层目标，并记录整个帮助循环。VLM 同样受到约束：它输出视觉事实而非高层的程序决策。由此产生的系统既不是一个通用的座舱自动驾驶仪，也不是一个通用的 VR 助手。它是一个面向基于证据的程序性解释的研究原型。

1.4 研究问题

本论文围绕一个总体问题和三个下属研究问题展开。

主研究问题 (Main RQ) . 基础模型如何在 Meta Quest 3 程序性训练环境中支持交互解释, 当其输出根植于仿真器状态、程序性知识和结构化视觉证据之中?

RQ1——基于证据的辅导运行时. 如何将仿真器遥测、检索到的程序知识、视觉事实、模式验证、叠加层白名单和回放日志集成到一个运行时环境中, 使辅导输出保持状态感知和可审计性?

RQ2——VLM 适配与视觉事实可靠性. 小数据 LoRA 适配的 VLM 在多大程度上能够可靠地提取结构化座舱视觉事实? 本体设计和主干选择如何影响关键假阳性?

RQ3——形成性 Quest 3 试点证据. 一项形成性的、非随机的 Quest 3 试点研究在任务完成、程序性错误、工作负荷/信任响应、参与者评论以及辅助与可信协作之间的边界方面提供了哪些描述性证据?

RQ1 通过已实现的 SimTutor 运行时、程序包、验证逻辑、回放/导出基础设施以及实时帮助循环证据来回答。RQ2 通过视觉事实本体、数据集构建流水线、LoRA 训练配方, 以及针对 Qwen3.5、Qwen3.6 和 Gemma 的基础模型对比 LoRA 的留存基准测试来回答。RQ3 通过一项包含九个参与者编码试次的已完成形成性试点来回答。RQ3 的证据仅为描述性的。它不建立统计显著性、学习增益、工作负荷减少、记忆保持、迁移或更快的任务完成。

1.5 方法

本方法将基于证据的运行时与一个聚焦的机器学习适配流水线相结合。

运行时方面将 F/A-18C 冷启动表示为一个声明式程序包。步骤、前置条件、完成门控、源文件优先级、视觉事实绑定和叠加层目标均保持在模型提示词之外。DCS-BIOS 遥测数据被标准化并聚合为运行时变量。检索到的手册和训练指南片段为解释提供文本依据。当帮助请求发生时, 运行时在模型生成之前组装一个结构化的证据包。然后, 响应被解析、验证、对照白名单化的叠加层目标进行检查, 必要时进行修复或拒绝, 并记录以供回放。

机器学习方面聚焦于座舱视觉事实。VLM 数据流水线捕获座舱显示图像, 应用预标注, 支持人工审核, 导出监督微调行, 训练 LoRA 适配器, 并在独立留存数据上评估基础和适配后的主干模型。关键的设计选择是从早期的 8 事实本体过渡到与运行时对齐的 13 事实本体。修订后的本体移除了复合的程序完成目标, 代之以局部的显示观察。这使 VLM 的角色更谦逊且更有用: 它为下游规则提供证据, 而非成为决策者。

试点方面将系统放回最初的 Quest 3 动机场景中。四名参与者使用了导师系统，五名参与者完成了被动的无导师试次。参与者背景按自报从新手到专家不等。研究记录了完成状态、人工错误编码、帮助循环、VLM 调用、叠加层操作、原始 NASA-TLX、可用性/信任响应以及开放式评论。包含该试点的原因是它测试了系统是否能够在 VR 中与真实参与者一起运行，以及会出现哪些类型的失效模式。它不被用作一项有统计效力的人类受试者有效性研究。

1.6 贡献

核心贡献是一个面向高保真程序性仿真的基于证据的基础模型辅导循环。该循环将生成的解释视为一个有边界的系统行为：DCS-BIOS 遥测、人工编写的程序门控、检索到的源文件片段、结构化视觉事实、响应模式、叠加层白名单、确定性修复/回退行为以及回放日志，所有这些都位于模型与学习者之间。这是本论文的主要贡献，直接回应 RQ1。

三个证据支柱支撑着这一贡献。

1. **视觉事实本体与 LoRA 适配协议.** 本论文为 F/A-18C 座舱显示状态开发了一个 13 事实本体，并将其用于一个小数据 LoRA 适配流水线。该本体将局部视觉感知与程序性解释分离开，解决了 8 事实基线所暴露的关键假阳性风险。这一支柱回应 RQ2。
2. **匹配的 VLM 主干对比.** 本论文在 Qwen3.5、Qwen3.6 和 Gemma 主干上评估了相同的 Run-003 + Run-005x2 配方。Qwen3.5 仍然是主要结果线，因为它在所报告的留存数据上实现了最强的适配后精确匹配行为。Qwen3.6 被视为本地服务/部署候选，而 Gemma 提供了不同的对比错误特征。
3. **具有有边界人类面向证据的形成性 Quest 3 试点.** 本论文报告了一项非随机试点，包含九个参与者编码试次，包括参与者经验背景、完成和错误模式、原始 NASA-TLX、可用性/信任评分以及匿名简短评论。这一支柱回应 RQ3，通过展示可行性、工具准备度和辅助耦合风险，而不做出因果性学习论断。

1.7 论文结构

第二章提供基于证据的辅导、VLM、LoRA 适配、结构化视觉输出、仿真器仪器化以及 AR/VR 中的可解释辅助的理论背景和相关工作。

第三章描述基于证据的运行方法：程序包设计、遥测处理、检索、帮助循环验证、叠加层映射和回放。

第**四**章描述 VLM 和试点方法学：数据集构建、从 8 事实到 13 事实的本体演进、LoRA 训练、基准测试指标、主干对比以及 Quest 3 试点协议。

第**五**章定义使结果可审计的产物与主张边界，包括 RQ 层级溯源以及完整实验重跑的限制。

第**六**章按顺序报告 RQ1、RQ2 和 RQ3 的结果：运行时就绪度、VLM 适配基准测试以及形成性试点。

第**七**章解释研究发现和局限性，然后运用“AI 作为动态、高负荷、多模态环境中可信赖的协作者”这一理念来定义未来工作。

第**八**章总结贡献和声明边界。附录**九**包含补充表格、图表、命令参考和试点数据。

第二章 理论背景与相关工作

引言将本论文框定为一个证据设计问题：基础模型应当只通过运行时可以观察、验证和回放的证据来解释一个实时训练状态。因此，本章不是对 VR、飞行仿真或基础模型的百科式综述，而是围绕一个问题组织相关工作：为什么程序性 VR 仿真需要一个基于证据的辅导循环？

答案是累积的。手册和检查单提供权威性，但不具备实时状态感知。智能辅导系统提供任务模型，但通常不是围绕多模态仿真器中的基础模型生成而构建。检索增强生成（RAG）可以约束文本来源，但它本身并不知道座舱是否真的处于被声称的状态。AR/VR 引导可以将指令保留在任务情境中，但很多工作仍是人工编写或静态呈现。视觉语言模型（VLM）可以读取显示图像，但在影响导师之前，其输出必须被转换为有边界的视觉事实。本论文的贡献位于这些缺口的交叉处。

2.1 沉浸式仿真中的程序性训练

程序性训练不同于事实性教学，因为成功依赖于状态约束下的有序操作。学习者不仅需要知道一个操作是什么，还要知道它何时被允许、如何检查它已经生效、以及当中间状态与预期不一致时如何恢复。在航空和工业场景中，这些要求通常通过手册、检查单、教员和仿真器程序来外化。飞行仿真器具有长期训练传统，但仿真器训练是否有效取决于任务、反馈和教学设计，而不只是保真度 [16]。

本论文使用的冷启动任务是一个适合暴露问题的案例。它足够紧凑，可以在硕士论文范围内研究；同时它又具有明显的顺序敏感性、状态依赖性和视觉中介性。在 DCS World 中，学习者佩戴 Meta Quest 3 头戴设备，操作 F/A-18C Lot 20。任务涉及通电、发动机启动、显示器使用、导航对准、飞行控制检查和滑行前配置 [9, 10]。纸质检查单可以描述这些步骤，但交互式导师必须知道当前哪个步骤可执行，以及哪些证据支持这一判断。

虚拟现实提高了弱辅助的代价。头戴设备中的学习者更难忍受切换到 PDF、搜索桌面窗口或重放外部视频。面向装配和维护的 AR 引导研究已经证明，将指令保留在用户任务情境中具有价值 [17, 30, 33]。本论文接受这种情境内帮助的动机，但增加更

严格的系统条件：生成式帮助必须根植于当前仿真器状态，而不仅仅是视觉上靠近座舱。

2.2 已有辅助方法

手册、检查单与仿真器训练。 本案例中最权威的来源是 DCS World 仿真器、F/A-18C 手册/训练材料，以及由这些材料人工分解出的程序包。这些来源定义了程序性先验知识：哪些操作重要、哪些状态转移应当发生。其限制在于，它们不会自动观察学习者的当前状态。一条检查单文本在抽象意义上可能正确，但如果前置条件尚未满足，或学习者已经越过该状态，它在当前时刻就可能是错误的。

智能辅导与约束式辅导。 智能辅导系统 (ITS) 研究长期将显式任务模型、学习者状态跟踪、反馈和约束式诊断视为有效辅导的核心 [2, 23, 29, 35]。这与 SimTutor 直接相关：导师需要的不只是会话能力，还需要任务表示和进度状态。差异在于运行基底。本文系统不是一个拥有封闭题目界面的经典 ITS，而是通过遥测、座舱显示图像、人工编写的门控和事件日志观察高保真仿真器，并将基础模型作为有边界的组件使用。

RAG 与有依据的语言模型辅助。 RAG 使语言生成以检索到的文档为条件，而不是只依赖参数化记忆 [25]。在教育中，大语言模型可以生成灵活的解释和反馈，但也存在无依据自信、幻觉引用和流畅但脱离情境的回答等风险 [20, 21]。神经生成中的 faithfulness 研究同样表明，流畅文本可能偏离其来源证据 [28]。SayCan 等有依据的行动研究则将语言合理性与操作可行性分开 [1]。SimTutor 沿用同一设计直觉：一个回答可能流畅且有来源，但除非运行时能够验证状态、步骤、证据引用和叠加层目标，否则它不应被显示为程序性指导。

AR/VR 引导与仿真器遥测。 AR/VR 程序性引导解决的是将帮助保留在任务情境中的交互问题 [30]。仿真器遥测解决的是另一个问题：观察状态。在本论文中，DCS-BIOS 被用作外部遥测与座舱 I/O 接口 [6]。本论文并不实现 DCS-BIOS。本文贡献从 DCS-BIOS 导出仿真器状态之后开始：SimTutor 选择相关变量，将原始控制量映射为程序级谓词，区分源缺失与已观测为假的值，将遥测与视觉事实和程序门控结合，并记录所得证据以供回放。

2.3 为什么已有方法在这里不足

本案例同时需要四种性质。第一，辅助必须具有实时状态感知。一个只检索到正确手册段落的系统仍可能在仿真器尚未达到前置条件时推荐错误操作。第二，辅助必须是多模态的。DCS-BIOS 暴露了许多开关位置和指示器状态，但座舱显示页面和文本提示同样重要。左右数字显示指示器（DDI）和先进多用途彩色显示器（AMPCD）包含冷启动证据，而这些证据并不总是可以简化为遥测字段。

第三，辅助必须可审计。一个自然语言回答不足以支撑可能引导学习者下一步操作的系统。系统应当保存为什么某个回答被接受、修复、降级或拒绝。这解释了后续章节对事件日志和回放的强调。第四，辅助必须有边界。基础模型不应发明步骤标识符、叠加层目标、来源引用或视觉观察。这些元素必须由程序包、来源策略、模式验证和治理套件控制。

这四项要求解释了本论文的架构。手册和检索提供文本权威。ITS 与约束式辅导提供显式任务状态的需求。遥测提供高置信度仿真器变量。VLM 提供选定视觉事实。运行时在请求语言模型生成解释之前，将这些元素绑定成一个证据包。

2.4 作为有边界组件的基础模型

基于 Transformer 的基础模型为现代语言和多模态系统提供了表示与指令遵循能力 [36]。在本论文中，它们被有意视为组件，而不是整个导师。语言模型接收证据包并返回结构化响应。VLM 接收图像并返回结构化视觉事实对象。二者的输出都必须经过检查，才能影响面向用户的指导。

这种组件视角改变了“解释”的含义。解释不只是一段有帮助的文字。它是主张与证据之间经过检查的关系。如果导师说学习者应继续飞控检查，运行时应能指出当前活跃步骤、已满足的前置条件、支持该指导的检索来源或程序规则，以及相关视觉或遥测证据是否存在。如果证据缺失，模型不应被允许用自信叙事填补空白。

人机交互和可解释 AI 研究支持这种谨慎。可解释 AI 强调需要理解系统为何产生某个推荐，以及如何评估解释是否有效 [13, 18]。人机交互与自动化研究强调可理解性、适当依赖、不确定性处理和可恢复性 [3, 24]。SimTutor 在一个狭窄的程序性场景中将这些思想操作化：响应 schema、证据引用类型、来源策略、叠加层白名单和回放日志共同构成使模型回答可审查的机制。

2.5 视觉事实提取与 PEFT 适配

视觉语言模型将基础模型能力扩展到图像文本任务。Qwen-VL、Qwen3-VL、LLaVA 和 InstructBLIP 等通用 VLM 工作展示了视觉编码器和语言解码器如何支持图像推理、视觉问答、指令遵循和富文本感知 [4, 5, 26, 31]。本论文中的座舱任务以一种很窄的方式使用这些能力。VLM 不被要求生成自由形式的场景描述，而是返回一个固定视觉事实本体上的类型化 JSON 对象。

视觉事实表示包含三种状态：`seen`、`not_seen` 和 `uncertain`。例如 `fcsmc_final_go_result_visible` 是关于一个可见显示提示的局部主张，而不是声称整个 FCS BIT 步骤已经完成。这一区分是核心。最初的 8 事实本体包含更多复合目标，并暴露出一种反复出现的失效模式：即使人工标签为 `not_seen`，模型也可能将类似程序完成的事实报告为 `seen`。当前 13 事实本体将此类目标分解为本地视觉原子，再由下游程序引擎解释。

这一设计也与屏幕和 GUI 理解相关。屏幕内容模型和 UI 数据集强调固定区域、符号文本和布局，而不是普通自然图像 [7, 38]。座舱显示器具有同样的结构化特征。一个很小的视觉线索可能是按钮标签、页面标题、BIT 结果表中的一行，或一个短暂的对准消息。因此，本体是感知与控制逻辑之间的桥梁。

2.5.1 结构化输出与可靠性指标

VLM 任务是小本体上的结构化预测。对于每张图像，模型预测的是一个类别状态向量，而不是一段描述。JSON 格式是集成接口，但学习问题并不只是生成 JSON。模型必须将视觉证据与事实定义对齐，区分页面标签与页面本身，分离中间状态与最终状态，并在线索过于模糊时选择 `uncertain`。

因此，评估使用多个指标。JSON 有效性和 schema 有效性衡量模型是否返回了可用对象。事实准确率统计单个事实状态决策。Macro F_1 平衡不同状态类别。Seen F_1 聚焦正向视觉检测。样本完全匹配要求整个视觉状态向量正确。关键假阳性统计高风险情形，即模型对本不应被视为可见的事实预测 `seen`。最后一个指标尤其重要：完成类线索上的假 `seen` 标签可能比漏检一个线索更严重地污染下游程序推理。

2.5.2 参数高效适配

对大型多模态模型进行全量微调，对狭窄领域任务而言往往既不必要也不实际。低秩适配 (LoRA) 冻结基础模型权重，并为选定模块学习低秩更新矩阵 [19]。如果基础权重矩阵 W 被冻结，LoRA 将更新表示为：

$$W' = W + \Delta W, \quad \Delta W = BA,$$

其中 A 和 B 是低秩可训练矩阵。PEFT、TRL 和 Unsloth 等参数高效微调工具使本地实验中的这一流程变得可行 [14, 27, 37]。QLoRA 和 VeRA 等相关 PEFT 变体说明，该领域存在多种降低适配成本或参数规模的方法 [8, 22]。本论文并不提出新的 PEFT 算法，而是将 LoRA 作为一种实用机制，用于领域特定的结构化视觉事实适配。

因此，本文主张不是“提出了更好的 LoRA 方法”。主张更窄：对于一个 VR 程序性导师，结构化视觉事实加小领域 LoRA 适配，可以比直接使用基础 VLM 产生更可靠的证据通道。这使本体设计、标签审查、留存集独立性和关键假阳性分析成为机器学习方法的一部分。第 六章中的 Qwen3.5、Qwen3.6 和 Gemma 结果用于说明，模型选择是下游风险决策，而不是单纯的排行榜决策。

2.6 定位与最接近工作的缺口

表 2.1 总结了最接近的研究线索和本论文所处理的剩余缺口。上文已经给出代表性来源；该表保留的是压缩后的论证结构。它并不声称既有工作在自身场景中薄弱，而是说明为什么本文场景需要一个整合式证据契约。

本论文位于机器学习适配、辅导系统、仿真器仪器化和 HCI/VR 评估之间。其核心贡献不是发明手册、遥测、RAG、VLM、LoRA 或 AR/VR 引导，而是有纪律的整合：在高负荷 VR 程序性训练中，只有当遥测、程序规则、检索、视觉事实、验证和回放日志约束模型可以说什么、做什么时，基础模型才能提供可审计的交互式解释。上文所综述的任何单一研究线索，都没有同时为本文场景提供实时仿真状态证据、多模态座舱事实、过程层级权限、受边界约束的基础模型生成、头戴设备内指导和可回放审计日志。

Table 2.1: 面向程序性 VR 仿真的基于证据辅导循环的最接近工作定位。

研究线索	可借鉴思想	在本文场景中的缺口	本文处理方式
ITS 与约束式辅导	显式任务模型、学习者状态推理和反馈约束	通常假设导师控制的问题界面，而非带生成式解释的实时多模态仿真器	使用人工编写的程序门控和遥测谓词作为模型生成帮助的权限层。
RAG 与有依据的 LLM/行动系统	将生成语言根植于检索来源或可行动作	检索文本和语言合理性不能证明座舱状态或叠加层目标有效	将检索与遥测、视觉事实、schema 验证和回放日志结合。
VLM 屏幕/文档理解	用多模态模型识别富文本视觉内容	自由描述过宽，难以直接用于程序门控，且会隐藏高风险假阳性	定义 13 事实座舱本体，并报告完全匹配、seen F_1 和关键假阳性。
基础模型 PEFT	以较小训练参数量适配大型模型	PEFT 本身不规定任务本体、证据语义或下游风险指标	将 LoRA 作为视觉事实证据管线中的一种机制，而非新的适配器方法。
AR/VR 程序性引导	将指令保留在用户的具身任务情境中	引导可能是人工编写或静态的，并不总是暴露生成动作的实时状态证据	在 Quest 3 工作流中提供帮助，同时将生成输出绑定到证据和叠加层白名单。
人机信任与可解释性	使推荐可理解并校准用户依赖	一般性指南需要在具体辅导运行时中被转化为操作契约	通过证据引用、不确定性状态、验证和回放实现解释审计线索。

第三章 方法：基于证据的教学运行时

本章在方法层面回答 RQ1。它描述了 SimTutor 如何将基础模型辅助转化为面向 F/A-18C Lot 20 冷启动任务的基于证据的帮助循环。运行时方法由交互式解释所需的契约定义：程序建模、遥测基础、检索、视觉事实集成、响应校验、覆盖层执行以及回放。

3.1 设计需求

该运行时围绕六个需求进行设计。

1. **状态感知的帮助。**教学系统必须基于当前模拟器状态进行推理，而非仅依赖静态检查单。
2. **证据分离。**遥测数据、视觉事实、检索文本以及程序规则在生成后必须保持可区分。
3. **受限的模型权限。**语言模型可以表述解释，但不得静默地定义程序状态或凭空编造覆盖层目标。
4. **可检查的视觉感知。**VLM 应输出可检查、可评分的结构化事实，而非自由形式的座舱叙述。
5. **可回放性。**一条帮助决策必须能够从记录的观测、证据包、模型输出、校验决策以及覆盖层动作中重建。
6. **面向被试的准备。**运行时必须生成被试级别的产物以供后续分析，同时不得将形成性被试变为隐藏的手动编码练习。

这些需求直接源于论文标题。当且仅当解释可以追溯到其所描述的模拟现实时，VR 中的交互式解释才具有可辩护性。

3.2 证据对象模型

运行时将证据视为带类型的对象，而非非结构化的提示文本。这是一个具有方法论意义的设计选择。一个遥测变量、一个失败的门、一条检索到的句子、一个视觉事实以及一个近期动作对教学系统都有用，但它们不应具有相同的含义。如果在生成之前将它们折叠成一个段落，模型可以产生一个流利的回答，但其依据却无法重建。如果将它们保持为带类型的条目，运行时随后可以检查覆盖层或诊断是否引用了实际存在的证据。

因此，证据对象模型为每个可用的上下文片段记录四个属性。第一，记录证据类型，如 `var`、`gate`、`rag`、`delta` 或 `visual`。第二，记录一个可在提示、校验和日志中使用的稳定引用。第三，记录观测到的值或文本依据。第四，在相关情况下记录可用性和质量元数据，如数据源缺失状态、帧年龄或检索来源。这种结构使得帮助响应具有可审计性，因为模型不能简单地引用任意理由；所引用的理由必须对应于当前证据包中的某个证据引用。

证据与解释之间的区分是有意为之的。一个视觉事实可以声明 `fcsmc_final_go_result_visible` 为 `seen`；它不应声明整个 FCS BIT 程序已完成。一个遥测变量可以声明襟翼开关在 `AUTO` 位置；它不应判定学员是否理解为什么需要 `AUTO`。程序引擎和教学响应将证据组合成解释，但这些解释之下的原始证据仍然保持可检查。

3.3 程序包作为权威先验

程序包是教学系统的已编写领域先验。它将 F/A-18C 冷启动表示为 33 个教学步骤，这些步骤源自 DCS World 手册和本地训练材料。每个步骤具有稳定标识符、阶段、前置条件、完成门、证据需求以及 UI 目标。程序包以配置形式存储，而非嵌入提示中。这保持了程序的可审计性，并将领域知识与模型措辞分离。

程序包在帮助循环期间完成三件事。第一，它约束哪些步骤可能被考虑为下一步。当前置条件未满足时，一个步骤不能被推荐为可用的。第二，它指定用于确认进展的证据。某些步骤以遥测为主；依赖显示屏的步骤使用视觉事实绑定；其他检查在所需证据不可用时保守地降级。第三，它定义覆盖层目标空间。模型可以建议帮助，但运行时仅将视觉高亮映射到已知的座舱目标。

这种设计避免了提示驱动教学系统的常见失败模式。如果程序仅以自然语言表示，模型可以混合步骤、跳过前置条件或编造目标名称。在 SimTutor 中，提示接收运行时生成的证据包，但程序本身仍然是一个由系统控制的声明式对象。

3.4 权限层级

运行时使用权限层级来决定什么可以覆盖什么。程序包在步骤顺序、允许的目标和证据需求方面具有权限。遥测在直接导出的模拟器状态方面具有权限。经过审查的视觉事实仅对所定义的视觉命题具有权限，并且仅在其过期时间和质量约束范围内。检索到的文本支持解释，但不覆盖门。LLM 表述指导并可以提出诊断，但不定义最终的程序状态。

该层级防止了若干细微的失败。没有它，一条检索到的手册片段可能建议一种与当前机场冷启动程序包冲突的程序变体。VLM 可能因为看到一个相关页面而推断步骤已完成，即使所需的遥测门为假。LLM 可能选择一个不在当前 UI 白名单中的貌似合理的座舱控件。该层级在面向用户的输出产生之前解决这些冲突：更严格的局部契约胜过更宽泛或不太可靠的证据来源。

该层级还支持优雅降级。如果某个视觉事实缺失，运行时不必须放弃整个帮助循环。它仍然可以使用遥测、门、近期动作和检索到的程序文本。生成的响应仅被限制在这些证据来源所能支持的范围内。在实践中，这意味着教学系统可以说视觉确认不可用，可以要求学员验证一个显示屏，或者在不高亮目标的情况下给出纯文本提示。用户看到的是不够全面的帮助，但不是凭空编造的确定性。

3.5 遥测基础

DCS-BIOS 遥测是模拟器状态的主要观测通道。运行时接收原始帧，归一化导出值，推导高层变量，并将缺失的数据源与假值分开追踪。这种区分很重要。一个变量可以为假，因为座舱状态未满足；也可以因为数据源未被导出或在当前帧中未被观测到而不可用。将两种情况视为相同会使教学系统过于自信。

遥测管线还执行增量清洗和聚合。原始模拟器信号可能抖动、重复或变化过快，不适合模型提示。因此，运行时将高频状态变化转化为稳定变量和简洁的近期动作摘要。这些摘要帮助教学系统解释发生了什么变化，同时不将模型暴露于无界的日志中。

遥测派生的证据示例包括：电池和发电机状态、APU 就绪、发动机 RPM 阈值、油门运动、INS 模式、雷达模式、襟翼状态、驻车制动释放、IFEI BINGO 燃油设置以及姿态源选择。在遥测具有权威性的地方，不使用 VLM。这是一个有意为之的设计选择：当存在直接的模拟器状态时，计算机视觉不应替代它。

3.6 检索与数据源策略

检索到的程序知识支持帮助响应中的自然语言解释部分。运行时从当前程序候选和模拟器状态构建锚定查询，检索本地手册或训练片段，并将其作为源材料提供给模型。数据源策略限制哪些文档和块是允许的。这防止模型接收到任意的仓库文本或无关的模拟器材料。

因此，检索用于解释，而非不受控制的决策。程序包和遥测决定一个步骤是否可用或阻塞；检索到的文本帮助表述动作、检查和理由。这种划分反映了论文更广泛的边界：基础模型应该解释证据，而非替代证据。

3.7 视觉事实集成

当显示内容无法从遥测中可靠读取时，视觉事实进入帮助循环。运行时使用固定的复合面板布局，覆盖左 DDI、右 DDI 和 AMPCD。VLM 接收一帧或多帧候选图像并返回一个 JSON 对象，其中包含允许的事实标识符和状态。当前的 13 事实本体包括页面可见性事实、FCS 页面标记、FCS-MC BIT 状态、HSI/地图图层事实以及 INS 对准文本事实。

运行时将这些事实视为观测，而非程序决策。只有当程序包说明一个视觉事实是相关的，它才能满足步骤绑定。某些事实存活时间短，很快过期；其他事实，如最终 GO 提示，可能粘性更久，因为当学员更换页面后显示状态可能消失。粘性机制防止系统遗忘短暂但重要的视觉证据，同时仍保持证据显式化。

这一架构使得 VLM benchmark 性能与运行时相关。更高的准确率之所以重要，是因为下游规则引擎使用这些事实作为证据。关键的假阳性之所以重要，是因为它可以使一个类似完成的视觉提示在不存在时看起来存在。因此，运行时记录视觉事实调用并保存其输出，用于回放和错误分析。

3.8 帮助循环

帮助循环在学员请求帮助时开始，例如通过被试中使用的已配置热键路径。运行时随后执行以下序列：

1. 读取最新遥测帧和推导变量。
2. 合并近期动作和任何可用的视觉事实观测。
3. 评估程序前置条件和完成门。

4. 选择当前阻塞、待处理或下一个候选步骤。
5. 在本地数据源策略下检索源片段。
6. 构建包含证据包的结构化提示。
7. 请求模型响应。
8. 根据预期 Schema 解析响应。
9. 校验覆盖层目标和证据引用。
10. 执行、修复或抑制覆盖层动作。
11. 将观测、模型响应、校验结果和动作记录到事件日志中。

因此，模型仅在证据组装之后被调用。响应仅在校验之后被使用。这种顺序是“解释现实”的运行时表达：模型解释一个有界的证据包，而系统检查该解释是否可以安全显示。

3.9 结构化响应与覆盖层校验

教学响应是结构化的，而非自由形式的。它包含诊断、推荐动作、检查、解释和覆盖层目标等字段。运行时解析响应，根据 Schema 校验，并通过白名单映射覆盖层目标。如果模型提出不支持的目标、粗糙的目标或缺乏证据的动作，运行时可以修复输出、回退到纯文本指导或抑制覆盖层。

这一校验层对安全性和评估都很重要。它防止模型通过任意文本直接控制视觉高亮。它还创建了模型输出需要修复的频率记录。在后面报告的被试中，所有执行的覆盖层动作均通过了校验；回退事件主要是修复或映射事件，而非完全的仅确定性响应。该结果在系统层面支持 RQ1，同时也显示了模型仍然需要运行时纠正的地方。

3.10 不确定性与降级模式

运行时必须将不确定性作为一种正常运行状态来处理。在实时模拟器中，帮助请求可能在开关正在移动时、显示屏页面正在切换时、DCS-BIOS 变量不可用时或 VLM 帧过时到达。将这些情况视为普通的假值会使教学系统过于自信。将它们视为硬失败会使系统在实时使用中过于脆弱。因此，该方法定义了降级模式。

第一种模式是证据缺失。所需的数据源不可用，或已知数据源超出当前观测契约。运行时可能仍然提供一般性程序指导，但不应声称状态已被检查。第二种模式是证据

冲突。例如，一个视觉事实和一个遥测派生的步骤候选可能指向不同的解释。在这种情况下，更严格的权限层级和校验器规则决定响应是被修复、降级还是暂缓。第三种模式是输出无效。模型响应未通过 Schema、目标或证据引用校验，因此运行时回退到确定性或纯文本响应。

这些模式之所以重要，是因为它们使不确定性在日志中以及在适当的用户可见对话中可见。一个无法区分"你没有这样做"和"我无法观察到这个"的教学系统会误导学员。SimTutor 的设计保持这些情况分离。这在 F/A-18C 冷启动中尤其重要，因为某些步骤结合了缓慢变化的模拟器状态、短暂的显示文本以及手动座舱导航。只有当运行时知道自己证据不完整时，它才能提供帮助。

3.11 VR 交互边界

Meta Quest 3 环境影响了运行时设计，尽管本论文主要不是一项 VR 界面研究。在桌面环境中，用户可以更容易地在模拟器、手册、聊天窗口和日志之间切换。在头显中，这种切换成本要高得多。指导必须简短、在空间上有用，并与学员当前动作的时间同步。同时，如果 VR 指导高亮过多目标、使用过时状态或打断已经在完成动作的学员，它可能变得具有侵入性。

因此，运行时将覆盖层指导视为一个受约束的输出通道，而非装饰性 UI。高亮的目标必须来自程序包的 UI 映射。多目标指导是有限的。覆盖层计划需要证据引用。当模型提出过于粗糙或不够扎实的目标时，校验器可以修复它或抑制覆盖层。响应的语言部分仍然可用，但空间指导受到更严格的标准约束，因为它直接塑造学员在座舱中的注意力。

这一边界也解释了为何被试日志很重要。一次成功的 VR 试验不仅是被试到达最后一步。它还是一系列可在事后检查的帮助请求、VLM 调用、修复、高亮和状态转换。没有这些记录，很难判断教学系统有帮助是因为其证据循环起作用，是因为被试已经有经验，还是因为人类观察者非正式地填补了空白。导出的帮助循环产物使这种区分在未来的工作中可以分析。

3.12 日志记录、回放与导出

每个帮助循环和试验级别的事件都被写入可回放和导出的日志。回放之所以重要，是因为实时 VR 会话难以在当下检查。导出管线产生试验摘要、逐步骤编码文件、帮助循环表、动作时间线、质量门以及会话元数据。这些产物同时支持回归测试和被试分析。

回放设计也保护了对结果的解释。一个 benchmark 指标本身不能展示教学系统在

实时试验中的行为。一个被试完成表本身不能展示覆盖层路径是否有效。通过保存证据包、模型输出、校验决策和被试级别的导出，论文可以将 ML 可靠性与用户在 VR 中看到帮助的实际条件联系起来。

3.13 方法边界

运行时方法有一个明确的边界。它不是一个经过认证的飞行训练系统，不是一个通用的座舱自动化系统，也不是学习效果的证明。它是一个研究原型，用于研究基于证据的基础模型解释如何在沉浸式模拟器内部运行。后续章节评估该原型的两个最重要部分：VLM 视觉证据层和形成性 Quest 3 被试。

第四章 方法：视觉事实适配与试点协议

第三章展示了运行时架构，该架构将教学系统的输出置于证据的下游和校验的上游。本章描述剩余的经验证据如何被产生、整理和评估。方法围绕一个实际问题组织：少量经过审核的座舱图像、结构化标签和形成性 VR 会话如何成为机器学习教学系统可审计的证据？

因此，本章将运行时、VLM 数据流水线 and 试点研究视为相互连接的证据协议，而不是实现清单。对于 RQ1，它记录哪些运行时信号可以支撑回放和试点分析。对于 RQ2，它定义截图如何转化为经审核的视觉事实标签、训练行、LoRA 适配器和独立留出基准确。对于 RQ3，它记录形成性 VR 试点协议，并保持描述性声明边界：试点能够说明可行性和交互模式，但不能推断学习收益。

4.1 程序运行时与遥测基础

遥测和程序门控提供了帮助循环所依赖的状态证据。原始 DCS-BIOS 字段被投影到规范化运行时变量上，而不可用来源则单独记录在 `vars_source_missing` 中。这一区分具有方法论意义：已知为 `false` 的值可以支持纠正性指导，而未观测到的值只能支持带不确定性的指导或回退。

随后，每个程序步骤在这些变量上评估前置条件和完成条件门控。门控 DSL 覆盖阈值检查、范围、布尔标志和经过时间条件。缺失值、源缺失值或哨兵值会以诊断原因失败，而不会被静默强制转换；这些原因会与帮助循环上下文一起记录。最近学习者操作则通过清洗后的遥测增量表示：逐变量阈值、去抖窗口和过滤之后，才产生紧凑的、适合提示词使用的摘要。如果模型输出不可用或无效，确定性回退会根据活动步骤、未满足门控、最近操作和证据可用性生成保守提示；除非局部规则识别出唯一有效目标，否则覆盖层指导保持抑制。

4.2 知识基础与来源策略

检索到的程序性知识为生成的帮助提供文本上下文，但它被有意地进行来源控制。本地检索适配器以句子级别索引经过整理的程序和飞机文档，并使用 BM25 [32] 对片段进行排序。一个基础查询由活动步骤、其描述和当前观测构建；排名靠前的片段被纳入帮助循环上下文中。

声明式来源策略将检索限制在允许的文档来源范围内。这防止模型接收到活动程序包之外的程序变体，例如当前配置为机场冷启动时收到航母特定的指令。因此，在本论文方法中，检索并非一个通用文档搜索工具。它是一个受控的证据通道，其范围是程序配置的一部分。


4.3 视觉事实数据流水线

视觉事实流水线是针对 RQ2 的主要方法论。它将 DCS World 座舱截图转化为监督样本，进而转化为一个经过基准测试的视觉事实提取器。流水线设计以可追溯性为目标：一个基准测试错误应能追溯到模型预测、人工审核标签、预标签和原始图像。

图 4.1 将流水线展示为一个循环。留出失败不仅是最终结果；它们还能揭示本体中的弱点并指导后续数据采集。

1. **截图采集。** DCS World 将左侧 DDI、AMPCD 和右侧 DDI 渲染为一幅复合面板图像。相同的复合布局用于数据采集、预标注、训练、基准测试和运行时推理。这在方法中保持输入分布稳定。
2. **VLM 预标注。** 一个大型外部 VLM 为每张图像生成初始标签和证据注释。预标注用作标注辅助手段，而非真实标签。
3. **人工审核。** 预标注样本在 Label Studio [34] 中进行审核。审核者纠正事实状态和证据注释，同时保留与原始图像和预标签的链接。
4. **经审核的 JSONL 导出。** 经审核的导出是下游训练和评估的权威真实标签制品。
5. **双语 SFT 生成。** 每张经审核的图像产生一个英文和一个中文训练数据行，具有相同的图像和事实标签。助手目标为包含视觉事实和简短摘要的结构化 JSON；外部管理字段（如帧标识符、文件路径和置信度字段）被排除在目标之外。
6. **LoRA 适配。** SFT 数据行用于为 VLM 骨干模型训练 LoRA 适配器 [19]。实现使用 PEFT 适配器定义 [27]、TRL 监督微调基础设施 [37] 和用于 4 比特 VLM 训练的 Unsloth 加速 [14]。

Small-data VLM adaptation pipeline



Each benchmark prediction remains traceable to a reviewed label and original cockpit image.

Figure 4.1: VLM 适配流水线。DCS World 复合截图经预标注、人工审核后，转换为双语监督微调数据行，使用 LoRA 适配，在独立留出集上进行评估，并用于推动本体修订。

7. **留出基准测试与修订。**基础模型和 LoRA 配置在独立留出集上进行评估。错误在事实层面进行检查，特别关注完成关键型事实，所产生的失败模式反馈给本体和数据集修订。

该方法有意让 VLM 的任务保持狭窄。模型被训练为以状态 `seen`、`not_seen` 或 `uncertain` 报告视觉事实。它不被训练来判断程序完成状态或产生导师操作。这些决策保留在程序引擎和校验器中。

4.3.1 标注单元与决策边界

标注单元是一幅复合面板截图，配以完整的 13 个事实标签向量。样本并不只标注触发采集的那个事实；本体中的每个事实都被审核。这种全向量标注很重要，因为基准测试随后评估完整的视觉快照。它还可以防止训练数据变成一组孤立的、负面样例定义不清的正例集合。

审核者应用特定于事实的决策边界。页面选项标签与页面本身不是同一回事。BIT 根页面上可见的 FCS-MC 条目不是 FCS-MC 子页面。PBIT GO 状态与最终的 FCS-MC GO 结果不同。没有彩色地图图层的 HSI 符号不满足地图图层事实的要求。INS OK 必须对准块附近清晰可读，而非从经过的程序阶段推断。这些规则被写入基准提示词并反映在本体中，因此模型在训练和评估中使用相同的概念契约。

`uncertain` 标签在截图不支持明确判断时使用。这包括模糊的帧、部分遮挡的显示区域、模糊的文本，或需要时间历史而非单张图像的状态。审核者不被要求猜测模拟器在截图前后可能做了什么。这种纪律使 VLM 任务与运行时边界保持一致：单帧感知报告可见事实，而程序推理在下游进行。

预标注加速了流程，但并不定义真实标签。外部 VLM 的输出被视作标注建议。人工审核可以更改状态、修订证据注释或保留不确定性。最终的经审核 JSONL 而非预标签才是 SFT 和基准评分的来源。这一区别至关重要，否则基准测试将衡量与另一个模型的一致性，而非与经审核视觉事实的一致性。

经审核的标签未做独立双重编码。因此它们应被解释为单人审核的、人工审核过的标签，而非评分者间信度研究。这对于本文报告的组件基准测试是可接受的，因为论文声明是关于适配器在经审核制品集上的领域内可靠性，但对于未来的可靠性研究——特别是针对稀有完成关键型事实——仍是一个局限。

4.4 数据集整理

4.4.1 数据集概览

六个经审核的数据集支撑跨两个本体世代的视觉事实工作。表 4.1 列出了它们的角色和追踪数量。

Table 4.1: 用于视觉事实提取的数据集清单。

运行	数据集	样本数	事实数	语言	角色
Run-001	v1 SFT	180	8	en/zh	v1 训练来源
Run-002	v1 留出	50	8	en	v1 留出
Run-002	v2 新事实留出	50	13	en	v2 留出
Run-003	v2 SFT	220	13	en/zh	v2 训练来源
Run-004	v2 随机留出	100	13	en	v2 留出
Run-005	组成再平衡	122	13	en/zh	v2 训练补充

Run-003 和 Run-005 包含自由文本摘要字段为空的样本（分别为 82 和 25 个样本）。这些样本对视觉事实任务仍然有效，因为每个样本仍包含完整的事实数组。由运行时和基准测试使用的监督目标是结构化事实状态，而非可选的摘要。

4.4.2 数据集质量检查

数据流水线在经审核导出用于训练或基准测试之前应用若干检查。首先，每个样本必须恰好包含预期的事实标识符一次。缺失或重复的事实 ID 会使模型错误是视觉性还是结构性变得不明确。其次，每个事实状态必须是允许的状态之一。第三，图像路径必须能解析为审核中使用的复合面板图像。第四，在将留出指标解释为独立证据之前，需要检查训练集和留出集是否存在精确图像重叠。

质量检查不保证每个标签都是完美的。它们保证数据制品具有进行有意义基准测试所需的结构。这是一个不同但重要的主张。在小数据适配中，少量模糊标签可能产生可见的影响，特别是对于稀有正例事实。因此，论文将错误分析视为数据工作流的一部分。如果留出错误揭示某个事实定义过于接近程序性结论，正确的回应不一定是收集更多数据；而是可能需要修订本体。

Run-005 是数据中心纠正的一个例子。原始的 Run-003 训练来源包含有用的覆盖范围，但若干稀有状态的代表性不足。组成再平衡补充有意增加了对这些状态的曝光。这并不使训练集在统计上代表所有可能的座舱状态，本文也不这样呈现它。其角色是实用性的：让适配器接触到对下游程序证据重要的正例，然后在独立留出集上测试行为。

4.4.3 本体演进：从 8 事实 v1 到 13 事实 v2

第一版本本体包含覆盖复合座舱面板的八个事实。它证明了少量经审核数据集可以改善结构化座舱事实提取，但也暴露了一个表示问题：某些目标将视觉观测与程序性解释混在一起。最明显的案例是 `ins_go`，它要求单帧 VLM 推断 INS 完成状态，而非报告直接可见的证据。

图 4.2 说明了方法论纠正。复合程序性目标被分解为局部可观测的视觉原子，将时间和程序性解释留给导师运行时。

Visual fact ontology evolution




Figure 4.2: 从 8 事实 v1 到 13 事实 v2 的本体演进。复合目标如 `ins_go` 和宽泛的 FCS-MC 完成事实被分解为局部可验证的视觉原子；程序引擎随后将这些观测与遥测、阶段和时序证据结合起来。

当前的 13 事实本体遵循三条设计规则：

1. **分解复合目标。**将 `ins_go` 目标替换为 GRND 对准文本和 INS OK 文本的独立视觉原子。FCS-MC 序列由页面、中间结果、正在测试和最终 GO 事实表示。
2. **将区域与语义分离。**事实名称描述可见状态，而非在标识符中编码显示区域。区域约束是本体元数据的一部分。

3. **保持事实局部可观测。**每个事实应能从复合图像中判断，无需程序历史。程序引擎随后将事实与遥测、步骤绑定和时序信息结合。

这种本体纪律是本论文的核心。它定义了感知和程序推理之间的边界：VLM 报告视觉证据，而运行时判断该证据是否满足程序步骤。

4.4.4 训练配方：Run-003 + Run-005x2

主要的 v2 训练配方将 Run-003 与重复的 Run-005 组成再平衡补充结合。Run-003 贡献 220 张经审核的图像，以双语导出为 440 个 SFT 数据行。Run-005 贡献 122 张经审核的图像，以双语导出为 244 个数据行；此补充被包含两次，产生 488 个数据行。因此最终配方包含 **928 个 SFT 数据行**。

Run-005 针对 Run-003 中代表性不足的正例状态，包括 INS OK 文本、FCS 页面 X 标记和 FCS-MC 子状态事实。重复的补充是一种有意的组成再平衡策略，而非独立的验证集。因此，泛化声明基于外部留出集，而非内部同池评估划分。

4.4.5 留出独立性

两个 13 事实 v2 留出集用于主评估。Run-002 新事实包含来自较早采集会话的 50 张图像，在 13 事实本体下重新标注。Run-004 随机包含 100 张随机采样的座舱状态截图。本地重叠检查报告任一留出集与 Run-003 + Run-005 训练并集之间零精确重叠。

较早的 Run-001 评估线被区别对待。因为它与训练数据池重叠，它可作为受污染的开发基准用于检查模式学习和历史本体行为，但它不被用作 v2 泛化的独立证据。

4.5 LoRA 微调配置

4.5.1 骨干模型与比较策略

主要适配线使用 Qwen/Qwen3.5-9B-Base 配合 Run-003 + Run-005x2 配方。引入两个补充骨干模型来测试相同的数据配方在规模、版本和家族变化下是否仍具有意义：Qwen/Qwen3.6-27B 和 google/gemma-4-31B [11, 12]。这些字符串是本地基准制品和推理服务设置中使用的模型标识符；引文提供了模型家族的上下文，而非声称每个本地端点细节都由公开报告描述。在本论文中，"本地部署候选"指的是在成功的基模型服务、LoRA 加载和基准执行之后，作为项目本地服务路径的候选。它不意味着一个经过普遍验证的产品模型。第 六 章报告数值结果。

比较在可能情况下保持主要因素不变：本体、训练配方、基准提示词、留出集、生成温度、输出模式和指标计算。特定于骨干模型的差异仍然存在，因此被明确报告。Qwen

家族运行对视觉和语言模块应用 LoRA；Gemma 运行使用全线性 LoRA 配置，视觉层不单独微调。完整设置见附录 九，表 9.1。

4.5.2 训练栈与超参数

所有骨干模型运行使用 4 比特加载，LoRA 秩 $r = 16$ ， $\alpha = 16$ ，dropout 0.0，四个 epoch，学习率 2×10^{-4} ，有效批次大小 4，最大序列长度 4096，种子 3407，预热比例 0.1，权重衰减 0.01。适配器权重与基模型分开保存。

Epoch 数和 LoRA 秩是为小数据领域适配选择的。使用 928 个 SFT 数据行，适配器必须同时学习固定的 JSON 模式和座舱事实的视觉边界。过少的 epoch 可能无法可靠地教授这些边界，而过多的训练则有记忆采集会话的风险。秩 16 提供适度的适配容量，同时不会将适配器变为高容量任务特定模型。

4.5.3 双语 SFT 与组成再平衡

双语 SFT 策略为每张经审核图像创建两个指令变体：一个英文和一个中文。图像和事实标签保持相同。这增加了指令格式覆盖，而不需要额外的图像标注。它不替代对新座舱状态或困难负例的需求。

组成再平衡通过 Run-005 处理。由于稀有正例事实对下游程序推理特别重要，训练配方通过添加目标采集并重复 Run-005 双语数据行来增加其曝光度。因此方法将两个问题分开：适配器能否从再平衡后的训练配方中学习本体，以及学到的提取器能否泛化到独立留出集。

4.5.4 训练目标构建

SFT 目标有意小于运行时观测对象。它包含简短摘要字段和事实对象数组，其中包含 `fact_id`、`state` 和 `evidence_note`。它排除了帧标识符、文件路径、置信度值、粘性/过期元数据和程序建议。这些被排除的字段是运行时管理元数据，而非视觉标签。将其纳入会教会模型生成它无法从图像中观测到的数据，并使输出更难验证。

目标也避免要求超出简短证据注释之外的解释性文字。冗长的自由形式解释会使 SFT 目标不够聚焦，并引入额外的评估模糊性。下游语言模型可以随后将事实转化为面向用户的教学语言。VLM 适配器被训练来提供这些语言可能引用的视觉事实。

这种分离使训练配方与系统架构保持一致。VLM 不因听起来有帮助、预测下一步或解释程序而获得奖励。它因返回完整的、可解析的、与本体对齐的事实向量而获得奖励。这就是为什么本论文中的基准增益被解释为感知层增益，而非整个导师系统在教学上更优越的证据。

4.6 基准测试协议

4.6.1 指标

基准测试在样本和事实两个层面上将模型预测与人工审核的真实标签进行比较。指标的选择反映了下游运行时风险：

- `json_valid_rate`: 输出可解析 JSON 的样本比例。
- `schema_valid_rate`: JSON 恰好包含所需事实标识符一次且仅使用有效状态的样本比例。
- `fact_accuracy`: 所有事实和样本上的三分类准确率。
- `macro_f1`: 三个状态上的宏平均 F1，在事实上取平均。
- `seen_f1`: 正例 `seen` 类别的 F1，在事实上取平均。这很重要，因为遗漏或幻觉的可见状态会改变程序证据。
- `sample_exact_match`: 所有 13 个事实与经审核标签完全匹配的样本比例。
- `critical_false_positive_count`: 被预测为 `seen` 而经审核标签为 `not_seen` 或 `uncertain` 的完成关键型事实的计数。

关键假阳性被单独追踪，因为它们是导师系统最危险的视觉错误。完成关键型事实的假阳性可能使程序引擎认为某个显示状态已被观测到，而实际上并未。

4.6.2 Base vs. LoRA 比较

基础模型和 LoRA 配置接收相同的提示词、图像、生成参数和输出模式。解码使用温度 0.0，最大新 token 数 1024，种子 3407。预测写入 JSONL，经解析、规范化和评分，无后处理过滤。比较制品报告 LoRA 减去 Base 的差值，第 六 章解释这些差值。

4.6.3 基准测试类别

基准测试运行按证据状态分类。受污染的开发集来自与训练相同的数据池，仅用于回归和历史解释。留出的新会话基准使用具有零精确训练重叠的独立采集。这一区别决定了从某个指标可以做出的声明的强度。

4.6.4 基准测试制品

每次基准测试运行产生一个标准目录，包含每个模型的指标、逐样本预测、错误 JSONL 文件、逐事实评分 CSV、比较摘要、可读报告和图表。这些制品构成第 六 章技术结果的证据链。

4.6.5 错误审查协议

基准测试后进行定性错误审查。审查首先关注关键假阳性，因为这些错误最有可能为程序门控产生不安全的证据。然后检查视觉优先事实的假阴性，因为重复的假阴性可能使导师要求不必要的检查或未能识别进展。最后检查模式和精确匹配失败，以识别剩余问题是格式问题、视觉模糊性还是事实定义不匹配。

这种审查有意识地与运行时使用场景关联。聚合准确率和 F_1 不足以刻画风险，因为导师系统会以不对称方式消费错误。一个幻觉的 FCS-MC 最终 GO 结果比对一个可以重新检查的页面做出保守的 `not_seen` 预测更严重。一个模式无效的输出在视觉上不太有趣，但在操作上更重要，因为它会触发回退。因此基准测试协议将数值指标连接到第 三 章描述的验证和降级路径。

4.7 人类被试试点方法论

进行了一项小规模形成性 VR 试点研究，以收集关于导师系统在 F/A-18C 冷启动任务中实际使用的描述性证据。该试点研究不是统计功效控制实验。其目的是在逼真的 VR 环境中运行系统，检查交互日志，并识别程序性错误模式以供后续研究设计。

4.7.1 伦理、知情同意与数据保护

该试点研究是作为形成性、非临床的程序训练研究进行的。研究操作协议要求在 VR 会话之前进行欢迎和知情同意步骤。参与者被告知该研究评估的是训练系统而非个人能力，他们可以随时停止，并且在出现 VR 不适时可以暂停或终止会话。同一协议指示实验者除技术问题外不提供程序步骤提示。

论文仅以化名标识符 P01-P09 报告参与者。用于分析的导出制品包含模拟器遥测、运行时事件、导师交互、步骤编码、问卷字段和简短评论；姓名、电子邮件地址和学生标识符不在论文中报告。问卷和评论证据以描述性方式报告，在适当时聚合，并在正文中进行匿名化或改述。本论文不声称拥有任何正式的外部伦理审批标识符；因此该研究保守地报告为本地形成性试点研究，不做推断性的人类被试效能声明。

招募和条件分配按本地硕士论文试点的便利排班处理，而不是随机抽样。保留的分析包按化名参与者目录组织；原始参与者产物不作为公开数据集发布，论文也不发布头戴设备视频或可识别个人身份的招募记录。非公开原始材料被视为论文准备和导师审阅所需的项目内部材料。参与者可以在 VR 会话中停止；只要数据对作者仍可识别，退出或删除请求即可处理。论文不报告金钱补偿，也不使用任何与补偿相关的分析。

4.7.2 参与者与条件

九名参与者 (P01–P09) 各完成一次试验。该研究使用基于排班可用性的非随机分配的被试间设计：

有导师 (n=4)。 P04、P05、P08 和 P09 接收到覆盖层高亮、结构化帮助文本、基于遥测的步骤推断，以及适用情况下的 VLM 视觉事实支持。

无导师 (n=5)。 P01、P02、P03、P06 和 P07 未收到导师协助。遥测仍被记录以用于离线步骤推断和错误编码。

参与者经验概况在附录 九，表 9.5 中报告。因为分配不是随机的且样本量小，条件比较仅为描述性的。

4.7.3 任务与设备

所有试验使用 DCS World 中的 33 步 F/A-18C 冷启动程序，在 Meta Quest 3 上通过 Quest Link 进行。复合座舱面板被镜像用于实验者观察。导师条件试验使用实时运行时，通过 OpenAI 兼容端点进行远程模型推理。当参与者完成程序或因无法推进而自愿停止时，试验结束。

4.7.4 数据来源与编码

导出流水线产生每个试验的摘要、逐步骤编码文件、导师试验的帮助循环日志、操作时间线、质量门控元数据和会话摘要。试验后表单记录了参与者体验、试验前信心、原始 NASA-TLX 工作负荷维度 [15]、适用条件下的导师评分、通用可用性/用户评分和自由文本评论。

步骤错误以五个类别进行编码：遗漏 (OM，一个必需操作未被完成)、多余操作 (CO，执行了不必要或错误的操作)、顺序错误 (OR，操作以错误顺序执行)、提示/辅助错误 (PA，与导师或实验设置的交互影响了步骤) 和状态违反 (SV，飞机状态与预

期条件相矛盾)。自动编码输出使用遥测、帮助循环日志和操作时间线进行人工审核；人工编码的列是报告试点结果的权威来源。

编码明确区分未被确认为完成与编码为遗漏。这一区分对无导师试验尤其重要，因为被动记录模式没有运行导师条件中使用的 VLM 页面检查。因此，一个纯视觉步骤可能在 Completed 列中仍未确认，即使遥测或操作时间线证据足以避免将其评分为参与者遗漏。结果章将确认步骤数和人工错误计数作为两个独立的描述性指标报告。

4.7.5 问卷与评论工具

试验后表单记录原始 NASA-TLX 工作负荷维度，而非加权 NASA-TLX。论文报告原始平均值，因为形成性试点研究并非设计用于估计心理测量工作负荷效应。表单还记录了试验前信心、在导师可用条件下的特定条件导师评分、通用可用性/ 用户评分和简短开放评论。评分值保留在其记录的尺度上，不归一化为单一综合效能分数。

评论被谨慎使用。它们不被视为具有评分者间信度的编码定性主题。相反，它们为观测到的日志和问卷模式提供背景。例如，关于小型固定检查单文本的评论有助于解释为什么无导师参与者在 VR 中即使程序列表技术上可用的情况下仍可能遇到困难。关于 AI 识别学习者卡在何处的评论有助于解释为什么导师条件下的参与者即使辅助耦合错误仍然存在，也可能认为系统是有用的。

这种工具设计符合试点研究的形成性地位。问卷和评论可以揭示可用性问题、信任信号和认知摩擦，这些应塑造下一次研究。它们无法建立工作负荷、信任或学习的因果变化。这一边界在结果章节中通过排除 P02 不匹配的问卷、以人工任务编码报告 P08，以及在元数据更正后将 P09 视为独立参与者而得以维持。

4.7.6 数据质量说明

表 4.2 记录了已知试点数据质量问题的最终权威规则。目的不是隐藏原始制品冲突，而是在结果章节之前使分析规则可见。

P09 在试验元数据记录的导出更正后被视为独立参与者。

4.7.7 分析方法

试点分析报告逐参与者结果和条件层面的描述性摘要。不进行零假设显著性检验。观测到的持续时间被记录，但不被解释为完成时间比较，因为不完整的无导师试验在不同的停止点结束。问卷值仅作为原始描述性分数报告。分析重点关注完成状态、人工错误类别、导师交互模式（如帮助请求、VLM 调用、覆盖层操作和回退事件），以及澄清交互摩擦的简短匿名评论。

Table 4.2: 试点数据质量问题与最终分析权威。

个案	数据质量问题	最终分析规则	报告用途
P08	自动 trial_summary.csv 报 告了不完整的进度。	手动遥测审查和经审核的 step_coding.csv 列是 完成和错误计数的权威来 源。	计为 33/33 完成，零人工 程序错误。
P02	P02 下的问卷文件包含内 部参与者 ID 不匹配。	任务日志和步骤编码被保 留；从问卷派生的信心、 TLX、可用性/信任和评 论被排除。	列入任务/错误表；从问 卷摘要中排除。
P07	无导师表单包含特定于导 师的数值字段，尽管有条 件/NA 标志。	除非参与者在导师条件下 且 NA 标志为 false，否则 忽略特定于导师的字段。	用户评分保留；导师评分 报告为 N/A。
P04	质量门控报告非阻塞链接 警告。	任务指标保留；受影响的 链接字段不被过度解释。	列入试验概览，附来源说 明。

4.8 小结

方法论建立了论文其余部分使用的证据链。遥测和检索提供受控的运行时上下文。视觉事实流水线为 RQ2 产生了一个经审核和基准测试的感知层。13 事实本体将感知与程序推理分离。LoRA 协议使用匹配的数据和留出集来评估小数据适配，而不依赖受污染的开发集。试点协议为 RQ3 提供形成性 VR 证据，同时将其声明保持在描述性层面。这些方法共同使后续结果可审计，同时不过度声称现有证据能够证明什么。

第五章 可复现性与产物溯源

前两章方法章节定义了基于证据的辅导循环、视觉事实适配协议，以及形成性的 Quest 3 试点。本章将这些方法连接到支撑结果主张的产物，定义产物类别、权限规则和可复现性限制。只有当工程细节决定主张溯源、约束模型权限，或定义已报告结果如何被检查时，才将其写入正文。

5.1 产物与主张边界

研究产物将程序性知识、运行时逻辑、外部系统和导出证据分开。程序包存储 F/A-18C Lot 20 冷启动步骤、门控定义、遥测绑定、UI 目标和视觉事实绑定。运行时加载这些声明，并产生证据包、模型提示词、验证决策、叠加层动作和事件日志。DCS World、DCS-BIOS、Quest 3 显示路径、模型服务器和截图采集均被视为外部系统。

这一边界避免不同主张之间发生证据转移。模型生成文本本身不被视为研究观察。它只有在通过相应的 schema、映射、治理套件、基准测试或人工审查步骤之后，才成为可用证据。因此，论文报告三类产物：

- **声明式配置：**程序步骤、遥测映射、视觉事实本体、UI 目标、来源策略规则和回放套件定义。
- **生成证据：**JSONL 事件日志、试验摘要、帮助循环表、基准测试预测、基准测试指标和质量门控报告。
- **人工审查证据：**经审查的视觉标签、人工步骤编码覆盖、按排除规则处理后的问卷记录，以及匿名化自由文本评论。

每个研究问题使用不同的证据单位。RQ1 以帮助循环为单位检查：触发上下文、可用证据、模型响应、验证决策和叠加层结果。RQ2 以图像和事实为单位检查：经审查的标签向量、预测、解析状态和逐事实错误。RQ3 以参与者和步骤为单位检查：试验摘要、人工编码、问卷行和评论。VLM 基准测试数字不被用作参与者证据；参与者完成记录也不被用作每个模型响应都正确的证明。

5.2 RQ 层级溯源

RQ1: 辅导循环可审计性。 运行时写入追加式事件和分析导出，而不仅仅渲染瞬时头戴式指导。一次帮助循环记录触发上下文、遥测快照、活跃步骤、门控诊断、检索片段、可用视觉事实、提示词构造元数据、响应状态、验证结果、叠加层执行状态以及回退或修复元数据。相同格式支持回放：录制的 DCS-BIOS 数据流可以通过实时运行时所用的同一遥测映射、程序门控、来源策略和治理套件契约。这是 RQ1 关于导师可审计性的产物基础。

RQ2: 视觉事实基准测试可追溯性。 第六章报告的所有 VLM 指标均复制自本地基准测试产物，例如 `metrics_base.json`、`metrics_lora.json`、`benchmark_summary.json` 和逐事实得分文件。正文中选择的基准测试图来自同一报告资产。证据链为：座舱图像采集、人工标签审查、双语 SFT 行生成、LoRA 训练，以及在固定提示词、schema、生成设置和指标计算下进行的独立留存集基准测试。训练 runtime 和 loss 值被视为训练报告层级溯源；结果主张依赖的是基准测试 JSON 和经审查标签产物。

RQ3: 试点数据权限。 每个参与者试验目录包含事件日志、试验摘要、步骤编码、动作时间线、帮助循环表、会话元数据和质量门控报告。试后表单提供经验、信心、NASA-TLX 维度、适用条件下的导师专项评分、总体可用性/信任评分和自由文本评论。分析使用三条权限规则：当自动重建不一致时，P08 使用人工步骤编码；P02 保留任务日志指标，但由于问卷元数据存在内部参与者 ID 不匹配，排除问卷衍生值；P09 在元数据记录的参与者更正后作为独立参与者分析。

这些溯源规则使试点主张保持有界。试点可以描述这个小型形成性样本中的观察到的完成情况、编码错误、工作负荷评分、信任/可用性评分、评论和导师交互次数。它不能支持统计显著性、因果学习效应、保持、迁移、工作负荷降低或更快完成等主张。

5.3 可复现性限制

代码仓库支持本地检查论文、导出分析表、回放夹具、基准测试摘要和选定图表。完整实验重跑需要外部状态：DCS World、F/A-18C 模块、DCS-BIOS 集成、Quest 3 设置、模型服务访问、VLM 适配所需 GPU 资源，以及形成性参与者会话条件。因此，本论文区分产物可复现性与完整实验重演可复现性。前者是本文提出的主张：已报告结果可追溯到存储产物，并可进行内部一致性检查。后者需要重建仿真器、硬件、模型和参与者语境。

这一区分也解释了原始提案的角色。提案有助于理解 VR 动机场景和后续范围演

变，但它并不作为最终系统结果的证据。结果章节中的主张绑定到已实现的程序包、运行时导出、基准测试 JSON、经审查标签和试点产物，而不是绑定到拟议设计本身。

第六章 结果

本章按研究问题的顺序报告结果：RQ1 对应基于证据的教学运行时，RQ2 对应 VLM 适配，RQ3 对应形成性 Quest 3 先导实验。三条证据线具有不同的声明强度。回放、约束层和导出产物支撑 RQ1 的技术可审计性声明。留出基准测试支撑 RQ2 的组件级机器学习声明。先导实验支撑关于实时使用、任务完成情况、错误、工作负荷评分、可用性/信任评分以及评论的描述性观察，用于回答 RQ3。

图 6.1 总结了证据流。重要之处在于，三条证据流不可互换。VLM 基准测试不是学习成果；回放夹具不是参与者结果；形成性先导实验不是有统计效力的对照实验。

Evaluation data flow across research questions




Figure 6.1: 各研究问题的评估与数据流。回放与约束层产物支撑 RQ1，VLM 基准测试产物支撑 RQ2，Quest 3 先导实验导出数据支撑 RQ3 的描述性发现。

6.1 RQ1：基于证据的教学运行时

RQ1 询问一个基于证据的基础模型教学运行时如何整合遥测、检索、视觉事实与验证。其成果是一个可运行的运行时，其帮助循环决策可从存储的产物中重建。证据是技术性而非教学性的：配置文件定义了哪些证据是可接受的，回放和夹具对已知的故障模式进行演练，实时先导实验导出数据表明在头显使用期间运行了相同的日志路径。

6.1.1 运行时就绪性总结

表 6.1总结了 RQ1 的就绪性证据。它并不声称未来的每一次帮助响应都将是正确的。它表明当前运行时在模型生成与学习者指导之间设置了显式检查。

Table 6.1: RQ1 运行时就绪性证据，以产物覆盖率的形式呈现。

证据组	覆盖率	示例不变式	观察结果	支撑的声明
程序包	33 步	步骤顺序、门控规则、UI 目标和源策略是显式编写的,而非由模型生成。	存在	预先编写的过程先验知识。
遥测接地	运行时变量映射	来源缺失的证据与观察到的假值保持区分。	存在	状态感知的证据包。
视觉绑定	S08、S15、S18、S19	视觉事实可以支撑依赖显示屏的步骤,而不决定过程完成与否。	存在	有边界的 VLM 权限。
响应 Schema 与覆盖层约束层	源自 Pack 的 Schema 和 UI 允许列表	未知或范围过宽的目标在覆盖层执行前被修复、降级或拒绝。	存在	有边界的动作面。
回放用例	5 个用例	录制的 DCS-BIOS 流和视觉侧车在实时 VR 之外使用相同的程序包、源策略和验证路径。	通过, 作为回放覆盖率	可复现的接地检查。
实时夹具	20 个条目	过时的 VLM 证据不得满足非视觉步骤;正在移动的控制件必须按稳定状态处理。	通过, 作为夹具覆盖率	针对接地故障的回归检查。
先导实验导出	9 次试验; 4 次导师试验含帮助循环日志	在实际使用后产出了试验摘要、步骤编码、动作时间线、质量门和帮助循环表。	通过, P04 有警告	可审计的实时导出。

6.1.2 回放与约束层结果

回放套件包含五个用例，覆盖早期电源、发动机与发电机状态、FCS 复位/BIT 交互以及 INS 模式证据。标记为视觉可用的用例包含侧车帧文件，以便无需实时模拟器

即可演练视觉依赖的逻辑。这些用例确认了录制的 DCS-BIOS 流可以通过与实时教学相同的过程包、遥测映射、源策略、UI 映射和验证路径来处理。

实时夹具回归矩阵包含 20 个条目。这些条目覆盖五类就绪性风险：步骤已完成时的推进、错误目标的预防与修复、过时的 VLM 证据泄露到非视觉步骤中、对移动或稳定中控件的等待行为，以及交互语义（如鼠标滚轮控件）的保持。该夹具证据支撑了 RQ1 的可审计性声明：系统对特定的证据接地故障具有可执行的检查。它并不证明教育有效性。

6.1.3 实时导出结果

全部九次参与者试验均产出了试验摘要、步骤编码、动作时间线、原始事件副本、会话元数据和质量门报告。四次导师条件下的试验还产出了帮助循环表。没有参与者的导出数据出现阻塞性质量门故障。一次试验（P04）保留了元数据警告，涉及缺失或不完整的链接字段；这些警告限制了这些字段的可追溯性，但并不改变下文报告的手动审核任务指标。

在四次导师条件下的试验中，运行时记录了 77 个帮助循环、23 次 VLM 调用、82 次覆盖层执行、零次覆盖层拒绝以及 21 次回退或修复事件。零覆盖层拒绝计数应谨慎解读：这意味着最终的覆盖层动作通过了配置的允许列表和证据检查，而并非表示模型提案始终直接正确。21 次修复/回退事件表明验证层在实际使用中处于活跃状态。

6.1.4 示例证据路径

RQ1 的结果可以被解读为一条证据路径，而非单一的系统状态。一个典型的视觉优先帮助循环从遥测推导的过程上下文开始：运行时识别当前的候选步骤，评估前置条件和完成门控，并将不可用来源与假值分开记录。如果活跃步骤需要显示屏证据，运行时请求或选择一个复合面板帧并获取结构化视觉事实。检索随后添加受源控制的过程上下文。只有经过这些步骤之后，LLM 才会收到提示词。

模型响应并不会立即展示。JSON 对象首先被解析，根据源自 Pack 的 Schema 进行检查，映射到允许的响应字段，并根据 UI 目标绑定和证据引用进行验证。如果模型提出的目标范围过宽，约束层可以将其修复为更具体的目标。如果证据缺失，覆盖层可以被抑制，或者响应可以降级为纯文本指导。事件日志保留了遥测快照、视觉事实快照、提示词元数据、原始模型输出、映射决策、约束层决策和覆盖层结果。

这个例子之所以重要，是因为它澄清了 RQ1 显示了什么和没有显示什么。运行时结果并不是“模型给出了好的答案”。结果是，一个帮助循环可以被分解为证据生产、模型生成、验证、修复和导出。这种分解是技术基础，之后的有对照研究才能询问教学系统是否改善了学习、信任、工作负荷或迁移。

6.2 RQ2: 面向座舱视觉事实的 VLM 适配

RQ2 询问小数据 LoRA 适配的 VLM 是否能改善可靠的座舱视觉事实提取。主要结果线是使用 Run-003 + Run-005×2 配方训练的 Qwen3.5-9B。Qwen3.6-27B 作为同一配方下的更大规模本地推理/部署候选模型报告，Gemma-4-31B 作为对比基座模型报告。本节中的所有指标均从基准测试 JSON 产物中复制，并在独立的 13 事实留出集上计算。

6.2.1 数据集与训练总结

v2 训练配方将 Run-003 (220 张审核图像) 与 Run-005 (122 张审核图像，重复两次作为组合再平衡补充) 合并。双语导出产生 928 行监督微调数据。两个主要留出集为 Run-002 newfacts (50 张图像) 和 Run-004 random (100 张图像)，均在 13 事实本体下评分，与训练并集之间精确重叠为零。

Table 6.2: 所报告 VLM 结果的视觉事实数据集清单。

来源	Run	事实数	图像数	角色
v1 训练来源	Run-001	8	180	历史 8 事实训练来源
v1 留出集	Run-002	8	50	历史 8 事实留出集
v2 newfacts 留出集	Run-002	13	50	主要留出集
v2 训练来源	Run-003	13	220	主要 13 事实训练来源
v2 组合再平衡	Run-005	13	122	再平衡补充，使用两次
v2 random 留出集	Run-004	13	100	主要留出集

6.2.2 Qwen3.5 主要结果

表 6.3 报告了 Qwen3.5 基座模型对比 LoRA 的主要结果。适配后的模型在 Run-004 上改善了 JSON/Schema 可靠性，在两个留出集上将事实准确率提升至约 0.99，并将关键假阳性从 Run-002 上的 11 降至 4，从 Run-004 上的 70 降至 8。

表 6.4 以计数形式给出同样的结果。这一点很重要，因为留出集规模较小：Run-002 包含 50 张图像，即 650 个事实判断；Run-004 包含 100 张图像，即 1,300 个事实判断。LoRA 行在 Run-002 上做出 645/650 个正确的事实状态判断，在 Run-004 上做出 1,291/1,300 个正确判断。精确匹配的改进也体现在样本计数上：适配后，44/50 和 92/100 的完整视觉快照完全正确。残留的关键假阳性仍然集中在类完成事实上。

这些计数应被解读为领域内的组件证据，而非对所有座舱状态的统计估计。未报告置信区间或显著性检验，因为本论文并不基于这些小规模留出集做出推断性泛化声

Table 6.3: 13 事实主要结果：Qwen3.5-9B 基座对比 LoRA 在两个留出集上的表现。

指标	Run-002 newfacts (50)			Run-004 random (100)		
	Base	LoRA	Δ	Base	LoRA	Δ
JSON valid	1.0000	1.0000	0.0000	0.9600	1.0000	+0.0400
Schema valid	1.0000	1.0000	0.0000	0.9600	1.0000	+0.0400
Fact accuracy	0.8677	0.9908	+0.1231	0.8038	0.9931	+0.1893
Macro F_1	0.4513	0.6515	+0.2002	0.4393	0.6100	+0.1707
Seen F_1	0.5022	0.9648	+0.4626	0.5659	0.9159	+0.3500
Exact match	0.1000	0.8800	+0.7800	0.0300	0.9200	+0.8900
Critical FP	11	4	-7	70	8	-62

Table 6.4: Qwen3.5 主要结果的计数解读。

留出集	事实数	Base 正确数	LoRA 正确数	LoRA 精确匹配	LoRA 残留关键 FP
Run-002 newfacts	650	564	645	44/50	共 4 个： FCS-MC final GO 1, INS GRND text 1, INS OK text 2
Run-004 random	1,300	1,045	1,291	92/100	共 8 个： FCS-MC final GO 8

明。标签经过人工审核但未经独立双重编码，因此罕见的完成关键事实仍然是未来标签审计和数据收集的最重要目标。

图 6.2 补充了正文选取的训练报告图。第一幅图可视化了 Run-002 的准确率提升；第二幅图突出了为什么关键假阳性需要与 Run-004 上的总体准确率分开追踪。




Figure 6.2: 选自 VLM 训练报告的 Qwen3.5 基准测试图。

实用的解读并非 VLM 可以运行过程。适配器使视觉事实通道作为一种证据来源变得更加可用。类完成事实仍然是主要的残留风险，仍必须由过程引擎、遥测、时间上下文和约束层约束在下游进行检查。

6.2.3 主要结果的指标解读

当各项指标联合解读时，Qwen3.5 的结果最为有力。JSON 和 Schema 有效性表明模型是否能够参与运行时契约。在 Run-004 上，基座模型在四个样本上未能满足该契约，而 LoRA 适配器对所有样本返回了有效且符合 Schema 的 JSON 对象。这一点很重要，因为运行时拒绝和回退是由格式和 Schema 失败触发的，发生在视觉正确性被考虑之前。

事实准确率显示了广泛的改进，但它低估了已见状态行为的重要性。教学过程中最重要的视觉事实通常是正面线索：某个页面可见、某个状态文本已出现、或者可以读取到最终的 GO 结果。因此 Seen F_1 捕捉了适配器是否更好地识别可见线索而同时不过多地产生幻觉。在 Run-002 上从 0.5022 提升至 0.9648，在 Run-004 上从 0.5659 提升至 0.9159，这是适配器学会了运行时所需的正面视觉状态的最直接证据。

样本精确匹配提供了另一种视角。一个帮助循环可以携带完整的视觉快照，因此一个错误的事实仍可能产生误导性的上下文。Qwen3.5 适配器将 Run-002 上的精确匹配从 0.10 提升至 0.88，将 Run-004 上的精确匹配从 0.03 提升至 0.92。这表明适配后的模型不仅仅改进了少数容易的事实而大多数快照仍然不一致。关键假阳性的减少是最终的面向安全的检查：适配器减少了最可能使下游教学系统高估完成线索的错误。

6.2.4 Qwen3.6 与 Gemma 的比较

表 6.5 报告了匹配的补充基座模型结果。Qwen3.6-27B 在这些留出集上的基座模型强于 Qwen3.5，尤其是在 Run-004 上，且在 LoRA 适配后仍然是本地推理/部署的候选模型。然而，Qwen3.6 LoRA 在此本地基准测试的主要指标上并未超越 Qwen3.5 LoRA。Gemma-4-31B 在同一配方下有所改进，但其适配后的精确匹配和 seen- F_1 值仍低于 Qwen 适配器，且具有不同的关键假阳性分布。

Table 6.5: 在匹配的 Run-003 + Run-005×2 配方下的补充基座模型比较。


骨干模型	Model	Run-002 newfacts				Run-004 random			
		Acc.	Seen F_1	Exact	Crit. FP	Acc.	Seen F_1	Exact	Crit. FP
Qwen3.5-9B	Base	0.8677	0.5022	0.1000	11	0.8038	0.5659	0.0300	70
Qwen3.5-9B	LoRA	0.9908	0.9648	0.8800	4	0.9931	0.9159	0.9200	8
Qwen3.6-27B	Base	0.9108	0.6712	0.2600	1	0.9769	0.8211	0.7000	7
Qwen3.6-27B	LoRA	0.9877	0.9479	0.8600	3	0.9892	0.9147	0.8600	7
Gemma-4-31B	Base	0.8169	0.5128	0.0400	16	0.8146	0.6332	0.1200	47
Gemma-4-31B	LoRA	0.9492	0.8123	0.4400	0	0.9715	0.7959	0.7400	13

表 6.6 在设计层面解释这一比较。该表之所以必要，是因为相关问题不是哪个骨干模型最大或最新，而是哪条模型线能为导师的下游使用提供风险更合适的证据通道。

Table 6.6: Qwen3.5、Qwen3.6 与 Gemma 匹配比较的解释。

问题	观察结果	解释
Qwen3.5 基础模型 vs. Qwen3.6 基础模型	Qwen3.6 基础模型更强，尤其是在 Run-004 上。	更强的骨干模型在适配前就可能已经编码了有用的座舱显示行为。
Qwen3.5 LoRA vs. Qwen3.6 LoRA	Qwen3.5 LoRA 在当前适配后的事实准确率和完全匹配指标上仍略强。	最强基础模型并不自动成为本地配方下最强的适配证据通道。
Gemma 使用同一配方	Gemma 显著改善，但完全匹配低于 Qwen 适配器，并在部分关键假阳性上更保守。	不同骨干模型暴露不同错误代价结构；较低聚合性能仍可能为风险分析提供信息。
设计结论	没有一条已评估模型线在所有下游关切上都占优。	模型选择应取决于下游风险，而不是只看排行榜排名。

该比较支持一个保守的结论。数据与本体配方并不绑定于单一评估的基座模型，但部署选择是模型特定的。Qwen3.5 仍然是论文的主要结果，因为它在当前留出集中给出了最佳的适配准确率/精确匹配组合。Qwen3.6 作为本地推理/部署候选模型具有吸引力，因为其基座基线已经更强，而 Gemma 提供了关于不同错误风格的有用对比证据。



(a) Qwen3.6 Run-002 总体准确率。

(b) Gemma Run-002 总体准确率。

Figure 6.3: 选自 VLM 训练报告的补充基座模型基准测试图。

6.2.5 模型特定解读

Qwen3.6 的结果之所以有用，是因为它区分了基座模型强度与 LoRA 增益。其基座模型在两个留出集上已经远强于 Qwen3.5 基座，尤其是在 Run-004 上，适配前的事实准确率即达到 0.9769，精确匹配达到 0.70。LoRA 适配器仍然改善了 seen F_1 和精确匹配，但相对增益较小，因为基座基线已经更接近任务要求。因此，Qwen3.6 被视为本地部署候选，而非论文的主要结果。它很强，但并不改变主要的方法论结论——小数据适配加上良好的本体可以使 VLM 成为一个有边界的感知组件。

Gemma 展示了相反的模式。其基座基线弱于 Qwen3.6 基座，在广泛准确率上接近 Qwen3.5 基座，但适配器将 Run-002 上的关键假阳性降至零。同时，其精确匹配和 seen F_1 仍低于 Qwen 适配器。这表明在本地数据上的适配行为更为保守或不完整：在一个留出集中更少的关键幻觉，但对正面状态的识别不够完整。对于教学系统而言，这种取舍并非自动地更差或更好。保守的模型对于某些显示屏线索可能更安全，但也可能迫使更多的重复检查或回退指导。

因此，匹配的比较支撑的是设计结论，而非排行榜结论。基座模型的选择应考虑到下游错误的代价。如果聚合准确率略低的模型能避免安全敏感事实的关键假阳性，则可能是可以接受的。精确匹配较高的模型如果其残留错误集中在完成线索周围，可能仍需要约束层约束。论文将 Qwen3.5 作为主线，因为它在这些基准测试中具有最佳的适配平衡，同时记录 Qwen3.6 和 Gemma 以使模型选择的边界可见。

6.2.6 错误模式

Qwen3.5 基座模型的主要失败模式是罕见状态幻觉。在 Run-004 中，FCS-MC 中间结果事实仅在 100 个样本中的 7 个中出现，但基座模型在许多额外样本中将其预测为可见。LoRA 适配消除了这种弥散幻觉模式的大部分。剩余的适配后错误更少且更

集中在类完成显示屏信号周围，这正是运行时谨慎对待的事实。

这种模式解释了为什么 13 事实本体很重要。页面存在事实比过程完成状态更容易学习。将复合目标分解为局部可观察的视觉原子，为模型提供了更好的监督任务，并为运行时提供了更安全的证据边界。

残留错误模式对未来数据收集也提供了信息。如果额外的随机截图主要是重复已有的简单页面存在状态，则不一定能解决最困难的情况。缺失的数据是有针对性的困难负样本和时间上相邻的状态：页面存在但最终状态尚不可见的帧、中间和最终 BIT 状态看起来相似的帧，以及显示文本较小或短暂的帧。这些示例比通用截图更有价值，因为它们直接攻击剩余的关键假阳性风险。

因此，基准测试充当了本体审计的角色。当一个事实对适配器来说很容易且在不同留出集上稳定时，它很可能是一个良好的局部视觉命题。当一个事实在适配后仍然容易出错时，问题可能在于数据不足、视觉模糊性或事实定义仍嵌入了过多的过程推理。论文将这些情况视为对表征的反馈，而不仅仅是模型的不足。

6.3 RQ3：形成性 Quest 3 先导实验

RQ3 询问一个形成性的、非随机的 Quest 3 先导实验能提供哪些描述性证据，涉及任务完成情况、过程错误、工作负荷、信任/可用性、评论以及可信任 AI 协作者的边界。九名参与者各完成一次试验：四人使用导师辅助，五人不使用导师辅助。该先导实验仅以描述性方式报告。它不支持统计显著性、学习增益、保持效应、迁移效应、工作负荷降低或速度等声明。

6.3.1 参与者与任务结果

表 6.7 总结了试验结果和交互计数。该表使用手动审核的步骤编码列作为完成情况和错误计数的最终权威。原始试验摘要作为溯源产物保留，在手动审核纠正了被动重建的地方可能存在差异。P08 使用第 4.7 节中描述的手动编码覆写；P09 被视为独立参与者。观察持续时间是从第一个到最后一个记录事件的间隔，不是完成时间比较，因为无导师条件下的试验在不同的过程节点结束。

已确认步骤数与表 6.8 中的人工遗漏计数不是同一指标。它统计的是某一步是否被可用导出证据确认。在无导师条件下，被动记录没有运行导师试验中使用的 VLM/视频页面检查。因此，纯视觉的 FCS BIT 页面和最终 GO 检查 (S18 和 S19) 在五个无导师步骤计数行中都保持未确认。人工操作时间线审核给出了不同解释。五位无导师参与者均存在右 DDI PB5 活动，因此 S18 未被编码为用户遗漏。对于 S19，P02、P03、P06 和 P07 有 FCS BIT 开关拨起序列；只有 P01 被编码为 S19 遗漏。剩余的不确定

Table 6.7: 参与者和试验概览。

P	条件	已完成	已确认	时长 (s)	帮助	VLM	覆盖层	回退
P01	without_tutor	否	23/33	2015	0	0	0	0
P02	without_tutor	否	27/33	739	0	0	0	0
P03	without_tutor	否	24/33	243	0	0	0	0
P06	without_tutor	否	29/33	269	0	0	0	0
P07	without_tutor	否	19/33	218	0	0	0	0
P04	with_tutor	是	33/33	442	19	6	22	6
P05	with_tutor	是	33/33	317	7	2	6	2
P08	with_tutor	是 *	33/33	332	7	5	10	4
P09	with_tutor	是	33/33	1033	44	10	44	9

*P08: 自动摘要报告了未完成的进度; 手动编码确认 33/33 已完成。

性是视觉层面的: 被动导出无法确认 FCS-MC 页面和最终 GO 结果是否实际可见。

在审核数据中, 所有四位导师条件下的参与者均达到了最终的 33 步状态, 而五位无导师条件下的参与者中无人达到。如果只按照导出的已确认步骤行排序, S18 (FCS-MC BIT 页面)、S19 (FCS BIT 最终 GO) 和 S27 (襟翼开关至 AUTO) 并列, 因为它们在五个无导师行中均未确认。但这一排序不应被解读为参与者错误排序。对 S18 和 S19 而言, 它主要暴露的是被动导出的测量盲点; 对 S27 而言, 它与人工编码的过程问题重合。因此, 人工遗漏编码给出了更相关的行为口径: S09、S27 和 S29 是最常见的遗漏编码步骤, 各出现在五位无导师参与者中的三位。这一模式标识了参与者遇到困难的位置以及被动导出流水线缺少视觉确认的位置; 它不是对导师效果的因果估计。

参与者画像使得描述性边界尤为重要。样本包括新手、中级用户和专家用户, 但条件之间并未按先前的 DCS World 或 F/A-18C 经验平衡。P05 和 P06 是不同条件下的专家参与者, 而 P01 和 P09 是新手。P09 在导出数据更正后被视作独立参与者, 但先导实验仍然无法排除经验、时间安排或会话上下文的影响。因此正确的解读不是"导师导致了完成"。正确的解读是, 完成的运行时能够在此形成性样本中支持四位导师条件下的参与者完成完整过程, 而无数师辅助条件下的运行揭示了值得进行有对照的后续研究的反复出现的失败点。

6.3.2 过程错误模式

表 6.8 报告了手动错误计数。无导师条件下的试验以遗漏为主, 而导师条件下的试验转向执行错误和提示/辅助错误。这种转变对未来设计很重要: 辅助可以帮助参与者持续推进过程, 但同时仍可能引入时机、解读或过度引导的风险。

无导师条件下的参与者平均有 7.4 个手动编码错误。导师条件下的参与者平均有 4.5 个手动编码错误。这些是来自小型非随机先导实验的描述性统计。更稳健的定性结

Table 6.8: 手动过程错误计数。OM = 遗漏, CO = 执行错误, OR = 顺序错误, PA = 提示/辅助错误, SV = 状态违反。

P	条件	OM	CO	OR	PA	SV
P01	without_tutor	8	0	1	0	1
P02	without_tutor	0	0	0	1	0
P03	without_tutor	7	0	2	0	2
P06	without_tutor	2	0	0	2	0
P07	without_tutor	11	0	0	0	0
P04	with_tutor	0	3	0	3	1
P05	with_tutor	0	3	0	3	0
P08	with_tutor	0	0	0	0	0
P09	with_tutor	0	3	0	2	0

果是错误类型对比：无导师辅助条件下以遗漏为主，而导师条件下仍存在与辅助相关的错误。

辅助相关错误之所以重要，是因为它们表明一个可信任的助手不只是一台完成机器。参与者可以完成所有步骤，同时仍接收到时机不当、冗余或在状态已经达成后过于急切的指导。在先导实验中，导师条件下的执行错误和提示/辅助错误指向了这些交互风险。它们推动未来版本实现更严格的确认逻辑、对已完成状态的更好检测以及更清晰的不确定性处理。

6.3.3 工作负荷、可用性、信任与评论

由于问卷元数据存在内部参与者 ID 不匹配，P02 被排除在所有问卷衍生摘要之外。表 6.9 报告了其余原始问卷值。分数仅为描述性。导师特定评分仅在导师条件下可用；一般用户/可用性评分在两种条件下均可用。

原始 TLX 值在无导师条件下从 13.33 到 55.83，在导师条件下从 13.33 到 33.00。描述性均值分别为 34.12 和 23.66，但样本过小且不平衡，不足以做出工作负荷降低声明。导师组中导师特定评分始终高于量表的中点，均值为 5.92。这些分数支持形成性解读：参与者总体上对导师给予正面评价，而日志和错误编码仍然显示出未解决的辅助风险。

问卷值之所以有用，是因为它们使纯粹基于日志的解读变得复杂。P09 有大量帮助请求和最长的导师条件轨迹，但记录的用户评分很高，评论将接地反馈描述为有帮助的。P05 作为专家参与者，需要的帮助循环较少，记录的 TLX 值也低，但仍然存在辅助相关错误。这些例子表明，未来的评估不应将教学系统简化为单一结果变量。完成情况、工作负荷、感知有用性、信任、错误类型和帮助循环修复频率对新手和专家可能有不同的表现。

Table 6.9: 排除 P02 后的试验后问卷摘要。Confidence、tutor rating 和 user rating 使用记录的 1-7 响应量表；Raw TLX 以未加权原始工作负荷平均值报告。

P	条件	自信度	Raw TLX	导师评分	用户评分
P01	without_tutor	3.5	55.83	n/a	4.20
P03	without_tutor	6.0	26.67	n/a	5.20
P06	without_tutor	7.0	13.33	n/a	5.60
P07	without_tutor	5.0	40.67	n/a	5.20
P04	with_tutor	7.0	26.33	6.00	6.20
P05	with_tutor	7.0	13.33	6.17	5.60
P08	with_tutor	5.0	33.00	5.67	5.00
P09	with_tutor	3.5	22.00	5.83	6.40
无导师均值		5.38	34.12	n/a	5.05
有导师均值		5.63	23.66	5.92	5.80

表 6.10总结了简短的匿名评论。评论并未被编码为主题并计算评分者间信度；它们被用来解释先导实验中观察到的具体交互摩擦。评论以改写或轻微压缩的英文摘要形式报告；如果参与者使用了其他语言，摘要为翻译而非逐字引用。

Table 6.10: 简短的匿名参与者评论，为节省空间进行了改写或轻微压缩。

条件	主题	评论摘要
无导师	检查单可读性	一位参与者报告膝板阅读困难，VR 中小的固定文本难以使用。
无导师	过程映射	一位参与者报告某些检查单步骤与他们的座舱体验不够清晰地匹配。
有导师	遗漏操作	一位参与者报告导师帮助他们填补了遗漏的操作。
有导师	接地反馈	一位新手参与者描述了逐步指导，能够识别他们卡住的位置，并且在动作错误时不继续推进。
有导师	认知努力	一位参与者仍然需要将座舱显示与 AI 指令进行对比，并觉得 FCS 和 BIT 等缩写令人困惑。

6.3.4 RQ3 总结

该先导实验提供了三项描述性发现。第一，运行时可以在 Quest 3 环境中实时使用，并产生可分析的导出数据。第二，经审核的任务日志显示，在此非随机样本中，所有四位导师条件下的参与者达到最终 33 步状态，而所有五次无导师试验均未达到经确认的最终 33 步状态。第三，导师改变了观察到的错误模式而非消除了所有错误：遗漏在导师条件下消失了，但执行错误和提示/辅助错误仍然存在。这些发现推动了未来工

作的问题：AI 如何能在动态、高负荷、多模态环境中成为可信任的协作者，而不仅仅是流畅的指令来源。

第七章 讨论

第 六 章报告了三条证据线索，各自的声明强度不同：针对 RQ1 的回放和 harness 就绪性证据、针对 RQ2 的视觉事实基准测试、以及针对 RQ3 的形成性 VR 试点。本章综合解读这些证据线索。核心主张并非 tutor 已被证明能够改善学习效果，而是展示如何通过在学习者与基础模型响应之间放置遥测数据、过程规则、检索来源、VLM 导出的视觉事实以及 harness 验证，将过程性 tutor 构建为技术上可审计的系统。

第 7.1 节阐述了实现的工作与原始提案之间的差异。第 7.2 节解读技术证据。第 7.3 节在其形成性边界内讨论试点发现。第 7.4 节从本体演进中提炼主要的设计教训。第 7.5 和第 7.6 节说明本论文的局限性以及最直接的后续研究步骤。

7.1 从提案到实现系统的演进

原始论文提案 [39] 描述了一个面向 Meta Quest 3 的 VR 优先教学系统，包含注视追踪、手部追踪、语音输入、RAG+LLM 后端，以及一项受控的三条件人体受试者研究。最终论文保留了沉浸式过程性教学的动机，但工作重心发生了转移。已实现的贡献最好理解为一个基于证据的教学运行时和视觉事实提取方法，其中 VR 用于形成性试点，而非用于受控的有效性声明。

这一转变不仅仅是工程上的便利。冷启动过程揭示了一个先决问题：在 tutor 能够提供有用的过程性帮助之前，它必须知道自己被允许信任哪些状态。某些所需证据通过 DCS-BIOS 以遥测数据形式导出。某些证据仅在座舱显示屏上可见。某些证据超出了当前遥测或视觉事实契约的范围，因此运行时必须将其视为不可用，而不是默不作声地转变成为一个确信的状态断言。因此，本论文必须首先构建证据层：过程包、门控推理、证据数据包、检索边界、VLM 视觉事实、受 Schema 约束的模型输出、harness 验证、叠加层白名单以及可回放的日志。

VLM 工作源自同一种压力。提案假设模拟器状态足以用于过程性追踪。在实践中，诸如对准和 BIT 状态等显示页面内容必须通过视觉方式观察。这引出了 13 事实本体、经过审核的屏幕截图数据集、LoRA 适配管线以及独立的留存验证集基准测试。这些之所以成为核心贡献，是因为它们定义了如何将基础模型用作一个有界感知组件，而

非一个不受约束的过程状态裁判。

已完成的 VR 试点在一定程度上回归了原始提案中人体受试者研究的雄心。它表明基于证据的运行时可以在头戴设备中与真实参与者一起运行，并且导出管线能够捕获任务日志、工作负荷评分、可用性/信任度评分以及评论文本，以供后续分析。然而，它并未完成项目初始阶段提出的受控三条件研究。在 $n = 9$ 、非随机分组、P02 被排除在问卷衍生汇总之外、以及 P08 需要人工完成编码的情况下，该试点是形成性和描述性的。

7.2 技术证据的解读

最强的技术结果是 RQ2 视觉事实基准测试。主要 Qwen3.5-9B LoRA 线在两个独立的 13 事实留存验证集上均达到约 0.99 的事实准确率，同时相对于基础模型大幅减少了关键假阳性。补充性的 Qwen3.6-27B 和 Gemma-4-31B 结果表明，相同的数据与本体方案并不依赖单一的骨干模型，尽管本论文并不声称具备广泛的模型家族通用性。更重要的解读更窄但也更有用：一个经人工审核、与本体对齐的小规模数据集，可以使 VLM 在座舱视觉事实提取方面比相应的基础模型在本地留存验证数据上显著更可靠。

这一结果之所以重要，是因为教学运行时将 VLM 输出视为证据而非权威。诸如可见页面、标签或状态文字等视觉事实，是下游步骤推理的一个输入。过程引擎仍然将视觉事实与遥测数据、过程顺序、时间上下文和过程包定义的门控规则结合起来。正是这种分离防止了基准测试结果被曲解为无根据的教学声明。VLM 结果为教学系统的感知层提供了支撑，但其本身并不证明 tutor 的教学效果更好。

RQ1 的回放和 harness 证据支撑了论文的另一部分。回放案例、实时 fixture 覆盖、过程包衍生的 Schema、响应映射以及叠加层白名单表明，已实现的运行时能够在模型输出到达学习者之前对其进行约束。这是一项技术就绪性和可审计性的声明。它意味着帮助循环可以被回放、检查，并根据明确的证据契约进行核验。它并不意味着每个未来的模型响应都在教学上最优，也不意味着运行时已在不同模拟器或不同过程中得到验证。

综合来看，技术证据支撑了架构的核心前提：当基础模型的角色被明确的证据生产和验证所约束时，它们在过程性教学中可以发挥有益作用。本论文并不要求 LLM 成为真相的来源，而是要求 LLM 在一个运行时中生成响应，其中可观察状态、过程包、检索来源和 harness 共同定义了响应可以安全地主张或高亮什么。

7.2.1 技术证据不能证明什么

技术证据并未显示学习收益、记忆保持、迁移、工作负荷降低或更优的训练成果。VLM 基准测试衡量的是单帧视觉事实提取。回放和 harness 测试衡量的是证据契约和输出约束是否按预期运行。两者对于构建一个可靠的 tutor 是必要的，但对于做出人类学习效果的声明而言，两者都不是充分的。学习者可能接收到准确、有据的指导，却仍然未能形成持久的程序性理解。反之，学习者也可能会从一个不那么完备的系统中学习，如果该系统恰好符合其先验知识和策略的话。

证据也尚未分离出每个组件的单独价值。本论文不包含消融实验，来比较纯遥测教学、视觉增强教学、不同检索策略或不同 harness 严格程度的差异。因此，评估支撑的是一项集成式工件声明：已实现的系统展示了一种技术上可审计的方式来组合这些元素。它并未将每个设计选择与替代方案进行排名比较。

7.2.2 对 VLM 结果的数据导向解读

VLM 结果在一定程度上是模型的结果，但更重要的，它是一个数据与表征的结果。最显著的改进来自 LoRA 适配，然而适配器只是从早期薄弱的视觉管线到当前结果之间系统中发生变化的一部分。本体被修订了，标签契约被收窄了，训练分布被重新平衡了，基准测试将独立的留存验证集与受污染的开发集分离开了。这些选择是数据导向的机器学习选择。它们定义了模型被要求学习什么，以及哪种错误被认为是危险的。

这一区分对未来的工作至关重要。很容易将 Qwen3.5 的数据解读为更大或更新的骨干模型是主要解决方案的证据。Qwen3.6 的对比反驳了这种简单化的解读。更强的基座模型有帮助，但它并不能消除对任务特定本体或能够衡量正确失败模式的留存验证基准测试的需求。Gemma 的对比也反驳了单一指标的解读：一个模型可以在某个关键假阳性指标上更保守，同时在精确匹配和已见状态识别上仍然不够完备。实践上的教训是，模型选择应当显式考虑下游风险。

同样的教训也适用于训练数据。只有当新增示例针对的是剩余的决策边界时，添加更多示例才有用。在当前适配之后，页面可见性不如时间上相邻的完成线索、罕见阳性状态以及标签或页面名称出现但目标页面并未激活的困难负例有趣。因此，未来的数据收集应由基准测试中的失败案例驱动，而非出于均匀扩大数据集的愿望。

7.2.3 对 ML 系统设计的启示

本论文还暗示了一种更广泛的 ML 系统模式。在这种场景下，当系统设计者将模型的工作收窄到其输出可以被测试的程度时，基础模型最为有用。VLM 没有被要求理解整个座舱；它被要求预测一个小型的事实向量。LLM 没有被要求执行整个过程；它

被要求解释当前证据数据包的内容。运行时没有被要求无条件信任任一模型；它对两者的输出进行验证和记录。这种分工将广泛的基础模型能力转化为一组更小的契约。

这一模式不同于简单地在聊天机器人周围添加护栏。护栏通常在模型产生自由形式的回答之后才起作用。在 SimTutor 中，契约在生成之前就已存在：过程包定义了目标空间，证据数据包定义了模型被允许引用什么，视觉本体定义了 VLM 可以报告什么，harness 定义了什么可以成为叠加层。模型仍然贡献了灵活性，但问题的形状是在模型之外定义的。这就是为什么本论文可以做出可审计性声明，尽管它无法证明完整的教育有效性。

对于可部署的 ML 系统而言，这一区分很重要。以模型为中心的方法会问：哪个模型足够强大以解决这个任务？以证据为中心的方法会问：任务的哪些部分应分配给学习模型，哪些部分应保持符号化或人工编写，以及冲突应如何解决？座舱 tutor 从第二种方法中受益，因为不同错误的代价是不对称的。解释中的错误同义词不如错误的叠加目标严重。遗漏的视觉线索不如幻觉般的完成线索严重。如果运行时在 Schema 不合法的 VLM 响应成为证据之前就加以拒绝，那么它的危险性就更低。

这样得到的系统并不比一个无约束的聊天机器人更简单，但它更具可检查性。每增加一个约束就创建一个工件：一个 Schema、一个来源策略、一个本体、一个 UI 映射、一个基准测试或一个回放 fixture。这些工件是将基础模型的流畅性转化为一个可评估的研究对象所需的工程代价。

7.3 试点发现的解读

形成性 VR 试点提供了关于系统在真实使用场景下的描述性证据。在经审核的数据中，四位有 tutor 的参与者均达到最终 33 步状态，而五次无 tutor 试验均未达到经确认的最终 33 步状态。人工编码也显示，tutor 条件下的遗漏错误为零，无 tutor 条件下的遗漏错误均值为 5.6 个。这些观察与 tutor 的预期功能一致：它使当前过程步骤保持可见，检索相关的过程上下文，并能为学习者指示座舱控制的位置。

问卷数据增加了第二层较弱的描述性证据。在排除 P02 之后，无 tutor 条件下的原始 NASA-TLX 均值为 34.12，有 tutor 条件下为 23.66，且有 tutor 组在记录的 1-7 分量表上给出了均值为 5.92 的 tutor 专项评分。这些数值对于形成性解读是有用的，尤其是与关于有据反馈、遗漏操作、VR 检查清单文字过小以及令人困惑的缩写的评论文本结合起来阅读时。它们不应被解读为 tutor 在受控意义上降低了工作负荷或提高了信任度的证据。

同样的数据也表明，辅助并不能消除过程性错误。在 tutor 条件下仍然存在执行错误和提示辅助错误。这是一个重要的发现，因为它指向了一个比“tutor 是否有帮助？”更精确的设计问题。剩余的问题是，灵活的模型生成指导、确定性的 harness 修复、视

觉状态的不确定性以及人的动作时机如何与严格的过程规范对齐。tutor 可以减少遗漏步骤的模式，但仍然可能留出错时机、不完整执行或过度信任辅助的空间。

实时的帮助循环日志支撑了基础设施层面的声明。在四次有 tutor 的试验中，系统记录了 77 个帮助循环、23 次 VLM 调用、82 次叠加层执行、零次叠加层拒绝以及 21 次回退或修复事件。零次叠加层拒绝不应被解读为"一切正常"，而是意味着提出的叠加层动作在经过 Schema 验证和 harness 处理后，保持在已配置在白名单范围内。修复事件证明约束层是活跃的，而非证据表明模型输出始终直接正确。

因此，试点在论文中承担两个角色。首先，它展示了经过仪表化的教学运行时可以在实时 VR 环境中使用并生成可分析的日志。其次，它揭示了后续受控研究应更仔细衡量的那种人-系统交互数据。它并不支持关于学习效果、工作负荷、记忆保持、迁移或任务速度的因果性声明。

7.3.1 辅助与协作的边界

试点也澄清了"可信 AI 协作伙伴"的含义。协作伙伴并不仅仅是提供更多指令的系统。在高负荷的 VR 座舱中，更多的指令如果在错误的时间到达、使用了不熟悉的缩写或迫使学习者在多个证据来源之间进行比对，反而可能增加认知负荷。一个可信的协作伙伴必须调节自身的确定性，决定何时高亮、何时停留在纯文本，并帮助学习者理解下一步操作背后的证据。

有 tutor 的试验展示了这一边界的两个方面。完成率和遗漏模式表明，步骤感知的指导可以使学习者保持定向。执行错误和提示/辅助错误则表明，定向是不够的。系统还必须避免在状态已经达成后重复或产生过时的指导。P09 的评论尤其具有启发意义：tutor 因其能识别参与者卡在何处而不简单地推进而受到赞赏，但同一位参与者仍然报告需要将显示内容与 AI 指令进行比对，并且受到缩写的困扰。在此语境下，信任不是盲目接受，而是一种互动，学习者在其中能够看到助手为何做出断言，并且在断言不完整时能够恢复。

这一解读强化了论文标题的含义。"解释现实"并不是要取代学习者的情境意识，而是通过使状态、证据和不确定性更易于采取行动来支撑它。当前的原型仅实现了这一理念的早期版本。它具备证据数据包、视觉事实、验证和日志，但尚未优化何时帮助应最小化、何时应明确、以及何时应询问学习者或教官进行确认。

7.4 本体设计的教训

本体的演进是本论文中最清晰的设计教训。最初的视觉事实本体将可观察事实与过程性结论混在一起。例如，ins_go 要求 VLM 判断对准状态是否已有效达成。该目

标并非单纯依赖于视觉，它依赖于特定的显示文字、其他显示状态的缺失以及过程阶段。第一个基准测试中的失败模式使这个边界问题得以显现：一个单帧 VLM 被要求同时执行感知和过程推理。

13 事实本体纠正了这一边界。它将复合目标分解为更低层次的视觉观察，例如地面对准文字或 OK 文字是否可见，并将 FCS-MC 状态分解为视觉上可区分的阶段。下游运行时随后将这些观察与遥测数据和过程上下文结合起来进行解读。因此，设计原则是：

视觉事实目标应为低层次的、局部可验证的视觉命题。更高层次的过程状态应由下游基于视觉事实、遥测数据、时间上下文和过程规则推断得出。

这一原则的重要性不仅体现在标签命名上，它影响着标注质量、训练信号质量、错误诊断以及运行时安全。一位人工审核者可以在不知道过程历史的情况下判断一段文字是否在屏幕截图中可见。但同一位审核者在不知道图像之前发生了什么的情况下，并非总能判断一个过程状态是否已完成。当事实实际约尊重这一区分时，模型的输出就更易于审核，也更能安全地与确定性门控结合使用。

完成类事实上的残留假阳性显示了该方法的剩余局限性。某些状态在中间阶段和最终阶段之间在视觉上相似，尤其是涉及数字读数或瞬态显示状态时。这些情况可能需要更平衡的数据、更高分辨率的裁剪、重复观察或显式引入时间信息的 VLM 输入。因此，本论文并不声称 13 事实本体在一般意义上解决了视觉接地问题。它为一项高要求的过程提供了一种经过验证的设计准则，并提供了发现视觉目标何时仍然过于接近过程性结论的具体方法。

作为面向未来领域的一条启发式规则，该准则很简单：如果一个事实不能在不了解过程步骤的情况下仅从一张图像中标注出来，那么它对于 VLM 契约来说可能层次过高。它应当被分解为可见的原子事实，或交由过程引擎处理。正是在这一点上，本论文从一个案例特定的实现细节转向了一个可复用的表征教训。

7.5 局限性

本论文的贡献应在以下限制条件内进行理解。

7.5.1 评估范围

所有数据集、回放案例和试点试验均涉及一项过程：F/A-18C 冷启动。视觉提取器在相同的飞机类型和渲染环境中的固定复合座舱面板上训练和评估。留存测试集是独立的会话，与训练集无重叠，但它们衡量的仍然是域内泛化，并未建立跨过程、跨机型或跨模拟器的通用性。

最大的训练配方在经过 Run-005 过采样步骤后包含 928 行双语 SFT 数据。这对一项领域特定的适配研究而言故意做得较小，且在实践上有用，但它并未确定最低数据需求、性能上限或每个配方组件的效果。本论文不包含对双语行、过采样、LoRA 秩、组合再平衡、本体修订或替代微调方法的消融实验。具体而言，它没有分别隔离 Run-005 过采样、双语指令行、LoRA 秩，或从 8 事实本体转向 13 事实本体的独立效果。

7.5.2 系统与 VLM 范围

VLM 被评估为一个单帧视觉事实提取器。它不决定过程进展、不选择最终的 tutor 动作、也不直接控制叠加层。完成类事实上残留的关键假阳性仍然很重要，因为如果一项错误的视觉观察未被遥测数据、时间确认或 harness 约束检查到，它仍可能影响下游推理。粘性事实和确认策略缓解了这种风险，但其完整的端到端效果尚未通过实验隔离。

骨干模型比较在匹配的 LoRA 风格适配配方下覆盖了 Qwen3.5-9B、Qwen3.6-27B 和 Gemma-4-31B。这在项目范围内是有用的模型多样性证据，但并未覆盖其他 VLM 家族、更大的模型、全量微调、替代适配器或非座舱视觉领域。

运行时已通过回放、fixture、桌面 DCS World 和 Quest 3 试点实现并得到实际运用。然而，头戴设备延迟、叠加层可读性、注视或手部追踪精度以及专家评定的响应有用性并未作为受控的系统级结果进行测量。

7.5.3 构念效度

论文中的若干构念是代理指标。VLM 基准测试衡量的是单帧视觉事实提取，而非人类对座舱显示的理解。回放 fixture 衡量的是已知的证据接地案例是否被正确处理，而非每个可能的实时帮助请求是否安全。人工步骤完成判定衡量的是过程状态是否被达成，而非学习者随后能否在没有辅助的情况下执行任务。原始 NASA-TLX 值衡量的是一次形成性试验后报告的工作负荷，而非稳定的工作负荷降低。

这些代理指标仍然有用，因为它们与系统当前的开发阶段相匹配。在测试学习成果之前，tutor 必须能够观察状态、产生有界视觉事实、验证模型输出并导出可解释的日志。因此，本文所选的构念优先考虑技术就绪性和描述性交互证据。后续的受控研究应增加本论文未衡量的构念：延迟后的记忆保持、向不同启动场景的迁移、专家评定的解释质量、头戴设备中叠加层的可读性以及校准后的信任度。

构念效度的边界也保护了 ML 结果免于过度推断。高 VLM 准确率对视觉证据通道是必要的，但它不是解释质量的直接度量。反之，参与者可能给 tutor 打出高分，即便某些视觉事实或叠加层需要修复。因此，评估将组件可靠性、系统可审计性和人类响应作为独立的构念。

7.5.4 试点范围

试点包含九名参与者：四位有 tutor，五位无 tutor。分组未随机化，先前的 DCS World 经验未做到均衡，样本量过小无法进行推断统计。无 tutor 试验在不同的过程节点停止，因此其持续时间无法与完成的有 tutor 试验进行比较。

问卷证据虽可使用但有限。P02 的问卷元数据无法可靠归属，因此被排除在所有问卷衍生汇总之外。剩余的原始 NASA-TLX、tutor 评分、可用性/用户评分和自由文本评论数据仅为描述性数据。它们支撑形成性解读，而非具有推断强度的工作负荷、信心、信任或可用性声明。

最后，人工审查从被动遥测门控和动作时间线推断无 tutor 条件下的完成情况。由于主动 VLM 通道在该条件下不可用，视觉证据步骤的确定性较低。这一局限并不使形成性发现无效，但它表明了为什么下一步研究需要更严格的仪表化和编码。

7.5.5 范围总结

在这些局限之内，本论文支撑四项声明：一个受证据约束的过程性教学运行时可以以明确的架构边界加以实现；一个小数据 VLM 适配管线可以在本地留存验证集上实现可靠的视觉事实提取；视觉本体的演进提供了一条关于感知与推理的具象设计教训；VR 试点表明系统可以与参与者一起实际运行并生成可分析的日志。它并未确立受控的教育有效性。

7.6 未来工作

上述局限性指向一个更大的研究议程：AI 如何能在动态、高负荷、多模态的训练环境中成为可信的协作伙伴？在本论文中，可信赖性并不意味着模型听起来自信，而是指助手能够暴露其指导背后的证据、知道某个模态何时不可用、遵从明确的过程规则、从不确性中恢复，并留下教官可以检查的审计轨迹。以下方向拓展了这一议程。

7.6.1 受控人体受试者评估

下一步研究应将有据 tutor 与基线条件进行比较，采用随机化分组、均衡的参与者元数据、预定义的编码规则以及完整的问卷和工作负荷采集。对下一次迭代而言，双条件设计比原始的三条件提案更为现实，因为当前优先事项是确认已完成的运行时在受控条件下是否在学习完成度、错误、工作负荷和记忆保持方面产生可测量的差异。

7.6.2 本体向其他过程的扩展

13 事实本体应仅在新的任务分析识别出哪些状态是遥测可见的、哪些是视觉优先的、哪些超出了当前证据来源契约范围之后，才扩展到其他过程。每个新过程都需要自己的视觉事实契约、经审核的数据、留存验证基准测试和运行时绑定。这是检验本体准则是否能在冷启动之外迁移的恰当测试。

7.6.3 时序与多帧视觉推理

若干残留错误涉及难以从单张屏幕截图中辨别的状态。多帧输入、短时视觉历史或重复确认门控可以帮助区分中间和最终的显示状态。这将需要对采集、标注、模型输入格式和基准测试指标进行变更。

7.6.4 系统级帮助循环评估

应单独进行一项评估来测量完整的帮助循环而非单个组件：从触发到叠加层的延迟、高亮目标的正确性、harness 修复的频率和类型、专家审查下的响应有用性，以及视觉优先步骤是否相对于纯遥测基线有所改善。这将把 RQ1 和 RQ2 的技术证据更直接地与 RQ3 连接起来。

对于可信合作伙伴议程而言，这一系统级评估还应测量助手何时应保持沉默、何时应请求确认、何时应声明不确定性而非给出另一条指令。在高负荷 VR 使用中，过多的指导如果与学习者的注意力竞争或模糊了行动所需的证据，可能与过少的指导一样有害。

7.6.5 多模态协作策略

未来工作应将模态选择视为一个策略问题。助手可以用文字、空间叠加层、视觉确认请求、检索到的操作手册摘录或沉默来回应。每种模态都有其代价。文字消耗阅读和记忆资源。叠加层消耗视觉注意力，并可能将学习者引向某个特定控制。VLM 调用消耗延迟并可能返回不确定的事实。检索可以增加权威性，但也可能延长消息长度。一个可信的合作伙伴应选择足以应对当前证据状态的最轻量模态。

这种策略可以从确定性策略开始。例如，如果遥测数据已确认完成，tutor 应避免重复指令。如果某个视觉事实不确定，它应请求确认而非高亮完成目标。如果学习者正处于已知的高困惑步骤，tutor 可以先给出较简短的解释，仅在请求时才揭示更多细节。后续工作可以从专家纠正中学习该策略的部分内容，但策略应保持可审计性：每个模态选择仍应与状态、证据和不确定性绑定。

7.6.6 原位纠正与适配

当前的 VLM 适配管线是离线的。未来版本可以在视觉事实出错时采集教官或学习者的纠正，并将这些纠正纳入后续审核或增量适配中。这一方向需要谨慎的安全防护，因为原位标签可能存在噪声，且适配不得抹除之前可靠的行为。

7.6.7 未来方向总结

表 7.1 总结了主要的未来工作方向及每个方向所针对的局限性。

Table 7.1: 未来工作方向总结。

方向	当前状态	主要挑战
受控人体受试者研究	形成性试点已完成；因果证据待获取	随机化、元数据、工作负荷和统计功效
本体扩展	冷启动本体仅在当前座舱布局内评估	新任务分析、标注和留存验证设计
时序视觉推理 系统级帮助循环评估	当前 VLM 使用单张复合面板帧组件和回放证据可用	多帧数据、模型容量和时序指标定义集成的延迟、质量和修复指标
原位纠正与适配	离线审核和 LoRA 管线已实现	噪声标签、遗忘和安全更新策略

这些方向保持了论文的主线不变。下一阶段不是让基础模型更不受约束，而是加强其周围的证据回路：更广泛的过程包、更好的视觉事实、更丰富的时序证据、受控的人体评估，以及使每个 tutor 响应在事后都可审计的日志。

第八章 结论

本论文源自许多过程性训练场景共有的一个实践问题：学习者在复杂模拟系统中操作时常常需要帮助，但有用的帮助必须立足于当前的真实状态。当下一个正确动作取决于遥测数据、过程顺序、显示状态和先前的操作时，仅凭基础模型流利的回答是不够的。本论文发展的核心答案是：当基础模型被置于一个可审计的证据回路中时，它们可以被改造为适用于过程性教学。

F/A-18C 冷启动任务为这一理念提供了一个极为苛刻的案例。它要求 tutor 将遥测可见的座舱状态、来自显示页面的视觉证据、检索到的过程知识、不可用来源的边界以及验证结合在一起，然后才能生成叠加层或文字指导。其结果并非声称学习有效性已被证明，而是一项技术与方法论贡献：一种使模型辅助的过程性帮助具备状态感知、可检查性并受可用证据约束的方法。

8.1 已完成工作总结

已完成的工作回答了三个研究问题，如下所述。

RQ1：证据集成与教学架构。 本论文展示了如何将模拟器遥测数据、检索到的过程来源和视觉事实观察集成到一个受约束的帮助循环中。运行时在模型生成之前构建证据数据包，从声明性门控推理候选过程步骤，要求模型在过程包衍生的 Schema 内进行响应，通过 harness 验证或修复该响应，并仅执行白名单中的叠加层动作。日志和回放随后使整个帮助循环在事后可被检查。这在技术可审计性的层面上回答了 RQ1：LLM 不是过程状态的权威，而是受证据、Schema、harness 和过程包规则约束的生成器。

RQ2：视觉事实提取与本体设计。 本论文还展示了小数据 VLM 适配可以支撑 tutor 所需的座舱显示状态的可靠视觉事实提取。13 事实本体和 LoRA 训练管线在 Qwen3.5-9B 线上产生了最强的首要结果，在两个独立的 13 事实留存验证集上达到约 0.99 的事实准确率，并相对于基础模型大幅减少了关键假阳性。补充性的 Qwen3.6-27B 和 Gemma-4-31B 结果在评估的骨干模型范围内支撑了相同的数据与本体方案。更一般性

的教训是表征层面的：VLM 应报告局部可验证的视觉事实，而过程性完成应由下游基于视觉事实、遥测数据、时间和过程上下文推断得出。

RQ3：形成性 VR 试点证据。 已完成的 Quest 3 试点为运行时和仪表化能否在沉浸式模拟中与参与者一起实际运行提供了形成性证据。在经审核的数据中，四位有 tutor 的参与者达到最终 33 步状态，而五次无 tutor 试验均未达到经确认的最终 33 步状态。遗漏错误在 tutor 条件下消失，而辅助耦合的错误仍然存在。帮助循环日志还显示，tutor 可以在线运行，包括 VLM 调用、叠加层动作、harness 修复和可回放的导出。这些发现以描述性方式回答了 RQ3。它们支撑了可行性、仪表化就绪性和错误模式分析；它们并未确立因果性的学习收益、工作负荷降低、记忆保持、迁移或速度提升。

综合起来，这些答案定义了本论文的贡献。第一，本工作为过程性模拟提供了一种基于证据的教学运行时模式，其中生成的帮助是在明确的状态证据和验证之后产生的。第二，它贡献了一套将 VLM 感知与过程性推理相分离的视觉事实本体和适配方法。第三，它提供了一条可试点的评估路径，用于研究在真实 VR 参与者中的有据教学。贯穿这三者的要点不在于 LLM 或 VLM 本身的存在，而在于基础模型输出周围所设置的边界。

这一边界是主要的可迁移理念。基础模型可以在高保真度过程性训练器中发挥作用，但前提是其角色必须被明确界定。LLM 是语言 and 解释组件，而非模拟器真相的来源。VLM 是感知组件，而非过程引擎。检索是文本接地的来源，而非混合过程变体的许可。遥测在存在之处具有权威性，但它不是完整的教学法。运行时的贡献在于提供了一种机制，将这些部分权威组合成一个帮助循环，并记录该组合是如何形成的。

ML 贡献同样是有界的，但也是具体的。本论文并不声称 LoRA 适配在一般意义上解决了座舱感知问题。它展示的是，通过精心修订的本体、经人工审核的小规模数据、组合再平衡和独立留存验证，VLM 可以在 tutor 所需的具体结构化视觉事实上显著变得更可靠。Qwen3.5、Qwen3.6 和 Gemma 的比较表明，为什么这应当被视为一个模型与数据的联合决策，而非简单地选择最大的骨干模型。可靠性取决于事实契约、错误代价以及预测的下游使用方式。

论文范围保持了有意为之的有限性。评估涵盖了一项过程、一种座舱布局、本地视觉留存验证集、回放和 harness 就绪性，以及一个小规模非随机试点。当前证据对技术可靠性和可审计性的支撑强于对教育有效性的支撑。它并未显示 tutor 能跨领域泛化，也未显示试点中的差异仅由 tutor 引起。这些边界不是需要隐藏的弱点，而是使贡献可被检查的原因所在。

8.2 未来工作

最为直接的下一步是一项受控的人体受试者评估。这样的研究应保留当前的导出和回放基础设施，但增加随机化分组、均衡的参与者元数据、完整的问卷和工作负荷采集、预定义的编码规则以及足以进行推断性分析的样本量。只有这类研究才能检验技术上有据的帮助循环是否、以及如何改变了学习效果、工作负荷、记忆保持或迁移。

技术议程同样清晰。过程包和视觉事实方法应扩展到其他过程，但每个扩展都需要新的任务分析、证据来源映射、视觉本体设计、经审核的数据和独立的留存验证评估。VLM 管线还应超越孤立的屏幕截图，针对过程状态依赖于时间证据的情况：短时视觉历史、重复确认或多帧输入是完成类事实的自然下一步机制。最后，完整的帮助循环应作为一个集成系统进行评估，包括延迟、叠加层正确性、harness 修复频率、专家评定的响应有用性，以及助手应抑制、推迟或明确声明不确定性的时刻。

系统的更长期版本可以从教官或学习者的原位纠正中学习。这一方向将使实时教学变成数据采集回路，但它需要谨慎的安全防护：纠正标签可能存在噪声，更新不得抹除已经可靠的行为，且每个适配后的模型仍必须针对未受污染的留存验证集进行评估。

更广泛的研究问题是：如何使 AI 成为协作伙伴而非答案生成器？在本文所研究的场景中，协作意味着帮助学习者在不确定性下采取行动，同时保持学习者检查情境的能力。它意味着选择何时高亮、何时解释、何时请求确认以及何时保持沉默。它还意味着留下足够的证据，使教官、研究者或开发者可以在事后重建系统当时相信了什么以及为什么采取了那样的行动。本论文中的原型并未完成这一议程，但它建立了追求这一目标所需的证据回路。

本论文的标题——解释现实——抓住了最终的设计承诺。一个过程性 tutor 不应仅仅解释一份检查清单，也不应仅仅生成关于任务的可信语言描述。它应当解释学习者当前的现实：什么是可观察的，哪些证据支撑了它，哪条过程规则适用，什么仍然不确定，以及为什么下一个响应是被允许的。这也是通向在动态、高负荷、多模态环境中让 AI 成为可信协作伙伴的长期路径。本论文的贡献是一种架构和一种证据方法，使得这种解释变得可审计。

参考文献

- [1] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, et al. Do as i can, not as i say: Grounding language in robotic affordances. In *Proceedings of the 6th Conference on Robot Learning*, 2022. doi: 10.48550/arXiv.2204.01691.
- [2] Vincent Aleven, Bruce M. McLaren, Jonathan Sewall, and Kenneth R. Koedinger. A new paradigm for intelligent tutoring systems: Example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2):105–154, 2009. doi: 10.3233/IRG-2009-19(2)02.
- [3] Saleema Amershi, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, Jina Suh, Shamsi Iqbal, Paul N. Bennett, Kori Inkpen, Jaime Teevan, Ruth Kikin-Gil, and Eric Horvitz. Guidelines for human-AI interaction. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, pages 1–13, 2019. doi: 10.1145/3290605.3300233.
- [4] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.
- [5] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems*, volume 36, 2023. doi: 10.48550/arXiv.2305.06500.
- [6] DCS-BIOS Project. DCS-BIOS documentation, n.d. DCS-BIOS v0.10.0 documentation. Accessed 2026-06-05. Available at: <https://dcs-bios.readthedocs.io/en/latest/>.

-
- [7] Biplab Deka, Zifeng Huang, Chad Franzen, Joshua Hibschan, Daniel Afergan, Yang Li, Jeffrey Nichols, and Ranjitha Kumar. Rico: A mobile app dataset for building data-driven design applications. In *Proceedings of the 30th Annual ACM Symposium on User Interface Software and Technology*, pages 845–854, 2017. doi: 10.1145/3126594.3126651.
 - [8] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL <https://arxiv.org/abs/2305.14314>.
 - [9] Eagle Dynamics. DCS World, 2013. Digital Combat Simulator. Available at: <https://www.digitalcombatsimulator.com/>.
 - [10] Eagle Dynamics. DCS: F/A-18C early access guide, 2023. Updated 18 July 2023. Available at: https://www.digitalcombatsimulator.com/en/downloads/documentation/dcs-hornet_early_access_guide_en/.
 - [11] Gemma Team. Gemma: Open models based on gemini research and technology, 2024. URL <https://arxiv.org/abs/2403.08295>.
 - [12] Gemma Team. Gemma 3 technical report, 2025. URL <https://arxiv.org/abs/2503.19786>.
 - [13] David Gunning, Mark Stefik, Jaesik Choi, Timothy Miller, Simone Stumpf, and Guang-Zhong Yang. XAI—explainable artificial intelligence. *Science Robotics*, 4(37):eaay7120, 2019. doi: 10.1126/scirobotics.aay7120.
 - [14] Daniel Han and Michael Han. Unsloth: Open-source library for faster LLM finetuning, 2024. URL <https://github.com/unslothai/unsloth>.
 - [15] Sandra G. Hart and Lowell E. Staveland. Development of NASA-TLX (Task Load Index): Results of empirical and theoretical research. In Peter A. Hancock and Najmedin Meshkati, editors, *Human Mental Workload*, volume 52 of *Advances in Psychology*, pages 139–183. North-Holland, 1988. doi: 10.1016/S0166-4115(08)62386-9.
 - [16] Robert T. Hays, John W. Jacobs, Carolyn Prince, and Eduardo Salas. Flight simulator training effectiveness: A meta-analysis. *Military Psychology*, 4(2):63–74, 1992. doi: 10.1207/s15327876mp0402_1.

-
- [17] Steven J. Henderson and Steven Feiner. Exploring the benefits of augmented reality documentation for maintenance and repair. *IEEE Transactions on Visualization and Computer Graphics*, 17(10):1355–1368, 2011. doi: 10.1109/TVCG.2010.245.
- [18] Robert R. Hoffman, Shane T. Mueller, Gary Klein, and Jordan Litman. Metrics for explainable AI: Challenges and prospects. In *arXiv preprint arXiv:1812.04608*, 2018. URL <https://arxiv.org/abs/1812.04608>.
- [19] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [20] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Ho Ho Shu Chan, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023. doi: 10.1145/3571730.
- [21] Enkelejda Kasneci, Kathrin Seßler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günnemann, Eyke Hüllermeier, Stephan Krusche, Gitta Kutyniok, Tilman Michaeli, Claudia Nerdel, Jürgen Pfeffer, Oleksandra Poquet, Michael Sailer, Albrecht Schmidt, Tina Seidel, Matthias Stadler, and Gjergji Kasneci. ChatGPT for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274, 2023. doi: 10.1016/j.lindif.2023.102274.
- [22] Dawid J. Kopiczko, Tijmen Blankevoort, and Yuki M. Asano. VeRA: Vector-based random matrix adaptation. *arXiv preprint arXiv:2310.11454*, 2023. URL <https://arxiv.org/abs/2310.11454>.
- [23] James A. Kulik and J. D. Fletcher. Effectiveness of intelligent tutoring systems: A meta-analytic review. *Review of Educational Research*, 86(1):42–78, 2016. doi: 10.3102/0034654315581420.
- [24] John D. Lee and Katrina A. See. Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1):50–80, 2004. doi: 10.1518/hfes.46.1.50_30392.
- [25] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-

- intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- [26] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in Neural Information Processing Systems*, 36, 2023. doi: 10.48550/arXiv.2304.08485.
- [27] Sourab Mangrulkar, Sylvain Gugger, Lysandre Debut, Younes Belkada, Sayak Paul, and Benjamin Bossan. PEFT: State-of-the-art parameter-efficient fine-tuning methods, 2022. URL <https://github.com/huggingface/peft>.
- [28] Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1906–1919, 2020. doi: 10.18653/v1/2020.acl-main.173.
- [29] Antonija Mitrovic. Fifteen years of constraint-based tutors: What we have achieved and where we are going. *User Modeling and User-Adapted Interaction*, 22(1–2):39–72, 2012. doi: 10.1007/s11257-011-9105-9.
- [30] Riccardo Palmarini, John Ahmet Erkoyuncu, Rajkumar Roy, and Hosein Torabmostaedi. A systematic review of augmented reality applications in maintenance. *Robotics and Computer-Integrated Manufacturing*, 49:215–228, 2018. doi: 10.1016/j.rcim.2017.06.002.
- [31] Qwen Team. Qwen3-VL technical report, 2025. URL <https://arxiv.org/abs/2511.21631>.
- [32] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/15000000019.
- [33] Arthur Tang, Charles Owen, Frank Biocca, and Weimin Mou. Comparative effectiveness of augmented reality in object assembly. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, pages 73–80, 2003. doi: 10.1145/642611.642626.
- [34] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. Label Studio: Data labeling software, 2020. URL <https://github.com/HumanSignal/label-studio>.

-
- [35] Kurt VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011. doi: 10.1080/00461520.2011.611369.
- [36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [37] Leandro von Werra, Younes Belkada, Lewis Tunstall, Edward Beeching, Tristan Thrush, Nathan Lambert, and Shengyi Huang. TRL: Transformer reinforcement learning, 2020. URL <https://github.com/huggingface/trl>.
- [38] Bryan Wang, Gang Li, Xin Zhou, Zhourong Chen, Tovi Grossman, and Yang Li. Screen2Words: Automatic mobile UI summarization with multimodal learning. *arXiv preprint arXiv:2108.03353*, 2021. doi: 10.48550/arXiv.2108.03353.
- [39] Yu Zhang. Explain reality: Grounded procedural tutoring with foundation models and visual fact extraction in immersive simulation — MSc thesis proposal. TU Clausthal, Institute for Software and Systems Engineering (ISSE). Unpublished manuscript., 2025.

第九章 附录

本附录支撑方法论、实现和评估各章。它保留了原始的配置、数据集、回放、图表和试点编码材料，而未扩展正文各章所声明的声明边界。

9.1 完整 LoRA 超参数配置

表 9.1 列出了三种骨干模型在匹配的 Run-003 + Run-005 $\times$ 2 配方下的完整超参数配置。数值来源于可用的训练报告和基准测试工件。

注意：由于不同骨干模型在分词器行为、对话模板结构、目标序列分布和模型参数化方面存在差异，训练损失值不可直接跨骨干比较。

9.2 8 事实 v1 基线基准测试

最早的完整基准测试使用基于 Run-001（180 个任务）训练的 8 事实 LoRA 适配器，并在 Run-002 留存验证集（50 个样本）上评估。该基线先于 13 事实本体，收录于此仅供参考历史。

LoRA 适配器显著提升了事实层面的指标，但将关键假阳性从 13 增至 15。这一历史结果展示了 8 事实 v1 本体的结构性弱点：诸如 `ins_go` 等复合目标无法从单帧中进行视觉验证，并在完成类事实上产生了系统性的假阳性错误。

9.3 数据集事实分布

表 9.3 报告了两个主要训练来源（Run-003、Run-005）和两个 13 事实留存验证集（Run-002 newfacts、Run-004 random）中每个事实的 `seen` 计数。计数数据来源于相应的 `stats.json` 文件。表中使用了简短的显示标签；权威的事实标识符定义在过程包所使用的视觉事实本体文件中。

Run-005 与 Run-003 合并后增加了若干稀疏目标的覆盖：SUPT 页面观察从 20 升至 54，FCS-MC 页面观察从 55 升至 111，INS 地面校准文字观察从 58 升至 130。此

Table 9.1: 三种骨干模型的完整 LoRA 微调超参数配置。

参数	Qwen3.5-9B	Qwen3.6-27B	Gemma-4-31B
max_seq_length	4096	4096	4096
num_train_epochs	4.0	4.0	4.0
learning_rate	2×10^{-4}	2×10^{-4}	2×10^{-4}
per_device_train_batch_size	1	1	1
gradient_accumulation_steps	4	4	4
lora_r	16	16	16
lora_alpha	16	16	16
lora_dropout	0.0	0.0	0.0
seed	3407	3407	3407
load_in_4bit	True	True	True
warmup_ratio	0.1	0.1	0.1
weight_decay	0.01	0.01	0.01
train_rows	928	928	928
eval_rows	0	0	0
骨干模型特定参数			
视觉 LoRA	已启用	已启用	已禁用
LoRA 目标模块	vision+lang	vision+lang	all-linear
对话模板	Qwen 默认	Qwen 默认	gemma-4
GPU 内存使用率	0.6	0.6	0.95
训练结果			
训练时长 (s)	6419	12619	8050
训练损失 (最终)	0.2156	0.1068	0.0474

Table 9.2: 8 事实 v1 基准测试：Qwen3.5-9B 基础模型 vs. LoRA-v1 在 Run-002 留存验证集上（50 样本，英文）。

指标	基础模型	LoRA-v1	Δ
JSON 合法率	1.0	1.0	—
Schema 合法率	1.0	1.0	—
事实准确率	0.7600	0.9150	+0.1550
宏观 F_1	0.4241	0.5847	+0.1605
已见 F_1	0.4714	0.8380	+0.3666
样本精确匹配率	0.06	0.36	+0.30
关键假阳性	13	15	+2

Table 9.3: 训练集和留存验证集中各事实 `seen` 计数 (13 事实 v2 本体)。

事实标签	Run-003	Run-005	Run-002	Run-004
TAC 页面可见	46	24	23	3
SUPT 页面可见	20	34	5	3
FCS 页面可见	30	40	13	94
FCS X 标记可见	16	18	1	5
BIT 根页面可见	18	43	9	16
FCS-MC 页面可见	55	56	9	84
FCS-MC 中间结果	18	15	1	7
FCS-MC 测试中状态	18	19	6	17
FCS-MC 最终 GO 结果	18	22	2	60
HSI 页面可见	106	109	49	100
HSI 地图图层可见	79	37	27	50
INS 地面校准文字	58	72	42	69
INS OK 文字	12	14	4	0

表记录了数据来源；第 六 章评估了由此产生的训练配方是否在留存验证集上改善了模型行为。

9.4 CLI 命令参考

`simtutor` 包提供以下 CLI 命令：

run. 使用模拟环境适配器和预录制的场景文件执行模拟，并写入事件日志。

replay. 根据过程包验证现有事件日志，检查步骤顺序和状态机一致性。

score. 使用评分引擎对事件日志进行评分，产生遗漏计数、状态违规计数和总错误分数。

record-vlm. 对一组视觉观察执行 VLM 事实提取，并记录预测结果用于基准测试。

replay-bios. 通过遥测管线回放原始 DCS-BIOS 捕获数据，并可选择调用帮助生成循环。

validate. 根据 Schema 注册库中的指定 Schema 验证 JSONL 文件。

所有命令均接受模型配置覆盖参数 (`-model-provider`、`-model-name`、`-model-base-url`、`-model-timeout-s`) 和语言切换参数 (`-lang`)。

9.5 模型提供方配置

模型访问通过环境变量配置，并在运行时验证：

提供方. SIMTUTOR_MODEL_PROVIDER 选择 openai_compat、ollama 或 stub。

Base URL. SIMTUTOR_MODEL_BASE_URL 设置提供方端点。

模型. SIMTUTOR_MODEL_NAME 选择模型名称。

超时. SIMTUTOR_MODEL_TIMEOUT_S 设置请求超时时间。

凭证. SIMTUTOR_MODEL_API_KEY 是 openai_compat 提供方所必需的。API 密钥在日志输出中会被遮盖。

图像. SIMTUTOR_MODEL_ENABLE_MULTIMODAL 切换请求中的 base64 图像编码。

语言. SIMTUTOR_LANG 选择 zh 或 en。

9.6 回放评估套件

表 9.4 列出了 fa18c_startup_v04 套件中的五个回放评估案例。此处显示标签为简写；套件文件保留了确切的 case_id 字符串。

Table 9.4: 回放评估案例。

案例	步骤	视觉	目标
空操作捕获	S01	否	电池开关
电池开启	S02	否	火警测试开关
电池开启，发动机发电机关闭	S01	否	左侧发电机开关
FCS 重置 / FCS BIT	S18	是	FCS BIT 开关
INS 模式	S12	是	INS 模式旋钮

标记为视觉可用的案例包含在相应 DCS World Saved Games 捕获中的逐帧 sidecar 文件 (frames.jsonl)。这些文件允许依赖视觉的回放案例在没有实时 DCS World 实例的情况下运行。

9.7 补充架构与导出图示

正文各章使用简化图示来支撑研究论证。图 9.1、9.2和9.3保留了额外的工程细节，以便复现和操作上下文。

Harness and evidence validation




Figure 9.1: Harness 与证据验证。候选 tutor 动作在接受为叠加层动作计划之前，需经过 Schema 约束、UI 白名单、证据一致性和过程状态的检查；不安全或证据不足的动作会被修复、拒绝或降级为纯文字指导。

Deployment topology




Figure 9.2: 原型所使用的部署拓扑。模拟器、Quest 3 叠加层路径、本地运行时、回放工具和远程模型提供方被分离开来，使得实时试验和离线分析可以使用相同的证据和日志契约。

Detailed experiment export pipeline




Figure 9.3: 详细的实验导出管线。运行时事件日志和试验元数据被转换为参与者级别的汇总、步骤编码、帮助循环记录、质量门控和研究级分析表。

9.8 VR 试点研究——补充数据

表 9.5 列出了用于描述性解读的参与者经验画像。P02 的问卷衍生字段被排除在工作负荷、信心、可用性、信任和评论汇总之外，因为可用的问卷元数据中存在内部参与者 ID 不匹配。P08 使用人工完成编码，P09 在经过试验元数据记录的纠正后被视为独立参与者。

Table 9.5: 试点参与者经验画像（自我报告）。

P	条件	组别	DCS World	F/A-18C	冷启动	VR
P01	无 tutor	新手	无	无	无	非常少
P02	无 tutor	中级	频繁	有经验	尝试过	频繁
P03	无 tutor	中级	偶尔	尝试过	尝试过	偶尔
P04	有 tutor	中级	偶尔	尝试过	尝试过	偶尔
P05	有 tutor	专家	频繁	有经验	可以完成	频繁
P06	无 tutor	专家	频繁	有经验	可以完成	频繁
P07	无 tutor	中级	偶尔	尝试过	尝试过	偶尔
P08	有 tutor	中级	偶尔	尝试过	尝试过	偶尔
P09	有 tutor	新手	无	无	无	非常少

表 9.6 列出了每位无 tutor 参与者在可用导出证据下未被确认为完成的具体步骤。它需要与第 六 章的人工错误表一起阅读，因为无 tutor 的被动记录没有运行 tutor 试验中使用的 VLM 页面检查。

Table 9.6: 无 tutor 条件下未被确认为完成的步骤。

P	未确认的步骤
P01	S09, S12, S18, S19, S20, S22, S24, S27, S29, S31
P02	S02, S14, S18, S19, S27, S30
P03	S07, S09, S16, S18, S19, S26, S27, S29, S32
P06	S07, S18, S19, S27
P07	S02, S09, S12, S13, S16, S17, S18, S19, S22, S26, S27, S28, S29, S32

S18（右侧 DDI 上的 FCS-MC BIT 页面）和 S19（FCS BIT 最终 GO 结果）在五个无 tutor 导出行中都保持未确认，且属于视觉优先的显示检查。这并不意味着五位参与者都遗漏了这两个动作。操作时间线审核发现，五位无 tutor 参与者均存在右 DDI PB5 活动，且 P02、P03、P06 和 P07 存在 FCS BIT 开关拨起活动。剩余的不确定性是页面跳转和最终 GO 结果是否在视觉上出现，因为无 tutor 的被动导出没有运行 tutor 试验中使用的 VLM/页面检查。S27（襟翼开关拨至 AUTO）同样在五个行中均未确认，但过程包将其归类为 BIOS 优先，具有变量和门控证据而非 VLM 绑定的视觉证据。因此，该表是导出确认表，而不是直接的遗漏表。

表 9.7 报告了自动编码的错误计数（人工审核前）与人工错误计数的对比，显示了在试点解读之前自动化导出需要进行多少纠正。

Table 9.7: 每位参与者的自动编码 vs. 人工错误计数。

P	条件	自动 OM	自动 CO	人工 OM	人工 CO	人工总计
P01	无 tutor	4	3	8	0	10
P02	无 tutor	0	3	0	0	1
P03	无 tutor	0	4	7	0	11
P06	无 tutor	0	3	2	0	4
P07	无 tutor	1	9	11	0	11
P04	有 tutor	0	4	0	3	7
P05	有 tutor	0	3	0	3	6
P08	有 tutor	0	3	0	0	0
P09	有 tutor	0	3	0	3	5

自动编码错误来自自动化管线（`step_coding.csv` 中的 `Auto_Error_*` 列）。人工错误来自人工审核列（`Error_*`）。P08 的自动错误在人工审核中全部被覆盖为零（参见第 6.3 节中的数据质量说明）。

表 9.8 记录了当原始导出数据与人工审核证据出现分歧时使用的补充工件权威规则。

Table 9.8: 试点补充数据质量权威规则。

案例	工件问题	权威规则	在论文中的使用
P08	<code>trial_summary.csv</code> 报告未完成的进展，而经审核的 <code>step_coding.csv</code> 标记全部 33 步已完成。	人工遥测审核和经审核的步骤编码列覆盖自动化试验汇总。	报告为完成 33/33，零人工过程性错误。
P02	问卷 JSON 存储在 P02 下，但包含 P01 的参与者 ID 元数据不匹配。	任务日志仍可使用；问卷衍生字段被排除。	纳入任务和错误表；排除在 TLX、评分和评论汇总之外。
P07	无 tutor 问卷包含 tutor 专项数值字段，尽管 tutor 专项的 NA 标志为 true。	条件和 NA 标志覆盖原始的 tutor 专项数值字段。	保留通用用户评分；tutor 评分报告为 N/A。
P04	质量门控元数据包含非阻塞的关联警告。	保留人工任务指标和帮助循环计数；不过度解读受影响的关联字段。	纳入试验概览，并注明来源注意事项。