



TU Clausthal

硕士学位论文

作者：

Yu Zhang

**解释现实：基于基础模型与视觉事实提取的
沉浸式仿真中的证据驱动程序性教学**

第一导师： Prof. Dr. Christian Bartelt

第二导师： Prof. Dr. Rüdiger Ehlers

9th June 2026

软件与系统工程研究所
克劳斯塔尔工业大学

原创性声明

本人已阅读并理解克劳斯塔尔工业大学以及 ISSE 公告中发布的各项指南，包括关于使用文献及其他来源的规定。本人确认已独立完成本论文。任何取自其他来源并在本论文中复制的信息均已明确标注。

根据通用考试条例，本论文尚未提交至任何其他考试机构。

本人特此同意，本人的硕士学位论文可在本研究所图书馆内展出并供查阅。

克劳斯塔尔-采勒费尔德，9th June 2026

地点，日期

Yu Zhang

摘要

许多对安全性和技能要求严苛的领域，包括航空、工业维修、医学以及应急操作，都要求学习者练习有序规程，其中下一步正确操作取决于当前系统状态。随着此类训练向高保真沉浸式仿真迁移，教学系统必须能够提供与上下文相关的帮助，而不能仅依赖于语言模型的流畅性。本论文通过 DCS World 中的 F/A-18C 冷启动规程来研究该问题。论文设计了一个基于证据的教学运行时系统，该系统结合了规程包状态跟踪、检索到的规程上下文，以及用于从座舱显示屏中提取结构化视觉事实的微调视觉语言模型（VLM）。两项技术发现支撑了视觉证据层。第一，8 事实本体暴露了将感知与规程完成混合在一起的复合目标所带来的风险。第二，与运行时对齐的 13 事实本体，配合小数据 LoRA 适配，在独立保留集上的主要 Qwen3.5 基础模型与 LoRA 的对比中，将关键误报降低了 64–89%。Qwen3.5-9B LoRA 适配器在 928 条双语数据行上训练，在两个保留集上达到 0.99 的事实准确率，且经验证与训练集零重叠。补充的 Qwen3.6 和 Gemma-4 结果表明该方案可应用于所评估的主干模型，但性能仍与具体主干模型相关。一项包含九名参与者的形成性 VR 试点研究提供了描述性证据：所有四名有教学辅助条件的参与者完成了全部 33 步规程，而五名无教学辅助的参与者中无人完成；有教学辅助条件下的遗漏错误被辅助耦合型错误大量取代。更大样本的受控评估仍有待未来工作。

Zusammenfassung

Prozedurales Lernen in hochrealistischer Simulation erfordert das Ausführen geordneter, zustandsabhängiger Handlungsabfolgen bei gleichzeitiger Überprüfung von Systemzuständen. Herkömmliche Trainingshilfen unterbrechen jedoch entweder die Immersion oder haben keinen Zugriff auf den Simulatorzustand. Diese Arbeit begegnet dieser Lücke durch eine telemetriegestützte Tutoring-Laufzeitumgebung, die paketbasierte Zustandsverfolgung, Retrieval-Augmented-LLM-Hilfegenerierung und ein feinabgestimmtes Vision-Language-Model (VLM) zur strukturierten Extraktion visueller Fakten aus Cockpit-Anzeigen kombiniert. Zwei technische Ergebnisse stützen die visuelle Evidenzschicht. Erstens zeigte die 8-Fact-Ontologie das Risiko zusammengesetzter Ziele, die Wahrnehmung und prozedurale Fertigstellung vermischen. Zweitens reduzierte die runtime-ausgerichtete 13-Fact-Ontologie in Verbindung mit kleiner LoRA-Anpassung kritische False-Positives um 64–89% im primären Qwen3.5-Base-gegen-LoRA-Vergleich auf unabhängigen Holdout-Sets. Der Qwen3.5-9B LoRA-Adapter, trainiert mit 928 bilingualen Datenzeilen, erreicht eine Fact-Genauigkeit von 0,99 auf zwei Holdout-Sets mit verifizierter Null-Überlappung zum Training. Ergänzende Qwen3.6- und Gemma-4-Ergebnisse zeigen, dass die Rezeptur auf die untersuchten Backbones anwendbar ist; die Leistung bleibt jedoch backbone-spezifisch. Eine kleine formative VR-Pilotstudie mit neun Teilnehmern liefert deskriptive Evidenz: Alle vier Teilnehmer mit Tutor absolvierten die vollständige 33-Schritt-Prozedur, während keiner der fünf Teilnehmer ohne Tutor dies schaffte; Auslassungsfehler wurden in der Tutor-Bedingung weitgehend durch assistenzgekoppelte Fehler ersetzt. Eine kontrollierte Evaluation mit größeren Stichproben bleibt zukünftige Arbeit.

致谢

我要感谢我的导师在本论文全过程中给予的指导与反馈。同时感谢试点研究参与者在 VR 环节中所付出的时间、耐心与认真投入。

AI 工具使用声明

在本论文的准备过程中，使用了 AI 辅助工具（包括 ChatGPT/Codex 和 Claude Code），用于语言编辑、结构调整建议、LaTeX 一致性检查、引用缺口审计以及在作者指导下检查代码仓库产物。这些工具未被用于捏造实验数据、参与者结果或文献元数据。所有声明、数值结果、引用、解释和最终措辞均由作者负责。

Contents

第一章 引言	1
1.1 动机与问题背景	1
1.2 研究缺口与问题陈述	1
1.3 研究问题	2
1.4 方法与范围	3
1.5 贡献	4
1.6 论文结构	5
第二章 背景与相关工作	6
2.1 F/A-18C 冷启动任务	6
2.1.1 程序结构: S01-S33 及阶段 P1-P6	6
2.1.2 座舱显示器与复合面板	7
2.1.3 DCS-BIOS 遥测	8
2.2 视觉事实本体	9
2.2.1 从 8 事实 v1 到 13 事实 v2	9
2.2.2 粘性事实与步骤绑定	10
2.3 智能教学系统与程序化训练	11
2.4 基于模拟器的训练与仪表化	11
2.5 基于规则与状态感知的教学	12
2.6 基础模型与 VLM 用于情境化辅助	12
2.7 AR/VR 中的可解释与基于证据的 AI 辅助	13
2.8 本工作的定位	13
第三章 系统架构	14
3.1 设计需求	14
3.2 端口-适配器架构	15
3.3 证据约束帮助循环	16
3.3.1 帮助循环各阶段	17

3.3.2	Schema 级别证据锚定	18
3.4	遥测作为状态证据	18
3.5	过程引擎与证据门控	19
3.5.1	确定性回退	19
3.5.2	按证据来源进行步骤分类	19
3.6	校验器工程与证据验证	20
3.6.1	基于 Fixture 的回归测试	20
3.7	适配器边界：模拟器、覆盖层与视觉	20
3.8	事件日志与回放	21
3.9	VLM 视觉证据适配器	21
3.10	本章小结	22
第四章	方法论	23
4.1	过程运行时与遥测锚定	23
4.1.1	变量解析与来源缺失追踪	23
4.1.2	门控规则评估	23
4.1.3	增量清洗与聚合	24
4.1.4	确定性回退	24
4.2	知识锚定与来源策略	24
4.3	视觉事实数据管线	24
4.4	数据集构建	26
4.4.1	数据集概览	26
4.4.2	本体演进：从 8-Fact v1 到 13-Fact v2	27
4.4.3	训练方案：Run-003 + Run-005×2	27
4.4.4	留出集独立性	29
4.5	LoRA 微调配置	29
4.5.1	骨干模型与对比策略	29
4.5.2	训练栈与超参数	29
4.5.3	双语 SFT 与组合再平衡	30
4.6	基准测评协议	30
4.6.1	度量指标	30
4.6.2	基础模型与 LoRA 对比	31
4.6.3	基准测评类别	31
4.6.4	基准测评工件	31

4.7	人类受试者先导研究方法论	31
4.7.1	参与者与条件	31
4.7.2	任务与设备	32
4.7.3	数据来源与编码	32
4.7.4	数据质量说明	32
4.7.5	分析方法	32
4.8	本章小结	32
第五章	实现	33
5.1	运行时边界与配置	33
5.2	证据根基执行	34
5.3	确定性降级	35
5.4	VLM 视觉事实提取运行时	35
5.5	回放与日志基础设施	36
5.6	实时运行时编排	36
第六章	评估	37
6.1	RQ2: VLM 技术评估	37
6.1.1	数据集与训练概览	37
6.1.2	Qwen3.5 13 事实 V2 结果	39
6.1.3	Gemma-4 与 Qwen3.6 骨干对比	39
6.1.4	错误分析	40
6.2	RQ1: 系统级技术就绪性	40
6.2.1	回放评估	41
6.2.2	Harness 夹具回归	41
6.2.3	实验导出基础设施	41
6.3	RQ3: 形成性 VR 试点研究	41
6.3.1	参与者与试验概览	42
6.3.2	程序性错误	42
6.3.3	教学交互	43
6.3.4	数据质量注记	44
6.3.5	试点发现总结	44
第七章	讨论	45
7.1	从提案到实现系统的演变	45

7.2	技术证据的解读	46
7.2.1	技术证据未能证明的内容	46
7.3	试点发现的解读	47
7.4	本体设计经验	48
7.5	局限性	48
7.5.1	评估范围	49
7.5.2	系统与 VLM 范围	49
7.5.3	试点范围	49
7.5.4	范围总结	50
7.6	未来工作	50
7.6.1	受控人类受试者评估	50
7.6.2	向其他程序的本体扩展	50
7.6.3	时序与多帧视觉推理	50
7.6.4	系统级帮助循环评估	50
7.6.5	原位纠正与自适应	51
7.6.6	未来方向总结	51
第八章	结论	52
8.1	已完成工作总结	52
8.2	未来工作	53
参考文献		55
第九章	附录	58
9.1	完整 LoRA 超参数配置	58
9.2	8 事实 V1 基线基准测试	58
9.3	数据集事实分布	58
9.4	CLI 命令参考	60
9.5	模型提供方配置	61
9.6	回放评估套件	61
9.7	补充架构与导出图表	61
9.8	VR 试点研究 — 补充数据	65

List of Figures

2.1	F/A-18C 冷启动任务的证据来源。33 步骤程序结合了遥测可见步骤、视觉优先的显示检查以及少量手动或超出布局范围的确认；下游教学决策立足于相应证据来源，而非仅仅依赖语言模型的输出。	8
3.1	证据约束教学架构	16
3.2	实时证据约束帮助循环。每一次帮助请求被转换为遥测和视觉观测，对照过程门控进行解释，通过检索到的知识进行锚定，经过文本 LLM 处理后由校验器验证，然后以覆盖层/文本输出形式分发，并附带事件日志追踪。	17
4.1	VLM 适配管线。DCS 复合截图经预标注、人工审核，转换为双语监督微调数据行，通过 LoRA 进行适配，在独立留出集上评估，并用于驱动本体修订。	25
4.2	从 8-fact v1 到 13-fact v2 的本体演进。诸如 <code>ins_go</code> 和宽泛的 FCS-MC 完成事实等复合目标被分解为局部可验证的视觉原子；过程引擎随后将这些观测与遥测、阶段和时间证据结合。	28
6.1	跨研究问题的评估与数据流。VLM 基准测试产物支撑 RQ2, 回放和 Harness 日志支撑 RQ1 技术就绪性，VR 试点导出数据支撑描述性 RQ3 发现。	38
9.1	安全约束与证据验证。候选教学系统动作在被接受为叠加层动作计划之前，需经过 Schema 约束、UI 白名单、证据一致性和程序状态的检查；不安全或证据不够充分的动作将被修复、拒绝或降级为纯文本指导。	62
9.2	原型所使用的部署拓扑。仿真器、Quest 3 叠加层通道、本地运行时、回放工具和远程模型提供方被区分开来，使得实时试验和离线分析可以使用相同的证据和日志记录契约。	63
9.3	详细的实验导出流水线	64

List of Tables

4.1	用于视觉事实提取的数据集清单。	27
6.1	标注视觉事实数据集概览。	38
6.2	13 事实 v2 基准测试: Qwen3.5-9B Base vs. LoRA 在两个保留集上。 . .	39
6.3	三种骨干上的 13 事实 v2 结果 (仅 LoRA 模型)。	40
6.4	参与者与试验概览。观察时长为从第一次遥测事件到最后一次的挂钟间隔; 对未完成试验而言, 它不是完成时间的度量。	42
6.5	每参与者人工程序性错误计数 (来自人工步骤编码)。OM = 遗漏, CO = 执行错误, OR = 顺序错误, PA = 提示/辅助错误, SV = 状态违反。	43
6.6	教学交互摘要 (仅导师辅助条件)。	43
7.1	未来工作方向总结。	51
9.1	三种骨干的完整 LoRA 微调超参数。	59
9.2	8 事实 v1 基准测试: Qwen3.5-9B 基座 vs. LoRA-v1 在 Run-002 留存集上的对比 (50 样本, EN)。	59
9.3	训练集与留存数据集中每个事实的 seen 计数 (13 事实 v2 本体)。 . . .	60
9.4	回放评估案例。	61
9.5	试点参与者经验概况 (自报告)。	65
9.6	无教学系统辅助条件下未完成的步骤 (手动编码)。	65
9.7	每位参与者的自动编码 vs. 手动错误计数。	66

第一章 引言

1.1 动机与问题背景

许多对安全性和技能要求严苛的领域要求人们学习有序规程，其中下一步正确操作取决于系统当前状态。例如飞机座舱规程、工业维修、应急操作以及医疗或技术设备工作流。在此类场景中，规程知识不仅是操作列表，还包括前置条件、中间检查、状态依赖的分支，以及从部分完成或错误完成的步骤中恢复。

高保真沉浸式仿真使这些规程可用于练习，而无需将学习者暴露于真实环境的风险和成本之中。与此同时，高保真度也带来了教学难题。已经置身于模拟座舱、机器或规程室内的学习者需要的可能是针对当前状态的帮助，而非对任务的一般性解释。如果学习者必须离开仿真环境去查阅手册、视频或检查单，训练流程就会中断。如果学习者转而向语言模型求助，其回答可能流利流畅，却与仿真中真实存在的状态脱节。

本论文通过 DCS World 中的 F/A-18C 冷启动规程来研究该问题。飞行仿真场景被用作一个具体而高要求的案例研究，而非声称该研究问题仅存在于航空领域。该案例的用处在于它使证据问题可视化：规程推进取决于开关状态、发动机参数、告警灯、座舱显示页面以及先前操作的完成顺序。这些状态中有些可通过遥测直接观测；有些需要对座舱显示器进行视觉检查；少数则需要人工确认或位于视觉管线所使用的显示布局之外。

当前规程包包含 33 个有序步骤 (S01-S33)，分为六个操作阶段，从初始供电到发动机启动、航电配置、飞控检查，直至最终的滑行前配置（第 2.1 节）。本论文报告的基准测试和 VLM 评估聚焦于原始的 25 步核心规程；后续扩展到 S33 增加了进一步的滑行前检查，但未改变核心证据问题。这使得冷启动成为高保真仿真中状态依赖型规程教学的一个紧凑而有代表性的案例。

1.2 研究缺口与问题陈述

现有训练辅助工具和近期的基础模型系统各自解决了问题的一部分，却留下一个重要缺口。手册、视频和检查单提供了权威的规程知识，但它们无法观察学习者在仿

真器中的当前状态。传统仿真器遥测能够暴露许多状态，但其本身并不能解释学习者下一步应做什么，也无法解读未导出为数据的显示内容。基础模型能够生成灵活的解释，但其输出用于规程引导时的可靠度不足，除非受到显式证据的约束。

本论文的核心前提是：当每一个可执行的教学输出都与一个显式证据源绑定时，规程辅助会变得更可靠、更可审计。在本论文所开发的系统中，此类证据可以是遥测量、规程门控评估、检索到的手册或检查单片段，或由 VLM 得出的视觉事实。因此，语言模型并不被要求仅凭参数化知识推断规程状态。它在一个运行时环境内运作，该环境提供状态证据、检查结构化输出、校验叠加层目标，并记录生成的帮助周期以供回放和分析。

这一框架改变了基础模型的角色。模型本身并非教师，而是基于证据的规程教学运行时中的一个组件。因此，研究问题既是架构性和方法性的，也是生成性的：应如何将仿真器遥测、规程规则、检索和视觉事实提取连接起来，使生成的帮助保持状态感知、可检查，并受限于可用证据？

1.3 研究问题

本论文由一个主研究问题和三个子问题引导：

主研究问题。 基于证据的多模态教学系统如何支持高保真沉浸式仿真中的状态依赖型规程训练？

RQ1 ——系统架构与证据集成。 如何将仿真器遥测、检索到的规程知识和视觉事实观测集成起来，使教学输出具有状态感知能力、可审计且对规程引导安全？

RQ2 ——VLM 适配与本体设计。 小数据 LoRA 适配的 VLM 在多大程度上能够可靠地提取结构化座舱视觉事实？视觉事实本体设计如何影响关键误报？

RQ3 ——形成性 VR 试点证据。 在基于 VR 的 F/A-18C 冷启动训练任务中，一项小型试点研究在有教学辅助与无教学辅助的对比中，为任务完成、规程错误和教学交互提供了哪些形成性证据？

RQ1 和 RQ2 通过已实现的运行时、回放与测试基础设施以及技术基准评估来回答。RQ3 通过一项已完成的形成性 VR 试点研究 ($n = 9$) 来回答。该试点被视为关于可行性、仪器化、完成度和错误模式的描述性证据；不用于宣称受控的学习收益、工作负荷降低、记忆保持或迁移效果。

1.4 方法与范围

本论文通过构建和评估一个用于 F/A-18C 冷启动案例的基于证据的教学运行时来回答研究问题。该方法结合了四条证据通道。第一，DCS-BIOS 遥测为许多座舱控制器、指示灯以及发动机或系统数值提供了最权威的信号。原始 UDP 帧经过规范化、清洗和聚合，形成稳定的运行时变量，使规程门控能够区分假值和缺失的源信号。第二，在遥测不充分的地方，视觉事实层将座舱显示屏截图转换为具有 `seen`、`not_seen` 或 `uncertain` 状态的结构化事实。第三，检索到的规程来源为解释提供文本支撑。第四，规程包门控定义了步骤被视为可用或完成之前需要哪些证据。

帮助周期被有意地加以约束。运行时在模型生成之前组装一个证据包，包含当前规程候选步骤、遥测状态、视觉观测和检索到的来源。LLM/VLM 的输出随后根据运行时生成的 JSON Schema 约束进行校验，并通过白名单叠加层目标进行映射。如果模型路径不可用或无效，系统将回退到确定性的纯文本引导。该设计使帮助周期可审计：后续回放可以检查哪些证据可用、推断出哪个步骤、模型返回了什么、响应在显示前是如何校验的。

研究范围被有意地加以限制。本论文从技术上验证了架构和视觉事实管线，并报告了一项已完成的形成性 VR 试点研究。论文不声称该系统已确立受控的学习收益、工作负荷降低、记忆保持、迁移效果或跨所有规程领域的通用性。F/A-18C 案例被用于使证据锚定问题变得具体和可衡量。将该方法扩展到其他飞机、工业设备、医疗训练任务或应急规程，将需要新的规程包、证据映射和领域特定的验证。

在此边界内，论文范围包括三个方面：

1. 设计并实现基于证据的教学运行时，结合了 DCS-BIOS 遥测、规程包门控、检索到的规程知识、VLM 导出的视觉事实、结构化响应校验、叠加层显示、日志记录和回放（第 三、四和五章）；
2. 通过独立保留集基准测试和跨主干模型对比对视觉事实适配管线进行技术验证（第 六章，第 6.1和6.1.3节）；
3. 一项已完成的形成性 VR 试点研究（ $n = 9$ ），提供了在有教学辅助和无教学辅助条件下关于任务完成、错误模式、教学交互和仪器化就绪情况的描述性证据（第 六章，第 6.3节）。

规程定义、门控、遥测映射、视觉事实绑定和错误分类法均保存在声明式规程包配置中，而非嵌入提示词中。这种基于包的设计使架构与整洁/六边形原则保持一致：领域规则与仿真器适配器、视觉适配器、模型适配器和导出工具保持分离。

1.5 贡献

本论文做出三项贡献。

1. **基于证据的教学架构**。本论文提出了一个端口-适配器教学运行时，其中每个可执行的帮助输出都必须可追溯到遥测数据、规程门控评估、检索到的来源或视觉事实。贡献不仅在于将 LLM 连接到仿真器，更在于将生成式教学置于一个受约束的帮助周期中，具备声明式规程包、经 Schema 校验的响应、白名单叠加层目标、确定性回退和可回放日志。该贡献回答 RQ1，内容见第 三和五章，验证证据见第 六章第 6.2 节。
2. **视觉事实本体与小数据 VLM 适配**。本论文为 F/A-18C 座舱显示状态开发了一个 13 事实视觉本体，该本体由一个 8 事实基线演进而来，基线暴露了要求 VLM 直接识别复合规程状态的弱点。修订后的本体将此类目标分解为局部可观察的视觉原子，将规程解释留给下游规则。相关数据管线涵盖 DCS 截图采集、AI 预标注、人工审查、双语 SFT 数据行生成、LoRA 微调和独立保留集基准测试。在 Qwen 主干模型上，以 928 条双语数据行训练的 LoRA 适配器在两个独立保留集上达到约 0.99 的事实准确率，并将关键误报相对于对应基础模型降低了 64–89%。补充的 Qwen3.6 和 Gemma-4 结果表明该方案可应用于所评估的主干模型，但性能仍与具体主干模型相关。该贡献回答 RQ2，内容见第 三和四章，评估见第 六章第 6.1.2 和 6.1.3 节。
3. **VR 评估框架与形成性试点**。本论文提供了研究基于证据的规程教学所需的全套仪器化工具，以支持真实参与者实验：实验导出工具、基线和教学辅助条件配置、会话启动支持、可回放日志、半自动预评分、错误编码指南和实验操作手册。一项形成性 VR 试点研究 ($n = 9$) 已实施，其中四名参与者有教学辅助，五名无教学辅助。所有四名教学辅助条件下的参与者完成了全部 33 步规程，而五名无教学辅助的参与者中无人完成。观察到的错误模式也不同：教学辅助条件下的错误主要是辅助耦合型，而无教学辅助条件下的错误主要是遗漏型。这些结果支持可行性和仪器化方面的声明，但不支持关于学习效果的受控声明。该贡献回答 RQ3，内容见第 六章第 6.3 节及附录 九。

综合来看，这些贡献界定了本论文的边界。本工作表明，基于证据的教学可以被工程化实现、基准测试，并在一个高要求仿真器规程的形成性 VR 研究中进行演练。论文不声称在该形成性证据之外已确立了教育有效性。

1.6 论文结构

第二章解释了为什么 F/A-18C 冷启动任务需要多种证据源，并介绍了视觉事实本体。然后将本论文与教学辅导、仿真器仪器化、状态感知辅助、VLM 适配以及基于证据的 AR/VR 系统等相关工作进行定位对照。

第三章介绍了基于证据的架构，包括端口-适配器结构、运行时数据流、规程与门控模型、遥测处理、回放基础设施和 VLM 组件。

第四章描述了用于创建和验证证据链的方法：遥测锚定、知识检索与来源策略、视觉事实数据收集、本体演进、LoRA 微调和保留集基准测试设计。

第五章记录了使架构可运行的实现选择，包括核心领域逻辑、适配器边界、结构化帮助生成、叠加层映射、VLM 集成和实验工具。

第六章通过三条证据线评估论文声明：针对 RQ2 的 VLM 基准测试、针对 RQ1 的回放与测试就绪性，以及针对 RQ3 的形成性 VR 试点证据。

第七章对结果进行解读，从本体修订中提炼设计教训，讨论范围边界，并阐明局限性与未来工作。

第八章对照研究问题总结已完成的工作，并重申论文的声明边界。

附录 九包含补充图表、基准测试表格、数据集统计、超参数配置、CLI 参考和 8 事实基线基准测试。

第二章 背景与相关工作

前一章将论文围绕一个需求展开：生成的程序化帮助应立足于可被检查的证据，并且这些证据在学习者收到帮助前后均可被审查。本章解释该需求为何在 F/A-18C 冷启动任务中产生，以及它与现有工作的关系。第一部分介绍任务本身、可用的证据通道，以及将座舱截图转化为结构化观察的视觉事实本体。第二部分将本论文置于智能教学系统、基于模拟器的训练、基于规则的状态追踪、VLM 适配以及 AR/VR 中基于证据的辅助等研究领域的交叉点上。

2.1 F/A-18C 冷启动任务

本论文研究的程序化场景为 DCS World 中的 F/A-18C 冷启动——一项将飞机从冷舱、不通电状态推至滑行就绪状态的前置座舱程序 [7, 8]。该任务适合作为研究案例，因为它既有界又对状态敏感。它有一组已知操作顺序，但成功完成取决于一些无法简化为文本检查单的中间状态：在启动发动机之前必须先建立电源；在启动第二台发动机之前，发动机参数必须进入标称范围；座舱显示器必须显示预期的页面；某些检查只有在较早的系统转换完成之后才具有意义。

因此，对教学系统而言，冷启动的相关属性并不只是其步骤长度，而在于该程序迫使教学系统综合三类证据：关于哪些步骤已完成的序列证据、关于座舱控制器和仪表状态的遥测证据，以及关于显示页面内容的视觉证据。一个忽视其中任意一类信号的响应可能在局部表达流畅，但在程序层面是错误的。

2.1.1 程序结构：S01–S33 及阶段 P1–P6

当前程序包将冷启动表示为 33 个编号步骤 (S01–S33)，分为六个阶段。本论文使用该阶段结构来简洁描述任务对证据提出的需求：

P1 (S01–S03)： 上电与安全检查。电池及发电机启动、火警探测测试和 APU 启动为后续程序奠定了最初的电气与安全前置条件。

P2 (S04–S07): 右发动机启动。右发动机盘车、油门推进、引气循环以及注意/警告/提示灯测试引入了依赖遥测的时序与验证。

P3 (S08–S09): 显示器与通信。DDI、AMPCD、HUD、显示页面以及 COMM1 预置配置使显示状态成为程序证据链的一部分。

P4 (S10–S14): 左发动机与核心系统。左发动机启动、INS 对准模式选择、雷达开机和 OBOGS 激活均依赖于较早的发动机和航电状态。

P5 (S15–S27): FCS 与飞控。FCS 复位与 BIT、襟翼/配平配置、弹射杆和拦阻钩检查、受油管检查以及空速管加温配置将遥测可观测的控制动作与基于显示的确认相结合。

P6 (S28–S33): 滑行前仪表与最终检查。停机刹车、BINGO 燃油、高度表调校、备用姿态指示仪开锁以及姿态源选择完成滑行就绪状态。

每个步骤在程序包中均以前置条件和完成门控来表示。这些门控明确规定了教学系统在将某个步骤视为可用或完成之前，哪些前置步骤和哪些状态变量必须得到满足。例如，右发动机盘车步骤依赖于 APU 的支持，而左发动机启动则依赖于右发动机参数（如转速、温度、燃油流量、喷口位置和滑油压力）进入标称范围。正因如此，该任务是验证基于证据的帮助的有效测试案例：一个仅凭检查单顺序推进学习者的教学系统可能会忽略实际的飞机状态。

2.1.2 座舱显示器与复合面板

冷启动中的许多状态在 F/A-18C 的座舱显示器上可见，而非直接作为简单的遥测变量提供。因此，视觉管线操作于一个包含三个显示区域的固定复合面板图像之上：

- **左 DDI (数字显示指示器):** 在程序中用于诸如 FCS、SUPT 和 TAC 等页面。在评估的冷启动流程中，FCS 页面及 FCS 页面标记是重要的视觉确认。
- **AMPCD (先进多用途彩色显示器):** 用于 HSI 页面、地图图层和 INS 对准文本。这些状态对与对准相关的视觉事实至关重要。
- **右 DDI:** 用于 BIT 根页面和 FCS-MC BIT 序列，包括中间状态、测试进行中和最终 GO 状态。


使用复合图像使训练与推理保持一致：模型在数据集构建、基准测试和运行时采集过程中看到的是相同的三显示器布局。更重要的是，复合面板定义了一个狭窄的感知边界。VLM 不需要解释整个 VR 场景，也不需要推断飞行员的意图，而只需报告特定的座舱显示事实在已知区域中是否可见。

2.1.3 DCS-BIOS 遥测

DCS-BIOS 为运行时提供了主要的非视觉证据来源。它通过 UDP 遥测流从 DCS World 导出座舱开关位置、指示器、警告灯、仪表和其他仪器状态 [6]。教学运行时将该流标准化为稳定的变量，如 `rpm_r`、`apu_ready` 和 `ins_mode`，并应用差值消抖以减少抖动，同时追踪某个数据源是缺失而非仅仅为假。

在遥测可覆盖的范围内，该通道具有权威性。诸如电池电源、油门动作、雷达模式和许多最终滑行前开关状态等步骤无需计算机视觉即可检查。然而，DCS-BIOS 并不导出冷启动教学系统所需的所有显示页面内容。因此，运行时仅将视觉用于遥测无法观测的状态，例如 FCS 页面、BIT 根页面、FCS-MC BIT 结果或 INS 对准文本是否可见。图 2.1 总结了这一证据分工在 33 个步骤中的分布。

F/A-18C cold-start evidence sources



The task cannot be grounded by language alone because completion evidence comes from mixed sources.

Figure 2.1: F/A-18C 冷启动任务的证据来源。33 步骤程序结合了遥测可见步骤、视觉优先的显示检查以及少量手动或超出布局范围的确认；下游教学决策立足于相应证据来源，而非仅仅依赖语言模型的输出。

2.2 视觉事实本体

视觉事实本体是感知与程序推理之间的契约。运行时并非要求 VLM 直接输出诸如"学习者下一步应按此按钮"之类的教学决策,而是要求其产生一小组关于可见座舱显示状态的结构化命题。每个事实是一个离散观察,具有以下三种取值之一:

seen: 指定的视觉证据清晰存在;

not_seen: 指定的视觉证据不存在或不可辨识;

uncertain: 图像质量、遮挡、裁剪或显示状态不足以做出有信心的判断。

这一表示方式有意避免了将感知与任务解释混为一谈。VLM 报告视觉证据是否可见,程序引擎随后将这些事实与遥测数据、序列状态和步骤绑定结合起来,以判断某个步骤是已确认、待定还是被阻止。因此,该本体并非一个次要的实现细节;它界定了模型被允许做出的断言类型。

2.2.1 从 8 事实 v1 到 13 事实 v2

该本体经历了两代演进。第一版包含覆盖左 DDI、右 DDI 和 AMPCD 的八个事实。它包括了有用的显示级目标,如 FCS 页面可见性、BIT 页面可见性、FCS-MC 页面状态和 INS 对准页面可见性,同时也包含了诸如 `ins_go` 这样的复合目标,要求模型从单一视觉帧中推断出一个高层的程序完成状态。

这一设计产出了一个清晰的教训。基于 180 张人工审核过的 Run-001 图像训练的第一个 LoRA 适配器虽然在分布内行为有所改善,但在独立的 Run-002 保留集上产生了严重的误判:在 50 个样本中有 13 个样本被预测为 `ins_go` 的 `seen`,而人工标签为 `not_seen`。这一错误不仅是模型的失败,更暴露了目标本身的设计问题:`ins_go` 将视觉感知与程序解释混为一谈。

第二代本体用 13 个可观察的视觉原子替代了此类复合目标:

区域	视觉事实
左 DDI	tac_page_visible
左 DDI	supt_page_visible
左 DDI	fcs_page_visible
左 DDI	fcs_page_x_marks_visible
右 DDI	bit_root_page_visible
右 DDI	fcsmc_page_visible
右 DDI	fcsmc_intermediate_result_visible
右 DDI	fcsmc_in_test_visible
右 DDI	fcsmc_final_go_result_visible
AMPCD	hsi_page_visible
AMPCD	hsi_map_layer_visible
AMPCD	ins_grnd_alignment_text_visible
AMPCD	ins_ok_text_visible

重要的变化不只是标签数量的增加，而在于本体从程序级判断转向了可观察的证据。例如，v1 的 `ins_go` 目标被分解为上表中所示的 AMPCD 文本和地图图层观察，程序引擎随后决定这些观察如何与对准步骤关联。这一设计原则承载了论文 VLM 部分的主要科学洞察：VLM 应提取局部视觉证据，而程序含义应由显式的下游规则来赋予。

2.2.2 粘性事实与步骤绑定

两种运行时机制使本体在实时帮助周期中可用。

粘性事实。 某些视觉事件是瞬态的，但在程序上具有重要意义。例如，`fcsmc_final_go_result_visible` 事实被标记为粘性，有效期为 600 秒。一旦它被观察为 `seen`，后续帧中出现的 `not_seen` 或 `uncertain` 不会立即清除该证据。这防止了已完成的视觉事件仅仅因为学习者切换了页面、显示器闪烁或采集窗口错过了相关时刻而消失。非粘性事实（如页面可见性事实）则快速过期并被持续重新评估。

步骤绑定。 视觉事实仅通过 `vision_facts.yaml` 中的显式绑定才具有程序意义。绑定指定了某个步骤要被视觉确认所必须可见的事实。某些绑定要求所有列出的事实同时满足，例如 S08 同时要求左 DDI 上的 FCS 页面和右 DDI 上的 BIT 根页面。其他绑定则在多个视觉线索可以支撑同一程序状态时允许选择其一。

程序包还根据每个步骤的首选证据来源对其进行分类：

- `bios_priority_steps` 用于遥测可见的状态；
- `vision_priority_steps` 用于依赖显示的状态；

- `manual_or_out_of_layout_steps` 用于需要人工确认或超出三显示器复合面板范围的状态。

这一分类是论文基于证据原则的实际表达：每个步骤在被用于教学之前，都要经过最可靠可用信号的校验。

2.3 智能教学系统与程序化训练

智能教学系统 (ITS) 为本工作提供了最接近的教育范式先例。经典的 ITS 研究区分专家知识、学习者状态和教学反馈，并已证明基于步骤的计算机教学系统在结构化学习领域中具有有效性 [21]。在程序化情境中，基于约束和示例追踪的教学系统对期望行为进行建模，并将学习者行为与作者编写的任务知识进行比对 [2, 17]。这些思想直接启发了本论文中程序包和门控规则的使用。

区别在于观察接口。许多 ITS 运行在学习者行为已表示为形式化事件的环境之中，而本工作所用的模拟器并非面向教学系统原生设计。运行时必须从 DCS-BIOS 遥测、截图、序列历史和偶发的人工确认中推断程序状态，这使得证据整合本身成为教学问题的一部分。

LLM 带来了进一步的张力。它们能够产生流畅且灵活的教学对话，近期的教育讨论既认识到其潜力，也认识到其可靠性风险 [13]。对于座舱程序而言，仅凭流畅是不够的。因此，本论文的贡献并非一个开放式的 LLM 教学系统，而是一个受约束的教学运行时：其中生成的语言位于证据采集、检索、程序推理和验证的下游。

2.4 基于模拟器的训练与仪表化

基于模拟器的航空训练是一个成熟的领域，已有研究考察了模拟如何支持飞行训练情境中的技能习得与迁移 [11]。DCS World 提供了本论文所使用的高保真仿真环境 [7]。对本工作而言，相关的研究问题是仪表化：教学系统如何在不用自定义教学接口替换模拟器的前提下，观测学习者和飞机正在做什么。

DCS-BIOS 通过一个结构化的遥测桥接暴露座舱状态，部分解决了这一问题 [6]。与单纯的屏幕采集相比，遥测提供了对许多开关位置、指示器状态和数值的确定性访问。然而，遥测并不覆盖冷启动所需的每一条证据，尤其是显示页面内容和文本。因此，本论文将模拟器仪表化视为一个多模态问题：在遥测可靠且直接的地方使用遥测，而视觉则保留用于遥测不导出的座舱证据。

这种分工也改善了可审计性。一个记录下来的帮助周期事后可以展示哪些状态来自 DCS-BIOS、哪些事实来自 VLM、哪条规则使某个步骤具备资格或处于阻塞状态，

以及哪些检索到的来源支撑了所生成的解释。仪表化因此不仅是一个工程需求，更是评估教学系统行为的前提条件。

2.5 基于规则与状态感知的教学

教学运行时将确定性状态追踪与模型生成的语言相结合。基于规则的程序追踪方法——包括有限状态机、产生式规则和面向约束的模型——因其显式地呈现任务结构而具有可解释性。本论文的程序包遵循这一原则：步骤、前置条件、完成门控、视觉绑定和错误分类均以声明式配置形式编写，而非隐藏在提示词中。

纯规则式教学系统的局限性在于，当学习者在意外状态下请求帮助或需要解释而非二元纠错时，预编写的反馈可能变得脆弱。因此，运行时将自然语言的构造委托给 LLM，但不将决定程序状态的权力交给它。步骤推理、资格判定、证据可用性和覆盖层白名单均保持在确定性控制之下。

这种混合分工与将语言模型基于行动可行性和符号结构的更广泛研究相关，例如将语言基于机器人能力的 SayCan 式工 [1]。本论文将这种基于直觉扩展到模拟器教学中：在一个生成的响应得以执行之前，必须将其与运行时能够观察、验证和回放的证据绑定在一起。

2.6 基础模型与 VLM 用于情境化辅助

基础模型提供了两种对情境化教学有吸引力的能力：语言模型可以生成灵活的解释，视觉语言模型可以从座舱图像中提取信息。参数高效微调方法，特别是低秩适配 (LoRA)，使得用有限的课训练参数将大型模型适配到狭窄任务上成为可能 [12, 16]。本论文使用的模型骨干网络和 VLM 文献为这一适配环境提供了一般技术背景 [4, 5, 15]。

本论文以受限的方式使用这些能力。VLM 不负责生成自由形式的座舱描述，LLM 也不负责凭空推断下一个程序状态。相反，VLM 输出结构化的 JSON 视觉事实，帮助生成模型接收由运行时组装好的证据包。这一选择遵循了与检索增强生成相同的一般动机：模型输出应以显式外部证据为条件，而非仅依赖参数化记忆 [14]。

座舱显示任务也与结构化屏幕理解类似。针对 GUI 和屏幕内容理解的研究表明，视觉模型可以对固定区域、标签和符号化布局进行推理 [23]。座舱显示器具有相同的结构化特征，但教学环境对误报施加了更严格的后果：一个 VLM 如果错误地将关键显示状态报告为可见，可能导致教学系统在错误的时间推进学习者。正因如此，本体设计和关键误报分析在本论文中被视为核心方法论问题，而非次要的基准细节。

2.7 AR/VR 中的可解释与基于证据的 AI 辅助

初始提案曾将教学系统部署于沉浸式 Quest 3 座舱体验中，所实现的系统通过 VR 先导研究保留了这一评估方向。先前关于面向维护和程序化任务的 AR 指导的研究展现了在用户任务情境中呈现指令的价值，通常通过空间注册的文本、箭头或动画来实现 [18]。这类系统说明了情境内指导为何有吸引力：学习者可以将注意力保持在任务环境上，而无需切换到外部材料。

本文研究的系统不同于预编写的 AR 指导，因为它生成的帮助内容是在运行时根据当前证据动态产生的，这使得可解释性和可追溯性成为核心议题。关于可解释 AI 和人机交互的工作强调，用户和开发者需要理解系统为何产生了某个推荐，尤其是在高风险或安全敏感的场景下 [3, 9]。在本论文中，解释需求通过证据引用得以具体落实：每个被推荐的步骤、覆盖层目标或拒绝推进的决定都可以追溯至遥测、某条规则、某个视觉事实或某条检索到的来源。

这种基于证据的要求也限制了关于 VR 的声明。第 六 章中的先导研究表明，运行时和仪表化可以在 VR 中由真实参与者验证运行，但该研究并未建立受控的教育效果。因此，VR 的贡献属于评估框架和形成性证据的一部分，而论文的主要声明仍然是基于证据的教学运行时的设计与验证。

2.8 本工作的定位

本论文位于上述各个领域的交叉点上，但其贡献在于特定的集成方式，而非单纯归属于任何单一领域。从智能教学系统中，它汲取了对显式任务模型和状态敏感反馈的需求。从模拟器训练中，它汲取了在高保真环境中观测真实学习者行为所需的仪表化能力。从基于规则的辅助中，它汲取了确定性程序门控。从基础模型工作中，它汲取了灵活的语言生成和领域适配的视觉提取能力。从可解释性及 AR/VR 辅助中，它汲取了帮助在情境中保持可审查性的要求。

所得到的系统是一个基于证据的程序化教学运行时。其程序包定义了什么算作有效的状态证据；DCS-BIOS 在可用处提供遥测；视觉事实本体在遥测缺失处提供结构化的座舱显示观察；检索提供程序化源材料；帮助周期通过验证、白名单、回退、日志记录和回放来约束模型输出。这是本论文后续章节中发展的研究立场。

声明边界同样重要。技术章节和基准测试评估了该架构和视觉事实管线是否能够为教学产生可靠、可审计的证据。形成性 VR 先导研究提供了关于可行性、任务完成情况、错误模式和仪表化在真实参与者中的描述性证据。在能够对学习收益、工作负荷降低、记忆保持或技能迁移做出声明之前，仍需要更大规模的受控研究。

第三章 系统架构

本章从架构层面回答 RQ1：如何将模拟器遥测、检索到的过程性知识以及视觉观测整合在一起，使得教学输出保持状态感知、可审计且对过程性引导安全？核心设计决策是将基础模型的输出视为证据约束运行时中的一个阶段，而非教学者本身。每一条帮助响应都由显式证据包生成，对照过程包规则进行检查，由校验器验证，通过覆盖层白名单映射，并记录以供回放。

本章首先从证据锚定问题出发推导设计需求。随后介绍端口-适配器架构、实时帮助循环、遥测与过程门控证据层、校验器验证机制、模拟器适配器边界、日志与回放基础设施，以及 VLM 衍生视觉事实的运行时角色。数据集构建与 VLM 微调方法论留待第 四 章讨论；实现层面的细节见第 五 章。

3.1 设计需求

基于证据的过程性教学对系统提出了与传统清单式应用或不受约束的 LLM 聊天机器人截然不同的需求。运行时必须观测状态、根据过程顺序进行推理、以语言解释帮助内容，同时防止未经支持的覆盖层操作到达学习者。以下六项需求指导架构设计。

- **G1 – 实时过程状态观测。**教学者必须通过模拟器状态（而非仅靠学习者自述）来观测学习者的进度。在 F/A-18C 场景中，这意味着在有结构化数据导出的地方使用 DCS-BIOS 遥测，在座舱显示状态未以结构化数据形式导出的地方使用视觉事实。
- **G2 – 过程感知的步骤推断。**教学者必须基于前置条件、完成门控和序列历史进行推理。下一个有用的帮助条目不一定是清单上的下一行，而是在当前证据下有效的下一个操作。
- **G3 – 可操作输出的显式证据。**每一个推荐的步骤、覆盖层目标或拒绝推进的决定都必须可追溯到证据：遥测数据、门控结果、检索到的过程性来源、最近的状态变化或视觉事实。仅凭模型流畅的语言输出不足以作为证据。

- **G4 – 清晰的架构边界。**领域逻辑必须独立于模拟器 API、模型提供方、GPU 可用性以及 VR 显示管道。这使得核心过程逻辑和验证逻辑可以在没有运行中模拟器的情况下进行测试。
- **G5 – 优雅降级。**当模型输出不可用、格式错误或证据锚定不足时，运行时必须回退到确定性文本引导或安全拒绝，而非执行不安全的覆盖层操作。
- **G6 – 声明式过程配置。**过程步骤、门控、遥测映射、UI 目标、视觉事实绑定以及错误分类标准必须表示为一个过程包，而非隐藏在提示词或适配器代码中。这使得任务模型可检查且可版本控制。

这些需求解释了为什么系统被设计为证据管线。该架构并不试图让语言模型本身足够可靠以独立行动，而是用显式状态证据、声明式规则、Schema 验证、白名单和可回放日志来包围模型的生成过程。

3.2 端口-适配器架构

运行时遵循端口-适配器架构，依赖方向严格：外部系统通过适配器连接，适配器实现稳定的端口，核心层包含过程逻辑和验证逻辑。核心层绝不导入 DCS 特定、提供方特定或 VR 特定的模块。这一边界对论文的核心论点至关重要，因为证据锚定必须能够在脱离实时模拟器的条件下进行测试和检查。

核心层 (Core layer). 核心层包含与模拟器无关的领域逻辑：过程状态追踪、门控评估、视觉事实状态合并、BM25 检索原语、事件类型、响应 Schema 生成、证据包构造、校验器验证、评分以及面向回放的状态检查。

端口层 (Ports layer). 端口层定义领域核心与外部世界之间的稳定接口。主要端口涵盖模型推理、知识检索、视觉输入和遥测输入。这些端口使得替换模型提供方、知识后端或模拟器适配器时无需修改过程引擎。

适配器层 (Adapters layer). 适配器层包含外部集成代码：DCS-BIOS 接收器、遥测数据清洗与聚合、DCS 覆盖层分发、OpenAI 兼容及本地模型客户端、BM25 文档检索、截图捕获以及 VLM 视觉事实提取。

过程包 (Procedure packs). 过程包是核心层消费的任务特定契约。F/A-18C 过程包定义了步骤顺序、前置门控、完成门控、UI 目标标识符、遥测变量映射、视觉事实绑定以及错误分类标准。它不是适配器，因为它不与模拟器通信；它是声明式的领域规格说明。

图 3.1 总结了该架构。该图应从左到右解读为一条证据流：模拟器状态与座舱图像通过适配器进入，过程包规则构建运行时的解释框架，检索到的来源与模型服务支持帮助生成，校验器在输出到达座舱之前检查生成的操作计划。




Figure 3.1: 证据约束教学架构。模拟器遥测、复合面板视觉、过程包配置、检索到的知识以及模型输出通过证据包整合，并在覆盖层或教学文本到达座舱之前由校验器进行检查。

同样的边界也支持研究工作流程。关于门控、证据包、校验器决策和回放的技术声明可以使用 fixture 进行测试。关于视觉事实提取的声明可以与实时教学分开进行基准测评。关于 VR 呈现的声明可以作为形成性先导证据处理，而非验证架构的前提条件。


3.3 证据约束帮助循环

实时帮助循环是核心运行时的调用链。简洁地表示为：

帮助触发 → 遥测快照 → 可选视觉捕获 → 步骤与门控推断 → 证据包 → 检索 → 模型响应
→ 校验器验证 → 覆盖层/文本输出 → 事件日志

这个顺序很重要，因为它确定了权威的来源顺序。模型并非首先决定模拟器状态意味着什么。相反，运行时在生成之前组装状态证据和候选步骤，并在显示之前验证生成的响应。图 3.2 展示了这一循环。

Live evidence-grounded help cycle



The LLM never acts directly on the simulator; mapped responses pass through harness validation first.

Figure 3.2: 实时证据约束帮助循环。每一次帮助请求被转换为遥测和视觉观测，对照过程门控进行解释，通过检索到的知识进行锚定，经过文本 LLM 处理后由校验器验证，然后以覆盖层/文本输出形式分发，并附带事件日志追踪。

3.3.1 帮助循环各阶段

观测 (Observation). DCS-BIOS 适配器接收模拟器状态，遥测管线将其规范化为运行时变量。当活跃或可能活跃的步骤需要显示证据时，视觉适配器可以捕获复合座舱面板图像并请求视觉事实提取。

候选推断 (Candidate inference). 过程引擎评估前置条件和完成门控，识别候选步骤，并记录缺失或不确定的证据。生成的候选不是自然语言建议，而是从当前证据中推导出的结构化运行时对象。

证据包组装 (Evidence packet assembly). 运行时收集遥测值、门控结果、最近变化增量、视觉事实状态、检索到的来源引用以及步骤候选，组装为证据包。该证据

包是状态解释与模型辅助帮助生成之间的边界对象。

模型响应 (Model response). 提示词要求模型基于证据包生成结构化的帮助响应。输出必须符合运行时 HelpResponse Schema。无法解析或无法安全映射的自由文本不会成为可执行操作。

验证与映射 (Validation and mapping). 响应经过 JSON 提取、Schema 验证、证据引用检查、步骤与目标白名单以及校验器验证。只有通过这些检查的响应才能映射为覆盖层操作或教学文本。验证失败会触发修复、拒绝或确定性回退。

执行与日志 (Execution and logging). 覆盖层命令仅限于安全的显示操作，如高亮、脉冲或清除。控制注入和自动点击不在架构范围内。每一次帮助循环均被记录为结构化事件，以便会话结束后可回放。

3.3.2 Schema 级别证据锚定

证据锚定在输出执行之前强制执行。HelpResponse Schema 根据当前过程包和 UI 映射生成，因此有效步骤和覆盖层目标的集合是任务特定的。模型提出的每个目标必须附带证据，其类型和引用必须与帮助循环上下文中可用的数据相对应。支持的证据类型包括遥测变量 (var)、门控评估 (gate)、检索到的来源 (rag)、最近状态变化 (delta) 以及视觉事实 (visual)。

这种设计改变了未经支持的模型响应的失败模式。如果模型提出了一个貌似合理但未经锚定的覆盖层操作，该响应不仅是作为可疑记录记入日志，而是在结构上对操作执行无效。系统随后可以修复到允许的目标、回退到纯文本引导，或拒绝该操作计划。

3.4 遥测作为状态证据

遥测是控制器、指示器和 DCS-BIOS 直接导出的数值状态值的主要证据来源。遥测管线通过四个阶段将原始模拟器帧转换为稳定的状态证据：

1. **原始摄入 (Raw ingestion).** DCS-BIOS UDP 帧被解码为带有时间戳和序列信息结构化观测。
2. **变量解析 (Variable resolution).** 过程包映射将原始 BIOS 字段投影到规范化变量上，例如 rpm_r、apu_ready 或 battery_on。解析器同时追踪缺失的数据源，使运行时能够区分观测到的假值与不可用的值。
3. **增量清洗 (Delta sanitisation).** 配置的阈值、去抖窗口和过滤策略抑制由传感器抖动、开关弹跳和乱序帧引起的虚假变化。

4. **增量聚合 (Delta aggregation)**. 最近的状态变化被压缩为适合提示词的摘要, 并作为帮助循环推理的证据来源。

缺失来源的区分对于过程性教学很重要。当开关已知为关闭状态与遥测来源缺失时, 门控的失败方式不应相同。第一种情况可以证明纠正性引导是合理的; 第二种情况可能需要带有不确定性或纯文本的帮助。

3.5 过程引擎与证据门控

过程引擎维护有序冷启动序列的状态。每个步骤可以是待处理、活跃、已完成或阻塞状态, 状态转移由前置条件和完成门控驱动。门控以声明式方式在过程包中表达, 而非嵌入提示词中。这确保过程状态是由规则支配的领域决策, 而非模型推断。

门控评估器支持阈值检查、范围检查、布尔标志和经过时间条件。缺失、来源缺失或哨兵值会产生诊断性失败, 而非被静默地强制转换为有效状态。这些诊断信息同时反馈给证据包和确定性回退。

3.5.1 确定性回退

确定性回退是架构的一部分, 而非事后的紧急补救措施。当模型不可用或模型输出验证失败时, 运行时根据活跃步骤、未满足的门控、最近操作和证据可用性计算出保守的提示。它区分硬阻塞(证据显示某门控未满足)和软阻塞(所需证据缺失或不明确)。覆盖层输出被抑制, 除非局部规则能够唯一确定一个有效目标。

3.5.2 按证据来源进行步骤分类

当前的 F/A-18C 过程包根据最可靠的可获得证据来源对步骤进行分类:

- **视觉优先步骤:** S08、S15、S18 和 S19 需要来自视觉事实管线的座舱显示证据。
- **BIOS 优先步骤:** S01、S03–S13、S16 和 S20–S33 在过程包元数据中声明为主要通过遥测验证。
- **手动或面板外步骤:** S14 和 S17 需要手动确认, 或涉及三屏复合面板之外的座舱区域。

火警测试步骤 S02 通过其自身的门控和最近操作契约处理, 而非通过过程包中的三个优先级列表。重要的架构要点是: 运行时不会让模型来决定哪个证据通道对某个步骤具有权威性。该选择由过程包声明, 并由帮助循环消费。

3.6 校验器工程与证据验证

校验器是输出到达模拟器之前的最终安全边界。它将模型提出的响应转换为经过验证的操作计划，或转换为修复、拒绝或纯文本结果。详细的对象关系见附录图 9.1；此处仅概述其主要的架构角色。

校验器使用四个概念对象：

EvidencePacket. 当前帮助循环的规范化快照：遥测状态、门控诊断、最近操作、视觉事实、检索到的引用以及候选步骤信息。

StepCandidate. 关于学习者可能位于过程哪个位置的候选解释，由门控、遥测、最近操作和视觉证据推导得出。

StepHarnessSpec. 每个步骤的过程包派生契约：允许的覆盖层目标、所需的可观测项、遥测事实、视觉事实、完成谓词、恢复策略和信号新鲜度要求。

HarnessActionPlan. 验证后的结果：选中的步骤、选中的覆盖层步骤、目标、证据引用、引导文本、纯文本状态、修复状态、拒绝状态及原因。

验证序列具有三个效果。第一，它防止错误步骤或错误目标的输出绕过过程包。第二，它防止陈旧或不适当的证据驱动后续步骤。第三，它为修复和拒绝创建机器可读的原因，这些原因随后可用于回放和评估。

3.6.1 基于 Fixture 的回归测试

校验器通过实时帮助 fixture 进行测试：在曾经暴露失败的特定过程状态下记录的遥测快照和运行时上下文。每个 fixture 通过帮助循环回放，并断言期望的结果，例如正确的目标、修复后的目标、纯文本回退或安全拒绝。

当前的覆盖矩阵包含 20 个实时 fixture 回归条目，覆盖 S01-S33。这些 fixture 涵盖正确推进、错误目标拒绝、不完整或不匹配视觉证据的修复、防止陈旧的 VLM 事实泄漏到非视觉步骤、移动控件等待引导，以及开关、按钮和旋转控件的交互语义。这一覆盖范围并非教育评估，而是技术证据，证明证据锚定约束可以在运行时边界上被系统性地执行。

3.7 适配器边界：模拟器、覆盖层与视觉

适配器层将 DCS 特定行为隔离在核心层使用的端口之后。三个适配器职责对实时运行时至关重要。

遥测输入 (Telemetry input). 遥测适配器接收 DCS-BIOS 状态数据并馈送给遥测管线。其输出是规范化的状态证据，而非模拟器特定的帧数据。

覆盖层输出 (Overlay output). 覆盖层适配器将抽象的教学目标映射为 DCS 覆盖层标识符，并发送高亮、脉冲或清除命令。它不执行座舱控制操作。

视觉输入 (Vision input). 视觉适配器触发截图捕获，并将复合面板图像传递给 VLM 事实提取器。生成的视觉事实作为结构化证据返回核心层。

VR 路径遵循相同的边界。VR 镜面显示、教学文本传输和复合面板捕获属于适配器的关注范围；过程推断和校验器验证保留在核心层。VR 代码路径已在第 6.3 节报告的形成性先导研究中得到使用。更大规模的受控人类受试者评估仍属未来工作。

3.8 事件日志与回放

可审计性要求帮助循环决策在实时会话结束后仍然可被追溯。运行时以 JSONL 格式记录版本化、带时间戳的事件。事件包括观测、帮助请求、证据摘要、模型输出、校验器决策、覆盖层操作以及与评分相关的交互数据。

回放使用这些记录离线重建步骤顺序、状态机一致性和帮助循环行为。当前的回放评估套件包括五种场景类型：无操作、接通电池、电池与发电机断开、FCS 重置与 BIT 以及 INS 对准。这些案例使用 DCS-BIOS 原始捕获数据，并在可能的情况下使用视觉 sidecar 产物。

日志和回放层从两个方面支撑本论文。在开发过程中，它使回归可重现。在评估过程中，它将关于就绪性和仪表化的声明的论证基础连接到具体的产物，而非仅依赖人工观察。具有同步视觉帧的多模态人在回路会话的完整端到端回放目前仍是一个局限。

3.9 VLM 视觉证据适配器

VLM 组件为遥测未直接导出的显示状态提供视觉证据。其运行时输出是一组视觉事实，而非过程决策。每个事实是关于可见座舱显示内容的有限命题，状态为 `seen`、`not_seen` 或 `uncertain`。过程引擎和校验器决定这些事实如何影响帮助循环。

当前运行时契约使用第 2 章中介绍的本体，包含 13 个事实。事实具有生存时间 (TTL) 设置、可选的粘性语义，以及通过 `all-of` 或 `any-of` 条件的步骤绑定。例如，与 FCS-MC 最终 GO 相关的事实可以被锁存，以便学习者在切换页面时不会丢失已完成的瞬态显示状态。

当帮助请求涉及视觉优先步骤时，运行时可以触发截图捕获，提取视觉事实，将其合并到当前证据快照中，并纳入证据包。如果视觉适配器不可用或多模态请求失败，帮助循环将继续使用遥测、检索和过程门控。这种优雅降级保留了遥测锚定的核心功能，同时允许视觉证据改善需要显示内容解释的步骤。

数据管线、本体从 8 个事实到 13 个事实的演进、LoRA 微调配置以及留出集基准测评协议属于方法论问题而非架构问题，因此安排在第 四 章讨论，并在第 六 章进行评估。

3.10 本章小结

本章提出的架构将基础模型教学转变为受约束的证据处理管线。遥测和视觉事实提供观测数据，过程包定义有效的状态转移和证据需求，检索提供来源锚定的上下文，模型生成结构化的帮助，校验器验证或修复提出的操作，日志使决策可回放。这是从系统层面回答 RQ1：当模型输出被置于显式证据的下游和强制验证的上游时，过程性帮助就变得可审计。

第四章 方法论

第 三 章给出了将教学输出置于证据下游和验证上游的运行时架构。本章描述这些证据如何被产生、筛选和评估。方法论围绕一个实际问题展开：如何将模拟器遥测、检索到的过程性知识和 VLM 衍生的视觉事实转变为过程性教学者的可审计输入？

本章承担三个角色。第一，它定义了过程引擎使用的运行时证据接口：遥测变量、门控诊断、检索到的文本片段以及确定性回退。第二，它为 RQ2 呈现了视觉事实方法论：截图捕获、预标注、人工审核、本体修订、双语 SFT 导出、LoRA 适配以及留出集基准测评。第三，它为 RQ3 记录了形成性 VR 先导研究协议。先导研究被视为关于可行性和交互模式的描述性证据，不用于提出关于学习收益的推断性声明。

4.1 过程运行时与遥测锚定

遥测和过程门控提供了帮助循环所依赖的方法论层面的状态证据。该层的架构布局已在第 三 章中描述；此处的方法论关注点在于原始模拟器观测如何成为稳定的、可检查的变量，以便后续用于基准测评、回放和帮助循环分析。

4.1.1 变量解析与来源缺失追踪

过程包声明了一个遥测映射，将原始 DCS-BIOS 字段投影到规范化的运行时变量上。解析器生成一个扁平的键值对字典，并在 `vars_source_missing` 中单独追踪不可用的数据源。这种分离很重要，因为假值与未观测到的值在方法论上不应具有相同的含义。已知为关闭状态的开关可以支持纠正性引导。缺失的数据源仅能支持带有不确定性意识的引导或回退。

4.1.2 门控规则评估

每个过程步骤包含前置条件和完成门控。门控 DSL 支持阈值检查、范围检查、布尔标志和经过时间条件。缺失、来源缺失或哨兵值会带着诊断原因失败，而非被静默

地强制转换。失败的门控及其原因被包含在帮助循环上下文中，并可在日志中事后检查。这将过程进度转变为由规则支配的证据声明，而非模型推断的叙事。

4.1.3 增量清洗与聚合

原始遥测数据可能因模拟器物理、仪表抖动和过渡性开关状态而以高频率变化。增量清洗应用逐变量阈值、去抖窗口和过滤规则。增量聚合随后将最近、清洗后的变化压缩为适合提示词的摘要。生成的增量被用作最近学习者操作的证据，而无需将每个原始模拟器帧暴露给语言模型。

4.1.4 确定性回退

回退是方法论的一部分，而非仅仅是实现层面上的安全措施。当模型输出不可用或无效时，运行时根据活跃步骤、未满足的门控、最近操作和证据可用性计算出保守的提示。回退区分硬阻塞（观测到的证据显示某门控未满足）和软阻塞（所需证据缺失）。覆盖层引导被抑制，除非局部规则能够识别出唯一有效的目标。

4.2 知识锚定与来源策略

检索到的过程性知识为生成的帮助提供文本上下文，但它被刻意地进行了来源控制。本地检索适配器以句子级别索引经过筛选的过程文档和飞机文档，并使用 BM25 [19] 对文本片段进行排序。锚定查询由活跃步骤、其描述和当前观测构造；得分最高的文本片段被包含在帮助循环上下文中。


声明式来源策略将检索限制在允许的文档来源内。这防止模型接收到当前活跃过程包之外的过程变体，例如当前配置文件为陆基冷启动时接收到航母特定的指令。因此，在本论文的方法论中，检索不是一个通用的文档搜索设施。它是一个受控的证据通道，其范围属于过程配置的一部分。

4.3 视觉事实数据管线

视觉事实管线是 RQ2 的主要方法论。它将 DCS 座舱截图转换为监督学习示例，再转换为经过基准测评的视觉事实提取器。该管线为可追溯性而设计：一个基准测评错误应可追溯到模型预测、人工审核标签、预标签和原始图像。

图 4.1 以循环形式展示了该管线。留出集失败不仅是最终结果，还可以揭示本体中的弱点并指导后续数据采集。

Small-data VLM adaptation pipeline



Each benchmark prediction remains traceable to a reviewed label and original cockpit image.

Figure 4.1: VLM 适配管线。DCS 复合截图经预标注、人工审核，转换为双语监督微调数据行，通过 LoRA 进行适配，在独立留出集上评估，并用于驱动本体修订。

1. **截图捕获**。DCS 将左 DDI、AMPCD 和右 DDI 渲染为一张复合面板图像。相同的复合布局用于数据采集、预标注、训练、基准测评和运行时推理。这保持了整个方法论中输入分布的稳定性。
2. **VLM 预标注**。一个大型外部 VLM 为每张图像生成初始标签和证据注释。预标注用作标注辅助手段，而非真实标签。
3. **人工审核**。预标注样本在 Label Studio [20] 中进行审核。审核者纠正事实状态和证据注释，同时保留与原始图像和预标签的链接。
4. **审核后 JSONL 导出**。审核后的导出是下游训练和评估的权威真实标签工件。
5. **双语 SFT 生成**。每张审核后的图像生成一行英文和一行中文训练数据，共享相同的图像和事实标签。助手目标是包含视觉事实和简短摘要的结构化 JSON；外部管理字段如帧标识符、文件路径和置信度字段被排除在目标之外。
6. **LoRA 适配**。SFT 数据行用于为 VLM 骨干模型训练 LoRA 适配器 [12]。实现使用 PEFT 适配器定义 [16]、TRL 监督微调基础设施 [22] 以及 Unsloth 加速用于 4 位 VLM 训练 [10]。
7. **留出集基准测评与修订**。基础模型和 LoRA 配置在独立留出集上进行评估。错误在事实层面进行检查，特别是对完成关键事实，由此发现的失败模式反馈到本体和数据集修订中。

该方法论刻意将 VLM 的任务保持狭窄。模型被训练为以 `seen`、`not_seen` 或 `uncertain` 状态报告视觉事实。它不被训练来决定过程完成或产生教学操作。这些决策仍保留在过程引擎和校验器中。

4.4 数据集构建

4.4.1 数据集概览

六个经审核的数据集支撑跨两个本体版本的视觉事实工作。表 4.1 列出了它们的角色和追踪的样本数量。

Run-003 和 Run-005 包含自由文本摘要字段为空的样本（分别为 82 和 25 个样本）。这些样本对视觉事实任务仍然有效，因为每个样本仍然包含完整的事实数组。运行时和基准测评使用的监督目标是结构化的事实状态，而非可选的摘要。

Table 4.1: 用于视觉事实提取的数据集清单。

运行批次	数据集	样本数	事实数	语言	角色
Run-001	v1 SFT	180	8	en/zh	v1 训练源
Run-002	v1 留出集	50	8	en	v1 留出集
Run-002	v2 新事实留出集	50	13	en	v2 留出集
Run-003	v2 SFT	220	13	en/zh	v2 训练源
Run-004	v2 随机留出集	100	13	en	v2 留出集
Run-005	组合再平衡	122	13	en/zh	v2 训练补充

4.4.2 本体演进：从 8-Fact v1 到 13-Fact v2

第一个本体包含覆盖复合座舱面板的 8 个事实。它证明了小型经审核数据集可以改进结构化座舱事实提取，但也暴露了一个表示问题：一些目标将视觉观测与过程解释混合在一起。最明显的案例是 `ins_go`，它要求单帧 VLM 推断 INS 完成状态，而非报告直接可见的证据。

图 4.2 说明了方法论上的纠正。复合过程性目标被分解为局部可观测的视觉原子，将时间和过程解释留给教学运行时。

当前的 13-fact 本体遵循三条设计规则：

1. **分解复合目标。** `ins_go` 目标被替换为 GRND 对准文字和 INS OK 文字的独立视觉原子。FCS-MC 序列以页面、中间结果、测试中和最终 GO 事实表示。
2. **将区域与语义分离。** 事实名称描述可见状态，而非在标识符中编码显示区域。区域约束属于本体元数据的一部分。
3. **保持事实局部可观测。** 每个事实应可从复合图像中判定，而不需要过程历史。过程引擎稍后将事实与遥测、步骤绑定和时间信息结合。

这种本体纪律对论文至关重要。它定义了感知与过程推理之间的边界：VLM 报告视觉证据，而运行时决定该证据是否满足过程步骤。

4.4.3 训练方案：Run-003 + Run-005 $\times$ 2

主要的 v2 训练方案将 Run-003 与重复的 Run-005 组合再平衡补充数据合并。Run-003 贡献 220 张经审核的图像，以双语导出为 440 行 SFT 数据。Run-005 贡献 122 张经审核的图像，以双语导出为 244 行数据；该补充数据被包含两次，产生 488 行数据。因此，最终方案包含 **928 行 SFT 数据**。

Visual fact ontology evolution




Figure 4.2: 从 8-fact v1 到 13-fact v2 的 ontology 演进。诸如 `ins_go` 和宽泛的 FCS-MC 完成事实等复合目标被分解为局部可验证的视觉原子；过程引擎随后将这些观测与遥测、阶段和时间证据结合。

Run-005 针对 Run-003 中代表性不足的正类状态，包括 INS OK 文字、FCS 页面 X 标记和 FCS-MC 子状态事实。重复补充数据是一种刻意的组合再平衡策略，而非独立的验证集。因此，泛化声明基于外部留出集，而非内部同池评估划分。

4.4.4 留出集独立性

两个 13-fact v2 留出集用于主要评估。Run-002 newfacts 包含 50 张来自更早捕获会话的图像，在 13-fact 本体下重新标注。Run-004 random 包含 100 张随机采样的座舱状态截图。本地重叠检查报告两个留出集与 Run-003 + Run-005 训练并集之间零精确重叠。

较早的 Run-001 评估线被区别对待。由于它与训练数据池有重叠，它作为受污染开发基准可用于检查 Schema 学习和历史本体行为，但不作为 v2 泛化的独立证据使用。

4.5 LoRA 微调配置

4.5.1 骨干模型与对比策略

主要的适配线使用 Qwen/Qwen3.5-9B-Base 配合 Run-003 + Run-005 $\times 2$ 方案。两个补充骨干模型被纳入，以检验相同的数据方案在规模、版本和模型家族变化下是否仍然有意义：Qwen/Qwen3.6-27B 和 google/gemma-4-31B。这些对比是方法论对照组，而非独立的论文声明。第 六 章报告数值结果。

对比在可控范围内尽可能保持主要因素不变：本体、训练方案、基准测评提示词、留出集、生成温度、输出 Schema 和度量计算。骨干特定的差异仍然存在，因此被显式报告。Qwen 家族运行对视觉和语言模块施加 LoRA；Gemma 运行使用 all-linear LoRA 配置，视觉层不单独微调。完整设置见附录 九，表 9.1。

4.5.2 训练栈与超参数

所有骨干运行使用 4 位加载，LoRA 秩 $r = 16$ ， $\alpha = 16$ ，dropout 0.0，4 个 epoch，学习率 2×10^{-4} ，有效批次大小 4，最大序列长度 4096，种子 3407，预热比例 0.1，权重衰减 0.01。适配器权重与基础模型分开保存。

Epoch 数和 LoRA 秩的选择针对小数据领域适配。在 928 行 SFT 数据下，适配器必须同时学习固定的 JSON Schema 和座舱事实的视觉边界。过少的 epoch 可能无法可靠地教会这些边界，而过多的训练则存在记忆捕获会话的风险。秩 16 提供适度的适配容量，而不会将适配器变成高容量的任务特定模型。

4.5.3 双语 SFT 与组合再平衡

双语 SFT 策略为每张经审核的图像创建两个指令变体：一个英文和一个中文。图像和事实标签保持相同。这在无需额外图像标注的情况下增加了指令格式的覆盖范围。它不替代对新的座舱状态或困难负例的需求。

组合再平衡通过 Run-005 处理。由于稀有正类事实对下游过程推理特别重要，训练方案通过添加针对性捕获和重复 Run-005 双语数据行来增加它们的曝光度。因此，该方法论分离了两个问题：适配器是否能从再平衡后的训练方案中学习本体，以及学习到的提取器是否能泛化到独立留出集。

4.6 基准测评协议

4.6.1 度量指标

基准测评在样本和事实两个层面比较模型预测与人工审核的真实标签。度量指标的选择反映了下游运行时风险：

- `json_valid_rate`: 输出可解析为 JSON 的样本比例。
- `schema_valid_rate`: JSON 包含所需事实标识符恰好一次且仅使用有效状态的样本比例。
- `fact_accuracy`: 所有事实和样本上的三分类准确率。
- `macro_f1`: 三种状态上的宏平均 F1 值，在事实间平均。
- `seen_f1`: 正类 `seen` 的 F1 值，在事实间平均。这很重要，因为遗漏或幻觉的可见状态会改变过程证据。
- `sample_exact_match`: 所有 13 个事实与审核标签匹配的样本比例。
- `critical_false_positive_count`: 当审核标签为 `not_seen` 或 `uncertain` 时，完成关键事实被预测为 `seen` 的次数。

关键假阳性被单独跟踪，因为它们是对教学者最危险的视觉错误。完成关键事实的假阳性可能使过程引擎相信某显示状态已被观测到，而实际上并未。

4.6.2 基础模型与 LoRA 对比

基础模型和 LoRA 配置接收相同的提示词、图像、生成参数和输出 Schema。解码使用温度 0.0、最大新 tokens 1024 和种子 3407。预测写入 JSONL，经解析、规范化后评分，不做事后过滤。对比工件报告 LoRA 减去基础模型的增量，第 六 章对这些增量进行解释。

4.6.3 基准测评类别

基准测评运行按证据状态分类。受污染开发集来自与训练相同的数据池，仅用于回归和历史解释。留出的新会话基准使用独立捕获，与训练数据零精确重叠。这种区分决定了从某个度量中可以得出的声明的强度。

4.6.4 基准测评工件

每个基准测评运行产生一个标准目录，内含每个模型的度量、逐样本预测、错误 JSONL 文件、逐事实评分 CSV、对比摘要、人类可读报告和图表。这些工件构成第 六 章报告的技术结果的证据链。

4.7 人类受试者先导研究方法论

开展了一项小型形成性 VR 先导研究，以收集关于教学者在 F/A-18C 冷启动任务中实际使用情况的描述性证据。该先导研究并非具有统计效力的受控实验。其目的是在真实的 VR 环境中运行教学系统，检查交互日志，并为后续研究设计识别过程性错误模式。

4.7.1 参与者与条件

9 名参与者 (P01–P09) 每人完成一次试验。研究采用受试者间设计，基于日程可用性进行非随机分配：

有教学者组 (n=4)。 P04、P05、P08 和 P09 接收覆盖层高亮、结构化帮助文本、遥测锚定的步骤推断以及适用的 VLM 视觉事实支持。

无教学者组 (n=5)。 P01、P02、P03、P06 和 P07 未接收教学辅助。遥测仍被记录，用于离线步骤推断和错误编码。

参与者经验概况见附录 九，表 9.5。由于分配未随机且样本量小，条件间对比仅为描述性。

4.7.2 任务与设备

所有试验使用 DCS World 中 33 步 F/A-18C 冷启动程序，通过 Quest Link 在 Meta Quest 3 上进行。复合座舱面板被镜像以供实验者观察。教学者条件下的试验使用带有远程模型推理（OpenAI 兼容端点）的实时运行时。试验在参与者完成程序或无法继续后自愿停止时结束。

4.7.3 数据来源与编码

导出管线生成每次试验的摘要、每步编码文件、教学者试验的帮助循环日志、操作时间线、质量门控元数据以及会话摘要。步骤错误编码为五类：遗漏（OM）、执行错误（CO）、顺序错误（OR）、提示/辅助错误（PA）和状态违反（SV）。自动编码输出通过遥测、帮助循环日志和操作时间线进行人工审核；人工编码列为报告先导结果的权威来源。

4.7.4 数据质量说明

两个试验层面的注意事项影响解读。第一，P08 的自动摘要报告了不完整的进度，但人工遥测审核确认完成了全部 33 步。分析使用人工编码，审核前的文件保留以供审计。第二，P02 的问卷元数据包含内部参与者 ID 不匹配。P02 的任务度量被保留，但 P02 被排除在问卷衍生的工作负荷或信心摘要之外。

4.7.5 分析方法

先导分析报告每位参与者的结果和条件层面的描述性摘要。不执行零假设显著性检验。观测到的持续时间被记录，但不解释为完成时间比较，因为未完成的无教学者试验在不同停止点结束。分析聚焦于完成状态、人工错误类别以及教学者交互模式，如帮助请求、VLM 调用、覆盖层操作和回退事件。

4.8 本章小结

本章方法论建立了论文其余部分使用的证据链。遥测和检索提供受控的运行时上下文。视觉事实管线为 RQ2 产出一个经审核和基准测评的感知层。13-fact 本体将感知与过程推理分离。LoRA 协议使用匹配的数据和留出集来评估小数据适配，而不依赖受污染的开发集。先导研究协议为 RQ3 提供形成性 VR 证据，同时将其声明保持为描述性。这些方法论共同使后续结果可审计，而不夸大现有证据所能证明的范围。

第五章 实现

第 三章和第 四章描述了基于证据的教学系统的架构与方法。本章阐述这些思想如何被实现为一个可运行的研究原型系统。论述重点是有选择性的：仅当实现细节用于执行证据边界、保持清洁/六边形架构分离、使帮助循环可审计，或支撑第 六章所用的评估产物时，才予以包含。

因此，本章的实现问题并非简单地回答存在哪些模块，而是回答：在生成的教学帮助到达学习者之前，在何处进行了权限检查。答案分布在多个层面：从过程包派生的 Schema、证据包、响应映射、Harness 验证、有边界的叠加层执行、降级逻辑，以及追加式事件日志。不改变上述论证的操作性细节（如完整的命令参考和完整部署拓扑）置于附录 九中。

5.1 运行时边界与配置

代码库围绕清洁/六边形架构边界组织。领域逻辑位于 `core/`；稳定接口在 `ports/` 中声明；外部系统通过 `adapters/` 连接；任务相关的程序知识存储在 `F/A-18C` 过程包中。这种布局是一种实现决策，而非仅仅是代码风格偏好。它将仿真器传输、模型提供方、视觉采集、检索、叠加层分发和实验导出等外部关注与决定什么证据可采信的区域对象隔离开来。

Python 项目目标为 Python 3.10+，使用 `pyproject.toml` 中声明的依赖集。运行时依赖少量通用库：`httpx` 用于 HTTP 模型调用，`PyYAML` 用于声明式配置，`jsonschema` 用于契约验证，`Pillow` 用于 VLM 路径中的图像处理。测试使用 `pytest` 实现。这些技术栈选择之所以重要，主要是因为它们支持可检查的基于文件的配置和可复现的验证。

模型访问在设计中保持提供方无关。文本帮助路径使用 OpenAI 兼容适配器，可配置用于 `vLLM`、`llama.cpp` 或 `TGI` 等服务器。通过 `Ollama` 适配器提供本地兼容性，确定性 stub 则支持测试。同样的边界也用于多模态 VLM 路径：运行时将视觉事实提取视为返回结构化观测的适配器，而非程序决策的权威来源。

DCS 端集成扮演着同样狭窄的角色。`Lua` 脚本和 `sidecar` 组件导出 DCS-BIOS 状态、触发复合面板截图，并应用叠加层高亮指令。它们不决定当前过程步骤、不生成

教学文本，也不绕过 Python 端的验证链。这使得仿真器集成保持为 I/O 适配器，而过程包、证据包和 Harness 仍然是教学决策的权威来源。

5.2 证据根基执行

证据根基通过多个实现关卡来执行，而非仅仅通过提示词措辞。模型可以提出诊断、下一步建议、解释和叠加层目标，但该提议必须通过从过程包生成的契约，以及针对当前帮助循环中可用证据的检查。

从过程包派生的 Schema。 函数 `build_help_response_schema` 在运行时生成 `HelpResponse` JSON Schema。步骤标识符来自步骤注册表，叠加层目标来自 UI 映射，错误类别来自分类法。Schema 要求每个叠加层目标至少有一项相应的证据项。证据项必须使用下列运行时根基类型之一：`var`、`gate`、`rag`、`delta` 或 `visual`。这使得输出契约针对具体过程，而非一个通用的语言模型格式。

证据包构建。 帮助提示词是由结构化上下文而非原始日志片段构建的。`build_evidence_packet` 将遥测证据、门控证据、最近操作、视觉事实、确定性候选和已知冲突聚合成一个紧凑的证据包。`build_help_prompt_result` 然后将此证据包、允许的证据引用、检索到的片段以及叠加层目标策略纳入面向模型的提示词中。因此，证据引用可以在之后针对展示给模型的同一上下文进行检查。

模型输出映射与 Harness 验证。 响应路径故意保持狭窄。JSON 提取会移除代码围栏并读取第一个有效对象，但不会将任意格式错误的文本修复为新的答案。解析后的对象先对照动态 Schema 进行验证，然后传递给响应映射器。映射器检查叠加层证据引用是否存在于帮助循环上下文中，对照白名单验证叠加层目标，在元数据中记录映射失败，并应用配置的叠加层目标数量限制。

Harness 层添加了第二个实现边界。提示词暴露了用于候选决策的 `HarnessDecision` 契约，而公共运行时输出仍然通过稳定的 `HelpResponse` 路径映射。`plan_harness_action` 然后检查所选步骤、候选证据、允许的叠加层目标、证据引用和最终状态一致性。它可以接受模型提议、将其修复为更安全的目标、强制仅文本指导，或拒绝叠加层输出。这是架构原则“LLM 不是最终权威”的具体实现。

有边界的叠加层执行。 最终执行器仅接受类型为 `overlay` 的操作。它拒绝控制注入、按键仿真、空目标、无法映射的目标、超出 UI 白名单的目标，以及需要证据但缺少证据引用的叠加层。当前运行时支持可配置的多目标指导。超过配置限制的目标将被丢

弃并记录，而非静默执行。当 DCS 发送端发出确认消息时，请求、应用和失败的叠加层事件会被规范化到与帮助循环其余部分相同的 JSONL 事件流中。

5.3 确定性降级

降级被实现为一条保守的退化路径。当模型不可用、JSON 提取失败、Schema 验证失败、响应映射拒绝提议的操作，或 Harness 无法生成有根基的叠加层计划时，系统会使用降级路径。降级逻辑检查当前活动过程步骤、未满足的门控条件、最近操作、UI 目标绑定和证据可用性。

重要的是区分硬阻塞和软阻塞。硬阻塞意味着观测到的证据显示某个必要条件为假。软阻塞意味着所需的证据源缺失或不可观测。对于硬阻塞，降级可以给出纠正性指导；但对于软阻塞，当必要证据缺失时，降级路径避免声称学习者未能完成某个步骤。叠加层输出被抑制，除非本地过程规则识别出唯一有效的目标，或当前配置明确允许有边界的多目标计划。

这条降级路径同样维护了论文声明的边界。帮助循环可以在没有模型或没有视觉证据的情况下继续，但由此产生的指导会更加保守：它依赖观测到的遥测数据、过程门控和确定性步骤提示，而非编造的视觉或教学解读。

5.4 VLM 视觉事实提取运行时

VLM 运行时被实现为视觉事实提取器，而非教学导师。当前过程包将 S08、S15、S18 和 S19 标记为视觉优先步骤。对于这些步骤，实时运行时可以在组装最终帮助上下文之前请求复合面板截图。对于其他步骤，过期的视觉事实不允许覆盖更新鲜的遥测或过程门控证据。

截图请求被发送到 DCS 端的视觉 sidecar，后者将左 DDI、AMPCD 和右 DDI 渲染为复合图像。Python 端的缓冲视觉会话保留最近的观测记录，并选择帮助触发时刻附近的帧。在实时模式下，默认同步窗口为 250 ms；回放使用更窄的确定性窗口。所选帧的元数据记录了帧标识符、截图时间、同步状态、与触发时刻的偏差以及过期帧标志。

选定的图像帧被传递给视觉事实提取器。提取器根据当前的 13 项事实本体、复合布局和事实特定的决策边界构建提示词。模型响应被解析为 JSON，经清理后对照一个其事实标识符来自视觉事实包配置的 Schema 进行验证。未知的事实 ID、无效状态、不完整的事实对象和非 Schema 字段将被忽略或记录在元数据中。被接受的事实仅限于 `seen`、`not_seen` 和 `uncertain` 三种状态。

经过验证的视觉事实按照本体的粘性和过期策略合并到运行时视觉快照中。这一实现细节很重要，因为某些座舱显示状态是瞬态的：某项事实可能需要短暂保持可用以满足过程门控或 Harness 决策，而过期事实必须在误导后续步骤之前失效。如果多模态提取被禁用或 VLM 调用失败，帮助循环仅依靠遥测、检索和降级证据继续。

5.5 回放与日志基础设施

该实现将日志视为证据链的一部分。运行时事件被写入 JSONL 存储，并在每次追加后立即刷新。因此，一个帮助循环会留下可审计的轨迹，包括触发元数据、遥测上下文、视觉帧选择、提示词构建元数据、模型和映射状态、Harness 决策、叠加层执行和失败原因。

回放使用与实时操作相同的边界准则。预录的 DCS-BIOS 捕获可以通过运行时回放，并可选择附带视觉帧目录，而过程包、UI 映射、遥测映射、源策略和 Harness 规格仍然是显式输入。fa18c_startup_v04 回放套件组合了五个场景案例和实时 fixture 回归条目，覆盖了 VLM 过期证据、错误目标阻止、移动控件稳定、已完成的完成条件以及交互文本语义等情况。

这些日志和回放套件并不证明学习效果。它们的技术作用是：使帮助循环决策可复现，检查叠加层为何被接受、修复、丢弃或拒绝，并为第 六章报告的 RQ1 就绪性证据提供支撑。

5.6 实时运行时编排

实时运行时通过一条共享的帮助循环路径连接各实现组件。帮助触发首先从 DCS-BIOS 帧创建遥测快照。遥测管线将原始观测富化为运行时变量和最近增量。如果当前步骤需要视觉确认，则发出截图请求，缓冲视觉会话选择同步的帧。过程引擎和门控评估器生成确定性候选和缺失条件诊断。这些观测被组装为证据包，检索添加源受控的过程知识片段，提示词构建器构造模型请求。

文本模型返回结构化响应而非自由形式的指令。该响应被解析、Schema 验证、映射为运行时教学响应、经 Harness 检查，并转换为最多不超过配置数量的叠加层操作。叠加层执行器仅将经过验证的叠加层意图分发到 DCS，并记录确认或失败。完整的帮助循环（包括降级和修复元数据）被追加到 JSONL 日志中。

在可能的情况下，回放和回归工具也使用相同的编排路径。共享路径对论文而言很重要，因为评估并非基于一个独立的教学系统模拟实现。约束实时教学的同一套契约也产出了用于评估技术就绪性的日志、回放输出和质量门控。

第六章 评估

本章通过三条证据线对论文进行评估，每条证据线的声明力度各不相同。VLM 基准测试线通过在独立保留的截图上的结构化视觉事实提取度量来回答 RQ2。回放与 Harness 线通过检查基于证据的帮助循环是否可复现、可验证且可被回归夹具约束来回答 RQ1。VR 试点线通过九次参与者试验的描述性观察来回答 RQ3。这三条证据线故意不可互换：组件准确率不是学习效果，回归覆盖不是人类被试结果，试点是形成性的而非推断性的。

图 6.1 给出了章节级的证据映射图。它展示了基准测试产物、回放/Harness 日志和试点导出数据如何进入评估，而非将它们合并为单一类型的证明。

6.1 RQ2: VLM 技术评估

技术评估关注的是：小数据 LoRA 适配能否使 VLM 在导师系统所需的狭窄任务上——从 F/A-18C 座舱显示屏截图中提取结构化视觉事实——足够可靠。模型本身不作为导师来评估，也不被认为具有程序推理能力。它被评估为一个感知组件，其输出成为帮助循环中的证据源之一。所有指标均由第 4.6 节描述的自动化基准测试 Harness 计算。

6.1.1 数据集与训练概览

视觉事实提取任务经历了两个代际的事实本体演变。第一代 (v1) 定义了 8 个视觉事实并建立了初始训练流水线。第二代 (v2) 将本体扩展为 13 个事实，与运行时契约对齐。表 6.1 总结了六个标注数据集。

v2 训练配方将 Run-003 (220 个人工审查任务) 与 Run-005 (122 个人工审查任务，专门采集用于再平衡代表性不足的事实状态) 结合，其中 Run-005 应用两次 (Run-005 $\times$ 2)。双语导出 (EN + ZH) 产生总计 **928 行** 训练数据。两个 v2 保留集——Run-002 newfacts (50 样本) 和 Run-004 random (100 样本)——均为仅英文，并经验证与训练集的并集之间**零精确重叠**。因此，基准测试在保持同一仿真器座舱和程序领域的前

Evaluation data flow across research questions




Figure 6.1: 跨研究问题的评估与数据流。VLM 基准测试产物支撑 RQ2，回放和 Harness 日志支撑 RQ1 技术就绪性，VR 试点导出数据支撑描述性 RQ3 发现。

Table 6.1: 标注视觉事实数据集概览。

数据源	Run	事实数	任务数	双语	用途
v1 train	Run-001	8	180	yes	初始训练
v1 holdout	Run-002	8	50	no	首次保留
v2 newfacts holdout	Run-002	13	50	no	运行时对齐保留
v2 train	Run-003	13	220	yes	主要训练源
v2 rebalance	Run-005	13	122	yes	构成再平衡
v2 random holdout	Run-004	13	100	no	独立保留

提下，测试了超出精确图像重用的适配能力。

6.1.2 Qwen3.5 13 事实 V2 结果

主要技术结果是基于 Run-003 + Run-005 $\times$ 2 训练的 Qwen3.5-9B LoRA 适配器 (928 行, 4 轮, 学习率 2×10^{-4} , LoRA $r = 16$, $\alpha = 16$)。这是最强的 RQ2 证据, 因为它在两个独立的保留集上将适配后的模型与对应的基础模型进行了比较, 且使用了与运行时对齐的 13 事实本体。表 6.2 报告了结果。

Table 6.2: 13 事实 v2 基准测试: Qwen3.5-9B Base vs. LoRA 在两个保留集上。

指标	Run-002 newfacts (50)			Run-004 random (100)		
	Base	LoRA	Δ	Base	LoRA	Δ
JSON valid	1.0	1.0	—	0.96	1.0	+0.04
Schema valid	1.0	1.0	—	0.96	1.0	+0.04
Fact accuracy	0.8677	0.9908	+0.1231	0.8038	0.9931	+0.1892
Macro F_1	0.4513	0.6515	+0.2002	0.4393	0.6100	+0.1707
Seen F_1	0.5022	0.9648	+0.4626	0.5659	0.9159	+0.3500
Exact match	0.10	0.88	+0.78	0.03	0.92	+0.89
Critical FP	11	4	-7	70	8	-62

适配后的模型在 Run-002 上达到 0.9908 的事实准确率, Run-004 上达到 0.9931, 样本完全匹配率分别为 0.88 和 0.92。对导师系统而言, 更重要的是关键误报的变化, 因为一个错误的 **seen** 状态可能使后续帮助循环的决策看起来有根基, 而实际上显示证据并不存在。关键误报在 Run-002 上从 11 降至 4, 在 Run-004 上从 70 降至 8。基础模型在 Run-004 上的较大失败不仅仅是格式问题: 它包括 4 个 Schema 无效的响应和大量稀有状态幻觉。LoRA 适配器恢复了 JSON/Schema 可靠性, 并将这种幻觉模式缩减为一组较小的可解释残余错误。

LoRA 的残余关键误报集中在完成信号而非页面存在信号上。在实践中, 这意味着适配后的 VLM 足够强以支撑视觉事实流水线, 但不足以被视为程序完成的独立来源。这一边界与第三章的架构一致: 视觉事实是证据输入, 而非程序决策。

6.1.3 Gemma-4 与 Qwen3.6 骨干对比

相同的 Run-003 + Run-005 $\times$ 2 配方也被应用于 Qwen3.6-27B 和 Gemma-4-31B。这一对比是补充性的: 它检查数据与本体配方在所评估的补充骨干上是否仍然可用, 而 Qwen3.5 基础模型与 LoRA 的对比线仍然是主要技术结果。表 6.3 总结了仅 LoRA 的对比。

Table 6.3: 三种骨干上的 13 事实 v2 结果 (仅 LoRA 模型)。

指标	Run-002 newfacts (50)			Run-004 random (100)		
	Q3.5-9B	Q3.6-27B	G-4-31B	Q3.5-9B	Q3.6-27B	G-4-31B
Fact accuracy	0.9908	0.9877	0.9492	0.9931	0.9892	0.9715
Seen F_1	0.9648	0.9479	0.8123	0.9159	0.9147	0.7959
Exact match	0.88	0.86	0.44	0.92	0.86	0.74
Critical FP	4	3	0	8	8	13

Qwen3.6-27B 产生了接近的结果，但在主要指标上并未超越更小的 Qwen3.5 适配器。这表明，对于这一狭窄的视觉事实任务，更大的骨干并不自动弥补一个精心匹配的小数据适配配方的价值。

Gemma-4-31B 展现出不同的错误风格。在 Run-002 上，它产生了零关键误报，但其 seen 状态召回率和样本完全匹配率低于 Qwen3.5。在 Run-004 上，Gemma 适配器相较于其基础线有显著提升，但仍然记录了比 Qwen3.5 适配器更多的关键误报。因此，对比支持一个保守的结论：13 事实数据配方可以应用于所评估的补充骨干，但部署选择仍然依赖具体骨干。Qwen3.5 是这些本地基准测试中的最佳配置；Gemma 在一个保留集上更保守，但不够完整。

6.1.4 错误分析

Qwen LoRA 的错误画像也解释了为什么第 四章中的本体修订是重要的。粗粒度的页面存在事实近乎完美解决。细粒度状态指示器在适配后大多数可靠，但完成类信号仍然是主要的残余风险。小文本事实可用，但对立即可辨的显示状态仍然敏感。

基础模型的主要失败模式是对稀有状态的单向幻觉。在较大的 Run-004 保留集中，FCS-MC 中间结果仅出现在 100 个样本中的 7 个中，但基础模型在额外的 60 个样本中断言该状态为 `seen`。LoRA 适配器几乎完全消除了这种弥漫性幻觉模式。剩余的误差数量更少且更可诊断，这正是基于证据的教学系统所需要的错误画像类型：运行时可以推理一组已知的有界视觉事实风险，而不是将原始 VLM 文本视为不透明的权威。

6.2 RQ1：系统级技术就绪性

RQ1 关注的是运行时能否以技术上可靠且可审计的方式整合证据源。因此，相关证据不是参与者表现，而是帮助循环决策的可复现性、已知失败模式的回归覆盖率，以及用于后续分析的导出质量。

6.2.1 回放评估

回放评估套件定义了五个测试用例：无操作、电池开启、电池与发电机关闭、FCS 复位与 BIT，以及 INS 校准（见附录 九，表 9.4）。每个用例包含 DCS-BIOS 原始捕获，并在适用时包含视觉依赖步骤的逐帧 sidecar 文件。该套件同时覆盖了仅遥测和视觉辅助的回放条件。其作用是展示录制状态可以通过与约束实时教学的同一过程包、遥测映射、UI 映射、证据策略和 Harness 契约进行驱动。

6.2.2 Harness 夹具回归

步骤 Harness（第 3.6 节）通过覆盖矩阵中的 20 个 live-fixture 回归条目进行了覆盖。每个条目重放一个特定的实时遥测快照通过帮助循环，并断言期望的结果。这些夹具覆盖了五类就绪性风险：步骤已完成后仍然推进、错误目标阻止与修复、防止过期 VLM 证据泄漏到非视觉步骤、对移动/稳定控件的等待行为，以及交互语义的保留（如鼠标滚轮控件）。这一覆盖率并不证明导师具有教学有效性；它表明已知的证据根基失败已被捕获为可复现的测试。

6.2.3 实验导出基础设施

实验导出流水线（第 4.7 节）已在九次实时 VR 试验中得到运用，为每次试验生成了试验摘要、步骤编码、帮助循环、操作时间线、原始事件副本和质量门控报告。全部九次导出均无阻塞性质量门控错误，且记录的过程包、分类法、UI 映射和 DCS-BIOS-to-UI 哈希值在整个研究中保持一致。这支撑了 RQ1 的测量工具部分：运行时能够从真实参与者会话中产生可审计的产物。它也暴露了一个剩余的局限。一次试验 P04 在非严格模式下通过，但出现了问卷、录像、任务和提示词关联字段缺失的元数据警告。这些警告不会使下面使用的任务指标失效，但它们表明在更大规模的受控研究之前，参与者/会话元数据 Schema 应予以收紧。

6.3 RQ3：形成性 VR 试点研究

一项小型形成性试点研究以九名参与者开展。四名参与者在 F/A-18C 冷启动任务中使用导师系统，五名在无导师辅助的情况下练习。该试点的目的是描述性的：展示运行时、叠加层指导、视觉证据路径和导出流水线在实时 VR 使用中的表现。它不是一个有统计效力的受控实验，不支持关于学习收益、工作负荷、记忆保持、迁移或任务速度的推断性声明。方法论细节见第 4.7 节。

6.3.1 参与者与试验概览

表 6.4 总结了每位参与者的条件、完成状态、人工审查的步骤完成情况、观察时长和关键交互计数。当自动重建与人工审查不一致时，该表以人工步骤编码作为权威来源。

Table 6.4: 参与者与试验概览。观察时长为从第一次遥测事件到最后一轮的挂钟间隔；对未完成试验而言，它不是完成时间的度量。

P	条件	完成	步骤	时长 (s)	帮助	VLM	叠加	降级
P01	without_tutor	no	23/33	2015	0	0	0	0
P02	without_tutor	no	27/33	739	0	0	0	0
P03	without_tutor	no	24/33	243	0	0	0	0
P06	without_tutor	no	29/33	269	0	0	0	0
P07	without_tutor	no	19/33	218	0	0	0	0
P04	with_tutor	yes	33/33	442	19	6	22	6
P05	with_tutor	yes	33/33	317	7	2	6	2
P08	with_tutor	yes*	33/33	332	7	5	10	4
P09	with_tutor	yes	33/33	1033	44	10	44	9

*P08: 自动摘要报告未完成；人工编码确认 33/33 完成（见下方数据质量注记）。

完成情况。所有四名有导师辅助的参与者在人工审查下达到了最终的 33 步状态。五名无导师辅助的参与者无一完成完整程序；他们在完成 19–29 步后停止。无导师辅助条件下最常见遗漏的步骤是 S18 (FCS-MC BIT 页面)、S19 (FCS BIT 最终 GO) 和 S27 (襟翼开关至 AUTO)，每位步骤均被全部五名无导师辅助参与者遗漏。

观察时长。有导师辅助的试验范围为 317s 至 1033s（中位数 387s）。无导师辅助试验范围为 218s 至 2015s。这些值仅作为追踪时长报告。由于无导师辅助试验在不同的程序节点结束，这些时长不是条件间的完成时间比较。

6.3.2 程序性错误

表 6.5 报告了每参与者的人工错误计数。

遗漏错误。无导师辅助条件显示出明显的遗漏模式：五分之四的参与者记录了遗漏错误，三名参与者记录了七个或以上的遗漏。相比之下，有导师辅助条件记录了零人工遗漏错误；在人工审查下，每个必需的步骤最终都被完成。

执行错误与提示错误。有导师辅助条件显示出不同的错误画像。CO 和 PA 错误出现在 P04、P05 和 P09 中，而 P08 在审查后没有人工编码的程序性错误。这些错误是辅助耦合型的：参与者通常遵循了指导，但指导或其时机并未完全匹配程序规范或当前状态。这是一个重要的形成性发现。导师条件与程序中的持续推进相关联，但也引入了新的指导风险类别，这些风险应在更大规模的研究之前予以减少。

Table 6.5: 每参与者人工程序性错误计数（来自人工步骤编码）。OM = 遗漏，CO = 执行错误，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违反。

P	条件	OM	CO	OR	PA	SV
P01	without_tutor	8	0	1	0	1
P02	without_tutor	0	0	0	1	0
P03	without_tutor	7	0	2	0	2
P06	without_tutor	2	0	0	2	0
P07	without_tutor	11	0	0	0	0
P04	with_tutor	0	3	0	3	1
P05	with_tutor	0	3	0	3	0
P08	with_tutor	0	0	0	0	0
P09	with_tutor	0	3	0	2	0

错误总计。无导师辅助参与者平均有 7.4 个人工错误；有导师辅助参与者平均有 4.5 个。这一差异仅为描述性，不应被解读为推断性的处理效应。更重要的是定性的发现：无导师辅助的错误以遗漏为主，而有导师辅助的错误转向执行错误、提示/辅助错误和一次状态违反。

6.3.3 教学交互

表 6.6 总结了四次有导师辅助试验的教学交互指标。

Table 6.6: 教学交互摘要（仅导师辅助条件）。

P	帮助循环	VLM 调用	叠加执行	叠加拒绝	降级
P04	19	6	22	0	6
P05	7	2	6	0	2
P08	7	5	10	0	4
P09	44	10	44	0	9
合计	77	23	82	0	21

全部 77 个帮助循环使用了模型生成路径；没有循环降级到仅确定性响应。四次有导师辅助试验中 VLM 调用合计 23 次。当前过程包将 S08、S15、S18 和 S19 视为视觉优先步骤，但试点日志也揭示了在非视觉或已推进状态下偶尔出现不必要的 VLM 调用。这种过度触发是运行时调优问题，而非参与者结果。

叠加拒绝率为零：全部 82 个已执行的叠加操作通过了运行时的证据根基、白名单和 Schema 检查。21 个降级事件 ($21/77 =$ 帮助循环的 27%) 并非仅确定性的降级。它们是 Harness 或验证器对模型提议的叠加层计划的修复，例如将粗粒度的显示目标重

映射为更具体的 BIT-root 子状态目标。这支撑了 RQ1 的声明：实时系统能够在叠加层到达之前修复模型输出，同时也显示了模型在哪些地方仍然需要运行时纠正。

6.3.4 数据质量注记

1. **P08 自动摘要校正。**自动化流水线将 P08 报告为未完成 (5/33 步)。人工遥测审查确认所有 33 步均达到所需状态。自动流水线未能从被动遥测中为视觉优先步骤重建完成证据。人工编码覆盖自动摘要；P08 报告为已完成，0 个人工错误。
2. **P02 问卷排除。**P02 的问卷 JSON 文件包含内部参与者 ID 不匹配，表明标注错误。P02 被排除在任何工作负荷、TLX 或信心摘要之外。来自试验摘要和人工步骤编码的任务指标保留。
3. **质量门控解释。**全部九次参与者导出均无阻塞性质量门控错误通过。P04 仍然存在问卷、录像、任务和提示词关联字段缺失的元数据警告。这些警告限制了问卷级分析和可追溯性，但不与表 6.4 和表 6.5 中报告的任务指标相矛盾。
4. **时长解释。**无导师辅助试验在参与者无法继续推进的不同程序节点结束。观察时长仅为完整性报告，不支持条件间的完成时间比较。
5. **非随机分配。**参与者基于排期可用性被分配到条件，非随机化。先前的 DCS 和 VR 经验在参与者之间有所不同（见附录 九，表 9.5）。

6.3.5 试点发现总结

本次试点提供了三项形成性证据。第一，导师条件在这些四次试验中支撑了程序推进：全部四名有导师辅助参与者完成了经审查的 33 步程序，而五名无导师辅助参与者无一完成。第二，错误模式发生了变化。导师条件消除了编码遗漏，但并未消除所有程序性问题；辅助耦合的 CO 和 PA 错误出现在四分之三的有导师辅助试验中。第三，实时教学基础设施在 77 个帮助循环和 82 个叠加层执行中无叠加拒绝地运行，同时记录了审计所需的修复和降级决策。

纵观全章，最强的实证声明是 RQ2 VLM 结果：小数据 LoRA 适配在本地保留集上产生了可靠得多的 13 事实视觉提取器。RQ1 得到了回放、Harness 和导出证据的支撑，表明运行时可以被审计和回归测试。RQ3 得到了已完成的形成性 VR 试点的支撑，但仅达到描述性强度。这些结果并未建立学习改进、工作负荷降低、技能获取加速、记忆保持或迁移。这些声明需要更大规模、随机化、受控的研究。

第七章 讨论

第 六 章报告了三条证据线，其声明强度各不相同：针对 RQ2 的视觉事实基准测试、针对 RQ1 的回放与安全约束就绪证据，以及针对 RQ3 的形成性 VR 试点。本章对这些证据线进行综合解读。核心主张并非教学系统已被证明能够改善学习效果，而是本论文展示了一种方法，通过在学习者与基础模型响应之间放置遥测数据、程序性规则、检索到的来源、VLM 导出的视觉事实以及安全约束验证，使程序性教学系统在技术上变得可审计。

第 7.1 节解释了实现的工作与原提案之间的差异。第 7.2 节对技术证据进行解读。第 7.3 节在其形成性边界内讨论试点发现。第 7.4 节从本体演进中提炼主要的设计经验。第 7.5 节和第 7.6 节阐述了论文的局限性以及最直接的研究下一步方向。

7.1 从提案到实现系统的演变

原始论文提案 [24] 描述了一个面向 Meta Quest 3 的 VR 优先教学系统，具备眼动追踪、手部追踪、语音输入、RAG+LLM 后端，以及一项受控的三条件人类受试者研究。最终的论文保留了沉浸式程序性教学的动机，但工作的重心发生了转移。最终实现的贡献最好理解为：一个基于证据的教学运行时系统与视觉事实提取方法，而 VR 则用于形成性试点而非受控的有效性声明。

这一转变不仅仅是工程的便利。冷启动程序使得一个前置问题变得可见：在教学系统能够提供有用的程序性帮助之前，它必须知道哪些状态可以被信任。某些所需的证据通过 DCS-BIOS 以遥测数据形式导出，某些证据仅在座舱显示屏上可见，某些步骤是手动的、不在布局中的或不适合自动确认的。因此，论文必须首先构建证据层：程序包、门控推理、证据包、检索边界、VLM 视觉事实、受 Schema 约束的模型输出、安全约束验证、叠加层白名单以及可回放日志。

VLM 工作也源于同样的压力。提案假设仿真器状态足以满足程序性跟踪的需求。然而在实践中，诸如对准和 BIT 状态等显示页内容必须通过视觉观察获取，这催生了 13 事实本体、经过人工审核的截图数据集、LoRA 适配流水线以及独立的留存基准测试。这些成为核心贡献，因为它们定义了如何将基础模型用作一个有界的感知组件，而

非一个不加约束的程序状态判断器。

已完成的 VR 试点部分回应当了原始提案中人类受试者研究的宏愿。它表明，基于证据基础的运行时系统可以在头戴式设备中面向真实参与者运行，并且导出流水线可以捕获后续分析所需的数据。然而，它并未完成项目之初所提出的受控三条件研究。在 $n = 9$ 、非随机分配且一名参与者的问卷数据未解决的情况下，该试点是形成性和描述性的。

7.2 技术证据的解读

最强的技术结果是 RQ2 视觉事实基准测试。在 Qwen3.5-9B 主干上，主要 LoRA 线在两个独立的 13 事实留存集上均达到约 0.99 的事实准确率，同时相对于基座模型大幅减少了关键假阳性。补充的 Qwen3.6-27B 和 Gemma-4-31B 结果表明，相同的数据和本体配方并非绑定于单一骨干模型，虽然论文并不主张广泛的模型家族通用性。更重要的解读更窄也更有用：一个经过审核的、与本体对齐的小型数据集可以使 VLM 在座舱视觉事实提取方面的可靠性显著优于相应的基座模型（在本地留存数据上）。

这一结果的重要性在于：教学运行时系统将 VLM 输出视为证据而非权威。诸如可见页面、标签或状态文本等视觉事实是下游步骤推理的输入之一，程序引擎仍会将视觉事实与遥测数据、程序顺序、时间上下文以及程序包定义的门控结合起来。正是这种分离防止了基准测试结果沦为缺乏支撑的教学声明。VLM 结果支持教学系统的感知层，但本身并不证明教学系统的教学效果更好。

RQ1 的回放与安全约束证据支持论文的另一部分。回放案例、在线 Fixture 覆盖、程序包导出的 Schema、响应映射以及叠加层白名单表明，所实现的运行时系统能够在模型输出到达学习者之前对其进行约束。这是一种技术就绪性与可审计性的声明，意味着帮助循环可以被回放、检查和对照显式证据契约进行验证。这并不意味着每个未来的模型响应都将在教学上最优，也不意味着该运行时系统已经跨仿真器或跨程序得到了验证。

综合而言，技术证据支持了架构的核心前提：当基础模型的角色被显式证据生成与验证所约束时，它们可以在程序性教学中发挥作用。论文并非要求 LLM 作为真相的来源，而是要求 LLM 在一个运行时系统中生成响应——在该系统中，可观察状态、程序包、检索到的来源以及安全约束共同定义了响应可以安全地主张或高亮的内容。

7.2.1 技术证据未能证明的内容

技术证据未能显示学习增益、记忆保持、迁移效果、工作负荷降低或更优的训练成果。VLM 基准测试测量的是单帧视觉事实提取，回放与安全约束测试测量的是证据契

约和输出约束是否按预期运行。这两者对于一个可靠的教学系统而言都是必要的，但任何一项都不足以构成人类学习效果的声明。一个学习者可能接收到准确、有据可查的帮助，却仍然无法形成持久的程序性理解；相反，一个学习者也可能从一个不那么精密但恰好契合其已有知识和策略的系统中学到东西。

证据也尚未隔离每个组件的价值。本论文未包含消融实验来对比仅遥测教学、视觉增强教学、不同检索策略或不同安全约束严格程度。因此，评估支持的是一个集成的工件声明：所实现的系统展示了一种将上述各元素在技术上可审计地组合起来的方式，而非对每个设计选择与其替代方案进行排序。

7.3 试点发现的解读

形成性 VR 试点提供了关于系统实际使用的描述性证据。在经过审核的数据中，所有四名有教学系统辅助的参与者完成了 33 步程序，而五名无教学系统辅助的参与者均未完成。手动编码还显示，教学系统辅助条件下无遗漏错误，而无教学系统辅助条件下的遗漏错误平均为 5.6 个。这些观察与教学系统的预期功能一致：它保持当前程序步骤可见，检索相关的程序上下文，并能指导学习者找到座舱控制。

相同的数据也表明，辅助并不能消除程序性错误。在教学系统辅助条件下，执行错误和提示辅助错误仍然存在。这是一个重要的发现，因为它指向了一个比“教学系统是否有帮助？”更精确的设计问题。剩下的问题是：灵活的模型生成式指导、确定性的安全约束修复、视觉状态的不确定性以及人类操作时机如何与严格的程序规范对齐。教学系统可以减少遗漏步骤的模式，但仍可能留下时机不当、执行不完整或过度信赖辅助的空间。

实时帮助循环日志支持了基础设施的主张。在四次有教学系统辅助的试验中，系统记录了 77 个帮助循环、23 次 VLM 调用、82 次叠加层执行、零次叠加层拒绝以及 21 次回退或修复事件。零次叠加层拒绝不应被解读为“一切顺利”。相反，它意味着在 Schema 验证和安全约束处理后，所提议的叠加层动作保持在已配置白名单范围内。修复事件是约束层正在活跃运行的证据，而非模型输出始终直接正确的证据。

因此，该试点在论文中有两个角色。首先，它表明经过仪器化装备的教学运行时系统可以在真实 VR 环境中使用并产生可分析的日志；其次，它揭示了后续受控研究应该更仔细测量的那种人机交互数据。它不支持关于学习效果、工作负荷、记忆保持、迁移效果或任务速度的因果性主张。

7.4 本体设计经验

本体演进是本论文中最清晰的设计经验。初版视觉事实本体将可观察事实与程序性结论混合在一起。例如，`ins_go` 要求 VLM 判断对准状态是否已有效达到。该目标不仅仅是视觉性的，它依赖于特定的显示文本、其他显示状态的缺失以及程序阶段。第一次基准测试中的失败模式揭示了这一边界问题：一个单帧 VLM 被要求同时执行感知和程序推理。

13 事实本体纠正了这一边界。它将复合目标分解为更低层的视觉观察，例如接地对准文本或 OK 文本是否可见，并将 FCS-MC 状态分解为视觉上可区分的阶段。下游运行时系统随后将这些观察与遥测数据和程序上下文结合起来解释。因此，设计原则是：

视觉事实目标应该是低层级的、可局部验证的视觉命题。更高层级的程序状态应该在下游从视觉事实、遥测数据、时间上下文和程序规则中推断得出。

这条原则的意义超越了标签命名。它影响标注质量、训练信号质量、错误诊断和运行时安全性。一位人工审查者可以在不知道程序历史的情况下判断一段文本是否在截图中可见，但同一位审查者如果不知道图像之前发生了什么，则无法总是判断程序状态是否完成。当事实契约尊重这一区别时，模型的输出变得更容易审查，也更安全地可以与确定性门控结合起来。

在完成型事实上残留的假阳性显示了该方法的当前边界。某些状态在中间阶段和最终阶段之间视觉上相似，尤其是在涉及数值读数或瞬态显示状态时。这些情况可能需要更平衡的数据、更高分辨率的裁剪、重复观察或显式引入时序信息的 VLM 输入。因此，论文并不主张 13 事实本体普遍解决了视觉接地问题，而是为一项高要求的程序提供了一种经过验证的设计纪律，以及一种用于发现视觉目标何时仍然过于接近程序性结论的具体方法。

作为面向未来领域的启发式规则，原则很简单：如果一个事实无法在不知道程序步骤的情况下从单张图像中标注，那么它对 VLM 契约来说可能层级过高，应该被分解为可见原子事实或推迟给程序引擎处理。正是在这一点上，论文从一个案例特定的实现细节转向了可复用的表示经验。

7.5 局限性

论文的贡献应在以下局限性范围内理解。

7.5.1 评估范围

所有数据集、回放案例和试点试验均涉及一个程序：F/A-18C 冷启动。视觉提取器在相同的机型与渲染环境下的固定复合座舱面板上训练和评估。留存集是零训练重叠的独立会话，但测量的仍为域内泛化，而非建立跨程序、跨机型或跨仿真器的通用性。

最大的训练配方在 Run-005 过采样步骤后包含 928 行双语 SFT 数据。这对于一项特定领域的适配研究而言刻意地小且具有实用价值，但它并未识别出最低数据需求、性能上限或每个配方组件的效果。论文未包含针对双语行、过采样、LoRA 秩、组合再平衡或替代微调方法的消融实验。

7.5.2 系统与 VLM 范围

VLM 作为单帧视觉事实提取器被评估。它不决定程序进度、不选择最终的教学系统动作、也不直接控制叠加层。在完成型事实上残留的关键假阳性仍然重要，因为一个错误的视觉观察如果没有被遥测数据、时序确认或安全约束检查，仍可能影响下游推理。粘性事实和确认策略缓解了这一风险，但其完整的端到端效果尚未通过实验隔离。

骨干比较涵盖了 Qwen3.5-9B、Qwen3.6-27B 和 Gemma-4-31B，在匹配的 LoRA 式适配配方下进行。这在本项目范围内是有用的模型多样性证据，但并未覆盖其他 VLM 家族、更大模型、全量微调、替代适配器或非座舱视觉领域。

运行时系统通过回放、Fixtures、桌面 DCS 和 Quest 3 试点进行了实现和演练。然而，头戴设备延迟、叠加层可读性、眼动或手部追踪精度以及专家评定的响应有用性并未作为受控的系统级结果进行测量。

7.5.3 试点范围

试点包含九名参与者：四名有教学系统辅助和五名无教学系统辅助。分配未随机化，已有 DCS 经验未平衡，样本量过小无法进行推断性统计。无教学系统辅助的试验在不同程序点停止，因此其持续时间无法与完成的有教学系统辅助试验进行比较。

问卷和工作负荷证据不完整。P02 的问卷元数据无法被可信地归因，且 NASA-TLX 整合未纳入已完成的导出流水线。因此，试点支持的是任务日志和编码观察，而非工作负荷、信心或主观可用性结论。

最后，手动审查从被动遥测门控和动作时间线推断出无教学系统辅助条件下的完成情况。由于主动 VLM 通路在该条件下不可用，视觉证据支撑的步骤确定性较低。这一局限性并不否定形成性发现，但它说明了为什么下一步研究需要更严格的仪器装备和编码。

7.5.4 范围总结

在上述局限性范围内，论文支持四项主张：一个受证据约束的程序性教学运行时系统可以以显式架构边界实现；一个小数据 VLM 适配流水线可以在本地留存集上产生可靠的视觉事实提取；视觉本体演进提供了一条关于感知与推理之间边界的具体设计经验；VR 试点表明系统可以在有参与者的条件下运行并产生可分析的日志。它并不确立受控的教育有效性。

7.6 未来工作

上述局限性指向了一个聚焦的研究议程。

7.6.1 受控人类受试者评估

下一项研究应将具有依据的教学系统与基线条件进行对比，采用随机分配、平衡的参与者元数据、预定义的编码规则以及完整的问卷和工作负荷捕获。在下一轮迭代中，两条件设计相比原提案的三条件设计更为现实，因为当前的优先事项是确定已完成的运行时系统是否能在受控条件下产生可测量的完成度、错误、工作负荷和记忆保持方面的差异。

7.6.2 向其他程序的本体扩展

13 事实本体应仅在经过新的任务分析后扩展到其他程序——该分析需识别哪些步骤是遥测可见的、视觉优先的，或手动的/不在布局中的。每个新程序都需要自己的视觉事实契约、经审核的数据集、留存基准测试以及运行时绑定。这是检验本体纪律是否能迁移到冷启动之外场景的适当测试。

7.6.3 时序与多帧视觉推理

若干残留错误涉及难以从单张截图中消除歧义的状态。多帧输入、短视觉历史或重复确认门控可能有助于区分中间和最终显示状态。这需要更改捕获方式、标注、模型输入格式和基准测试指标。

7.6.4 系统级帮助循环评估

应单独评估完整的帮助循环而非各组件：触发到叠加层的延迟、高亮目标的正确性、安全约束修复的频率与类型、专家审阅下的响应有用性，以及视觉优先步骤是否

优于仅遥测基线。这将更直接地将 RQ1 和 RQ2 的技术证据与 RQ3 连接起来。

7.6.5 原位纠正与自适应

当前 VLM 适配流水线是离线的。未来版本可以在视觉事实错误时收集教员或学习者的纠正，并将这些纠正输入到后续审查或增量自适应中。这一方向需要谨慎的安全防护，因为在位标签可能带有噪声，且自适应不能抹除先前可靠的行为。

7.6.6 未来方向总结

表 7.1 总结了主要的未来工作方向以及每个方向所回应的局限性。

Table 7.1: 未来工作方向总结。		
方向	当前状态	主要挑战
受控人类受试者研究	形成性试点已完成；因果证据待定	随机化、元数据、工作负荷与统计功效
本体扩展	冷启动本体仅在当前座舱布局内进行了评估	新任务分析、标注与留存设计
时序视觉推理	当前 VLM 使用单张复合面板帧组件与回放证据已可用	多帧数据、模型容量与时序指标定义综合延迟、质量与修复指标
系统级帮助循环评估	离线审查与 LoRA 流水线已实现	噪声标签、灾难性遗忘与安全更新策略
原位纠正与自适应		

这些方向保持了论文的核心主线不变。下一阶段不是让基础模型变得更不受约束，而是强化围绕它的证据循环：更广泛的程序包、更好的视觉事实、更丰富的时序证据、受控的人类评估，以及使每个教学系统响应在事后均可审计的日志。

第八章 结论

本论文始于一个在许多程序性训练场景中普遍存在的实践问题：学习者在复杂仿真系统内操作时经常需要帮助，但有用的帮助必须立足于是当前的真实状态。当下一个正确操作取决于遥测数据、程序顺序、显示状态和先前操作时，仅靠一个流畅的基础模型响应是不够的。本论文发展出的核心答案是：当基础模型被置于一个可审计的证据循环之内时，它们可以变得适用于程序性教学。

F/A-18C 冷启动任务为这一理念提供了一个高要求的案例。它要求教学系统结合遥测可见的座舱状态、来自显示页面的视觉证据、检索到的程序性知识、手动或不在布局中的边界，以及验证——然后才能产生叠加层或文本指导。最终结果并非宣称学习有效性已得到证明，而是一项技术与方法论的贡献：一种使模型辅助的程序性帮助变得具备状态感知能力、可检查和受可用证据约束的方法。

8.1 已完成工作总结

已完成的工作对三项研究问题作出了如下回答。

RQ1：证据整合与教学架构。 论文展示了如何将仿真器遥测数据、检索到的程序性来源以及视觉事实观察整合到一个受约束的帮助循环中。运行时系统在模型生成之前构建证据包，从声明式门控中推断候选程序步骤，要求模型在程序包导出的 Schema 内生成响应，通过安全约束层验证或修复响应，并仅执行白名单内的叠加层动作。日志记录与回放则使产生的帮助循环在事后可被检查。这从技术可审计性的层面回答了 RQ1：LLM 不是程序状态的权威，而是一个受证据、Schema、安全约束和程序包规则约束的生成器。

RQ2：视觉事实提取与本体设计。 论文还表明，小数据 VLM 适配可以支持针对教学系统所需的座舱显示状态的可靠视觉事实提取。13 事实本体与 LoRA 训练流水线在 Qwen3.5-9B 主线上产出了最强的核心结果，在两个独立的 13 事实留存集上达到约 0.99 的事实准确率，并且相对于基座模型大幅减少了关键假阳性。补充的 Qwen3.6-27B

和 Gemma-4-31B 结果在已评估的骨干范围内支持了相同的数据与本体配方。更一般的经验是表示性的：VLM 应报告可局部验证的视觉事实，而程序性完成应该在下游从视觉事实、遥测数据、时间和程序上下文中推断得出。

RQ3: 形成性 VR 试点证据。 已完成的 Quest 3 试点提供了关于运行时系统和仪器装备能否在沉浸式仿真环境中与参与者一起运行的形成性证据。在经过审核的数据中，四名有教学系统辅助的参与者完成了 33 步程序，而五名无教学系统辅助的参与者未能完成。遗漏错误在教学系统辅助条件下消失，而与辅助耦合的错误依然存在。帮助循环日志还表明，教学系统可以在线运行，包括 VLM 调用、叠加层动作、安全约束修复和可回放导出。这些发现以描述性方式回答了 RQ3。它们支持可行性、仪器装备就绪性和错误模式分析；并不确立因果性的学习增益、工作负荷降低、记忆保持、迁移效果或速度提升。

综合而言，这些答案定义了论文的贡献。首先，该工作为程序性仿真提供了一个基于证据的教学运行时系统模式，其中生成的帮助是显式状态证据和验证的下游产物。其次，它贡献了将 VLM 感知与程序性推理分离的视觉事实本体和适配方法。再次，它提供了一条可进行试点的评估路径，用于研究有真实 VR 参与者参与的有依据教学。贯穿三者的关键点不在于 LLM 或 VLM 本身的存在，而在于放置在基础模型输出周围的边界。

论文的范围保持了刻意限定。评估涵盖一个程序、一种座舱布局、本地视觉留存集、回放与安全约束就绪性，以及一个小规模非随机的试点。当前证据对技术可靠性和可审计性的支持强于对教育有效性的支持。它并未表明教学系统可以跨领域泛化，也未表明试点中的差异仅由教学系统造成。这些边界不是需要隐藏的弱点，而是使贡献可被审查的前提。

8.2 未来工作

最直接的下一步是一项受控的人类受试者评估。此类研究应保留当前导出和回放基础设施，但增加随机分配、平衡的参与者元数据、完整的问卷与工作负荷捕获、预定义的编码规则，以及足以进行推断性分析的样本量。只有这类研究才能检验在技术上具备依据的帮助循环是否以及如何改变学习效果、工作负荷、记忆保持或迁移效果。

技术议程同样清晰。程序包和视觉事实方法应扩展到其他程序，但每个扩展都需要新的任务分析、证据源映射、视觉本体设计、经审核的数据集以及独立的留存评估。VLM 流水线还应超越孤立截图的处理——当程序状态依赖于时序证据时：短视觉历史、重复确认或多帧输入自然成为处理完成型事实的下一步机制。最后，完整的帮助循环应作为集成系统进行评估，包括延迟、叠加层正确性、安全约束修复频率以及专

家评定的响应有用性。

该系统的长期版本可以从教员或学习者的原位纠正中学习。这一方向将把实时教学转变为数据收集循环，但它需要谨慎的安全防护：纠正标签可能带有噪声，更新不得抹除已可靠的行为，且每个经过自适应的模型必须仍然在接受未触及的留存集评估。

本论文的标题 *Explain Reality* (解释现实) 凝结了最终的设计承诺。一个程序性教学系统不应仅仅解释一份检查单，也不应仅仅生成关于任务的流畅语言描述。它应解释学习者当前的现实：哪些是可观察的、哪些证据支持它、哪条程序规则适用、哪些仍存在不确定性，以及为何下一个响应被允许。本论文的贡献在于提出了一种架构和一套证据方法，使得这种解释变得可审计。

参考文献

- [1] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, et al. Do as i can, not as i say: Grounding language in robotic affordances. In *Proceedings of the 6th Conference on Robot Learning*, 2022. doi: 10.48550/arXiv.2204.01691.
- [2] Vincent Aleven, Bruce M. McLaren, Jonathan Sewall, and Kenneth R. Koedinger. A new paradigm for intelligent tutoring systems: Example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2):105–154, 2009. doi: 10.3233/IRG-2009-19(2)02.
- [3] Saleema Amershi, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, Jina Suh, Shamsi Iqbal, Paul N. Bennett, Kori Inkpen, Jaime Teevan, Ruth Kikin-Gil, and Eric Horvitz. Guidelines for human-AI interaction. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, pages 1–13, 2019. doi: 10.1145/3290605.3300233.
- [4] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.
- [5] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems*, volume 36, 2023. doi: 10.48550/arXiv.2305.06500.
- [6] DCS-BIOS Project. DCS-BIOS documentation, n.d. DCS-BIOS v0.10.0 documentation. Accessed 2026-06-05. Available at: <https://dcs-bios.readthedocs.io/en/latest/>.

-
- [7] Eagle Dynamics. DCS World, 2013. Digital Combat Simulator. Available at: <https://www.digitalcombatsimulator.com/>.
- [8] Eagle Dynamics. DCS: F/A-18C early access guide, 2023. Updated 18 July 2023. Available at: https://www.digitalcombatsimulator.com/en/downloads/documentation/dcs-hornet_early_access_guide_en/.
- [9] David Gunning, Mark Stefik, Jaesik Choi, Timothy Miller, Simone Stumpf, and Guang-Zhong Yang. XAI—explainable artificial intelligence. *Science Robotics*, 4(37):eaay7120, 2019. doi: 10.1126/scirobotics.aay7120.
- [10] Daniel Han and Michael Han. Unsloth: Open-source library for faster LLM fine-tuning, 2024. URL <https://github.com/unslothai/unsloth>.
- [11] Robert T. Hays, John W. Jacobs, Carolyn Prince, and Eduardo Salas. Flight simulator training effectiveness: A meta-analysis. *Military Psychology*, 4(2):63–74, 1992. doi: 10.1207/s15327876mp0402_1.
- [12] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuezhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [13] Enkelejda Kasneci, Kathrin Seßler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günnemann, Eyke Hüllermeier, Stephan Krusche, Gitta Kutyniok, Tilman Michaeli, Claudia Nerdel, Jürgen Pfeffer, Oleksandra Poquet, Michael Sailer, Albrecht Schmidt, Tina Seidel, Matthias Stadler, and Gjergji Kasneci. ChatGPT for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274, 2023. doi: 10.1016/j.lindif.2023.102274.
- [14] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- [15] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in Neural Information Processing Systems*, 36, 2023. doi: 10.48550/arXiv.2304.08485.

-
- [16] Sourab Mangrulkar, Sylvain Gugger, Lysandre Debut, Younes Belkada, Sayak Paul, and Benjamin Bossan. PEFT: State-of-the-art parameter-efficient fine-tuning methods, 2022. URL <https://github.com/huggingface/peft>.
- [17] Antonija Mitrovic. Fifteen years of constraint-based tutors: What we have achieved and where we are going. *User Modeling and User-Adapted Interaction*, 22(1–2):39–72, 2012. doi: 10.1007/s11257-011-9105-9.
- [18] Riccardo Palmarini, John Ahmet Erkoyuncu, Rajkumar Roy, and Hosein Torabmostaedi. A systematic review of augmented reality applications in maintenance. *Robotics and Computer-Integrated Manufacturing*, 49:215–228, 2018. doi: 10.1016/j.rcim.2017.06.002.
- [19] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/15000000019.
- [20] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. Label Studio: Data labeling software, 2020. URL <https://github.com/HumanSignal/label-studio>.
- [21] Kurt VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011. doi: 10.1080/00461520.2011.611369.
- [22] Leandro von Werra, Younes Belkada, Lewis Tunstall, Edward Beeching, Tristan Thrush, Nathan Lambert, and Shengyi Huang. TRL: Transformer reinforcement learning, 2020. URL <https://github.com/huggingface/trl>.
- [23] Bryan Wang, Gang Li, Xin Zhou, Zhourong Chen, Tovi Grossman, and Yang Li. Screen2Words: Automatic mobile UI summarization with multimodal learning. *arXiv preprint arXiv:2108.03353*, 2021. doi: 10.48550/arXiv.2108.03353.
- [24] Yu Zhang. Explain reality: Grounded procedural tutoring with foundation models and visual fact extraction in immersive simulation — MSc thesis proposal. TU Clausthal, Institute for Software and Systems Engineering (ISSE). Unpublished manuscript., 2025.

第九章 附录

本附录为方法论、实现和评估章节提供支持材料。它保留了原始配置、数据集、回放、图表和试点编码材料，而不扩展主章节中所述的声明边界。

9.1 完整 LoRA 超参数配置

表 9.1 列出了在匹配的 Run-003 + Run-005 $\times$ 2 配方下三种骨干模型的完整超参数配置。数值来自可用的训练报告和基准测试工件。

注意：由于分词器行为、对话模板结构、目标序列分布和模型参数化的差异，训练损失值在不同骨干之间不可直接比较。

9.2 8 事实 V1 基线基准测试

最早的完整基准测试使用在 Run-001（180 个任务）上训练并在 Run-002 留存集（50 个样本）上评估的 8 事实 LoRA 适配器。该线早于 13 事实本体，在此作为历史参考收录。

LoRA 适配器大幅提升了事实级指标，但将关键假阳性从 13 增加到 15。这一历史结果说明了 8 事实 v1 本体的结构性弱点：诸如 `ins_go` 等复合目标无法从单帧中视觉验证，并在完成型事实上产生了系统性的假阳性错误。

9.3 数据集事实分布

表 9.3 报告了两个主要训练来源（Run-003、Run-005）和两个 13 事实留存集（Run-002 newfacts、Run-004 random）中每个事实的 `seen` 计数。计数来自对应的 `stats.json` 文件。表格使用简短显示标签；权威的事实标识符定义在程序包使用的视觉事实本体文件中。

Run-005 在与 Run-003 组合时为多个稀疏目标增加了覆盖：SUPT 页面观察从 20 增加到 54，FCS-MC 页面观察从 55 增加到 111，INS GRND 对准文本观察从 58 增加

Table 9.1: 三种骨干的完整 LoRA 微调超参数。

参数	Qwen3.5-9B	Qwen3.6-27B	Gemma-4-31B
max_seq_length	4096	4096	4096
num_train_epochs	4.0	4.0	4.0
learning_rate	2×10^{-4}	2×10^{-4}	2×10^{-4}
per_device_train_batch_size	1	1	1
gradient_accumulation_steps	4	4	4
lora_r	16	16	16
lora_alpha	16	16	16
lora_dropout	0.0	0.0	0.0
seed	3407	3407	3407
load_in_4bit	True	True	True
warmup_ratio	0.1	0.1	0.1
weight_decay	0.01	0.01	0.01
train_rows	928	928	928
eval_rows	0	0	0
骨干特定			
Vision LoRA	启用	启用	禁用
LoRA 目标模块	vision+lang	vision+lang	all-linear
对话模板	Qwen 默认	Qwen 默认	gemma-4
GPU 内存利用率	0.6	0.6	0.95
训练结果			
训练运行时间 (s)	6419	12619	8050
训练损失 (最终)	0.2156	0.1068	0.0474

Table 9.2: 8 事实 v1 基准测试：Qwen3.5-9B 基座 vs. LoRA-v1 在 Run-002 留存集上的对比（50 样本，EN）。

指标	基座	LoRA-v1	Δ
JSON 有效率	1.0	1.0	—
Schema 有效率	1.0	1.0	—
事实准确率	0.7600	0.9150	+0.1550
宏平均 F_1	0.4241	0.5847	+0.1605
Seen F_1	0.4714	0.8380	+0.3666
样本完全匹配	0.06	0.36	+0.30
关键假阳性	13	15	+2

Table 9.3: 训练集与留存数据集中每个事实的 `seen` 计数 (13 事实 v2 本体)。

事实标签	Run-003	Run-005	Run-002	Run-004
TAC 页面可见	46	24	23	3
SUPT 页面可见	20	34	5	3
FCS 页面可见	30	40	13	94
FCS X 标记可见	16	18	1	5
BIT 根页面可见	18	43	9	16
FCS-MC 页面可见	55	56	9	84
FCS-MC 中间结果	18	15	1	7
FCS-MC 测试中状态	18	19	6	17
FCS-MC 最终 GO 结果	18	22	2	60
HSI 页面可见	106	109	49	100
HSI 地图图层可见	79	37	27	50
INS GRND 对准文本	58	72	42	69
INS OK 文本	12	14	4	0

到 130。本表记录了数据来源；第 六 章评估了所得训练配方是否改善了模型在留存集上的行为。

9.4 CLI 命令参考

`simtutor` 包提供以下 CLI 命令：

run. 使用模拟环境适配器以预录制的场景文件执行仿真并写入事件日志。

replay. 对照程序包验证现有事件日志，检查步骤顺序和状态机一致性。

score. 使用评分引擎对事件日志进行评分，生成遗漏计数、状态违反计数和总错误分数。

record-vlm. 在一组视觉观察上运行 VLM 事实提取，并记录预测结果用于基准测试。

replay-bios. 将原始 DCS-BIOS 捕获数据通过遥测流水线回放，并可选择性地调用帮助生成循环。

validate. 对照 Schema 注册表中的命名 Schema 验证 JSONL 文件。

所有命令均接受模型配置覆盖参数(`-model-provider`、`-model-name`、`-model-base-url`、`-model-timeout-s`) 和语言切换参数 (`-lang`)。

9.5 模型提供方配置

模型访问通过环境变量配置并在运行时验证：

提供方。 SIMTUTOR_MODEL_PROVIDER 选择 openai_compat、ollama 或 stub。

基础 URL。 SIMTUTOR_MODEL_BASE_URL 设置提供方端点。

模型。 SIMTUTOR_MODEL_NAME 选择模型名称。

超时。 SIMTUTOR_MODEL_TIMEOUT_S 设置请求超时时间。

凭证。 SIMTUTOR_MODEL_API_KEY 是 openai_compat 提供方所必需的。API 密钥在日志输出中被遮蔽。

图像。 SIMTUTOR_MODEL_ENABLE_MULTIMODAL 切换请求中的 base64 图像编码。

语言。 SIMTUTOR_LANG 选择 zh 或 en。

9.6 回放评估套件

表 9.4 列出了 fa18c_startup_v04 套件中的五个回放评估案例。此处显示标签已缩短；套件文件保留了确切的 case_id 字符串。

Table 9.4: 回放评估案例。

案例	步骤	视觉	目标
空操作捕获	S01	否	电池开关
电池接通	S02	否	火警测试开关
电池接通，发动机发电机关闭	S01	否	左发电机开关
FCS 重置 / FCS BIT	S18	是	FCS BIT 开关
INS 模式	S12	是	INS 模式旋钮

标记为视觉可用的案例在对应的 DCS Saved Games 捕获中包含每帧侧车文件 (frames.jsonl)。这些文件允许依赖视觉的回放案例在无实时 DCS 实例的情况下运行。

9.7 补充架构与导出图表

主章节使用简化的图表来支持研究论证。图 9.1、9.2 和 9.3 保留了额外的工程细节，以确保可复现性和操作上下文。

Harness and evidence validation




Figure 9.1: 安全约束与证据验证。候选教学系统动作在被接受为叠加层动作计划之前，需经过 Schema 约束、UI 白名单、证据一致性和程序状态的检查；不安全或证据不够充分的动作将被修复、拒绝或降级为纯文本指导。

Deployment topology

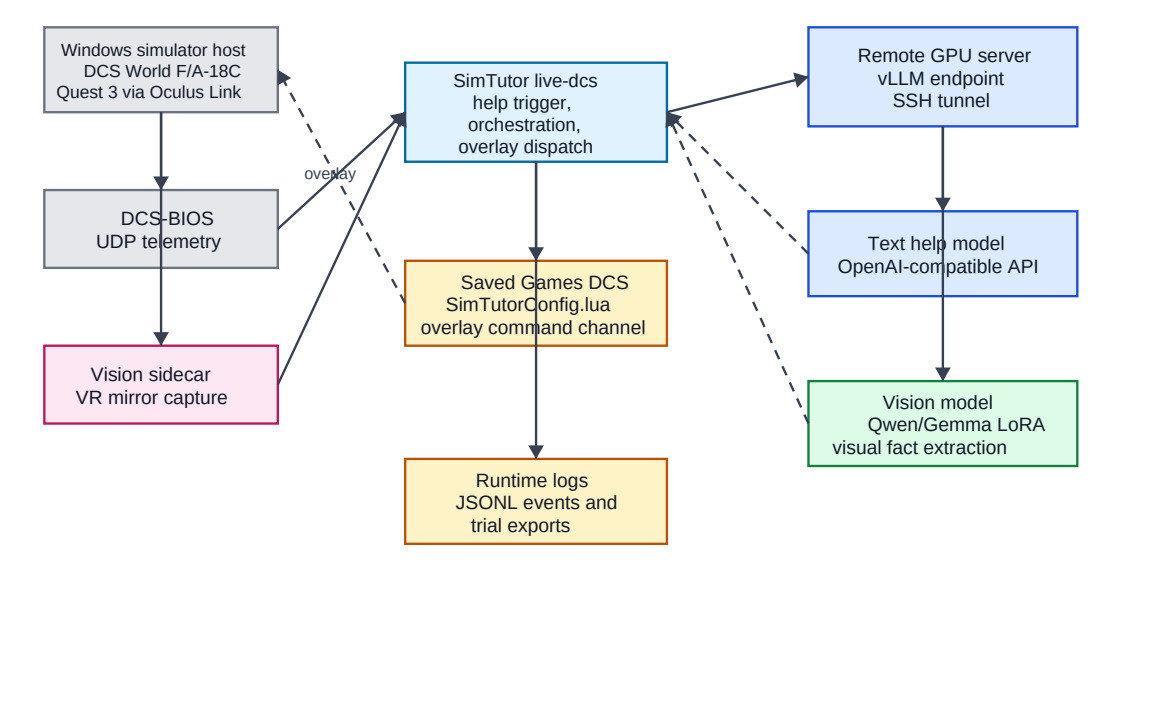


Figure 9.2: 原型所使用的部署拓扑。仿真器、Quest 3 叠加层通道、本地运行时、回放工具和远程模型提供方被区分开来，使得实时试验和离线分析可以使用相同的证据和日志记录契约。

Detailed experiment export pipeline




Figure 9.3: 详细的实验导出流水线。运行时事件日志和试验元数据被转换为参与者级摘要、步骤编码、帮助循环记录、质量门控和研究级分析表。

9.8 VR 试点研究 — 补充数据

表 9.5 列出了参与者经验概况。

Table 9.5: 试点参与者经验概况（自报告）。

P	条件	自报告经验	分组
P01	无教学系统	DCS 频繁；飞行模拟频繁；VR 频繁；Quest 3 频繁	中级
P02	无教学系统	DCS 中级；飞行模拟中级；VR 频繁；Quest 3 频繁	未记录
P03	无教学系统	DCS 新手；飞行模拟新手；VR 中级；Quest 3 频繁	入门
P04	有教学系统	DCS 中级；飞行模拟中级；VR 频繁；Quest 3 频繁	中级
P05	有教学系统	DCS 中级；飞行模拟中级；VR 频繁；Quest 3 频繁	未记录
P06	无教学系统	DCS 新手；飞行模拟新手；VR 中级；Quest 3 频繁	入门
P07	无教学系统	DCS 新手；飞行模拟新手；VR 中级；Quest 3 频繁	入门
P08	有教学系统	DCS 新手；飞行模拟新手；VR 频繁；Quest 3 频繁	未记录
P09	有教学系统	DCS 新手；飞行模拟新手；VR 中级；Quest 3 中级	入门

未记录 = 未记录。

表 9.6 列出了每位无教学系统辅助参与者未完成的具体步骤。

Table 9.6: 无教学系统辅助条件下未完成的步骤（手动编码）。

P	未完成的步骤
P01	S09、S12、S18、S19、S20、S22、S24、S27、S29、S31
P02	S02、S14、S18、S19、S27、S30
P03	S07、S09、S16、S18、S19、S26、S27、S29、S32
P06	S07、S18、S19、S27
P07	S02、S09、S12、S13、S16、S17、S18、S19、S22、S26、S27、S28、S29、S32

S18（右 DDI 上的 FCS-MC BIT 页面）和 S19（FCS BIT 最终 GO 结果）被所有五名无教学系统辅助参与者遗漏，且属于视觉优先的显示检查。S27（襟翼开关置于 AUTO）同样被所有五名参与者遗漏，但程序包将其归类为 BIOS 优先，使用变量和门控证据而非 VLM 约束的视觉证据。因此，该模式是描述性的：它显示了参与者在哪些地方遇到困难，而非某一种证据源能够解释遗漏。

表 9.7 报告了自动编码的错误计数（手动审查前）与手动错误计数的对比，显示了在试点解读之前自动导出结果有多少需要被纠正。

Table 9.7: 每位参与者的自动编码 vs. 手动错误计数。

P	条件	自动遗漏	自动执行	手动遗漏	手动执行	手动总计
P01	无教学系统	4	3	8	0	10
P02	无教学系统	0	3	0	0	1
P03	无教学系统	0	4	7	0	11
P06	无教学系统	0	3	2	0	4
P07	无教学系统	1	9	11	0	11
P04	有教学系统	0	4	0	3	7
P05	有教学系统	0	3	0	3	6
P08	有教学系统	0	3	0	0	0
P09	有教学系统	0	3	0	3	5

自动编码错误来自自动化流水线 (`step_coding.csv` 中的 `Auto_Error_*` 列)。手动错误来自经人工审查的列 (`Error_*`)。P08 的自动错误经手动审查后全部被覆盖为零 (参见第 6.3 节中的数据质量说明)。