



TU Clausthal

硕士学位论文

作者：

Yu Zhang

**SimTutor: A Telemetry-Grounded Tutoring
Runtime with
Structured Visual Fact Extraction for Procedural
Learning**

第一导师: Prof. Dr. Christian Bartelt

第二导师: Prof. Dr. Rüdiger Ehlers

11th May 2026

软件与系统工程研究所
克劳斯塔尔工业大学

原创性声明

本人已阅读并理解克劳斯塔尔工业大学以及 ISSE 公告中发布的各项指南，包括关于使用文献及其他来源的规定。本人确认已独立完成本论文。任何取自其他来源并在本论文中复制的信息均已明确标注。

根据通用考试条例，本论文尚未提交至任何其他考试机构。

本人特此同意，本人的硕士学位论文可在本研究所图书馆内展出并供查阅。

克劳斯塔尔-采勒费尔德, 11th May 2026

地点, 日期

Yu Zhang

摘要

在高保真仿真环境中进行程序性学习面临诸多独特的挑战：学习者必须执行固定且有序的动作序列，同时验证中间系统状态、从错误中恢复并保持态势感知——而这一切都必须在没有专家教员持续在场的情况下完成。传统的培训辅助手段（如视频演示和纸质检查单）会打断仿真器内练习的连续性，而缺乏系统状态基础的纯语言模型辅助则存在提供流畅但事实性错误指导的风险。本文提出 SimTutor，一个基于遥测数据基础的教学运行时系统，它结合了基于程序包驱动的状态跟踪、检索增强的语言模型辅助生成，以及用于从座舱显示器中提取结构化视觉事实的微调视觉语言模型（VLM）。该系统强制实施显式的证据溯源：每个叠加目标（overlay target）和步骤推荐都必须可追溯到遥测变量、门控规则、检索到的文档片段或视觉事实观察。训练场景为 DCS World 中 F/A-18C 的冷启动程序，涵盖六个操作阶段的 25 个步骤，其步骤间依赖关系使其成为序列敏感、状态依赖型程序性任务的代表性案例。VLM 适配流水线——包括截图捕获、预标注、人工审查、双语监督微调、LoRA 适配和自动化基准测试——在两个骨干架构上进行了应用。在主要的 13 事实本体上，基于 928 条双语训练数据训练的 Qwen3.5-9B LoRA 适配器将事实准确率从基础模型的 0.80–0.87 提升至两个独立留出集上的 0.99（已核实训练数据零重叠），同时将关键假阳性减少了 64–89%。相同的训练数据方案应用于 Gemma-4-31B 也证实了该改进在不同骨干架构间的泛化性。本文交付了一个可运行的桌面运行时系统，包含自动化测试、基准测试工件和回放基础设施。原始研究计划中设想的 VR 部署和受控人因评估仍为计划的下一阶段；当前系统为构建该评估提供了技术基线。

Zusammenfassung

Prozedurales Lernen in hochrealistischen Simulationsumgebungen stellt besondere Herausforderungen: Lernende müssen feste, geordnete Handlungsabfolgen ausführen, während sie Zwischenzustände des Systems überprüfen, Fehler korrigieren und das Situationsbewusstsein aufrechterhalten—und dies ohne die ständige Anwesenheit eines erfahrenen Ausbilders. Herkömmliche Trainingshilfen wie Videoanleitungen und gedruckte Checklisten unterbrechen den Übungsfluss im Simulator, während nicht zustandsgebundene Sprachmodell-Assistenz Gefahr läuft, flüssige, aber faktisch inkorrekte Anweisungen zu geben. Diese Arbeit stellt SimTutor vor, eine telemetriegestützte Tutoring-Laufzeitumgebung, die paketbasierte Prozedurzustandsverfolgung, Retrieval-Augmented-LLM-Hilfegenerierung und ein feinabgestimmtes Vision-Language-Model (VLM) zur strukturierten Extraktion visueller Fakten aus Cockpit-Anzeigen kombiniert. Das System erzwingt eine explizite Evidenzgrundlage: Jede hervorgehobene Cockpit-Referenz und jede Schrittempfehlung muss auf eine Telemetrie-Variable, eine Gating-Regel, einen abgerufenen Dokumentausschnitt oder eine visuelle Faktbeobachtung zurückführbar sein. Als Trainingsszenario dient der Kaltstart der F/A-18C in DCS World mit 25 Schritten in sechs Betriebsphasen, deren Abhängigkeiten untereinander sie repräsentativ für zustandsabhängige prozedurale Aufgaben machen. Die VLM-Adaptationspipeline—Screenshot-Erfassung, Vorlabeling, menschliche Überprüfung, bilingualer SFT-Export, LoRA-Feinabstimmung und automatisiertes Benchmarking—wird auf zwei Backbone-Architekturen angewendet. Auf der primären 13-Fact-Ontologie verbessert ein Qwen3.5-9B LoRA-Adapter (928 bilinguale Trainingszeilen) die Fact-Genauigkeit von 0,80–0,87 (Basismodell) auf 0,99 auf zwei unabhängigen Holdout-Sets mit verifizierter Null-Überlappung zum Training und reduziert kritische False-Positives um 64–89%. Die identische Datenrezeptur, auf Gemma-4-31B angewendet, bestätigt die Übertragbarkeit der Verbesserung über Backbones hinweg. Die Arbeit liefert eine funktionsfähige Desktop-Laufzeitumgebung mit automatisierten Tests, Benchmark-Artefakten und Replay-Infrastruktur. Die im ursprünglichen Forschungsantrag vorgesehene VR-Implementierung und kontrollierte Human-

Subject-Evaluation bleiben geplante nächste Phasen; das aktuelle System stellt die technische Basis dar, auf der diese Evaluation aufgebaut werden kann.

致谢

Contents

第一章 引言	1
1.1 研究动机	1
1.2 论文愿景与范围	2
1.3 当前实现范围	2
1.4 贡献	3
1.5 论文结构	5
第二章 背景与相关工作	7
2.1 F/A-18C 冷启动任务	7
2.1.1 程序结构: S01-S25 与 P1-P6 阶段	7
2.1.2 座舱显示器与复合面板	8
2.1.3 DCS-BIOS 遥测	8
2.2 视觉事实本体	9
2.2.1 从 8-Fact v1 到 13-Fact v2	9
2.2.2 粘性事实与步骤绑定	10
2.3 智能教学系统与程序性训练	11
2.4 基于仿真器的培训与数据采集	11
2.5 基于规则与状态感知的教学	12
2.6 基础模型与面向情境辅助的 VLM	13
2.7 AR/VR 中可解释且基于证据的 AI 辅助	13
2.8 本工作的定位	14
第三章 系统设计	15
3.1 设计目标与需求	15
3.2 整体架构	16
3.3 核心教学逻辑与仿真器适配器的分离	17
3.4 数据流	18
3.4.1 观察	18

3.4.2	教学请求	18
3.4.3	上下文组装	18
3.4.4	模型推理（可选）	19
3.4.5	响应验证与映射	19
3.4.6	操作执行	19
3.4.7	事件日志记录	19
3.5	遥测处理	20
3.6	程序引擎与门控规则引擎	20
3.6.1	程序引擎	20
3.6.2	门控规则引擎	20
3.6.3	确定性步骤推理	20
3.6.4	程序包结构	21
3.7	仿真器适配层	21
3.7.1	遥测输入适配器	21
3.7.2	叠加输出适配器	21
3.7.3	视觉输入适配器	21
3.7.4	Lua 端集成	21
3.7.5	计划中及部分实现的适配器	22
3.8	事件日志与回放	22
3.8.1	事件模型	22
3.8.2	JSONL 事件存储	22
3.8.3	回放与验证	22
3.8.4	评分与交互度量	22
3.8.5	当前局限	23
3.9	用于视觉状态理解的可选 VLM 适配	23
3.9.1	VLM 组件的角色	23
3.9.2	视觉事实本体	23
3.9.3	VLM 在帮助循环中的集成	23
3.9.4	VLM 适配流水线	24
3.9.5	与基于规则的状态门控的区别	24
3.10	与原始研究计划的差异	24
3.10.1	从 VR 优先到桌面优先运行时	24
3.10.2	新增 VLM 适配流水线	24
3.10.3	扩展的遥测数据基础	25
3.10.4	新增程序性、回放和基准测试基础设施	25

3.10.5	推迟的人因评估	25
3.10.6	设计演进摘要	25
第四章	方法论	27
4.1	程序运行时与遥测数据基础	27
4.1.1	DCS-BIOS 原始帧摄入	27
4.1.2	变量解析与源丢失跟踪	28
4.1.3	门控规则评估	28
4.1.4	增量去噪与聚合	28
4.1.5	确定性降级	29
4.2	知识溯源与来源策略	29
4.2.1	BM25 检索	29
4.2.2	来源策略	29
4.3	视觉事实数据流水线	30
4.3.1	第一阶段：DCS 截图捕获	30
4.3.2	第二阶段：初始 VLM 预标注	30
4.3.3	第三阶段：Label Studio 人工审查	31
4.3.4	第四阶段：经审查的 JSONL 导出	31
4.3.5	第五阶段：双语 SFT JSONL 生成	31
4.3.6	第六阶段：LoRA 微调	31
4.3.7	第七阶段：基础模型与 LoRA 对比基准测试	32
4.3.8	端到端可追溯性	32
4.4	数据集构建	32
4.4.1	数据集概览	32
4.4.2	本体演进：从 8-Fact v1 到 13-Fact v2	32
4.4.3	训练方案：Run-003 + Run-005x2	34
4.4.4	留出集独立性验证	34
4.5	LoRA 微调配置	35
4.5.1	基础模型	35
4.5.2	训练栈	35
4.5.3	超参数配置	35
4.5.4	双语 SFT 策略	37
4.5.5	组合再平衡策略	37
4.6	基准测试协议	37
4.6.1	度量指标	37

4.6.2	基础模型与 LoRA 对比方法论	38
4.6.3	留出定义与基准测试类别	39
4.6.4	基准测试工件	39
4.7	本章小结	40
第五章	实现	41
5.1	技术栈	41
5.2	核心领域层	42
5.2.1	程序引擎	42
5.2.2	门控规则引擎	42
5.2.3	评分引擎	42
5.2.4	视觉事实本体与状态管理	43
5.2.5	动态 HelpResponse 模式	43
5.2.6	数据契约	43
5.2.7	其他核心模块	44
5.3	遥测与 DCS 集成	44
5.4	结构化帮助生成	45
5.4.1	提示构建	45
5.4.2	模型适配器	46
5.4.3	带最小修复的 JSON 提取	46
5.4.4	模式验证	46
5.4.5	响应映射与证据溯源	46
5.4.6	确定性降级	47
5.4.7	操作执行安全	47
5.5	VLM 视觉事实提取	47
5.5.1	捕获触发与帧选择	47
5.5.2	多模态负载构建	48
5.5.3	13-Fact 提示	48
5.5.4	模型响应清洗	48
5.5.5	事实合并与后端兼容性	48
5.5.6	计划扩展	49
5.6	回放与日志基础设施	49
5.6.1	JSONL 事件存储	49
5.6.2	回放与验证	49
5.6.3	交互度量	49

5.6.4	当前局限	50
5.7	CLI 与运行时入口点	50
5.7.1	CLI 命令	50
5.7.2	实时运行时编排	50
5.7.3	DCS Lua 脚本	51
5.7.4	模型提供者配置	52
第六章	评估	53
6.1	当前技术结果	53
6.1.1	数据集与训练摘要	53
6.1.2	Qwen3.5 8-Fact V1 基线	54
6.1.3	Qwen3.5 13-Fact V2 结果	55
6.1.4	Gemma-4 13-Fact V2 对比	56
6.1.5	错误分析	57
6.1.6	运行时基础设施就绪度	59
6.2	计划中的运行时数据采集与人因评估	59
6.2.1	原始评估愿景	59
6.2.2	计划评估度量	60
6.2.3	所需运行时数据采集升级	60
6.2.4	计划实验设计	61
6.2.5	已知有效性威胁	62
第七章	讨论	63
7.1	从研究计划到实现系统的演进	63
7.1.1	为何发生转变	63
7.1.2	这是重新框架化，而非失败	64
7.2	技术结果解读	64
7.2.1	基准测试结果证明了什么	64
7.2.2	基准测试结果未能证明什么	65
7.2.3	ins_go 到 ins_ok_text 分解的设计教训	65
7.3	本体设计经验	66
7.3.1	抽象层次纪律	66
7.3.2	复合目标的分解	66
7.3.3	残余失效模式及其影响	67
7.3.4	对未来本体设计的启示	67

7.4	局限性	68
7.4.1	实验设置的局限性	68
7.4.2	系统的局限性	68
7.4.3	VLM 适配结果的局限性	69
7.5	未来工作	69
7.5.1	VR 运行时集成	69
7.5.2	人因评估	70
7.5.3	将视觉事实本体扩展到其他程序	70
7.5.4	多帧时序推理	70
7.5.5	从现场纠正进行在线适配	70
7.5.6	系统级端到端评估	71
7.5.7	未来方向总结	71
第八章	结论	72
8.1	已完成工作总结	72
8.2	未来工作	73
参考文献		76
第九章	附录	77

List of Figures

3.1	SimTutor 系统架构。核心层包含仿真器无关的领域逻辑。端口层定义抽象接口。适配器层为 DCS、模型提供者、知识源和视觉流水线提供具体实现。程序包提供声明式配置。	17
3.2	主运行时数据流——贯穿帮助循环。	18
4.1	七阶段视觉事实数据流水线。捕获和预标注供给人工审查；经审查的标注驱动双语 SFT 导出；导出的数据训练 LoRA 适配器；基础模型和 LoRA 模型在独立留出集上进行基准测试。	30

List of Tables

3.1	从研究计划到实现系统的设计演进。	25
4.1	数据集清单。所有样本数来自相应的 <code>stats.json</code> 文件。	33
4.2	LoRA 微调超参数，在 Qwen3.5-9B 和 Gemma-4-31B 间匹配。	36
6.1	标注视觉事实数据集摘要。双语导出从相同的经审查任务生成独立的英文和中文样本。留出集仅英文。	54
6.2	8-fact v1 基准测试：Qwen3.5-9B 基础模型 vs. LoRA-v1 在 Run-002 留出集上（50 样本，英文）。	54
6.3	13-fact v2 基准测试：Qwen3.5-9B 基础模型 vs. LoRA（Run-003 + Run-005 $\times$ 2）在两个留出集上。	55
6.4	13-fact v2 基准测试：Gemma-4-31B 基础模型 vs. LoRA（Run-003 + Run-005 $\times$ 2）在两个留出集上。	56
7.1	未来工作方向总结。	71

第一章 引言

本文描述了 SimTutor 的设计、实现与技术评估。SimTutor 是一个基于遥测数据基础的教学运行时系统，结合了程序包驱动的状态跟踪、检索增强的语言模型辅助生成以及微调视觉语言模型（VLM）的视觉事实提取功能，以支持高保真飞行仿真器中的程序性学习。本研究以 DCS World 中 F/A-18C 冷启动任务为代表案例，针对复杂、序列敏感的程序性教学挑战展开，同时弥合了原始研究愿景（基于虚拟现实的教学系统）与截至目前已完成的技术基线之间的差距。本章定义研究问题，追溯从研究计划到当前实现的演进过程，列举本研究的贡献，并概述论文剩余部分的组织结构。

1.1 研究动机

程序性学习——获取必须在正确上下文中正确执行的固定有序动作序列——面临着与其区别于陈述性学习或概念性学习的独特挑战。学习者不仅需要记忆步骤，还必须识别每个步骤的适用时机，验证其前提条件是否满足，在推进前确认其完成，并在出错时恢复，而不将错误传播到程序的后续部分。在高保真仿真环境中，这些挑战因座舱或工作空间的复杂性、仪表信息的密度以及在执行不熟悉序列时保持态势感知的认知负荷而进一步加剧。

传统的培训辅助手段——视频演示、纸质检查单、教员引导示范——在初始熟悉阶段有效，但会打断仿真器内练习的连续性。暂停练习查阅手册或重播视频片段的学习者必须从座舱环境中切换注意力，从而丧失沉浸感，在某些情况下甚至会丢失最初触发查阅需求的瞬态仿真器状态。相反，来自大语言模型（LLM）的缺乏系统状态基础的纯文本辅助可能提供流畅但事实性错误的指导，因为模型无法获取当前仿真器状态。在这两个极端之间，需要一种基于状态感知证据的、上下文相关的教学方式：一个通过实时仿真器遥测数据观察学习者操作、检索相关文档、在遥测数据不足时从座舱中提取视觉证据、并在不中断训练流程的前提下提供简洁、可验证指导的系统。

DCS World 中 F/A-18C 的冷启动程序是本论文的训练场景。该程序包含 25 个步骤（S01-S25），分为六个阶段（P1-P6），从电瓶供电开始，历经发动机启动、航电配置、飞行控制检查，直至滑行准备（详见 §2.1）。每个步骤都带有显式的前提条件，这些条

件取决于先前步骤的完成情况以及特定遥测条件的满足程度：例如，左发启动（S10）要求右发参数——转速、温度、燃油流量、尾喷口位置和滑油压力——在启动左发之前处于标称范围内。这些步骤间依赖关系使得冷启动任务成为航空、海事操作、工业维护和医疗程序指导中基于仿真器培训的序列敏感、状态依赖型程序性任务这一更广泛类别的代表性实例。TODO:CITE ——智能教学系统和程序性学习文献。

本研究的核心前提是：通过将每个可操作的输出都建立于显式证据之上——遥测变量、门控规则评估、检索到的文档片段或视觉事实观察——可以使教学系统显著提升可靠性与可审计性。这种证据溯源约束不仅仅是一种架构偏好，更是一项安全要求：在座舱程序的语境中，被错误高亮的控件或被错误识别的程序状态可能会使学习者产生混淆或误导。本文所描述的 SimTutor 系统在一个包含自动化测试、基准测试工件和回放基础设施的可运行运行时环境中实例化了这一原则。

1.2 论文愿景与范围

本论文的原始研究愿景，如研究计划所述，核心是在 Meta Quest 3 上结合 DCS-VR [?] 构建一个以虚拟现实为先导的基于状态证据的教学系统。计划的系统将通过 VR 座舱内的眼动追踪、手部追踪和语音输入接收学习者交互；检索相关手册和检查单摘录；通过检索增强的 LLM 生成简洁、附带引文依据的步骤指导；并将指导渲染为头显内步骤卡片或注册到座舱控件上的叠加标注。研究计划进一步规定了一个三条件受控人因评估，比较视频加笔记基线、无状态基础的纯文本 LLM 以及基于状态证据的教学系统，评估指标包括完成率、程序性错误率、任务时间、NASA-TLX 工作负荷评分、前/后知识测验，以及在 2–4 周间隔后进行的保持和迁移测试。

该愿景定义了本论文的长期研究议程。然而，截至目前已完成的工作代表了技术基线，而非完整 VR 教学系统的实现。当前实现在桌面/DCS 运行时上运行，使用座舱叠加高亮而非头显内步骤卡片作为主要输出模态，并通过自动化基准测试而非人因实验进行验证。VR 部署和人因评估仍为计划的下一阶段（见第六章，第6.2节）。

我们在开篇即明确记录这一差距，以在原始研究愿景与已完成的技术贡献之间建立清晰的边界。本论文应被理解为：一项系统与方法论贡献，奠定了技术基础——运行时、数据采集、VLM 适配流水线、基准测试基础设施——VR 和人因评估可在该基础上进行构建。

1.3 当前实现范围

已构建的系统在研究计划的多个重要方面有所不同，而这些差异本身正是本论文贡献的来源之一。详细比较见第3.10节；在此我们总结关键差异以帮助读者定位。

平台。 当前系统运行于桌面/DCS（非 VR）配置。显示器为标准显示器；输入通过键盘和 HOTAS（手不离杆操纵系统）；输出渲染为 DCS 屏幕上的座舱叠加高亮，而非头显内步骤卡片。Meta Quest 3 VR 适配器尚未实现。

遥测数据基础。 当前实现包含一个比原计划预期更为精细的遥测子系统：原始 DCS-BIOS UDP 接收、带源丢失跟踪的变量解析、增量去噪处理（阈值、防抖动和逐变量过滤），以及用于提示安全压缩的增量聚合。这些新增功能是由处理嘈杂高频仿真器遥测数据的实际工程需求所驱动的。

VLM 视觉事实提取。 相对于研究计划最显著的新增内容是 VLM 视觉事实提取流水线。原计划设想一个纯文本 RAG+LLM 导师，以只读仿真器状态作为唯一的系统状态基础信号。在实现过程中，我们发现若干关键程序步骤（S08、S15、S18）需要对未通过 DCS-BIOS 导出的显示页面内容进行视觉确认。VLM 流水线即为弥补这一缺口而添加，并发展成为一个自成一体的研究贡献，涵盖结构化视觉事实本体设计、带人工审查的数据集构建、双语 LoRA 微调，以及跨两个模型骨干的自动化基准测试评估。

程序包和基础设施。 当前系统将程序定义、门控规则、遥测映射、错误分类法和视觉事实本体组织为声明式 YAML 配置（程序包），而非将其隐式编码在提示或代码中。系统还包含事件日志记录与回放基础设施、自动化评分引擎，以及在没有模型可用或模型输出验证失败时运行的确定性降级路径。这些要素在原计划中均未规定。

这些差异并不使原计划失效；它们反映了一个工程现实：基于状态证据的教学运行时系统在可部署于 VR 人因研究之前，需要大量支撑性基础设施。当前系统恰好提供了这一基础设施。

1.4 贡献

本论文做出以下贡献：

1. **程序包驱动、基于遥测数据基础的教学运行时架构。** 我们提出了一个以端口-适配器（六边形）架构组织的教学运行时设计与实现，将仿真器无关的核心逻辑（程序跟踪、门控、评分、知识检索）与仿真器相关适配器（DCS-BIOS 遥测、叠加渲染、视觉捕获）相分离。系统支持实时帮助循环：运行时从规范化遥测变量、增量摘要、候选程序步骤、确定性步骤提示、叠加目标允许列表、检索到的知识片段以及可选的视觉事实观察中组装结构化上下文；将该上下文传递给 LLM 以生成结构化帮助响应；依据模式、允许列表和证据溯源约束验证响应；执行经过验证的叠加操作，同时记录每个阶段以便下游回放和分析。确定性降级路径确保在没

有模型可用或模型输出验证失败时系统仍能正常运行。此贡献在第三、四和五章中描述。

2. **结构化视觉事实本体及完整的 VLM 数据、适配与基准测试流水线。**我们定义了一个包含 13 个视觉事实的本体，将座舱显示页面状态分解为跨三个显示区域 (Left DDI、Right DDI、AMPCD) 的离散、可审计命题。该本体经历了两代演进——从早期的 8-fact v1 基线到当前与运行时对齐的 13-fact v2——并在抽象层次混合和假阳性风险方面积累了经验教训。我们实现了一个完整的适配流水线：DCS 中的截图捕获、由大型 VLM 进行预标注、在 Label Studio 中进行人工审查、双语 (英文和中文) 监督微调导出、使用 Unsloth、PEFT 和 TRL 进行 LoRA 微调，以及在经核实训练数据零重叠的独立留出集上进行自动化基础模型与 LoRA 对比基准测试。此流水线中的每个工件——原始截图、预标注、人工审查标注、SFT 数据集、训练摘要、基准测试指标以及逐事实混淆图表——均存储在代码仓库中，可供独立检查和复现。此贡献在第三和四章中描述。
3. **基准测试结果表明小数据 LoRA 适配能显著提升座舱 VLM 在独立留出集上的事实提取准确率。**在 13-fact v2 本体下，基于 928 条双语训练数据 (Run-003 + Run-005 $\times$ 2) 训练的 Qwen3.5-9B LoRA 适配器在 Run-002 newfacts 留出集 (50 样本) 上实现事实准确率 0.9908 (基础模型: 0.8677)，在 Run-004 random 留出集 (100 样本) 上实现 0.9931 (基础模型: 0.8038)。样本完全匹配率从 Run-002 的 0.10 升至 0.88，从 Run-004 的 0.03 升至 0.92。关键假阳性计数——即对下游具有直接风险、可能导致程序过早推进的错误——在 Run-002 上减少 64%，在 Run-004 上减少 89%。逐事实错误分析将完成类事实假阳性确定为主要残余失效模式。这些结果见第六章，第 6.1 节。
4. **骨干对比表明训练数据方案可跨模型架构泛化。**相同的训练数据方案 (Run-003 + Run-005 $\times$ 2, 928 条, 双语) 被应用于第二个 VLM 骨干 Gemma-4-31B。Gemma LoRA 适配器在 Run-002 newfacts 留出集上实现事实准确率 0.9492 (基础模型: 0.8169)，在 Run-004 random 留出集上实现 0.9715 (基础模型: 0.8146)，并在 Run-002 上实现零关键假阳性。虽然 Qwen 适配器在绝对准确率和召回率方面表现更优，但 Gemma 结果证实了改进是由训练数据方案——而非特定骨干的偶然产物——所驱动的，并揭示了骨干层面的精度-召回权衡差异，这对安全关键型部署具有重要参考价值。这些结果见第六章，第 6.1.4 节。
5. **针对未来 VR 人因研究的计划性评估框架。**我们在设计层面规定了受控受试者间评估方案，比较视频加笔记、无状态基础纯文本 LLM 和基于状态证据教学三种条件，计划的评估指标涵盖即时表现 (完成率、错误率、任务时间)、工作负荷

(NASA-TLX)、学习效果（前/后测验）、保持（2-4 周延迟后测）和迁移（变体程序）。我们确定了从当前回放基础设施过渡到人因实验数据流水线所需的运行时数据采集升级，并编目了设计阶段已知的有效性威胁。此计划性评估在第六章第6.2节中描述，代表研究计划的下一阶段。

贡献 1-4 由当前代码仓库中已有的已验证声明和基准测试工件支撑。贡献 5 是方法论和设计层面的贡献，记录了评估路径；它不报告人因数据，其所述指标和比较仍处于计划而非完成状态。

1.5 论文结构

论文的剩余部分组织如下。

第二章提供理解本系统所需的领域和技术背景。它详细描述了 F/A-18C 冷启动程序，介绍了视觉事实本体及其从 8-fact v1 到 13-fact v2 的演进，并综述了智能教学系统、基于仿真器的培训、基于规则和状态感知的教学、面向结构化输出的 VLM 适配以及 AR/VR 环境中可解释 AI 辅助等相关工作。

第三章介绍 SimTutor 的设计。它从问题陈述中推导设计目标，描述端口-适配器架构，追踪完整帮助循环中的运行时数据流，并详细阐述遥测处理流水线、程序和门控规则引擎、仿真器适配层、事件日志与回放基础设施以及可选 VLM 适配组件的设计。该章最后与原论文研究计划进行系统性比较，记录设计在实现过程中的演进。

第四章描述 VLM 适配流水线的方法论框架。涵盖数据集构建（Run-001 至 Run-005，本体版本，标注分布，经核实零重叠的留出集构建），截图-预标注-审查-导出-训练-基准测试流水线，Qwen3.5-9B 和 Gemma-4-31B 的 LoRA 微调配置，以及基准测试协议，包括指标定义和污染控制。

第五章记录技术栈、核心领域逻辑模块、遥测与 DCS 集成、结构化帮助生成、VLM 视觉事实提取、回放与日志基础设施以及 CLI 和运行时入口点的实现细节。

第六章分为两部分。A 部分报告当前技术结果：数据集和训练摘要、8-fact v1 基线、主要 13-fact v2 Qwen 基准测试结果、Gemma 骨干对比、逐事实错误分析，以及运行时基础设施就绪度评估。B 部分描述计划中的人因评估：原始评估愿景、计划指标、所需基础设施升级、拟议实验设计，以及已知有效性威胁编目。B 部分中的所有陈述均代表未来工作。

第七章对结果及其局限性进行解读。它考察了项目为何从 VR 优先转向遥测/VLM 重度实现，阐明当前基准测试能够和不能够证明的内容，分析本体从 8-fact 到 13-fact 的演进，论证人因证据为何仍然不可或缺，并识别将基准测试成功解读为学习成功的风险。

第八章总结已完成的工作，重申贡献，并概述未来工作方向，包括 VR 运行时集成、人因评估、本体向其他程序的扩展、多帧时序推理以及在线适配。

第二章 背景与相关工作

本章提供理解 SimTutor 系统设计所需的领域和技术背景，随后综述若干交叉研究领域的相关工作。第2.1节介绍作为系统训练场景的 F/A-18C 冷启动任务。第2.2节描述视觉事实本体——一个连接原始座舱截图与下游程序性推理的结构化中间表示。本章剩余部分将本工作定位于智能教学系统、基于仿真器的培训、状态感知教学、视觉语言模型适配以及基于证据的 AI 辅助等现有研究之中。

2.1 F/A-18C 冷启动任务

本论文核心的程序性训练场景是 F/A-18C 冷启动，这是一个标准的飞行前座舱程序，将飞机从断电状态过渡到可滑行配置。该任务是 DCS World 培训课程中的经典科目，并代表了一类更广泛的固定序列、状态敏感型程序性任务，其中操作顺序、中间系统状态的验证以及对座舱仪表的正确解读共同决定了任务的成功完成。

2.1.1 程序结构：S01–S25 与 P1–P6 阶段

冷启动程序由 25 个编号步骤（S01–S25）、分为六个粗粒度阶段（P1–P6）组成，反映了不同的操作阶段：

- P1 — 供电与安全检查 (S01–S03)：** 电瓶和发电机激活、火警探测系统测试以及 APU 启动。这些步骤建立电源并确认关键安全系统在发动机点火前处于正常状态。
- P2 — 右发启动 (S04–S07)：** 右发起动、在 25% 转速时推进油门、引气系统循环以及注意/警告/提示灯测试。首先启动右发以为后续程序提供液压和电源。
- P3 — 显示器与通信 (S08–S09)：** 两个 DDI、AMPCD 和 HUD 的通电；特定显示页面配置（左 DDI 显示 FCS 页面，右 DDI 显示 BIT 根页面）；通过 UFC 编程 COMM1 预设频率。
- P4 — 左发与核心系统 (S10–S14)：** 在验证右发参数处于标称范围后启动左发，INS 校准模式选择（地面或航母），雷达通电，以及 OBOGS 激活。

P5 — FCS 与飞行控制 (S15–S19): FCS 复位与 BIT 执行, 襟翼和配平配置, 以及包括受油管、减速板、弹射杆和拦阻钩在内的"四项放下"飞行前检查。

P6 — 滑行前仪表与最终检查 (S20–S25): 驻车制动释放, BINGO 燃油设定, 气压和雷达高度表配置, 备用姿态指示仪解锁, 以及姿态源选择。

该程序严格有序: 每个步骤都带有显式的前提门控条件, 这些条件取决于先前步骤的完成情况以及特定遥测条件的满足。例如, S04 (右发起动) 要求已建立 APU 启动支持 (S03 完成), 而 S10 (左发起动) 要求右发参数——转速、温度、燃油流量、尾喷口位置和滑油压力——在启动左发之前全部处于标称绿区范围内。这些步骤间依赖关系使冷启动任务成为上下文感知教学的引人注目的测试案例: 跳过验证或误判仪表读数的学习者可能将错误传播到序列的其余部分。

2.1.2 座舱显示器与复合面板

视觉事实提取子系统 (第2.2节) 操作于一个固定的复合面板图像, 该图像捕获三个座舱显示区域, 从上到下排列:

- **左 DDI (数字显示指示器):** 多功能显示器, 用于 FCS 页面、SUPT 页面、TAC 页面及其他系统页面。在冷启动过程中, 左 DDI 主要用于 FCS 监控 (S08、S15)。
- **AMPCD (先进多用途彩色显示器):** 中央彩色显示器, 用于 HSI 页面、INS 校准状态、地图图层和导航数据。在冷启动中, AMPCD 在 INS 校准阶段 (S12) 起关键作用。
- **右 DDI:** 第二个多功能显示器, 在冷启动中用于 BIT 根页面 (S08), 随后用于 FCS-MC BIT 序列 (S18)。右 DDI 也是 BIT 故障指示以及 FCS BIT 中间和最终结果出现的位置。

复合面板图像将这三个区域合并为 VLM 的单一输入。这一设计选择避免了训练与推理之间的不匹配 (即模型在各区域裁剪上训练但在完整复合图像上评估, 或反之), 并将多轮视觉流水线简化为每个观察窗口的单图像提取步骤 [1]。

2.1.3 DCS-BIOS 遥测

DCS-BIOS 提供来自 DCS World 的基于 UDP 的实时遥测数据流, 将座舱开关、指示器、警告灯、仪表及其他仪器的状态导出为结构化数据。SimTutor 运行时接收这些原始 BIOS 帧, 并将其传递通过遥测增强流水线, 该流水线将原始值规范化为稳定

的运行时变量（如 `rpm_r`、`apu_ready`、`ins_mode`），应用增量去噪处理以抑制噪声和抖动，并锁定离散状态完成标志以供门控评估。

这一遥测数据流是教学系统的主要状态基础信号。与纯视觉方法（必须仅从像素级证据推断程序状态）不同，SimTutor 运行时可以将视觉观察与确定性遥测状态进行交叉比对。S01（电瓶和发电机）、S05（右发慢车）、S13（雷达模式 OPR）等步骤可直接通过 DCS-BIOS 观测，无需视觉推理。其他步骤，如 S08 和 S18，涉及未通过 DCS-BIOS 直接导出的显示页面状态，因此依赖于下文描述的视觉事实提取流水线。

2.2 视觉事实本体

SimTutor 系统的一个核心设计决策是视觉感知与程序性推理的分离。系统不是训练模型直接产生导师决策（“学习者现在应该按下 PB5”），而是使用一个称为视觉事实的中间结构化表示。一个视觉事实是关于某一时刻某个座舱显示区域可见状态的离散、可审计命题。每个事实被标注为三种状态之一：

seen: 事实所描述的视觉证据在当前座舱图像中清晰可见。

not_seen: 视觉证据不存在或不可识别。

uncertain: 图像模糊、被遮挡、不完整或因其他原因无法做出确信判断。

这些事实被下游程序引擎（第??节）消费，该引擎将其与遥测状态、门控规则和知识检索相结合，以判断程序步骤是视觉确认、仍未完成还是被阻塞。这种分层架构将 VLM 的职责隔离在结构化视觉证据提取上，而将程序级决策保留给确定性的基于规则的组件。

2.2.1 从 8-Fact v1 到 13-Fact v2

视觉事实本体经历了两代演进，反映了早期微调实验的经验教训以及运行时程序包的需求。

8-fact v1（早期基线）。 第一代本体包含八个事实，针对三个显示区域。这些事实涵盖 FCS 页面可见性（左 DDI）、BIT 页面和 BIT 故障可见性（右 DDI）、FCS-MC 页面和在测状态（右 DDI）、FCS BIT 结果可见性（右 DDI）、INS 校准页面可见性（AMPCD）以及 INS GO 完成信号（AMPCD）。该本体用于在 180 张经人工审查的 Run-001 图像上训练首个 LoRA 适配器（LoRA-v1），产生了有希望的分布内结果，但也暴露了一个关键弱点：`ins_go` 事实混合了抽象层次，要求 VLM 从单帧视觉图像中

识别出一个高级程序完成状态 ("INS 校准已完成")。结果是独立 Run-002 留出集上的高假阳性率 (50 个样本中有 13 个在人工标注为 `not_seen` 时被预测为 `seen`)。

13-fact v2 (运行时对齐)。 第二代本体通过将高级程序状态分解为低层次、视觉可观测的证据来解决这一问题。当前的 13-fact 集合定义于 `vision_facts.yaml`, 包括:

- **左 DDI 事实:** `tac_page_visible`、`supt_page_visible`、`fcs_page_visible`、`fcs_page_x_marks_visible`。
- **右 DDI 事实:** `bit_root_page_visible`、`fcsmc_page_visible`、`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`。
- **AMPCD 事实:** `hsi_page_visible`、`hsi_map_layer_visible`、`ins_grnd_alignment_text_visible`、`ins_ok_text_visible`。

注意, `v1` 中的 `ins_go` 已被分解为若干低层次 AMPCD 事实 (`ins_grnd_alignment_text_visible`、`ins_ok_text_visible`、`hsi_map_layer_visible`)，每个事实描述一个特定的、局部可验证的视觉证据。下游程序引擎 (而非 VLM) 负责将这些原子观察结果组合成关于 INS 校准阶段是否完成的程序性判断。

2.2.2 粘性事实与步骤绑定

本体中的两个额外机制提高了其在运行时使用中的鲁棒性。

粘性事实。 某些视觉事实代表瞬态状态，一旦被观察到，就不应被后续的 `not_seen` 帧覆盖。例如，`fcsmc_final_go_result_visible` 事实被标记为 `sticky: true`，生存时间为 600 秒。一旦 VLM 报告该事实为 `seen`，它就在运行时事实状态中被锁定，不会在 TTL 窗口内被后续的 `not_seen` 或 `uncertain` 预测覆盖。这防止了在关键视觉事件已被捕获后，因显示页面切换、摄像机遮挡或短暂渲染伪影导致的闪烁和假阴性。

非粘性事实 (如 `fcs_page_visible`、`bit_root_page_visible`) 带有较短的 2 秒 TTL，并被持续重新评估，反映了这些显示页面可能因学习者在不同座舱页面之间导航而发生变化。

步骤绑定。 视觉事实通过定义于 `vision_facts.yaml` 中的显式步骤绑定与程序步骤相链接。步骤绑定规定了哪些事实必须为 `seen` 状态，程序引擎才能将该步骤视为视觉确认。当前本体定义了两种绑定类型：

- **all_of:** 绑定集合中的每个事实都必须为 `seen`。例如, S08 要求 `fcs_page_visible` (左 DDI) 和 `bit_root_page_visible` (右 DDI) 均被确认。

- `any_of` (多选一事实集合): 集合中至少有一个事实必须为 `seen`。这应用于程序状态可通过若干替代视觉线索中的任何一个来验证的情况。

依赖视觉确认的步骤(S08、S15、S18)被注册为程序包中的 `vision_priority_steps`, 而可直接通过 DCS-BIOS 遥测观测的步骤 (S01、S03–S07、S09–S13、S21) 被注册为 `bios_priority_steps`。需要人工确认或涉及三显示器布局以外座舱区域的步骤 (S02、S14、S16–S20、S22–S25) 被标记为 `manual_or_out_of_layout_steps`。这种三元分类确保每个步骤的完成证据来自最可靠的可用信号。

2.3 智能教学系统与程序性训练

智能教学系统 (ITS) 在程序性训练领域有着悠久的历史, 从军事装备操作到医疗程序指导。经典的 ITS 架构通常对专家知识进行建模, 通过学生模型跟踪学习者状态, 并通过教学模块提供上下文敏感的反馈。TODO:CITE ——基础性 ITS 综述或架构论文 (如经典的四组件 ITS 模型或近期的全面综述)。

在程序性领域, 基于约束的导师和示例追踪导师已被应用于飞机维修、编程和设备故障排除等任务。TODO:CITE ——程序性训练中的基于约束建模; TODO:CITE ——程序性领域中的示例追踪导师或认知导师。这些系统通常在封闭、定义明确的任务环境中运行, 其中正确和错误操作的空间可以被枚举。本论文研究的冷启动任务共享此封闭程序的特性, 但在两个关键方面有所不同。首先, 系统通过仿真器遥测和座舱视觉来观察学习者行为, 而非通过自定义导师界面, 使其适用于未修改的仿真环境。其次, 教学输出由 LLM 动态生成, 而非从预编写的反馈消息库中检索, 使系统能够响应程序中任意的学习者状态, 而不仅仅响应预期的错误模式。

更近期的研究探索了使用大语言模型进行教学和指导对话。TODO:CITE ——基于 LLM 的教学系统或对话式导师 (如 Khanmigo 风格的系统, 或任何 LLM 作为导师的论文)。这些系统证明 LLM 能够产生流畅、上下文适当的教学文本, 但它们通常在非结构化的对话环境中运行, 不强制执行 SimTutor 方法的严格证据溯源约束。特别是, 本工作约束每个叠加目标和步骤推荐都必须具有可验证的证据来源——遥测数据、门控规则、检索到的文档片段或视觉事实——而非仅仅依赖模型的参数化知识。

2.4 基于仿真器的培训与数据采集

高保真仿真环境 (如 DCS World) 为程序性训练提供了真实、可重复的平台。仿真器在航空培训中的应用已十分成熟, 对从仿真器到真实飞机的培训迁移有广泛的研究。TODO:CITE ——航空领域基于仿真器的培训有效性 (如培训迁移研究或飞行仿真培训综述)。

基于仿真器的培训研究中的一个关键挑战是数据采集：即培训系统观察学习者操作和座舱状态的方式。先前的工作通过屏幕捕获、事件日志或直接状态导出 API 对仿真器进行了数据采集。TODO:CITE —— 仿真器数据采集方法，如 X-Plane 数据输出、Microsoft Flight Simulator SimConnect 或 DCS-BIOS 学术使用。本工作使用 DCS-BIOS，这是一个社区开发的遥测桥梁，通过 UDP 导出 DCS World 座舱状态。DCS-BIOS 提供比单独屏幕捕获更丰富的信号，暴露开关的确切位置、发动机参数的数值以及警告灯的状态，而无需依赖计算机视觉来恢复它们。这使得系统能够将视觉感知保留给显示页面状态（DCS-BIOS 不导出这些内容），同时依赖确定性遥测获取开关位置和仪表读数。

TODO:CITE —— 任何将 DCS World 或 DCS-BIOS 用作 AI、HCI 或培训研究平台的先前学术工作。

2.5 基于规则与状态感知的教学

SimTutor 系统在基于 LLM 的帮助生成之外，大量使用显式门控规则、确定性步骤推理和遥测驱动的状态跟踪。这种混合设计将其定位于基于规则和基于神经方法的智能辅助的交叉点。

基于规则的程序跟踪方法——使用有限状态机、Petri 网或产生式规则来建模任务进度——在可解释性和正确性方面提供强有力的保证。TODO:CITE —— 基于规则的程序跟踪或训练中的计划识别（如程序性任务的计划识别、或程序执行的有限状态模型）。然而，这些方法通常需要手动编写程序模型，并且不能泛化到新颖的学习者错误或意外的状态配置。SimTutor 系统使用手动编写的程序包（定义步骤、门控和证据需求）作为状态跟踪的骨干，但将自然语言解释和叠加目标选择委托给 LLM。这种分工保持了程序模型的可解释性，同时赋能于语言模型生成反馈的灵活性。

混合神经-符号架构已被提出用于任务指导，结合了神经感知或生成与符号任务模型。TODO:CITE —— 神经-符号任务辅助或混合规划 + LLM 系统（如 SayCan 风格的 grounding、或 LLM+PDDL 集成）。本工作与这些努力的不同之处在于其对证据溯源的强调：系统的每个可操作输出都必须可追溯到一个具体的、可审计的证据来源（遥测变量、视觉事实观察、门控规则评估或检索到的文档块）。这一约束不仅是一种架构偏好，更是一项安全要求：在座舱程序的语境中，被错误高亮的控件或被错误识别的程序状态可能会使学习者产生混淆或误导。

2.6 基础模型与面向情境辅助的 VLM

将视觉语言模型（VLM）适配到特定领域的结构化提取任务是一个快速发展的领域。参数高效微调方法，特别是低秩适配（LoRA），使得以适度的计算资源和小规模精选数据集将大型预训练模型适配到狭窄领域变得可行。TODO:CITE ——LoRA (Hu et al., 2021)；TODO:CITE ——QLoRA 或其他用于 VLM 微调的 PEFT 方法；TODO:CITE ——针对特定领域视觉问答或结构化输出任务微调 VLM 的代表性工作。

本论文中的 VLM 适配流水线（第??节）遵循一个捕获-预标注-审查-训练-基准测试的循环，其显著特点在于使用经人工审查的小数据（数百张图像，而非数万张）来推动结构化提取准确率的有意义改进。这与依赖网络规模数据和广泛指令微调的大规模 VLM 微调工作形成对比。TODO:CITE ——小数据领域适配 VLM 或 LLM 的工作，少样本任务特定微调。

先前关于图形用户界面和结构化屏幕内容视觉理解的研究已探索了诸如控件检测、屏幕摘要和 UI 状态分类等任务。TODO:CITE ——使用 VLM 进行 UI 理解或屏幕解析（如 Screen2Words、Widget Captioning 或基于视觉的 UI 自动化）。本研究中的座舱显示领域与 GUI 理解具有结构相似性——固定区域、结构化布局、符号内容——但在任务的关键性以及需要显式、可审计的证据而非开放式描述方面有所不同。

本工作中使用的双语 SFT 策略（从相同的图像和标注训练英文和中文变体）与微调中的跨语言迁移和指令多样性相关。TODO:CITE ——跨语言指令微调或 VLM 的多语言 SFT。然而，这里的主要动机并非多语言部署，而是指令多样性作为一种正则化形式：通过在两种语言上训练，鼓励模型关注视觉内容而非语言特定的先验，而结构化 JSON 输出格式保持与语言无关。

2.7 AR/VR 中可解释且基于证据的 AI 辅助

原始论文研究计划设想了一个运行在 Meta Quest 3 上的头显内增强现实/虚拟现实教学界面。虽然当前实现在桌面 DCS 运行时上运行（见第1.3节），但长期研究议程仍然锚定在沉浸式程序性训练中。

关于程序性任务增强现实指导的研究已经证明了空间注册指令在装配、维护和维修任务中的价值。TODO:CITE ——AR 引导的程序性训练综述（如用于装配、维护或医疗程序指导的 AR）。这些系统通常使用注册到已知物理对象的预编写内容（箭头、文本、动画）。SimTutor 的愿景不同之处在于，教学内容是在运行时从当前程序状态和视觉证据生成的，而非从固定库中检索。

关于决策支持系统中可解释 AI 的研究强调了可追溯推理的重要性，特别是在安全关键领域。TODO:CITE ——决策支持或安全关键 AI 辅助中的可解释 AI（如航空

领域的 XAI，或高风险任务中的可解释推荐系统）。SimTutor 中的证据溯源约束与此原则一致：每个叠加目标和推荐步骤必须携带一个证据引用，将输出链接到其来源（遥测变量、门控规则、视觉事实或检索到的文档块）。此审计追踪旨在支持运行时调试（系统为什么高亮此控件？）和帮助循环的事后分析。

TODO:CITE ——任何在 VR/AR 中处理 grounding、证据或程序正确性（而非开放式对话）的基于 LLM 或 AI 驱动的辅助工作。

2.8 本工作的定位

SimTutor 系统占据了一个在单一系统中很少被同时组合的若干研究领域的交汇点：它应用了**基于遥测证据**的方法而非纯视觉或纯文本方法进行程序性状态跟踪；使用**参数高效 VLM 适配**产生结构化视觉事实而非自由形式描述；对所有可操作输出强制执行**显式证据溯源**；并将**程序包**视为可独立于模型进行编写、版本化和回放的一等配置工件。

从智能教学系统的角度看，SimTutor 贡献了一种将教学逻辑分布在三个层次的设计：用于状态跟踪的确定性程序包驱动引擎、用于基于证据帮助生成的 LLM，以及用于显示页面视觉事实提取的微调 VLM。从 VLM 适配研究的角度看，它贡献了一个领域特定的基准测试和本体演进叙事（8-fact 到 13-fact），明确了早期视觉目标与可靠程序级推理所需粒度之间的差距。从基于仿真器的培训角度看，它贡献了一个可复用的数据采集与回放基础设施，可支持未来的人因研究而无需实时实验者监督。

本论文呈现的工作代表了一个技术基线，而非完整评估。VLM 适配结果（第 6 章）提供了证据表明结构化视觉事实提取可通过小数据领域微调得到实质性改进，但它们尚未构成学习增益、工作负荷降低或迁移的证据。原始论文研究计划中设想的人因评估仍为计划的下一阶段（第 6.2 节），当前系统最好被理解为使该评估成为可能的运行时与数据采集基础设施。

第三章 系统设计

本章描述 SimTutor 的设计——一个用于 DCS F/A-18C 冷启动任务中程序性训练的基于遥测数据基础的教学运行时。本章涵盖系统架构、组件设计和设计原理。详细的方法论——包括 VLM 适配协议、数据集构建和基准测试设计——延至第 4 章；具体模块的实现级细节见第 5 章。第 3.1 节从论文问题陈述中推导设计目标。第 3.2 节呈现整体架构以及核心教学逻辑与仿真器特定适配器的分离。第 3.4 节描述主帮助循环中的运行时数据流。第 3.5 和 3.6 节涵盖遥测处理流水线以及程序和门控规则引擎。第 3.7 节详述仿真器适配层及 Lua 端集成。第 3.8 节描述事件日志、回放和评分基础设施。第 3.9 节介绍用于视觉状态理解的可选 VLM 适配组件。第 3.10 节最后与原论文研究计划进行系统性比较，记录设计在实现过程中的演进。

3.1 设计目标与需求

本论文解决的是为操作复杂仿真器的学习者提供基于状态证据、上下文感知的程序性指导这一问题。在目标场景——DCS World 中 F/A-18C 冷启动程序——中，学习者必须执行跨越六个阶段（P1–P6）的 25 个固定步骤序列（S01–S25），从电瓶供电开始，历经发动机启动、航电配置、飞行控制检查，直至滑行准备。每个步骤都有执行前必须满足的特定前提条件和推进前必须满足的完成条件。错误包括遗漏、顺序错误、参数设置错误和状态违反——这些类别在第 4 章描述的错误分类法中予以形式化。

基于此问题，我们推导出以下设计目标：

- G1 – 基于仿真器的程序性教学。** 系统必须通过仿真器状态观察学习者的操作，确定学习者当前正在尝试的程序步骤，并在学习者卡住或请求帮助时提供及时、基于证据的指导。教学输出必须引用具体的座舱元素，并引用来自遥测、文档或视觉事实的证据。
- G2 – 状态感知的步骤指导。** 系统必须通过形式化状态机跟踪程序进度。在允许步骤变为活跃状态之前，必须评估前提条件；在推进之前，必须验证完成条件。指导必须以当前仿真器状态为条件，而不仅仅是步骤顺序。

- G3 – 教学逻辑与仿真器特定集成的分离。** 核心教学逻辑——程序跟踪、门控、评分和帮助生成——必须独立于任何特定仿真器、模型提供者或知识源。仿真器特定代码、模型提供者代码和知识检索代码必须隔离在稳定接口之后，使核心能够在没有运行仿真器的情况下进行测试，并可移植到其他仿真器或训练领域。
- G4 – 可回放性和可检查性。** 学习者、教学系统和仿真器之间的每次交互都必须记录为结构化、带时间戳的事件。这些事件日志必须支持用于调试的离线回放、针对程序包的自动化评分，以及学习者行为的事后分析。它们还必须支持 VLM 适配流水线的遥测捕获和基准测试追踪的回放。
- G5 – 可选的基础模型和 VLM 支持。** 系统必须能够在有大语言模型或无大语言模型的情况下运行。当模型可用时，它可以提供更丰富的诊断和解释。当模型不可用或其输出验证失败时，系统必须优雅降级到确定性的基于规则的降级行为。用于从座舱截图中提取视觉事实的 VLM 支持必须是可选的、可独立运行的组件。
- G6 – 对不同仿真器和程序的可扩展性。** 程序定义、UI 目标映射、遥测映射、错误分类法和知识源策略必须以声明式配置（YAML 文件）表达，而非硬编码在源代码中。添加新程序或将系统适配到不同仿真器应该仅需新的配置工件，而无需更改核心教学逻辑。

这些目标直接影响以下各节描述的架构决策。

3.2 整体架构

SimTutor 遵循端口-适配器（六边形）架构。系统组织为三个主要层次，每个层次具有明确定义的职责和依赖方向。

核心层 (core/)。核心包含所有独立于任何特定仿真器、模型提供者或外部服务的领域逻辑。它定义了运行时消息传递的数据契约（第3.4节）、程序状态机和门控规则引擎（第3.6节）、评分和交互度量引擎、视觉事实本体及粘性/TTL 持久化语义、BM25 检索实现、HelpResponse 模式构建器，以及安全和审计基础设施。按设计，核心仅依赖标准 Python 库和端口层中定义的抽象接口。

端口层 (ports/)。端口层为核心在运行时可能需要的四个外部依赖定义了稳定的、技术无关的 Python 协议：模型推理 (ModelPort)、知识检索 (KnowledgePort)、视觉输入 (VisionPort) 和遥测输入 (TelemetryPort)。这些接口是核心与外部世界之间的唯一依赖注入点。

适配器层 (adapters/)。适配器层包含所有仿真器特定、提供者特定和基础设施特定的代码。它包括 DCS-BIOS 遥测接收器、遥测增强与增量去噪流水线、DCS 叠加发送器、OpenAI 兼容模型客户端（带和不带多模态支持）、Ollama 降级客户端、用于测试的确定性模型桩、本地 BM25 知识适配器、视觉事实提取运行时，以及连接模型输出与运行时行为的响应映射和操作执行组件。适配器依赖于它们所实现的端口以及它们生成和消费的核心类型；它们从不向核心引入反向依赖。

三个层次由另外两个结构元素补充：

程序包 (packs/)。程序包是一个声明式 YAML 配置文件的目录，完整描述一个程序性任务。包定义了步骤列表、前提条件和完成条件（门控规则）、UI 目标及其仿真器特定元素标识符、遥测变量映射、错误分类法类别和评分权重、增量去噪策略、带步骤绑定的视觉事实本体，以及视觉布局描述。当前代码仓库包含一个包：`fa18c_startup`，涵盖完整的 F/A-18C 冷启动程序。

CLI 与运行时入口点 (simtutor/、live_dcs.py)。`simtutor` 包提供命令行界面，用于运行模拟场景、回放和验证事件日志、评分运行、记录 VLM 预测以进行基准测试，以及回放 DCS-BIOS 原始捕获。`live_dcs.py` 模块编排完整的实时运行时循环：它将 DCS-BIOS 接收器、遥测增强流水线、知识检索、基于模型的帮助生成、可选的 VLM 视觉事实提取、叠加操作执行和事件日志记录连接成一个长期运行进程。

图3.1展示了高层组件图。

Figure 3.1: SimTutor 系统架构。核心层包含仿真器无关的领域逻辑。端口层定义抽象接口。适配器层为 DCS、模型提供者、知识源和视觉流水线提供具体实现。程序包提供声明式配置。

3.3 核心教学逻辑与仿真器适配器的分离

仿真器无关核心逻辑与仿真器特定适配器之间的分离服务于四个具体目的：

1. **可测试性**。核心逻辑可以使用模拟适配器和确定性场景进行测试，无需运行中的 DCS 实例、GPU 或到模型服务器的网络连接。代码仓库包含一个重放预录制观察序列的 `MockEnvAdapter` 和一个返回确定性响应的 `ModelStub`，从而支持快速、可复现的单元和集成测试。

2. **可维护性**。当仿真器 API 发生变化时，只需更新受影响的适配器；核心保持不变。当模型提供者发生变化时（例如，从 Ollama 变为 OpenAI 兼容的 vLLM 服务器），只有模型适配器配置受到影响。通过单一配置接口支持三种提供者（`openai_compat`、`ollama`、`stub`）。
3. **可移植性**。将系统移植到新仿真器或飞机只需编写新的遥测和叠加适配器并创建新的程序包。程序性推理、门控、评分和帮助生成基础设施可以原样复用。端口接口有意保持最小化：遥测端口需要 `start`、`poll` 和 `stop` 方法；叠加端口仅需向命名座舱元素发送高亮、清除和脉冲命令的能力。
4. **VLM 流水线的独立演进**。VLM 视觉事实提取组件通过视觉端口和视觉事实观察模式与教学运行时通信，而非直接耦合。VLM 流水线可以独立于教学运行时进行开发、训练和基准测试。运行时部署可以包含 VLM 组件、完全省略它，或用不同的感知后端替换它，而不影响教学逻辑。

3.4 数据流

运行时数据流遵循从仿真器观察到教学输出和日志记录的结构化流水线。图3.2提供了可视化摘要。

Figure 3.2: 主运行时数据流——贯穿帮助循环。

3.4.1 观察

仿真器适配器——在当前实现中为 DCS-BIOS UDP 接收器——产生一组观察流：带有版本号和时间戳的数据对象，包含原始仿真器状态以及增强后的一组规范化状态变量。

3.4.2 教学请求

当学习者触发帮助时——通过热键或 UDP 消息——将创建一个教学请求。该请求携带一个意图（`help`）、一个可选的自由文本消息、对当前观察的引用，以及由运行时编排器填充的上下文字典。

3.4.3 上下文组装

运行时编排器通过收集以下内容为帮助循环组装上下文：

- **状态变量** (vars): 来自最近遥测观察的规范化键值对。
- **最近增量** (recent_deltas): 最近状态变化的去噪、聚合摘要。
- **候选步骤** (candidate_steps): 来自程序包的合格步骤标识符。
- **确定性步骤提示** (deterministic_step_hint): 来自基于规则推理的本地计算的降级建议, 同时用作提示指导和模型输出不可用时的降级方案。
- **叠加目标允许列表** (overlay_target_allowlist): 模型被允许引用的 UI 元素集合。
- **知识片段** (rag_topk, 可选): top-k BM25 检索结果, 仅在存在知识索引时包含。

3.4.4 模型推理 (可选)

如果 ModelPort 实现可用, 组装后的上下文将被格式化为提示并发送给语言模型。模型返回一个符合 HelpResponse 模式的 JSON 结构化对象, 该模式在运行时从程序包、UI 映射和分类法动态生成。

3.4.5 响应验证与映射

原始模型输出通过验证流水线: (1) 带最小修复的 JSON 提取, (2) 模式验证, (3) 对诊断步骤 ID、下一步步骤 ID 和叠加目标的允许列表检查, (4) 证据溯源验证。如果验证成功, 帮助对象被映射为 TutorResponse, 叠加操作通过 UI 映射解析。如果验证失败, 或没有可用模型, 系统进入确定性降级。

3.4.6 操作执行

教学响应可能包含针对特定座舱元素的叠加操作 (高亮、清除或脉冲)。操作执行器根据 UI 目标允许列表验证每个操作, 限制并发高亮数量 (默认: 一个), 并通过 UDP 将命令分发到仿真器。自动点击和控件注入操作在设计上被禁止。

3.4.7 事件日志记录

帮助循环的每个阶段被记录为带版本号和时间戳的 Event 对象, 并追加到 JSONL 事件日志中, 该日志作为所有下游分析、回放和评分的权威记录。

3.5 遥测处理

遥测处理子系统通过四个阶段将原始仿真器数据转换为规范化状态表示：

1. **原始数据摄入**。DCS-BIOS 接收器在 UDP 套接字上监听二进制 DCS-BIOS 导出帧，将每帧解码为结构化 JSON 对象，附带挂钟时间戳和单调递增的序列号。
2. **变量解析**。遥测映射规定原始 BIOS 字段如何投影到规范化状态变量上。变量解析器生成一个扁平的键值对字典，并在 `vars_source_missing` 集合中跟踪不可用或未知的来源，使下游组件能够区分"值为零"和"值未知"。
3. **增量去噪处理**。可配置的策略（阈值、防抖动窗口、逐变量过滤规则）抑制由开关回弹、传感器漂移和 UDP 乱序传递引起的虚假变化。
4. **增量聚合**。去噪后的增量在可配置时间窗口内累积并被压缩为紧凑摘要以供提示上下文使用。

遥测流水线持续运行，独立于帮助循环。

3.6 程序引擎与门控规则引擎

3.6.1 程序引擎

程序引擎在步骤有序序列上维护一个有限状态机。每个步骤处于四种状态之一：`pending`、`active`（最多一个）、`done` 或 `blocked`。操作包括 `activate_next`、`complete_active`、`block_active`、`rewind` 和 `check_timeout`。所有转换被记录为内部事件并传播到事件日志。

3.6.2 门控规则引擎

门控规则引擎使用具有四个操作符的 v1 DSL 评估前提门控和完成门控：`var_gte`、`arg_in_range`、`flag_true` 和 `time_since`。评估器包含显式的未知值处理：缺失、来源缺失或哨兵值变量会导致规则失败并附诊断原因，而非静默地视为 `false`。规则在首次失败时短路；失败索引和原因被输入确定性步骤提示。

3.6.3 确定性步骤推理

当没有模型可用或模型输出验证失败时，系统降级到确定性步骤推理，该推理检查活跃步骤、未满足的门控规则和最近的 UI 目标，以产生限制在当前活跃步骤的文本

提示。默认情况下，除非本地规则能够根据当前遥测状态证明一个唯一、有效的目标，否则在降级模式下不发送叠加高亮。

3.6.4 程序包结构

程序包是驱动整个教学运行时的声明式配置。每个步骤按主要证据来源分类：

- **BIOS 优先步骤** (S01, S03–S07, S09–S13, S21)：完成证据主要在遥测变量中。
- **视觉优先步骤** (S08, S15, S18)：需要通过座舱显示器进行视觉确认。
- **手动或超出布局步骤** (S02, S14, S16, S17, S19, S20, S22–S25)：无法通过遥测或当前视觉布局完全观测。

包还定义了每个步骤的门控规则、UI 目标、教学提示和配置文件覆盖 (陆基 vs. 航母)。

3.7 仿真器适配层

3.7.1 遥测输入适配器

通过 UDP 接收 DCS-BIOS 状态数据。Python 端 `DcsBiosRawReceiver` 解析二进制协议并发射原始帧作为 JSONL 记录，供给遥测增强流水线。

3.7.2 叠加输出适配器

通过纯文本 UDP 消息向 DCS 发送高亮、清除和脉冲命令。DCS 内的 Lua 脚本 (`VRHilite.lua`) 在座舱元素上渲染图形叠加。适配器使用程序包的 UI 映射将抽象目标名称映射到 DCS 内部点代码。

3.7.3 视觉输入适配器

通过基于 UDP 的捕获触发器触发 DCS 中的截图捕获。Lua 端 `SimTutor.lua` 将三个主要座舱显示器渲染到单个复合图像中。Python 端适配器选择预触发帧和触发帧，并将它们传递给视觉事实提取器。

3.7.4 Lua 端集成

三类 Lua 脚本在 DCS 内执行：

- **状态导出** (`Export.lua`)：配置 DCS-BIOS 导出。

- **叠加渲染** (Hooks/VRHilite.lua、Hooks/SimTutorHighlight.lua): 接收并渲染高亮命令。
- **SimTutor 集成** (SimTutor/SimTutor.lua、SimTutor/SimTutor Function.lua、SimTutor/SimTutorDcsBiosHub.lua): 处理捕获和复合面板渲染。

3.7.5 计划中及部分实现的适配器

当前代码仓库包含一个 MockEnvAdapter, 用于无需运行仿真器的确定性测试。原始论文研究计划设想了一个 Meta Quest 3 VR 适配器。该适配器尚未实现; VR 部署仍为计划阶段 (第6.2节)。

3.8 事件日志与回放

3.8.1 事件模型

所有运行时事件均表示为具有固定模式的 Event 对象: 唯一标识符、挂钟时间戳、会话标识符、事件类型(observation、tutor_request、tutor_response、overlay_requested、overlay_applied、overlay_failed)、类型化负载、模式版本和可扩展元数据。

3.8.2 JSONL 事件存储

事件通过 JsonlEventStore 以 JSONL 格式持久化, 支持仅追加写入和全文件加载。

3.8.3 回放与验证

录制的事件日志可离线回放, 以验证步骤顺序和状态机一致性。遥测日志经过独立验证以确保单调序列号和时间戳。回放基础设施已在代码层面实现并使用录制的遥测追踪进行了演练; 尚未通过端到端的人在环会话进行验证。

3.8.4 评分与交互度量

评分引擎使用可配置的逐类别权重和关键步骤乘数计算遗漏和状态违反。交互度量刻画学习者行为: 停滞时间、帮助请求、LLM 触发、UI 点击次数以及叠加请求/确认次数。

3.8.5 当前局限

回放基础设施当前支持遥测层面的合成回归回放，包括带视觉帧副文件的场景 (replay_eval/fa18c_startup_v04/)。来自真人运行的带同步视觉帧的完整多模态会话的端到端回放尚未验证。

3.9 用于视觉状态理解的可选 VLM 适配

SimTutor 中的视觉感知是一个可选的、可独立运行的子系统。

3.9.1 VLM 组件的角色

VLM 组件从座舱截图中提取结构化视觉事实——关于可见显示内容的中间命题。视觉事实不是最终的教学决策；它们提供视觉证据，教学运行时将其与遥测、程序状态和文档相结合。这种分解使每个组件能够独立开发、测试和评估。

3.9.2 视觉事实本体

当前本体 (v2) 定义了跨三个显示区域的 13 个事实：

- 左 DDI: tac_page_visible、supt_page_visible、fcs_page_visible、fcs_page_x_marks_visible。
- 右 DDI: bit_root_page_visible、fcsmc_page_visible、fcsmc_intermediate_result_visible、fcsmc_in_test_visible、fcsmc_final_go_result_visible。
- AMPCD: hsi_page_visible、hsi_map_layer_visible、ins_grnd_alignment_text_visible、ins_ok_text_visible。

每个事实具有三值状态 (seen、not_seen、uncertain)、生存时间、可选的 sticky 标志，以及通过 all_of / any_of 条件实现的步骤绑定。

3.9.3 VLM 在帮助循环中的集成

当帮助请求到达且活跃步骤为视觉优先 (S08、S15、S18) 时，向 DCS 发送捕获触发器。预触发帧和触发帧被渲染并发送给 VLM。返回的事实被合并到视觉事实快照中 (具有粘性和 TTL 语义)，并包含在帮助循环上下文中。如果视觉适配器不可用或多模态请求失败，帮助循环仅使用遥测和知识继续。

3.9.4 VLM 适配流水线

运行时使用的 VLM 经过微调。适配流水线——详见第4章——包括截图捕获、由大型 VLM 进行预标注、在 Label Studio 中进行人工审查、双语 SFT 导出、LoRA 微调 (Unsloth + PEFT + TRL)，以及在独立留出会话上进行基础模型与 LoRA 对比基准测试。该流水线构成一个自成一体的贡献，涵盖从数据捕获到基准测试评估的全过程。

3.9.5 与基于规则的状态门控的区别

基于规则的门控确定性地评估遥测变量；它是确定性的和可审计的，但限于遥测可表示的条件。基于 VLM 的视觉事实提取解释没有遥测表示的显示内容。这两种机制是互补的：门控引擎提供主要的程序跟踪骨干；视觉事实为那些无法仅从遥测推断完成情况的步骤提供补充证据。

3.10 与原始研究计划的差异

本章描述的系统在若干重要方面与原论文研究计划中设想的系统有所不同。我们记录这些差异以在原始研究愿景和当前实现的系统之间建立清晰的边界。

3.10.1 从 VR 优先到桌面优先运行时

原计划描述了一个带有头显内步骤卡片的 Meta Quest 3 VR 教学系统。当前实现是一个桌面/DCS 运行时，以座舱叠加高亮作为主要输出模态。这一转变是由于构建一个具有增量去噪、确定性降级和自动化测试的基于遥测证据的运行时被证明是 VR 部署的实质性前提条件，而桌面配置为系统性基准测试提供了更受控的环境。VR 部署仍为计划的下一阶段（第6.2节）。

3.10.2 新增 VLM 适配流水线

原计划设想了一个纯文本 RAG+LLM 导师。VLM 视觉事实提取流水线是在发现若干关键程序步骤需要无法仅从遥测推断的视觉确认后添加的。VLM 流水线发展成为一个适配和基准测试循环，现在构成了一项实质性的技术贡献。

3.10.3 扩展的遥测数据基础

当前实现包含一个比原计划更为精细的遥测子系统：原始 DCS-BIOS UDP 接收、带源丢失跟踪的变量解析、增量去噪处理和增量聚合。这一扩展是由处理嘈杂、高频仿真器遥测数据的实际工程需求所驱动的。

3.10.4 新增程序性、回放和基准测试基础设施

原计划未描述形式化的程序引擎、门控规则引擎、错误分类法、事件日志记录、回放或自动化基准测试。这些是在实现过程中作为系统性评估所需的必要基础设施而开发的。

3.10.5 推迟的人因评估

原计划规划了一项三条件人因研究，但尚未实施。当前代码仓库包含了支持此类研究的技术基础设施，但没有参与者数据。人因评估仍是计划的核心组成部分（第6.2节）。

3.10.6 设计演进摘要

表3.1总结了关键差异。

Table 3.1: 从研究计划到实现系统的设计演进。

方面	原始计划	实现的系统
平台	Meta Quest 3 VR	桌面 / DCS
输出模态	头显内步骤卡片	座舱叠加高亮
状态输入	只读 DCS 状态标志	完整 DCS-BIOS 遥测 + 增量去噪
视觉感知	无（纯文本 RAG）	可选 VLM 视觉事实提取（13fact v2）
模型适配	未涉及	LoRA 微调流水线（主线：Qwen3.5-9B；补充：Gemma-4-31B） ¹
程序表示	提示中隐式表示	显式程序包驱动配置 + 门控规则
错误处理	未规定	结构化分类法、确定性降级和操作限制
评估基础设施	未规定	事件日志、回放验证、自动化评分、基准测试流水线
人因研究	计划作为主要评估	推迟；基础设施已准备

这一演进并不使原计划失效。相反，实现的系统提供了一个具体的技术基础——包含可运行代码、自动化测试和基准测试工件——计划的 VR 部署和人因评估可在此基础上进行构建。

¹Qwen3.5-9B (Qwen/Qwen3.5-9B-Base) 微调和基准测试结果是主要的已验证实验线 (C-VLM-04, C-VLM-05)。Gemma-4-31B (google/gemma-4-31B) 结果是补充性的 (C-VLM-06, *likely*)。

第四章 方法论

本章描述支撑已实现 SimTutor 系统的方法论框架。第4.1节涵盖将原始 DCS-BIOS 数据转换为规范化运行时状态的遥测处理流水线。第4.2节描述知识溯源子系统，包括 BM25 检索和来源策略执行。第4.3节介绍从截图捕获到 LoRA 微调再到基准测试评估的七阶段视觉事实数据流水线。第4.4节详述六个精选数据集、从 8-fact v1 到 13-fact v2 的本体演进以及训练方案构建。第4.5节说明 LoRA 微调配置，包括两个骨干模型的确切超参数。第4.6节定义基准测试协议、度量和留出策略。本章为第三章呈现的系统设计和第六章报告的技术结果提供了方法论基础。

4.1 程序运行时与遥测数据基础

程序运行时是 SimTutor 跟踪学习者 F/A-18C 冷启动程序进度并生成基于证据、状态感知教学输出的核心机制。它摄入原始仿真器遥测数据，将其规范化为稳定状态变量，评估门控规则以确定步骤合格性，并将结果状态表示提供给帮助循环上下文组装机。本节描述遥测处理链的每个阶段以及门控规则评估框架。

4.1.1 DCS-BIOS 原始帧摄入

遥测子系统始于原始 DCS-BIOS 数据摄入。DCS-BIOS 接收器在 UDP 套接字上监听仿真器发送的二进制 DCS-BIOS 导出帧。每帧被解码为结构化 JSON 对象，附带挂钟时间戳和单调递增的序列号。解码后的帧被写入 JSONL 文件用于存档和回放目的，并转发到遥测增强流水线中。

DCS-BIOS 协议涵盖广泛的座舱控件和指示器——开关位置、旋钮状态、警告灯以及显示相关状态标志——但原始帧是嘈杂的。开关回弹、传感器漂移、快速波动的仪表值以及 UDP 乱序传递会产生虚假变化，如果直接传递给教学运行时，将产生虚假的状态变化事件并触发不必要的帮助循环。后续流水线阶段系统地解决了这些问题。

4.1.2 变量解析与源丢失跟踪

遥测映射（在程序包的 `telemetry_map.yaml` 中指定）定义了原始 DCS-BIOS 字段如何投影到规范化状态变量上。变量解析器消费增强后的遥测观察，并生成一个扁平的键值对字典，其中每个键对应程序包中的一个命名变量（如 `apu_ready`、`battery_switch_on`）。

至关重要的是，解析器在 `vars_source_missing` 集合中跟踪不可用或未知的来源。这一机制使下游组件能够区分“值为零”和“值未知”，这对正确的门控规则行为至关重要。缺失的变量永远不会静默地评估为成功条件。

4.1.3 门控规则评估

程序引擎为每个步骤评估两种类型的门控：前提门控（在步骤变为活跃之前必须满足）和完成门控（在步骤被标记为完成之前必须满足）。门控规则 DSL 支持四种操作符：

var_gte ——命名变量必须大于或等于阈值。

arg_in_range ——命名变量必须落在指定范围内。

flag_true ——布尔标志必须为 `true`。

time_since ——自指定事件以来必须经过最小时间。

评估器包含显式的未知值处理：缺失、来源缺失或哨兵值变量会导致规则失败并附诊断原因，而非静默地视为 `false`。规则在首次失败时短路，失败索引和原因被传播到下游组件，包括确定性步骤提示和帮助循环上下文。

门控规则以声明方式在程序包的配置中指定。F/A-18C 冷启动程序中的每个步骤都根据程序的操作要求被分配了前提门控和完成门控。分类为 BIOS 优先的步骤（S01、S03-S07、S09-S13、S21）主要依赖基于遥测的门控规则进行完成检测。分类为视觉优先的步骤（S08、S15、S18）以视觉事实证据补充门控评估，因为它们的完成条件涉及遥测中未反映的座舱显示状态。

4.1.4 增量去噪与聚合

原始遥测变量由于仿真器物理以高频率变化，即使没有执行任何学习者操作。为产生适合提示上下文的稳定状态表示，流水线应用两个连续的处理阶段。

增量去噪。可配置的策略（在程序包的 `delta_policy.yaml` 中指定）定义了逐变量阈值、防抖动窗口和过滤规则。由开关回弹、传感器噪声和 UDP 乱序传递引起的虚

假变化被抑制。只有超过配置阈值并在防抖动窗口后持续存在的变化才被提升到去噪后的增量流中。

增量聚合。去噪后的增量在可配置时间窗口内累积，并被压缩为紧凑的、人类可读的摘要。该摘要作为 `recent_deltas` 包含在帮助循环上下文中，为语言模型提供最近学习者操作和状态转换的简洁表示，而不暴露原始高频遥测数据。

4.1.5 确定性降级

当没有语言模型可用或模型输出验证失败时，程序运行时降级到确定性步骤推理。降级机制检查当前活跃步骤、其未满足的门控规则以及最近的 UI 目标，以产生限制在当前活跃步骤的文本提示。默认情况下，除非本地规则能够根据当前遥测状态证明一个唯一、有效的目标，否则在降级模式下不发送叠加高亮。这确保系统即使在没有模型的情况下也能保持运行和安全。

4.2 知识溯源与来源策略

知识溯源子系统为教学运行时提供检索增强的程序性文档。它从已索引的文档集合中检索相关文本片段，并强制执行限制哪些文档可以呈现给模型的来源策略。

4.2.1 BM25 检索

知识检索使用 BM25，一种来自概率信息检索家族的词袋排序函数。文档使用 `index_docs.py` 工具在句子级别进行索引，该工具将 F/A-18C NATOPS 飞行手册和补充冷启动文档预处理为本地 JSON 索引。

在检索时，从当前程序状态构造一个溯源查询：活跃步骤标识符、其在步骤注册表中的描述以及最近的遥测观察。查询使用标准 BM25 加权函数以默认参数 ($k_1 = 1.2$, $b = 0.75$) 进行分词并与索引句子进行评分。返回 top- k 得分片段（默认 $k = 5$ ），并作为可选上下文包含在帮助循环提示中。

4.2.2 来源策略

并非所有知识源都适用于每种教学上下文。声明式来源策略（在 `knowledge_source_policy.yaml` 中指定）定义了允许的文档来源允许列表。每个索引句子携带一个来源标识符，策略强制执行只有来自允许来源的片段才包含在检索结果中。

来源策略服务于两个目的。首先，它防止模型暴露于与当前程序包相矛盾的程序变体——例如，当当前配置文件为陆基时的航母程序。其次，它将检索范围限制在经

过筛选、已验证的文档中，降低因过时或不相关来源产生幻觉的风险。

知识子系统是可选的：如果不存在知识索引，帮助循环仅使用遥测和程序上下文继续。缺失的知识检索不得阻塞主教学流程。

4.3 视觉事实数据流水线

视觉事实数据流水线将原始 DCS 座舱截图转换为结构化视觉事实提取模型。它包含七个阶段，涵盖数据捕获、人工标注、监督微调数据集生成、模型训练和基准测试评估。每个阶段产生带版本号、可检查的工件，实现从原始图像到基准测试指标的完全可追溯性。图4.1提供了概览。

Figure 4.1: 七阶段视觉事实数据流水线。捕获和预标注供给人工审查；经审查的标注驱动双语 SFT 导出；导出的数据训练 LoRA 适配器；基础模型和 LoRA 模型在独立留出集上进行基准测试。

4.3.1 第一阶段：DCS 截图捕获

第一阶段从 DCS World 捕获座舱截图。Lua 端 `SimTutor.lua` 脚本将三个主要多功能显示器——左 DDI、AMPCD 和右 DDI——渲染为单个复合面板图像。Python 端 `capture_vlm_dataset.py` 脚本编排捕获过程：它在可配置的时间间隔触发截图，将每次捕获与一个会话标识符和挂钟时间戳关联，并存储原始图像及副文件清单。

选择复合面板格式是为了使训练、预标注、评估和运行时使用保持在同一输入分布上，避免训练-评估不匹配——即模型在训练期间接受三个分离区域裁剪，但在推理时接收单个复合图像。

4.3.2 第二阶段：初始 VLM 预标注

每张捕获的复合面板图像由大型 VLM（通过 OpenAI 兼容 API 访问的 Qwen 397B 级模型）使用目标视觉事实本体作为提示契约进行预标注。预标注脚本将每张图像与一个结构化提示一起发送，该提示枚举本体中的所有事实、其定义以及三种可接受状态（`seen`、`not_seen`、`uncertain`）。VLM 返回一个包含逐事实标签和证据注释的 JSON 对象。

预标注作为种子步骤：它大规模生成初始标注，然后通过人工审查加以完善。预标注 VLM 是大型通用模型；它未在座舱领域进行微调，经常在模糊或稀有视觉状态上出错。下一阶段的人工审查纠正这些错误。

4.3.3 第三阶段：Label Studio 人工审查

预标注样本被导入 Label Studio，一个开源数据标注平台。每个任务向审查者呈现复合面板图像、VLM 对所有事实的预测标签以及一个自由文本摘要字段。审查者检查图像，纠正任何标注错误的事实，并为每处更正提供证据注释。审查界面强制要求每个事实接收三种可接受状态之一，并且摘要字段必须填写。

人工审查是质量控制瓶颈：每个捕获会话包含 50 到 220 张图像，每张图像的审查时间取决于可见事实的数量和审查者对座舱显示的熟悉程度。所有经审查的样本都带有审计追踪，可追溯到原始图像、原始 VLM 预标注和审查者的更正。

4.3.4 第四阶段：经审查的 JSONL 导出

人工审查后，Label Studio 将更正后的标签导出为 JSONL 文件。每行包含任务标识符、原始图像路径、带逐事实状态和证据注释的经审查事实，以及经审查的摘要。此经审查的 JSONL 是所有下游阶段（SFT 导出、训练和基准测试）的权威真实标注工件。

4.3.5 第五阶段：双语 SFT JSONL 生成

经审查的 JSONL 由 `export_vision_sft_dataset.py` 转换为 OpenAI 兼容的多模态对话 SFT 格式。每个经审查的样本生成两行训练数据——一行英文和一行中文——共享相同的复合面板图像和相同的事实标签，但在系统和用户指令文本上有所不同。

每个 SFT 行是一个三轮对话：一则系统消息指示模型仅输出 JSON，一则用户消息包含 base64 编码的图像和文本指令（枚举所有事实、其定义和决策边界），以及一则助手消息包含带有 `facts` 数组和 `summary` 字符串的真实标注 JSON 对象。助手输出中的每个事实条目恰好包含三个字段：`fact_id`、`state` 和 `evidence_note`。外部元数据字段如 `frame_id`、`session_id`、`confidence` 和图像路径被排除在训练目标之外，因为它们是数据集管理字段，而非视觉可推断属性。

双语 SFT 增加的是指令多样性而非视觉多样性：英文和中文示例共享相同的图像和事实标签。其目的是提高两种语言下的 JSON 格式鲁棒性，并支持最终的双语运行时部署。

4.3.6 第六阶段：LoRA 微调

导出的 SFT JSONL 文件用于通过低秩适配（LoRA）微调基础 VLM。训练栈组合三个组件：Unsloth 用于 4 位 VLM 加载、LoRA 注入和视觉批次整理；PEFT 用于

LoRA 适配器定义；TRL SFTTrainer 用于监督微调循环。

训练脚本通过 Unsloth 的 `FastVisionModel.from_pretrained` 以 4 位精度加载基础模型，对视觉和语言层（Qwen）或仅语言线性层（Gemma）应用 LoRA 适配器，并在双语 SFT 数据上进行训练。适配器权重与基础模型分开保存，便于高效存储和推理时加载。完整的训练配置细节见第4.5节。

4.3.7 第七阶段：基础模型与 LoRA 对比基准测试

最后阶段在留出数据集上评估微调后的 LoRA 适配器与未适配基础模型。基准测试脚本以 4 位推理模式加载每个模型（基础模型和基础模型加 LoRA），通过训练期间使用的相同提示发送每个留出样本，根据预期 JSON 模式解析和验证模型输出，并计算一套将模型预测与人工审查真实标注进行比较的度量。基准测试协议详见第4.6节。

4.3.8 端到端可追溯性

该流水线的一个定义性方法论属性是端到端可追溯性。每个基准测试预测都可以通过训练数据、人工审查标签、VLM 预标注和原始 DCS 截图进行追溯。流水线在每个阶段产生带版本号的工件：捕获清单、预标注 JSONL 文件、Label Studio 导出文件、SFT JSONL 文件、LoRA 适配器权重、`train_summary.json` 文件、基准测试预测以及基准测试度量摘要。这一监管链使得对任何观察到的模型行为进行严格审计成为可能，从单个事实误分类到聚合基准测试度量。

4.4 数据集构建

4.4.1 数据集概览

视觉事实数据流水线在连续的捕获和审查周期中生成了六个数据集。表4.1总结了每个数据集的角色、样本数、事实本体版本、审查状态和导出语言。

每个数据集均经过完全人工审查：每个样本都已在 Label Studio 中检查并更正。Run-003 和 Run-005 包含人工审查者将摘要字段留空的样本（分别有 82 和 25 个样本，如 `missing_summary_count` 字段所记录）。这些样本对训练和评估仍然有效，因为事实数组——主要监督目标——对每个样本中的每个事实都已完全标注。

4.4.2 本体演进：从 8-Fact v1 到 13-Fact v2

初始的 8-fact v1 本体(用于 Run-001 和 Run-002)定义了八个事实：`fcs_page_visible`、`bit_root_page_visible`、`bit_page_failure_visible`、`right_ddi_fcsmc_page_visible`、

Table 4.1: 数据集清单。所有样本数来自相应的 `stats.json` 文件。

数据集	角色	样本	本体	已
Run-001 (<code>vision_sft</code>)	训练源 (8-fact v1)	180	8-fact v1	
Run-002 (<code>vision_sft_holdout_run002</code>)	留出 (8-fact v1)	50	8-fact v1	
Run-002 newfacts (<code>vision_sft_holdout_run002_newfacts</code>)	留出 (13-fact v2)	50	13-fact v2	
Run-003 (<code>vision_sft_run003</code>)	训练源 (13-fact v2)	220	13-fact v2	
Run-004 (<code>vision_sft_holdout_run004_random</code>)	留出 (13-fact v2)	100	13-fact v2	
Run-005 (<code>vision_sft_run005_composition_rebalance</code>)	训练补充 (13-fact v2)	122	13-fact v2	

`right_ddi_in_test_visible`、`fcs_bit_result_visible`、`ins_alignment_page_visible` 和 `ins_go`。

v1 本体在初始基准分析中暴露出两个结构性弱点。首先，它混合了抽象层次：一些事实描述低层视觉观察（如 `fcs_page_visible`），而另一些则编码了更高层的程序性判断（如 `ins_go`，它代表 INS 校准过程的完成信号而非直接可观察的视觉特征）。其次，若干事实共享重叠语义：`bit_root_page_visible` 和 `bit_page_failure_visible` 可能在某些座舱状态下重叠，而 `right_ddi_fcsmc_page_visible` 将区域标识符与事实语义混淆。

13-fact v2 本体（用于 Run-003、Run-004、Run-005 及当前运行时）重新设计并扩展了事实集。v2 事实为：`tac_page_visible`、`supt_page_visible`、`fcs_page_visible`、`fcs_page_x_marks_visible`、`bit_root_page_visible`、`fcsmc_page_visible`、`fcsmc_intermediate`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`hsi_page_visible`、`hsi_map_layer_visible`、`ins_grnd_alignment_text_visible` 和 `ins_ok_text_visible`。

v2 重新设计通过三种策略解决了 v1 的弱点。首先，模糊的 `ins_go` 事实被分解为两个低层、直接可观察的事实：`ins_grnd_alignment_text_visible`（要求字面 GRND 校准块文本）和 `ins_ok_text_visible`（要求校准块附近清晰可读的 OK 文本）。其次，区域标识符从事实名称中移除（`right_ddi_fcsmc_page_visible` 变为 `fcsmc_page_visible`），并为 TAC 和 SUPT 菜单添加了页面可见性事实以覆盖左 DDI。第三，FCS-MC 状态序列被分解为更细粒度的四状态链（`page`、`intermediate_result`、`in_test`、`final_go_result`），替换了单一的 `fcs_bit_result_visible` 事实。第四，HSI 相关事实被拆分为 `hsi_page_visible` 和 `hsi_map_layer_visible`，FCS X 标记事实与 FCS 页面可见性分离。

4.4.3 训练方案：Run-003 + Run-005x2

13-fact v2 模型的主要训练方案将 Run-003 (220 个经审查样本, 双语导出生成 220 条英文和 220 条中文训练行) 与包含两次的 Run-005 组合再平衡数据 (122 个经审查样本, 双语导出生成 $122 \times 2 = 244$ 条英文和 $122 \times 2 = 244$ 条中文训练行) 相结合。得到的训练集包含 928 行。

Run-005 专门作为组合再平衡数据集采集。对 Run-003 事实状态分布的分析揭示了严重的类别不平衡: 若干关键事实 (如 `fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`ins_ok_text_visible`) 在训练数据中具有极少的 `seen` 示例。Run-005 设计了目标座舱状态转换以过采样这些代表性不足的视觉状态。

Run-005 的双重计数 (Run-005x2) 进一步放大了这些稀有状态在训练分布中的代表性。该训练运行的输入文件为: 来自 Run-003 的 `sft_en.jsonl` 和 `sft_zh.jsonl`, 加上来自 Run-005 的 `sft_en.jsonl` 和 `sft_zh.jsonl` 各两份副本, 共计六个输入文件。

未使用内部评估划分: 训练配置设置 `eval_rows = 0`。所有评估均在独立留出数据集上执行。

4.4.4 留出集独立性验证

留出集独立性是一项关键的方法论要求: 基准测试必须测量跨会话泛化, 而非分布内记忆。构建了两个留出集:

- **Run-002** (及其 13-fact 重标注 `run002_newfacts`): 一个与所有训练会话不同的新 DCS 捕获会话。包含 50 个经审查样本。
- **Run-004 random**: 一个进一步独立的捕获会话, 采用均匀随机采样的座舱状态。包含 100 个经审查样本。

每个留出集与训练数据之间的完全重叠经验证为零 (0)。重叠检查比较了训练和留出划分中的图像工件路径和样本标识符。没有留出样本出现在任何训练输入文件中。

相比之下, 早期 8-fact v1 实验中使用的 Run-001 基准测试是一个**受污染开发集**: 训练示例所来源的同一数据池被用于评估。Run-001 结果仅为回归分析报告, 并与独立留出结果明确区分。

4.5 LoRA 微调配置

4.5.1 基础模型

两种基础 VLM 架构在相同训练数据方案下进行了微调以实现骨干对比：

Qwen/Qwen3.5-9B-Base ——一个 90 亿参数的视觉语言模型，支持多模态输入（图像 + 文本）和文本生成。这是主要的实验骨干。

google/gemma-4-31B ——来自 Google DeepMind 的 310 亿参数视觉语言模型。这是补充对比骨干，用于检验相同训练数据方案是否可跨模型家族泛化。

两个模型均通过 Unsloth 的 `FastVisionModel.from_pretrained` 以 4 位精度加载。对 Qwen, LoRA 适配器应用于视觉和语言层 (`finetune_vision_layers=True`, `finetune_language_layers=True`)。对 Gemma, LoRA 被限制在所有线性模块 (`lora_target_modules`) 且视觉层未微调 (`finetune_vision_layers=False`)。

4.5.2 训练栈

训练栈包含三个集成组件：

1. **Unsloth** ——处理 4 位模型加载、LoRA 注入、通过 `UnslothVisionDataCollator` 进行视觉批次整理，以及 FP16/BF16 自动精度选择。
2. **PEFT (参数高效微调)** ——定义 LoRA 适配器格式，包括秩、alpha、dropout 和目标模块选择。
3. **TRL SFTTrainer** ——以可配置的批次大小、梯度累积、轮数、学习率、预热和权重衰减运行监督微调循环。

4.5.3 超参数配置

表4.2列出了主要训练运行 (Run-003 + Run-005x2) 使用的精确超参数，在两个骨干间匹配。所有值取自 `train_summary.json` 工件。

最终训练损失值 (Qwen 为 0.2156, Gemma 为 0.0474) 不应在骨干间直接比较，因为分词器行为、对话模板结构、目标序列分布和模型参数化各不相同。4 个轮数的选择是作为小数据领域适配的折衷：仅有 928 个训练样本，更少的轮数可能无法可靠地教会模型固定的 JSON 模式和座舱事实边界，而更多的轮数则有过度拟合训练会话的风险。

Table 4.2: LoRA 微调超参数，在 Qwen3.5-9B 和 Gemma-4-31B 间匹配。

参数	Qwen3.5-9B	Gemma-4-31B
max_seq_length	4096	4096
num_train_epochs	4.0	4.0
learning_rate	2×10^{-4}	2×10^{-4}
per_device_train_batch_size	1	1
gradient_accumulation_steps	4	4
lora_r	16	16
lora_alpha	16	16
lora_dropout	0.0	0.0
seed	3407	3407
load_in_4bit	True	True
warmup_ratio	0.1	0.1
weight_decay	0.01	0.01
train_rows	928	928
eval_rows	0	0
骨干特定		
视觉 LoRA	启用	禁用
LoRA 目标模块	vision + language + attention + MLP	all-linear
对话模板	Qwen 默认	gemma-4
GPU 内存利用率	0.6	0.95
训练结果		
训练运行时间（秒）	6419.16	8049.65
训练损失（最终）	0.2156	0.0474

LoRA 秩 $r = 16$ 和 $\alpha = 16$ 提供适度的适配能力：足以学习座舱布局模式和 JSON 格式，但不像高容量适配器 ($r \geq 64$) 那样可能更激进地过度拟合小数据集。在主要运行中将 Dropout 设置为零，在首次适配实验中优先考虑可学习性而非正则化。

4.5.4 双语 SFT 策略

双语 SFT 策略为每个经审查样本生成两行训练数据：一行使用英文系统和用户指令，一行使用中文指令。两行共享相同的图像 (base64 编码) 和相同的助手目标 (真实标注事实 JSON)。英文助手目标被复用于中文行；模型的任务是从图像中提取视觉事实，而非生成语言特定的自然语言描述。

这种方法在不增加额外人工标注工作量的情况下提高了跨语言指令遵循的鲁棒性。然而，它不能替代额外的座舱状态截图或困难负样本视觉数据。

4.5.5 组合再平衡策略

组合再平衡策略 (Run-005) 解决了主要训练源 (Run-003) 中观察到的类别不平衡。在 Run-003 中，若干事实具有极低的正例 (seen) 计数: `ins_ok_text_visible` 在 220 个样本中仅有 12 个 seen 示例 (5.5%); `fcs_page_x_marks_visible` 有 16 个 (7.3%); `fcsmc_intermediate_result_visible`, `fcsmc_in_test_visible` 和 `fcsmc_final_go_result_visible` 各有 18 个 (8.2%)。

Run-005 捕获了 122 个额外样本，针对这些稀有事实为 seen 的座舱状态。在 Run-005 增强后，组合训练集提供了对先前代表性不足事实的改进覆盖: `supt_page_visible` (组合 seen 从 20 到 54)、`fcsmc_page_visible` (从 55 到 111)、`hsi_page_visible` (从 106 到 215) 以及 `ins_grnd_alignment_text_visible` (从 58 到 130)。

Run-005 数据在训练方案中被包含两次 (Run-005x2)，进一步放大了这些代表性不足视觉状态的信号。

4.6 基准测试协议

4.6.1 度量指标

基准测试使用以下度量比较模型预测与人工审查真实标注标签：

json_valid_rate —— 模型输出可被解析为 JSON 对象的样本比例。此处的失败表明模型产生了非 JSON 文本 (如 markdown、自然语言评论或格式错误的括号)。

schema_valid_rate ——解析后的 JSON 符合预期模式的样本比例：顶层对象仅包含 `summary` 和 `facts` 键，`facts` 数组中每个条目恰好包含 `fact_id`、`state` 和 `evidence_note`，所有 13 个事实 ID 均恰好出现一次，所有状态均在 `{seen, not_seen, uncertain}` 中。

fact_accuracy ——所有样本中所有事实的三类准确率，计算为与真实标注标签匹配的单个事实预测的比例。

macro_f1 ——跨三种状态 (`seen`、`not_seen`、`uncertain`) 的宏平均 F1 分数，逐事实计算后跨所有 13 个事实平均。

seen_f1 ——正类 `seen` 的 F1 分数，逐事实计算后跨所有 13 个事实平均。这是一个特别重要的指标，因为遗漏 `seen` 状态（假阴性）或幻觉出 `seen` 状态（假阳性）直接影响下游程序状态推理。

sample_exact_match ——所有 13 个事实与真实标注标签完全匹配的样本比例。单个事实的误分类计为样本级失败。

critical_false_positive_count ——分类为关键的事实子集(6 个事实的子集:`fcs_page_x_marks`、`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`、`ins_grnd_alignment_text_visible`、`ins_ok_text_visible`) 中，当真实标注为 `not_seen` 或 `uncertain` 时被预测为 `seen` 的错误计数。

关键假阳性被单独跟踪，因为它们代表了教学上下文中最具后果性的错误类型：错误地报告一个完成关键状态为已观察而实际上并非如此。例如，一个错误地认为 INS 校准已完成（基于 `ins_ok_text_visible` 假阳性）的导师可能跳过必要的指导，潜在地导致程序性错误。

基准测试还计算逐事实混淆矩阵以及逐事实的精确率、召回率和 F1 分数，这些存储在 `fact_scores.csv` 中，并附带自动生成的图表（总体准确率、样本完全匹配、逐事实宏 F1、逐事实 `seen` F1、关键假阳性以及逐事实混淆矩阵）。

4.6.2 基础模型与 LoRA 对比方法论

基准测试协议比较两种模型配置在相同真实标注标签上的表现：

1. **基础模型**：未适配的基础 VLM，以 4 位推理模式加载，不带任何 LoRA 适配器。
2. **LoRA 模型**：相同基础 VLM，以 4 位推理模式加载，通过 PEFT 的 `PeftModel.from_pretrained` 加载 LoRA 适配器权重。

两种配置接收相同的提示、相同的图像和相同的生成参数：temperature = 0.0（贪婪解码）、max_new_tokens = 1024、seed = 3407。基准测试独立运行每个样本，将预测序列化到 JSONL 中，并在没有任何事后过滤或排除的情况下计算度量。

对比脚本（comparison.json）计算增量度量（LoRA 减去基础模型）和一个自动化推荐标志（recommend_simtutor_chain_validation），该标志在 LoRA 适配器同时提升 JSON 有效性、事实准确率、seen F1，且不增加关键假阳性时激活。

4.6.3 留出定义与基准测试类别

每个基准测试运行被赋予一个 benchmark_kind，决定其结果应如何解读：

contaminated_dev_set ——评估集从与训练集相同的数据池中抽取。结果表明模型是否学会了模式和分布内视觉边界，但不能支持泛化声明。用于 Run-001 基准测试。

heldout_new_session ——评估集是一个完全独立的捕获会话，与任何训练数据零重叠。结果支持跨会话泛化声明。这是主要评估类别。Run-002 newfacts 和 Run-004 random 基准测试属于此类别。

受污染与留出基准测试之间的区分在整个基准测试基础设施中被严格执行，并反映在结果章节（第六章）中。

4.6.4 基准测试工件

每个基准测试运行生成一个标准化的工件目录：

- benchmark_summary.json ——顶层摘要，包含对比增量和图表路径。
- metrics_base.json / metrics_lora.json ——完整度量字典，包括逐事实分数和混淆矩阵。
- predictions_base.jsonl / predictions_lora.jsonl ——逐样本模型输出，每行一个 JSON 对象。
- errors_base.jsonl / errors_lora.jsonl ——单个预测错误，包含金标签、预测标签和原始模型文本。
- comparison.json ——增量度量和推荐标志。
- fact_scores.csv ——逐事实逐模型度量的 CSV 表。

- `report.md` —— 人类可读的 markdown 摘要。
- `charts/` —— 自动生成图表：总体准确率、样本完全匹配、逐事实宏 F1、逐事实 seen F1、关键假阳性，以及基础模型和 LoRA 模型的逐事实混淆矩阵。

这些工件构成了第**六**章中报告的技术结果的完整证据链。通过使用相同的经审查 JSONL 和 LoRA 适配器权重重新运行基准测试脚本，每个度量、图表和错误记录都是可复现的。

4.7 本章小结

本章描述了 SimTutor 系统的四个方法论支柱：基于遥测证据的程序运行时、以 BM25 检索和来源策略为基础的知识溯源、从截图捕获到基准测试的七阶段视觉事实数据流水线，以及在两个骨干架构间匹配超参数的 LoRA 微调协议。该方法论的特征在于端到端可追溯性——每个基准测试度量可通过训练数据、人工审查标签和原始截图进行追溯——以及受污染开发基准测试与独立留出基准测试之间的严格分离。这些方法论选择直接支撑了第**六**和第**七**章中呈现的声明和结果。

第五章 实现

本章描述 SimTutor 系统的具体实现，其设计已在第[三](#)章中呈现。本章涵盖技术栈、核心领域模块、遥测与 DCS 集成流水线、结构化帮助生成子系统、VLM 视觉事实提取运行时、回放与日志基础设施，以及 CLI 和实时运行时入口点。方法论层面的细节——VLM 适配协议、数据集构建和基准测试设计——见第[四](#)章。

5.1 技术栈

SimTutor Python 代码库使用 Poetry¹ 管理，要求 Python 3.10 或更高版本。核心库依赖保持最小化：`httpx` (v0.28+) 用于 HTTP 客户端功能，`PyYAML` (v6+) 用于所有声明式配置，`jsonschema` (v4.23+) 用于模型输出和遥测帧的 Draft 2020-12 JSON Schema 验证，以及 `Pillow` (v12+) 用于 VLM 流水线中的图像处理。测试依赖 `pytest` (v7.4+) 和 `pytest-cov` (v5.0+) 并启用分支覆盖率。

DCS Lua 端集成包含部署到 DCS Saved Games 目录的五个脚本：`Export.lua` 引导 DCS-BIOS 导出协议；`VRHilite.lua` 和 `SimTutorHighlight.lua` 在 UDP 套接字上监听高亮、清除和脉冲命令，并通过 `net.dostring_in` 将它们渲染为座舱叠加；`SimTutor.lua` 及其配套 `SimTutor Function.lua` 处理复合面板截图捕获和 DCS-BIOS 集线器集成。

模型服务是提供者无关的。主要路径使用 OpenAI 兼容 API 端点（适用于 vLLM、llama.cpp 或 TGI 服务器），通过环境变量 `SIMTUTOR_MODEL_PROVIDER=openai_compat` 以及基础 URL 和 API 密钥进行配置。Ollama 降级方案(`SIMTUTOR_MODEL_PROVIDER=ollama`)提供无需 API 密钥的本地兼容性。确定性桩(`SIMTUTOR_MODEL_PROVIDER=stub`)为测试返回固定响应，无需任何外部模型服务。通过设置 `SIMTUTOR_MODEL_ENABLE_MULTIMODAL=1` 启用多模态支持，使 OpenAI 兼容适配器在请求负载中包含 base64 编码的图像。

视觉语言模型的 LoRA 微调使用 Unsloth 库配合 PEFT 和 TRL，以 Qwen3.5-9B-Base 为主要骨干，Gemma-4-31B 为补充线。视觉事实标注的预标注和人工审查在 Label Studio 中进行。

¹版本 0.1.0，在 `pyproject.toml` 中以包名 `simtutor-core` 声明。

5.2 核心领域层

核心层实现所有独立于特定仿真器、模型提供者或外部服务的领域逻辑。它被组织为大约十五个模块，每个模块具有明确的单一职责。

5.2.1 程序引擎

`core/procedure.py` 中的 `ProcedureEngine` 类实现了第3.6节描述的步骤状态机。每个步骤由一个 `StepState` 数据类表示，包含步骤标识符和 `StepStatus` 枚举定义的四种状态之一：PENDING、ACTIVE、DONE 或 BLOCKED。引擎强制确保在任何时刻最多只有一个步骤为 ACTIVE。暴露五个操作：`activate_next` 将下一个 PENDING 步骤推进到 ACTIVE；`complete_active` 将活跃步骤转换为 DONE；`block_active` 将其标记为 BLOCKED；`rewind` 将已完成步骤返回到 ACTIVE；`check_timeout` 测试活跃步骤是否超过可配置的挂钟时限。所有状态转换发出带有 ISO-8601 时间戳和可选原因字符串的内部事件记录；这些事件随后传播到 JSONL 事件存储。

5.2.2 门控规则引擎

`core/gating.py` 中的门控引擎评估以前述小型领域特定语言表达的前提门控和完成门控。实现了四种操作符：`var_gte`（遥测值阈值）、`arg_in_range`（数值区间成员）、`flag_true`（带字符串强转的布尔标志）和 `time_since`（自标记事件以来的挂钟时间）。每条规则返回一个 `RuleResult` 数据类，携带布尔状态、点号表示法的失败路径以及人类可读的原因。评估器包含显式的未知值处理：哨兵字符串 "unknown"、"unk"、"missing"、"n/a" 和 "na" 导致规则失败并附诊断消息，而非静默地视为 False。规则在首次失败时短路；首个未满足规则的索引和原因输入确定性步骤推理逻辑。

5.2.3 评分引擎

`core/scoring.py` 中的评分模块实现了一个简单的事件日志评分器，遵循程序包中定义的错误分类法。它统计两类错误：遗漏（OM），定义为从未完成直到最大观察到步骤的规范步骤；以及状态违反（SV），通过观察负载中的 "state_violation" 标签识别。对步骤注册表中标记为 `critical` 的步骤遗漏应用关键步骤乘数。三个额外类别（CO、OR、PA）的分类法定义了计数器和基础权重，但在当前 v1 评分实现中默认值为零。总错误分数计算为向上取整的加权和。

5.2.4 视觉事实本体与状态管理

`core/vision_facts.py` 中的视觉事实模块将 13-fact v2 本体集中为 `VISION_FACT_IDS` 元组, 包含诸如 `tac_page_visible`、`fcsmc_final_go_result_visible` 和 `ins_ok_text_visible` 等标识符。配置通过一个文件系统 `stat` 缓存、LRU 缓存的加载器 (`load_vision_facts_config`) 从 `vision_facts.yaml` 加载, 该加载器规范化事实规范 (粘性标志、毫秒 TTL、预期区域、关联步骤 ID) 和步骤绑定 (`all_of` 和 `any_of` 条件)。

`merge_vision_fact_observation` 中的核心合并逻辑实现了三种关键语义。第一, 粘性保留: 先前状态为 `seen`、其 `sticky` 标志为 `True` 且其 TTL 未过期的事实不会被后续的 `not_seen` 或 `uncertain` 观察覆盖——只有后续的 `seen` 或过期才能替换它。第二, 基于 *TTL* 的过期: `prune_expired_facts` 丢弃任何 `expires_at_wall_ms` 早于当前挂钟时间的事实。第三, 步骤绑定满足: `facts_satisfy_step_binding` 检查 `all_of` 列表中的所有事实均为 `seen` 且 `any_of` 列表中至少有一个事实 (如果已定义) 为 `seen`。

对于 `fcsmc_final_go_result_visible` 事实 (步骤 S18), 一个额外的强制转换层检查 `result_kind` 字段和 `evidence_note` 文本, 对照一组正则表达式 (如 "MC1: GO"、"FCSA: GO")。seen 状态仅在分类产生 "final_go" 时保留; 中间状态 (如 "intermediate_go"、"in_test" 或 "not_ready") 被强制转换为 "not_seen", 其他任何状态被强制转换为 "uncertain"。

5.2.5 动态 HelpResponse 模式

`core/llm_schema.py` 模块在运行时而非从静态文件生成结构化帮助响应的 JSON Schema。函数 `build_help_response_schema` 接收三个枚举值列表——来自步骤注册表 (或包配置) 的步骤标识符、来自 UI 映射的叠加目标名称, 以及来自分类法的错误类别代码——并构建一个具有四个必需顶层键的 Draft 2020-12 模式: `diagnosis`、`next`、`overlay` 和 `explanations`。模式中一个特别详细的部分是 `overlay.evidence` 数组: 对于每个叠加目标, 一个条件子模式 (`if/then`) 要求证据数组至少包含一个引用该目标的项目, 从而强制模型不能在不引用推断该目标所依据的证据源的情况下请求叠加。该模式还要求每个证据项携带一个限制在集合 `{"var", "gate", "rag", "delta", "visual"}` 中的 `type` 字段、非空的 `ref` 和 `quote`, 以及介于 0.0 和 1.0 之间的 `grounding_confidence`。计算出的模式基于其源文件的文件系统修改时间和大小进行缓存键控, 从而在长时间运行会话中避免模式重新生成。

5.2.6 数据契约

两个版本的数据契约共存。`core/types.py` 中的 `v1` 类型定义了整个运行时使用的四个核心数据类: `Observation` (带时间戳的仿真器状态, 包含可选程序提示和标签)、

TutorRequest (学习者发起的帮助意图, 包含观察引用和上下文字典)、TutorResponse (教学输出, 包含状态、消息、叠加操作和解释) 以及 Event (通用日志条目, 包含会话标识符、事件类型、带版本号的负载和可扩展元数据)。所有四个类都带有基于 UUID 的标识符、ISO-8601 挂钟时间戳和 to_dict 序列化方法。

core/types_v2.py 中的 v2 类型扩展了契约空间, 增加了仿真器特定结构: DcsObservation (原始 DCS-BIOS 帧, 包含序列号和座舱字典)、TelemetryFrame (增强状态, 包含规范化的 vars、BIOS 快照和座舱参数)、VisionObservation (截图元数据, 包含帧标识符、布局标识符、捕获时间戳和图像 URI)、VisionFact (单个视觉事实, 包含标识符、三值状态、源帧引用、TTL 和证据注释) 以及 VisionFactObservation (提取器返回的事实集合, 携带触发时间戳和帧标识符列表)。

5.2.7 其他核心模块

若干支撑性核心模块完善了领域层。core/vars.py 实现了 VarResolver——一个遥测变量解析器, 评估受限的 Python 表达式 (数值算术、布尔逻辑、比较和 num() 强制转换函数) 以将原始 BIOS 数据投影到规范化状态变量上, 同时跟踪 vars_source_missing 以实现键级可观测性。core/knowledge.py 提供了一个 BM25Retriever 类, 实现了具有 Okapi 风格 IDF 的标准 BM25 词项加权, 供本地知识适配器用于文档片段检索。core/overlay.py 定义了 OverlayPlanner 类, 使用程序包的 UI 映射将抽象目标名称 (如 battery_switch) 映射到 DCS 内部点代码, 并生成具有三种意图之一的 OverlayIntent 对象: highlight、clear 或 pulse。core/step_signal_metadata.py 提供可观测性状态规范化和 compute_requires_visual_confirmation, 该函数基于步骤的 observability 字段和 evidence_requirements 列表确定步骤是否需要视觉证据。core/help_cycle_audit.py 定义了规范集合的帮助循环审计字段 (generation_mode、vision_used、frame_id、sync_delta_ms 等) 以及一个被实时运行和回放路径一致使用的规范化函数。

5.3 遥测与 DCS 集成

遥测集成流水线分四个阶段运行, 每个阶段由一个专用适配器模块实现。

原始 DCS-BIOS 摄入。 DcsBiosRawReceiver 类打开一个 UDP 套接字并监听 DCS-BIOS 二进制导出帧。原始帧被解码为 UTF-8 JSON 并直接写入 JSONL 文件而不做处理, 从而支持独立于实时运行时离线回放 BIOS 数据。配套的 DcsBiosReceiver 类提供更高层的接口, 解析 BIOS 负载, 强制单调序列号, 将全状态增量合并到累积状态字典中, 并生成供教学运行时消费的 Observation 对象。

BIOS 到 UI 的映射。BiosUiMapper 类从程序包加载 bios_to_ui.yaml, 将 DCS-BIOS 键名映射到抽象 UI 目标标识符。此映射使增量聚合流水线和确定性步骤推理模块能够将原始遥测变化转换为语义上有意义的 UI 引用。

变量解析与增强。adapters/telemetry_pipeline.py 中的 enrich_bios_observation 将 VarResolver 应用于 TelemetryFrame, 在 vars 字典中生成规范化的键值对。解析器通过 telemetry_map.yaml 中定义的表达式从四个引用根 (bios, lo, cockpit_args, vars) 进行投影。源引用缺失或表达式求值为 None 的变量在 vars_source_missing 中被跟踪, 为下游组件提供键级可观测性。

增量去噪与聚合。adapters/delta_sanitizer.py 中的 DeltaSanitizer 类应用从 delta_policy.yaml 加载的可配置 DeltaPolicy 以抑制虚假状态变化。该策略指定了逐变量数值变化阈值、防抖动窗口和过滤规则。验证后的变化作为 SanitizedDelta 记录发出, 携带保留和丢弃的变化计数以及逐原因细分。adapters/delta_aggregator.py 中的 DeltaAggregator 在可配置的时间窗口内累积去噪增量, 并将其压缩为包含最近 UI 目标 (通过 BiosUiMapper 映射)、top-*k* 键变化和丢弃变化统计的 DeltaSummary。这些摘要包含在帮助循环提示上下文和实时运行时使用的最近操作环形缓冲区中。

遥测帧模式。v2 遥测帧模式 (simtutor/schemas/v2/telemetry_frame.json) 定义了增强遥测记录的规范结构, 包括挂钟时间戳、会话标识符、BIOS 快照、座舱参数、规范化变量和可选的底层输出。所有实时和回放路径在发射点根据此模式验证遥测帧。

整个遥测流水线作为连续后台线程在实时运行时中运行, 独立于任何特定的帮助循环。

5.4 结构化帮助生成

帮助生成子系统将教学请求及其组装的上下文转换为经过验证的、可执行的教学响应。它经过六个阶段进行处理。

5.4.1 提示构建

adapters/prompting.py 中的 build_help_prompt_result 函数组装发送给语言模型的完整提示。它包括: 当前仿真器状态 (vars)、去噪后的最近增量、带可观测性状态和视觉确认要求的候选程序步骤、确定性步骤提示及其缺失条件列表、叠加目标允许列表、BM25 检索的知识片段 (最多五个, 每个截断为 220 字符), 以及当可用时的当前视觉事实摘要。提示受硬字符上限 (9000) 约束, 预估令牌限制为 2400。开关位置、旋钮旋转和按钮点击约定的交互策略规则以中文或英文包含。

5.4.2 模型适配器

模型适配器层通过统一接口支持三种后端。`OpenAICompatModel` (在 `adapters/openai_compat_model.py` 中) 将聊天完成请求发送到 OpenAI 兼容端点, 将 `/v1/chat/completions` 追加到配置的基础 URL。它要求 API 密钥, 支持可配置的超时和最大令牌限制, 并可切换到多模态模式。`OllamaModel` (在 `adapters/ollama_model.py` 中) 是用于本地 Ollama 服务器的零依赖适配器。`ModelStub` (在 `adapters/model_stub.py` 中) 为测试返回固定的确定性响应, 使得完整的帮助生成流水线无需外部模型服务即可运行。所有适配器通过统一的调用接口返回原始文本响应。

5.4.3 带最小修复的 JSON 提取

模型响应不保证仅包含有效的 JSON。`adapters/json_extract.py` 模块实现了一个 `parse_first_json` 函数, 具有刻意限制为四种转换的修复集: (1) 移除平衡的 Markdown 代码块 (三重反引号 JSON 块), (2) 移除导言 `<think>...</think>` 块, (3) 丢弃第一个 `{` 或 `[` 之前的非 JSON 前缀文本, (4) 丢弃闭合括号之后的后续文本。此集合之外的任何转换均被拒绝。提取使用基于栈的解析器, 跟踪字符串引号和转义序列以正确定位平衡的 JSON 分隔符。每次提取返回一个 `JsonExtractionResult`, 记录是否应用了修复以及具体的修复原因枚举。

5.4.4 模式验证

提取的 JSON 对象使用 `jsonschema` 库的 `Draft202012Validator` 根据运行时生成的 `HelpResponse` 模式 (第 5.2 节) 进行验证。验证错误以从验证器错误路径派生的 JSON Path 位置报告。该模式强制执行四类约束: (1) 必需的顶层键, (2) 步骤标识符和错误类别代码的枚举成员资格, (3) 叠加目标唯一性和允许列表成员资格, (4) 每个提及的叠加目标必须存在证据项。

5.4.5 响应映射与证据溯源

`adapters/response_mapping.py` 中的 `map_help_response_to_tutor_response` 函数将经过验证的 `HelpResponse` 转换为运行时 `TutorResponse`。它通过 `OverlayPlanner` (查询 `ui_map.yaml`) 将叠加目标解析为 DCS 内部元素标识符。映射函数还验证响应中引用的每个叠加目标至少有一个证据引用, 其前缀 (`VARS.`、`GATES.`、`VISION_FACTS.`、`RAG_SNIPPETS.` 或 `DELTA_KEYS.`) 与帮助循环上下文中实际存在的键匹配。没有溯源证据的目标被拒绝, 拒绝被记录在响应元数据中。解释和诊断字段原样传递。`TutorResponse` 状态在完全成功时设置为 `"ok"`, 在发生映射失败时设置为 `"partial"` 或 `"fallback"`。

5.4.6 确定性降级

当没有模型可用、模型输出未通过 JSON 提取或模式验证、或响应映射产生空或无效结果时,系统降级到确定性步骤推理。`adapters/step_inference.py` 中的 `StepInferenceResult` 类检查活跃步骤,评估未满足的门控规则,识别缺失条件,通过硬编码查找表将条件引用映射到可能的 UI 目标,并生成限制在当前活跃步骤的文本提示。默认情况下,确定性降级不触发叠加高亮,除非本地规则能够基于当前遥测状态证明一个唯一、有效的目标。降级结果连同降级原因记录在帮助循环审计元数据中。

5.4.7 操作执行安全

`adapters/action_executor.py` 中的 `OverlayActionExecutor` 在通过 UDP 向 DCS 分发操作之前对所有操作强制执行三项安全约束。第一,仅类型为 "overlay" 的操作可执行——无控件注入、无按键模拟、无点击模拟。第二,每个叠加目标均根据从程序包的 `ui_targets` 字段导出的 UI 目标允许列表进行检查;不在允许列表中的目标被拒绝并记录。第三,同一时间最多高亮一个目标 (`max_targets=1`)。当请求新的高亮时,先前的活跃高亮被自动清除以防止视觉混乱。`pulse` 意图在分发清除命令之前使用阻塞睡眠 (`ttl_s`),这会阻塞调用线程但保证脉冲的完整传递。可配置的确认接收器 (`DcsOverlayAckReceiver`) 可以通过监听来自 Lua 端叠加脚本的 UDP 确认消息来可选地验证传递。

5.5 VLM 视觉事实提取

VLM 视觉事实提取运行时被实现为可选的、可独立运行的子系统,通过结构化观察与教学运行时通信。

5.5.1 捕获触发与帧选择

当活跃步骤为视觉优先(S08、S15 或 S18)且帮助请求到达时,通过 `adapters/vision_capture_tr` 中的 `build_capture_request_payload` 向 DCS 发送 UDP 捕获请求。Lua 端 `SimTutor.lua` 脚本将三个主要座舱显示器(左 DDI、AMPCD、右 DDI)渲染为单个复合 PNG 图像。Python 端 `BufferedVisionSession` (在 `adapters/vision_sync.py` 中)维护最近视觉观察的滑动缓冲区并执行帧选择:默认情况下,它检索预触发帧(可配置同步窗口 250 ms 内紧接触发事件之前的最近帧)和触发帧本身。如果窗口内预触发帧不可用,会话降级为仅触发帧模式。帧过时和同步缺失原因记录在帧负载元数据中。

5.5.2 多模态负载构建

选定的候选帧由 `adapters/openai_compat_multimodal.py` 中的 `build_multimodal_image_con` 转换为多模态聊天完成负载。可配置根目录下的本地帧文件被读取并以 `data: URL` 形式进行 base64 编码, 并检测 MIME 类型。远程 URL 和内联数据 URL 被拒绝。可配置的最大文件大小防范意外的大图像。该函数生成一组 `image_url` 内容块, 每个块标记有帧的角色 ("`pre_trigger`" 或 "`trigger`"), 这些块与文本提示一起插入到 OpenAI 兼容请求的 `messages` 数组中。

5.5.3 13-Fact 提示

视觉事实提取的提示由 `adapters/vision_fact_prompting.py` 中的 `build_vision_fact_prompt` 构建。它枚举所有 13 个已配置的事实, 描述三区域复合面板布局 (上: 左 DDI; 中: AM-PCD; 下: 右 DDI), 并为每个事实提供详细的决策边界指令: 例如, `tac_page_visible` 要求实际的 TAC 页面内容, 而不仅仅是 TAC 菜单标签; `fcsmc_final_go_result_visible` 要求所有四个通道 (MC1、MC2、FCSA、FCSB) 的最终 GO 结果; `ins_ok_text_visible` 要求在 INS 校准块附近清晰可读的 OK 文本。提示通过 `lang` 参数以中文和英文两种语言可用。

5.5.4 模型响应清洗

原始模型输出由 `adapters/vision_fact_extractor.py` 中的 `_sanitize_model_response` 解析为 JSON 并进行清洗。清洗函数剥离未知的顶层键, 拒绝不是映射的事实数组条目, 拒绝缺失必需字段 (`fact_id`、`state`、`evidence_note`) 的条目, 并拒绝 `fact_id` 不属于配置中定义的有效事实 ID 集合的事实条目。仅接受三种事实状态: "`seen`"、"`not_seen`" 和 "`uncertain`"。使用 `_vision_fact_response_schema` 从允许的事实 ID 动态生成 JSON Schema, 清洗后的输出通过 `Draft202012Validator` 根据该模式进行验证。

5.5.5 事实合并与后端兼容性

清洗后的事实通过 `merge_vision_fact_observation` (第5.2节) 合并到运行时视觉事实快照中, 该函数在更新快照之前应用粘性保留和基于 TTL 的过期。`adapters/openai_compat_m` 中的 VLM 后端兼容性层处理特定于提供者的错误条件, 包括检测表明多模态或 JSON Schema 不支持后端的 400 响应, 以及区分真实错误与 DashScope 为多模态响应发送的 `null` 负载。当 VLM 不可用或多模态请求失败时, 帮助循环仅使用遥测和知识继续, 在视觉降级元数据中记录原因。

5.5.6 计划扩展

当前 VLM 运行时从复合面板布局（左 DDI、AMPCD、右 DDI）提取事实。VR 头显捕获路径已计划但尚未实现；视觉端口抽象支持替代帧来源而无需更改提取或合并逻辑。

5.6 回放与日志基础设施

5.6.1 JSONL 事件存储

`core/event_store.py` 中的 `JsonlEventStore` 类是运行时事件的唯一持久化机制。它实现了一个仅追加写入器，并在每次写入后立即 `flush`，确保崩溃安全的日志记录。该存储支持上下文管理器用法 (`__enter__` / `__exit__`)，并提供一个静态 `load` 方法，将整个 JSONL 文件读入内存作为字典列表。事件序列化接受 `Event` 数据类实例和普通字典，当提供前者时委托给 `Event.to_dict()`。

5.6.2 回放与验证

`simtutor/runner.py` 中的回放模块提供两个入口点。`run_simulation` 使用重放预录制观察序列的 `MockEnvAdapter` 驱动完整仿真，与 `ProcedureEngine` 实例协调，并将生成的事件日志写入带时间戳的 JSONL 文件。`replay_log` 通过根据程序包重放来验证现有事件日志：它重建步骤状态机，验证每个事件的步骤状态转换是否合法（例如，步骤不能在激活之前完成），并返回布尔成功标志和诊断消息。回放验证包括对遥测追踪中单调序列号和时间戳的检查。

`simtutor/replay_eval.py` 中的回放评估基础设施将回放扩展到支持套件驱动的评估：YAML 套件文件指定程序包路径、一组测试用例、模型配置和可选的视觉帧目录，从而在遥测层面和视觉副文件场景中实现系统性的回归回放。

5.6.3 交互度量

`core/interaction_metrics.py` 中的 `compute_interaction_metrics` 函数从事件日志中派生行为度量。它计算：每步骤停滞时间（总计和最大，从 `step_activated` 到 `step_completed` 间隔派生）、帮助请求计数、LLM 触发计数（带模型元数据的教学响应）、UI 点击计数和失败计数，以及高亮/清除请求和确认计数。输出是一个带有 `to_dict` 序列化方法的 `InteractionMetrics` 数据类。

5.6.4 当前局限

日志和回放基础设施已通过合成回归场景（模拟环境、预录制观察序列和离线 BIOS 捕获）进行了演练。来自真人的人在环运行的带同步视觉帧的完整多模态会话的端到端回放尚未验证。

5.7 CLI 与运行时入口点

5.7.1 CLI 命令

`simtutor` 包通过 `simtutor/__main__.py` 提供命令行界面。实现了以下命令：

run. 使用带有预录制场景文件的 `MockEnvAdapter` 执行仿真，并将事件日志写入带时间戳的 JSONL 文件。

replay. 根据程序包验证现有事件日志，检查步骤排序和状态机一致性。

score. 使用评分引擎对事件日志进行评分，生成遗漏计数、状态违反计数和总错误分数。

record-vlm. 在一组视觉观察上运行 VLM 事实提取并记录预测以进行基准测试。

replay-bios. 通过遥测流水线重放原始 DCS-BIOS 捕获 (`dcs_bios_raw.jsonl`)，并可选择调用帮助生成循环，生成新的带时间戳事件日志。

validate. 根据模式注册表中的命名模式（如 `dcs_bios_frame`、`telemetry_frame`、`vision_fact_observation`）验证 JSONL 文件。

所有命令接受 `-model-provider`、`-model-name`、`-model-base-url` 和 `-model-timeout-s` 参数，允许在命令行覆盖模型配置。`-lang` 标志在中文 (zh) 和英文 (en) 提示与输出语言之间切换。

5.7.2 实时运行时编排

`live_dcs.py` 模块是主要的实时运行时入口点。它编排以下连续循环：

1. `DcsBiosRawReceiver` 或 `DcsBiosReceiver` 从 DCS 摄入 UDP 帧。
2. 每个原始帧通过 `enrich_bios_observation` 进行增强以生成规范化的状态变量。

3. 当接收到帮助触发器时(通过 `WindowsGlobalHelpTrigger` 的热键或 UDP 消息), 帮助循环开始:

- 通过 `infer_step_id` 计算确定性步骤提示, 根据当前遥测评估程序包门控。
- 如果活跃步骤需要视觉确认, 发送视觉捕获触发器并调用 VLM 事实提取器。
- 构建 BM25 溯源查询并检索知识片段。
- 组装完整提示并发送给模型适配器。
- 模型响应被解析、验证并映射为 `TutorResponse`。
- 叠加操作通过 `OverlayActionExecutor` 执行, 并进行允许列表和基数强制。
- 完整帮助循环(请求、响应、操作、视觉事实、降级原因(如有))被记录为 `Event` 记录。

4. 循环持续直至终止。

实时运行时通过共享代码路径同时支持实时 DCS 操作和预录制 BIOS 捕获的回放, 由 `-replay-bios` 标志控制。所有线程(BIOS 接收器、叠加确认接收器、帮助循环处理)均通过 Python 标准库线程原语进行管理, 线程间通信基于队列。

5.7.3 DCS Lua 脚本

三类 Lua 脚本在 DCS 进程内执行:

状态导出。 `Export.lua` 加载 DCS-BIOS 和 SimTutor 集成模块, 建立状态导出链。

叠加渲染。 `VRHilite.lua` 在端口 7778 上绑定 UDP 套接字并监听纯文本叠加命令 (`HIGHLIGHT <pnt>`、`CLEAR`、`PULSE <pnt> <ttl_s>`)。高亮通过 DCS 的 `a_cockpit_highlight` / `a_cockpit_remove_highlight` API 渲染, 该 API 通过 `net.dostring_in` 访问。`SimTutorHighlight.lua` 为 SimTutor 特定的高亮上下文提供替代渲染路径。

SimTutor 集成。 `SimTutor.lua` 加载包含捕获和导出逻辑的 `SimTutor Function.lua`, 并安装导出链。`SimTutorDcsBiosHub.lua` 将 SimTutor 特定的状态查询桥接到 DCS-BIOS 数据模型。

5.7.4 模型提供者配置

模型访问通过具有统一命名约定的环境变量进行配置 (第3.2节)。实时运行时在启动时验证所有必需的配置, 发出非敏感的摘要 (提供者、模型名称、超时、语言、基础 URL), 并在任何必需变量缺失时以明确的错误消息拒绝会话。API 密钥从不包含在日志输出或异常消息中, 由 `core/security.py` 中的 `redact_sensitive_text` 函数强制执行。

第六章 评估

本章呈现在视觉事实提取子系统及其支撑运行时基础设施开发过程中收集的经验证据。本章分为两个明确区分的部分。A 部分（第6.1节）报告由当前代码仓库中存在的基准测试数据、数据集统计和训练工件支撑的技术验证结果。B 部分（第6.2节）描述构成本论文原始研究愿景的计划中人因评估，但尚未实施；此处包含该部分是为了记录评估设计，以便未来工作可据此进行衡量。

6.1 当前技术结果

技术评估针对一个核心问题：经过 LoRA 微调的视觉语言模型（VLM）能否可靠地从 F/A-18C 座舱截图中提取结构化视觉事实，并且所得到的适配器是否大幅优于未微调的基础模型？该问题通过在模型训练期间从未见过的数据（经核实零重叠的留出集）上进行一系列基准测试对比来评估。下文报告的度量由第4.6节描述的自动化基准测试框架计算得出，并直接取自代码仓库中存储的基准测试工件。

6.1.1 数据集与训练摘要

视觉事实提取任务经历了两代事实本体的演进。第一代（v1）定义了 8 个视觉事实，用于建立初始的训练和评估流水线。第二代（v2）将本体扩展到 13 个视觉事实，使其与 `packs/fa18c_startup/vision_facts.yaml` 中定义的运行时视觉契约对齐。这 13 个事实涵盖面板级页面可见性（如 `tac_page_visible`、`supt_page_visible`、`fcs_page_visible`）、面板内细粒度状态指示器（`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`）以及小文本识别目标（`ins_grnd_align`、`ins_ok_text_visible`）。

表6.1总结了代码仓库中存在的六个标注数据集，每个均具有经人工审查的真实标注标签。

v2 训练方案将 Run-003（220 个经审查任务）与 Run-005（122 个经审查任务，专门为再平衡代表性不足的事实状态而采集）相结合，并应用 Run-005 两次（以下记为

Table 6.1: 标注视觉事实数据集摘要。双语导出从相同的经审查任务生成独立的英文和中文样本。留出集仅英文。

数据集	Run	事实数	任务数	双语	角色
vision_sft	Run-001	8	180	是	v1 训练
vision_sft_holdout_run002	Run-002	8	50	否	v1 留出
vision_sft_holdout_run002_newfacts	Run-002	13	50	否	v2 留出
vision_sft_run003	Run-003	13	220	是	v2 训练源
vision_sft_run005_composition_rebalance	Run-005	13	122	是	v2 再平衡
vision_sft_holdout_run004_random	Run-004	13	100	否	v2 留出

Run-005 $\times$ 2) 作为适度的过采样策略。Run-003 (220 $\times$ 2 = 440 行) 和 Run-005 $\times$ 2 (122 $\times$ 4 = 488 行) 的双语导出 (中文 + 英文) 产生组合训练集共 **928 行**。v2 留出集——Run-002 newfacts (50 样本) 和 Run-004 random (100 样本) ——仅英文，并已核实与训练数据零完全重叠。

6.1.2 Qwen3.5 8-Fact V1 基线

最早的完整基准测试线使用在 Run-001 数据集 (180 个任务) 上训练并在 Run-002 留出集 (50 样本) 上评估的 8-fact LoRA 适配器。该线早于 13-fact 本体，主要作为历史参考点；此处将其纳入以建立性能轨迹，但可能更适合放置在附录中。

Table 6.2: 8-fact v1 基准测试：Qwen3.5-9B 基础模型 vs. LoRA-v1 在 Run-002 留出集上 (50 样本，英文)。

度量	基础模型	LoRA-v1	Δ
JSON 有效率	1.0	1.0	—
模式有效率	1.0	1.0	—
事实准确率	0.7600	0.9150	+0.1550
宏 F_1	0.4241	0.5847	+0.1605
Seen F_1	0.4714	0.8380	+0.3666
样本完全匹配	0.06	0.36	+0.30
关键假阳性	13	15	+2

表6.2显示事实级度量的显著改进：事实准确率从 0.7600 升至 0.9150，seen F_1 从 0.4714 几乎翻倍至 0.8380。然而，关键假阳性计数从 13 增加到 15，表明 8-fact v1 适配器没有抑制对高风险事实（其假阳性断言可能误导教学系统跳过必要步骤的事实）的幻觉。LoRA 适配器的样本完全匹配率为 0.36，表明在单个截图中完全正确提取所有八个事实仍然具有挑战性。

6.1.3 Qwen3.5 13-Fact V2 结果

本工作的主要技术结果是在 13-fact v2 本体下使用 Run-003 + Run-005×2 方案训练的 Qwen3.5-9B LoRA 适配器的性能。该适配器训练了 4 个轮数，学习率为 2×10^{-4} ，LoRA 秩 $r = 16$ ， $\alpha = 16$ ，dropout = 0.0，有效批次大小为 4，最大序列长度为 4096。训练在 6419 秒内收敛，最终训练损失为 0.2156。

表6.3报告了两个留出评估集上的结果：Run-002 newfacts 留出集（50 样本）和 Run-004 random 留出集（100 样本）。两个留出集均仅英文，且与训练数据零完全重叠。

Table 6.3: 13-fact v2 基准测试：Qwen3.5-9B 基础模型 vs. LoRA（Run-003 + Run-005×2）在两个留出集上。

度量	Run-002 newfacts (50)			Run-004 random (100)		
	基础模型	LoRA	Δ	基础模型	LoRA	Δ
JSON 有效	1.0	1.0	—	0.96	1.0	+0.04
模式有效	1.0	1.0	—	0.96	1.0	+0.04
事实准确率	0.8677	0.9908	+0.1231	0.8038	0.9931	+0.1892
宏 F_1	0.4513	0.6515	+0.2002	0.4393	0.6100	+0.1707
Seen F_1	0.5022	0.9648	+0.4626	0.5659	0.9159	+0.3500
完全匹配	0.10	0.88	+0.78	0.03	0.92	+0.89
关键 FP	11	4	-7	70	8	-62

Run-002 newfacts 留出集。LoRA 适配器实现事实准确率 0.9908，seen F_1 0.9648，样本完全匹配率 0.88。这意味着在 50 个样本中的 44 个中，所有 13 个事实被正确分类。相比之下，基础模型实现事实准确率 0.8677，完全匹配率仅为 0.10。关键假阳性计数从 11（基础模型）降至 4（LoRA），减少了 7。LoRA 适配器中剩余的三个错误源为：tac_page_visible 的两个假阴性（适配器在 TAC 页面存在时遗漏它），fcsmc_final_go_result_visible 的一个假阳性，ins_grnd_alignment_text_visible 的一个假阳性，以及 ins_ok_text_visible 的两个假阳性。

Run-004 random 留出集。模式一致，但基础模型在这个更大、更多样化的留出集上退化更加严重。基础模型产生 4 个无效 JSON/模式响应（有效率为 0.96），70 个关键假阳性（几乎全部集中在 fcsmc_intermediate_result_visible 上，达 60 个），样本完全匹配率仅为 0.03。LoRA 适配器恢复完美的 JSON 和模式有效性（1.0），事实准确率升至 0.9931，并实现样本完全匹配率 0.92（100 个样本中 92 个完全正确）。关键假阳性计数从 70 降至 8，全部在 fcsmc_final_go_result_visible 上。

跨两个留出集，LoRA 适配器展示了三个关键特性。第一，它恢复了输出格式的可靠性：基础模型在 Run-004 留出集上偶尔产生格式错误的 JSON 或模式无效的响

应，而 LoRA 适配器则不会。第二，它大幅提高了逐事实召回率，体现为 seen F_1 从基础模型的 0.50–0.57 范围升至 LoRA 的 0.92–0.96。第三，它将关键假阳性减少了 64% (Run-002) 和 89% (Run-004)，尽管完成类事实 (fcsmc_final_go_result_visible、ins_ok_text_visible) 上仍存在残余假阳性集。

与 8-fact v1 的比较。从 8-fact v1 本体迁移到 13-fact v2 本体后，LoRA 适配器在 Run-002 系列留出集上的事实准确率从 0.9150 升至 0.9908，样本完全匹配率从 0.36 升至 0.88。关键的是，v2 适配器减少了关键假阳性（在 Run-002 系列上从 15 降至 4），而不是像 v1 适配器相对于其基础模型那样增加它们。这表明扩展的事实本体、Run-003 + Run-005×2 数据方案以及组合再平衡策略的组合解决了 v1 线中存在的假阳性脆弱性。

6.1.4 Gemma-4 13-Fact V2 对比

为评估训练方案是否能泛化到单个骨干架构之外，相同的训练数据方案 (Run-003 + Run-005×2, 928 行, 双语, 13-fact 本体) 被应用于第二个 VLM 骨干: google/gemma-4-31B。训练超参数在可能的情况下进行了匹配: 4 个轮数, 学习率 2×10^{-4} , LoRA $r = 16$, $\alpha = 16$, dropout = 0.0, 有效批次大小 4, 最大序列长度 4096。差异包括使用 all-linear LoRA 目标模块 (对比 Qwen 的 vision+language 附加)、4 位量化 (load_in_4bit=true)、GPU 内存利用率 0.95, 以及 gemma-4 对话模板。训练在 8050 秒内收敛, 最终训练损失为 0.0474。注意, 训练损失值不可在骨干间直接比较, 因为分词器行为、模板结构和参数化各不相同。

Table 6.4: 13-fact v2 基准测试: Gemma-4-31B 基础模型 vs. LoRA (Run-003 + Run-005×2) 在两个留出集上。

度量	Run-002 newfacts (50)			Run-004 random (100)		
	基础模型	LoRA	Δ	基础模型	LoRA	Δ
JSON 有效	1.0	1.0	—	0.99	1.0	+0.01
模式有效	1.0	1.0	—	0.99	1.0	+0.01
事实准确率	0.8169	0.9492	+0.1323	0.8146	0.9715	+0.1569
宏 F_1	0.4432	0.5857	+0.1425	0.4400	0.5630	+0.1229
Seen F_1	0.5128	0.8123	+0.2995	0.6332	0.7959	+0.1627
完全匹配	0.04	0.44	+0.40	0.12	0.74	+0.62
关键 FP	16	0	−16	47	13	−34

表6.4证实 Run-003 + Run-005×2 数据方案同样为 Gemma 骨干带来有意义的改进。在两个留出集上, 事实准确率从基础模型的 0.81–0.82 范围升至 LoRA 适配器的 0.95–0.97。最具特色的结果在 Run-002 newfacts 留出集上, Gemma LoRA 适配器实现

了**零关键假阳性**（从 Gemma 基础模型的 16 降至 0）。这与 Qwen LoRA 适配器在同一留出集上保留 4 个关键假阳性形成对比。

然而，Gemma 的保守行为在召回率和完全匹配性能上付出了代价。在 Run-002 上，Gemma LoRA 适配器的样本完全匹配率为 0.44，而 Qwen LoRA 为 0.88。在 Run-004 上，差距为 0.74 (Gemma) vs. 0.92 (Qwen)。Seen F_1 遵循相似模式：在 Run-002 上为 0.81 (Gemma) vs. 0.96 (Qwen)，在 Run-004 上为 0.80 (Gemma) vs. 0.92 (Qwen)。Gemma 基础模型在 Run-004 上是更强的起点 (seen F_1 为 0.6332 vs. Qwen 基础模型的 0.5659)，但 Qwen LoRA 适配器的改进幅度更大，产生了更高的绝对性能天花板。

与骨干对比报告一致的实践解释是，Qwen3.5-9B 适配器因其更高的总体准确率、更强的 seen F_1 和更高的样本完全匹配率，仍然是下游系统集成的更优选择。Gemma 在 Run-002 上的零关键 FP 结果值得注意，表明即使在匹配的训练数据下，骨干层面的错误风格差异（保守 vs. 自信）也是可观察到的。

6.1.5 错误分析

为了解剩余错误发生的位置以及哪些模式区分基础模型与 LoRA 适配器，本节提供最强配置（Qwen LoRA 在 13-fact v2 本体上）的逐事实分解。

按难度分类的事实类别

13 个视觉事实可分组为三个反映不同提取难度层次的类别。

第一组：粗粒度面板存在性（6 个事实）。该组中的事实指示特定座舱面板或显示页面当前是否可见：`tac_page_visible`、`supt_page_visible`、`fcs_page_visible`、`bit_root_page_visible`、`fcsmc_page_visible` 和 `hsi_page_visible`。这些是依赖识别大型、视觉独特的面板布局的结构性识别任务。

Qwen LoRA 适配器在两个留出集——Run-002 newfacts 和 Run-004 random——上对所有六个事实实现了完美分类，唯一的例外是 Run-002 上的 `tac_page_visible`（50 个样本中有两个假阴性；TAC 页面在 50 个样本的 23 个中可见，因此这些代表遗漏检测而非幻觉）。相比之下，基础模型在若干这些事实上失败：它在 Run-002 上完全漏掉了所有五次 `supt_page_visible` 的出现 (seen $F_1 = 0.0$)，在 Run-002 上对 `bit_root_page_visible` 幻觉出五个假阳性，并在 Run-004 上漏掉了 `fcs_page_visible` 94 次出现中的 18 次 (seen recall = 0.81)。

第二组：细粒度状态指示器（5 个事实）。该组中的事实捕获微妙的面板内状态：`fcs_page_x_marks_visible`（FCS 页面上的 X 标记）、`fcsmc_intermediate_result_visible`、`fcsmc_in_test_visible`、`fcsmc_final_go_result_visible`（FCS-MC 测试序列的三个渐进状态）以及 `hsi_map_layer_visible`（HSI 上地图叠加层是否激活）。

Qwen LoRA 适配器在两个留出集上对 `fcs_page_x_marks_visible`、`fcsmc_intermediate_result` 和 `hsi_map_layer_visible` 实现了完美分类。在 Run-004 上 `fcsmc_in_test_visible` 出现一个假阴性(17 个 seen 样本, 正确识别 16 个)。最持久的错误源是 `fcsmc_final_go_result_visible`。适配器在 Run-002 上产生 1 个假阳性, 在 Run-004 上产生 8 个假阳性 (对比 60 个 seen 出现)。该事实要求区分 FCS-MC 面板内的特定数字读数, 而一致的假阳性模式表明视觉上相似的中间状态偶尔被误分类为最终 GO 结果。

基础模型在该组上的行为有质的不同。在 Run-004 上, 基础模型仅在 `fcsmc_intermediate_result` 上就产生了 60 个关键假阳性 (对比仅 7 个真正的 seen 出现), 表明在区分此状态上几乎完全失败。基础模型在 `fcs_page_x_marks_visible` (两个留出集上 seen $F_1 = 0.0$) 和 `fcsmc_in_test_visible` (seen recall ≈ 0.33 – 0.53) 上也表现出较差的召回率。

第三组: 小文本识别 (2 个事实)。事实 `ins_grnd_alignment_text_visible` 和 `ins_ok_text_visible` 要求模型识别 INS 面板上的小型文本指示器。这些是本体中最细粒度的事实, 对 9B 参数模型构成近乎 OCR 级别的挑战。

Qwen LoRA 适配器在 `ins_grnd_alignment_text_visible` 上表现强劲: 在 Run-004 上完美分类 (69 seen, 31 not seen), 在 Run-002 上一个假阳性 (42 seen, 7 not seen)。在 `ins_ok_text_visible` 上, 适配器在 Run-002 上产生 2 个假阳性 (对比 4 个 seen 出现; 这些是 OK 文本尚不可见但适配器断言其存在的样本)。在 Run-004 上, `ins_ok_text_visible` 从未出现 (100 中的 0), 适配器正确产生零假阳性, 实现完美准确率。

基础模型对这两个事实实际上是盲目的: 在两个留出集上 `ins_grnd_alignment_text_visible` 的 seen $F_1 = 0.0$, `ins_ok_text_visible` 的 seen $F_1 = 0.0$ (尽管基础模型在 Run-004 上也从未看到它, 因此 F_1 度量根据构造报告为 0.0)。

错误分类

跨两个留出集聚合 Qwen LoRA 适配器的观察错误, 可分为三种模式:

1. **完成事实假阳性(主要)。**残余错误的最大份额来自 `fcsmc_final_go_result_visible` 和 `ins_ok_text_visible`, 其中适配器偶尔断言一个尚不存在的完成/最终化状态。这些在基准测试中被归类为关键假阳性, 因为它们携带直接的下游风险: 如果教学系统认为某步骤已完成而实际上并未完成, 它可能过早推进程序。
2. **孤立的假阴性(次要)。**`tac_page_visible` 上的两个假阴性(Run-002)和 `fcsmc_in_test_visible` 上的一个假阴性 (Run-004) 代表对实际存在状态的遗漏检测。从教学安全角度来说这些不太严重 (遗漏检测触发冗余提示而非跳过步骤), 但表明残余的召回差距。

3. **小文本幻觉(次要)**。`ins_grnd_alignment_text_visible` 上的一个假阳性 (Run-002) 代表适配器错误地检测到了校准状态文本。考虑到该指示器的小视觉足迹, 此错误与预期难度特征一致。

混淆模式摘要

逐事实混淆矩阵 (在每个基准测试目录中作为图表可用) 揭示了基础模型错误中的系统性模式: 基础模型容易对训练分布中出现频率较低的事实产生单向幻觉。例如, `fcsmc_intermediate_result_visible` 在 Run-004 留出集的 100 个样本中仅出现 7 次, 但基础模型在另外 60 个不存在的样本中断言其为 `seen`。LoRA 适配器几乎完全消除了此类错误, 表明组合再平衡和过采样策略有效抵消了基础模型过度预测频繁共现事实状态的倾向。

6.1.6 运行时基础设施就绪度

除 VLM 基准测试外, 代码仓库包含功能性回放评估基础设施的证据。`replay_eval/fa18c_start` 处的回放评估套件定义了五个测试用例 (`batteryon_2min`、`Batteryon_enginGenoff_2min`、`fcs_reset_fcs_bit_2min`、`ins_2min`、`noop_2min`), 具有 DCS-BIOS 原始捕获 (`dcs_bios_raw.jsonl`) 和逐帧副文件 (`frames.jsonl`)。此基础设施支持在没有实时 DCS 实例的情况下回放录制的 DCS 会话, 用于离线测试遥测流水线、知识检索和程序执行逻辑。

运行时数据采集流水线通过 `core/event_store.py` 模块记录结构化事件, 并将其索引到 `logs/test_index/index.json` 下。目前, 该流水线捕获遥测快照、程序步骤转换和 VLM 推理请求。它尚未实现人因研究所需的参与者/会话模式、测验关联或 NASA-TLX 集成; 这些作为计划升级在第 6.2.3 节中讨论。

6.2 计划中的运行时数据采集与人因评估

本论文的原始研究愿景, 如研究计划所述, 包括在 DCS 程序性学习情境中对基于证据的教学系统进行受控人因评估。该评估尚未实施。以下小节描述了研究计划中制定的计划评估设计, 以及将当前运行时基础设施过渡到数据采集就绪状态所需的升级评估。本节中的所有陈述代表未来工作, 为透明说明研究的预期方向而纳入。

6.2.1 原始评估愿景

研究计划设想了一个三种条件的受试者间比较:

1. **视频 + 笔记基线**。学习者在冷启动程序前及过程中研习预录制的视频演示和书面检查单，无任何集成教学系统。
2. **无状态基础的纯文本 LLM**。语言模型通过文本提供逐步指导，但无法获取实时仿真器状态、检索到的手册摘录或视觉事实提取。
3. **基于状态证据的 RAG + LLM 导师**。第三、四和五章中描述的完整系统：基于遥测证据、检索增强，具有结构化视觉事实提取和叠加执行功能。

原始目标平台是 Meta Quest 3 配合 DCS-VR，通过步骤卡片或叠加标注提供头显内指导。当前系统运行于桌面/DCS（非 VR）配置，因此在此评估可进行之前需完成 VR 部署。目标样本量约为每种条件 $n = 5-10$ 名参与者，来自具有有限 F/A-18C 冷启动经验的初级到中级群体。

6.2.2 计划评估度量

研究计划规定了具有以下计划度量的多维评估框架：

- **即时表现**：程序完成率、程序性错误率、总任务时间以及死胡同计数（参与者卡住并需要外部干预的次数）。
- **工作负荷**：训练会话结束后立即进行的 NASA 任务负荷指数（NASA-TLX）。
- **学习效果**：测量冷启动程序陈述性知识的前测和后测测验分数。
- **保持**：训练会话结束 2-4 周后进行延迟后测，以评估知识保持。
- **迁移**：在变体程序（如修改后的冷启动序列）上的表现，以评估技能是否泛化到训练场景之外。

所有这些度量仍处于计划阶段；尚未采集任何参与者级别数据。

6.2.3 所需运行时数据采集升级

为支持计划中的人因评估，当前运行时数据采集基础设施需要几项具体升级：

1. **参与者与会话模式**。事件存储必须扩展结构化模式，包含参与者人口统计信息（匿名 ID、先前经验水平、条件分配）、会话元数据（日期、时长、DCS 版本）以及试次级标注。

2. **NASA-TLX 集成**。用于管理和记录 NASA-TLX 响应的会话后工具必须集成到运行时中，可以是应用内表单或带会话级别可追溯性的链接外部问卷。
3. **测验关联**。前测和后测测验响应必须链接到参与者和会话标识符，以实现受试者内学习增益分析。
4. **匿名化流水线**。所有可识别参与者的数据必须在存储前通过匿名化步骤，符合人因数据的标准研究伦理要求。
5. **VR 部署**。运行时必须从当前桌面/DCS 配置移植到 Quest 3 / DCS-VR 平台，包括研究计划中描述的头显内叠加渲染和交互处理。

撰写时这些升级无一已实现。

6.2.4 计划实验设计

计划实验遵循标准的前测 / 训练 / 后测 / 保持设计：

1. **招募与筛选**。参与者从具有有限 F/A-18C 经验的人群中招募。筛选问卷确定基线 DCS 熟悉度，并使用分层随机化将参与者分配到各条件。
2. **前测**。书面测验在任何训练暴露之前评估冷启动程序的陈述性知识。
3. **熟悉化**。一个简短的 DCS 座舱熟悉化阶段确保所有参与者能够定位基本控件和面板，减少因平台不熟悉带来的方差。
4. **训练试次**。参与者在分配的条件下执行 F/A-18C 冷启动程序。系统记录所有遥测数据、程序状态转换、帮助请求、VLM 推理调用以及（对于基于证据条件）叠加执行事件。
5. **后测与 NASA-TLX**。训练试次完成后立即进行，参与者完成 NASA-TLX 工具和与前测结构相同的后测测验。
6. **保持测试**。2-4 周间隔后，参与者返回进行延迟后测，并在可行的情况下进行第二次冷启动试次以评估程序性保持。
7. **迁移任务（可选）**。进行变体程序以评估学习技能的通用性。

此设计已在研究计划层面规定，但尚未试点或执行。

6.2.5 已知有效性威胁

在数据采集之前的设计阶段可识别若干有效性威胁：

1. **桌面与 VR 平台差距。**当前系统运行于桌面 DCS,而非研究计划中设想的 Quest 3 上的 DCS-VR。在任一平台获得的结果可能在没有额外验证的情况下无法泛化到另一平台。
2. **基准测试表现不等同于学习效果。**第6.1节报告的 VLM 基准测试结果证明 LoRA 适配器能准确提取视觉事实。然而,准确的视觉事实提取是改善人类学习效果的必要而非充分条件。需要人因研究来确定事实提取性能是否转化为可测量的程序性学习增益。
3. **小样本量。**计划的每种条件 $n = 5-10$ 样本量按受控人因研究标准偏小,限制了检测条件间差异的统计功效,特别是对于完成时间和错误率等嘈杂度量。
4. **初级群体泛化性。**计划的参与者群体由 DCS 经验有限的个体组成。结果可能无法泛化到经验丰富的飞行员或其他仿真平台。
5. **单一程序。**评估围绕单一程序(F/A-18C 冷启动)设计。教学方法是否能迁移到 DCS 内的其他程序性任务或其他领域仍是一个开放问题。
6. **实验者效应。**在小样本、单点研究中,实验者在熟悉化和干预过程中的行为可能引入难以与条件效应分离的系统性偏差。

这些威胁并不使计划评估设计失效,但它们界定了从其最终结果中可以得出的结论范围。在研究推进时,通过谨慎的协议设计、分析计划预注册和对局限性的明确承认来解决这些威胁至关重要。

总结而言,本章呈现了:(a) 技术验证结果,证实经过 LoRA 微调的 VLM 适配器在 13-fact 视觉本体下跨两个独立留出集大幅且一致地优于基础模型,其中 Qwen3.5-9B 骨干取得了最强的总体结果;(b) 训练方案泛化到第二个骨干架构(Gemma-4-31B)的证据,尽管具有不同的精确率-召回率权衡;(c) 逐事实错误分析,将完成事实假阳性确定为主要残余失效模式;(d) 计划中人因评估的结构化描述,包括其设计、所需基础设施升级和已知有效性威胁,所有这些仍为未来工作。

第七章 讨论

本章对第**六**章中呈现的结果进行解读,并将其置于论文的更大发展轨迹中。第**7.1**节解释了项目为何从原始 VR 优先的研究计划演变为本文报告的遥测和 VLM 重度实现。第**7.2**节解读基准测试结果能够证明和不能证明的内容。第**7.3**节从视觉事实本体的两代演进中提炼设计经验。第**7.4**节枚举当前系统和实验证据的已知局限。第**7.5**节基于这些局限概述未来工作方向。

7.1 从研究计划到实现系统的演进

本文描述的系统与原始研究计划中设想的系统有实质性的不同。本节将这些差异解读为一种重新框架化——它为实现最终论文目标产生了更坚实的技术基线——而非执行失败。

7.1.1 为何发生转变

原始计划设想了一个 VR 优先的教学系统: Meta Quest 3 部署、头显内步骤卡片、眼动和手部交互,以及作为主要证据来源的受试者间人因评估。而当前实现是一个桌面/DCS 运行时,具备遥测数据基础、结构化帮助生成以及可选的 VLM 视觉事实提取流水线。

这一转变出于三个相互关联的原因。首先,构建一个可靠的基于遥测证据的运行——包含 DCS-BIOS 摄入、增量去噪、变量解析、知识检索和确定性降级——被证明是一项不可跳过的实质性工程前提。在遥测流水线和程序引擎稳定之前尝试在 Quest 3 上部署将产生一个不适合受控实验的不可靠原型。其次,在开发这些前提基础设施的过程中,我们发现若干关键程序步骤(S08、S15、S18)需要对未通过 DCS-BIOS 遥测导出的显示页面状态进行视觉确认。这一缺口促使添加了 VLM 视觉事实提取组件,该组件随后扩展为自成一体的适配和基准测试流水线——这一工作线在原始计划中完全不存在。第三,桌面/DCS 配置为系统性基准测试提供了更受控的环境。它使得在经核实零重叠的留出数据上进行全自动基础模型与 LoRA 对比、可复现的训练配置以及

逐事实混淆分析成为可能——这些条件在具有人类参与者的 VR 环境中将难以实现。

7.1.2 这是重新框架化，而非失败

原始论文目标——在沉浸式仿真环境中进行基于证据的程序性教学，并对学习效果进行人因评估——仍然有效。改变的是操作顺序。当前系统提供了具体的技术基础：一个可运行的运行时，带有自动化测试、经过基准测试的 VLM 适配流水线，以及可支持未来人因研究的回放和日志基础设施。这一基础在研究计划提出时尚不存在，代表了朝向论文目标的非平凡进展。

特别是 VLM 适配工作，本身已成为一项实质性贡献。完整的流水线——从截图捕获到 AI 辅助预标注、人工审查、双语 SFT 导出、LoRA 微调，再到在独立留出集上进行基础模型与 LoRA 对比基准测试——构成了一个可将通用 VLM 适配到领域特定结构化提取任务的可复现 workflow，且仅需适量的人工审查数据。这一贡献虽未取代原始论文的 VR 教学系统愿景，但扩展了论文超出原计划的范围。

用实际术语来说，项目当前状态可总结如下：基于证据的教学系统所需的数据采集、程序表示和感知子系统已被构建、通过自动化基准测试进行了验证，并封装在可回放架构中。剩下的是完成 VR 部署并进行人因评估，以确定这些子系统在协同运行时是否能在程序性学习中产生可测量的改进。

7.2 技术结果解读

第6.1节报告的基准测试结果为 VLM 视觉事实提取流水线的性能提供了证据。本节从这些结果中提炼解释性结论，仔细区分基准测试所证明和未证明的内容。

7.2.1 基准测试结果证明了什么

小数据 LoRA 适配可大幅改善领域特定 VLM 提取。在 13-fact v2 本体下，基于 928 行 (Run-003 + Run-005×2) 训练的 Qwen3.5-9B LoRA 适配器在 Run-002 newfacts 留出集上实现事实准确率 0.9908，在 Run-004 random 留出集上实现 0.9931，相比之下基础模型分别为 0.8677 和 0.8038。Seen F_1 从基础模型的 0.50–0.57 升至 LoRA 的 0.92–0.96。这些无论以何种标准衡量都是大效应量，并且它们是在经核实零训练重叠的留出集上观察到的，排除了记忆作为解释的可能性。

训练数据方案可跨模型骨干迁移。相同的训练方案 (Run-003 + Run-005×2，双语，13-fact 本体) 应用于 Gemma-4-31B 骨干产生了类似模式的大幅改进：事实准确率在 Run-002 上从 0.82 升至 0.95，在 Run-004 上从 0.81 升至 0.97。这种跨骨干迁移提供了证据，表明改进是由数据和本体设计驱动的，而非单一模型架构的特异性属性。

JSON 和模式有效性在训练后接近完美。在 Run-004 random 留出集上，基础模型在 100 个样本中产生 4 个模式无效或 JSON 无效的响应；LoRA 适配器产生零个。这不是一个平凡的属性：在必须解析模型输出以提取叠加目标和步骤推荐的运行时系统中，格式可靠性是硬性要求。微调过程可靠地教会了模型遵循预期的输出模式。

错误特征从无差别幻觉转变为针对完成类事实的定向假阳性。基础模型的主要失败模式是单向幻觉：它对许多不存在的事实断言 `seen`，特别是在稀有状态上，如 `fcsmc_intermediate_result_visible`（在 Run-004 上仅 7 个真实出现中产生 60 个假阳性）。LoRA 适配器几乎完全消除了这类错误，将其残余错误集中在特定事实子集上：`fcsmc_final_go_result_visible`（Run-004 上 8 个假阳性），以及在较小程度上 `ins_ok_text_visible`（Run-002 上 2 个假阳性）。这种从弥漫性幻觉到集中、可解释的错误模式的转变是一种定性改进，聚合准确率度量未能完全捕捉。

基准测试协议本身构成一项贡献。使用经核实零重叠的留出集、逐事实混淆分析、关键假阳性跟踪和自动化图表生成，提供了一个可在未来本体迭代、不同骨干模型和其他程序中复用的可复现评估框架。

7.2.2 基准测试结果未能证明什么

它们未能证明教学系统改善了学习。基准测试测量从座舱截图中提取视觉事实的准确率。准确的事实提取是基于证据的教学系统正常运作的必要条件，但并非改善人类学习效果的充分条件。学习者可能接收到完全准确的视觉事实但仍然无法学会程序，也可能从一个事实提取不完美的系统中有效学习。从感知准确率到学习效果的因果链尚未接受检验。

它们未能证明视觉事实提取能带来更好的教学效果。基准测试在孤立环境中评估 VLM 组件，而非端到端的教学系统。视觉事实的可用性是否相对于仅遥测基线改善了导师帮助响应的质量、及时性或可接受性，是一个需要系统级评估的开放问题。

它们测量的是感知子任务，而非教学有效性。报告的度量——事实准确率、`seen` F_1 、样本完全匹配、关键假阳性——是感知度量。它们回答的是“VLM 是否正确地看到了座舱？”而非“教学系统是否帮助了学习者？”。将两者混为一谈将是一个范畴错误。

7.2.3 `ins_go` 到 `ins_ok_text` 分解的设计教训

8-fact v1 本体包含一个单一事实 `ins_go`，要求 VLM 识别 INS 校准是否已达到可见的 GO 状态。该事实被证明是 v1 适配器中假阳性的主要来源：50 个 Run-002 样本中有 13 个被错误预测为 `seen`。问题不在于 VLM 未能从训练数据中学习，而在于目标本身的定义不够完善。`ins_go` 并非与“FCS 页面在左 DDI 上可见”相同意义上的视觉事实；它是一个程序性完成判断，需要整合特定文本的存在（“OK”）、其他文本的不

存在（校准倒计时）以及程序上下文（系统处于校准的哪个阶段）。要求单帧 VLM 做出此判断将感知与推理混为一谈。

13-fact v2 本体将此复合目标分解为更底层的、视觉上可观察的事实：`ins_grnd_alignment_text_visible` 和 `ins_ok_text_visible` 各自描述 AMPCD 上的一段特定文本。程序性解释——这些事实的组合是否表明校准已完成——被推迟到下游程序引擎，该引擎可访问遥测、程序阶段和时序信息。这一分解并非表面性变化；它是本体演进中最重要的单一设计决策，基准测试结果证实了其有效性：`ins_grnd_alignment_text_visible` 在 Run-002 上实现 seen F_1 0.99，`ins_ok_text_visible` 在 Run-002 上仅产生 2 个假阳性，在 Run-004 上为零。

7.3 本体设计经验

从 8-fact v1 到 13-fact v2 的两代演进提供了可为程序性训练系统的未来视觉本体构建提供参考的具体设计经验。

7.3.1 抽象层次纪律

核心经验是：基于 VLM 的视觉事实提取器应被要求报告可观察的视觉证据，而非程序性结论。8-fact v1 本体在单一事实集中混合了这两个抽象层次：如 `fcs_page_visible` 和 `bit_root_page_visible` 等事实描述了视觉上可定位的显示页面状态，而如 `ins_go` 和 `fcs_bit_result_visible` 等事实则编码了更高层的程序性判断。混合抽象本体产生了可预见的后果：直接的页面可见性事实实现了强劲性能，而复合程序性事实占了关键假阳性的绝大部分。

13-fact v2 本体强制执行一项设计纪律：每个事实都是一段局部可验证的视觉证据。这一纪律有三个实践后果。首先，它使逐事实标注任务对人工审查者更加清晰：判断 AMPCD 上“OK”文本是否可见是一个定义明确的视觉判断；判断“INS 校准是否完成”则不是。其次，它产生更清晰的训练信号，因为从图像内容到事实标签的映射更直接，更少依赖隐含的程序上下文。第三，它局部化错误：当事实被误分类时，错误来源可以在该事实描述的图像区域中被检查，而无需对模型关于程序阶段的隐含理解进行推理。

7.3.2 复合目标的分解

`ins_go` $\rightarrow$ `{ins_ok_text_visible, ins_grnd_alignment_text_visible, hsi_map_layer_visible}` 的分解并非这一原则的唯一示例。v1 事实 `fcs_bit_result_visible` 同样也是要求 VLM 识别最终测试结果而非表征它的视觉指示器的复合目标。在 v2 中，它被分解为 `fcsmc_intermediate_1`

`fcsmc_in_test_visible` 和 `fcsmc_final_go_result_visible`, 每个捕获 FCS-MC 测试序列中一个视觉上可区分的阶段。下游程序引擎然后可以结合遥测状态解释这些事实的序列, 以确定 FCS BIT 是否完成。

通用设计原则可表述如下: 如果人工标注者无法在不了解程序步骤的情况下仅通过查看单张图像来确定事实标签, 那么该事实可能过于高层, 应当被分解。这一原则是可操作的且可迁移到其他程序。

7.3.3 残余失效模式及其影响

尽管本体经过了重新设计, 完成类事实仍然是最具挑战性的类别。在 Run-004 random 留出集上, Qwen LoRA 适配器的所有 8 个残余关键假阳性全部在 `fcsmc_final_go_result_visible` 上。该事实要求模型识别特定的数字读数 (最终 GO 结果), 并将其与同一屏幕区域中出现的视觉上相似的中间数字读数区分开来。

对此残余困难有两种合理的解释。一种认为这是数据覆盖问题: 最终 GO 结果可见的训练样本数量较少, 中间读数与最终读数之间的视觉区别可能未被充分表示。另一种认为这是基本的分辨率限制: 在用于训练和推理的图像分辨率下, 中间数值与最终 GO 值之间的差异可能确实低于模型的判别阈值。区分这两种解释需要一个同时独立变化图像分辨率和训练集组成的受控实验, 这超出了当前工作的范围。

7.3.4 对未来本体设计的启示

为 F/A-18C 冷启动设计两代视觉事实本体的经验为相关程序性领域中的本体构建提出了三条指南:

1. **以任务分析为起点**, 识别哪些程序状态需要视觉确认, 哪些可通过遥测或基于规则的推理覆盖。本体应仅包含真正需要视觉证据的状态的事实。
2. **在本体设计过程中执行单帧可验证性测试**: 每个事实应能在没有程序上下文的情况下从单张座舱图像中评估。未能通过此测试的事实应被分解或推迟到下游推理。
3. **在过程早期采集组合再平衡数据**, 特别是揭示视觉相似但程序性不同的状态之间边界的困难负样本。Run-005 组合再平衡是专门为处理代表性不足的事实状态而添加的, 将其纳入训练方案对于减少幻觉至关重要。

7.4 局限性

以下局限性界定了可从当前工作中得出的结论范围。它们被明确陈述，以使贡献能在其适当范围内被评估，并使未来工作能系统性地解决它们。

7.4.1 实验设置的局限性

单一程序。所有实验、基准测试和数据集构建工作均集中于单一程序：F/A-18C 冷启动。没有证据表明 13-fact 本体、训练方案或 LoRA 适配方法能泛化到其他程序（如 DCS 中的滑行、起飞、着陆或应急程序，或其他仿真器中的程序性任务）。第7.3节阐述的本体设计原则是合理的，但尚未在冷启动领域之外得到检验。

单一复合面板布局。视觉事实提取器在固定的三显示器复合面板（左 DDI、AM-PCD、右 DDI）上训练和评估。在显示器数量、排列或类型上不同的座舱配置（如具有两个 MFD 的 F-16C，或具有不同仪表布局的 A-10C）将需要新的布局描述下使用新数据重新训练。当前模型尚未在此类配置上进行测试。

小数据集规模。最大的训练配置使用 928 行（Run-003 + Run-005×2，双语）。这与典型的 VLM 微调数据集相比较小，后者通常使用数万或数十万示例。TODO:CITE 与相关 VLM 微调工作中报告的数据集规模的比较（如 LLaVA 指令微调、领域特定 VQA 微调）。虽然结果证明 928 行可以产生大幅改进，但它们并未确立更多数据可达到的上限。反之，结果也未确立最低数据需求；可能用更少的示例就能达到可比的性能，这对标注数据稀缺的领域具有实际意义。

留出集来自相同飞机和座舱世代。留出集（Run-002 和 Run-004）是经核实与训练数据零重叠的独立会话，但它们来自相同的飞机类型、相同的座舱配置和相同的渲染引擎（DCS World）。因此，基准测试测量的是领域内泛化（相同座舱的新会话），而非跨领域泛化（新座舱类型或新仿真器）。

7.4.2 系统的局限性

无实时 VR 部署。系统作为桌面/DCS 运行时运行。它尚未在 Meta Quest 3 或任何其他 VR 头显上部署，VR 叠加渲染、头显内交互和延迟特性尚未测试。从桌面到 VR 的过渡涉及非平凡的工程挑战（渲染流水线集成、输入处理、舒适度和延迟要求），可能需要架构变更。

无人因评估。这是当前工作最显著的局限。基准测试证明 VLM 适配器在留出数据上准确提取视觉事实，但未提供关于完整教学系统——带或不带视觉事实提取——是否能改善任何人类相关结果的证据：学习、保持、迁移、工作负荷或程序性错误率。需要人因研究来确立系统的教学价值，而当前工作不包括此类研究。

基准测试测量的是事实提取，而非教学质量。即使在技术评估内部，报告的度量也是在孤立的单帧事实提取上计算的感知度量。它们不测量导师帮助响应的质量、有用性或及时性，不测量叠加目标的正确性，也不测量多轮帮助序列的连贯性。尚未进行从仿真器观察到教学输出的完整帮助循环的端到端评估。

7.4.3 VLM 适配结果的局限性

完成类事实上存在残余关键假阳性。如第7.3节所讨论的，Qwen LoRA 适配器在 `fcsmc_final_go_result_visible` 上保留有关键假阳性（Run-002 上 1 个，Run-004 上 8 个）。在运行时部署中，每个此类假阳性都带有教学系统错误地认为 FCS-MC 测试已完成并过早推进程序的风险。缓解策略——如粘性事实 TTL 机制和多次确认观察的要求——已存在但尚末端到端评估。

有限的模型多样性。评估了两个骨干模型（Qwen3.5-9B 和 Gemma-4-31B），均使用 Unsloth + PEFT + TRL 栈进行 LoRA 微调。结果不能泛化到其他模型架构（如 LLaVA 风格模型、InternVL）、其他微调方法（如全量微调、不同秩配置的 QLoRA）或其他训练框架。

未对训练组件进行消融研究。训练方案组合了若干设计选择——双语 SFT、Run-005×2 过采样、组合再平衡、LoRA 秩和 alpha 设置——而未隔离每个组件的贡献。因此，不清楚哪些组件是必要的，哪些是偶然的。系统性消融研究将澄清设计空间，但尚未进行。

7.5 未来工作

上述列举的局限性定义了一个具体的研究议程。本节概述未来工作的主要方向，从最直接的技术扩展到较长期的论文目标依次排列。

7.5.1 VR 运行时集成

通往原始论文愿景最直接的路径是将当前桌面运行时与 Meta Quest 3 上的 DCS-VR 平台进行集成。这涉及将叠加渲染流水线从桌面 DCS Lua 钩子移植到 VR 渲染上下文，适配帮助触发机制（从桌面热键到 VR 控制器或基于眼动的交互），以及验证遥测流水线和 VLM 推理在 VR 渲染负载下是否在可接受的延迟范围内运行。第三章描述的模块化架构旨在支持这一过渡：核心教学逻辑、程序引擎和 VLM 流水线是仿真器平台无关的，仅输入/输出适配器需要修改。

7.5.2 人因评估

第6.2节描述的计划受试者间评估仍是论文的核心实证目标。开展此研究需要完成第6.2.3节枚举的基础设施升级——参与者/会话模式、NASA-TLX 集成、测验关联和匿名化——并招募足够的参与者样本。鉴于计划的小样本量（每种条件 $n = 5-10$ ），研究的设计和报告应关注效应量和置信区间而非零假设显著性检验，分析计划应预注册以增强发现的可信度。

TODO:VERIFY ——考虑到已转向桌面 DCS，三条件设计（视频 + 笔记 vs. 无状态基础纯文本 LLM vs. 基于状态证据的导师）是否仍然可行，或者两条件比较（基于状态证据的导师 vs. 无状态基础基线）对首次研究更为实际。

7.5.3 将视觉事实本体扩展到其他程序

当前的 13-fact 本体特定于 F/A-18C 冷启动。将方法扩展到其他程序——DCS 内（滑行、起飞、着陆、空中加油、应急程序）或其他仿真器——将检验第7.3节提出的本体设计原则的通用性。每个新程序将需要一项识别视觉优先步骤的任务分析、一个在单帧可验证性约束下设计的新事实本体、新训练数据的采集和标注，以及独立的留出评估。训练数据方案（双语 SFT、组合再平衡、适度过采样）是否能迁移到程序性不同的领域是一个开放的实证问题。

7.5.4 多帧时序推理

当前的视觉事实提取在单个复合面板图像上操作。若干感兴趣的座舱状态涉及无法从单帧中消除歧义の時序动态：INS 校准页面上的倒计时值、FCS-MC 测试显示器上的动画序列，以及瞬态警告指示器。将 VLM 输入扩展到短视频序列（如在 1-2 秒间隔下 3-5 个连续帧）可使模型直接捕获这些时序线索。此扩展将需要对数据捕获流水线（记录帧序列而非孤立截图）、训练格式（视频或多图像输入）和基准测试协议（时序事实定义）进行更改。当前小规模 VLM 能否有效利用时序信息进行座舱状态识别尚不确定。**TODO:VERIFY** ——在当前 9B 参数规模和 LoRA 训练方案下多帧 VLM 输入的可行性。

7.5.5 从现场纠正进行在线适配

当前的 VLM 适配流水线是一个离线过程：数据被捕获、预标注、审查，并用于在批次循环中训练 LoRA 适配器。在部署的教学系统中，学习者或教员可能实时纠正系统的视觉事实预测（如“OK 文本实际上尚不可见”）。收集这些现场纠正并将其用于在线或增量模型适配——无需完整的重标注和重训练循环——可使系统在单次训练会话

或跨多个学习者中逐步改善其提取准确率。此方向需要应对标注可靠性（学习者的纠正本身可能错误）、灾难性遗忘（在线更新不应降低先前正确事实的性能）和评估（在线适配必须根据保持不变的固定留出集进行基准测试）方面的挑战。**TODO:VERIFY**——当前 Unsloth + PEFT + TRL 栈是否支持增量微调而无需完整重训练。

7.5.6 系统级端到端评估

除本论文报告的组件级 VLM 基准测试外，还需要对完整帮助循环进行系统级评估。这将在回放或实时条件下测量：从帮助触发到叠加渲染的端到端延迟；视觉优先步骤上叠加目标的正确性；确定性降级率（模型输出验证失败时）；以及由领域专家审查回放日志判断的帮助响应的感知有用性。此类评估将弥合组件级基准测试（本文报告）与人因评估（计划中）之间的差距，提供关于系统组件在集成时是否正常运作的证据。

7.5.7 未来方向总结

表7.1总结了主要未来方向及其当前状态。

Table 7.1: 未来工作方向总结。

方向	当前状态	关键挑战
VR 运行时集成	桌面运行时已运行；VR 适配器未实现	渲染流水线、延迟、输入处理
人因评估	设计已规定；基础设施升级待完成	招募、统计功效、平台选择
本体向其他程序扩展	13-fact v2 仅对冷启动验证	任务分析、标注工作量、领域通用性
多帧时序推理	单帧流水线已运行	VLM 容量、训练数据量、基准测试设计
从纠正进行在线适配	未实现	标注可靠性、灾难性遗忘、评估
系统级端到端评估	未进行	定义有意义的系统级度量

本论文呈现的工作为上述每个方向提供了技术基础。架构、数据流水线、训练基础设施和基准测试协议均设计为可扩展的，从两代本体演进和跨骨干对比中汲取的经验教训为项目的下一阶段提供了基于证据的指导。

第八章 结论

本论文旨在设计、实现并从技术上验证一个基于遥测数据基础的教学运行时系统，用于高保真飞行仿真器中的程序性学习。研究的原始愿景是构建一个以 VR 为先导的基于状态证据的教学系统并进行人因评估，但实际交付的贡献属于技术基线层面：一个可运行的运行时环境、一个附带基准测试证据的微调 VLM 适配器、一条可复现的数据流水线，以及一份记录在案的下一阶段评估计划。本章总结已完成的工作，重申贡献，并概述未来工作方向。

8.1 已完成工作总结

本论文产生了五项具体贡献，每项均有已验证声明和代码仓库工件的支撑。

第一，程序包驱动、基于遥测数据基础的教学运行时。 SimTutor 系统实现了端口-适配器架构，其中仿真器无关的核心逻辑（程序状态机、门控规则引擎、评分、知识检索）与仿真器相关适配器（DCS-BIOS 遥测接收器、遥测增强与增量去噪流水线、叠加操作执行器、视觉捕获触发器）相分离。运行时编排完整的帮助循环：它从规范化遥测变量、增量摘要、候选程序步骤、确定性步骤提示、叠加目标允许列表、检索到的知识片段以及可选的视觉事实观察中组装结构化上下文；将该上下文传递给 LLM 以生成结构化帮助响应；依据模式、允许列表和证据溯源约束验证响应；在座舱中执行经过验证的叠加操作；并将每个阶段记录为带有版本和时间戳的事件，以便离线回放和分析。当没有模型可用或模型输出验证失败时，系统优雅降级至确定性的基于规则的降级方案。所有程序定义、门控规则、遥测映射、错误分类法、叠加目标映射和视觉事实本体均以声明式 YAML 配置（程序包）的形式表达，使系统可在无需修改核心逻辑的情况下扩展到新的程序和仿真器。

第二，结构化视觉事实本体及完整的 VLM 适配流水线。 13-fact v2 本体将座舱显示页面状态分解为跨三个显示区域（Left DDI、Right DDI、AMPCD）的离散、可审计命题，具备粘性事实持久化、生存时间语义以及通过 `all_of` 和 `any_of` 条件实现的步骤绑定机制。该本体从 8-fact v1 基线演进而来，后者混合了抽象层次，并在留出评估中对完成类事实产生了较高的假阳性率。适配流水线是完整且可复现的：DCS 中

的截图捕获、由大型 VLM 进行预标注、人工审查、双语（英文 + 中文）SFT 导出、通过 Unsloth + PEFT + TRL 进行 LoRA 微调，以及自动化基础模型与 LoRA 对比基准测试。此流水线中的每个工件均存储在代码仓库中。

第三，小数据 LoRA 适配能显著提升座舱 VLM 事实提取的基准测试证据。在 13-fact v2 本体上，Qwen3.5-9B LoRA 适配器（928 条双语训练数据，Run-003 + Run-005×2）在两个独立留出集上分别实现了 0.9908 和 0.9931 的事实准确率，相比之下基础模型准确率为 0.8677 和 0.8038。样本完全匹配率从 0.10 升至 0.88、从 0.03 升至 0.92。关键假阳性计数分别减少了 64% 和 89%。这些结果是在经核实与训练集零完全重叠的留出数据上获得的。

第四，骨干对比证明训练数据方案可迁移。相同的训练方案应用于 Gemma-4-31B 后，事实准确率分别达到 0.9492 和 0.9715（基础模型：0.8169 和 0.8146），证实了改进是由训练数据方案而非特定骨干的偶然产物所驱动的。Gemma 适配器在一个留出集上实现了零关键假阳性，揭示了骨干层面在错误风格（保守与自信）上的差异，这对安全关键型部署决策具有重要参考价值。

第五，针对未来人因研究的记录在案的评估计划。本论文规定了一个三条件受试者间设计（视频加笔记、无状态基础纯文本 LLM、基于状态证据教学）、一个多维测量框架（完成率、错误率、任务时间、NASA-TLX、前/后测验、保持、迁移），以及所需基础设施升级和已知有效性威胁的编目。该计划仍处于设计阶段；尚未采集任何参与者数据。

本系统是什么。 SimTutor 系统，按交付状态，是一个可运行的桌面/DCS 教学运行时，包含自动化测试、附带基准测试证据的微调 VLM 适配器、用于离线分析的回放和评分基础设施，以及记录在案的向 VR 部署和人因评估扩展的路径。它证明了教学系统可以在一个可运行、可测试的实现中强制执行显式的证据溯源——每个叠加目标和步骤推荐必须可追溯到遥测变量、门控规则、检索到的文档片段或视觉事实观察。

本系统不是什么。 该系统尚未在 VR 中部署。尚未与人因受试者进行评估。尚未被证明能够改善学习效果、降低工作负荷或加速程序性技能获取。这些仍为研究计划下一阶段的开放问题。当前系统提供了使这些问题成为可能的运行时、数据采集和基准测试基础设施。

8.2 未来工作

本论文的贡献为若干未来工作方向开辟了道路，每个方向都直接建立在已完成的技术基线之上。

VR 运行时集成。 最直接的扩展是实现原计划中设想的 Meta Quest 3 VR 适配器。这包括将叠加渲染移植到头显内步骤卡片，集成眼动和手部追踪输入以触发帮助，以及验证遥测流水线和帮助循环在 DCS-VR 环境中正常工作。现有的端口-适配器架构专为容纳此扩展而设计：一个新的 VR 适配器实现现有的叠加和遥测端口，将替换当前的桌面适配器而无需修改核心教学逻辑。

人因评估。 第6.2节描述的计划评估设计应作为受控受试者间研究加以执行。这需要完成第6.2.3节确定的运行时数据采集升级（参与者/会话模式、NASA-TLX 集成、测验关联、匿名化流水线），从初级到中级人群中招募参与者，并执行完整的前测 / 培训 / 后测 / 保持协议。只有这项研究才能确定基于状态证据的教学方法是否能在程序性学习效果、工作负荷和保持方面相对于基线条件产生可测量的改进。

本体向其他程序的扩展。 13-fact v2 本体特定于 F/A-18C 冷启动任务及其三显示器复合面板布局。将本体扩展到 DCS 内的其他程序——如导航、武器使用或应急检查单——将检验视觉事实分解策略的通用性，并需要新的数据集采集和标注周期。程序包格式专为容纳此类扩展而设计：一个新程序包目录，包含其自身的 `vision_facts.yaml`、`vision_layout.yaml`、`step_registry.yaml` 和 `telemetry_map.yaml`，将定义一个新的训练场景而无需更改流水线工具。

多帧时序推理。 当前的 VLM 流水线在单帧对上操作（预触发帧和触发帧），并在每个观察窗口上进行独立预测。在多个帧之间融入时序上下文可以提高涉及瞬态或状态转换的事实准确率，例如 FCS-MC 测试序列（`fcsmc_in_test_visible` → `fcsmc_final_go_result_visible`）。可能的方法包括将帧堆叠作为 VLM 的多图像输入、在滑动窗口上对事实预测进行递归聚合，或者使用一个轻量级时序模型，消费逐帧事实向量并生成时序一致的序列。

在线适配。 当前的 LoRA 适配器在固定数据集上离线训练并作为静态模型部署。在线适配循环——系统在实时教学会话中采集新的标注帧（经导师或专家验证）并定期更新适配器——可以逐步提高边缘情况的准确率，并适应 DCS 版本或飞机变体间座舱显示配置的变化。这将需要能够与教学运行时并发运行的轻量级微调基础设施，以及对新采集标注的质量控制机制。

确定性程序引擎增强。 当前的门控规则引擎使用一个包含四个操作符（`var_gte`、`arg_in_range`、`flag_true`、`time_since`）的 v1 DSL。扩展 DSL 以添加更多操作符（如逻辑组合、序列计数器、多变量条件）并支持用户自定义门控函数，将提高程序包的表达能力，并减少对边缘情况手动步骤分类的依赖。

本论文所完成的工作确立了：一个具有结构化视觉事实提取功能的、基于遥测数据与证据约束的教学运行时在技术上是可行的，并可通过自动化基准测试进行验证。下一阶段的研究必须确认这一技术能力能否转化为沉浸式仿真环境中人类学习的实际改善。

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

第九章 附录