



TU Clausthal

硕士论文

作者：

张宇

**解释现实：基于基础模型与 Meta Quest 3 的交互式教学
解释**

第一导师： Prof. Dr. Christian Bartelt

第二导师： Dr. Sascha Marton

15. Juni 2026

软件与系统工程研究所
克劳斯塔尔工业大学

原创性声明

本人已阅读并理解克劳斯塔尔工业大学及 ISSE 公告中发布的各项指南，包括关于使用文献和其他来源的规定。本人确认已独立完成本论文。凡引用他人成果并在本论文中复现的内容，均已作出适当引用标注。

根据通用考试条例，本论文尚未提交至任何其他考试机构。

本人同意将本硕士论文陈列于研究所图书馆，供查阅使用。

克劳斯塔尔-采勒费尔德，15. Juni 2026

地点，日期

张宇

摘要

解释现实 (*Explain Reality*) 研究基础模型如何在沉浸式模拟器中提供有用的交互式解释, 同时避免成为不受约束的对话代理。本文的应用场景是在 Digital Combat Simulator World 中使用 Meta Quest 3 进行训练: 学习者执行 F/A-18C Lot 20 冷启动程序, 教学系统必须根据实际存在的飞机状态来解释下一步操作。在这一场景中, "现实" 并非物理飞机, 而是一个实时、高负载、多模态的模拟状态。解释只有可追溯到可检查证据时, 才具有实际价值。

本论文提出一个基于证据的程序化教学运行时系统, 结合程序包规则、模拟器原始遥测数据、检索到的程序知识、结构化响应验证、可回放日志, 以及用于座舱显示事实的视觉语言模型 (VLM) 层。主要机器学习贡献是一个面向结构化视觉事实提取的小数据 LoRA 适配流水线。最初的 8 事实本体论表明, 复合目标 (如程序完成状态) 容易产生高风险假阳性。修订后的 13 事实本体论改为要求 VLM 输出局部视觉证据原子, 并将程序性解释交给确定性的下游规则处理。

在两个独立的 13 事实验证集上 (经核验与训练集零精确图像重叠), 采用 Run-003 + Run-005E2 方案训练的 Qwen3.5 LoRA 适配器是最强的离线模型。在 Run-002 newfacts 上, 事实准确率从 0.8677 提升至 0.9908, 样本完全匹配率从 0.10 提升至 0.88; 在 Run-004 random 上, 事实准确率从 0.8038 提升至 0.9931, 样本完全匹配率从 0.03 提升至 0.92。关键假阳性在 Run-002 上从 11 降至 4, 在 Run-004 上从 70 降至 8。匹配的 Qwen3.6-27B 实验展示了更强的基座模型和一个本地部署候选方案, 但在当前验证集上并未超越 Qwen3.5 LoRA 模型。Gemma 在相同数据方案下有显著改进, 且在某些关键事实上更为保守, 但整体完全匹配表现仍低于 Qwen3.5。

一项包含九名参与者的形成性、非随机 Quest 3 先导实验补充了技术证据。参与者包括自述为新手、中级和专家水平的用户。其中四名参与者使用教学系统, 五名在无教学辅助条件下操作。全部四名教学条件下的参与者均达到经人工审核的最终 33 步状态, 而五名无教学辅助试验中无一达到已确认的最终 33 步状态。教学条件下未出现人工编码的遗漏错误, 但在若干试验中出现了与辅助相关的误操作和提示性错误。原始 NASA-TLX 和自定义试验后教学/用户评分仅作描述性汇报。因此, 该先导实验支持可行性、仪器适配性和错误模式声明, 但不支持关于学习收益、工作负荷降低、记

忆保持、迁移或任务速度的因果声明。

本论文论证，沉浸式训练中可靠的交互式解释最好被视为一个证据设计问题：基础模型应仅通过运行时系统能够观察、验证和回放的证据来解释当前任务状态。

Zusammenfassung

Explain Reality untersucht, wie Foundation Models in einer immersiven Simulationsumgebung interaktive Erklärungen geben können, ohne als unbegrenzte Dialogsysteme eingesetzt zu werden. Der Anwendungskontext ist ein Training mit der Meta Quest 3 in Digital Combat Simulator World, in dem Teilnehmende den Kaltstart der F/A-18C Lot 20 ausführen. Die Erklärung des Systems muss sich auf den tatsächlich beobachtbaren Simulatorzustand beziehen. “Realität” bedeutet in dieser Arbeit daher den laufenden, multimodalen und kognitiv anspruchsvollen Zustand der Simulation.

Die Arbeit stellt eine evidenzbasierte Laufzeitumgebung für prozedurales Tutoring vor. Sie kombiniert deklarative Prozedurregeln, Simulatortelemetrie, Retrieval von Prozedurwissen, strukturierte Antwortvalidierung, Replay-Logs und ein Vision-Language Model für Cockpit-Anzeigen. Der zentrale Machine-Learning-Beitrag ist eine kleine LoRA-Anpassung für strukturierte visuelle Fakten. Eine frühe 8-Fact-Ontologie zeigte, dass zusammengesetzte Zielzustände riskante False Positives erzeugen können. Die revidierte 13-Fact-Ontologie trennt deshalb lokale visuelle Evidenz von der späteren prozeduralen Interpretation.

Auf zwei unabhängigen 13-Fact-Holdouts ist die Qwen3.5-LoRA-Linie mit Run-003 + Run-005x2 die stärkste Offline-Konfiguration. Die Fact Accuracy steigt auf Run-002 newfacts von 0,8677 auf 0,9908 und auf Run-004 random von 0,8038 auf 0,9931; gleichzeitig sinken kritische False Positives von 11 auf 4 beziehungsweise von 70 auf 8. Qwen3.6-27B liefert eine starke Kandidatenlinie für das lokale Serving, übertrifft die Qwen3.5-LoRA-Linie auf den aktuellen Holdouts jedoch nicht. Gemma profitiert ebenfalls von derselben Datenrezeptur, bleibt aber beim exakten Sample-Match hinter Qwen3.5.

Eine formative, nicht randomisierte Quest-3-Pilotstudie mit neun Teilnehmenden ergänzt die technische Evaluation. Die Stichprobe enthielt selbstberichtete Novizen, intermediäre und erfahrene Teilnehmende. Vier Teilnehmende nutzten den Tutor, fünf absolvierten eine passive Bedingung ohne Tutor. Alle vier Tutor-Teilnehmenden erreichten

den manuell geprüften finalen 33-Schritt-Zustand; keine der fünf Sitzungen ohne Tutor erreichte einen bestätigten finalen 33-Schritt-Zustand. Die Pilotdaten belegen Machbarkeit, Instrumentierung und Fehlermuster, aber keine kausalen Effekte auf Lernen, Arbeitsbelastung, Retention, Transfer oder Geschwindigkeit.

致谢

感谢我的导师在本论文全过程中的指导与反馈。同时感谢先导实验参与者在 VR 环节中付出的时间、耐心与专注。

AI 工具使用声明

在本论文及相关软件项目的准备过程中，使用了 AI 辅助工具，包括 ChatGPT/Codex、Claude Code 和 GitHub Copilot。其使用范围包括：语言编辑、结构调整建议、LaTeX 一致性检查、引用缺口审计、代码仓库工件检查、代码补全支持、代码审查辅助，以及在作者主导下进行代码集成与合并审查时的支持。这些工具未用于伪造实验数据、参与者结果或文献元数据。所有声明、数值结果、引用、解读、源代码决策以及最终措辞均由作者承担责任。

Inhaltsverzeichnis

第一章 引言	1
1.1 研究动机：解释实时训练中的"现实"	1
1.1.1 本论文中"现实"的含义	2
1.2 案例研究：DCS World 中的 F/A-18C Lot 20 冷启动	2
1.3 问题陈述	3
1.4 研究问题	3
1.5 研究方法	4
1.6 贡献	5
1.7 论文结构	5
第二章 理论背景与相关工作	7
2.1 沉浸式模拟中的程序性训练	7
2.2 现有辅助方法	8
2.3 为何现有方法在此场景中不充分	9
2.4 基础模型作为有边界组件	9
2.5 视觉事实提取与 PEFT 适配	10
2.5.1 结构化输出与可靠性指标	10
2.5.2 参数高效适配	11
2.6 定位与最接近工作的缺口	11
第三章 方法：基于证据的教学运行时系统	13
3.1 设计需求	13
3.2 证据对象模型	14
3.3 程序包作为权威先验	15
3.4 权威层级	15
3.5 遥测依据	16
3.6 检索与来源策略	16
3.7 视觉事实集成	17

3.8	帮助周期	17
3.9	结构化响应与叠加层验证	19
3.10	不确定性与降级模式	19
3.11	VR 交互边界	20
3.12	日志、回放与导出	20
3.13	方法边界	21
第四章	方法：视觉事实适配与先导实验方案	22
4.1	程序运行时与遥测依据	22
4.2	知识依据与来源策略	23
4.3	视觉事实数据流水线	23
4.3.1	标注单元与决策边界	24
4.4	数据集整理	25
4.4.1	数据集概览	25
4.4.2	数据集质量检查	25
4.4.3	本体论演化：从 8 事实 v1 到 13 事实 v2	26
4.4.4	训练方案：Run-003 + Run-005(E2)	26
4.4.5	验证集独立性	27
4.5	LoRA 微调配置	28
4.5.1	骨干模型与比较策略	28
4.5.2	训练栈与超参数	28
4.5.3	双语 SFT 与组合再平衡	28
4.5.4	训练目标构建	29
4.6	基准测试协议	29
4.6.1	指标	29
4.6.2	基座 vs. LoRA 比较	30
4.6.3	基准测试类别	30
4.6.4	基准测试输出	30
4.6.5	错误审查协议	30
4.7	人体受试先导实验方法	30
4.7.1	伦理、知情同意与数据保护	31
4.7.2	参与者与条件	31
4.7.3	任务与设备	31
4.7.4	数据来源与编码	32
4.7.5	问卷与评论工具	32

4.7.6	数据质量注释	33
4.7.7	分析方法	33
4.8	本章小结	33
第五章	可复现性与研究工件溯源	35
5.1	研究工件与声明边界	35
5.2	RQ 层面的溯源	36
5.3	可复现性限制	36
第六章	结果	38
6.1	RQ1: 基于证据的教学运行时系统	39
6.1.1	运行时就绪性摘要	39
6.1.2	回放与约束结果	39
6.1.3	实时导出结果	40
6.1.4	证据路径示例	41
6.2	RQ2: 面向座舱视觉事实的 VLM 适配	41
6.2.1	数据集与训练摘要	41
6.2.2	主要 Qwen3.5 结果	41
6.2.3	主要结果的指标解读	44
6.2.4	Qwen3.6 与 Gemma 比较	44
6.2.5	模型特定解读	46
6.2.6	错误模式	46
6.3	RQ3: 形成性 Quest 3 先导实验	47
6.3.1	参与者与任务结果	47
6.3.2	程序性错误模式	49
6.3.3	工作负荷、自定义评分与评论	49
6.3.4	RQ3 小结	51
第七章	讨论	52
7.1	从提案到已实现系统的演变	52
7.2	技术证据的解读	53
7.2.1	技术证据未能证明的内容	53
7.2.2	VLM 结果的数据中心解读	54
7.2.3	对 ML 系统设计的启示	54
7.3	先导实验发现的解读	55
7.3.1	辅助与未来协作之间的边界	56

7.4	本体论设计教训	56
7.5	局限性	57
7.5.1	评估范围	57
7.5.2	系统与 VLM 范围	57
7.5.3	构念效度	58
7.5.4	先导实验范围	58
7.5.5	范围总结	59
7.6	未来工作	59
7.6.1	受控人体受试评估	59
7.6.2	本体论向其他程序的扩展	59
7.6.3	时间性与多帧视觉推理	59
7.6.4	系统级帮助周期评估	60
7.6.5	多模态协作策略	60
7.6.6	现场修正与适配	60
7.6.7	未来方向总结	60
第八章	结论	62
8.1	已完成工作总结	62
8.2	未来工作	63
参考文献		65
第九章	附录	71
9.1	完整 LoRA 超参数配置	71
9.2	8 事实 V1 基线基准测试	71
9.3	数据集事实分布	71
9.4	CLI 命令参考	73
9.5	模型提供方配置	74
9.6	回放评估套件	74
9.7	补充架构与导出图表	74
9.8	VR 先导实验——补充数据	76

Abbildungsverzeichnis

3.1	基于证据的教学运行时架构。模拟器观察、预编写的程序规则、基础模型输出以及面向用户的叠加层动作，由显式的运行时契约分隔。	13
3.2	基于证据的教学的权威边界。程序规则和遥测约束状态；审查过的视觉事实提供有边界的显示证据；检索和 LLM 输出支持解释但不覆盖门控条件或 UI 白名单。	16
3.3	实时基于证据的帮助周期。辅助始于观察快照，将其转化为证据包，请求模型给出结构化响应，验证结果，并记录显示的输出。	18
4.1	VLM 适配流水线。DCS World 复合截图经预标注、人工审查、转换为双语监督微调行、使用 LoRA 适配、在独立验证集上评估，并用于驱动本体论修订。	23
4.2	从 8 事实 v1 到 13 事实 v2 的本体论演化。诸如 <code>ins_go</code> 和宽泛的 FCS-MC 完成事实等复合目标被分解为局部可验证的视觉原子；程序引擎随后将这些观察与遥测、阶段和时序证据相结合。	27
6.1	跨研究问题的评估与数据流。回放和约束研究工件支撑 RQ1，VLM 基准测试输出支撑 RQ2，Quest 3 先导实验导出支撑 RQ3 的描述性发现。	38
6.2	主要 Qwen3.5 基准测试摘要。左侧面板报告 Run-002 和 Run-004 上的事实准确率和完全匹配率；右侧面板报告完成关键假阳性计数。	43
6.3	Qwen3.5、Qwen3.6 和 Gemma 在 Run-003 + Run-005×2 方案下的匹配骨干模型比较。面板分别报告 Run-002 和 Run-004 上的事实准确率、完全匹配率和关键假阳性计数。	45
6.4	形成性 Quest 3 先导实验方案与分析权威规则。先导实验将单次试验的参与者会话连接到运行时日志、问卷、人工步骤编码和仅描述性解读。	47
9.1	约束层与证据验证。候选教学动作在接受叠加层行动计划之前，须经过模式约束、UI 白名单、证据一致性和程序状态的检查；不安全或依据不足的动作被修复、拒绝或降级为仅文本引导。	75

9.2	原型使用的部署拓扑。模拟器、Quest 3 叠加层路径、本地运行时、回放工具和远程模型提供方被分离，以使实时试验和离线分析能够使用相同的证据和日志契约。	75
9.3	详细的实验导出流水线	76

Tabellenverzeichnis

2.1	程序性 VR 模拟中基于证据的教学循环的最接近工作定位。	12
4.1	用于视觉事实提取的数据集清单。	25
4.2	先导实验数据质量问题与最终分析权威规则。	33
6.1	RQ1 运行时就绪性证据（以研究工件覆盖形式）。	39
6.2	教学条件下试验的实时帮助周期分解。	40
6.3	所报告 VLM 结果的视觉事实数据集清单。	42
6.4	主要 13 事实结果：Qwen3.5-9B 基座 vs. LoRA 在两个验证集上。	42
6.5	主要 Qwen3.5 结果的计数解读。	42
6.6	Qwen3.5 LoRA 线的逐事实剩余错误。	43
6.7	匹配的 Run-003 + Run-005×2 方案下的补充骨干模型比较。	44
6.8	匹配的 Qwen3.5、Qwen3.6 与 Gemma 比较的解读。	45
6.9	参与者与试验概览。	48
6.10	人程序性错误计数。OM = 遗漏，CO = 误操作，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违规。	49
6.11	排除 P02 后的试验后问卷摘要。信心、教学评分和用户评分使用记录的 1–7 响应量表；原始 TLX 报告为非加权的原始工作负荷平均。	50
6.12	简短匿名参与者评论（转述或轻度浓缩以节省篇幅）。	50
7.1	未来工作方向总结。	61
9.1	三个骨干模型的完整 LoRA 微调超参数。	72
9.2	8 事实 v1 基准测试：Qwen3.5-9B 基座 vs. LoRA-v1 在 Run-002 验证集上（50 样本，英文）。	72
9.3	训练集与验证集之间的逐事实 seen 计数（13 事实 v2 本体论）。	73
9.4	回放评估案例。	74
9.5	先导实验参与者经验概况（自我报告）。	77
9.6	无教学条件下未确认为已完成的步骤。	77

9.7 逐参与者的自动编码 vs. 人工错误计数。	78
9.8 补充先导实验数据质量权威规则。	78

第一章 引言

1.1 研究动机：解释实时训练中的"现实"

本论文标题"解释现实：基于基础模型与 Meta Quest 3 的交互式教学解释"有意将两个通常分开讨论的概念放在一起。其一是交互式解释：学习者需要在操作过程中获得帮助，而不是等任务结束后再得到反馈。其二是现实：解释必须紧扣训练环境中当前存在的状态。在本工作中，这一现实是高度逼真的实时仿真，而非不受约束的自然场景。学习者佩戴 Meta Quest 3 虚拟现实设备，在 DCS World 中操作 F/A-18C Lot 20，尝试在不脱离训练流程的情况下完成冷启动程序。

程序性训练与普通问答有着本质区别。正确的下一步操作并不仅仅是手册中的一个静态事实，它取决于操作顺序、前置条件、座舱状态、之前的错误，以及学习者当前的困惑点。在座舱启动任务中，"打开航电"这样的一般性回答是不充分的，除非飞机已有电力供应、相关显示器已激活、且程序已进入适当阶段。基础模型可以生成流畅的程序性语言，但流畅本身并不会使指令变得安全、及时或可检查。一个错误解释当前状态的教学系统可能比静态检查单更糟糕——因为它表面上适应学习者，实则已与模拟器状态脱节。

因此，本研究的场景不是面向航空问题的通用聊天机器人，而是一个用于序列敏感程序性训练的头盔内教学系统。学习者在需要提示时，不应被迫摘下头盔、搜索 PDF、回放视频，或丧失空间感知。本研究的科学核心是一个机器学习系统问题：如何通过模拟器证据、预编写的程序规则以及领域适配的视觉语言模型（VLM）——该模型报告结构化的座舱视觉事实——来约束基础模型教学系统？

这一聚焦并非对标题的偏离，而是使标题具有可信度的技术条件。在一个动态、高负载、多模态的 VR 任务中，AI 助手只有在能够解释学习者的实际任务状态时才有用。因此，系统必须：对任务状态进行充分观察、将模型输出与证据绑定、拒绝或修复无根据的操作、并保存可在会话结束后回放的日志。本论文将这一设计原则称为基于证据的交互式解释。

1.1.1 本论文中"现实"的含义

标题中的"现实"一词并非指哲学意义上的实在论,也非狭隘的混合现实渲染图形学概念。它指向学习者当前正在其中操作的任务状态。在 Quest 3 环境中,这种状态是多模态的,包括:模拟器遥测数据、座舱显示页面、预编写的程序阶段、学习者近期操作、检索到的手册上下文,以及学习者可能正在跟随的可见叠加层。一个忽略上述任一层次的教学系统,可能给出局部流畅但实际操作中错误的解释。

例如,指示学习者"继续 FCS BIT 序列"只有在以下条件下才有意义:相关显示页面可见或近期已被观察到、所需的前序步骤已满足、且学习者尚未越过被描述的状态。文本模型可以组织这样的指令文字,但不能被允许虚构支撑该指令的状态。VLM 可以读取显示内容,但不应由它决定整个程序。遥测可以确认开关位置和发动机参数,但仅凭遥测本身并不能解释学习者接下来应该做什么。"解释现实"因此是一个系统级论断:解释来自多种证据来源之间的连接,而不是让基础模型临场扮演教学者。

Meta Quest 3 的核心地位在于它使这一问题变得具有交互性和具身性。在桌面环境中,学习者可以更轻松地查阅外部文档或切换窗口。而在头盔中,帮助信息会与空间注意力、手部运动、座舱扫描和任务记忆形成竞争。错误或过时的叠加层会在错误的时间将注意力吸引到错误的对象上。一个正确但缺乏证据支撑的解释仍可能鼓励过度信任,因为学习者无法看到该解释为何被给出。因此,本论文将 VR 视为一种迫使证据基础解释变得精准、简洁、可审计的使用环境,而不仅仅是装饰性的输出媒介。关于 HMD 沉浸式学习的综述与理论模型也支持这种谨慎态度:其收益取决于任务匹配、教学设计、认知负荷和评估设计,而不是沉浸感本身 [20, 28, 37]。

这一框架也解释了为何本工作强调机器学习,而不只是界面设计。系统需要一个能够读取富含文本的座舱显示的感知组件,一个能够依据证据生成帮助表述的语言组件,以及一个防止任一组件越权的运行时系统。机器学习的贡献不仅在于使用了 VLM 或 LLM,更在于模型输出被转化为程序化教学循环中有边界、可检查断言的方式。

1.2 案例研究: DCS World 中的 F/A-18C Lot 20 冷启动

本实证研究的环境是 DCS World 中的 F/A-18C Lot 20 冷启动程序 [8, 9]。本文原型使用的程序包并非一个虚构的提示脚本,它是一个从 DCS World F/A-18C 手册及本地评估材料中手动分解出的训练指南,作为教学和评分的权威先验知识。当前程序包包含 33 个有序教学步骤,按阶段分组,从初始供电、发动机启动、航电准备、飞行控制检查,到最终的滑行前配置。

此任务紧凑到可以在硕士论文中研究,但其复杂程度足以暴露出证据问题。某些

状态可通过模拟器遥测获取，如开关位置、发动机参数或指示器数值。另一些状态则显示在座舱显示屏上。左右数字显示指示器 (DDI) 和先进多用途彩色显示器 (AMPCD) 展示的页面和文本对于确认飞行控制和导航状态至关重要。因此，教学系统不能依赖单一的观察通道，它必须将遥测、显示感知、程序规则和检索到的程序知识结合起来。

视觉组件被有意地设计为窄范围。VLM 不被要求描述整个 VR 场景、推断学习者的意图或决定哪个程序步骤已完成。它仅报告一组小型结构化视觉事实——例如 FCS 页面、BIT 根页面、FCS-MC 结果、HSI 页面或 INS 校准文本是否可见。随后程序引擎将这些事实与遥测和序列状态相结合进行解释。感知与程序逻辑之间的这种分离，是本论文的主要设计经验之一。

1.3 问题陈述

研究问题可以表述如下：

基础模型教学系统如何在沉浸式模拟器内提供交互式程序性解释，同时确保每个可操作的输出都以可观察、可验证、可回放的证据为基础？

三个缺口驱动了这一问题。首先，手册、视频和检查单具有权威性，但不具备状态感知能力。它们可以告诉学习者程序包含什么，却不知道学习者是否已经完成某个步骤、跳过某个前提条件，或者到达了需要视觉确认的显示页面。其次，模拟器遥测在可用处很精确，但它本身并不构成完整的解释通道。它暴露状态，却不决定如何生成即时提示，也不解释某个步骤为何被阻塞。第三，基础模型可以生成灵活的语言并解析视觉输入，但当其输出可能引导程序性操作时，必须受到运行时约束。

本论文的贡献在于将这些部分连接起来。语言模型本身并不被当作教学系统，它只是运行时系统中的一个组件——该运行时系统负责组装证据、评估程序门控条件、检索源材料、验证结构化输出、通过白名单映射叠加层目标，并记录整个帮助周期。VLM 同样受到约束：它输出视觉事实而非高层程序决策。由此构建的系统既非通用座舱自动驾驶仪，也非通用 VR 助手，而是一个面向基于证据的程序性解释的研究原型。

1.4 研究问题

本论文围绕一个总体问题和三个子研究问题展开。

主研究问题 (Main RQ)。 基础模型如何能够在 Meta Quest 3 程序性训练环境中支持交互式解释，当其输出以模拟器状态、程序知识和结构化视觉证据为基础？

RQ1 ——基于证据的教学运行时系统。 如何将模拟器遥测、检索到的程序知识、视觉事实、模式验证、叠加层白名单以及回放日志集成到一个运行时系统中，使教学输出保持状态感知性和可审计性？

RQ2 ——VLM 适配与视觉事实可靠性。 小数据 LoRA 适配的 VLM 在多大程度上能够可靠地提取结构化座舱视觉事实？本体论设计和骨干模型选择如何影响关键假阳性？

RQ3 ——形成性 Quest 3 先导实验证据。 一项形成性、非随机的 Quest 3 先导实验在以下方面提供了哪些描述性证据：任务完成情况、程序性错误、原始工作负荷评分、自定义试验后评分、参与者评论，以及辅助与未来可信协作之间的边界？

RQ1 通过已实现的教学运行时系统、程序包、验证逻辑、回放/导出基础设施以及实时帮助周期证据来回答。RQ2 通过视觉事实本体论、数据集整理流水线、LoRA 训练方案以及 Qwen3.5、Qwen3.6 和 Gemma 的基座-对比-LoRA 验证集基准测试来回答。RQ3 通过一项包含九名参与者编码试验的已完成形成性先导实验来回答。RQ3 的证据仅为描述性的，不建立统计显著性、学习收益、工作负荷降低、记忆保持、迁移或更快完成速度的结论。

1.5 研究方法

本方法将基于证据的运行时时系统与聚焦的机器学习适配流水线相结合。

在运行时系统方面，F/A-18C 冷启动被表示为一个声明式程序包。步骤、前置条件、完成门控条件、来源优先级、视觉事实绑定和叠加层目标均保存在模型提示词之外。模拟器原始遥测数据被归一化并聚合为运行时变量。检索到的手册和训练指南片段为解释提供文本依据。当学习者请求帮助时，运行时系统在模型生成之前先组装一个结构化的证据包。随后，响应被解析、验证、对照白名单叠加层目标进行检查，必要时进行修复或拒绝，并记录以供回放。

在机器学习方面，工作聚焦于座舱视觉事实。VLM 数据流水线捕获座舱显示图像，应用预标注，支持人工审核，导出监督微调行，训练 LoRA 适配器，并在独立验证集上评估基座模型和适配后的骨干模型。关键设计选择是从早期的 8 事实本体论过渡到与运行时对齐的 13 事实本体论。修订后的本体论移除了复合的程序完成目标，将其替换为局部显示观察。这使得 VLM 的角色更加谦逊且更加有用：它为下游规则提供证据，而非成为决策者。

在先导实验方面，本研究将系统放回最初的 Quest 3 动机场景中。四名参与者使用教学系统，五名参与者在无教学辅助条件下完成试验。参与者背景按自我报告从新

手到专家不等。研究记录完成状态、人工错误编码、帮助周期、VLM 调用、叠加层动作、原始 NASA-TLX、自定义教学/用户评分和开放式评论。纳入先导实验，是为了检验系统能否在真实 VR 参与者身上运行，以及会出现何种故障模式。自定义评分是形成性的试验后条目，而非验证后的信任或可用性量表；先导实验也不作为有统计效力的人体受试有效性研究。

1.6 贡献

核心贡献是一个面向高保真程序性模拟的基于证据的基础模型教学循环。该循环将生成的解释视为受约束的系统行为：模拟器遥测、预编写的程序门控条件、检索到的源材料片段、结构化视觉事实、响应模式、叠加层白名单、确定性的修复/回退行为以及回放日志，全部位于模型与学习者之间。这是本论文的主要贡献，直接回应了 RQ1。

三个证据支柱支撑了这一贡献。

1. **视觉事实本体论与 LoRA 适配协议。**本论文为 F/A-18C 座舱显示状态建立了 13 事实本体论，并将其用于小数据 LoRA 适配流水线。该本体论将局部视觉感知与程序性解释相分离，回应了 8 事实基线所暴露的关键假阳性风险。此支柱回应 RQ2。
2. **匹配的 VLM 骨干模型比较。**本论文在 Qwen3.5、Qwen3.6 和 Gemma 三个骨干模型上评估了相同的 Run-003 + Run-005(E2) 方案。Qwen3.5 仍是主要结果线，因为它在所报告的验证集上达到了最强的适配后完全匹配表现。Qwen3.6 被作为本地部署候选方案，而 Gemma 则提供了不同的对比误差模式。
3. **有边界的人体受试证据：形成性 Quest 3 先导实验。**本论文报告了一项非随机先导实验，包含九名参与者编码试验，涵盖参与者经验概况、完成和错误模式、原始 NASA-TLX、自定义试验后教学/用户评分，以及匿名的简短评论。此支柱回应 RQ3，展示可行性、仪器适配性和辅助相关风险，而不作出因果性学习声明。

1.7 论文结构

第二章提供了基于证据的教学、VLM、LoRA 适配、结构化视觉输出、模拟器仪表化以及 AR/VR 中可解释辅助的理论背景和相关工作。

第三章描述了基于证据的运行时方法：程序包设计、遥测处理、检索、帮助周期验证、叠加层映射和回放。

第四章描述了 VLM 和先导实验方法：数据集整理、8 事实到 13 事实的本体论演化、LoRA 训练、基准测试指标、骨干模型比较，以及 Quest 3 先导实验方案。

第 五 章定义了研究工件与声明边界，使结果具有可审计性，包括 RQ 层面的溯源和对完整实验重运行的约束。

第 六 章按 RQ1、RQ2 和 RQ3 的顺序报告结果：运行时就绪性、VLM 适配基准测试，以及形成性先导实验。

第 七 章解读研究发现与局限性，然后借助未来在动态、高负载、多模态环境中可信协作的理念，定义当前证据循环仍需支撑的内容。

第 八 章总结贡献与声明边界。附录 九 包含补充表格、图表、命令参考和先导实验数据。

第二章 理论背景与相关工作

引言将本论文框架定义为一个证据设计问题：基础模型应仅通过运行时系统能够观察、验证和回放的证据来解释当前训练状态。因此，本章并不泛泛综述 VR、飞行器模拟或基础模型，而是围绕一个问题审视最接近的研究线：为什么程序性 VR 模拟需要一个基于证据的教学循环？

答案是逐层累积的。手册和检查单提供权威性，但不提供实时状态。智能教学系统提供任务模型，但通常不是围绕多模态模拟器中的基础模型生成而构建。检索增强生成（RAG）为文本提供依据，但其本身并不知道座舱是否真的处于所声称的状态。AR/VR 引导将指令保持在任务上下文中，但其大部分内容是预编写或静态的。视觉语言模型（VLM）可以读取显示图像，但其输出必须先转化为有边界的视觉事实，才能影响教学系统。本论文的贡献正位于这些缺口的交汇处。

2.1 沉浸式模拟中的程序性训练

程序性训练不同于事实性教学，因为成功取决于在状态约束下的有序操作。学习者不仅需要知道某个操作是什么，还需要知道何时允许执行、如何检查该操作是否已生效，以及当中途状态与预期不符时如何恢复。在航空和工业环境中，这些要求通常通过手册、检查单、教练和模拟器程序外化。飞行模拟具有悠久的训练传统，但模拟器的有效性取决于任务、反馈和教学设计，而不仅仅取决于逼真度 [16]。

本论文使用的冷启动任务是此类教学的一个合适压力测试。它足够紧凑，适合在硕士论文中研究，同时又对序列和状态敏感，并且依赖视觉媒介。在 DCS World 中，学习者通过 Meta Quest 3 头盔操作 F/A-18C Lot 20。该任务要求完成供电、发动机启动、显示器使用、导航校准、飞行控制检查和最终滑行前配置 [8, 9]。纸质检查单可以描述这些步骤，但交互式教学系统必须知道当前哪个步骤可执行，以及哪些证据支持这一判断。

虚拟现实会放大低质量辅助的代价。佩戴头盔的学习者更难忍受切换到 PDF、搜索桌面窗口或回放外部视频。面向装配和维护的 AR 引导展示了将指令嵌入用户任务上下文的价值 [17, 33, 39]。本论文采纳这种上下文化动机，但增加了一个更严格的系

统条件：生成的帮助信息必须依据当前的模拟器状态，而不仅仅是视觉上放置在座舱附近。关于 HMD 和沉浸式 VR 学习的研究同样提醒我们：教学设计、任务匹配、认知负荷和评估设计决定沉浸能否真正帮助学习，而不是造成干扰 [20, 28, 37]。

2.2 现有辅助方法

手册、检查单与模拟器训练。 本案例研究最权威的来源是 DCS World 模拟器、F/A-18C 手册/训练材料及其衍生的预编写程序包。这些来源定义了程序性先验知识。它们规定了哪些操作是重要的，以及应当发生哪些状态转移。其局限性在于它们不会自动观察学习者的当前状态。检查单中的某一行在抽象层面可能是正确的，但在当前时刻可能是错误的——如果某个前置条件尚未满足，或者学习者已经越过了所描述的状态。

智能教学与基于约束的教学。 智能教学系统 (ITS) 研究长期将显式任务模型、学习者状态跟踪、反馈和基于约束的诊断视为有效教学的核心 [2, 24, 31, 41]。这与本文原型直接相关：教学系统需要的不只是对话能力，还需要表示任务和学习者进展。区别在于运行环境。当前系统并非带有封闭问题接口的经典 ITS。它通过遥测、座舱显示图像、预编写门控条件和事件日志来观察高保真模拟器，同时将基础模型作为有边界的组件使用。

RAG 与有依据的语言模型辅助。 RAG 使语言生成以检索到的文档为条件，而不是只依赖参数记忆 [26]。在教育领域，大型语言模型可以生成灵活的解释和反馈，但也存在缺乏依据的自信、虚构引用以及流畅但脱离上下文的答案等风险 [21, 22]。神经生成忠实性研究同样表明，流畅的生成文本可能偏离其源证据 [30]。SayCan 等有依据动作生成工作将语言合理性与动作可行性相分离 [1]。本文原型遵循同样的设计直觉：一个响应可能流畅且有来源依据，但只有当运行时系统能够验证状态、步骤、证据引用和叠加层目标时，才应将其作为程序性指导呈现。

AR/VR 引导与模拟器遥测。 AR/VR 程序性引导解决了将帮助信息保持在任务上下文中的交互问题 [33]。模拟器遥测解决了一个不同的问题：观察状态。在本论文中，外部遥测接口只作为原始模拟器状态的输入通道；本文不把该接口本身作为实现贡献。贡献始于原始遥测数据进入教学运行时之后：系统选取相关变量，将原始控件映射到程序级谓词，区分源数据缺失与观察到的假值，将遥测与视觉事实和程序门控条件相结合，并记录结果证据以供回放。

2.3 为何现有方法在此场景中不充分

本案例研究同时需要四个特性。第一，辅助必须具有实时状态感知能力。一个仅检索正确手册段落的系统，如果模拟器状态尚未达到所需的前置条件，仍可能推荐错误操作。第二，辅助必须是多模态的。原始遥测数据覆盖了许多开关位置和指示器，但座舱显示页面和文本线索同样重要。左右数字显示指示器（DDI）和先进多用途彩色显示器（AMPCD）包含无法始终被简化为简单遥测字段的冷启动证据。

第三，辅助必须是可审计的。当自然语言回答可能指导学习者的下一步操作时，仅有一个回答是不够的。系统应保留为何该回答被接受、修复、降级或拒绝的原因。这驱动了后续章节中对事件日志和回放的重点关注。第四，辅助必须是有边界的。基础模型不应虚构步骤标识符、叠加层目标、来源引用或视觉观察。这些元素必须由程序包、来源策略、模式验证和约束检查来控制。

这四个需求解释了本论文的架构。手册和检索提供文本权威性。ITS 和基于约束的教学提供对显式任务状态的需求。遥测提供高置信度的模拟器变量。VLM 提供选定的视觉事实。运行时系统将它们绑定为一个证据包，之后才请求语言模型生成解释。

2.4 基础模型作为有边界组件

基于 Transformer 的基础模型为现代语言和多模态系统提供了表征和指令遵循的基础 [42]。在本论文中，它们被有意地视为组件，而非整个教学系统。语言模型接收一个证据包并返回一个结构化响应。VLM 接收一张图像并返回一个结构化视觉事实对象。两种输出在被允许影响面向用户的指导之前都要经过检查。

这种组件视角改变了“解释”的角色。解释不仅是有帮助的文字，更是断言与证据之间的可检查关系。如果教学系统告知学习者应继续进行飞行控制检查，运行时系统应能够识别：哪个步骤处于活跃状态、哪些前置条件已满足、哪些检索到的源材料或程序规则支持该指导，以及相关视觉或遥测证据是否存在。如果证据缺失，模型不应被允许用自信叙述填补空白。

人机交互和可解释 AI 领域的工作为这种谨慎态度提供了依据。可解释 AI 研究强调理解系统为何产生某个推荐以及如何评估这类解释的需求 [13, 18]。人机交互与自动化研究强调可理解性、适度信任、不确定性处理和可恢复性 [3, 25]。本文原型在一个狭窄的程序性场景中将理念操作化：响应模式、证据引用类型、来源策略、叠加层白名单和回放日志，正是使流畅的模型答案变得可检查的机制。

2.5 视觉事实提取与 PEFT 适配

视觉语言模型将基础模型的能力扩展到图像-文本任务。Qwen-VL、Qwen3-VL、LLaVA 和 InstructBLIP 等通用 VLM 工作展示了视觉编码器和语言解码器如何支持图像推理、视觉问答、指令遵循和富含文本的感知 [4, 5, 27, 36]。本论文只在窄范围内使用这些能力。VLM 不被要求进行自由形式的场景描述，而是返回一个基于固定视觉事实本体论的类型化 JSON 对象。

视觉事实表示有三种状态：`seen` (已见)、`not_seen` (未见) 和 `uncertain` (不确定)。一个事实如 `fcsmc_final_go_result_visible` 是一个关于可见显示线索的局部断言，而非关于整个 FCS BIT 步骤已完成的断言。这一区分至关重要。最初的 8 事实本体论包含较多复合目标，暴露出一个反复出现的失败模式：即使人工标签为 `not_seen`，模型也可能将程序完成类事实报告为 `seen`。当前的 13 事实本体论将此类目标分解为局部视觉原子，由下游程序引擎加以解释。

这一设计与屏幕和 GUI 理解相关。屏幕内容模型和 UI 数据集强调固定区域、符号化文本和布局，而非普通自然图像 [6, 45]。座舱显示器具有同样的结构化特征。一个微小的视觉线索可能是一个按钮标签、一个页面标题、BIT 结果表中的一行，或一条暂时的校准消息。因此，本体论充当了感知与控制逻辑之间的桥梁。

2.5.1 结构化输出与可靠性指标

VLM 任务是在一个小型本体论上进行结构化预测。对于每张图像，模型预测一个分类状态向量而非说明文字。JSON 格式是集成接口，而 JSON Schema 提供了拒绝格式错误或越界输出的验证契约 [34]。但学习问题仍不只是 JSON 生成：模型必须将视觉证据与事实定义对齐，区分页面标签与实际页面，区分暂时性中间状态与最终状态，并判断某一线索何时过于模糊而无法做出 `seen` 或 `not_seen` 的决策。

因此，评估使用多种指标。JSON 有效性和模式有效性衡量模型是否能参与运行时合约。事实准确率统计单个事实状态决策的正确率。宏平均 F_1 在不同事实间平衡状态类别。Seen F_1 聚焦于正向视觉检测。样本完全匹配询问整个视觉状态向量是否正确。关键假阳性统计高风险案例——模型对不应被视为可见的事实预测为 `seen`。最后一项指标至关重要，因为对完成类线索的一个假 `seen` 标签可能比一个仅仅触发额外检查的漏检更严重地污染下游程序推理。这种指标组合也符合分类评估文献中的基本警告：准确率、 F_1 和宏平均指标回答的问题并不相同，指标选择必须围绕任务风险加以说明 [32, 35]。

2.5.2 参数高效适配

对于狭窄领域任务，对大型多模态模型进行全量微调通常是不必要或不切实际的。低秩适配（LoRA）冻结基座模型权重，为选定模块学习低秩更新矩阵 [19]。若基座权重矩阵 W 被冻结，LoRA 将更新表示为：

$$W' = W + \Delta W, \quad \Delta W = BA,$$

其中 A 和 B 为低秩可训练矩阵。PEFT、TRL 和 Unsloth 等参数高效微调库和工具使此工作流在本地实验中变得可行 [14, 29, 44]。QLoRA 和 VeRA 等相关 PEFT 变体表明，该领域包含多种降低适配成本或参数数量的方法 [7, 23]。本论文不提出新的 PEFT 算法，而是将 LoRA 作为领域特定的结构化视觉事实适配的实用机制。

因此，本文声明并非“一种更好的 LoRA 方法”，而是更窄的结论：对于 VR 程序性教学系统，结构化视觉事实配合小型领域 LoRA 适配，可以形成比直接使用基座 VLM 更可靠的证据通道。这使本体论设计、标签审查、验证集独立性和关键假阳性分析成为 ML 方法的一部分。第 六 章中评估的 Qwen3.5、Qwen3.6 和 Gemma 线用于说明：模型选择是一个下游风险决策，而不只是排行榜决策。

2.6 定位与最接近工作的缺口

表 2.1 总结了最接近的研究线以及本论文所处理的剩余缺口。上文引用讨论已列举代表性来源；该表使论述保持紧凑。它并不声称前人在其自身场景中薄弱，而是说明当前场景需要一种集成式证据契约。

本论文位于 ML 适配、教学系统、模拟器仪表化和 HCI/VR 评估的交汇处。其核心贡献并非发明手册、遥测、RAG、VLM、LoRA 或 AR/VR 引导，而是有纪律地集成这些要素：在高负载 VR 程序性训练场景中，只有当遥测、程序规则、检索、视觉事实、验证和回放日志共同约束模型可以说什么、做什么时，基础模型才能提供可审计的交互式解释。上文综述的任何单一研究线，都未能为当前案例同时提供全部需求：实时模拟器状态证据、多模态座舱事实、程序级权威、有边界的基础模型生成、面向头盔的引导，以及可回放的审计日志。

Tabelle 2.1: 程序性 VR 模拟中基于证据的教学循环的最接近工作定位。

研究线	有用理念	此处仍存的缺口	本论文的回应
ITS 与基于约束的教学	显式任务模型、学习者状态推理、反馈约束	通常假设教学者控制的接口，而非具有生成式解释的实时多模态模拟器	使用程序门控条件和遥测谓词作为生成帮助的权威层。
RAG 与有依据的 LLM/动作系统	使生成语言以检索到的来源或可行动作为基础	检索到的文本和语言合理性并不确立座舱状态或叠加层有效性	将检索与遥测、视觉事实、模式验证和回放日志相结合。
VLM 屏幕/文档理解	使用多模态模型识别富含文本的视觉内容	自由形式的视觉描述对程序门控条件而言过于宽泛，且可能隐藏高风险假阳性	定义 13 事实座舱本体论，并评分完全匹配、Seen F_1 和关键假阳性。
基础模型的 PEFT	以小型可训练足迹适配大型模型	PEFT 本身并不规定任务本体论、证据语义或下游风险指标	将 LoRA 用作视觉事实证据流水线中的一种机制，而非作为一种新的适配器方法。
AR/VR 程序性引导	将指令保持在用户具身任务的上下文中	引导可能是预编写或静态的，通常不暴露生成动作的实时状态证据	将帮助置于 Quest 3 工作流中，同时将生成输出与证据和叠加层白名单绑定。
人机信任与可解释性	使推荐可理解并校准用户信任	通用指南需要在具体教学运行时中有一份可操作的契约	实现证据引用、不确定性状态、验证和回放，作为解释的审计追踪。

第三章 方法：基于证据的教学运行时系统

本章在方法层面回答 RQ1。它描述本文原型如何将基础模型辅助转化为面向 F/A-18C Lot 20 冷启动任务的基于证据的帮助周期。运行时方法由对交互式解释至关重要的契约定义：程序建模、遥测依据、检索、视觉事实集成、响应验证、叠加层执行和回放。




Abbildung 3.1: 基于证据的教学运行时架构。模拟器观察、预编写的程序规则、基础模型输出以及面向用户的叠加层动作，由显式的运行时契约分隔。

3.1 设计需求

运行时系统围绕六项需求进行设计。

1. **状态感知帮助。**教学系统必须依据当前模拟器状态进行推理，而非仅依据静态检

查单。

2. **证据分离。**遥测、视觉事实、检索文本和程序规则在生成之后必须保持可区分。
3. **有边界的模型权限。**语言模型可以组织解释文字，但不得静默定义程序状态或虚构叠加层目标。
4. **可检查的视觉感知。**VLM 应输出可检查和可评分的结构化事实，而非自由形式的座舱叙述。
5. **可回放性。**帮助决策必须可从记录的观察、证据包、模型输出、验证决策和叠加层动作中重构。
6. **先导实验就绪性。**运行时系统必须为后续分析生成参与者级研究工件，而不将形成性先导实验变成隐性的人工编码练习。

这些需求直接源于论文标题。VR 中的交互式解释只有在可追溯至其所描述的模拟现实时，才站得住脚。

3.2 证据对象模型

运行时系统将证据视为类型化对象，而非作为非结构化提示词文本。这是一个具有方法论后果的设计选择。遥测变量、失败的触发条件、检索句子、视觉事实和近期动作对教学系统都有用，但它们的含义不应相同。如果它们在生成前被压缩为一个段落，模型可以产生一个流畅但支撑不可重构的答案。如果它们作为类型化条目保留，运行时系统随后可以检查某个叠加层目标或诊断是否引用了实际存在的证据。

因此，证据对象模型为每个可用的上下文记录四个属性。第一，记录证据类型，如 `var`、`gate`、`rag`、`delta` 或 `visual`。第二，记录可在提示词、验证和日志中使用的稳定引用。第三，记录观测值或文本支撑。第四，在相关时记录可用性和质量元数据，如源数据缺失状态、帧时效或检索来源。这种结构使帮助响应具有可审计性，因为模型不能简单地引用任意理由，引用的理由必须对应当前证据包中的证据引用。

证据与解释之间的区分是有意为之的。一个视觉事实可以声明 `fcsmc_final_go_result_visible` 为 `seen`；它不应声明整个 FCS BIT 程序已完成。一个遥测变量可以声明襟翼开关处于 `AUTO` 位置；它不应决定学习者是否理解为何需要 `AUTO`。程序引擎和教学响应将证据组合为解释，但原始证据在该解释之下仍然可检查。

3.3 程序包作为权威先验

程序包是教学系统的预编写领域先验知识。它将 F/A-18C 冷启动表示为 33 个教学步骤，源自 DCS World 手册及本地训练材料。每个步骤都有稳定标识符、阶段、前置条件、完成门控条件、证据需求和 UI 目标。程序包以配置形式存储，而非嵌入提示词中。这使程序保持可审计性，并将领域知识与模型表述分离。

程序包在帮助周期中完成三项工作。第一，约束哪些步骤可被考虑为下一步。前置条件不满足的步骤不能被推荐为可用。第二，规定用于确认进展的证据。某些步骤以遥测为主导；依赖显示的步骤使用视觉事实绑定；当所需证据不可用时，其他检查会保守地降级。第三，定义叠加层目标空间。模型可以建议帮助信息，但运行时系统仅将视觉高亮映射到已知的座舱目标。

此设计避免了基于提示词的教学系统的常见失败模式。如果程序仅以自然语言表示，模型可以混合步骤、跳过前置条件或虚构目标名称。在本文原型中，提示词接收到运行时生成的证据包，但程序本身仍然是一个由系统控制的声明式对象。

3.4 权威层级

运行时系统使用权威层级来决定何种信息可以覆盖何种信息。程序包对步骤顺序、允许目标和证据需求具有权威性。遥测对直接导出的模拟器状态具有权威性。审查过的视觉事实仅对已定义的视觉命题具有权威性，且只在其有效期和质量约束内有效。检索到的文本支持解释，但不覆盖门控条件。LLM 可以生成指导文字并提出诊断，但不定义最终程序状态。

这一层级防止了几种微妙的失败。若没有它，检索到的手册片段可能建议一个与当前活跃的机场冷启动包冲突的程序变体；VLM 可能因看到相关页面而推断步骤已完成，即便所需的遥测门控条件为假；LLM 可能选择一个不在当前 UI 白名单中的合理座舱控件。层级在面向用户的输出产生之前解决这些冲突：更严格的局部契约胜过来自更宽泛或更不可靠证据来源的冲突信息。

层级也支持优雅降级。如果视觉事实缺失，运行时系统不必放弃整个帮助周期。它仍可以使用遥测、门控条件、近期动作和检索到的程序文本。生成的响应简单地限制在那些证据来源能够支持的范围内。在实践中，这意味着教学系统可以说明视觉确认不可用，可以要求学习者核实某个显示，或给出仅有文字的提示而不高亮目标。用户看到不那么雄心勃勃的帮助，但不会被赋予虚构的确定性。




Abbildung 3.2: 基于证据的教学的权威边界。程序规则和遥测约束状态；审查过的视觉事实提供有边界的显示证据；检索和 LLM 输出支持解释但不覆盖门禁条件或 UI 白名单。

3.5 遥测依据

外部遥测接口提供的原始模拟器遥测是模拟器状态的主要观察通道。运行时系统接收原始帧，归一化导出值，推导高层变量，并将缺失的源数据与假值分别跟踪。这一区分至关重要。变量可能为假是因为座舱状态未满足，也可能是因为源数据未导出或在当前帧中未被观察到。将两种情形同等处理会使教学系统过于自信。

遥测流水线还进行增量清洗和聚合。原始模拟器信号可能抖动、重复或变化过快而无法放入模型提示词。因此，运行时系统将高频状态变化转化为稳定变量和简明的近期动作摘要。这些摘要帮助教学系统解释发生了什么变化，同时避免将模型暴露给无界的日志。

遥测推导的证据示例包括：电池和发电机状态、APU 就绪状态、发动机转速阈值、油门动作、INS 模式、雷达模式、襟翼状态、停机刹车释放、IFEI BINGO 燃油设置，以及姿态来源选择。在遥测具有权威性的地方，不使用 VLM。这是一个有意的设计选择：当直接状态存在时，计算机视觉不应替代直接的模拟器状态。

3.6 检索与来源策略

检索到的程序知识支撑帮助响应中的自然语言解释部分。运行时系统根据当前程序候选项和模拟器状态构建依据查询，检索本地手册或训练片段，并将其作为源材料提供给模型。来源策略限制允许哪些文档和块，这防止模型收到任意的仓库文本或不

相关的模拟器材料。

因此，检索用于解释，而非不受控制的决策。程序包和遥测决定某个步骤是可用还是被阻塞；检索到的文本帮助系统表述操作、检查和原理。这种分工反映了本论文更广泛的边界：基础模型应解释证据，而非取代证据。

3.7 视觉事实集成

当显示内容无法从遥测可靠读取时，视觉事实进入帮助周期。运行时系统使用覆盖左 DDI、右 DDI 和 AMPCD 的固定复合面板布局。VLM 接收一帧或多帧候选图像，返回包含允许的事实标识符和状态的 JSON 对象。当前的 13 事实本体论包括页面可见性事实、FCS 页面标记、FCS-MC BIT 状态、HSI/地图图层事实，以及 INS 校准文本事实。

运行时系统将这些事实视为观察，而非程序决策。仅当程序包说明某个视觉事实相关时，它才能满足步骤绑定。某些事实是短效的，会迅速过期；其他事实——如最终 GO 提示——可能是粘性的，因为在学习者切换页面后，显示状态可能消失。粘性机制防止系统遗忘短暂但重要的视觉证据，同时保持证据的显式性。

这种架构正是 VLM 基准测试性能与运行时系统相关的原因。更高的事实准确率之所以重要，是因为下游规则引擎将这些事实用作证据。关键假阳性之所以重要，是因为它可以使完成类视觉线索在没有实际出现时显得存在。因此，运行时系统记录视觉事实调用并保存其输出，以供回放和错误分析。

3.8 帮助周期

帮助周期始于学习者请求辅助时——例如通过先导实验中使用的已配置热键路径。运行时系统随后执行以下序列：

1. 读取最新的遥测帧和推导变量。
2. 合并近期动作和任何可用的视觉事实观察。
3. 评估程序前置条件和完成门控条件。
4. 选择当前被阻塞、待处理或下一个候选步骤。
5. 在本地来源策略下检索源材料片段。
6. 构建包含证据包的结构化提示词。




Abbildung 3.3: 实时基于证据的帮助周期。辅助始于观察快照，将其转化为证据包，请求模型给出结构化响应，验证结果，并记录显示的输出。

7. 请求模型响应。
8. 按预期模式解析响应。
9. 验证叠加层目标和证据引用。
10. 执行、修复或抑制叠加层动作。
11. 在事件日志中记录观察、模型响应、验证结果和动作。

因此，模型仅在证据组装后被调用。响应仅在验证后才被使用。这种排序是"解释现实"的运行时表达：模型解释一个有边界的证据包，系统检查该解释是否可以安全显示。

3.9 结构化响应与叠加层验证

教学响应是结构化的而非自由形式。它包含诊断、推荐动作、检查、解释和叠加层目标等字段。运行时系统解析响应，按模式验证，并通过白名单映射叠加层目标。若模型提出一个不受支持的目标、过于粗糙的目标，或缺乏证据的动作，运行时系统可以修复输出、回退到仅文本引导或抑制叠加层。

该验证层对安全性和评估都至关重要。它防止模型通过任意文本直接控制视觉高亮。它也创建了模型输出需要修复的频率记录。在后续报告的先导实验中，所有已执行的叠加层动作都通过了验证；回退事件主要是修复或映射事件，而非完全的仅确定性响应。该结果在系统层面支撑了 RQ1，同时也展示了模型在何处仍需要运行时修正。

3.10 不确定性与降级模式

运行时系统必须将不确定性作为正常操作状态来处理。在实时模拟器中，帮助请求可能在开关正在移动、显示页面正在切换、某个遥测变量不可用或 VLM 帧已过时时到达。将这些情况当作普通假值处理会使教学系统过于自信；将它们当作硬故障处理又会使系统对实时使用过于脆碎。因此，该方法定义了降级模式。

第一种模式是证据缺失。所需来源不可用，或来源已知超出当前观察合约。运行时系统仍可提供一般性程序指导，但不应声称状态已被检查。第二种模式是证据冲突。例如，视觉事实和遥测推导的候选步骤可能指向不同的解释，此时更严格的权威层级和约束规则决定响应被修复、降级还是挂起。第三种模式是输出无效。模型响应未通过模式、目标或证据引用验证，因此运行时系统回退到确定性或仅文本响应。

这些模式之所以重要，是因为它们使不确定性在日志中可见，并在适当情况下在面向用户的语言中可见。一个不能区分"你没有做这个"与"我无法观察这个"的教学系统会误导学习者。本文设计将这些情况分开处理。这在 F/A-18C 冷启动中尤其重要，因为某些步骤结合了缓慢变化的模拟器状态、短暂显示文本和手动座舱导航。运行时系统只有知道自身证据不完整时，才能提供真正有用的帮助。

3.11 VR 交互边界

Meta Quest 3 环境影响了运行时设计，尽管本论文主要不是一项 VR 界面研究。在桌面环境中，用户可以更轻松地在模拟器、手册、聊天窗口和日志之间切换。而在头盔中，这种切换成本要高得多。指导必须简短、在空间上有用，并与学习者当前的动作同步。同时，如果 VR 指导高亮了过多目标、使用了过期状态，或打断了一个已在进行该动作的学习者，它可能变得侵入性。

因此，运行时系统将叠加层指导视为一个受约束的输出通道，而非装饰性 UI。高亮目标必须来自程序包的 UI 映射；多目标引导有数量限制；叠加层计划需要证据引用。当模型提出的目标过于粗糙或不够有依据时，约束层可以修复它或抑制叠加层。响应的语言部分仍然可用，但空间引导需要满足更严格的标准——因为它会直接塑造学习者在座舱中的注意力。

这一边界也解释了为何先导实验日志很重要。一次成功的 VR 试验不仅意味着参与者到达最后一步，还应包含一串可事后检查的帮助请求、VLM 调用、修复、高亮和状态转移。没有这些记录，很难区分教学系统的帮助是否有效：是证据循环真正起作用，还是参与者已有经验，或是人类观察者非正式地填补了空白。导出的帮助周期记录使这种区分在未来工作中可以被分析。

3.12 日志、回放与导出

每个帮助周期和试验级事件都被写入可回放、可导出的日志。回放很重要，因为实时 VR 会话难以在当下检查。导出流水线生成试验摘要、逐步编码文件、帮助周期表格、动作时间线、质量门控结果和会话元数据。这些研究工件同时支撑回归测试和先导实验分析。

回放设计也保护了对结果的解释。单独一个基准测试指标并不显示教学系统在实时试验中的行为；单独一个先导实验完成表并不显示叠加层路径是否有效。通过保存证据包、模型输出、验证决策和参与者级导出，本论文能够将 ML 可靠性与用户在 VR 中实际看到帮助的条件联系起来。

3.13 方法边界

运行时方法具有清晰的边界。它不是一个经过认证的飞行训练系统，不是一个通用的座舱自动化系统，也不是学习有效性的证明。它是一个研究原型，用于研究基于证据的基础模型解释如何在沉浸式模拟器内运作。后续章节评估该原型的两个最重要部分：VLM 视觉证据层和形成性 Quest 3 先导实验。

第四章 方法：视觉事实适配与先导实验方案

第三章展示了将教学输出置于证据之后、验证之前的运行时架构。本章说明其余实证证据如何产生、整理和评估。方法围绕一个实际问题展开：一套小批量审查过的座舱图像、结构化标签和形成性 VR 会话，如何成为机器学习教学系统的可审计证据？

因此，本章将运行时系统、VLM 数据流水线和先导实验视为相互关联的证据协议，而非实现清单。对于 RQ1，它记录了哪些运行时信号被允许支撑回放和先导实验分析。对于 RQ2，它定义了截图如何成为审查过的视觉事实标签、训练行、LoRA 适配器和独立验证集基准测试。对于 RQ3，它记录了形成性 VR 先导实验方案，并将其声明保持为描述性：先导实验可以为可行性和交互模式提供信息，但不能推断学习收益。

4.1 程序运行时与遥测依据

遥测和程序门控条件提供了帮助周期所依赖的状态证据。原始模拟器遥测字段被映射为归一化的运行时变量，同时不可用源数据在 `vars_source_missing` 中被单独跟踪。这一区分在方法论上至关重要：已知的假值可以支撑纠正性指导，但未观察到的值只能支撑不确定性感知的指导或回退。

每个程序步骤随后在这些变量上评估前置条件和完成门控条件。门控 DSL 涵盖阈值检查、范围、布尔标志和经过时间条件。缺失、源数据缺失或哨兵值会以诊断原因为失败结果记录，而不是被静默强制转换；这些原因随帮助周期上下文一起保存。学习者的近期动作通过清洗后的遥测增量表示，使用逐变量阈值、防抖窗口和过滤规则，再生成适合提示词的紧凑摘要。如果模型输出不可用或无效，确定性回退会根据活跃步骤、未满足的门控条件、近期动作和证据可用性计算保守提示；除非局部规则确定了唯一有效目标，否则叠加层引导保持抑制状态。

4.2 知识依据与来源策略

检索到的程序知识为生成的帮助提供文本上下文，但它有意识地被来源控制。本地检索适配器以句子级别索引整理过的程序和飞机文档，并使用 BM25 [38] 排序片段。依据查询由活跃步骤、其描述和当前观察构建；排名靠前的片段被包含在帮助周期上下文中。

声明式来源策略将检索限制在允许的文档来源内。这防止模型收到活跃程序包之外的程序变体——例如，在当前配置为机场冷启动时收到航母特定的指令。因此，检索并非一个通用的文档搜索工具，而是一个受控制的证据通道，其范围是程序配置的一部分。

4.3 视觉事实数据流水线

视觉事实流水线是 RQ2 的主要方法。它将 DCS World 座舱截图转化为有监督示例，再转化为经过基准测试的视觉事实提取器。该流水线专为可追溯性设计：基准测试错误应可追溯至模型预测、人工审查标签、预标注和原始图像。这种设计呼应了数据集文档化实践：数据集的动机、组成、采集过程、推荐用途和来源追踪都应作为数据工件的一部分，而不是外部附注 [10]。

图 4.1 将流水线展示为一个循环。验证集失败不仅是最终结果，它们可以揭示本体论中的弱点并指导后续数据收集。




Abbildung 4.1: VLM 适配流水线。DCS World 复合截图经预标注、人工审查、转换为双语监督微调行、使用 LoRA 适配、在独立验证集上评估，并用于驱动本体论修订。

1. **截图捕获。** DCS World 将左 DDI、AMPCD 和右 DDI 渲染为一张复合面板图像。

相同的复合布局用于数据收集、预标注、训练、基准测试和运行时推理，这保持了方法中输入的分布稳定。

2. **VLM 预标注。**一个外部 VLM 为每张图像生成初始标签和证据注释。预标注用作标注辅助和工作流溯源，而非作为真值或基准测试基线。
3. **人工审查。**预标注样本在 Label Studio [40] 中审查。审查者修正事实状态和证据注释，同时保留与原始图像和预标注的链接。
4. **审查后的 JSONL 导出。**审查后的导出是下游训练和评估的权威真值来源。
5. **双语 SFT 生成。**每张审查图像生成一个英文和一个中文训练行，使用相同的图像和事实标签。助手目标是包含视觉事实和简短摘要的结构化 JSON；外部管理字段（如帧标识符、文件路径和置信度字段）被排除在目标之外。
6. **LoRA 适配。**SFT 行用于训练 VLM 骨干模型的 LoRA 适配器 [19]。实现使用 PEFT 适配器定义 [29]、TRL 监督微调基础设施 [44]，以及用于 4 位 VLM 训练的 Unsloth 加速 [14]。
7. **验证集基准测试与修订。**基座模型和 LoRA 配置在独立验证集上评估。错误在事实层面检查，尤其是对完成关键事实而言，结果失败模式反馈到本体论和数据集修订中。

该方法有意地使 VLM 的任务保持狭窄。模型被训练为以 `seen`、`not_seen` 或 `uncertain` 状态报告视觉事实。它不被训练来决定程序完成或产生教学动作，这些决策保留在程序引擎和约束层中。

4.3.1 标注单元与决策边界

标注单元是一张复合面板截图，配以完整的 13 事实标签向量。一个样本不仅标注触发采集的事实；本体论中的每个事实都经过审查。这种全向量标注至关重要，因为基准测试随后评估完整的视觉快照，也防止训练数据退化为一组孤立的、缺乏明确负例的正例。

审查者应用事实特定的决策边界。页面选项标签与页面本身不同。BIT 根页面上可见的 FCS-MC 条目不是 FCS-MC 子页面。PBIT GO 状态与最终的 FCS-MC GO 结果不同。没有彩色地图图层的 HSI 符号不足以满足地图图层事实。INS OK 必须在校准块附近可读，而非根据已过去的时间阶段推断。这些规则被写入基准测试提示词并反映在本体论中，因此模型按相同的概念契约进行训练和评估。

`uncertain` 标签在截图无法支持清晰决策时使用。这包括模糊帧、部分遮挡的显示区域、模糊文本，或需要时间历史而非单张图像的状态。审查者不被要求猜测模拟器在截图之前或之后可能做了什么。该纪律使 VLM 任务与运行时边界保持一致：单帧感知报告可见事实，而程序推理在下游发生。

预标注加速了流程，但不定义真值。外部 VLM 的输出被视为标注提案。人工审查可以更改状态、修正证据注释或保留不确定性。最终的审查后 JSONL——而非预标注——是用于 SFT 和基准测试评分的来源。这一区分至关重要，否则基准测试测量的是与另一个模型的一致性，而非与审查后视觉事实的一致性。因此，预标注来源是标注追踪的一部分，而非用于声明模型准确率的证据。

审查后的标签未经独立双重编码，因此应被解释为单一审查者人工审查的标签，而非评估者间可靠性研究。论文声明的是所审查数据集上的域内适配器可靠性；对于后续可靠性研究——尤其是针对罕见的完成关键事实——这仍是一个局限。

4.4 数据集整理

4.4.1 数据集概览

六个经审查的数据集支撑了跨两代本体论的视觉事实工作。表 4.1 列出它们的角色和跟踪数量。

Tabelle 4.1: 用于视觉事实提取的数据集清单。

Run	数据集	样本	事实	语言	角色
Run-001	v1 SFT	180	8	en/zh	v1 训练源
Run-002	v1 holdout	50	8	en	v1 验证集
Run-002	v2 newfacts holdout	50	13	en	v2 验证集
Run-003	v2 SFT	220	13	en/zh	v2 训练源
Run-004	v2 random holdout	100	13	en	v2 验证集
Run-005	composition rebalance	122	13	en/zh	v2 训练补充

Run-003 和 Run-005 包含摘要字段为空的样本（分别为 82 和 25 个样本）。这些样本对视觉事实任务仍然有效，因为每个样本仍包含完整的事实数组。运行时系统和基准测试使用的监督目标是结构化事实状态，而非可选摘要。

4.4.2 数据集质量检查

数据集流水线在审查后的导出用于训练或基准测试之前应用多项检查。首先，每个样本必须恰好包含预期的事实标识符一次。缺失或重复的事实 ID 会使模型错误是

视觉性的还是结构性的变得不明确。其次，每个事实状态必须是允许的状态之一。第三，图像路径必须解析为审查期间使用的复合面板图像。第四，在将验证集指标解释为独立证据之前，检查训练集和验证集之间的精确图像重叠。

质量检查不保证每个标签完美无缺，而是保证数据集具有进行有意义基准测试所需的结构。这是不同但重要的声明。在小数据适配中，少数模糊标签可能产生可见影响，尤其是对于罕见的正例事实。因此，本论文将错误分析视为数据工作流的一部分。如果验证集错误揭示某个事实定义过于接近程序性结论，正确回应不仅仅是收集更多数据，也可能是修订本体论。

Run-005 是一次以数据为中心的修正。原始 Run-003 训练源提供了有用覆盖，但若干稀有状态代表性不足。组合再平衡补充有意识地增加了这些状态的曝光。这并不使训练集在统计上代表所有可能的座舱状态，本文也不这样呈现它。它的角色是实践性的：让适配器接触对下游程序证据重要的正例，然后在独立验证集上测试行为。

4.4.3 本体论演化：从 8 事实 v1 到 13 事实 v2

第一个本体论在复合座舱面板上包含八个事实。它确立了小型审查数据集可以改进结构化座舱事实提取，但也暴露了一个表示问题：某些目标将视觉观察与程序性解释混为一谈。最清晰的案例是 `ins_go`，它要求单帧 VLM 推断 INS 完成状态，而非报告直接可见的证据。

图 4.2 说明了方法上的修正。复合的程序目标被分解为局部可观察的视觉原子，将时间性和程序性解释留给教学运行时系统。

当前的 13 事实本体论遵循三条设计规则：

1. **分解复合目标。**`ins_go` 目标被替换为独立的视觉原子：GRND 校准文本和 INS OK 文本。FCS-MC 序列由页面、中间结果、测试中和最终 GO 事实表示。
2. **将区域与语义分离。**事实名称描述可见状态，而非将显示区域嵌入标识符。区域约束属于本体论元数据的一部分。
3. **保持事实局部可观察。**每个事实应能够从复合图像中判定，而不需要程序历史。程序引擎后续将事实与遥测、步骤绑定和时序信息相结合。

这一本体论纪律是本论文的核心。它定义了感知与程序推理之间的边界：VLM 报告视觉证据，而运行时系统决定该证据是否满足某个程序步骤。

4.4.4 训练方案：Run-003 + Run-005CE2

主要的 v2 训练方案将 Run-003 与重复的 Run-005 组合再平衡补充相结合。Run-003 贡献 220 张审查图像，以双语导出为 440 个 SFT 行。Run-005 贡献 122 张审查图




Abbildung 4.2: 从 8 事实 v1 到 13 事实 v2 的本体论演化。诸如 `ins_go` 和宽泛的 FCS-MC 完成事实等复合目标被分解为局部可验证的视觉原子；程序引擎随后将这些观察与遥测、阶段和时序证据相结合。

像，以双语导出为 244 行；此补充被包含两次，得到 488 行。因此，最终方案包含 **928 个 SFT 行**。

Run-005 针对 Run-003 中代表不足的正例状态，包括 INS OK 文本、FCS 页面 X 标记和 FCS-MC 子状态事实。重复补充是一种有意的组合再平衡策略，而非独立的验证集。因此，泛化声明基于外部验证集，而非内部的同一池评估划分。

4.4.5 验证集独立性

两个 13 事实 v2 验证集用于主要评估。Run-002 newfacts 包含来自较早捕获会话的 50 张图像，在 13 事实本体论下重新标注。Run-004 random 包含 100 张随机采样的座舱状态截图。本地重叠检查报告任一验证集与 Run-003 + Run-005 训练并集之间的精确图像重叠为零。

这是一个精确重叠声明，而非更广泛的泄漏审计。本论文不声称感知最近邻分离、场景级独立性，或训练与验证集捕获之间不存在视觉相似的座舱状态。更强的划分审计适合作为未来的研究工件——特别是因为即便图像身份不同，座舱显示器也可能包含近乎重复的状态。

较早的 Run-001 评估线被不同地对待。由于它与训练数据池重叠，它被用作受污染的开发基准，用于检查模式学习和历史本体论行为，但不作为 v2 泛化的独立证据。

4.5 LoRA 微调配置

4.5.1 骨干模型与比较策略

主要适配线使用 Qwen/Qwen3.5-9B-Base 配合 Run-003 + Run-005×2 方案。两个补充骨干模型被纳入，以检验同一数据方案在规模、版本和家族变化下是否仍然有意义：Qwen/Qwen3.6-27B 和 google/gemma-4-31B [11, 12]。这些字符串是本地基准测试输出和部署设置中使用的模型标识符；引用提供模型家族上下文，而非声称每个本地端点细节均由公开报告描述。在本论文中，"本地部署候选方案"指在成功进行基座模型部署、LoRA 加载和基准测试执行后，符合项目本地部署路径的候选方案；它并不意味着该模型已经过普遍验证、可作为产品级模型使用。第 6 章报告数值结果。

比较尽可能保持主要因素不变：本体论、训练方案、基准测试提示词、验证集、生成温度、输出模式和指标计算。骨干模型特定的差异仍然存在，因此被显式报告。Qwen 家族运行将 LoRA 应用于视觉和语言模块；Gemma 运行使用全线性 LoRA 配置，视觉层不单独微调。完整设置见附录 9，表 9.1。

4.5.2 训练栈与超参数

所有骨干模型运行使用 4 位加载，LoRA 秩 $r = 16$ 、 $\alpha = 16$ 、dropout 0.0，四个 epoch，学习率 2×10^{-4} ，有效 batch size 4，最大序列长度 4096，种子 3407，warmup 比例 0.1，weight decay 0.01。适配器权重与基座模型分开保存。

Epoch 数量和 LoRA 秩是为小数据领域适配选择的。在 928 个 SFT 行的情况下，适配器必须学习固定的 JSON 模式和座舱事实的视觉边界。极少的 epoch 可能无法可靠地教授这些边界，而过量训练则可能记忆捕获会话。秩 16 提供了适度的适配容量，而不将适配器变成高容量任务特定模型。

4.5.3 双语 SFT 与组合再平衡

双语 SFT 策略为每张审查图像创建两个指令变体：一个英文、一个中文。图像和事实标签保持相同。这增加了指令格式覆盖，而不需要额外的图像标注。它不替代对新座舱状态或困难负例的需求。

组合再平衡通过 Run-005 处理。由于稀有正例事实对下游程序推理尤其重要，训练方案通过加入目标截图并重复 Run-005 双语行来增加它们的曝光。因此，该方法将两个问题分开：适配器能否从再平衡的训练方案中学习本体论，以及学习到的提取器能否泛化到独立验证集。

4.5.4 训练目标构建

SFT 目标有意地小于运行时观察对象。它包含简短摘要字段和事实对象数组，每个对象包含 `fact_id`、`state` 和 `evidence_note`。它排除帧标识符、文件路径、置信度值、粘性/过期元数据和程序建议。这些排除字段是运行时管理元数据，而非视觉标签。包含它们将教会模型发出它无法从图像中观察到的数据，并使输出更难验证。

目标也避免要求超出简短证据注释的解释性文字。冗长的自由形式解释会使 SFT 目标不够聚焦，并引入额外的评估模糊性。下游语言模型可以在后续将事实转化为面向用户的教学语言。VLM 适配器被训练来提供此类语言可能引用的视觉事实。

这种分离使训练方案与系统架构保持一致。VLM 不因听起来有帮助、预测下一步或解释程序而被奖励，而是因返回完整、可解析、与本体论对齐的事实向量而被奖励。这正是本论文中将基准测试收益解释为感知层收益，而非全教学系统在教法上更优的证据的原因。

4.6 基准测试协议

4.6.1 指标

基准测试在样本和事实两个层面将模型预测与人工审查真值进行比较。所选指标反映了下游运行时风险，也遵循分类评估中的一般原则：指标选择会塑造结果解释，因此需要围绕任务说明其理由 [32, 35]：

- `json_valid_rate`: 输出可解析 JSON 的样本比例。
- `schema_valid_rate`: JSON 包含恰好一次所需事实标识符且仅使用有效状态的样本比例。
- `fact_accuracy`: 所有事实和样本的三类准确率。
- `macro_f1`: 三类状态的宏平均 F1，在事实上平均。
- `seen_f1`: 正例 `seen` 类的 F1，在事实上平均。这很重要，因为遗漏或幻觉化的可见状态会改变程序证据。
- `sample_exact_match`: 全部 13 个事实与审查标签匹配的样本比例。
- `critical_false_positive_count`: 完成关键事实被预测为 `seen` 而审查标签为 `not_seen` 或 `uncertain` 的计数。

关键假阳性被单独跟踪，因为它们是对教学系统最危险的视觉错误。对完成关键事实的假阳性可能导致程序引擎认为某个显示状态已被观察到，而实际上并非如此。

4.6.2 基座 vs. LoRA 比较

基座模型和 LoRA 配置接收相同的提示词、图像、生成参数和输出模式。解码使用 temperature 0.0，最大新 token 数 1024，种子 3407。预测被写入 JSONL、解析、归一化并评分，不进行事后过滤。比较报告给出 LoRA 相对基座模型的差值，第 六 章解读这些差值。

4.6.3 基准测试类别

基准测试按证据状态分类。受污染的开发集来自与训练相同的数据池，仅用于回归和历史解释。验证集的新会话基准测试使用独立截图，与训练集精确重叠为零。这一区分决定了从某个指标可以得出何种强度的声明。

4.6.4 基准测试输出

每次基准测试运行生成一个标准目录，包含每个模型的指标、逐样本预测、错误 JSONL 文件、逐事实评分 CSV、比较摘要、人类可读报告和图表。这些输出构成了第 六 章所报告技术结果的证据链。

4.6.5 错误审查协议

基准测试之后进行定性错误审查。审查首先关注关键假阳性，因为这些错误最可能为程序门控条件创建不安全证据。然后检查视觉优先事实的假阴性，因为反复出现的假阴性可能导致教学系统要求不必要的检查或无法识别进展。最后，检查模式和完全匹配失败，以识别剩余问题是格式、视觉模糊还是事实定义不匹配。

该审查有意与运行时用例绑定。聚合准确率和 F_1 是不充分的，因为教学系统对错误的消耗是不对称的：一个幻觉化的 FCS-MC 最终 GO 结果比一个可重新检查的页面的保守 not_seen 预测更严重；一个模式无效的输在视觉上不那么有趣，但在操作上更重要，因为它触发回退。因此，基准测试协议将数值指标与第 三 章描述的验证和降级路径连接起来。

4.7 人体受试先导实验方法

本研究开展了一项小型形成性 VR 先导实验，用于收集教学系统在 F/A-18C 冷启动任务中实际使用的描述性证据。该先导实验不是有统计效力的对照实验，其目的是在真实 VR 环境中运行运行时系统，检查交互日志，并为后续研究设计识别程序性错误模式。

4.7.1 伦理、知情同意与数据保护

该先导实验作为一项形成性、非临床的程序性训练研究开展。研究操作方案要求在 VR 会话前进行欢迎和知情同意步骤。参与者被告知该研究评估训练系统而非个人能力，他们可以随时停止，若出现 VR 不适可暂停或终止会话。同一方案指示实验者除技术问题外不提供程序步骤提示。

本论文仅使用假名标识符 P01–P09 报告参与者。用于分析的导出数据包含模拟器遥测、运行时事件、教学交互、步骤编码、问卷字段和简短评论；姓名、电子邮件地址和学生标识符不在论文中报告。问卷和评论证据以描述性方式报告，适当时聚合，并在正文中进行匿名化或转述。本论文不声称拥有正式的外部伦理批准标识符；因此，该研究被保守地报告为一项本地硕士论文形成性先导实验，具有知情同意，且不做推断性的人体受试有效性声明。

招募与分组以本地便利调度的方式处理，服务于硕士论文先导实验，而非随机抽样。保留的分析包按假名参与者目录组织；原始参与者材料不作为公开数据集发布。某些会话元数据包含录制引用，但外部视频在本论文中不作为分析证据使用，且不发布可识别的视频、音频、姓名、电子邮件地址、学生标识符或招募记录。非公开原始材料的访问被视为项目内部用于论文准备和导师审查。参与者可在 VR 会话中停止；在数据对作者仍可识别时，撤回或删除请求将被处理。论文不报告金钱补偿，也不使用任何依赖补偿的分析。

4.7.2 参与者与条件

九名参与者 (P01–P09) 各完成一次试验。研究采用受试者间设计，基于调度可用性进行非随机分组：

有教学系统 (n=4)。 P04、P05、P08 和 P09 接收叠加层高亮、结构化帮助文本、基于遥测的步骤推理，以及 VLM 视觉事实支持（在适用情况下）。

无教学系统 (n=5)。 P01、P02、P03、P06 和 P07 无教学辅助。遥测仍被记录，用于离线步骤推理和错误编码。

参与者经验概况在附录 九 表 9.5 中报告。由于分组非随机且样本量小，条件比较仅为描述性。

4.7.3 任务与设备

所有试验使用 DCS World 中的 33 步 F/A-18C 冷启动程序，通过 Quest Link 在 Meta Quest 3 上运行。复合座舱面板被镜像以供实验者观察。教学条件下的试验使用

实时运行时系统，通过 OpenAI 兼容端点进行远程模型推理。试验在参与者完成程序或在无法进展后自愿停止时结束。

4.7.4 数据来源与编码

导出流水线生成逐试验摘要、逐步骤编码文件、教学试验的帮助周期日志、动作时间线、质量门控元数据和会话摘要。试验后表格记录参与者经验、试验前信心、原始 NASA-TLX 工作负荷维度 [15]、适用条件下的教学特定评分、通用自定义用户评分和自由文本评论。

步骤错误以五个类别进行编码：遗漏（OM，某必要动作未完成）、误操作（CO，执行了不必要或错误的动作）、顺序错误（OR，动作以错误顺序执行）、提示/辅助错误（PA，与教学系统或实验设置的交互影响了步骤），以及状态违规（SV，飞机状态与预期条件矛盾）。自动编码输出使用遥测、帮助周期日志和动作时间线进行人工审查；人工编码列是所报告先导实验结果的权威来源。

人工审查是项目内部的重构过程，而非盲法多编码员可靠性研究。它使用记录的遥测、动作时间线、可用的帮助周期证据和观察笔记，决定每个步骤是否被确认以及是否适用人工错误类别。当自动重构与审查证据不一致时，审查规则在结果之前声明，而非隐藏在结果表内。

编码区分未确认为已完成和编码为遗漏。这一区分对于无教学条件至关重要，因为被动日志记录未运行教学条件使用的 VLM 页面检查。因此，一个仅视觉的步骤在 Completed 列中可能保持未确认，即便遥测或动作时间线证据阻止将其评分为参与者遗漏。结果章节将已确认步骤计数和人工错误计数作为独立的描述性度量来报告。

4.7.5 问卷与评论工具

试验后表格记录原始 NASA-TLX 工作负荷维度，而非加权 NASA-TLX。论文报告原始平均值，因为形成性先导实验并非为估计心理测量学的工作负荷效应而设计。表格还记录试验前信心、有教学条件下的教学特定评分、通用用户评分和简短开放式评论。这些教学/用户评分是自定义的试验后条目，而非经过验证的 SUS、信任或可用性量表 [25, 43]。评分值保持在其记录尺度上，不归一化为单一综合有效性得分。

评论被谨慎使用，不被当作具有评估者间可靠性的编码定性主题，而是为观察到的日志和问卷模式提供背景。例如，关于小型固定检查单文本的评论有助于解释为何无教学参与者即便技术上有程序列表可用，在 VR 中仍可能困难重重。关于 AI 识别出学习者卡在哪儿的评论有助于解释为何教学条件下的参与者即便辅助相关错误仍然存在，也可能感知到系统有用。

该工具设计与先导实验的形成性状态相匹配。问卷和评论可以揭示感知有用性、交

互摩擦和应影响下一项研究的信任相关信号；它们不能建立工作负荷、信任、可用性或学习的因果变化。这一边界在结果章节中通过仅以描述性方式报告问卷值，并将任务编码与问卷推导证据分开处理来维持。

4.7.6 数据质量注释

表 4.2 记录了已知先导实验数据质量问题的最终权威规则。目的不是隐藏原始导出冲突，而是使分析规则在结果章节之前可见。

Tabelle 4.2: 先导实验数据质量问题与最终分析权威规则。

案例	数据质量问题	最终分析规则	报告用途
P08	自动 trial_summary.csv 报告了不完整的进展。	人工遥测审查和审查后的 step_coding.csv 列是 完成和错误计数的权威来源。	计为 33/33 完成，零人工 程序错误。
P02	P02 下的问卷文件包含内部参与者 ID 不匹配。	任务日志和步骤编码保留；问卷推导的信心、TLX、自定义评分和评论被排除。	纳入任务/错误表；排除 于问卷汇总。
P07	无教学表格包含教学特定数值字段，尽管条件/NA 标志已设置。	教学特定字段忽略，除非 参与者在教学条件下且 NA 标志为 false。	用户评分保留；教学评分 报告为 N/A。
P04	质量门控报告非阻塞性链接警告。	任务指标保留；受影响的 链接字段不过度解读。	纳入试验概览，附溯源说明。

P09 在试验元数据记录的导出修正后，作为独立参与者处理。

4.7.7 分析方法

先导实验分析报告逐参与者结果和条件层面的描述性汇总。不执行零假设显著性检验。记录观察到的持续时间，但不解释为完成时间比较，因为未完成的非教学试验在不同停止点结束。问卷值仅以原始描述性评分报告。分析聚焦于完成状态、人工错误类别、教学交互模式（如帮助请求、VLM 调用、叠加层动作和回退事件），以及澄清交互摩擦的简短匿名评论。

4.8 本章小结

本方法论确立了论文其余部分使用的证据链。遥测和检索提供受控制的运行时上下文。视觉事实流水线为 RQ2 产生经审查和基准测试的感知层。13 事实本体论将感

知与程序推理分离。LoRA 协议使用匹配的数据和验证集评估小数据适配，而不依赖受污染的开发集。先导实验方案为 RQ3 提供形成性 VR 证据，同时将其声明保持为描述性。这些方法共同使后续结果具有可审计性，而不夸大可用证据能够证明的范围。

第五章 可复现性与研究工件溯源

前两章方法论定义了基于证据的教学循环、视觉事实适配协议和形成性 Quest 3 先导实验。本章将这些方法与用于支撑所报告声明的研究工件连接起来，定义使结果具有可审计性的工件类别、权威规则和可复现性限制。凡决定声明溯源、约束模型权限或定义如何检查所报告结果的实现细节，均被纳入。

5.1 研究工件与声明边界

本研究的工件体系将程序知识、运行时逻辑、外部系统和导出证据分离。程序包存储 F/A-18C Lot 20 冷启动步骤、门控定义、遥测绑定、UI 目标和视觉事实绑定。运行时系统加载这些声明并产生证据包、模型提示词、验证决策、叠加层动作和事件日志。DCS World、外部遥测接口、Quest 3 显示路径、模型服务器和截图捕获属于外部系统。

这一边界防止证据在不同声明之间转移。生成的模型文本本身不被视为研究观察，它只有在通过相应的模式、映射、约束、基准测试或人工审查步骤后才成为可用证据。因此，论文报告三类研究工件：

- **声明性配置：**程序步骤、遥测映射、视觉事实本体论、UI 目标、来源策略规则和回放套件定义。
- **生成证据：**JSONL 事件日志、试验摘要、帮助周期表格、基准测试预测、基准测试指标和质量门控报告。
- **人工审查证据：**审查后的视觉标签、人工步骤编码覆盖、排除规则后的问卷记录，以及匿名化自由文本评论。

每个研究问题使用不同的证据单元。RQ1 在帮助周期粒度上检查：触发上下文、可用证据、模型响应、验证决策和叠加层结果。RQ2 在图像和事实粒度上检查：审查标签向量、预测、解析状态和逐事实错误。RQ3 在参与者和步骤粒度上检查：试验摘要、人工编码、问卷行和评论。VLM 基准测试数字不被用作参与者证据；参与者完成行不被用作每个模型响应正确的证明。

5.2 RQ 层面的溯源

RQ1: 教学循环的可审计性。 运行时系统写入追加式事件和分析导出, 而非仅渲染暂态的头盔指导。一个帮助周期记录: 触发上下文、遥测快照、活跃步骤、门控诊断、检索片段、可用的视觉事实、提示词构建元数据、响应状态、验证结果、叠加层执行状态, 以及回退或修复元数据。相同的格式支持回放: 记录的遥测流可以通过与实时运行时相同的遥测映射、程序门控条件、来源策略和约束契约。这是 RQ1 声明教学系统可审计的研究工件基础。

RQ2: 视觉事实基准测试的可追溯性。 第 六 章报告的所有 VLM 指标均复制自本地基准测试输出, 如 `metrics_base.json`、`metrics_lora.json`、`benchmark_summary.json` 和逐事实评分文件。正文中选定的基准测试图表复制自相同的报告资产。证据链为: 座舱图像捕获、人工标签审查、双语监督微调行生成、LoRA 训练, 以及使用固定提示词、模式、生成设置和指标计算的独立验证集基准测试。训练运行时间和损失值被视为训练报告溯源; 所报告的声明依赖于基准测试 JSON 和审查标签。

RQ3: 先导实验数据权威。 每个参与者试验由一个试验目录表示, 包含事件日志、试验摘要、步骤编码、动作时间线、帮助周期表、会话元数据和质量门控报告。试验后表格提供经验、信心、NASA-TLX 维度、适用的教学特定评分、通用自定义用户评分和自由文本评论。分析应用三条权威规则: P08 当自动重构与人工审查不一致时使用人工步骤编码; P02 保留任务日志指标但排除问卷推导值, 因为内部参与者 ID 不匹配; P09 在元数据记录的参与者修正后作为独立参与者分析。

这些溯源规则保持先导实验声明的边界。先导实验可以描述在一个小型形成性样本中观察到的完成情况、编码错误、原始工作负荷评分、自定义试验后评分、评论和教学交互计数; 它不能支撑统计显著性、因果学习效应、记忆保持、迁移、工作负荷降低或更快完成的声明。

5.3 可复现性限制

本仓库支持对手稿、导出分析表、回放夹具、基准测试摘要和选定图表的本地检查。完整实验重运行需要外部状态: DCS World、F/A-18C 模块、外部遥测接口集成、Quest 3 设置、模型部署访问、用于 VLM 适配的 GPU 资源, 以及形成性参与者会话条件。因此, 本论文区分研究工件可复现性和完整实验重运行可复现性。前者是本文所作的声明: 所报告结果可追溯至存储的研究工件, 并可检查其内部一致性。后者需要重建模拟器、硬件、模型和参与者上下文。

这一区分也解释了初始提案的角色。提案对于理解初始的 VR 场景动机和后续范围演化是有用的，但不用作最终系统结果的证据。结果章节中的声明绑定到已实现的程序包、运行时导出、基准测试 JSON、审查标签和先导实验材料，而非仅绑定到提案设计。

第六章 结果

本章按研究问题的相同顺序报告结果：RQ1 为基于证据的教学运行时系统，RQ2 为 VLM 适配，RQ3 为形成性 Quest 3 先导实验。三条证据线具有不同的声明强度。回放、约束和导出研究工件支撑 RQ1 的技术可审计性声明。验证集基准测试支撑 RQ2 的组件级机器学习声明。先导实验支撑 RQ3 关于实际使用、任务完成、错误、原始工作负荷评分、自定义试验后评分和评论的描述性观察。

图 6.1 总结了证据流。重要的是，三条流不是可互换的：VLM 基准测试不是学习结果；回放夹具不是参与者结果；形成性先导实验不是有统计效力的对照实验。




Abbildung 6.1: 跨研究问题的评估与数据流。回放和约束研究工件支撑 RQ1，VLM 基准测试输出支撑 RQ2，Quest 3 先导实验导出支撑 RQ3 的描述性发现。

6.1 RQ1：基于证据的教学运行时系统

RQ1 询问一个基于证据的基础模型辅助教学运行时系统如何集成遥测、检索、视觉事实和验证。其结果是一个可运行的运行时系统，其帮助周期决策能够从保存的研究工件中重构。证据是技术性而非教学性的：配置文件定义了哪些证据是可接受的，回放和夹具检测已知的失败模式，实时先导实验导出显示同一日志路径在头盔使用期间运行。

6.1.1 运行时就绪性摘要

表 6.1 总结了 RQ1 的就绪性证据。它不声称每个未来的帮助响应都是正确的，而是展示当前运行时系统在模型生成与学习者指导之间放置了显式检查。

Tabelle 6.1: RQ1 运行时就绪性证据（以研究工件覆盖形式）。

证据组	覆盖	示例不变量	观察结果	支撑的声明
程序包	33 步	步骤顺序、门控规则、UI 目标和来源策略是显式的,非模型生成。	就位	预编写的程序先验。
遥测依据	运行时变量映射	源数据缺失证据保持与观察到的假值不同。	就位	状态感知的证据包。
视觉绑定	S08, S15, S18, S19	视觉事实可支撑依赖显示的步骤,而不决定程序完成。	就位	有边界的 VLM 权限。
响应模式与叠加层约束	包衍生模式与 UI 白名单	未知或过于宽泛的目标在叠加层执行前被修复、降级或拒绝。	就位	有边界的动作空间。
回放案例	5 个案例	记录的遥测流和视觉侧车在实时 VR 之外检测相同的包、来源策略和验证路径。	作为回放覆盖通过	可复现的依据检查。
实时夹具	20 条	过期的 VLM 证据不得满足非视觉步骤;移动中的控件必须作为未稳定状态处理。	作为夹具覆盖通过	对依据失败的回归检查。
先导实验导出	9 次试验;含帮助周期日志的 4 次教学试验	试验摘要、步骤编码、动作时间线、质量门控和帮助周期表在实际使用后生成。	通过 (P04 含警告)	审计就绪的实时导出。

6.1.2 回放与约束结果

回放套件包含五个案例，涵盖早期供电、发动机与发电机状态、FCS 重置/BIT 交互，以及 INS 模式证据。标记为可视觉的案例包含侧车帧文件，使依赖视觉的逻辑可以在无实时模拟器的情况下被检测。这些案例确认记录的遥测流可以通过与实时教学相同的程序包、遥测映射、来源策略、UI 映射和验证路径处理。

实时夹具回归矩阵包含 20 条。这些条目涵盖五类就绪性风险：步骤已完成时仍推进、错误目标预防与修复、过期 VLM 证据泄露到非视觉步骤、移动或未稳定控件的等待行为，以及交互语义保持（如鼠标滚轮控件）。此夹具证据支撑 RQ1 的可审计性声明：系统对特定的证据依据失败具有可执行检查。它不证明教育有效性。

6.1.3 实时导出结果

全部九次参与者试验均生成试验摘要、步骤编码、动作时间线、原始事件副本、会话元数据和质量门控报告。四次教学条件下试验还生成帮助周期表。无参与者导出出现阻塞性质量门控失败。一次试验（P04）保留了缺失或不完整链接字段的元数据警告；这些警告限制了这些字段的可追溯性，但不改变下文报告的人工审查任务指标。

在四次教学条件下试验中，运行时系统记录了 77 个帮助周期、23 次 VLM 调用、82 次叠加层执行、零次叠加层拒绝，以及 21 次回退或修复事件。零叠加层拒绝计数应谨慎解读：这意味着最终叠加层动作通过了已配置的白名单和证据检查，而非模型方案总是直接正确的。21 次修复/回退事件表明验证层在实时使用中处于活跃状态。

表 6.2 分解了实时帮助周期导出。原因代码应被理解为运行时处理类别，而非独立的用户侧失败：某些代码修复叠加层目标，另一些将模型的目标替换为状态-动作规划器的选择，还有一些保持响应为仅文本或要求更强的证据。

Tabelle 6.2: 教学条件下试验的实时帮助周期分解。

度量	解读	计数
帮助周期	用户触发的教学周期，含导出的证据行	77
VLM 调用	需要并执行视觉事实调用的周期	23
不需要视觉	活跃证据路径不需要 VLM 调用的周期	54
叠加层执行	验证或修复后接受的叠加层目标执行	82
叠加层拒绝	最终叠加层动作被白名单拒绝	0
回退叠加层使用	回退或修复提供叠加层动作的周期	21
状态-动作规划器修复	回退叠加层原因 <code>state_action_planner</code>	7
最终证据一致性修复	回退叠加层原因 <code>final_evidence_consistency_validator</code> , 使用了回退	6
验证器动作提示修复	回退叠加层原因 <code>validator_action_hint</code>	6
模型提供的回退	回退叠加层原因 <code>model</code>	2

相同的导出行记录了一个视觉证据同步字段 `sync_delta_ms`。在 77 个周期中，该值范围从 50 到 134 ms，中位数为 84 ms。此数字检查帮助周期行与选定视觉帧之间的对齐；它不是端到端模型响应延迟的度量。

6.1.4 证据路径示例

RQ1 的结果可以解读为一条证据路径，而非单一的系统状态。一个典型的视觉优先帮助周期始于遥测推导的程序上下文：运行时系统识别当前候选步骤，评估前置条件和完成门控条件，并将不可用源数据与假值分开记录。如果活跃步骤需要显示证据，运行时系统请求或选择一个复合面板帧，并获取结构化视觉事实。检索随后添加来源控制的程序上下文。仅在这些步骤之后，LLM 才接收到提示词。

模型响应并非立即显示。JSON 对象被解析、对照包衍生模式检查、映射到允许的响应字段，并针对 UI 目标绑定和证据引用进行验证。如果模型提出的目标过于宽泛，约束层可将其修复为更具体的目标。如果证据缺失，叠加层可被抑制，或响应可降级为仅文本指导。事件日志保存遥测快照、视觉事实快照、提示词元数据、原始模型输出、映射决策、约束决策和叠加层结果。

此示例之所以重要，是因为它澄清了 RQ1 所展示和未展示的内容。运行时结果不是“模型给出了好的答案”，而是一个帮助周期可以被分解为证据产生、模型生成、验证、修复和导出。这一分解是在后续对照研究询问教学系统是否改善学习、信任、工作负荷或迁移之前所需的技术基础。

6.2 RQ2：面向座舱视觉事实的 VLM 适配

RQ2 询问小数据 LoRA 适配的 VLM 是否能改善可靠的座舱视觉事实提取。主要结果线是使用 Run-003 + Run-005×2 方案训练的 Qwen3.5-9B。Qwen3.6-27B 作为同一方案下更大的本地部署候选方案报告，Gemma-4-31B 作为对比骨干模型报告。本节所有指标均复制自基准测试 JSON 输出，并在独立的 13 事实验证集上计算。

6.2.1 数据集与训练摘要

v2 训练方案将 Run-003（220 张审查图像）与 Run-005（122 张审查图像，作为组合再平衡补充重复两次）相结合。双语导出产生 928 个监督微调行。两个主要验证集为 Run-002 newfacts（50 张图像）和 Run-004 random（100 张图像），两者均在 13 事实本体论下评分，与训练并集零精确图像重叠。

6.2.2 主要 Qwen3.5 结果

表 6.4 报告主要的 Qwen3.5 基座-对比-LoRA 结果。适配后的模型改善了 Run-004 上的 JSON/模式可靠性，在两个验证集上将事实准确率提升至约 0.99，并将关键假阳性在 Run-002 上从 11 降至 4，在 Run-004 上从 70 降至 8。

Tabelle 6.3: 所报告 VLM 结果的视觉事实数据集清单。

来源	Run	事实	图像	角色
v1 training source	Run-001	8	180	历史 8 事实训练源
v1 holdout	Run-002	8	50	历史 8 事实验证集
v2 newfacts holdout	Run-002	13	50	主要验证集
v2 training source	Run-003	13	220	主要 13 事实训练源
v2 composition rebalance	Run-005	13	122	再平衡补充, 使用两次
v2 random holdout	Run-004	13	100	主要验证集

Tabelle 6.4: 主要 13 事实结果: Qwen3.5-9B 基座 vs. LoRA 在两个验证集上。

指标	Run-002 newfacts (50)			Run-004 random (100)		
	基座	LoRA	Δ	基座	LoRA	Δ
JSON valid	1.0000	1.0000	0.0000	0.9600	1.0000	+0.0400
Schema valid	1.0000	1.0000	0.0000	0.9600	1.0000	+0.0400
Fact accuracy	0.8677	0.9908	+0.1231	0.8038	0.9931	+0.1893
Macro F_1	0.4513	0.6515	+0.2002	0.4393	0.6100	+0.1707
Seen F_1	0.5022	0.9648	+0.4626	0.5659	0.9159	+0.3500
Exact match	0.1000	0.8800	+0.7800	0.0300	0.9200	+0.8900
Critical FP	11	4	-7	70	8	-62

表 6.5 以计数形式给出相同结果。这很重要, 因为验证集较小: Run-002 包含 50 张图像 (650 个事实决策), Run-004 包含 100 张图像 (1,300 个事实决策)。LoRA 线在 Run-002 上做出 644/650 个正确的事实状态决策, 在 Run-004 上做出 1,291/1,300 个。完全匹配的改善也可视作样本计数: 44/50 和 92/100 个完整视觉快照在适配后完全正确。残余关键假阳性仍然集中在完成类事实上。

Tabelle 6.5: 主要 Qwen3.5 结果的计数解读。

验证集	事实数	基座正确	LoRA 正确	LoRA 完全匹配	LoRA 残余关键 FP
Run-002 newfacts	650	564	644	44/50	共 4: FCS-MC final GO 1, INS GRND text 1, INS OK text 2
Run-004 random	1,300	1,045	1,291	92/100	共 8: FCS-MC final GO 8

表 6.6 展示了 Qwen3.5 LoRA 剩余错误在事实层面的分布。适配后大多数事实在两个验证集上无错误。残差集中在少数页面/文本事实上, 最重要的是完成类 FCS-MC

final-GO 证据。

Tabelle 6.6: Qwen3.5 LoRA 线的逐事实剩余错误。

验证集	事实	错误	Seen FP	Seen FN	解读
Run-002	TAC page visible	2	0	2	遗漏可见页面证据；偏保守而非幻觉化完成。
Run-002	FCS-MC final GO visible	1	1	0	残余完成类假阳性。
Run-002	INS GRND text visible	1	1	0	残余文本状态假阳性。
Run-002	INS OK text visible	2	2	0	残余完成类文本假阳性。
Run-004	FCS-MC in-test visible	1	0	1	遗漏中间状态证据。
Run-004	FCS-MC final GO visible	8	8	0	主要剩余关键假阳性簇。

这些计数应被解读为域内组件证据，而非对所有座舱状态的统计估计。不报告置信区间或显著性检验，因为论文不从这些小验证集上做出推断性泛化声明。标签经人工审查但未经独立双重编码，因此稀有完成关键事实仍然是未来标签审计和数据收集的最重要目标。残差表也展示了为何未来数据收集应针对困难负例和时间上相邻的 FCS-MC 状态，而非简单地添加更多通用座舱截图。

图 6.2 以发表形式可视化主要 Qwen3.5 结果，展示准确率和完全匹配的改善，以及被单独跟踪的关键假阳性计数。




Abbildung 6.2: 主要 Qwen3.5 基准测试摘要。左侧面板报告 Run-002 和 Run-004 上的事实准确率和完全匹配率；右侧面板报告完成关键假阳性计数。

实践解读不是 VLM 可以运行程序，而是适配器使视觉事实通道作为一种证据源变得可用了很多。完成类事实仍是主要残余风险，必须仍由程序引擎、遥测、时间上下文和约束检查在下游处理。

6.2.3 主要结果的指标解读

当指标被联合解读时，Qwen3.5 结果最为有力。JSON 和模式有效性显示模型是否能够参与运行时合约。在 Run-004 上，基座模型在四个样本上未能满足此合约，而 LoRA 适配器为所有样本返回有效且模式有效的对象。这很重要，因为运行时拒绝和回退由格式和模式失败触发，在视觉正确性被考虑之前。

事实准确率展示了广泛的改善，但它低估了 seen 状态行为的重要性。教学期间最重要的视觉事实通常是正例线索：页面可见、状态文本已出现，或可读取最终 GO 结果。因此，Seen F_1 捕捉了适配器是否在不产生过多幻觉的情况下更好地识别可见线索。在 Run-002 上从 0.5022 到 0.9648 的提升，和在 Run-004 上从 0.5659 到 0.9159 的提升，是适配器学会了运行时所需的正例视觉状态的最直接证据。

样本完全匹配增加了另一个视角。一个帮助周期可能携带整个视觉快照，因此一个错误事实仍可能产生误导性上下文。Qwen3.5 适配器将完全匹配在 Run-002 上从 0.10 提升至 0.88，在 Run-004 上从 0.03 提升至 0.92。这表明适配后的模型不仅仅改善了几个容易的事实而留下大多数快照不一致。关键假阳性减少是最后的安全导向检查：适配器减少了最可能导致下游教学系统高估完成线索的错误。

6.2.4 Qwen3.6 与 Gemma 比较

表 6.7 报告匹配的补充骨干模型结果。Qwen3.6-27B 在这些验证集上具有比 Qwen3.5 更强的基座模型，尤其是在 Run-004 上，并且在 LoRA 适配后仍是一个本地部署候选方案。然而，Qwen3.6 LoRA 在本地基准测试的主要指标上未超越 Qwen3.5 LoRA。Gemma-4-31B 在同一方案下有所改善，但其适配后的完全匹配和 seen- F_1 值仍低于 Qwen 适配器，且具有不同的关键假阳性特征。

Tabelle 6.7: 匹配的 Run-003 + Run-005×2 方案下的补充骨干模型比较。

骨干	模型	Run-002 newfacts				Run-004 random			
		Acc.	Seen F_1	Exact	Crit. FP	Acc.	Seen F_1	Exact	Crit. FP
Qwen3.5-9B	Base	0.8677	0.5022	0.1000	11	0.8038	0.5659	0.0300	70
Qwen3.5-9B	LoRA	0.9908	0.9648	0.8800	4	0.9931	0.9159	0.9200	8
Qwen3.6-27B	Base	0.9108	0.6712	0.2600	1	0.9769	0.8211	0.7000	7
Qwen3.6-27B	LoRA	0.9877	0.9479	0.8600	3	0.9892	0.9147	0.8600	7
Gemma-4-31B	Base	0.8169	0.5128	0.0400	16	0.8146	0.6332	0.1200	47
Gemma-4-31B	LoRA	0.9492	0.8123	0.4400	0	0.9715	0.7959	0.7400	13

表 6.8 在设计层面解读比较。纳入此表是因为相关的问题不是哪个骨干模型最大或最新，而是哪个模型线为教学系统的下游使用产生最安全的证据通道。

比较支持一个保守的结论。数据与本体论方案不绑定到单一评估骨干模型，但部署选择是模型特定的。Qwen3.5 仍是本论文的主要结果，因为它在当前验证集中给出

Tabelle 6.8: 匹配的 Qwen3.5、Qwen3.6 与 Gemma 比较的解读。

问题	观察结果	解读
Qwen3.5 base vs. Qwen3.6 base	Qwen3.6 base 更强，尤其是在 Run-004 上。	更强的骨干模型在适配前已可编码有用的座舱显示行为。
Qwen3.5 LoRA vs. Qwen3.6 LoRA	Qwen3.5 LoRA 在当前适配后的事实准确率和完全匹配指标上仍略微更强。	最强的基座模型在本地方案下并非自动成为最强的适配后证据通道。
同一方案下的 Gemma	Gemma 有显著改善，完全匹配低于 Qwen 适配器，对某些关键假阳性更保守。	不同骨干模型暴露不同的错误代价特征；较低的聚合表现仍可为风险分析提供信息。
设计结论	无任何评估线在所有下游关注点上占优。	模型选择应取决于下游风险，而非仅排行榜排名。




Abbildung 6.3: Qwen3.5、Qwen3.6 和 Gemma 在 Run-003 + Run-005×2 方案下的匹配骨干模型比较。面板分别报告 Run-002 和 Run-004 上的事实准确率、完全匹配率和关键假阳性计数。

了最佳的适配后准确率/完全匹配组合。Qwen3.6 作为本地部署候选方案具有吸引力，因为其基线已更强；Gemma 则提供了关于不同错误风格的有用比较证据。

6.2.5 模型特定解读

Qwen3.6 结果很有用，因为它将骨干模型强度与 LoRA 增益分离开来。其基座模型在上述两个验证集上已远比 Qwen3.5 基座更强，尤其是在 Run-004 上——在适配前就达到了 0.9769 的事实准确率和 0.70 的完全匹配率。LoRA 适配器仍改善了 seen F_1 和完全匹配，但相对增益更小，因为基线已更接近任务要求。因此，Qwen3.6 被作为本地部署候选方案而非主要论文结果处理。它很强，但未改变主要的方法论结论：小数据适配加良好的本体论可以使 VLM 作为有边界的感知组件可堪使用。

Gemma 展现了相反的模式。其基座线弱于 Qwen3.6 基座，在宽泛准确率上接近 Qwen3.5 基座，但适配器在 Run-002 上将关键假阳性降至零。同时，其完全匹配和 seen F_1 仍低于 Qwen 适配器。这表明在本地数据上存在更保守或不完全的适配行为：一个验证集上较少的关键幻觉，但对正例状态的识别不够完整。对于教学系统来说，这种权衡并非自动更差或更好：保守模型对某些显示线索可能更安全，但可能迫使更多重复检查或回退引导。

因此，匹配比较支持设计结论而非排行榜结论。骨干模型选择应以下游错误代价为考量。如果模型避免了安全敏感事实的关键假阳性，即便聚合准确率略低也可能是可接受的。如果残差错误集中在完成线索上，即便完全匹配更高的模型仍可能需要约束检查。论文以 Qwen3.5 作为主线，因为它在这些基准测试中具有最佳适配平衡，同时记录 Qwen3.6 和 Gemma，以便模型选择边界可见。

6.2.6 错误模式

基座 Qwen3.5 模型的主导失败模式是稀有状态幻觉。在 Run-004 中，FCS-MC 中间结果事实仅出现在 100 个样本中的 7 个中，而基座模型在大量额外样本中将其预测为可见。LoRA 适配移除了大部分此扩散性幻觉模式。剩余适配错误更少，且更集中在完成类显示信号周围——这正是运行时系统谨慎对待的事实。

此模式解释了 13 事实本体论为何重要。页面存在事实比程序完成状态更容易学习。将复合目标分解为局部可观察的视觉原子，为模型提供了更好的监督任务，也为运行时系统提供了更安全的证据边界。

残差错误模式对未来的数据收集也有启发意义。额外的随机截图不一定会解决最困难的情况，如果它们主要重复已经容易的页面存在状态。缺失的数据是有针对性的困难负例和时间相邻状态：页面存在但最终状态尚未可见的帧、中间与最终 BIT 状态相似的帧，以及显示文本较小或短暂的帧。这些示例比通用截图更有价值，因为它们

直接攻击剩余的关键假阳性风险。

因此，基准测试充当了本体论审计。当一个事实对适配器容易且跨验证集稳定时，它很可能是一个良好的局部视觉命题。当一个事实在适配后仍易出错时，问题可能是数据不足、视觉模糊，或事实定义仍嵌入了过多的程序推理。论文将这些案例视为对表示层的反馈，而非仅仅是模型的不足。

6.3 RQ3: 形成性 Quest 3 先导实验

RQ3 询问一项形成性、非随机的 Quest 3 先导实验在以下方面提供了哪些描述性证据：任务完成、程序错误、原始工作负荷评分、自定义试验后评分、评论，以及辅助与未来可信协作之间的边界。九名参与者各完成一次试验：四名有教学辅助，五名无教学辅助。先导实验仅作描述性报告，不支撑统计显著性、学习收益、记忆保持、迁移、工作负荷降低或速度声明。

Formative Quest 3 pilot protocol and analysis authority




Abbildung 6.4: 形成性 Quest 3 先导实验方案与分析权威规则。先导实验将单次试验的参与者会话连接到运行时日志、问卷、人工步骤编码和仅描述性解读。

6.3.1 参与者与任务结果

表 6.9 汇总了试验结果和交互计数。该表使用人工审查的步骤编码列作为完成和错误计数的最终权威。原始试验摘要作为溯源材料保留，可能因人工审查纠正被动重构而有所不同。P08 按第 4.7 节描述的规则以人工编码为准；P09 作为独立参与者处理。观察持续时间是从第一个记录事件到最后一个记录事件的间隔，并非完成时间比较，因为无教学试验在不同的程序节点结束。

Tabelle 6.9: 参与者与试验概览。

P	条件	已完成	已确认	时长 (s)	帮助	VLM	叠加层	回退
P01	without_tutor	no	23/33	2015	0	0	0	0
P02	without_tutor	no	27/33	739	0	0	0	0
P03	without_tutor	no	24/33	243	0	0	0	0
P06	without_tutor	no	29/33	269	0	0	0	0
P07	without_tutor	no	19/33	218	0	0	0	0
P04	with_tutor	yes	33/33	442	19	6	22	6
P05	with_tutor	yes	33/33	317	7	2	6	2
P08	with_tutor	yes*	33/33	332	7	5	10	4
P09	with_tutor	yes	33/33	1033	44	10	44	9

*P08: 自动摘要报告了不完整进展; 人工编码确认 33/33 完成。

确认步骤计数与表 6.10 中的人工遗漏计数不是同一度量。它统计一个步骤是否被可用的导出证据确认。在无教学条件下, 被动日志记录未运行教学试验使用的 VLM/视频页面检查。因此, 视觉优先的 FCS BIT 页面和 final-GO 检查 (S18 和 S19) 在所有五个无教学步骤计数行中保持未确认。人工动作时间线审查给出了不同的解读: 所有五个无教学参与者都存在右侧-DDI PB5 活动, 因此 S18 不被编码为用户遗漏。对于 S19, P02、P03、P06 和 P07 显示了 FCS BIT 开关向上序列; 仅 P01 被编码为 S19 遗漏。剩余的不确定性是视觉性的: 被动导出无法确认 FCS-MC 页面和最终 GO 结果是否确实可见。

在审查数据中, 全部四名教学条件下参与者达到了最终 33 步状态, 而五名无教学试验中无一达到已确认的最终 33 步状态。这一对比是最明显的先导实验观察, 但也是最受混淆的: 分组非随机, 先前经验不平衡, 且无教学条件缺乏教学试验可用的活跃 VLM/页面检查。如果对仅导出确认步骤行进行排名, S18 (FCS-MC BIT 页面)、S19 (FCS BIT 最终 GO) 和 S27 (襟翼开关到 AUTO) 并列, 因为它们在所有五个无教学行中均未确认。这一排名不应被解读为参与者错误排名: 对于 S18 和 S19, 它主要暴露了被动导出的测量盲点; 对于 S27, 它与人工编码的程序问题重叠。因此, 人工遗漏编码讲述了更相关的行为故事: S09、S27 和 S29 是最频繁的遗漏编码步骤, 各出现在五个无教学试验中的三个。这一模式识别了参与者在何处遇到困难以及被动导出流水线在何处缺乏视觉确认; 它不是教学效果的因果估计。

参与者概况使描述性边界尤其重要。样本包括新手、中级用户和专家用户, 但条件未按先前的 DCS World 或 F/A-18C 经验平衡。P05 和 P06 是不同条件下的专家参与者, P01 和 P09 是新手。P09 在导出修正后作为独立参与者处理, 但先导实验仍无法排除经验、调度或会话上下文效应。因此, 正确的解读不是"教学系统导致了完成", 而是已完成的运行时系统能够在本次形成性样本中支持四名教学条件下参与者完成全部程序, 而无教学运行揭示了值得对照性后续研究的反复出现失败点。

6.3.2 程序性错误模式

表 6.10 报告人工错误计数。无教学试验以遗漏为主导，而教学试验转向误操作和提示/辅助错误。这一转变对未来设计很重要：辅助可以在保持参与者推进程序的同时，仍然引入时机、解读或过度引导风险。

Tabelle 6.10: 人工程序性错误计数。OM = 遗漏，CO = 误操作，OR = 顺序错误，PA = 提示/辅助错误，SV = 状态违规。

P	条件	OM	CO	OR	PA	SV
P01	without_tutor	8	0	1	0	1
P02	without_tutor	0	0	0	1	0
P03	without_tutor	7	0	2	0	2
P06	without_tutor	2	0	0	2	0
P07	without_tutor	11	0	0	0	0
P04	with_tutor	0	3	0	3	1
P05	with_tutor	0	3	0	3	0
P08	with_tutor	0	0	0	0	0
P09	with_tutor	0	3	0	2	0

无教学参与者平均 7.4 个人工编码错误。教学条件下参与者平均 4.5 个人工编码错误。这些是来自一个小型非随机先导实验的描述性统计。更稳健的定性结果是错误类型对比：遗漏在无教学辅助下占主导，而辅助相关错误在教学条件下仍然存在。

辅助相关错误之所以重要，是因为它们表明可信赖的助手不仅仅是一台完成机器。参与者可以在完成所有步骤的同时，仍然收到时机不当、冗余或在状态已实现后过于急切的引导。在先导实验中，教学条件下的误操作和提示/辅助错误指向了这些交互风险。它们驱使更严格的确认逻辑、更好地检测已完成状态，以及在未来版本中更清晰的不确定性处理。

6.3.3 工作负荷、自定义评分与评论

P02 被排除于所有问卷推导汇总之外，因为问卷元数据包含内部参与者 ID 不匹配。表 6.11 报告其余原始问卷值。评分仅为描述性。教学特定评分仅在有教学条件下可用；通用自定义用户评分在两种条件下均可用。这些评分是自定义试验后条目，不应解读为验证后的 SUS、信任或可用性量表。

原始 TLX 值在无教学条件下从 13.33 到 55.83 不等，在教学条件下从 13.33 到 33.00 不等。描述性均值分别为 34.12 和 23.66，但样本量太小且不平衡，无法做出工作负荷降低声明。教学组中的教学特定评分始终高于量表中点，均值为 5.92。这些评分支持形成性解读：参与者普遍对教学系统评价积极，而日志和错误编码仍显示未解

Tabelle 6.11: 排除 P02 后的试验后问卷摘要。信心、教学评分和用户评分使用记录的 1-7 响应量表；原始 TLX 报告为非加权的原始工作负荷平均。

P	条件	信心	原始 TLX	教学评分	用户评分
P01	without_tutor	3.5	55.83	n/a	4.20
P03	without_tutor	6.0	26.67	n/a	5.20
P06	without_tutor	7.0	13.33	n/a	5.60
P07	without_tutor	5.0	40.67	n/a	5.20
P04	with_tutor	7.0	26.33	6.00	6.20
P05	with_tutor	7.0	13.33	6.17	5.60
P08	with_tutor	5.0	33.00	5.67	5.00
P09	with_tutor	3.5	22.00	5.83	6.40
Mean without tutor		5.38	34.12	n/a	5.05
Mean with tutor		5.63	23.66	5.92	5.80

决的辅助风险。

问卷值之所以有用，是因为它们使纯粹基于日志的解读变得复杂。P09 有最多的帮助请求和最长的教学条件追踪，但记录的用户评分高，且评论将基于证据的反馈描述为有帮助。P05 是一位专家参与者，需要较少的帮助周期且记录了低 TLX 值，但仍有辅助相关错误。这些示例提示未来的评估不应将教学系统简化为单一结果变量。完成、工作负荷、感知有用性、校准信任、错误类型和帮助周期修复频率对新手和专家可能表现不同，但当前先导实验仅为这些未来构念记录了形成性替代指标。

表 6.12 汇总了简短匿名评论。评论不被编码为具有评估者间可靠性的主题；它们被用于解释先导实验中观察到的具体交互摩擦。评论以转述或轻度浓缩的英文摘要形式报告；若参与者使用其他语言，摘要为翻译而非逐字引用。

Tabelle 6.12: 简短匿名参与者评论（转述或轻度浓缩以节省篇幅）。

条件	主题	评论摘要
Without tutor	检查单可读性	一名参与者报告膝板阅读困难，小型固定文本在 VR 中难以使用。
Without tutor	程序映射	一名参与者报告某些检查单步骤与其座舱体验不够匹配。
With tutor	遗漏操作	一名参与者报告教学系统帮助填补了他们遗漏的操作。
With tutor	基于证据的反馈	一名新手参与者描述了逐步引导，能够识别他们卡住的位置，且在动作错误时不推进。
With tutor	认知负荷	一名参与者仍需要对比座舱显示器与 AI 指令，且觉得 FCS 和 BIT 等缩写令人困惑。

6.3.4 RQ3 小结

先导实验提供了三项描述性发现。第一，运行时系统能够在 Quest 3 环境中实时使用并产生可分析的导出。第二，审查后的任务日志显示在此非随机样本中，全部四名教学条件下参与者完成了完整流程，而五名无教学参与者无一完成。第三，教学系统改变了观察到的错误模式而非消除所有错误：遗漏在教学条件下消失，但误操作和提示/辅助错误仍然存在。这些发现驱动了未来工作的问题：在动态、高负载、多模态环境中，AI 如何能够成为可信赖的协作者，而非仅仅是一个流畅的指令来源。

第七章 讨论

第 六 章报告了三条具有不同声明强度的证据线：RQ1 的回放和约束就绪性证据，RQ2 的视觉事实基准测试，以及 RQ3 的形成性 VR 先导实验。本章将这些证据线结合起来解读。主要声明不是教学系统已被证明能够改善学习，而是论文展示了一个程序化教学系统如何通过将遥测、程序规则、检索来源、VLM 推导的视觉事实以及约束验证置于学习者与基础模型响应之间，变得技术上可审计。

第 7.1 节解释已实现的工作与初始提案的差异。第 7.2 节解读技术证据。第 7.3 节在其形成性边界内讨论先导实验发现。第 7.4 节从本体论演化中得出主要的设计教训。第 7.5 和 7.6 节陈述论文的局限性和最直接的研究后续方向。

7.1 从提案到已实现系统的演变

初始论文提案 [46] 描述了一个面向 Meta Quest 3 的 VR 优先教学系统，具备视线、手部追踪、语音输入、RAG+LLM 后端，以及一项受控的三条件人体受试研究。最终论文保留了沉浸式程序性教学的研究动机，但工作重心发生了转移。已实现的贡献最好被理解为一个基于证据的教学运行时系统和视觉事实提取方法，VR 用于形成性先导实验而非受控的有效性声明。

这一转变不仅仅是工程上的便利。冷启动程序使一个先决问题变得可见：在教学系统能够给出有用的程序性帮助之前，它必须知道哪些状态可以被信任。某些所需证据通过外部遥测接口导出为原始遥测数据；某些证据仅在座舱显示器上可见；某些证据超出当前的遥测或视觉事实合约，因此运行时系统必须将其视为不可用，而非静默地转化为自信的状态声明。因此，论文必须首先构建证据层：程序包、门控推理、证据包、检索边界、VLM 视觉事实、模式约束的模型输出、约束验证、叠加层白名单和可回放日志。

VLM 工作从同样的压力中生长出来。提案假设模拟器状态足以进行程序性跟踪。在实践中，显示页面内容（如校准和 BIT 状态）必须被视觉观察。这导致了 13 事实本体论、审查后的截图数据集、LoRA 适配流水线以及独立验证集基准测试。这些成为核心贡献，因为它们定义了基础模型如何被用作有边界的感知组件，而非不受约束的

程序状态判断者。

已完成的 VR 先导实验部分地回到了初始提案中的人体受试目标。它展示了基于证据的运行时系统能够在头盔中与真实参与者一起运行，并且导出流水线能够捕获任务日志、原始工作负荷评分、自定义试验后评分和评论以供后续分析。然而，它并未完成项目初始提出的受控三条件研究。在 $n = 9$ 、非随机分组、P02 排除于问卷推导汇总、P08 的完成状态以人工编码为准的情况下，先导实验是形成性和描述性的。

7.2 技术证据的解读

最强的技术结果是 RQ2 的视觉事实基准测试。主要 Qwen3.5-9B LoRA 线在两个独立的 13 事实验证集上达到约 0.99 的事实准确率，同时相对于基座模型显著降低了关键假阳性。补充的 Qwen3.6-27B 和 Gemma-4-31B 结果表明，同一数据与本体论方案不绑定到单一骨干模型，尽管论文不声称广泛的模型家族通用性。重要的解读更窄且更有用：一个小型、经过审查、与本体论对齐的数据集，可以使 VLM 在座舱视觉事实提取上比相应的基座模型在本地验证集数据上显著更可靠。

该结果之所以重要，是因为教学运行时系统将 VLM 输出视为证据而非权威。一个视觉事实——如可见的页面、标签或状态文本——是下游步骤推理的一个输入。程序引擎仍将视觉事实与遥测、程序顺序、时间上下文和包定义的门控条件相结合。这种分离正是防止基准测试成为未经支撑的教学法声明的原因。VLM 结果支撑了教学系统的感知层；它本身并不证明教学系统的教学效果更好。

RQ1 的回放和约束证据支撑了论文的另一部分。回放案例、实时夹具覆盖、包衍生模式、响应映射和叠加层白名单表明，已实现的运行时系统能够在模型输出到达学习者之前对其进行约束。这是一个技术就绪性和可审计性声明，意味着帮助周期可以被回放、检查和对照显式证据契约进行核对。它不意味着每个未来的模型响应都在教法上最优，也不意味着运行时系统已被跨模拟器或跨程序验证。

综合来看，技术证据支撑了该架构的核心前提：当基础模型的角色被显式证据产生和验证所限制时，它们可以在程序性教学中发挥作用。论文不要求 LLM 成为真值来源，而是要求 LLM 在一个运行时系统中生成响应，其中可观察状态、程序包、检索来源和约束层定义了该响应可以安全地声明或高亮什么。

7.2.1 技术证据未能证明的内容

技术证据未显示学习收益、记忆保持、迁移、降低的工作负荷或更优的训练结果。VLM 基准测试测量的是单帧视觉事实提取。回放和约束测试测量的是证据契约和输出约束是否按预期表现。两者对可靠的教学系统是必要的，但对人类学习声明都不充分。

学习者可以收到准确且有依据的帮助，但仍未能形成持久的程序性理解。反之，学习者可能从一个较少仪表化的系统中学习，如果该系统恰好契合其先验知识和策略。

证据也尚未分离每个组件的价值。本论文未包含比较遥测唯一教学、视觉增强教学、不同检索策略或不同约束严格性水平的消融实验。因此，评估支撑的是一个集成系统层面的声明：已实现的系统展示了一种技术上可审计的方式来组合这些元素，而不是对每个设计选择相对于替代方案进行排名。

7.2.2 VLM 结果的数据中心解读

VLM 结果部分是模型结果，但更重要的是数据和表示结果。最显著的改进来自 LoRA 适配，然而适配器只是早期薄弱的视觉流水线与当前结果之间发生变化的系统的一部分。本体论被修订，标签契约被收窄，训练分布被再平衡，基准测试将独立验证集与受污染的开发集分开。这些选择是数据中心的 ML 选择，它们定义了模型被要求学习什么以及何种错误被视为危险。

这一区分对未来工作很重要。人们很容易将 Qwen3.5 的数字解读为更大或更新的骨干模型是主要解决方案的证据。Qwen3.6 的比较反驳了这种简单解读。更强的基座模型有帮助，但不能消除对任务特定本体论或衡量正确失败模式的验证集基准测试的需求。Gemma 的比较也反驳了单一指标解读：一个模型在某项关键假阳性指标上可以更保守，同时在完全匹配和 seen 状态识别上仍不够完整。实践教训是模型选择应具有下游风险意识。

同样的教训适用于训练数据。添加更多示例仅在示例针对剩余决策边界时有用。在当前适配后，页面可见性远不如时间上相邻的完成线索、稀有正例状态，以及标签或页面名称出现但目标页面并非活跃状态时的困难负例有趣。因此，未来的数据收集应由基准测试失败驱动，而非出于统一扩大数据集的愿望。

7.2.3 对 ML 系统设计的启示

论文还提示了一个更广泛的 ML 系统模式。在此场景中，当系统设计者将模型的工作收窄到其输出可以被测试的程度时，基础模型最为有用。VLM 不被要求理解整个座舱，而是预测一个小型事实向量。LLM 不被要求运行程序，而是解释当前的证据包。运行时系统不被要求无条件信任任一模型，而是验证并记录它们的输出。这种劳动分工将宽泛的基础模型能力转化为一组更小的契约。

这一模式不同于简单地在聊天机器人周围添加护栏。护栏通常在模型已生成自由形式答案之后操作。在本文原型中，契约在生成之前就已存在：程序包定义了目标空间，证据包定义了模型允许引用什么，视觉本体论定义了 VLM 可以报告什么，约束层定义了什么可以成为叠加层。模型仍然贡献灵活性，但问题的形态是在模型外部定义

的。这正是论文可以做出可审计性声明——尽管不能证明完整的教育有效性——的原因。

对于可部署的 ML 系统，这一区分是重要的。以模型为中心的方法询问哪个模型强大到足以解决任务。以证据为中心的方法询问任务的哪些部分应分配给学习模型，哪些部分应保持符号化或预编写，以及冲突应如何解决。座舱教学系统受益于第二种方法，因为不同错误的代价不是对称的：解释中错误的同义词比错误的叠加层目标更不严重；遗漏的视觉线索比幻觉化的完成线索更不严重；模式无效的 VLM 响应若运行时系统在其成为证据之前将其拒绝，则不那么危险。

由此产生的系统并不比不受约束的聊天机器人更简单，但更可检查。每增加一个约束就创建一个研究工件：模式、来源策略、本体论、UI 映射、基准测试或回放夹具。这些研究工件是将基础模型的流畅性转化为一个可以被评估的研究对象的工程成本。

7.3 先导实验发现的解读

形成性 VR 先导实验提供了关于系统实际使用的描述性证据。在审查数据中，全部四名教学条件下参与者达到了最终 33 步状态，而五名无教学试验中无一达到已确认的最终 33 步状态。人工编码也显示教学条件下零遗漏错误，无教学条件下平均 5.6 个遗漏错误。这些观察与教学系统的预期功能一致：它保持当前程序步骤可见，检索相关程序上下文，并能够将学习者指向座舱控件。

问卷数据增添了第二个、较弱的描述性层。排除 P02 后，原始 NASA-TLX 均值在无教学条件下为 34.12，在教学条件下为 23.66，教学组在记录的 1-7 量表上给出了 5.92 的平均教学特定评分。这些值对形成性解读有用，尤其是与关于基于证据的反馈、遗漏操作、VR 检查单文本过小和缩写令人困惑的评论一起阅读时。它们不应被解读为教学系统以推断强度降低了工作负荷或改善了校准信任或可用性的证据。

相同数据也表明辅助并未消除程序性错误。误操作和提示-辅助错误在教学条件下仍然存在。这是一项重要发现，因为它指向了一个比“教学系统是否有帮助？”更精确的设计问题：剩余问题是灵活的模型生成引导、确定性约束修复、视觉状态不确定性和人类动作时机，如何与严格的程序规范对齐。教学系统可以减少遗漏步骤模式，同时仍为错误的时机、不完整的执行或对辅助的过度信任留有余地。

实时帮助周期日志支撑了基础设施声明。在四次教学试验中，系统记录了 77 个帮助周期、23 次 VLM 调用、82 次叠加层执行、零次叠加层拒绝和 21 次回退或修复事件。零叠加层拒绝计数不应被解读为“一切顺利”，而是意味着建议的叠加层动作在模式验证和约束处理后保持在已配置的白名单内。修复事件是约束层处于活跃状态的证据，而非模型输出始终直接正确的证据。

因此，先导实验在论文中有两个角色。第一，它展示了仪表化的教学运行时系统

能够在实时 VR 环境中使用并产生可分析的日志。第二，它揭示了后续受控研究应更仔细测量的那种人-系统交互数据。它不支撑关于学习、工作负荷、记忆保持、迁移或任务速度的因果声明。

7.3.1 辅助与未来协作之间的边界

先导实验有助于定义未来可信赖 AI 协作者的前提条件，但并不直接评估该构念。协作者不仅仅是提供更多指令的系统。在高负载 VR 座舱中，更多指令如果时机不对、使用不熟悉的缩写，或迫使学习者对比多个证据来源，可能增加认知工作量。可信赖的协作者必须调节自身的确定性、决定何时高亮何时保持仅文本，并帮助学习者理解下一步背后的证据。

教学试验同时显示了这一边界的两个方面。完成和遗漏模式表明，步骤感知的引导可以保持学习者方向感；误操作和提示/辅助错误表明方向感不够。系统还必须避免在状态已实现后给出重复或过期的引导。P09 的评论尤其具有启发意义：教学系统因识别出参与者卡住的位置且不盲目推进而被看重，但同一参与者仍报告需要将显示器与 AI 指令对比，且苦于缩写。在此语境中，信任不是盲目的接受，而是一种交互——学习者能够看到助手为何做出某项断言，并在断言不完整时能够恢复。

这一解读强化了论文标题。"解释现实"不是取代学习者的情境意识，而是通过使状态、证据和不确定性更易操作来支持它。当前原型仅实现了该理念的早期版本：它具有证据包、视觉事实、验证和日志，但尚未优化帮助应何时简洁、何时显式，及何时应向学习者或教练请求确认。

7.4 本体论设计教训

本体论演化是论文中最清晰的设计教训。第一个视觉事实本体论将可观察事实与程序性结论混杂在一起。例如，`ins_go` 要求 VLM 决定校准状态是否已有效达到。该目标不仅是视觉性的，它依赖于特定的显示文本、其他显示状态的不存在，以及程序阶段。第一个基准测试中的失败模式使边界问题变得可见：单帧 VLM 被要求同时执行感知和程序推理。

13 事实本体论纠正了这一边界。它将复合目标分解为较低层的视觉观察——例如地面校准文本或 OK 文本是否可见——并将 FCS-MC 状态分解为视觉上可区分的阶段。下游运行时随后将这些观察与遥测和程序上下文结合解读。因此，设计原则为：

视觉事实目标应是低层的、局部可验证的视觉命题。更高层的程序状态应在下游从视觉事实、遥测、时间上下文和程序规则中推断。

这一原则超越标签命名的意义。它影响标注质量、训练信号质量、错误诊断和运行时安全性。人工审查者可以在不知道程序历史的情况下判断一段文本是否在截图中可见，但同一审查者在不知道图像之前发生了什么的情况下，并不总能判断某个程序状态是否完成。当事实契约尊重这一区分时，模型的输出变得更容易审查，并且与确定性门控条件结合使用时更安全。

完成类事实上的残余假阳性展示了方法的剩余边界。某些状态在中间和最终阶段之间视觉上相似，尤其是涉及数值读数或暂态显示状态时。这些情况可能需要更平衡的数据、更高分辨率的裁剪、重复观察或显式的时间性 VLM 输入。因此，论文不声称 13 事实本体论一般性地解决了视觉依据问题，而是为一个高要求的程序提供了一种经过测试的设计纪律，以及一种用于发现视觉目标何时仍过于接近程序性结论的具体方法。

作为未来领域的启发式规则，其规则很简单：如果一个事实无法在不了解程序步骤的情况下从单张图像标注，它可能对 VLM 契约而言过于高层，应将其分解为可见原子或推迟到程序引擎处理。这是论文从案例特定实现细节转向可复用的表示教训之处。

7.5 局限性

本贡献应在以下局限性内理解。

7.5.1 评估范围

所有数据集、回放案例和先导实验试验均涉及一个程序：F/A-18C 冷启动。视觉提取器在固定的复合座舱面板上训练和评估，使用相同的飞机类型和渲染环境。验证集是独立的会话，与训练集零重叠，但它们仍测量域内泛化，不确立跨程序、跨飞机或跨模拟器的通用性。

最大训练方案在 Run-005 过采样步骤后包含 928 个双语 SFT 行。这对于领域特定适配研究是有意的小规模和实用性的，但未确定最小数据需求、性能上限或每个方案组件的效应。论文不包括对双语行、过采样、LoRA 秩、组合再平衡、本体论修订或替代微调方法的消融实验。特别是，它未分离 Run-005 过采样、双语指令行、LoRA 秩或从 8 事实本体论到 13 事实本体论的各自效应。

7.5.2 系统与 VLM 范围

VLM 作为单帧视觉事实提取器被评估。它不决定程序进展、不选择最终教学动作，也不直接控制叠加层。完成类事实上的残余关键假阳性仍然重要，因为一个虚假的视

觉观察，若未被遥测、时间确认或约束检查所检查，仍可影响下游推理。粘性事实和确认策略减轻了此风险，但其完整的端到端效应尚未在实验上被分离。

骨干模型比较覆盖了 Qwen3.5-9B、Qwen3.6-27B 和 Gemma-4-31B，使用匹配的 LoRA 式适配方案。这在项目范围内是有用的模型多样性证据，但不覆盖其他 VLM 家族、更大模型、全量微调、替代适配器或非座舱视觉领域。

运行时系统已通过回放、夹具、桌面 DCS World 和 Quest 3 先导实验实现和验证。但头盔延迟、叠加层可读性、视线或手部追踪准确性，以及专家评分的响应有用性未作为受控的系统级结果进行测量。

7.5.3 构念效度

论文中的若干构念是替代指标。VLM 基准测试测量的是单帧视觉事实提取，而非人类对座舱显示器的理解。回放夹具测量已知的证据依据案例是否被处理，而非每个可能的实时帮助请求是否安全。人工步骤完成测量程序状态是否被达到，而非学习者能否在之后独立执行任务。原始 NASA-TLX 值测量一次形成性试验后的报告工作负荷，而非稳定的工作负荷降低。

这些替代指标仍然有用，因为它们匹配了系统的开发阶段。在测试学习结果之前，教学系统必须能够观察状态、产生有边界的视觉事实、验证模型输出，并导出可解读的日志。因此，这里选择的构念优先考虑技术就绪性和描述性交互证据。后续的对照研究应增加当前论文未测量的构念：延迟后的记忆保持、对另一启动场景的迁移、专家评分的解释质量、头盔中叠加层的可读性，以及校准信任。

构念效度边界也保护了 ML 结果免于过度解读。高 VLM 准确率对视觉证据通道是必要的，但不是解释质量的直接度量。反之，参与者可能对教学系统评价积极，即便某些视觉事实或叠加层需要修复。因此，评估将组件可靠性、系统可审计性和人类响应作为独立的构念来保持。

7.5.4 先导实验范围

先导实验包含九名参与者：四名有教学系统，五名无。分组非随机，先前的 DCS World 经验未平衡，样本量对推断性统计过小。无教学试验在不同的程序节点停止，因此其持续时间不能与完成的教学试验比较。

问卷证据可用但有限。P02 的问卷元数据无法自信地归属，被排除于所有问卷推导汇总之外。其余原始 NASA-TLX、自定义教学/用户评分和自由文本评论数据仅为描述性，支撑形成性解读，而非具有推断强度的工作负荷、信心、信任或可用性声明。

最后，人工审查根据被动遥测门控条件和动作时间线推断无教学条件下的完成情况。因为活跃的 VLM 通路在该条件下不可用，视觉证据步骤具有更大的不确定性。此

限制不使形成性发现失效，但显示了为何下一项研究需要更严格的仪表化和编码。

7.5.5 范围总结

在这些限制内，论文支撑了四项声明：具有显式架构边界的证据约束的程序性教学运行时系统可以被实现；一个小数据 VLM 适配流水线可在本地验证集上产生可靠的视觉事实提取；视觉本体论演化提供了关于感知与推理的具体设计教训；VR 先导实验表明系统可以在参与者身上使用，同时产生可分析的日志。它未建立受控的教育有效性。

7.6 未来工作

上述局限性通向一个更大的研究议程：AI 如何在动态、高负载、多模态训练环境中成为可信赖的协作者？在本论文中，可信赖性不意味着模型听起来自信，而是助手能够揭示其指导背后的证据、知晓模态何时不可用、服从显式程序规则、从不确定性中恢复，并留下教练可以检查的审计追踪。以下方向扩展了这一议程。

7.6.1 受控人体受试评估

下一项研究应将基于基础模型的教学系统与基线条件进行比较，使用随机分组、平衡的参与者元数据、预定义的编码规则，以及完整的问卷和工作负荷捕获。对于下一次迭代，两条件设计比初始的三条件提案更现实，因为当前的优先事项是确立已完成的运行时系统是否在受控条件下在完成率、错误、工作负荷和记忆保持方面产生可测量的差异。

7.6.2 本体论向其他程序的扩展

13 事实本体论应仅在新的任务分析确定了哪些状态是遥测可见的、视觉优先的或超出当前证据来源合约之后，才扩展到其他程序。每个新程序需要自身的视觉事实契约、审查数据、验证集基准测试和运行时绑定。这是对本体论纪律是否能够超越冷启动进行迁移的恰当检验。

7.6.3 时间性与多帧视觉推理

若干残差错误涉及难以从单张截图消歧的状态。多帧输入、短暂视觉历史或重复确认门控条件可以帮助区分中间和最终显示状态。这需要改变截图捕获、标注、模型输入格式和基准测试指标。

7.6.4 系统级帮助周期评估

一项单独的评估应测量完整的帮助周期而非单个组件：触发到叠加层的延迟、高亮目标的正确性、约束修复的频率和类型、专家审查下的响应有用性，以及视觉优先步骤是否优于仅遥测基线。这将使 RQ1 和 RQ2 的技术证据更直接地与 RQ3 联系起来。

对于可信赖协作者议程，这种系统级评估还应测量助手应保持沉默、请求确认或陈述不确定性的时机——而非给出另一条指令。在高负载 VR 使用中，过多的指导如果与学习者的注意力竞争或掩盖行动所需的证据，可能与过少的指导一样有害。

7.6.5 多模态协作策略

未来工作应将模态选择视为一个策略问题。助手可以用文本、空间叠加层、视觉确认请求、检索到的手册摘录或沉默来响应。每种模态都有代价。文本消耗阅读和记忆资源；叠加层消耗视觉注意力，可能将学习者拉向一个控件；VLM 调用消耗延迟并可能返回不确定的事实；检索可以增加权威性但也可能加长消息。可信赖的协作者应选择满足当前证据状态的最轻量级模态。

这种策略可以从确定性开始。例如，如果遥测已确认完成，教学系统应避免重复指令；如果视觉事实不确定，应请求确认而非高亮完成目标；如果学习者处于已知的高困惑步骤，教学系统可先给出简短解释，仅在请求时才揭示更多细节。后续工作可以从专家修正中学习策略的部分内容，但策略应保持可审计：每个模态选择仍应绑定到状态、证据和不确定性。

7.6.6 现场修正与适配

当前的 VLM 适配流水线是离线的。未来版本可以在视觉事实错误时收集教练或学习者的修正，并将这些修正馈入后续审查或增量适配。这一方向需要谨慎的安全防护，因为现场标签可能嘈杂，且适配不得消除先前可靠的行为。

7.6.7 未来方向总结

表 7.1 总结了主要的未来工作方向及每个方向所回应的局限性。

这些方向使论文主线保持完整。下一阶段不是让基础模型减少约束，而是加强其周围的证据循环：更广泛的程序包、更好的视觉事实、更丰富的时间性证据、受控的人类评估，以及使每个教学系统响应在事后可审计的日志。

Tabelle 7.1: 未来工作方向总结。

方向	当前状态	主要挑战
受控人体受试研究	形成性先导实验已完成；因果证据待定	随机化、元数据、工作负荷和统计效力
本体论扩展	冷启动本体论仅在当前座舱布局内被评估	新任务分析、标注和验证集设计
时间性视觉推理	当前 VLM 使用单张复合面板帧	多帧数据、模型容量和时间性指标
系统级帮助周期评估	组件和回放证据可用	定义集成的延迟、质量和修复指标
现场修正与适配	离线审查和 LoRA 流水线已实现	嘈杂标签、遗忘，以及安全更新策略

第八章 结论

本论文从一个许多程序性训练场景共有的实践问题出发：学习者在复杂模拟系统内操作时经常需要帮助，但有用的帮助必须依据当前真实状态。当下一步正确操作取决于遥测、程序顺序、显示状态和先前动作时，仅有一个流畅的基础模型响应是不够的。本论文建立的核心答案是：当基础模型被置于一个可审计的证据循环中时，它们可以适用于程序性教学。

F/A-18C 冷启动任务为该理念提供了一个高要求的案例。它要求教学系统在生成叠加层或文本引导之前，结合遥测可见的座舱状态、来自显示页面的视觉证据、检索到的程序知识、不可用源边界和验证。结果并非一项学习有效性已被证明的声明，而是一项技术和方法论贡献：一种使模型辅助的程序性帮助变得状态感知、可检查且受可用证据边界约束的方法。

8.1 已完成工作总结

已完成工作回答了三个研究问题，如下所述。

RQ1：证据集成与教学架构。 论文展示了如何将模拟器遥测、检索到的程序来源和视觉事实观察集成到一个受约束的帮助周期中。运行时系统在模型生成前构建证据包，从声明式门控条件推断候选程序步骤，要求模型在包衍生模式内响应，通过约束层验证或修复响应，并仅执行白名单内的叠加层动作。日志和回放随后使产生的帮助周期在事后可检查。这在技术可审计性层面回答了 RQ1：LLM 不是程序状态的权威，而是一个受证据、模式、约束层和程序包规则约束的生成器。

RQ2：视觉事实提取与本体论设计。 论文还展示了小数据 VLM 适配可以支撑教学系统所需的座舱显示状态进行可靠的视觉事实提取。13 事实本体论和 LoRA 训练流水线在 Qwen3.5-9B 线上产生了最强的主要结果——在两个独立的 13 事实验证集上达到约 0.99 的事实准确率，且相对于基座模型显著降低了关键假阳性。补充的 Qwen3.6-27B 和 Gemma-4-31B 结果在已评估骨干模型范围内支持了相同的数据与本体论方案。更

一般的教训是表示性的：VLM 应报告局部可验证的视觉事实，而程序完成应在下游从视觉事实、遥测、时间和程序上下文中推断。

RQ3：形成性 VR 先导实验证据。 已完成的 Quest 3 先导实验提供了关于运行时系统和仪表化能否在沉浸式模拟中与参与者共同使用的形成性证据。在审查数据中，四名教学条件下参与者完成了 33 步程序，而五名无教学参与者未能完成。遗漏错误在教学条件下消失，辅助相关错误仍然存在。帮助周期日志还显示教学系统可以在实时环境中运作，包括 VLM 调用、叠加层动作、约束修复和可回放导出。这些发现描述性地回答了 RQ3——它们支撑可行性、仪表化就绪性和错误模式分析；不确立因果性学习收益、工作负荷降低、记忆保持、迁移或速度改善。

综合而言，这些答案定义了论文的贡献。第一，本工作提供了一个面向程序性模拟的基于证据的教学运行时模式，其中生成的帮助位于显式状态证据和验证的下游。第二，它贡献了一个将 VLM 感知与程序推理相分离的视觉事实本体论和适配方法。第三，它提供了一条可用于先导实验的评估路径，用于研究基于基础模型的教学系统与真实 VR 参与者的交互。在这三项中，重要的不是 LLM 或 VLM 本身的存在，而是围绕基础模型输出所设置的边界。

该边界是主要的可迁移理念。基础模型可以在高保真程序性训练器中发挥作用，但仅当其角色被显式化时方可如此。LLM 是语言和解释组件，而非模拟器真值的来源。VLM 是感知组件，而非程序引擎。检索是文本依据的来源，而非混合程序变体的许可。遥测在其存在的领域具有权威性，但不是完整的教法。运行时贡献正是将这些部分权威组合为一次帮助周期并记录该组合如何被做出的机制。

ML 贡献同样是有限的但具体的。论文不声称 LoRA 适配一般性地解决了座舱感知问题。它表明，通过精心修订的本体论、审查后的小型数据、组合再平衡和独立验证集，VLM 能够在教学系统所需的特定的结构化视觉事实上变得显著更可靠。Qwen3.5、Qwen3.6 和 Gemma 的比较展示了为何这应被视为模型与数据的决策，而非对最大骨干模型的简单选择。可靠性取决于事实契约、错误代价以及预测的下游用途。

范围被有意地保持有限。评估覆盖了一个程序、一种座舱布局、本地视觉验证集、回放和约束就绪性，以及一项小型非随机先导实验。当前证据支撑技术可靠性和可审计性的强于支撑教育有效性的。它未显示教学系统跨领域泛化，也未显示先导实验差异仅由教学系统造成。这些边界不是需要隐藏的弱点，而是使贡献可被检查的条件。

8.2 未来工作

最直接的下一步是进行受控的人体受试评估。此类研究应保留当前的导出和回放基础设施，但增加随机分组、平衡的参与者元数据、完整的问卷和工作负荷捕获、预

定义的编码规则，以及足以进行推断性分析的样本量。只有这种研究才能检验——以及如何——具有技术依据的帮助周期改变了学习、工作负荷、记忆保持或迁移。

技术议程同样清晰。程序包与视觉事实方法应扩展到其他程序，但每次扩展都需要新的任务分析、证据来源映射、视觉本体论设计、审查数据和独立验证集评估。VLM流水线也应超越孤立截图——当程序状态依赖时间性证据时：短暂视觉历史、重复确认或多帧输入是完成类事实自然的下一步机制。最后，完整的帮助周期应作为集成系统进行评估，包括延迟、叠加层正确性、约束修复频率、专家评分的响应有用性，以及助手应克制、推迟或显式陈述不确定性的时刻。

系统的更长时期版本可以从教练或学习者的现场修正中学习。这一方向将实时教学转变为数据收集循环，但需要谨慎的安全防护：修正标签可能嘈杂，更新不得消除已可靠的行为，且每个适配后的模型仍必须针对未触碰的验证集进行评估。

更广泛的研究问题是如何使 AI 成为协作者而非答案生成器。在本文研究的环境中，协作意味着帮助学习者在不确定性下行动，同时保持学习者检查情境的能力。它意味着选择何时高亮、何时解释、何时请求确认，以及何时保持沉默。它还意味着留下足够的证据，以便教练、研究者或开发者能够重构系统相信什么以及为何如此行动。本论文中的原型并未完成这一议程，但它确立了追求这一议程所需的证据循环——包括未来信任校准和专家质量研究的先决条件。

本论文标题解释现实，捕捉了最终的设计承诺。程序性教学系统不应仅仅解释一份检查单，也不应仅仅生成关于某项任务的看似合理的语言。它应解释学习者当前的现实：什么可被观察、哪些证据支撑它、哪条程序规则适用、什么仍不确定，以及为何下一个响应被允许。这也正是走向将 AI 作为动态、高负载、多模态环境中可信赖协作者来研究的长期路径。本论文的贡献是一种架构和证据方法，用于使这种解释可被审计。

参考文献

- [1] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, et al. Do as i can, not as i say: Grounding language in robotic affordances. In *Proceedings of the 6th Conference on Robot Learning*, 2022. doi: 10.48550/arXiv.2204.01691.
- [2] Vincent Aleven, Bruce M. McLaren, Jonathan Sewall, and Kenneth R. Koedinger. A new paradigm for intelligent tutoring systems: Example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2):105–154, 2009. doi: 10.3233/IRG-2009-19(2)02.
- [3] Saleema Amershi, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, Jina Suh, Shamsi Iqbal, Paul N. Bennett, Kori Inkpen, Jaime Teevan, Ruth Kikin-Gil, and Eric Horvitz. Guidelines for human-AI interaction. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, pages 1–13, 2019. doi: 10.1145/3290605.3300233.
- [4] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.
- [5] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems*, volume 36, 2023. doi: 10.48550/arXiv.2305.06500.
- [6] Biplab Deka, Zifeng Huang, Chad Franzen, Joshua Hibsichman, Daniel Afergan, Yang Li, Jeffrey Nichols, and Ranjitha Kumar. Rico: A mobile app dataset for building data-driven design applications. In *Proceedings of the 30th Annual ACM*

- Symposium on User Interface Software and Technology*, pages 845–854, 2017. doi: 10.1145/3126594.3126651.
- [7] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL <https://arxiv.org/abs/2305.14314>.
- [8] Eagle Dynamics. DCS World, 2013. Digital Combat Simulator. Available at: <https://www.digitalcombatsimulator.com/>.
- [9] Eagle Dynamics. DCS: F/A-18C early access guide, 2023. Updated 18 July 2023. Available at: https://www.digitalcombatsimulator.com/en/downloads/documentation/dcs-hornet_early_access_guide_en/.
- [10] Timnit Gebru, Jamie Morgenstern, Briana Vecchione, Jennifer Wortman Vaughan, Hanna Wallach, Hal Daumé III, and Kate Crawford. Datasheets for datasets. *Communications of the ACM*, 64(12):86–92, 2021. doi: 10.1145/3458723. URL <https://arxiv.org/abs/1803.09010>.
- [11] Gemma Team. Gemma: Open models based on gemini research and technology, 2024. URL <https://arxiv.org/abs/2403.08295>.
- [12] Gemma Team. Gemma 3 technical report, 2025. URL <https://arxiv.org/abs/2503.19786>.
- [13] David Gunning, Mark Stefik, Jaesik Choi, Timothy Miller, Simone Stumpf, and Guang-Zhong Yang. XAI—explainable artificial intelligence. *Science Robotics*, 4(37):eaay7120, 2019. doi: 10.1126/scirobotics.aay7120.
- [14] Daniel Han and Michael Han. Unsloth: Open-source library for faster LLM finetuning, 2024. URL <https://github.com/unslothai/unsloth>.
- [15] Sandra G. Hart and Lowell E. Staveland. Development of NASA-TLX (Task Load Index): Results of empirical and theoretical research. In Peter A. Hancock and Najmedin Meshkati, editors, *Human Mental Workload*, volume 52 of *Advances in Psychology*, pages 139–183. North-Holland, 1988. doi: 10.1016/S0166-4115(08)62386-9.
- [16] Robert T. Hays, John W. Jacobs, Carolyn Prince, and Eduardo Salas. Flight simulator training effectiveness: A meta-analysis. *Military Psychology*, 4(2):63–74, 1992. doi: 10.1207/s15327876mp0402_1.

-
- [17] Steven J. Henderson and Steven Feiner. Exploring the benefits of augmented reality documentation for maintenance and repair. *IEEE Transactions on Visualization and Computer Graphics*, 17(10):1355–1368, 2011. doi: 10.1109/TVCG.2010.245.
- [18] Robert R. Hoffman, Shane T. Mueller, Gary Klein, and Jordan Litman. Metrics for explainable AI: Challenges and prospects. In *arXiv preprint arXiv:1812.04608*, 2018. URL <https://arxiv.org/abs/1812.04608>.
- [19] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [20] Lasse Jensen and Flemming Konradsen. A review of the use of virtual reality head-mounted displays in education and training. *Education and Information Technologies*, 23:1515–1529, 2018. doi: 10.1007/s10639-017-9676-0.
- [21] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Ho Ho Shu Chan, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023. doi: 10.1145/3571730.
- [22] Enkelejda Kasneci, Kathrin Seßler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günnemann, Eyke Hüllermeier, Stephan Krusche, Gitta Kutyniok, Tilman Michaeli, Claudia Nerdel, Jürgen Pfeffer, Oleksandra Poquet, Michael Sailer, Albrecht Schmidt, Tina Seidel, Matthias Stadler, and Gjergji Kasneci. ChatGPT for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274, 2023. doi: 10.1016/j.lindif.2023.102274.
- [23] Dawid J. Kopiczko, Tijmen Blankevoort, and Yuki M. Asano. VeRA: Vector-based random matrix adaptation. *arXiv preprint arXiv:2310.11454*, 2023. URL <https://arxiv.org/abs/2310.11454>.
- [24] James A. Kulik and J. D. Fletcher. Effectiveness of intelligent tutoring systems: A meta-analytic review. *Review of Educational Research*, 86(1):42–78, 2016. doi: 10.3102/0034654315581420.
- [25] John D. Lee and Katrina A. See. Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1):50–80, 2004. doi: 10.1518/hfes.46.1.50_30392.

-
- [26] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- [27] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in Neural Information Processing Systems*, 36, 2023. doi: 10.48550/arXiv.2304.08485.
- [28] Guido Makransky and Gustav B. Petersen. The cognitive affective model of immersive learning (CAMIL): A theoretical research-based model of learning in immersive virtual reality. *Educational Psychology Review*, 33:937–958, 2021. doi: 10.1007/s10648-020-09586-2.
- [29] Sourab Mangrulkar, Sylvain Gugger, Lysandre Debut, Younes Belkada, Sayak Paul, and Benjamin Bossan. PEFT: State-of-the-art parameter-efficient fine-tuning methods, 2022. URL <https://github.com/huggingface/peft>.
- [30] Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1906–1919, 2020. doi: 10.18653/v1/2020.acl-main.173.
- [31] Antonija Mitrovic. Fifteen years of constraint-based tutors: What we have achieved and where we are going. *User Modeling and User-Adapted Interaction*, 22(1–2): 39–72, 2012. doi: 10.1007/s11257-011-9105-9.
- [32] Juri Opitz. A closer look at classification evaluation metrics and a critical reflection of common evaluation practice. *Transactions of the Association for Computational Linguistics*, 2024. doi: 10.1162/tacl_a_00675. URL <https://arxiv.org/abs/2404.16958>.
- [33] Riccardo Palmarini, John Ahmet Erkoyuncu, Rajkumar Roy, and Hosein Torabmostaedi. A systematic review of augmented reality applications in maintenance. *Robotics and Computer-Integrated Manufacturing*, 49:215–228, 2018. doi: 10.1016/j.rcim.2017.06.002.

-
- [34] Felipe Pezoa, Juan L. Reutter, Fernando Suarez, Martín Ugarte, and Domagoj Vrgoč. Foundations of JSON schema. In *Proceedings of the 25th International Conference on World Wide Web*, pages 263–273, 2016. doi: 10.1145/2872427.2883029.
- [35] David M. W. Powers. Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *International Journal of Machine Learning Technology*, 2(1):37–63, 2011. URL <https://arxiv.org/abs/2010.16061>.
- [36] Qwen Team. Qwen3-VL technical report, 2025. URL <https://arxiv.org/abs/2511.21631>.
- [37] Jaziar Radianti, Tim A. Majchrzak, Jennifer Fromm, and Isabell Wohlgenannt. A systematic review of immersive virtual reality applications for higher education: Design elements, lessons learned, and research agenda. *Computers & Education*, 147:103778, 2020. doi: 10.1016/j.compedu.2019.103778.
- [38] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/15000000019.
- [39] Arthur Tang, Charles Owen, Frank Biocca, and Weimin Mou. Comparative effectiveness of augmented reality in object assembly. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, pages 73–80, 2003. doi: 10.1145/642611.642626.
- [40] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. Label Studio: Data labeling software, 2020. URL <https://github.com/HumanSignal/label-studio>.
- [41] Kurt VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011. doi: 10.1080/00461520.2011.611369.
- [42] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [43] Roel Visser, Tobias M. Peters, Ingrid Scharlau, and Barbara Hammer. Trust, distrust, and appropriate reliance in (X)AI: A survey of empirical evaluation of user trust. *arXiv preprint arXiv:2312.02034*, 2023. doi: 10.48550/arXiv.2312.02034.

-
- [44] Leandro von Werra, Younes Belkada, Lewis Tunstall, Edward Beeching, Tristan Thrush, Nathan Lambert, and Shengyi Huang. TRL: Transformer reinforcement learning, 2020. URL <https://github.com/huggingface/trl>.
 - [45] Bryan Wang, Gang Li, Xin Zhou, Zhourong Chen, Tovi Grossman, and Yang Li. Screen2Words: Automatic mobile UI summarization with multimodal learning. *arXiv preprint arXiv:2108.03353*, 2021. doi: 10.48550/arXiv.2108.03353.
 - [46] Yu Zhang. Explain reality: Grounded procedural tutoring with foundation models and visual fact extraction in immersive simulation — MSc thesis proposal. TU Clausthal, Institute for Software and Systems Engineering (ISSE). Unpublished manuscript., 2025.

第九章 附录

本附录支撑方法、实现和评估章节。它保存原始配置、数据集、回放、图表和先导实验编码材料，而不扩展正文各章中所述的声明边界。

9.1 完整 LoRA 超参数配置

表 9.1 列出了匹配的 Run-003 + Run-005 $\times$ 2 方案下三个骨干模型的完整超参数配置。数值来自可用的训练报告和基准测试输出。

注意：训练损失值因分词器行为、对话模板结构、目标序列分布和模型参数化的不同，在骨干模型之间不可直接比较。训练运行时间和最终损失为训练报告溯源；所报告的主要 VLM 声明依赖于本地基准测试 JSON 和审查标签。

9.2 8 事实 V1 基线基准测试

最早的完整基准测试使用在 Run-001（180 个任务）上训练的 8 事实 LoRA 适配器，并在 Run-002 验证集（50 个样本）上评估。此线早于 13 事实本体论，纳入仅为历史参考。

LoRA 适配器显著改善了事实级指标，但将关键假阳性从 13 增加到 15。这一历史结果说明了 8 事实 v1 本体论的结构性弱点：诸如 `ins_go` 的复合目标无法从单帧图像中进行视觉验证，并在完成类事实上产生了系统性的假阳性错误。

9.3 数据集事实分布

表 9.3 报告了两个主要训练源（Run-003、Run-005）和两个 13 事实验证集（Run-002 newfacts、Run-004 random）的逐事实 `seen` 计数。计数取自相应的 `stats.json` 文件。表格使用简短显示标签；权威事实标识符定义在程序包使用的视觉事实本体论文件中。

Tabelle 9.1: 三个骨干模型的完整 LoRA 微调超参数。

参数	Qwen3.5-9B	Qwen3.6-27B	Gemma-4-31B
max_seq_length	4096	4096	4096
num_train_epochs	4.0	4.0	4.0
learning_rate	2×10^{-4}	2×10^{-4}	2×10^{-4}
per_device_train_batch_size	1	1	1
gradient_accumulation_steps	4	4	4
lora_r	16	16	16
lora_alpha	16	16	16
lora_dropout	0.0	0.0	0.0
seed	3407	3407	3407
load_in_4bit	True	True	True
warmup_ratio	0.1	0.1	0.1
weight_decay	0.01	0.01	0.01
train_rows	928	928	928
eval_rows	0	0	0
骨干特定			
Vision LoRA	启用	启用	禁用
LoRA 目标模块	vision+lang	vision+lang	all-linear
对话模板	Qwen 默认	Qwen 默认	gemma-4
GPU 内存利用率	0.6	0.6	0.95
训练结果			
训练运行时间 (s)	6419	12619	8050
训练损失 (最终)	0.2156	0.1068	0.0474

Tabelle 9.2: 8 事实 v1 基准测试: Qwen3.5-9B 基座 vs. LoRA-v1 在 Run-002 验证集上 (50 样本, 英文)。

指标	基座	LoRA-v1	Δ
JSON valid rate	1.0	1.0	—
Schema valid rate	1.0	1.0	—
Fact accuracy	0.7600	0.9150	+0.1550
Macro F_1	0.4241	0.5847	+0.1605
Seen F_1	0.4714	0.8380	+0.3666
Sample exact match	0.06	0.36	+0.30
Critical false positives	13	15	+2

Tabelle 9.3: 训练集与验证集之间的逐事实 **seen** 计数 (13 事实 v2 本体论)。

事实标签	Run-003	Run-005	Run-002	Run-004
TAC page visible	46	24	23	3
SUPT page visible	20	34	5	3
FCS page visible	30	40	13	94
FCS X marks visible	16	18	1	5
BIT root page visible	18	43	9	16
FCS-MC page visible	55	56	9	84
FCS-MC intermediate result	18	15	1	7
FCS-MC in-test state	18	19	6	17
FCS-MC final GO result	18	22	2	60
HSI page visible	106	109	49	100
HSI map layer visible	79	37	27	50
INS GRND alignment text	58	72	42	69
INS OK text	12	14	4	0

Run-005 与 Run-003 结合时增加了若干稀疏目标的覆盖: SUPT 页面观察从 20 升至 54, FCS-MC 页面观察从 55 升至 111, INS GRND 校准文本观察从 58 升至 130。此表格记录数据溯源; 第 六 章评估了所得训练方案是否在验证集上改善了模型行为。

9.4 CLI 命令参考

仓库中的原型 CLI 提供以下命令:

- run.** 使用模拟环境适配器配合预记录的场景文件执行模拟, 并写入事件日志。
- replay.** 对照程序包验证已有的事件日志, 检查步骤排序和状态机一致性。
- score.** 使用评分引擎对事件日志进行评分, 生成遗漏计数、状态违规计数和总错误得分。
- record-vlm.** 对一组视觉观察执行 VLM 事实提取, 并记录预测以供基准测试。
- replay-telemetry.** 通过遥测流水线回放原始遥测捕获, 并可选择性地调用帮助生成循环。
- validate.** 对照模式注册表中的命名模式验证 JSONL 文件。

所有命令接受模型配置覆盖 (`-model-provider`、`-model-name`、`-model-base-url`、`-model-timeout-s`) 和语言切换 (`-lang`)。

9.5 模型提供方配置

模型访问通过环境变量配置并在运行时验证。配置项包括：

- Provider.** 模型提供方，可选择 `openai_compat`、`ollama` 或 `stub`。
- Base URL.** 提供方端点。
- Model.** 模型名称。
- Timeout.** 请求超时。
- Credentials.** `openai_compat` 提供方所需的 API 密钥；密钥在日志输出中被遮蔽。
- Images.** 是否在请求中启用 `base64` 图像编码。
- Language.** 输出语言，选择 `zh` 或 `en`。

9.6 回放评估套件

表 9.4 列出了 `fa18c_startup_v04` 套件中的五个回放评估案例。此处显示标签经缩短；套件文件保存了精确的 `case_id` 字符串。

Tabelle 9.4: 回放评估案例。

案例	步骤	视觉	目标
No-op capture	S01	no	电池开关
Battery on	S02	no	火警测试开关
Battery on, engine generator off	S01	no	左发电机开关
FCS reset / FCS BIT	S18	yes	FCS BIT 开关
INS mode	S12	yes	INS 模式旋钮

标记为视觉可用的案例包含相应的 DCS World Saved Games 截图中的逐帧侧车文件 (`frames.jsonl`)。这些文件使视觉依赖的回放案例可以在没有实时 DCS World 实例的情况下运行。

9.7 补充架构与导出图表

正文各章使用简化图表来支撑研究论证。图 9.1、9.2 和 9.3 保留了额外的工程细节，供可复现性和操作上下文参考。

Harness validation boundary




Abbildung 9.1: 约束层与证据验证。候选教学动作在接受叠加层行动计划之前，须经过模式约束、UI 白名单、证据一致性和程序状态的检查；不安全或依据不足的动作被修复、拒绝或降级为仅文本引导。

Prototype deployment topology




Abbildung 9.2: 原型使用的部署拓扑。模拟器、Quest 3 叠加层路径、本地运行时、回放工具和远程模型提供方被分离，以使实时试验和离线分析能够使用相同的证据和日志契约。

Experiment export pipeline




Abbildung 9.3: 详细的实验导出流水线。运行时事件日志和试验元数据被转化为参与者级摘要、步骤编码、帮助周期记录、质量门控条件和研究级分析表。

9.8 VR 先导实验——补充数据

表 9.5 列出了用于描述性解读的参与者经验概况。问卷、步骤编码和参与者元数据的质量处理规则在表 4.2 中单独列出，以避免将数据清洗细节混入参与者概况本身。

表 9.6 列出了每名无教学参与者未被可用导出证据确认为已完成的特定步骤。应与第 六 章中的人工错误表一起阅读，因为被动无教学日志记录未运行教学试验使用的 VLM 页面检查。

表 9.7 报告了自动编码错误计数（人工审查前）与人工错误计数并排，展示了自动导出在用于先导实验解读之前需要多大程度的修正。

表 9.8 记录了当原始导出与人工审查证据不一致时使用的补充研究工件权威规则。

Tabelle 9.5: 先导实验参与者经验概况（自我报告）。

P	条件	分组	DCS World	F/A-18C	冷启动	VR
P01	无教学	新手	无	无	无	非常少
P02	无教学	中级	频繁	有经验	尝试过	频繁
P03	无教学	中级	偶尔	尝试过	尝试过	偶尔
P04	有教学	中级	偶尔	尝试过	尝试过	偶尔
P05	有教学	专家	频繁	有经验	能完成	频繁
P06	无教学	专家	频繁	有经验	能完成	频繁
P07	无教学	中级	偶尔	尝试过	尝试过	偶尔
P08	有教学	中级	偶尔	尝试过	尝试过	偶尔
P09	有教学	新手	无	无	无	非常少

Tabelle 9.6: 无教学条件下未确认为已完成的步骤。

P	未确认的步骤
P01	S09, S12, S18, S19, S20, S22, S24, S27, S29, S31
P02	S02, S14, S18, S19, S27, S30
P03	S07, S09, S16, S18, S19, S26, S27, S29, S32
P06	S07, S18, S19, S27
P07	S02, S09, S12, S13, S16, S17, S18, S19, S22, S26, S27, S28, S29, S32

S18（右侧 DDI 上的 FCS-MC BIT 页面）和 S19（FCS BIT 最终 GO 结果）在所有五个无教学导出行中保持未确认，且属于视觉优先的显示检查。这并不意味着所有五名参与者均遗漏了这两个动作。动作时间线审查发现所有五名无教学参与者存在右侧-DDI PB5 活动，P02、P03、P06 和 P07 存在 FCS BIT 开关向上活动。剩余不确定性在于页面转换和最终 GO 结果是否在视觉上出现，因为被动无教学导出未运行教学试验使用的 VLM/页面检查。S27（襟翼开关到 AUTO）同样在所有五行中未确认，但程序包将其分类为遥测优先，具有变量和门控证据而非 VLM 绑定的视觉证据。因此，该表是导出确认表，而非直接的遗漏表。

Tabelle 9.7: 逐参与者的自动编码 vs. 人工错误计数。

P	条件	自动 OM	自动 CO	人工 OM	人工 CO	人工总计
P01	无教学	4	3	8	0	10
P02	无教学	0	3	0	0	1
P03	无教学	0	4	7	0	11
P06	无教学	0	3	2	0	4
P07	无教学	1	9	11	0	11
P04	有教学	0	4	0	3	7
P05	有教学	0	3	0	3	6
P08	有教学	0	3	0	0	0
P09	有教学	0	3	0	3	5

自动编码错误来自自动化流水线 (`step_coding.csv` 中的 `Auto_Error_*` 列)。人工错误来自人工审查列 (`Error_*`)。P08 的自动错误在人工审查中全部被覆盖为零 (见第 6.3 节的数据质量注释)。

Tabelle 9.8: 补充先导实验数据质量权威规则。

案例	数据质量问题	权威规则	报告用途
P08	<code>trial_summary.csv</code> 报告不完整进展, 而审查后的 <code>step_coding.csv</code> 标记全部 33 步完成。	人工遥测审查和审查后的步骤编码列覆盖自动试验摘要。	报告为 33/33 完成, 零人工程序错误。
P02	问卷 JSON 存储在 P02 下, 但包含 P01 参与者 ID 元数据不匹配。	任务日志仍可用; 问卷推送字段被排除。	纳入任务和错误表; 排除于 TLX、评分和评论汇总。
P07	无教学问卷包含教学特定数值字段, 即便教学特定 NA 标志为 <code>true</code> 。	条件和 NA 标志覆盖原始教学特定数值字段。	通用用户评分保留; 教学评分报告为 N/A。
P04	质量门控元数据包含非阻塞性链接警告。	保留人工任务指标和帮助周期计数; 不过度解读受影响的链接字段。	纳入试验概览, 附溯源说明。